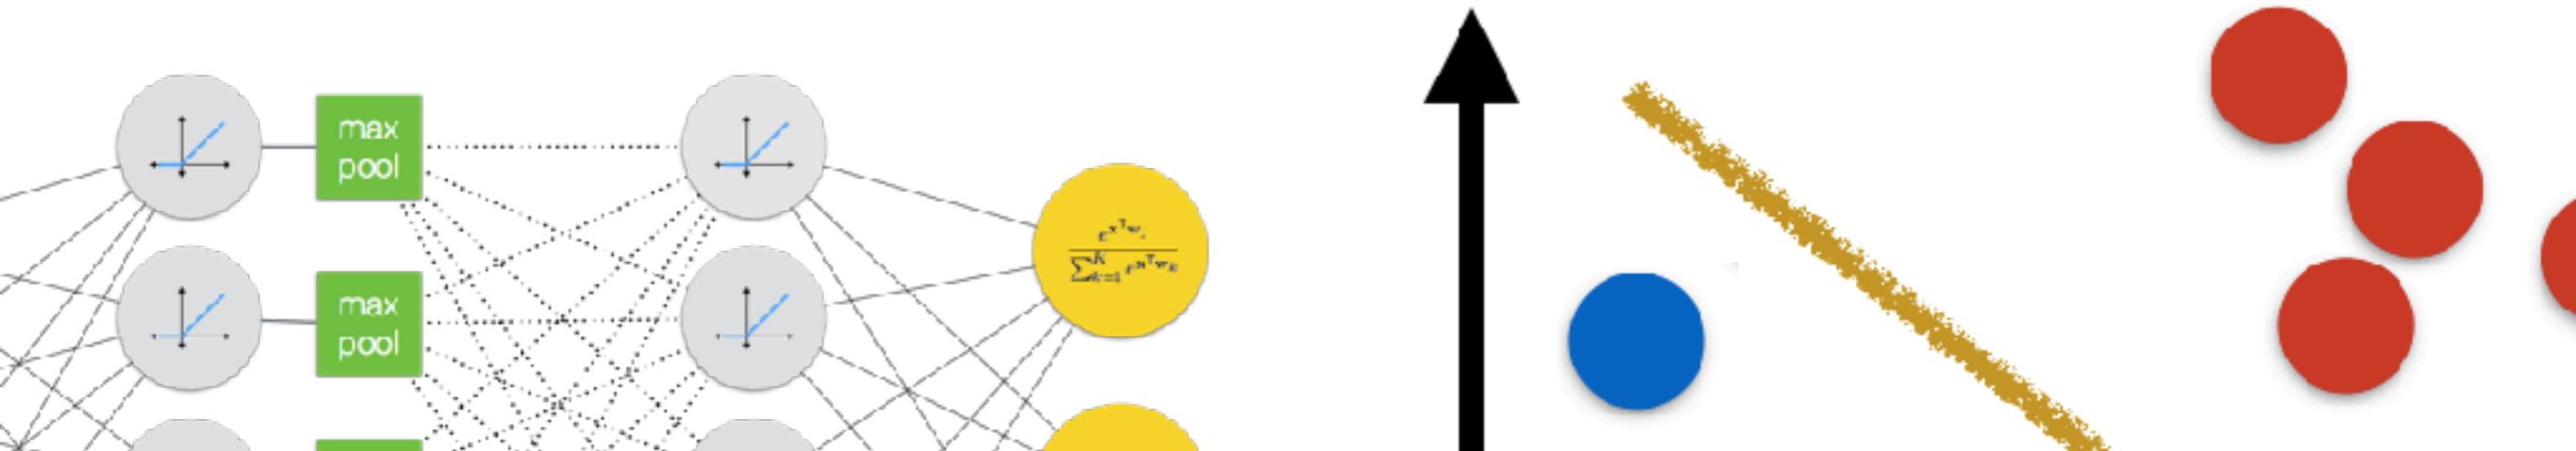
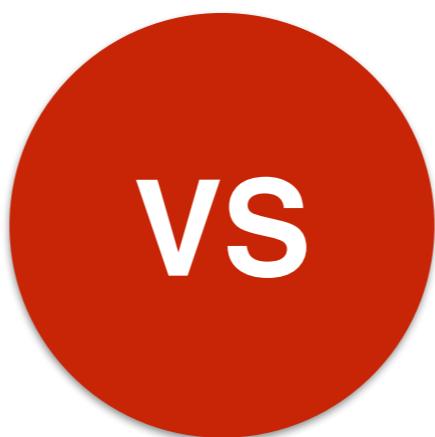


Escola Regional Itinerante - ERI SP OESTE

Introdução a
Deep Learning



Inteligência Artificial



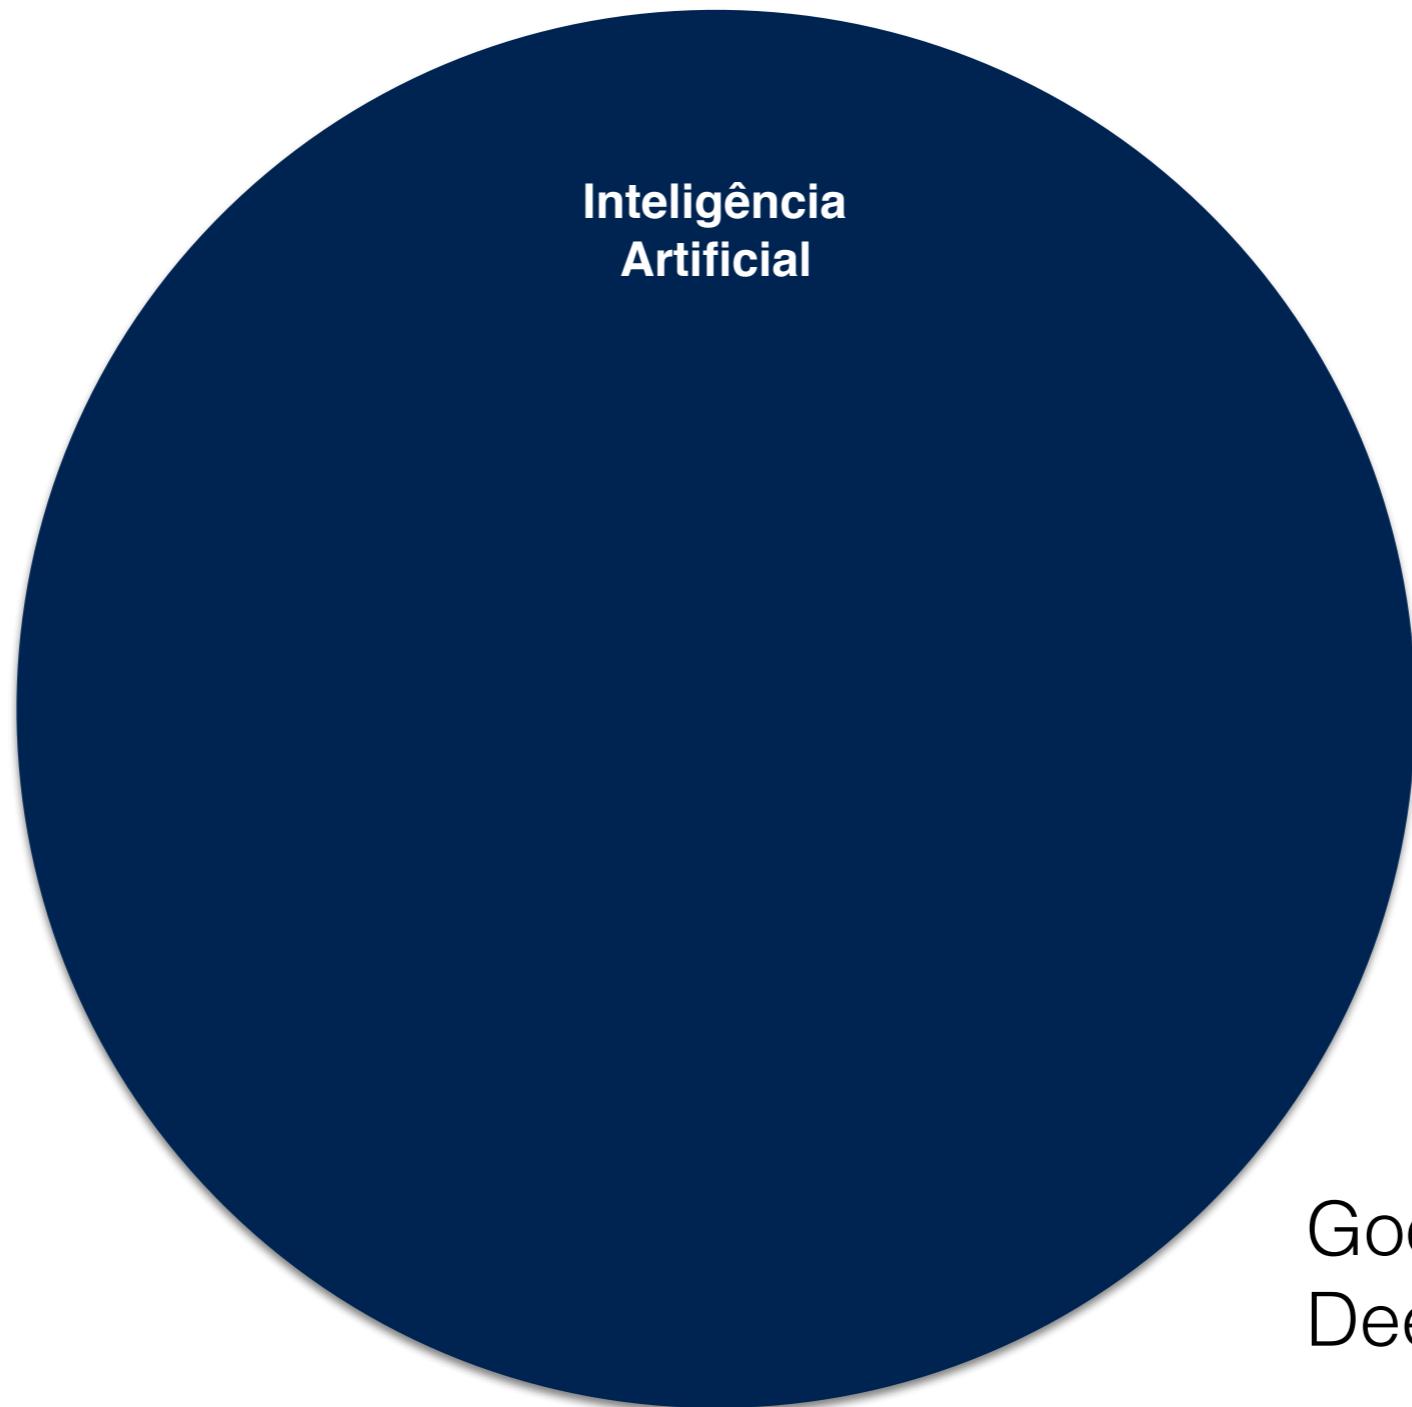
Aprendizado de Máquina

É um pouco mais
complicado que isso

As subáreas de IA

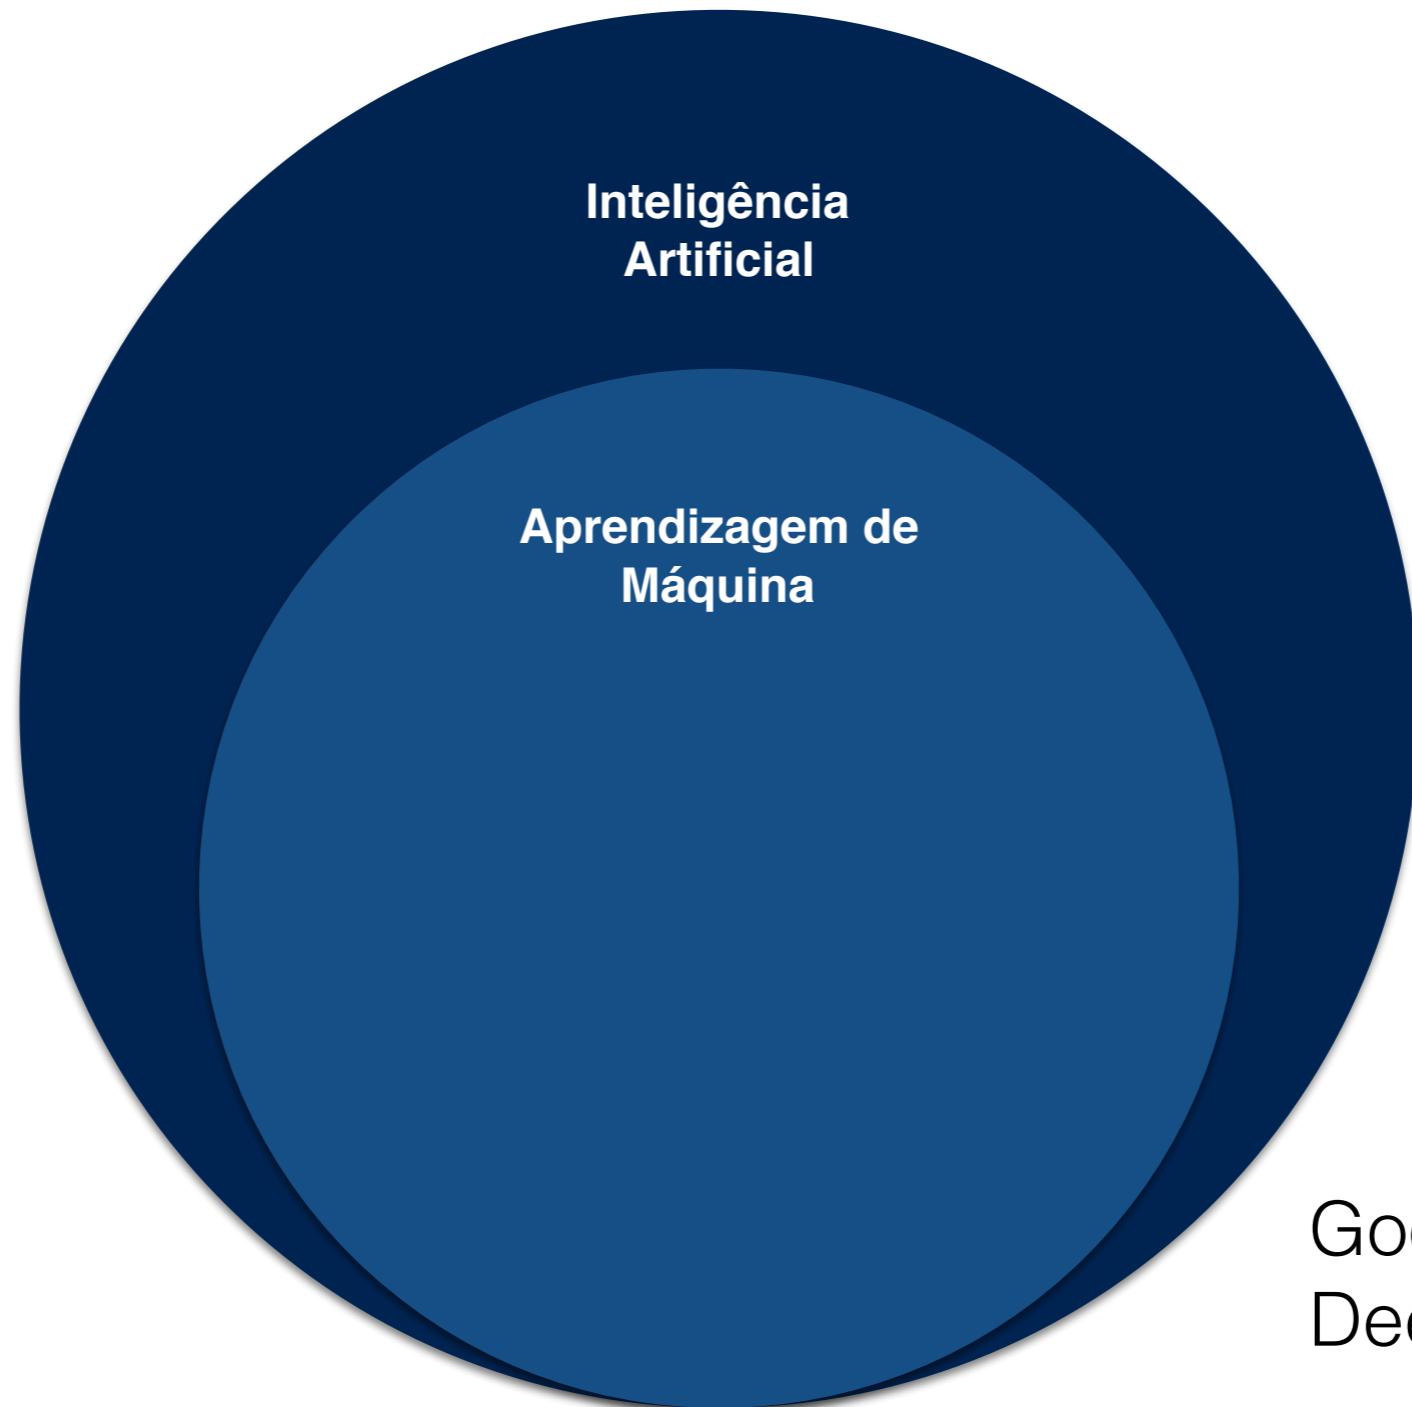
Goodfellow *et al*
Deep Learning Book

As subáreas de IA



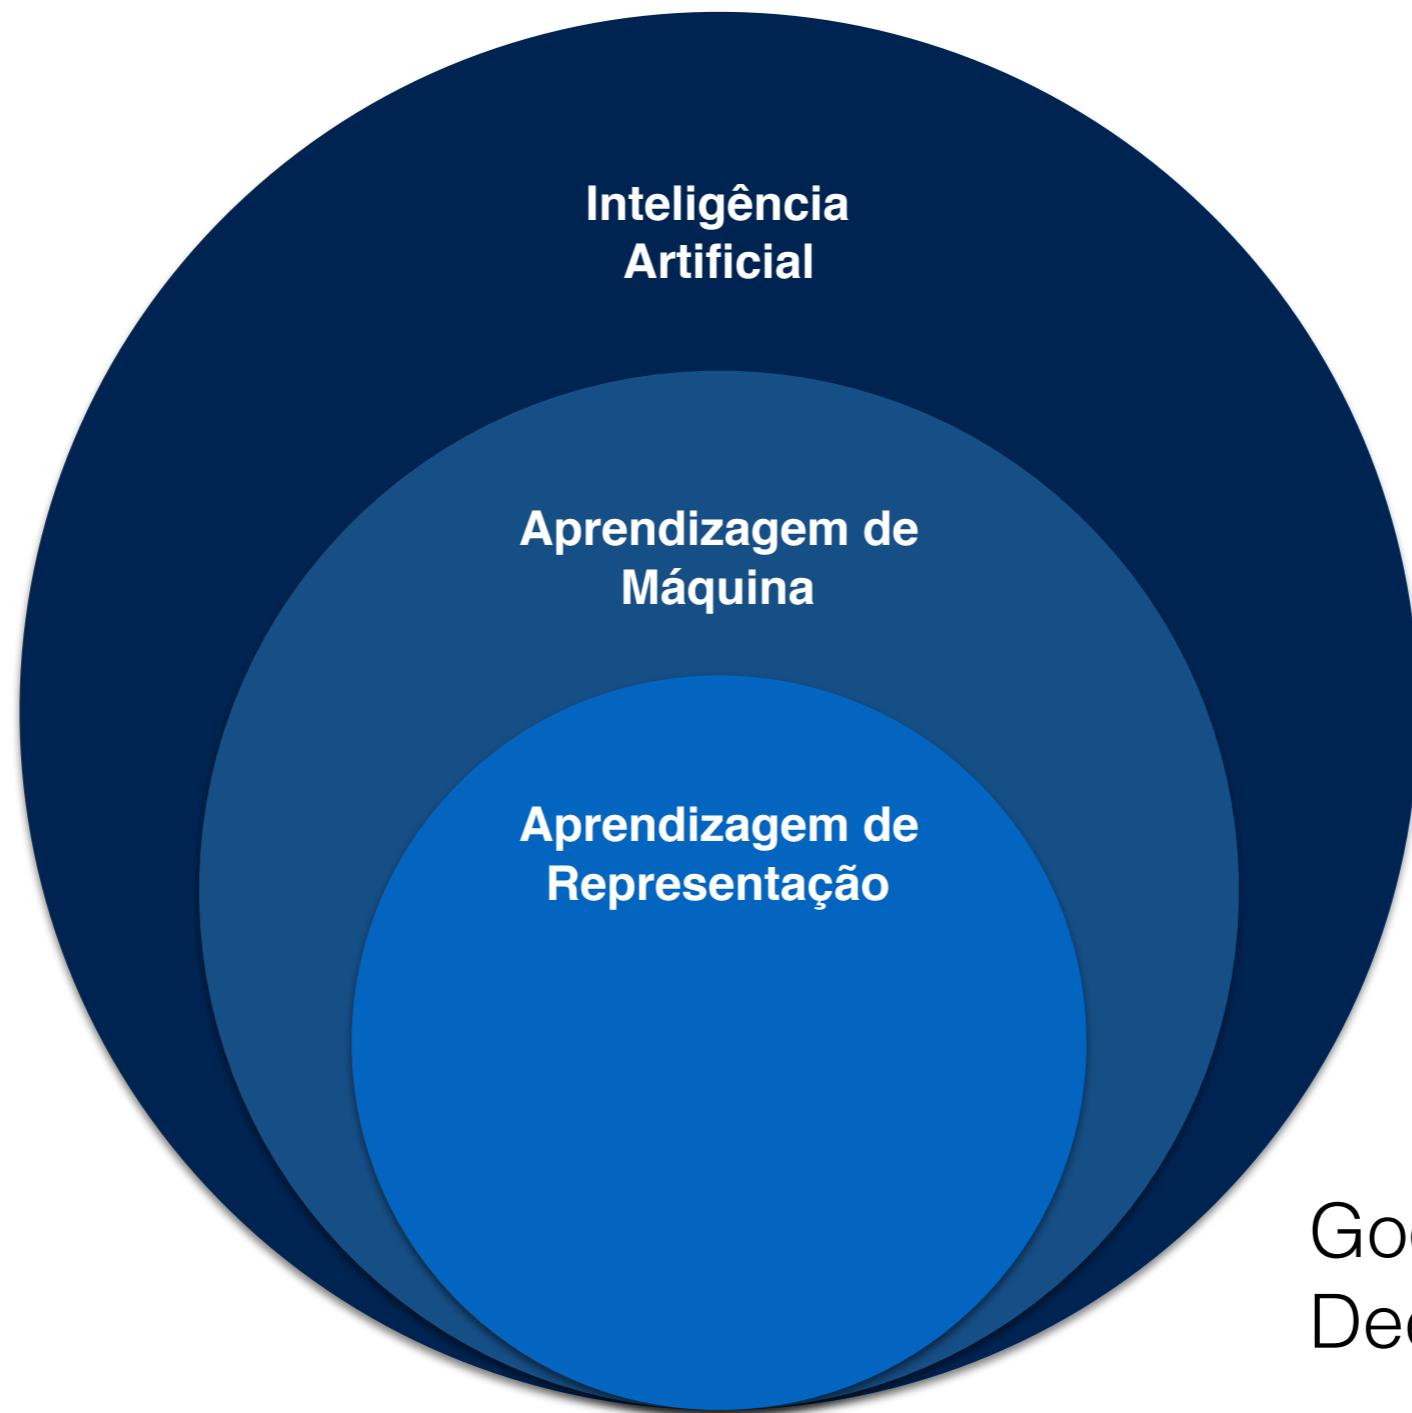
Goodfellow *et al*
Deep Learning Book

As subáreas de IA



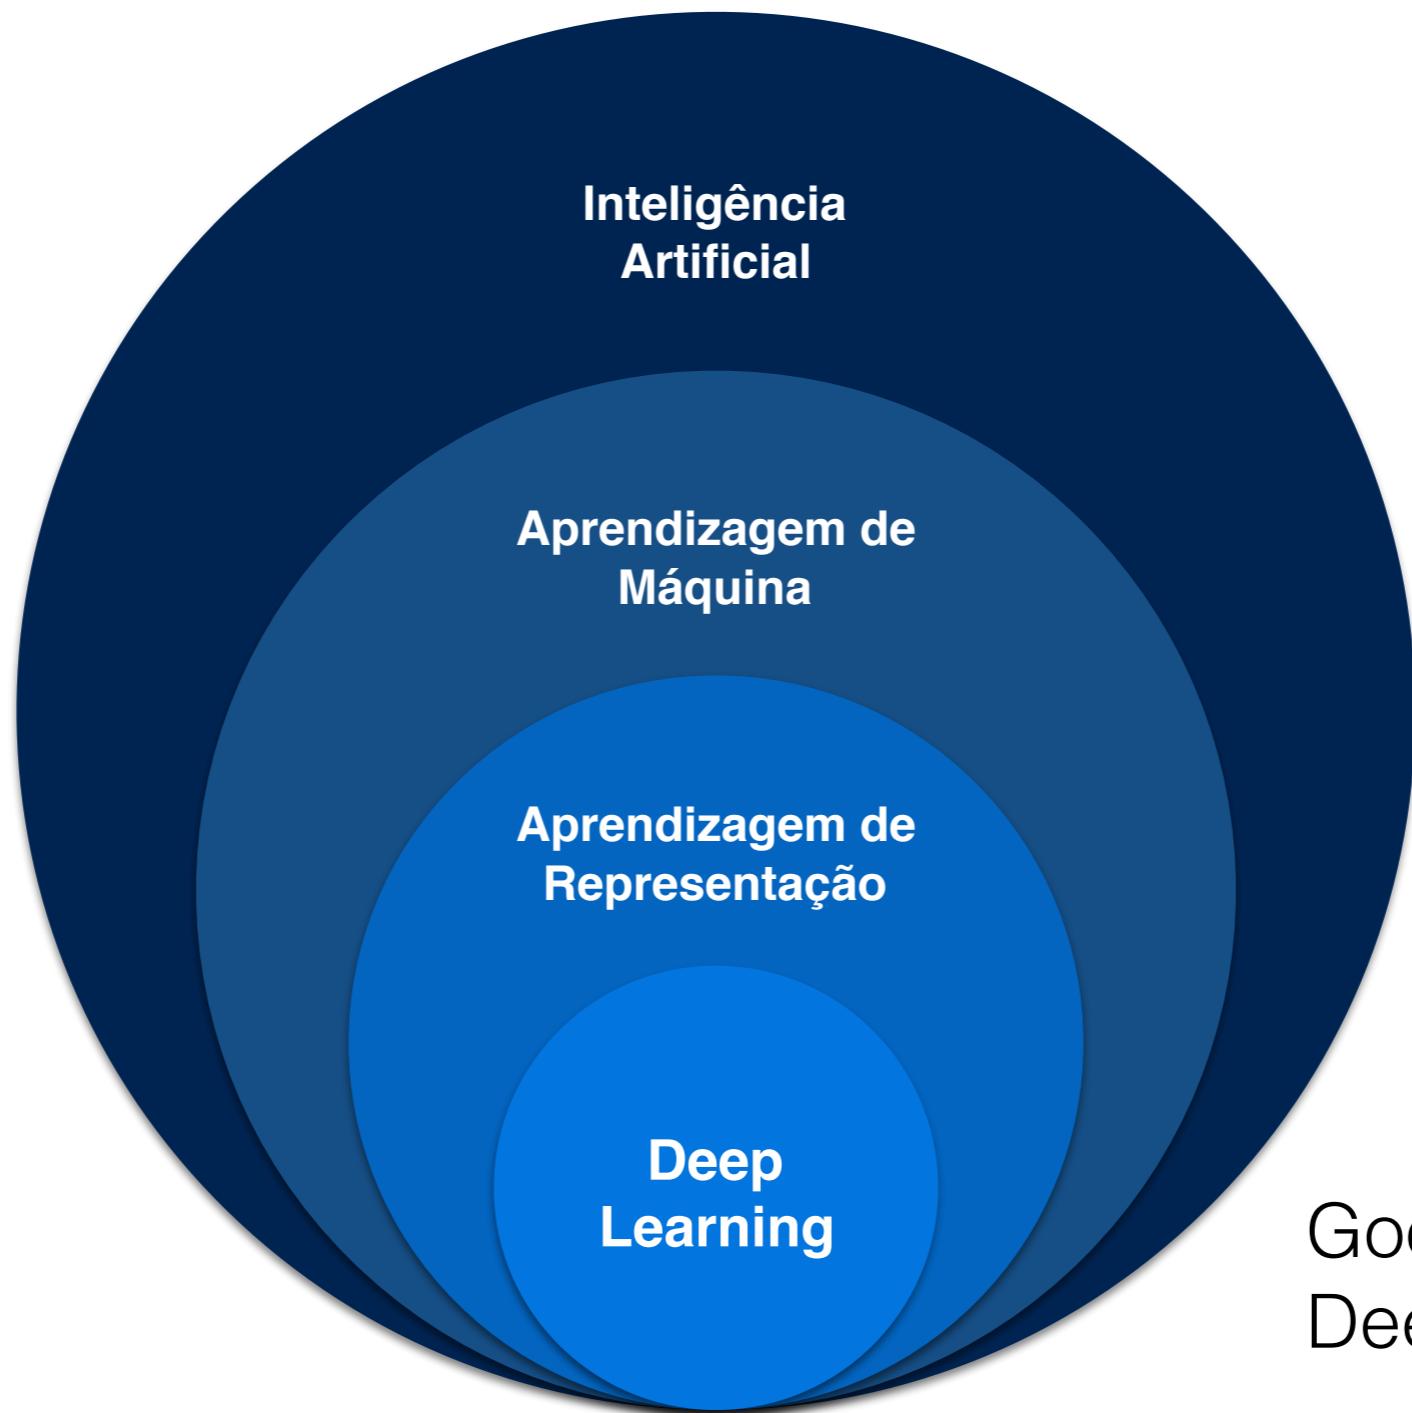
Goodfellow *et al*
Deep Learning Book

As subáreas de IA



Goodfellow *et al*
Deep Learning Book

As subáreas de IA



Goodfellow *et al*
Deep Learning Book

Cronograma da Apresentação

Inteligência Artificial

Aprendizagem de Máquina

Aprendizagem de Representação

Deep Learning

Cronograma da Apresentação



Cronograma da Apresentação

Aprendizagem de
Máquina

Definição e
Conceitos
Principais

Função de Custo
e o Risco

História

Introdução a

Aprendizagem de Máquina



Aprendizagem de Máquina

Definição e Conceitos Principais



Aprendizagem de Máquina



"The field of study that gives computers the ability to learn without being explicitly programmed." (*Arthur Samuel*)

Aprendizagem de Máquina



"The field of study that gives computers the ability to learn without being explicitly programmed." (*Arthur Samuel*)

Arthur Samuel foi um dos pioneiros da área e emplacou a nomenclatura da sub-área de IA em 1959

Aprendizagem de Máquina

Pipeline

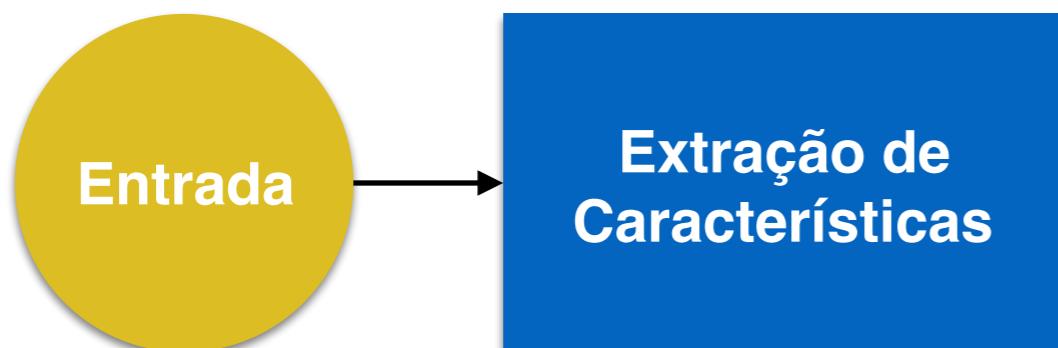
Aprendizagem de Máquina

Pipeline



Aprendizagem de Máquina

Pipeline



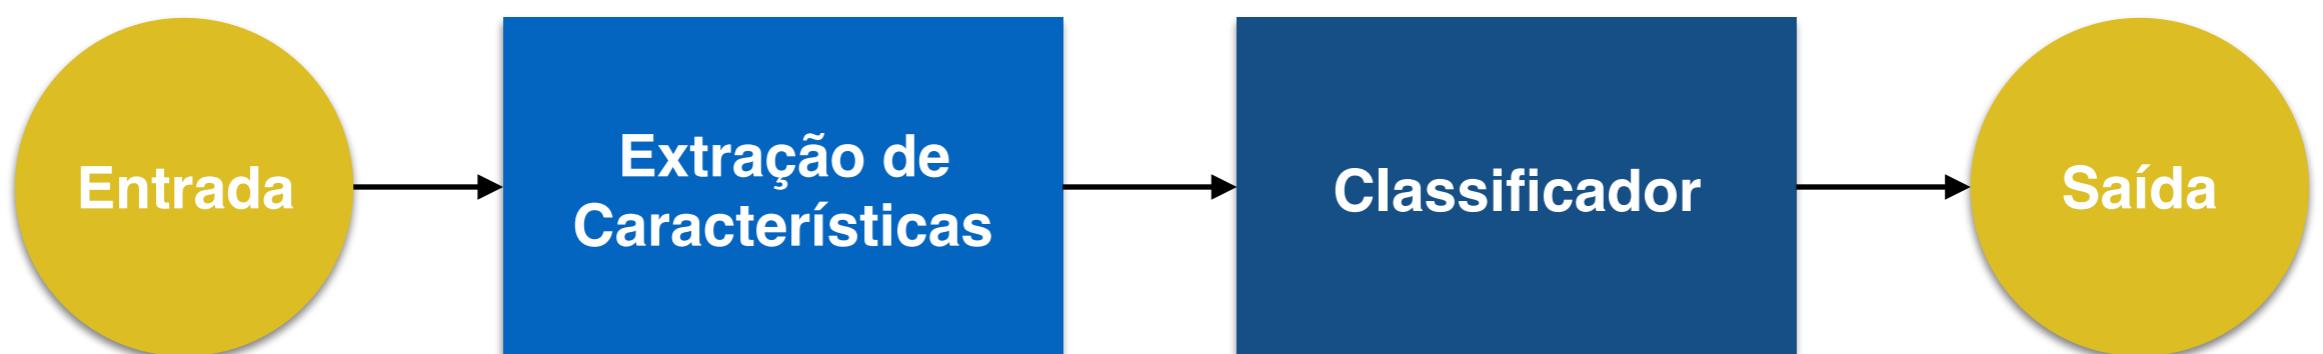
Aprendizagem de Máquina

Pipeline



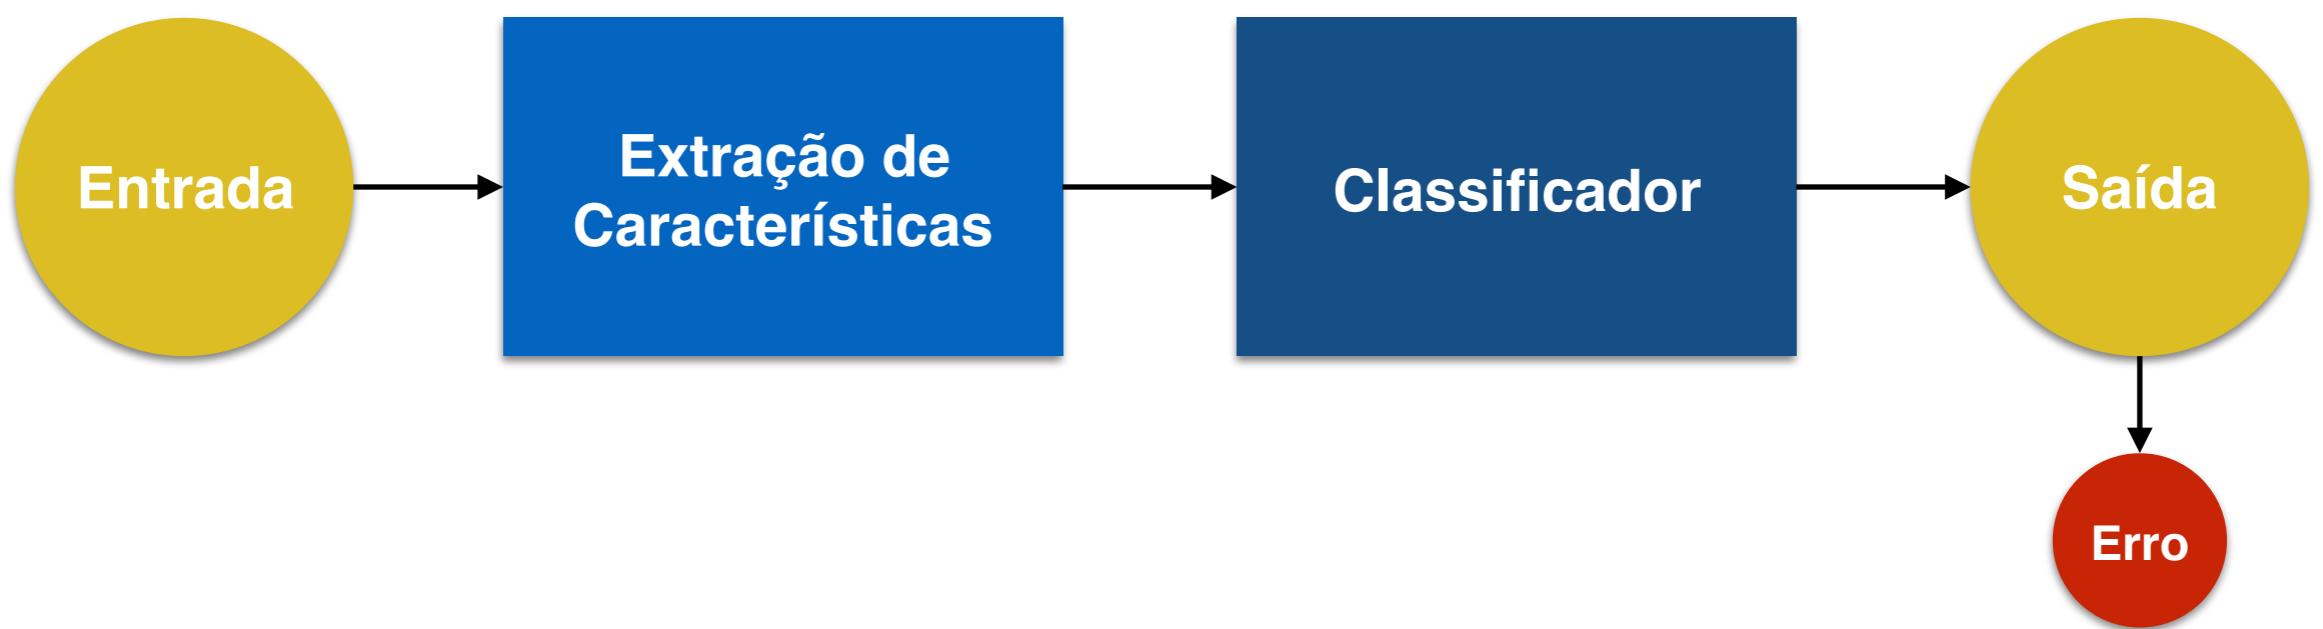
Aprendizagem de Máquina

Pipeline



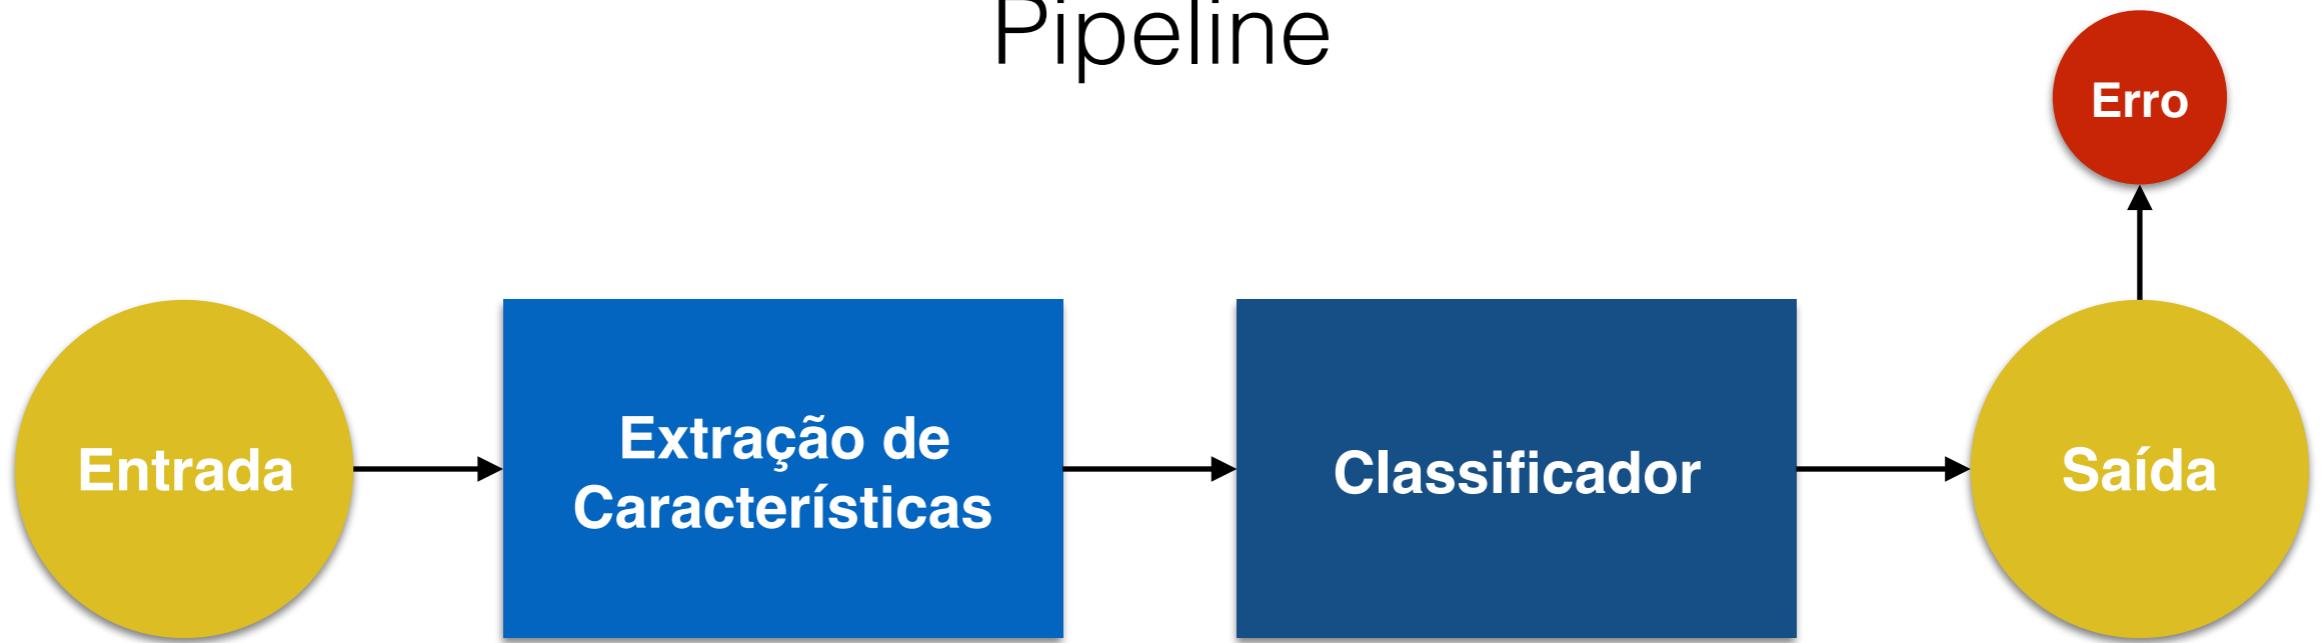
Aprendizagem de Máquina

Pipeline



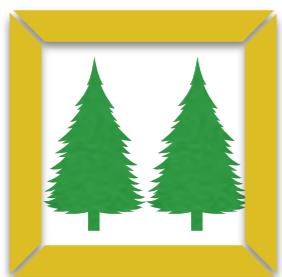
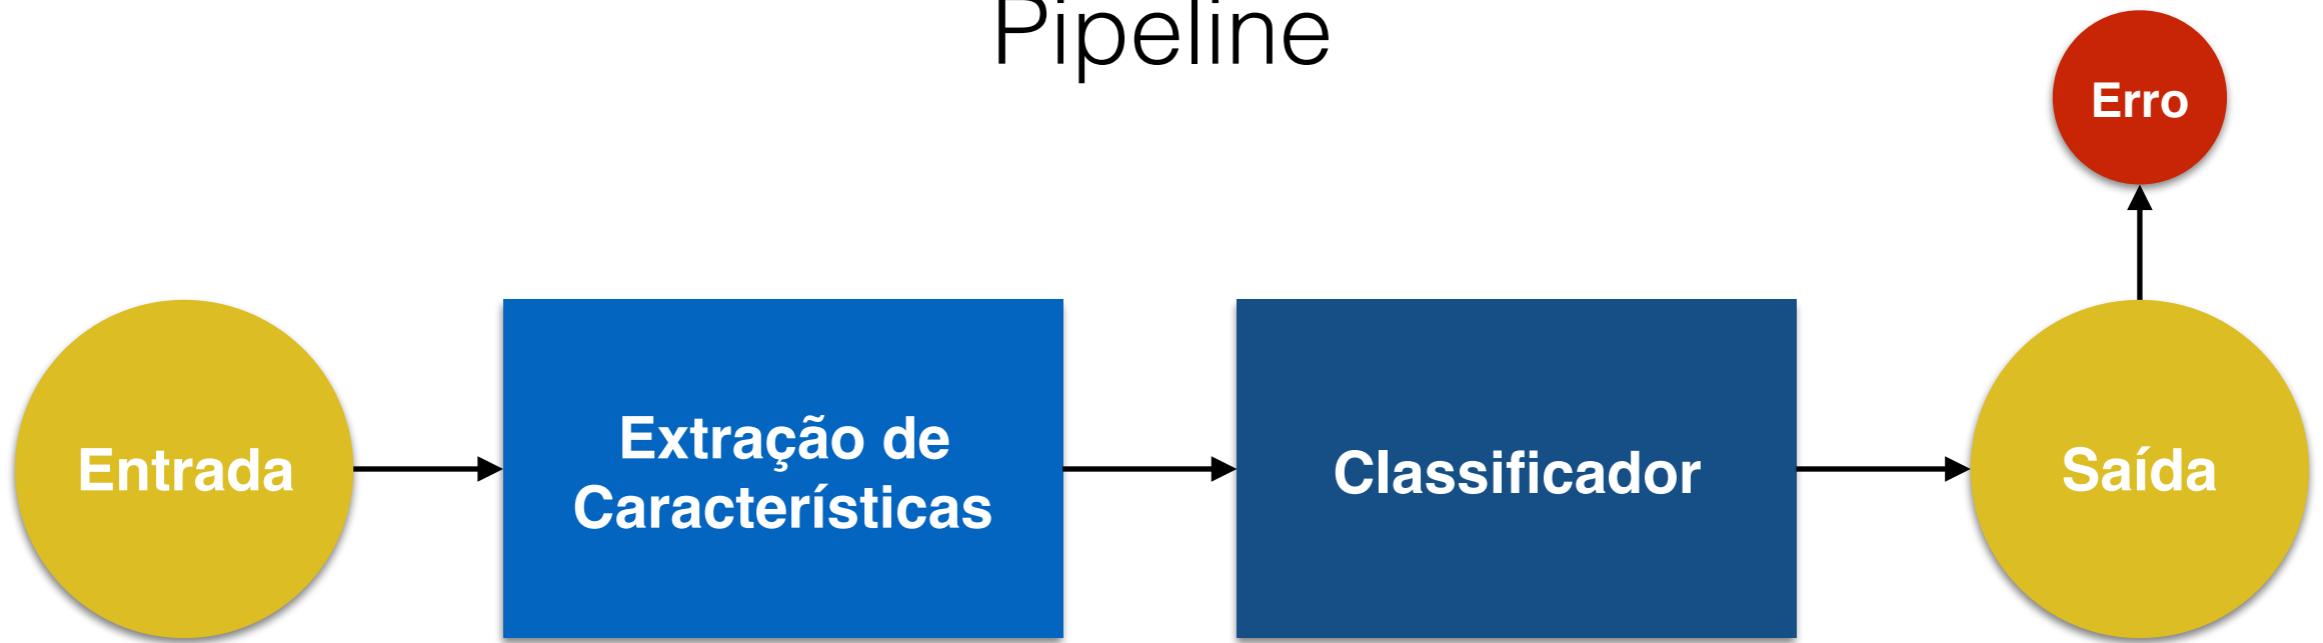
Aprendizagem de Máquina

Pipeline



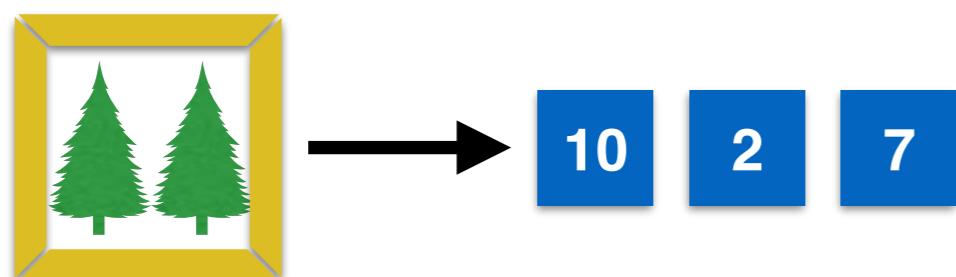
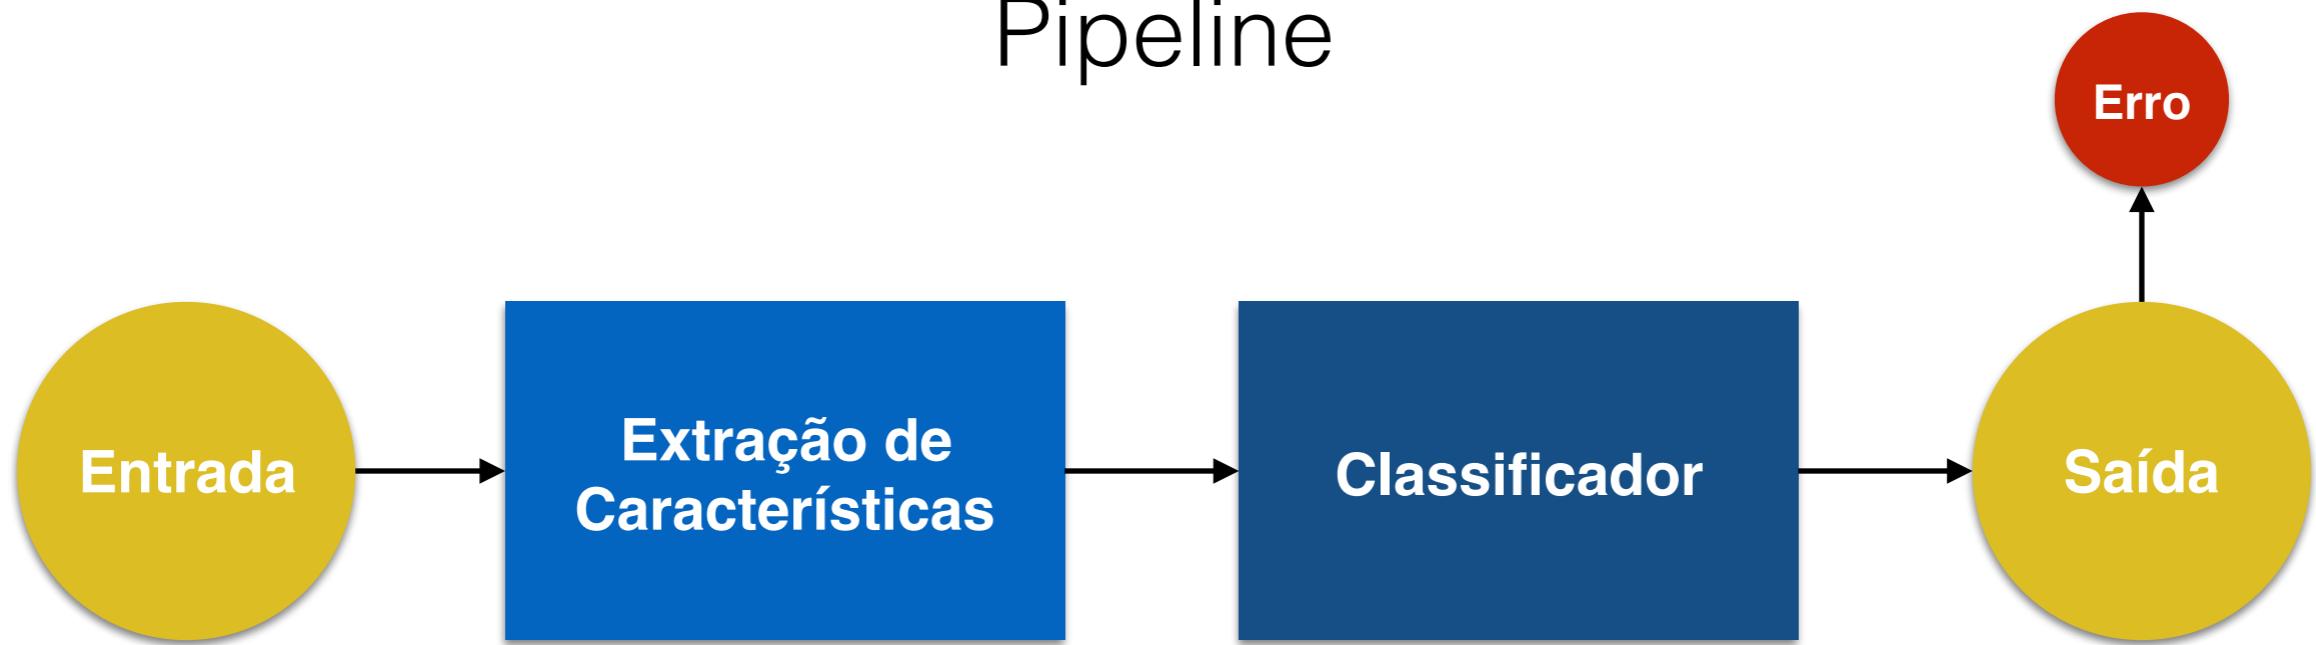
Aprendizagem de Máquina

Pipeline



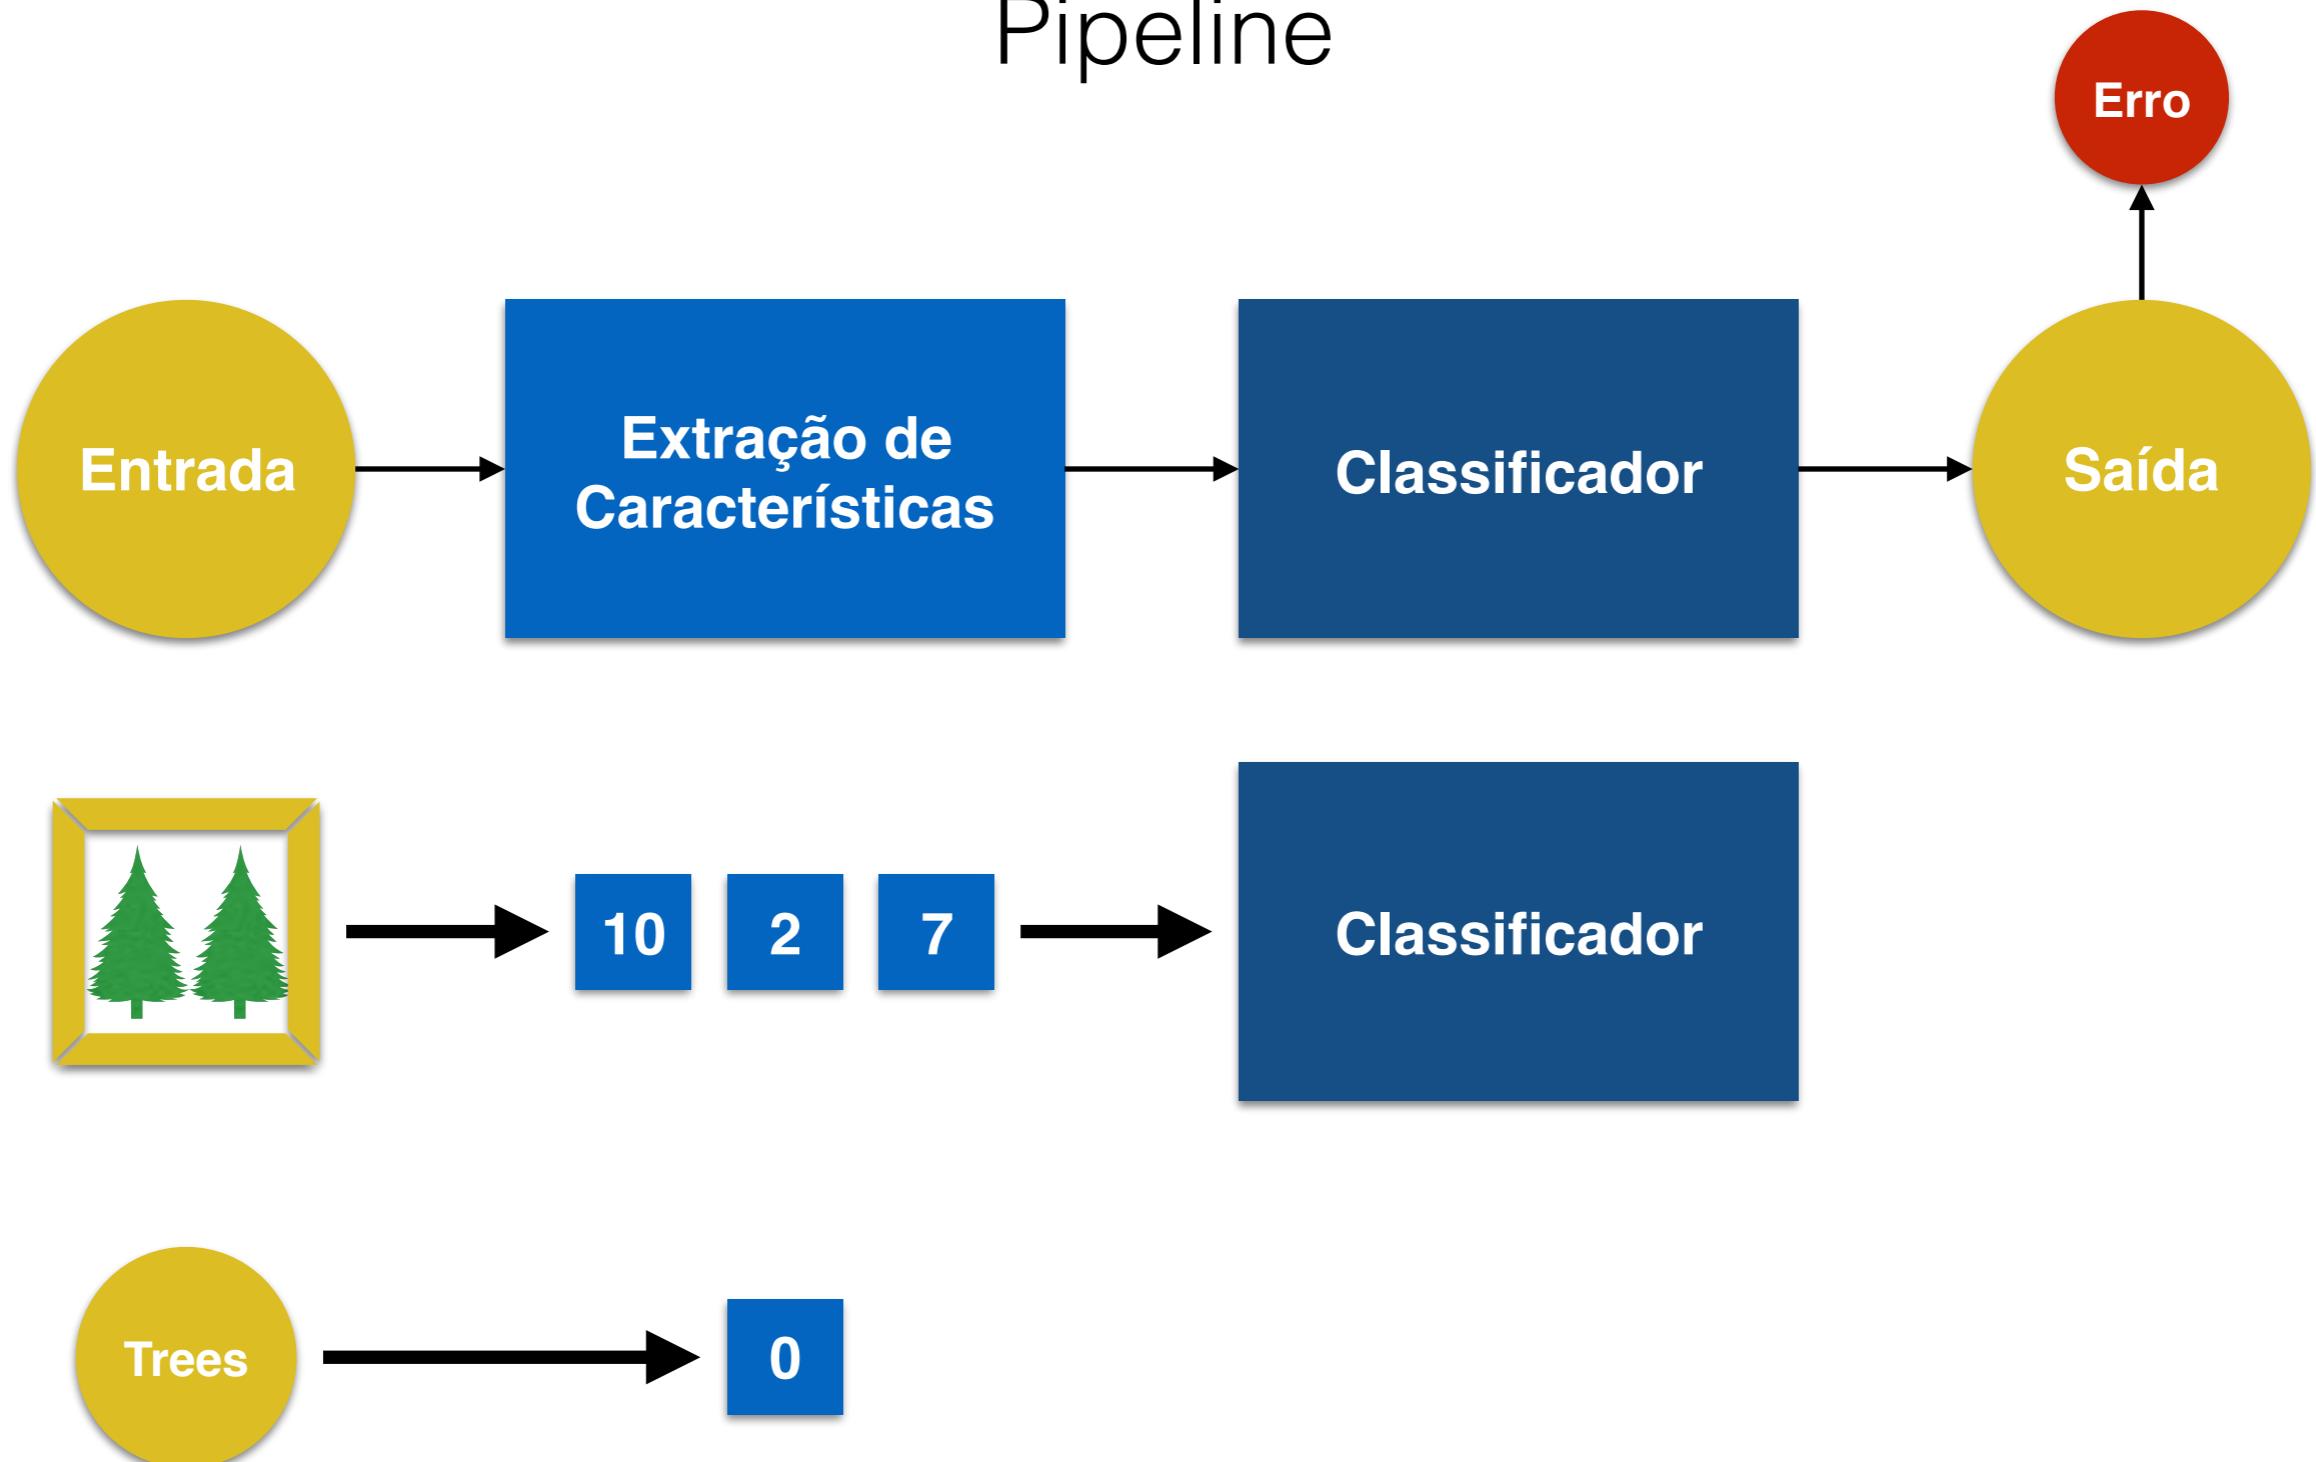
Aprendizagem de Máquina

Pipeline



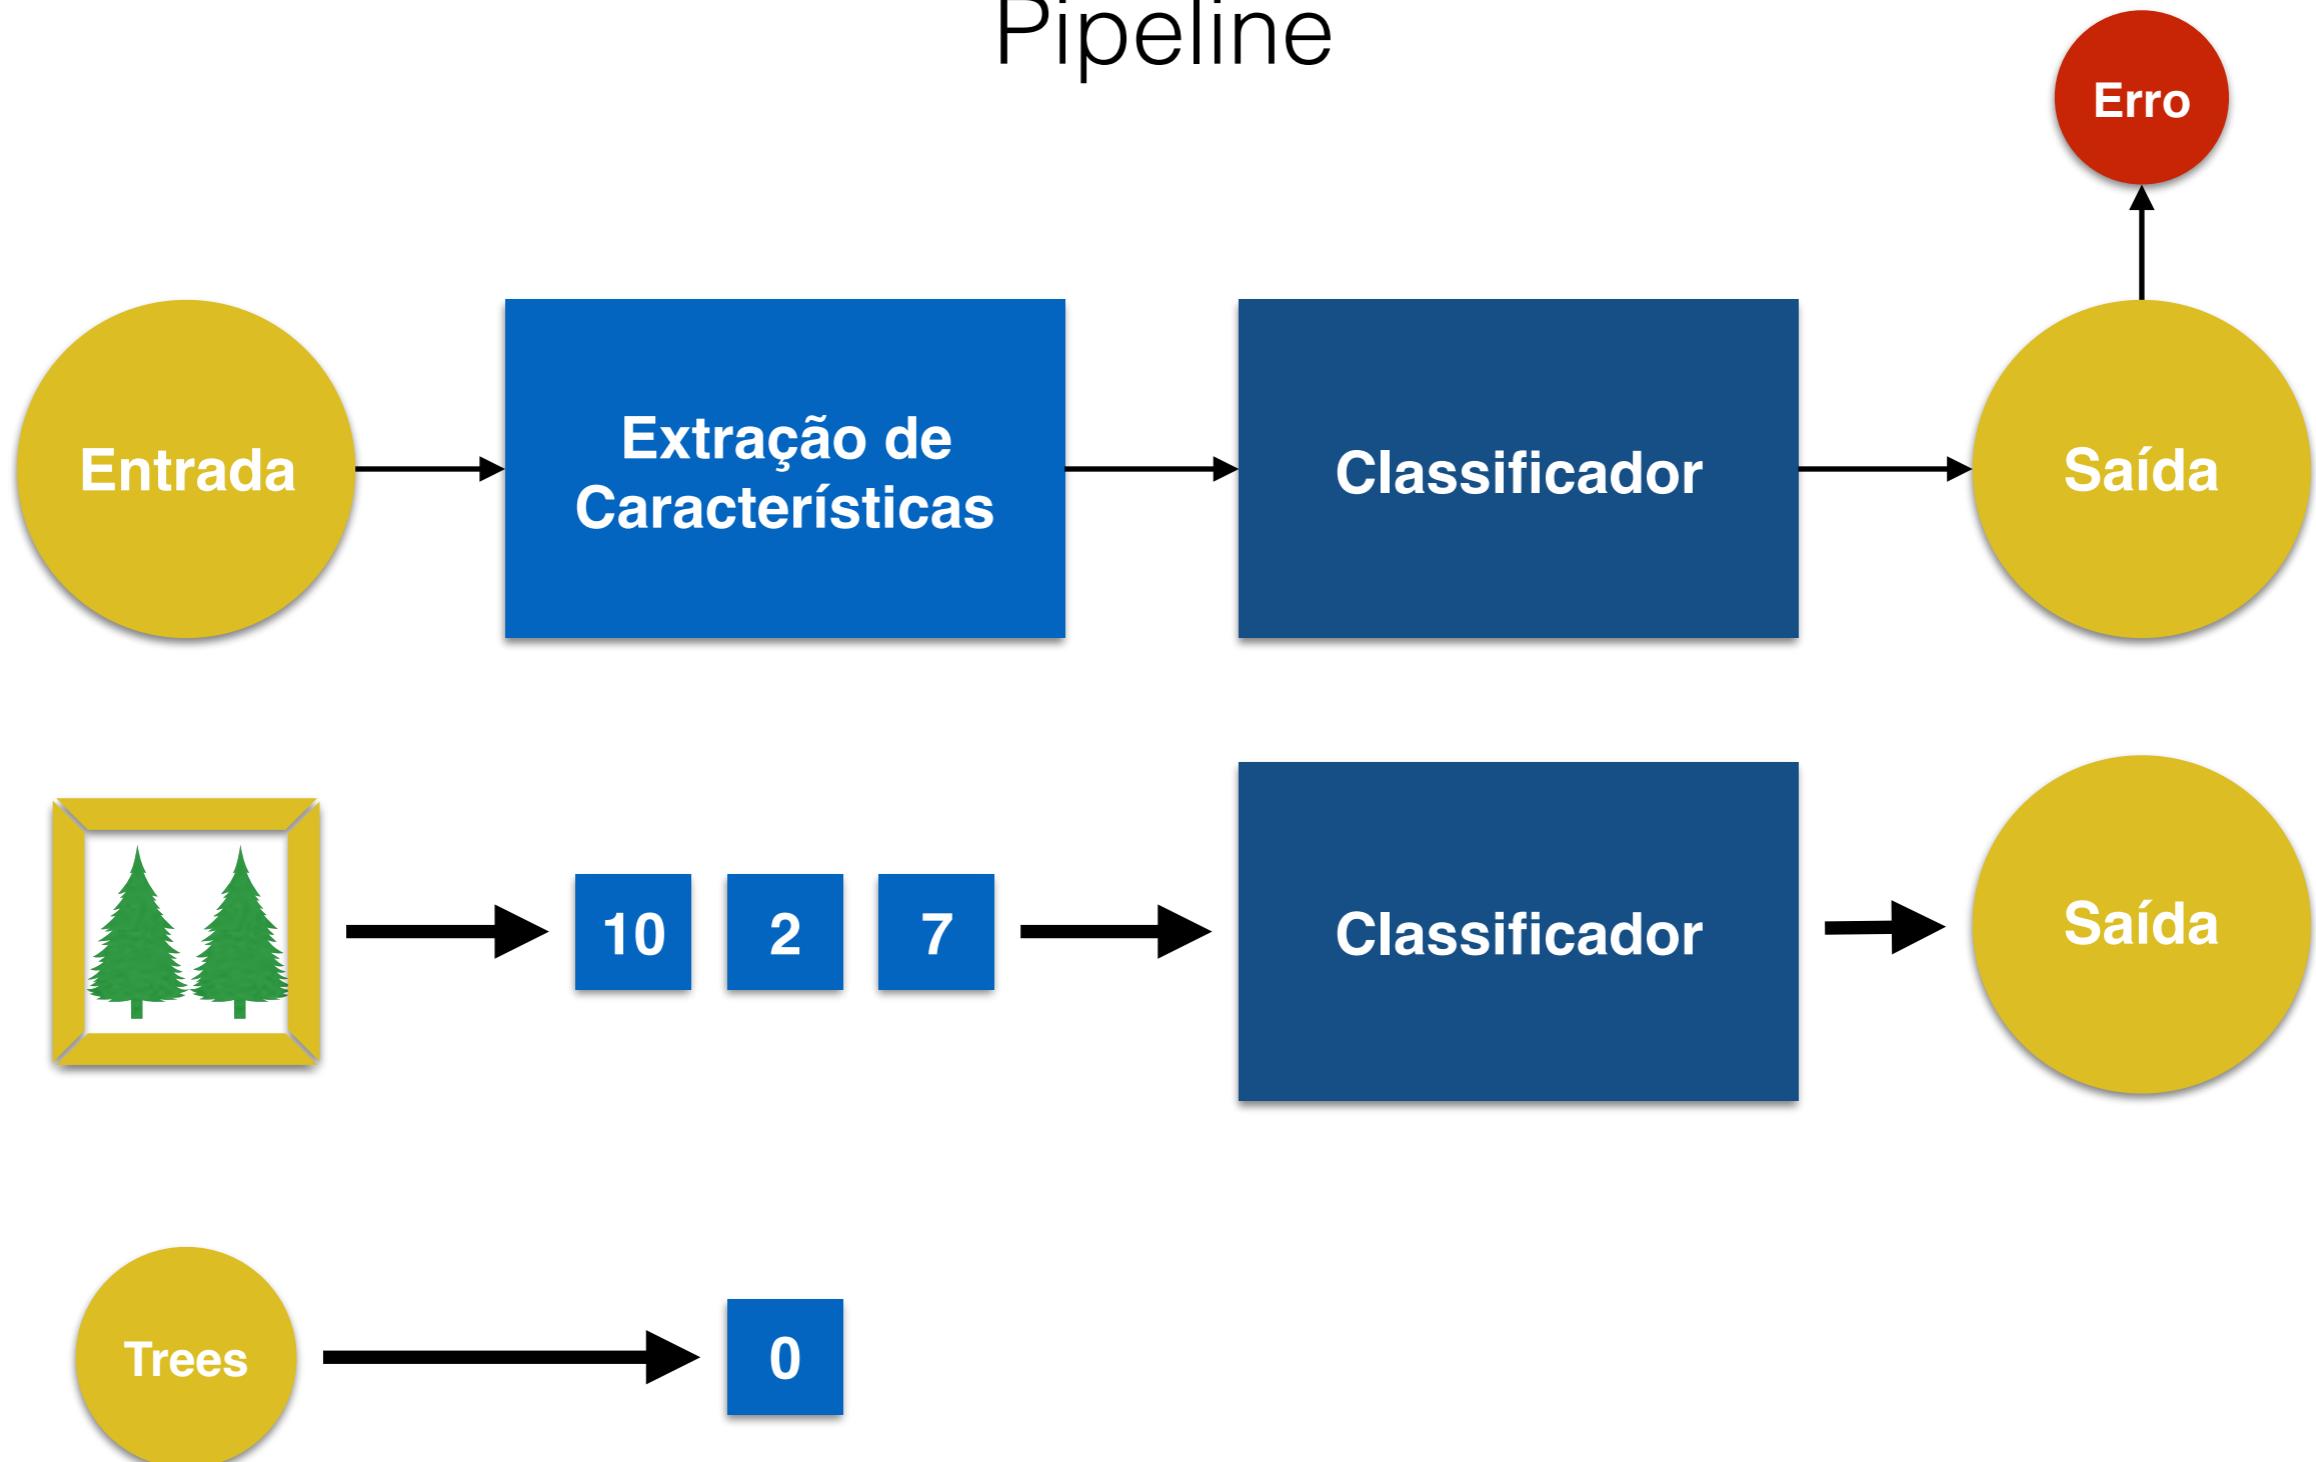
Aprendizagem de Máquina

Pipeline



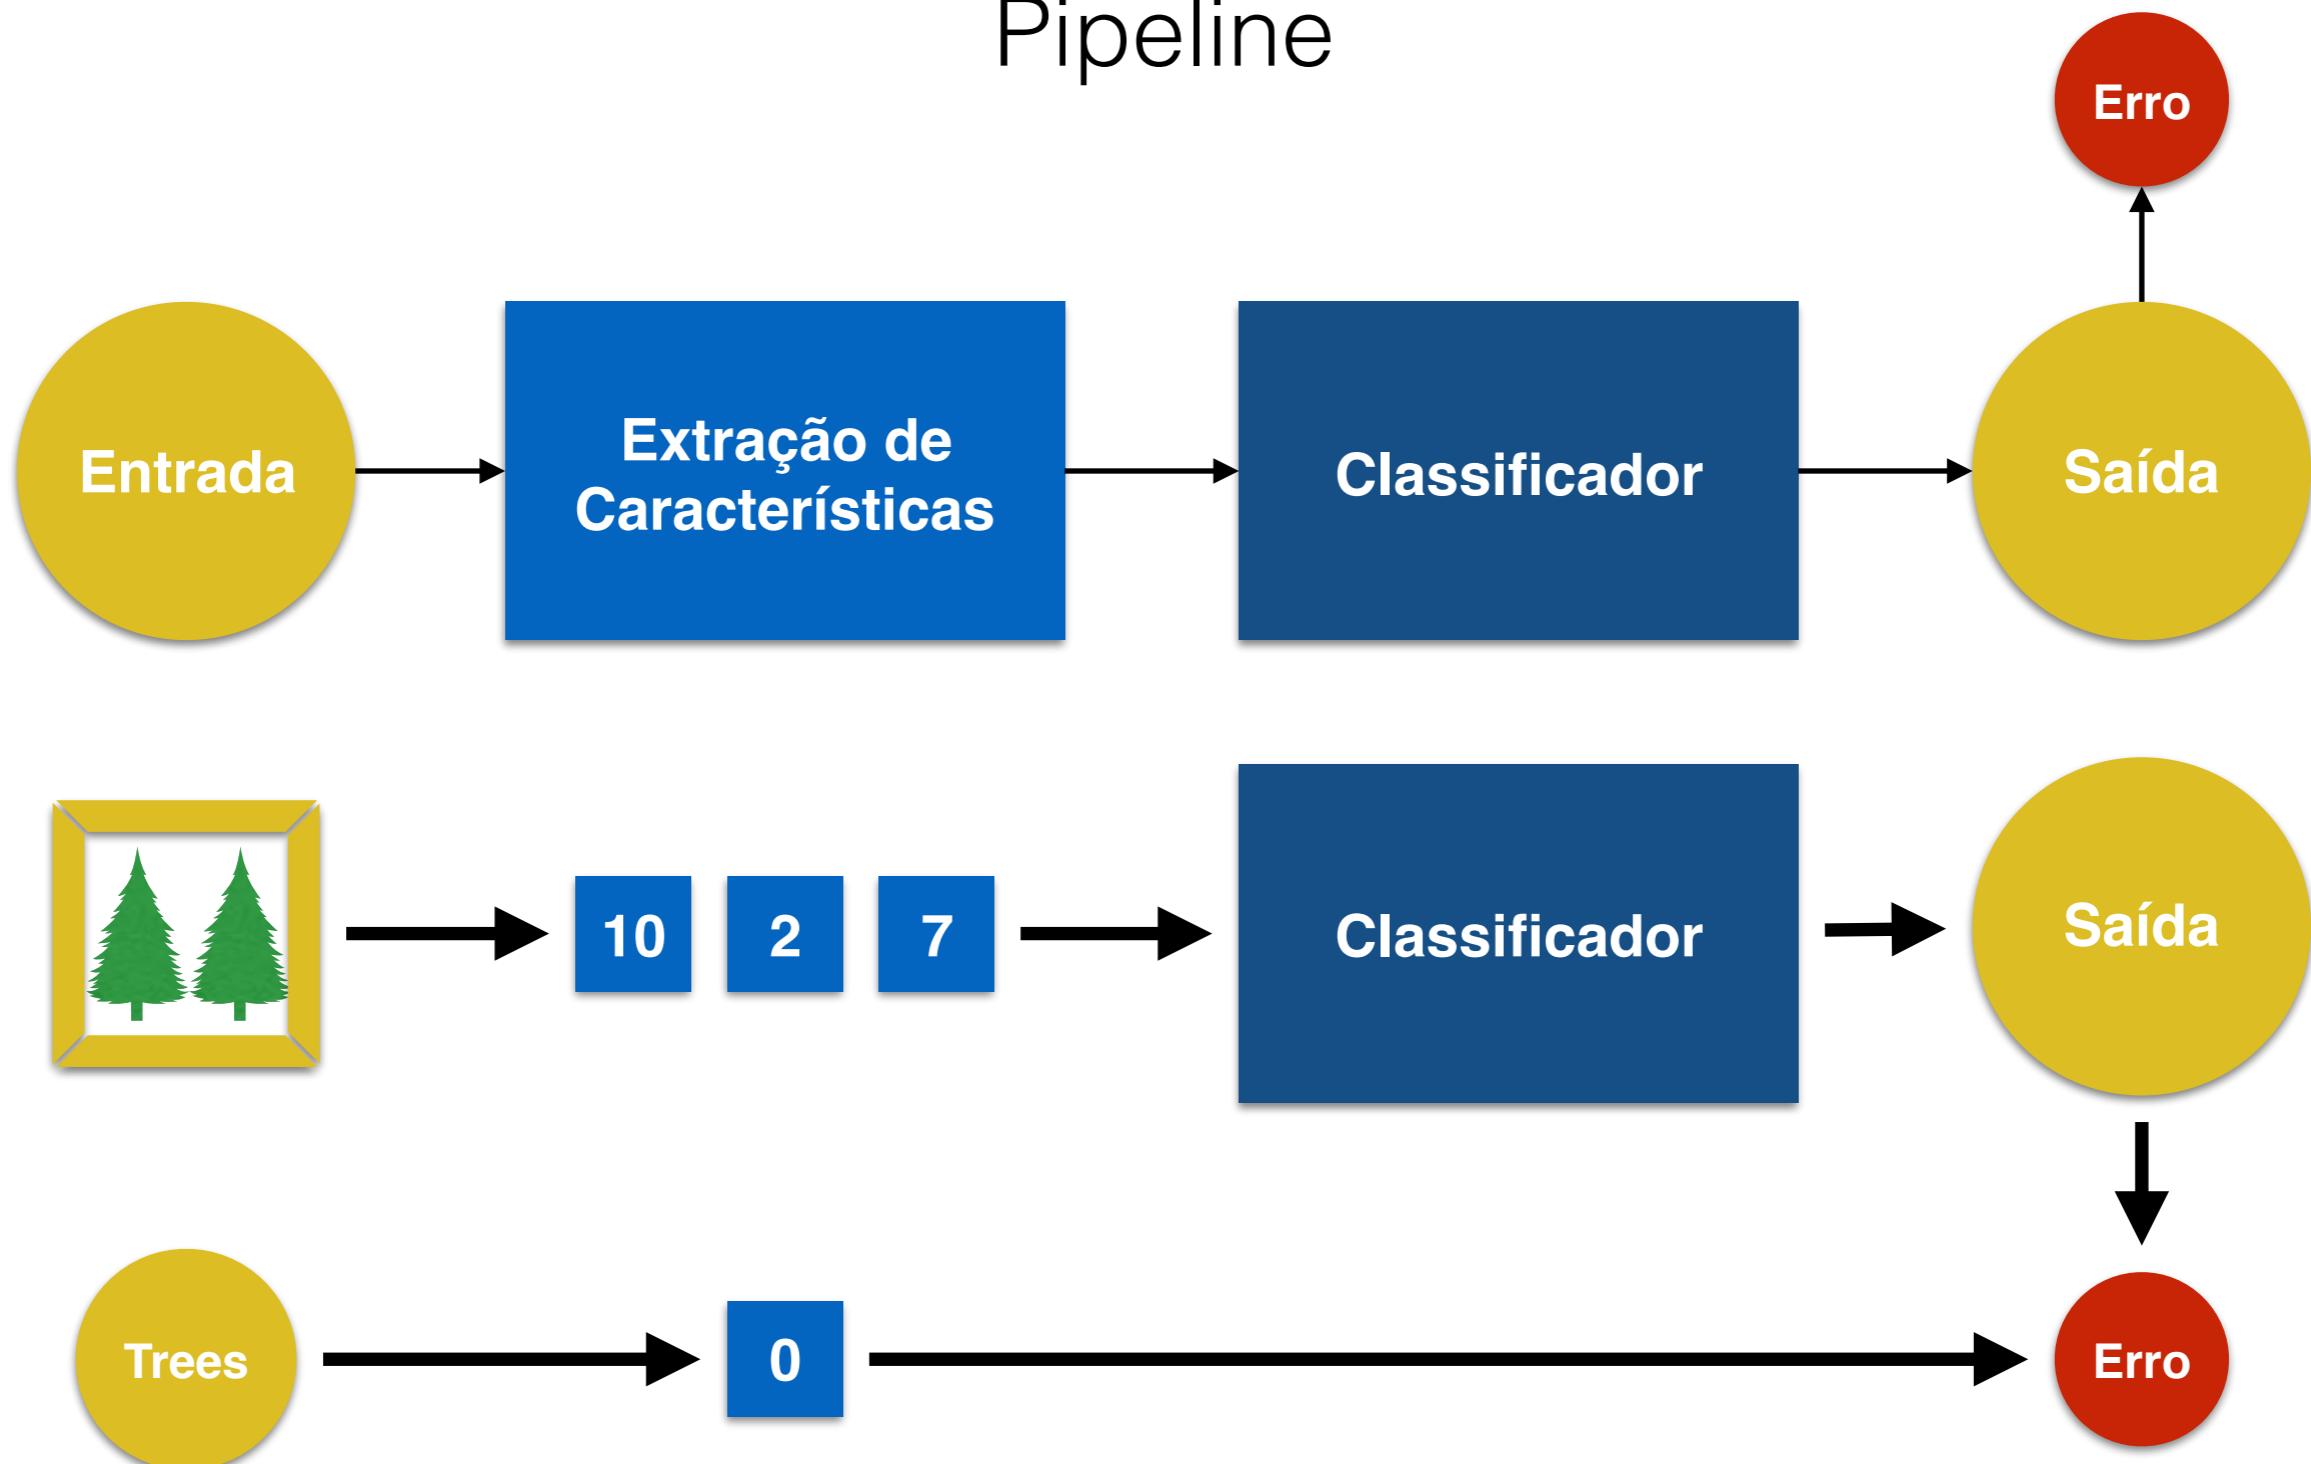
Aprendizagem de Máquina

Pipeline



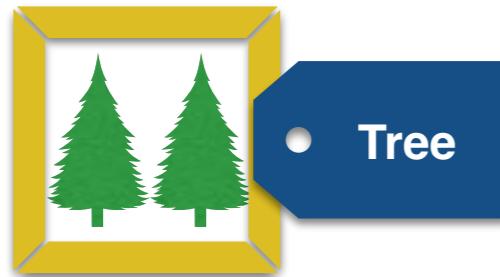
Aprendizagem de Máquina

Pipeline



Aprendizagem de Máquina

Pipeline



Usando Base de dados com muitos exemplos. Geramos melhores classificadores observando os erros iniciais

Aprendizagem de Máquina

Pipeline



Usando Base de dados com muitos exemplos. Geramos melhores classificadores observando os erros iniciais

Aprendizagem de Máquina

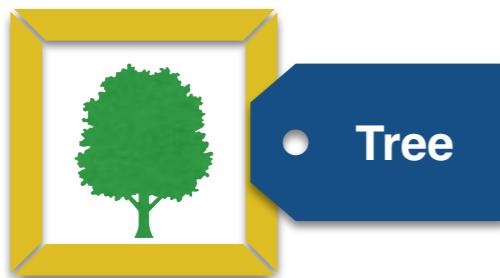
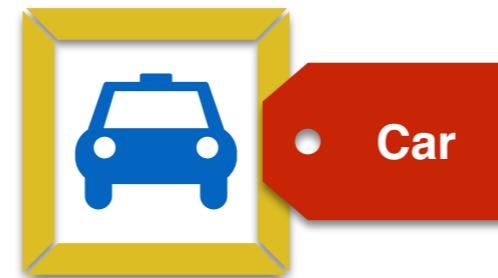
Pipeline



Usando Base de dados com muitos exemplos. Geramos melhores classificadores observando os erros iniciais

Aprendizagem de Máquina

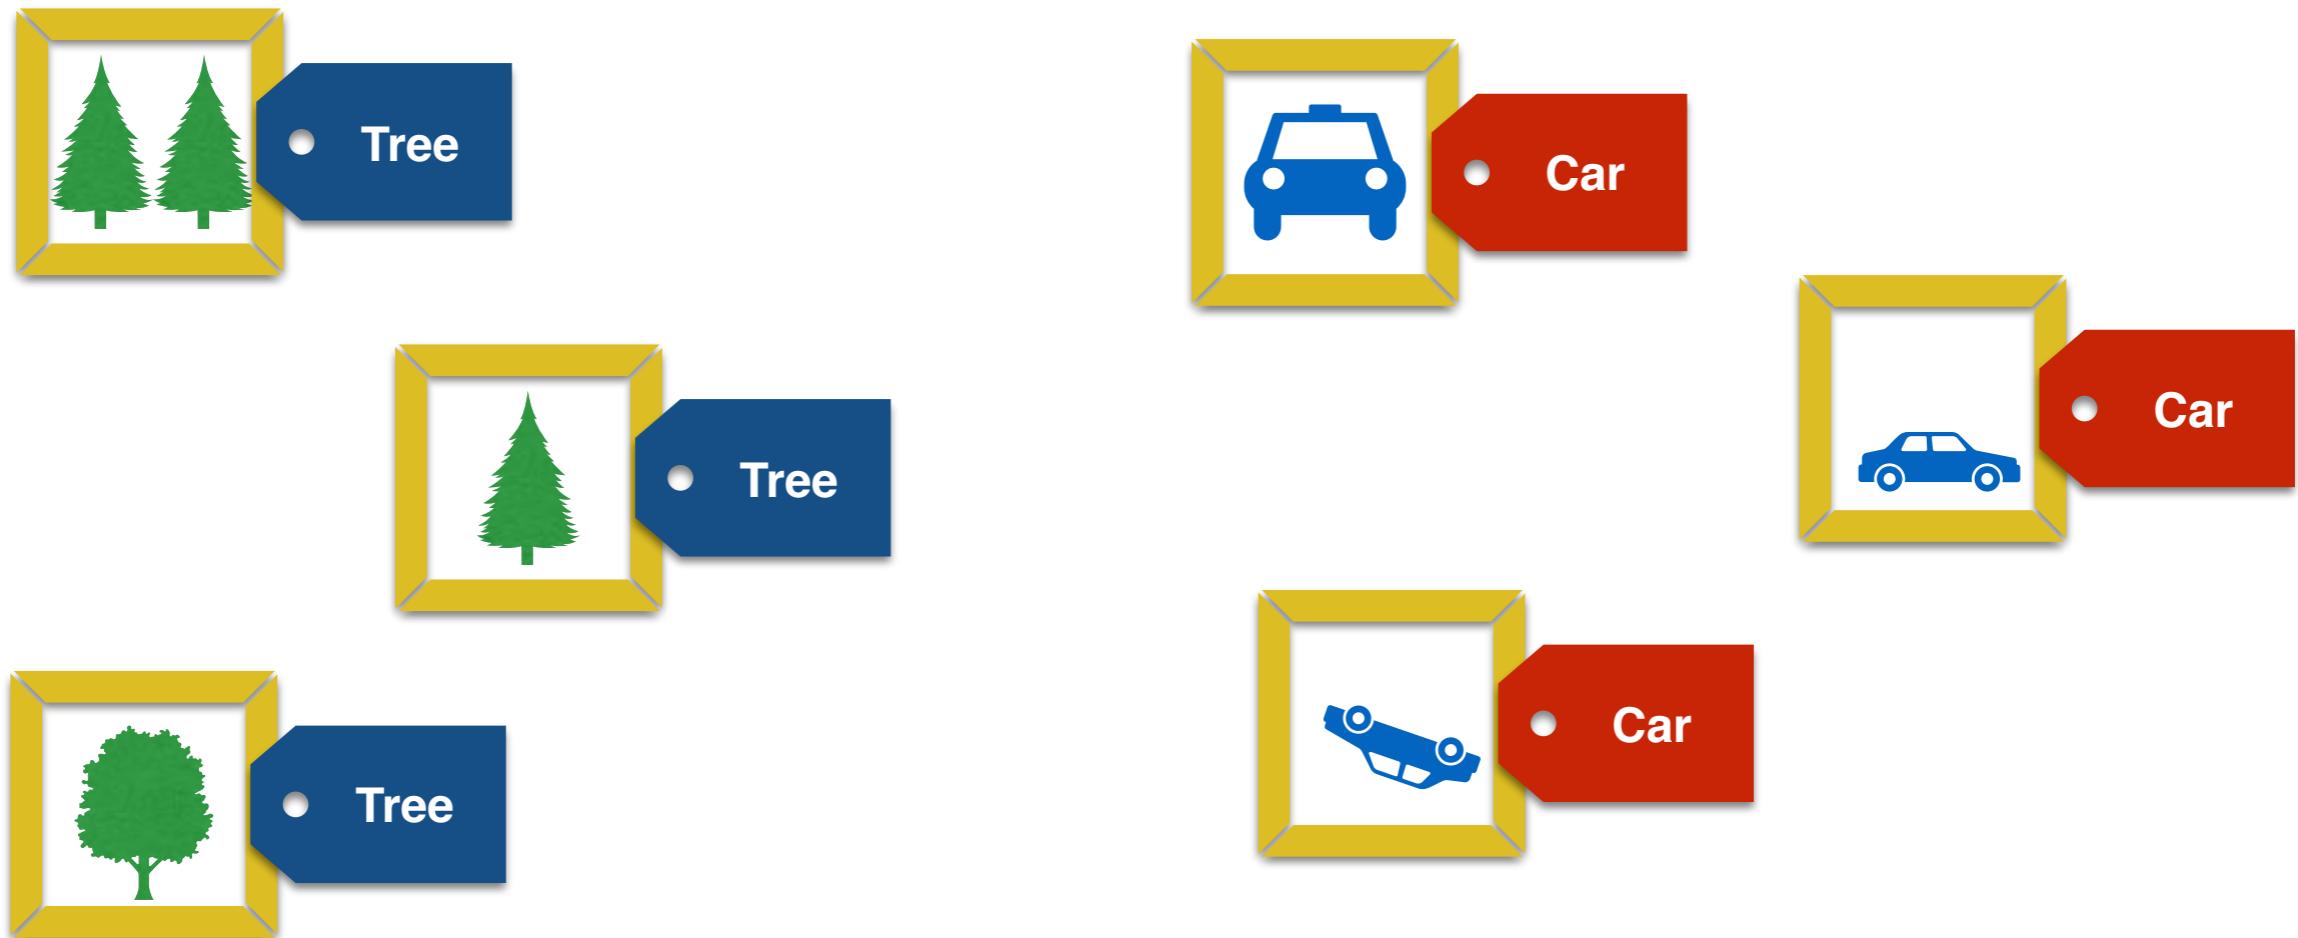
Pipeline



Usando Base de dados com muitos exemplos. Geramos melhores classificadores observando os erros iniciais

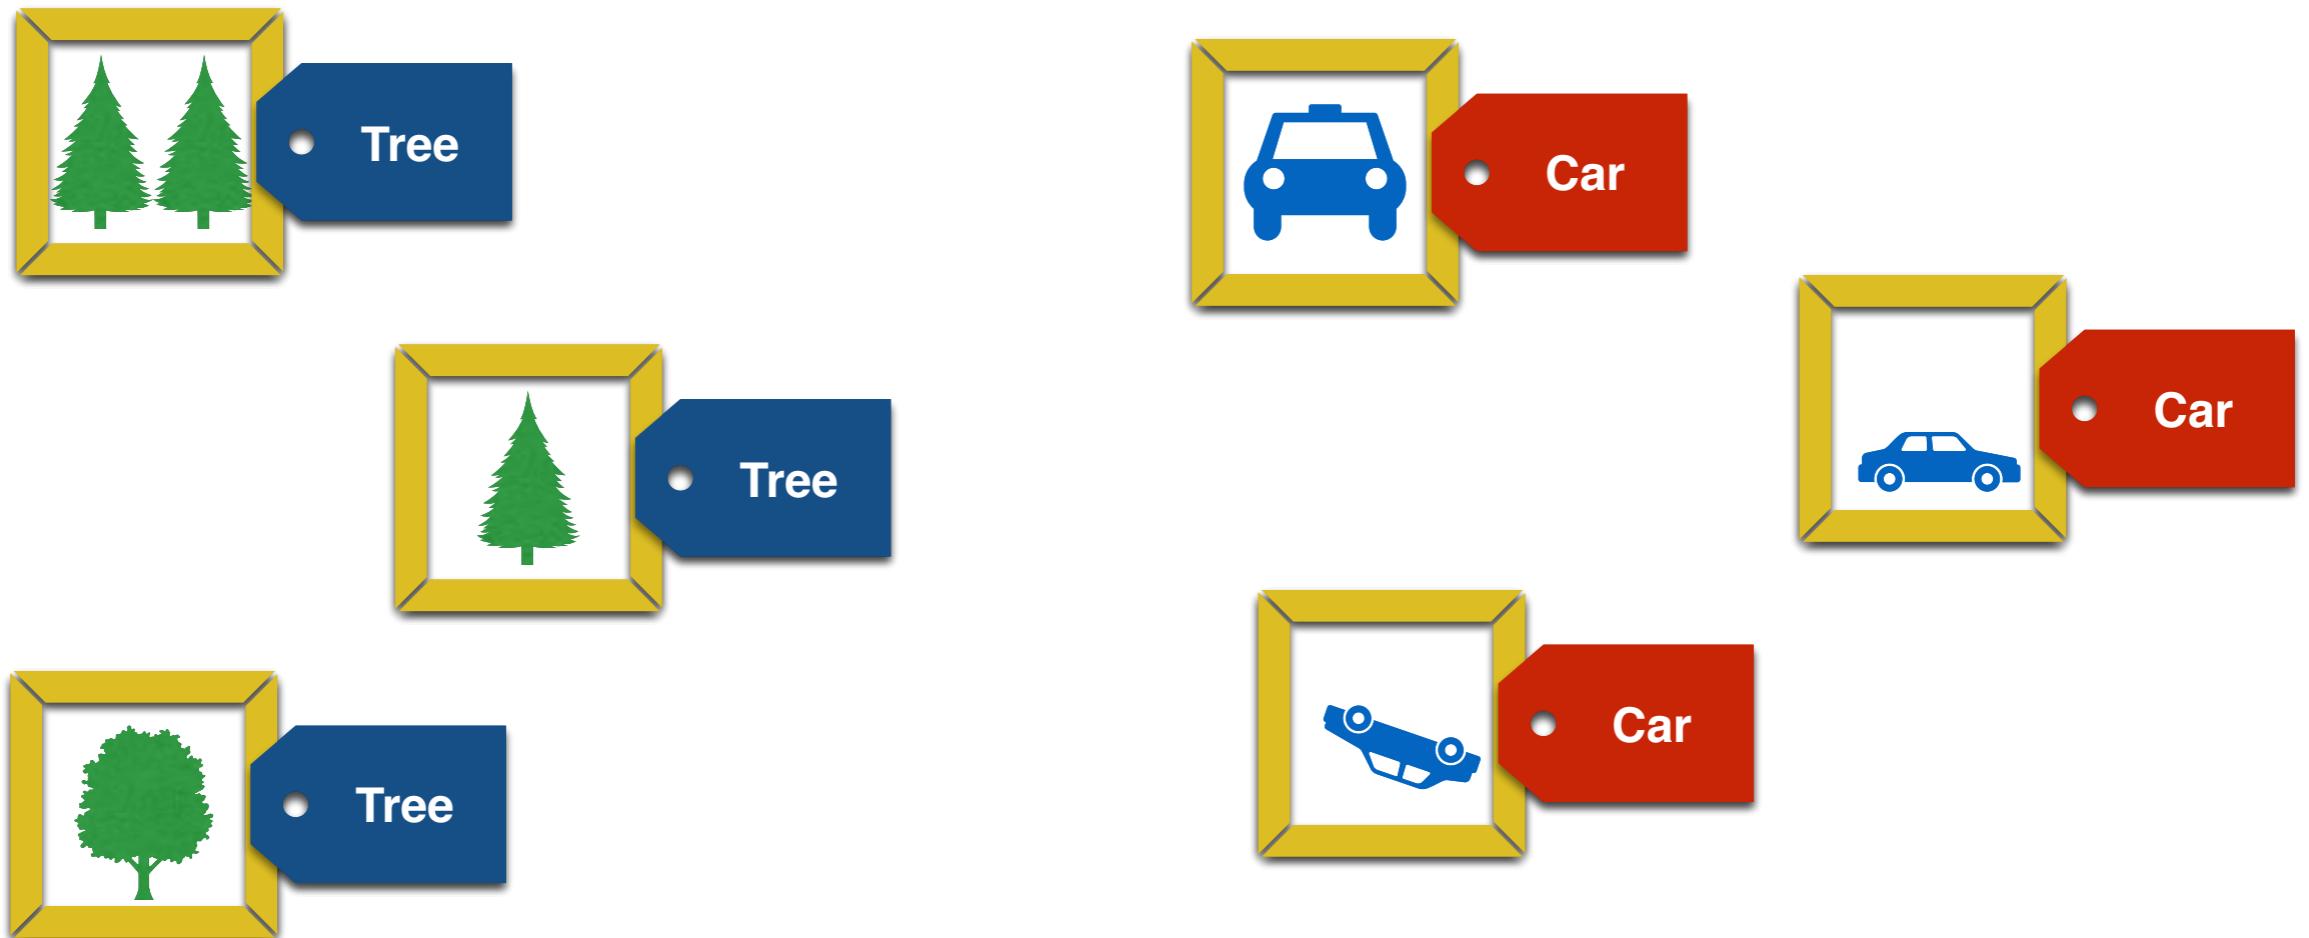
Aprendizagem de Máquina

Pipeline



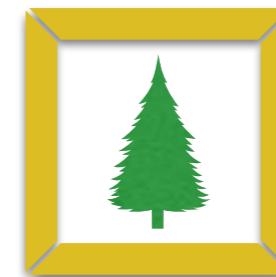
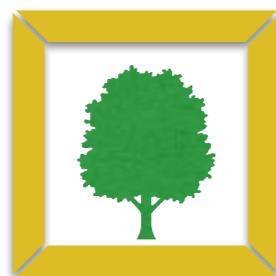
Usando Base de dados com muitos exemplos. Geramos melhores classificadores observando os erros iniciais

Aprendizado Supervisionado



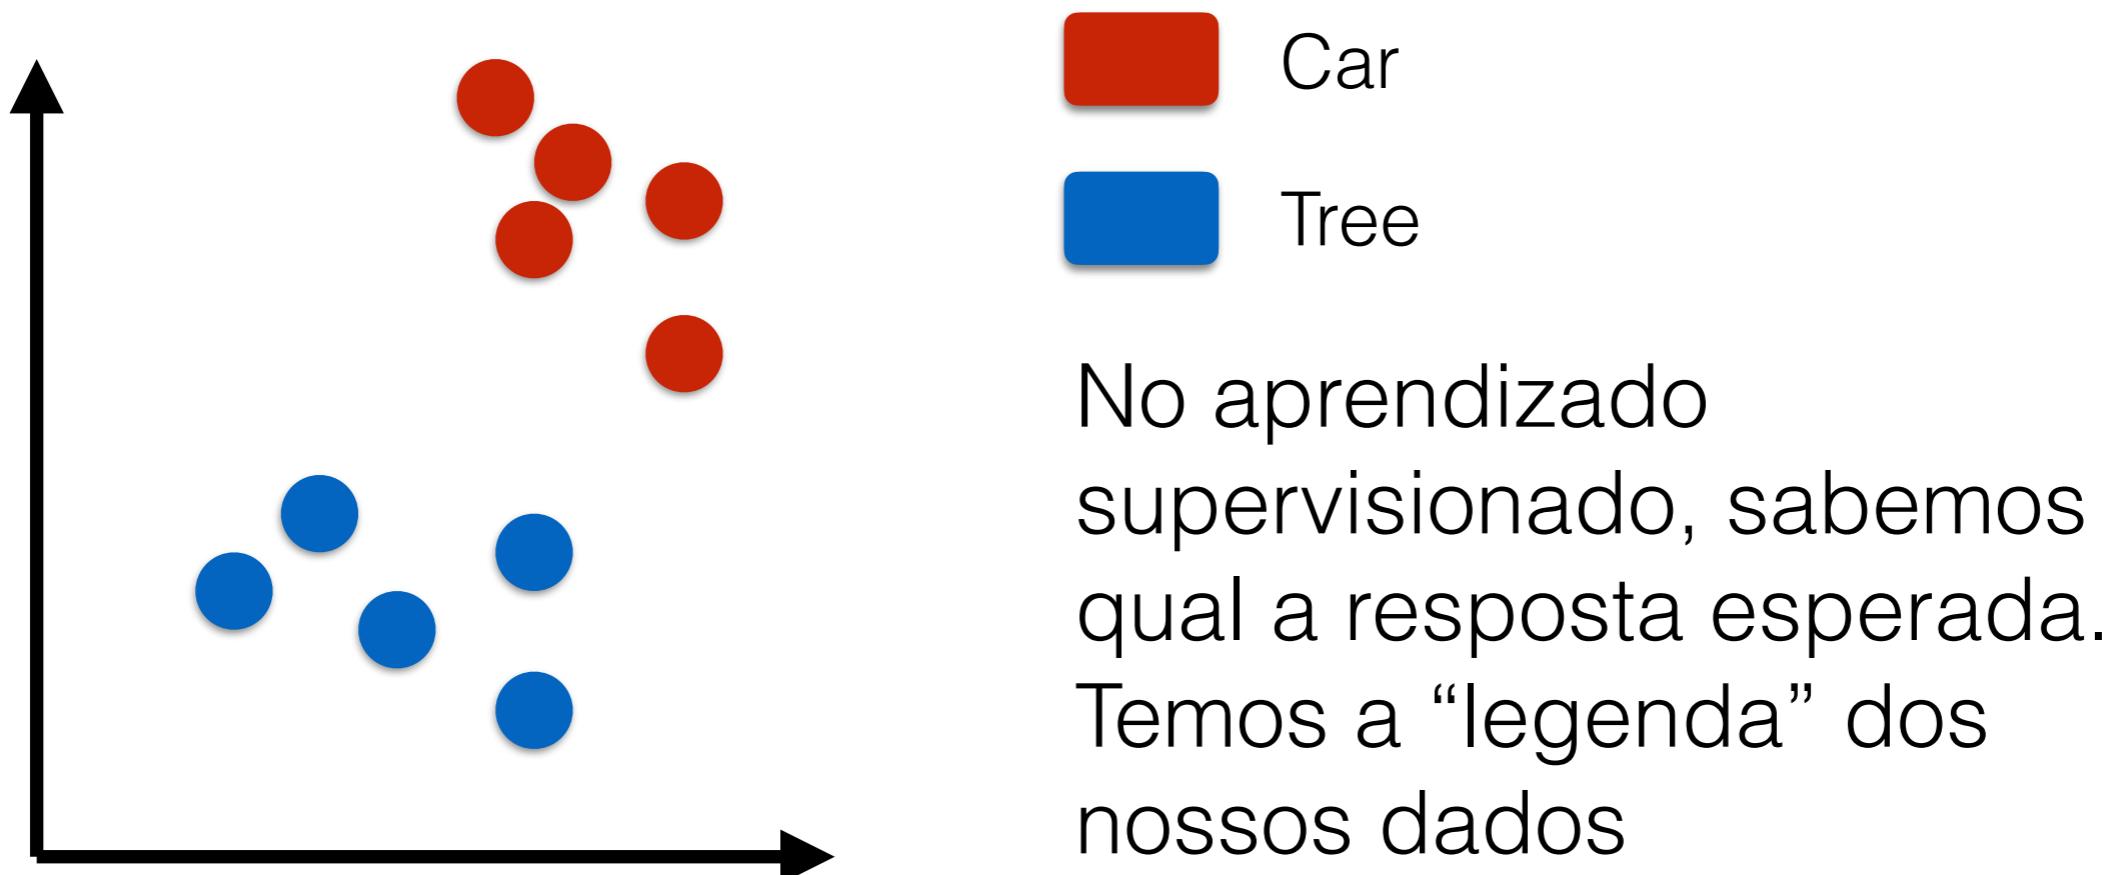
Usando Base de dados com muitos exemplos **rotulados**.
Geramos melhores classificadores observando os erros
iniciais

Aprendizado Não-Supervisionado

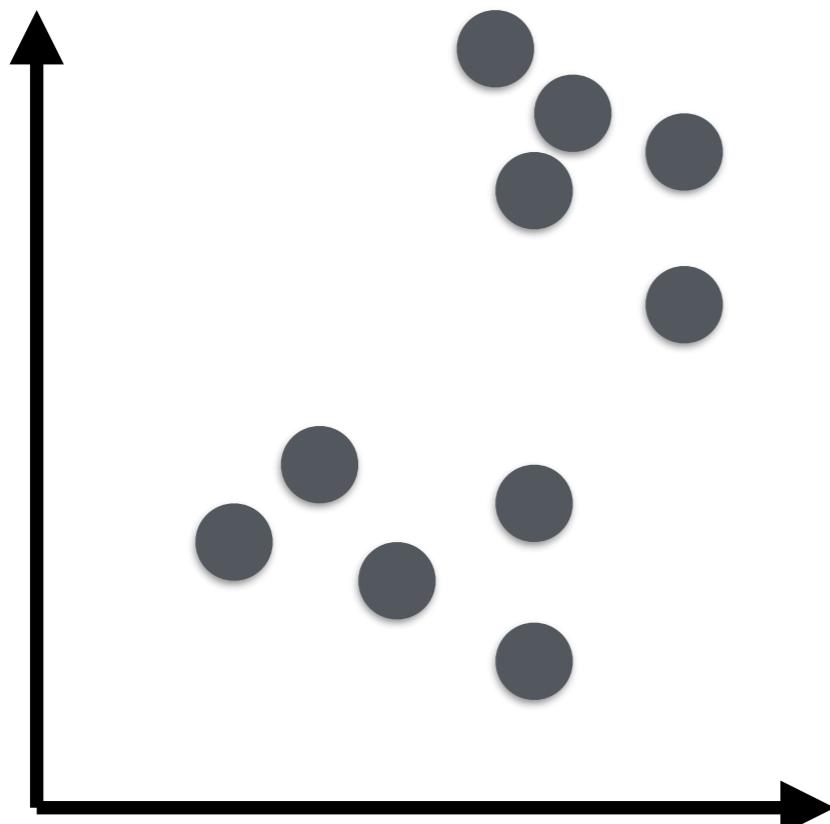


Usando Base de dados com muitos exemplos **não-rotulados**. Tentamos encontrar padrões nos dados que nos permitam categoriza-los

Aprendizado Supervisionado

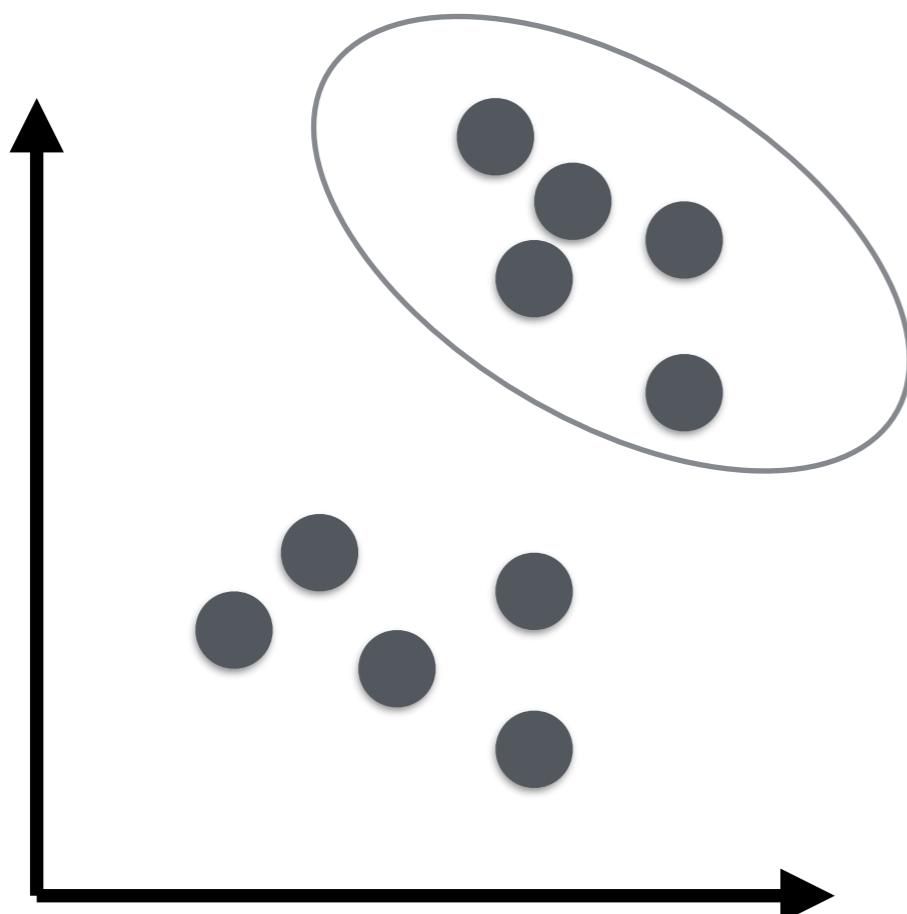


Aprendizado Não-Supervisionado



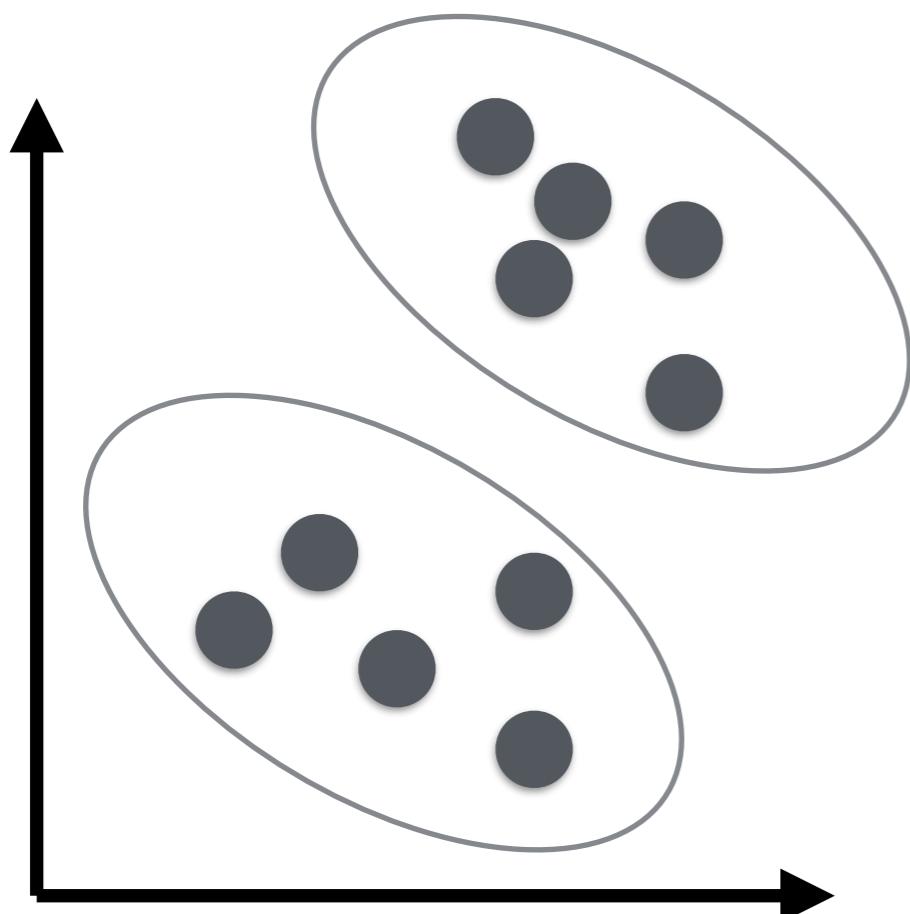
Sem os rótulos, ainda
podemos aprender algo
sobre a estrutura dos dados

Aprendizado Não-Supervisionado



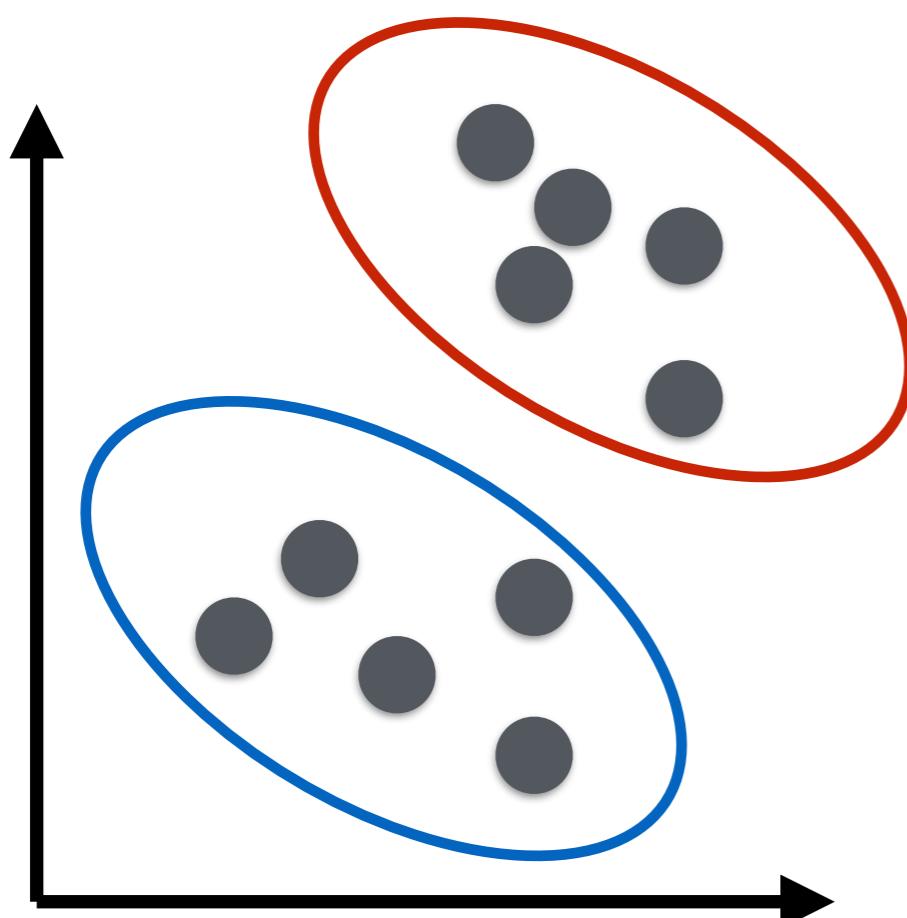
Sem os rótulos, ainda
podemos aprender algo
sobre a estrutura dos dados

Aprendizado Não-Supervisionado



Sem os rótulos, ainda
podemos aprender algo
sobre a estrutura dos dados

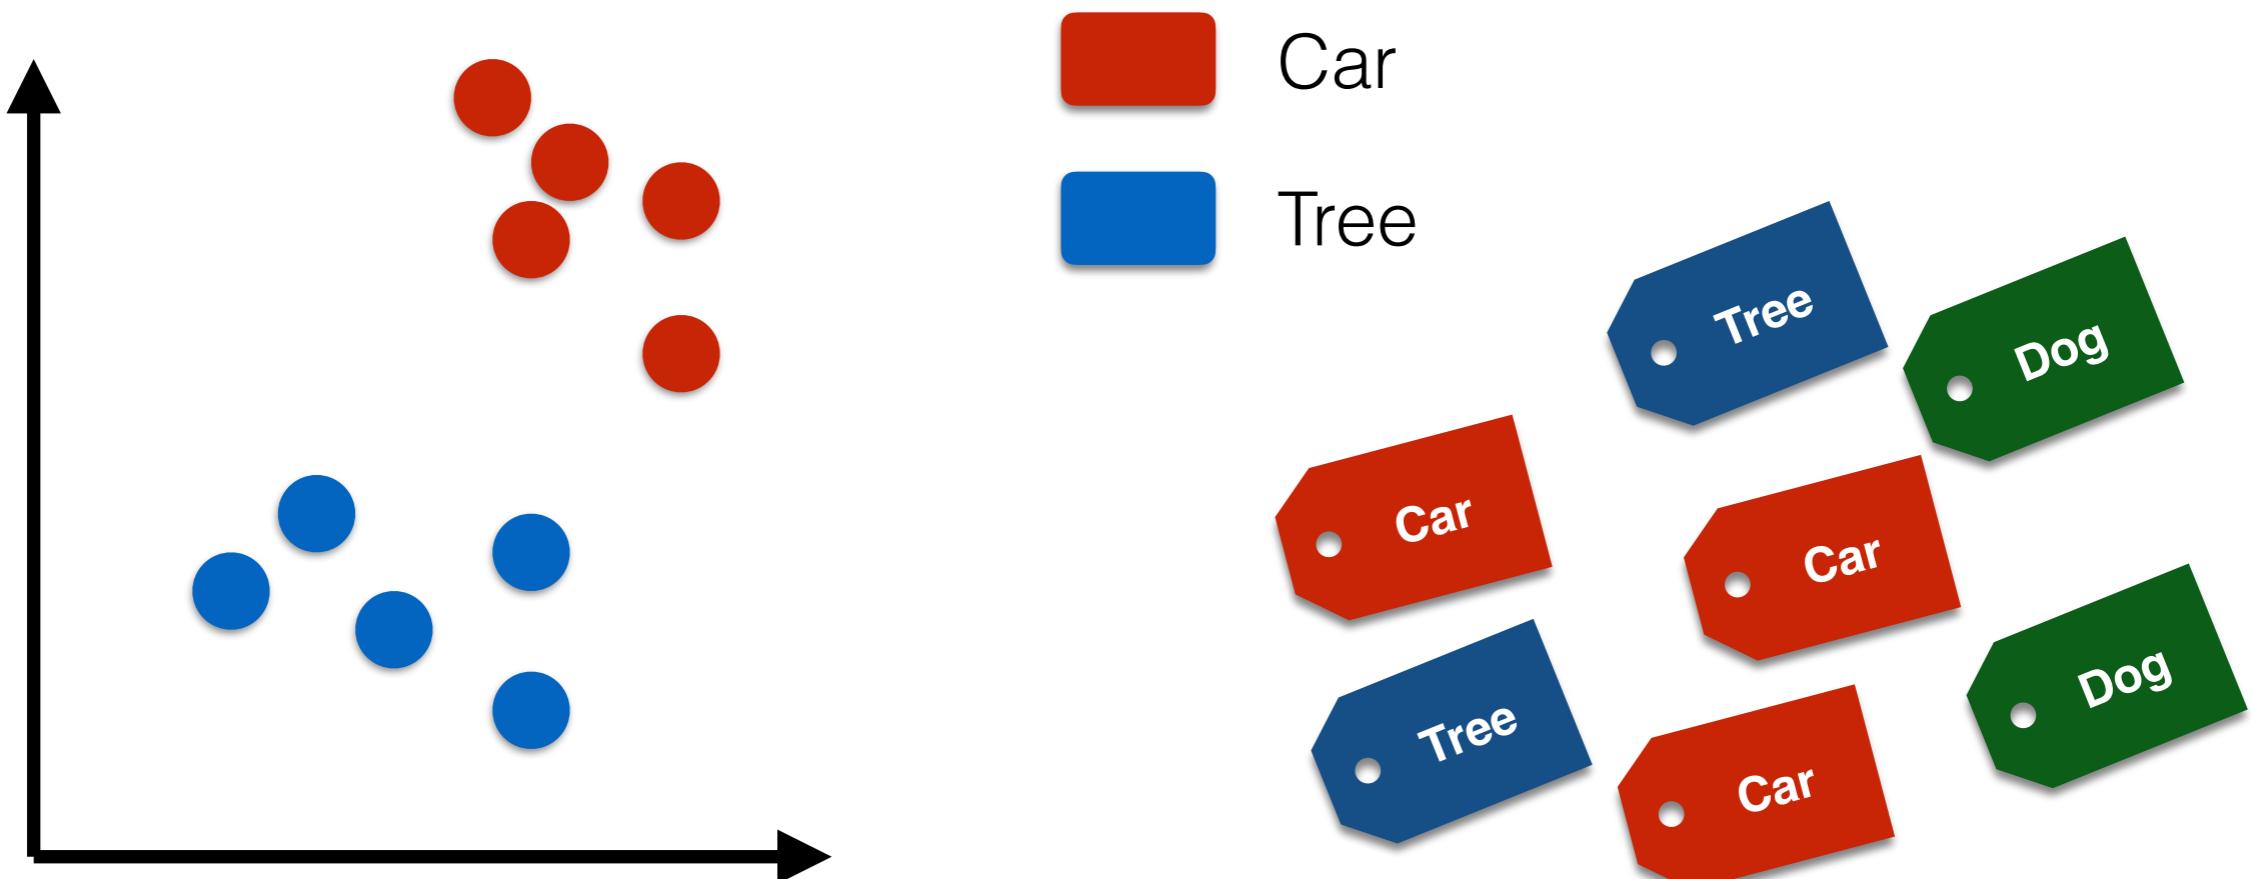
Aprendizado Não-Supervisionado



- Grupo 1
- Grupo 2

Mas ficará à cargo do pesquisador entender qual o significado desse agrupamento.

(Foco no) Aprendizado Supervisionado



Problema de Classificação

Cor Média	Medida de Textura	Medida de Borda	Rótulo
(255, 0, 0)	10	100	Car (0)
(10, 255, 5)	1	21	Tree (1)
(20, 40, 255)	50	23	Dog (2)
(255, 50, 50)	12	45	Car (0)

Nossos dados fictícios, organizados em uma tabela

Problema de Classificação

Cor Média	Medida de Textura	Medida de Borda	Rótulo
(255, 0, 0)	10	100	Car (0)
(10, 255, 5)	1	21	Tree (1)
(20, 40, 255)	50	23	Dog (2)
(255, 50, 50)	12	45	Car (0)

→ Vetores de características

Os vetores de características são as informações extraídas do dado original que vamos usar para representá-lo

Problema de Classificação

Cor Média	Medida de Textura	Medida de Borda	Rótulo
(255, 0, 0)	10	100	Car (0)
(10, 255, 5)	1	21	Tree (1)
(20, 40, 255)	50	23	Dog (2)
(255, 50, 50)	12	45	Car (0)

Rótulos ←

Os rótulos são a saída que desejamos obter de nosso classificador desejada.

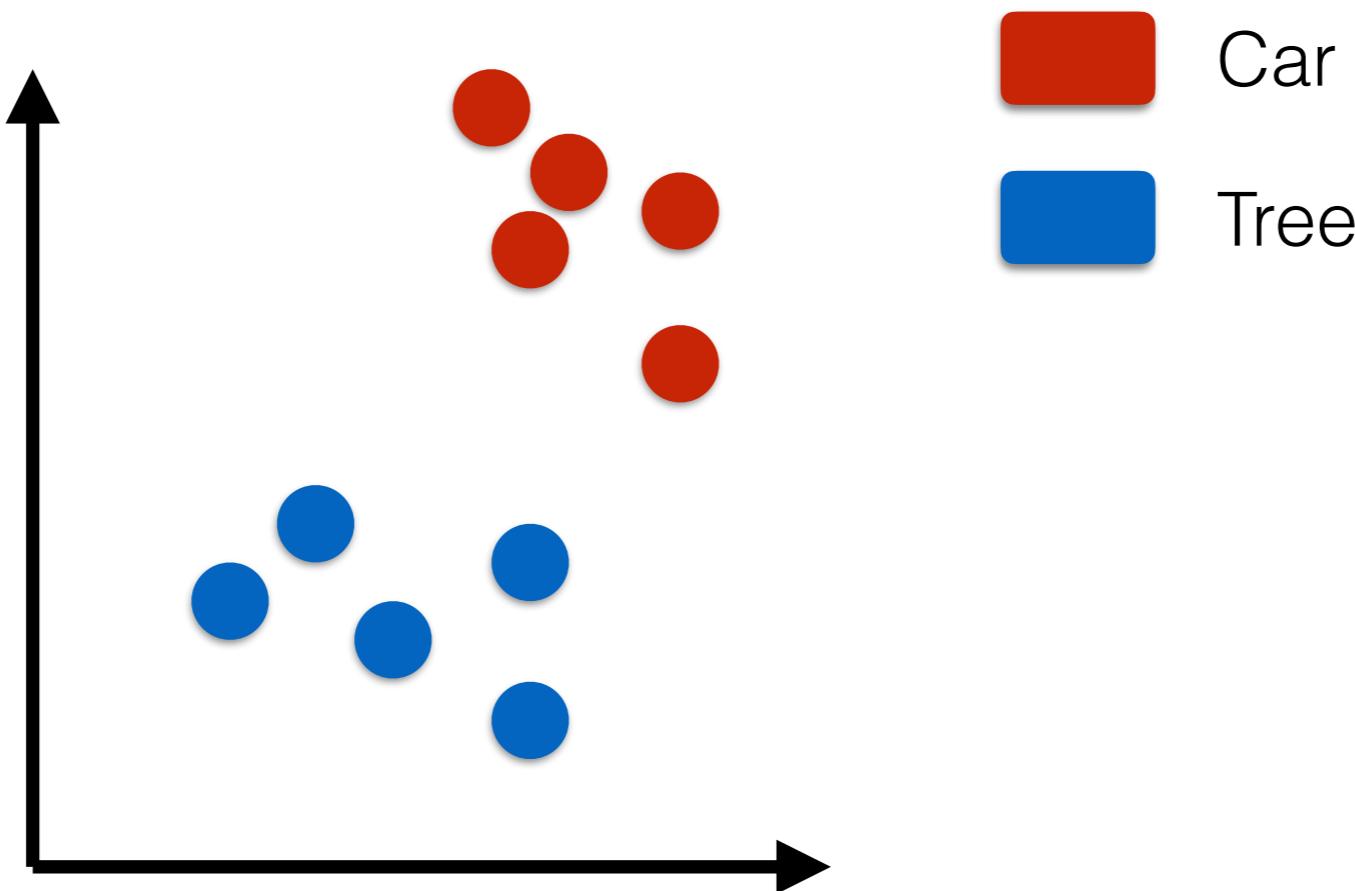
Problema de Classificação

Cor Média	Medida de Textura	Medida de Borda	Rótulo
(255, 0, 0)	10	100	Car (0)
(10, 255, 5)	1	21	Tree (1)
(20, 40, 255)	50	23	Dog (2)
(255, 50, 50)	12	45	Car (0)

Rótulos ←

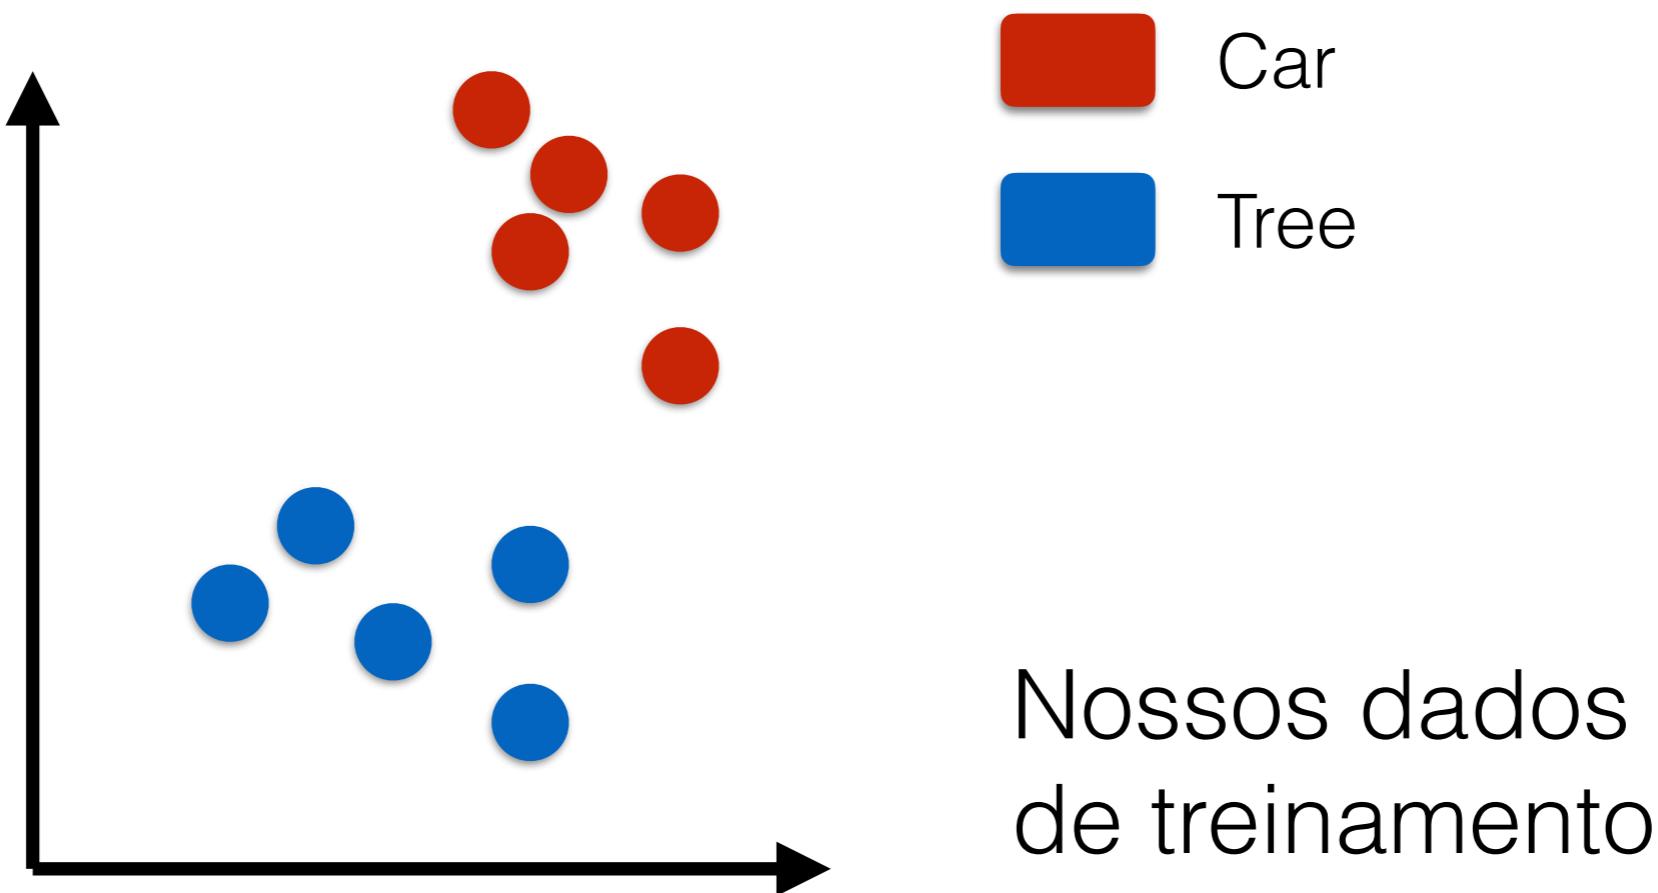
Em problemas de classificação, rótulos são
discretos

Problema de Classificação



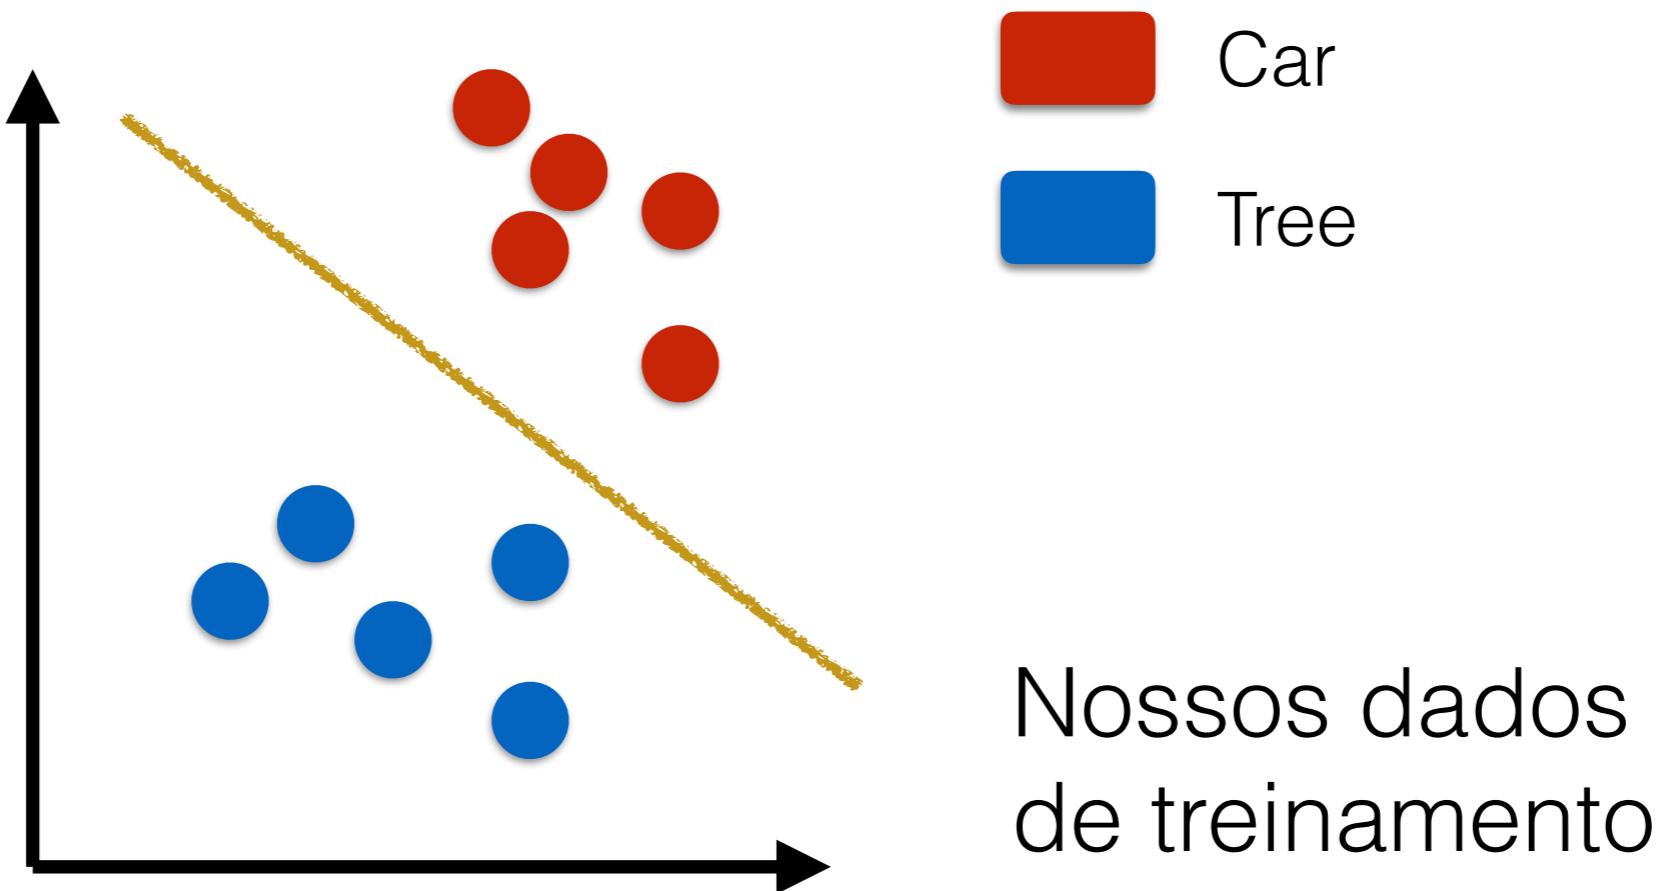
No problema de classificação, desejamos traçar uma divisão no espaço de forma que novos exemplos possam ser categorizados

Problema de Classificação



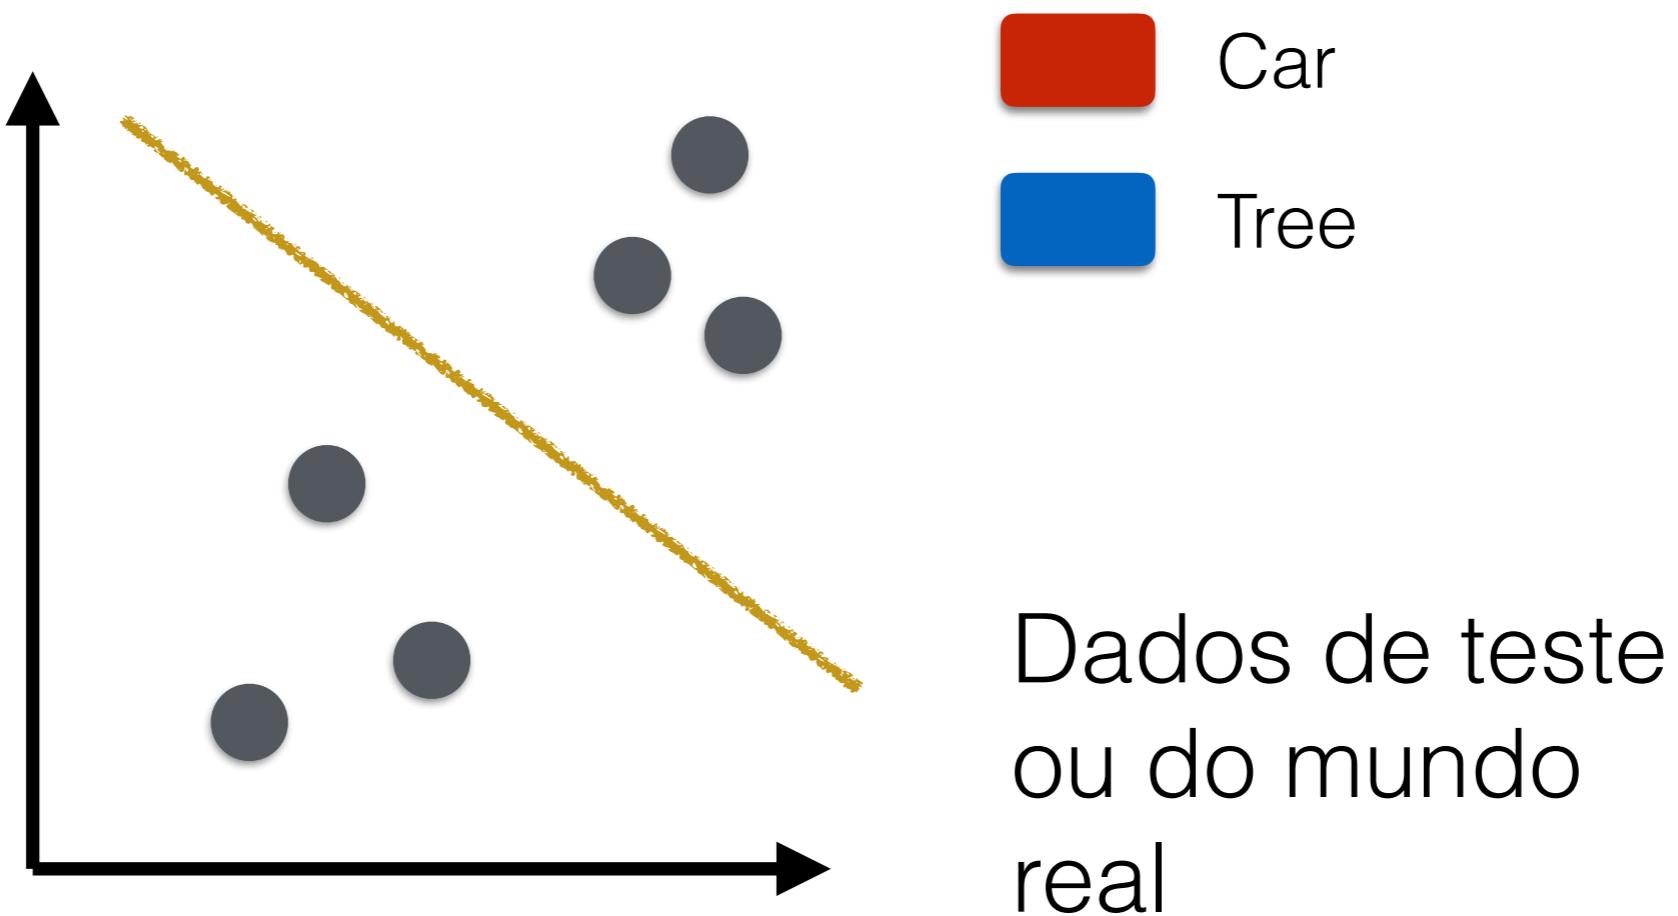
No problema de classificação, desejamos traçar uma divisão no espaço de forma que novos exemplos possam ser categorizados

Problema de Classificação



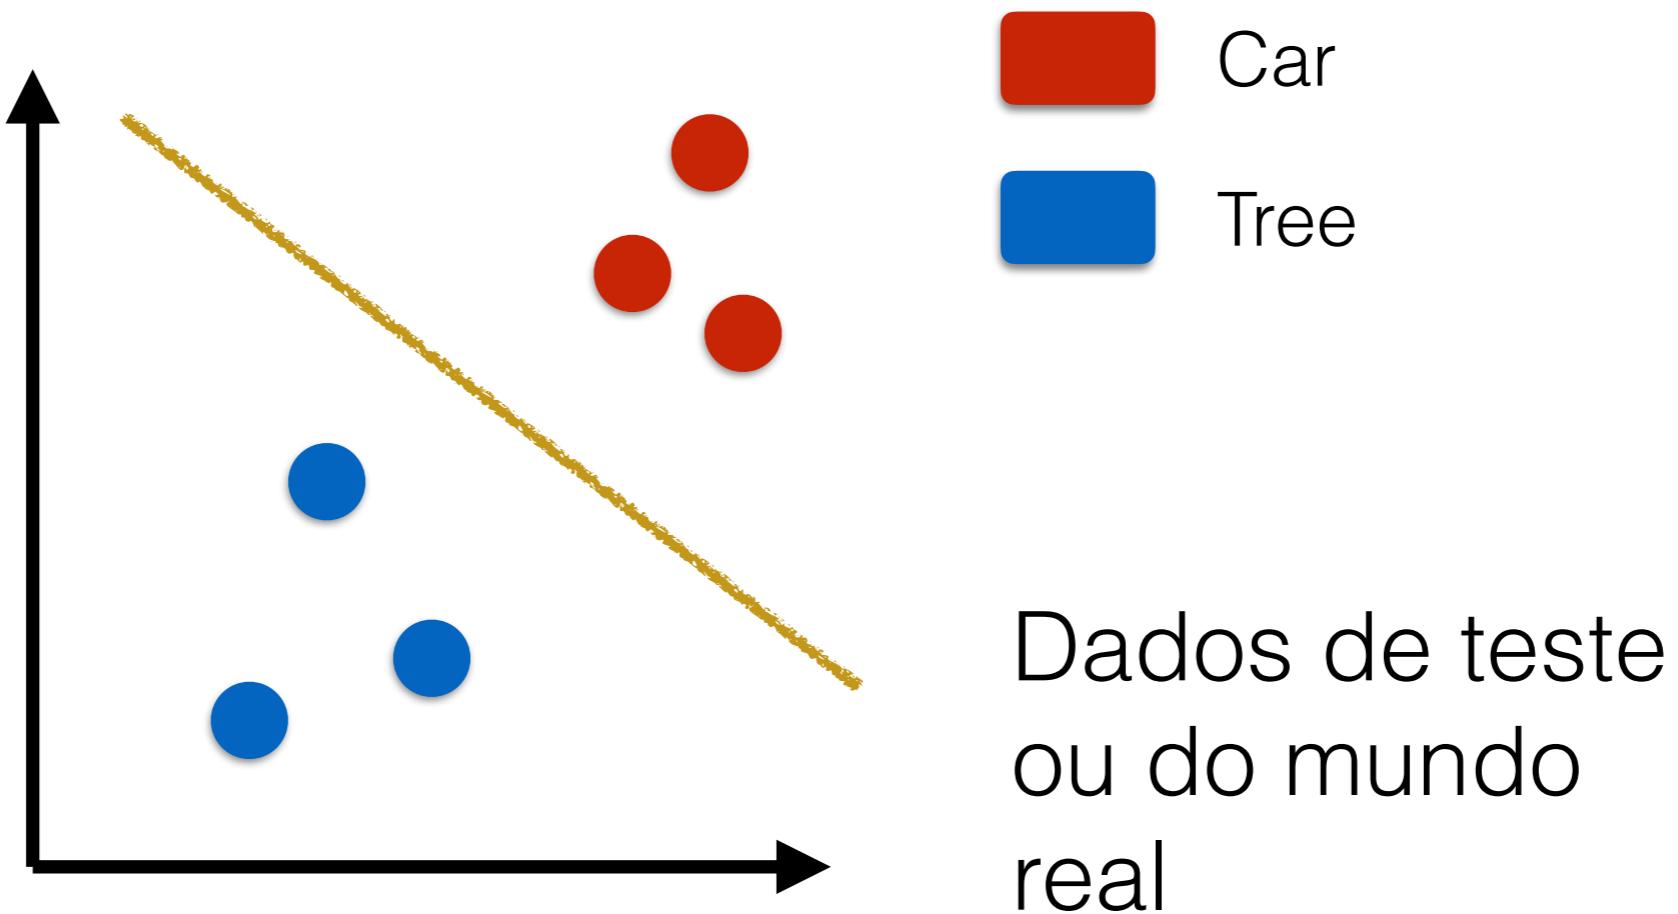
No problema de classificação, desejamos traçar uma divisão no espaço de forma que novos exemplos possam ser categorizados

Problema de Classificação



No problema de classificação, desejamos traçar uma divisão no espaço de forma que novos exemplos possam ser categorizados

Problema de Classificação



No problema de classificação, desejamos traçar uma divisão no espaço de forma que novos exemplos possam ser categorizados

Problema de Regressão

Tamanho	Nº de Quartos	Idade da Casa	Preço (1000U\$)
2104	5	45	460
1416	3	40	232
1534	3	30	315
852	2	36	178

Nossos dados fictícios, organizados em uma tabela

Problema de Regressão

Tamanho	Nº de Quartos	Idade da Casa	Preço (1000U\$)
2104	5	45	460
1416	3	40	232
1534	3	30	315
852	2	36	178

→ Vetores de Características

Problema de Regressão

Tamanho	Nº de Quartos	Idade da Casa	Preço (1000U\$)
2104	5	45	460
1416	3	40	232
1534	3	30	315
852	2	36	178

A red arrow points from the bottom text "Saída Esperada" up towards the "Preço (1000U\$)" column of the table, indicating the target variable being predicted.

Saída Esperada

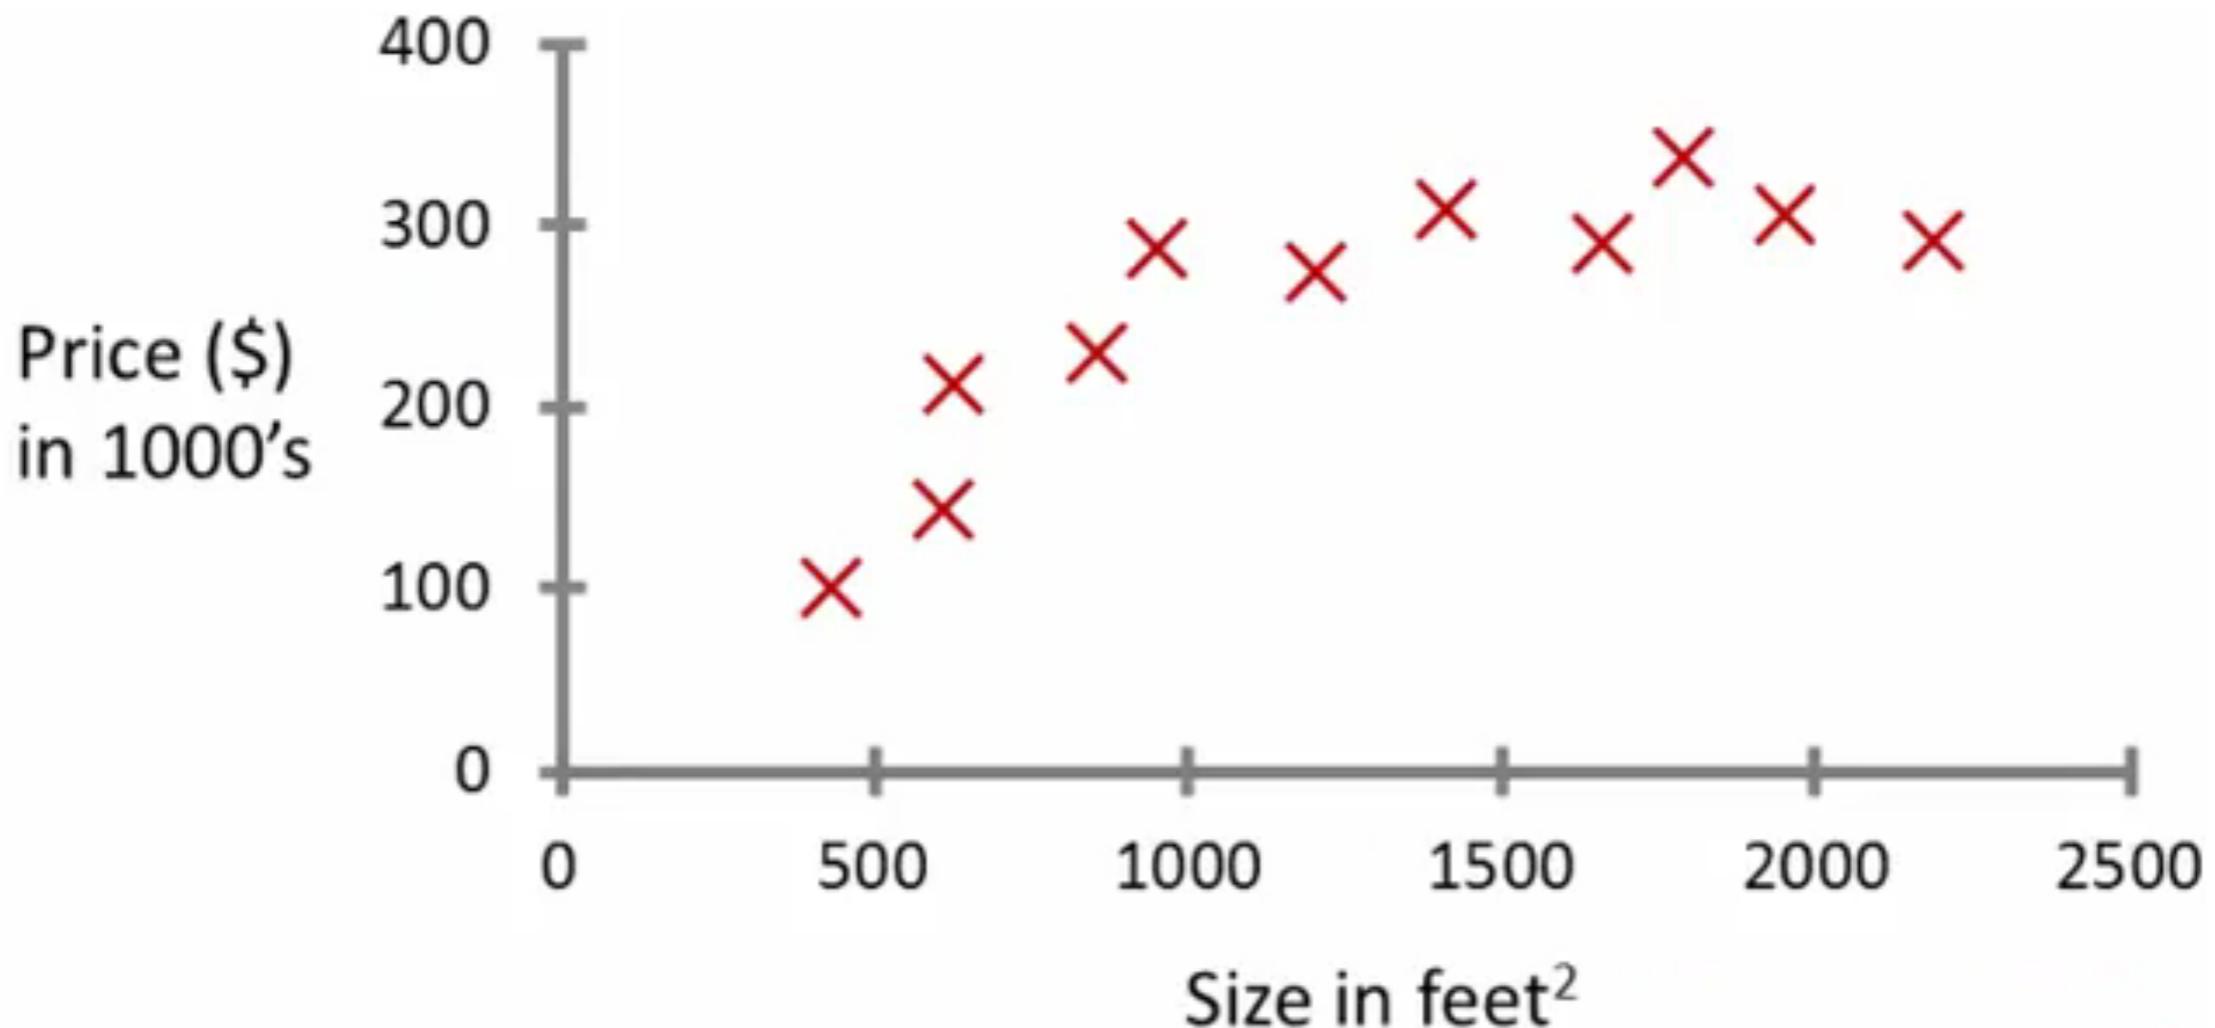
Problema de Regressão

Tamanho	Nº de Quartos	Idade da Casa	Preço (1000U\$)
2104	5	45	460
1416	3	40	232
1534	3	30	315
852	2	36	178

A grande diferença é que em um problema de regressão, a saída é contínua

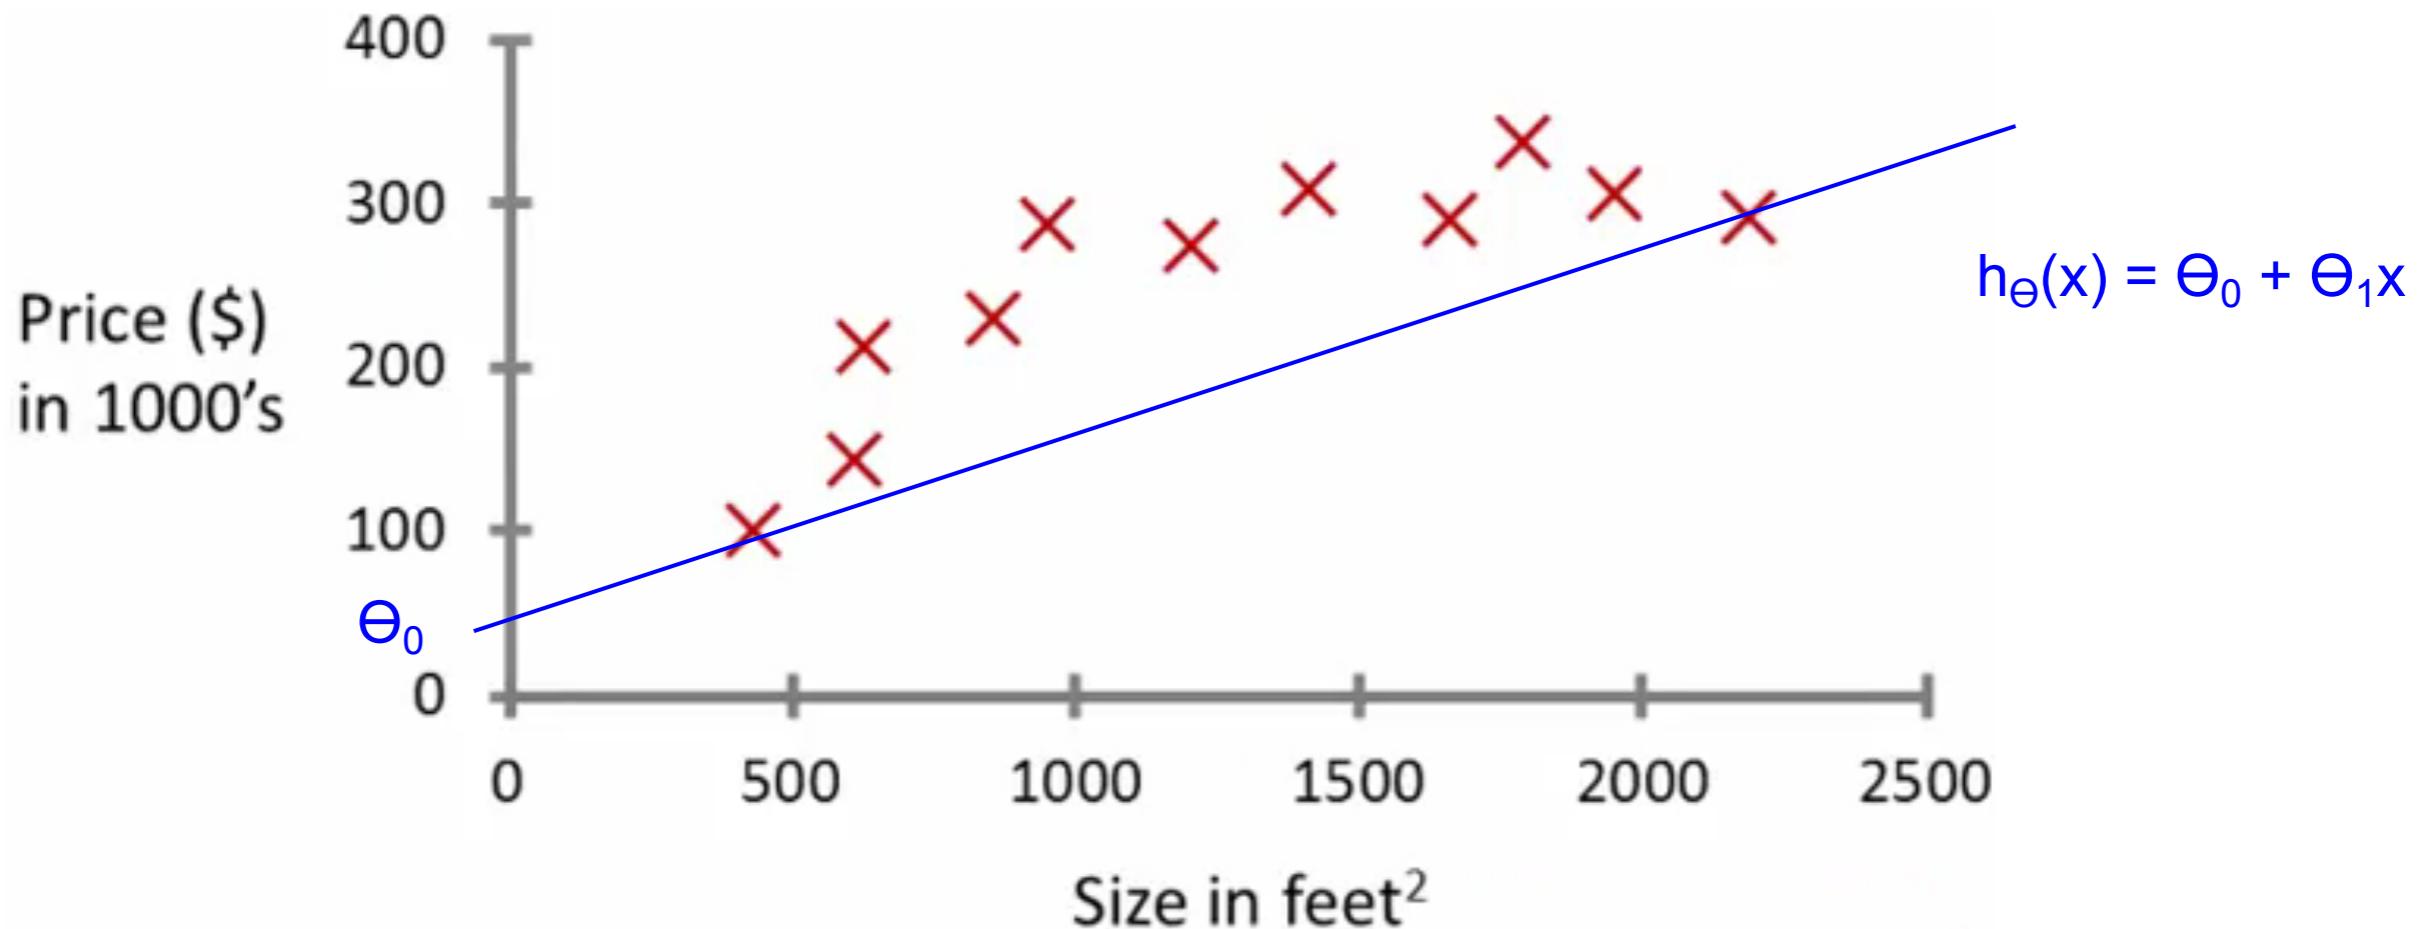
Problema de Regressão

ex.: predição de valor de casa



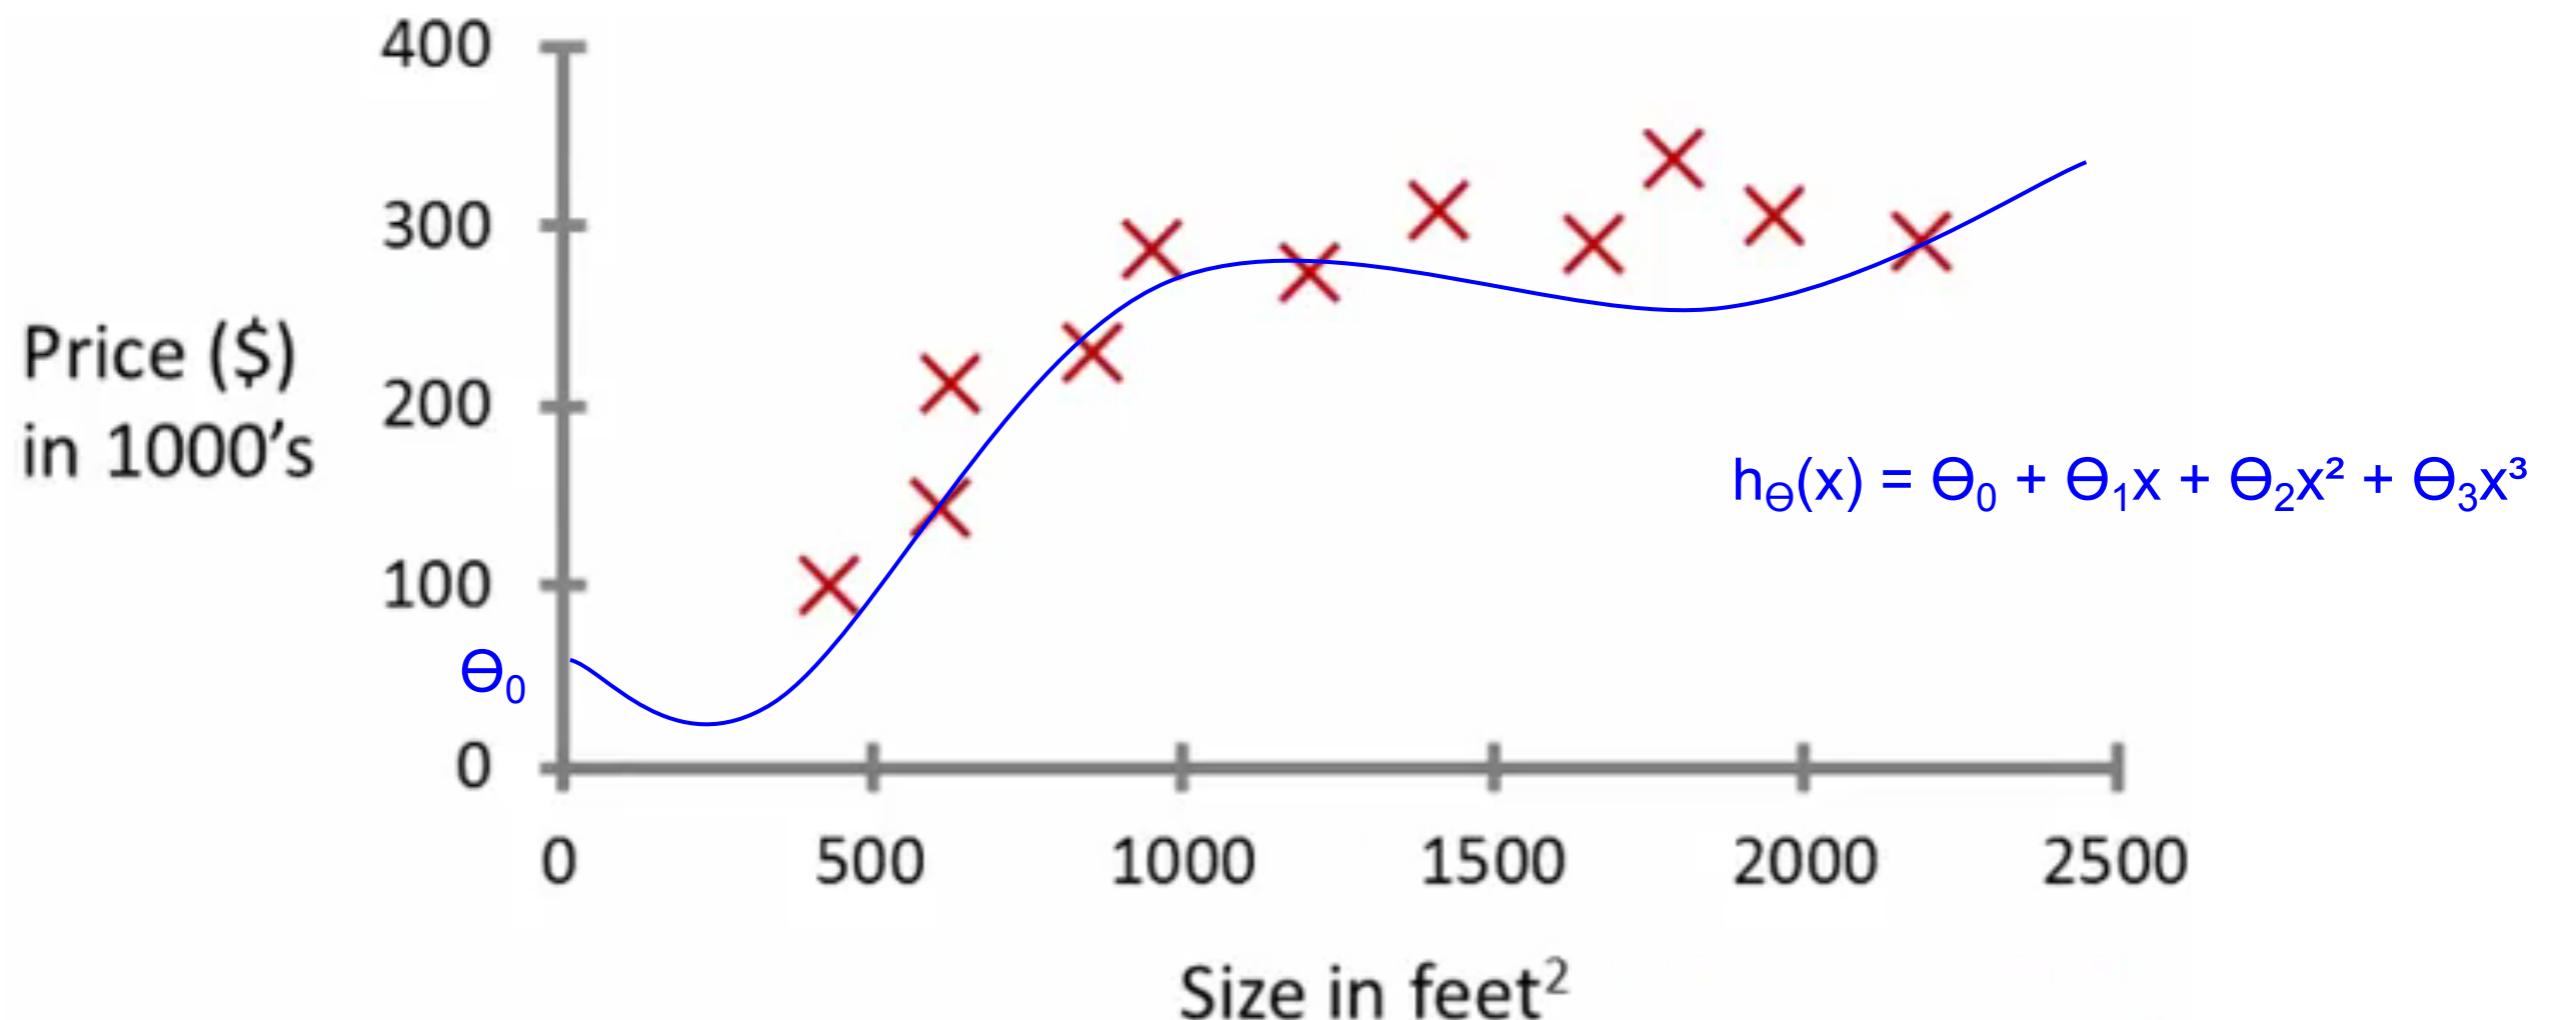
Problema de Regressão

ex.: predição de valor de casa



Problema de Regressão

ex.: predição de valor de casa



Aprendizagem de Máquina

Função de Custo e o Risco

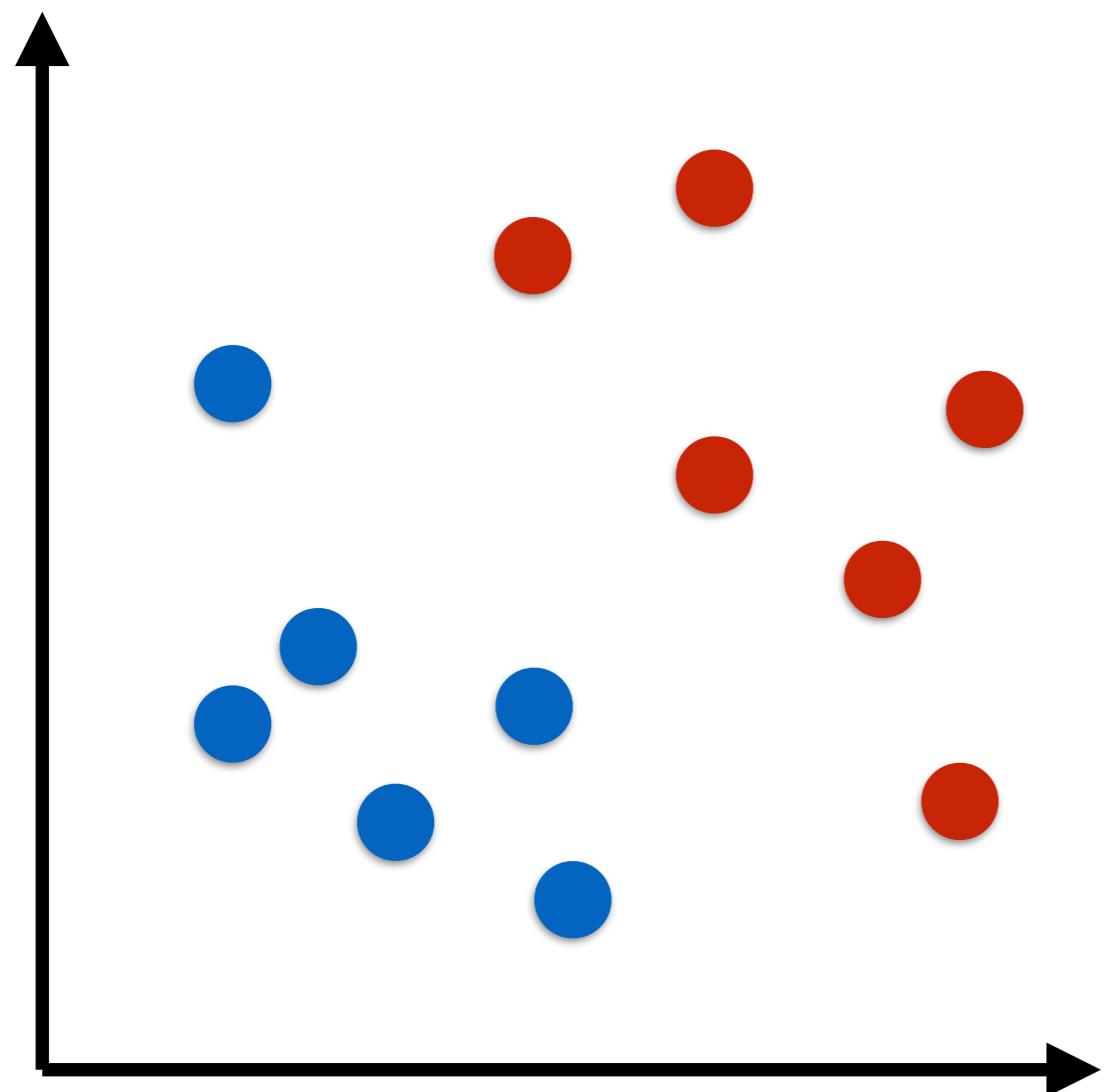


Como medimos o quanto
bem nosso sistema
funciona?

Como medimos o quanto
bem nosso sistema
funciona?

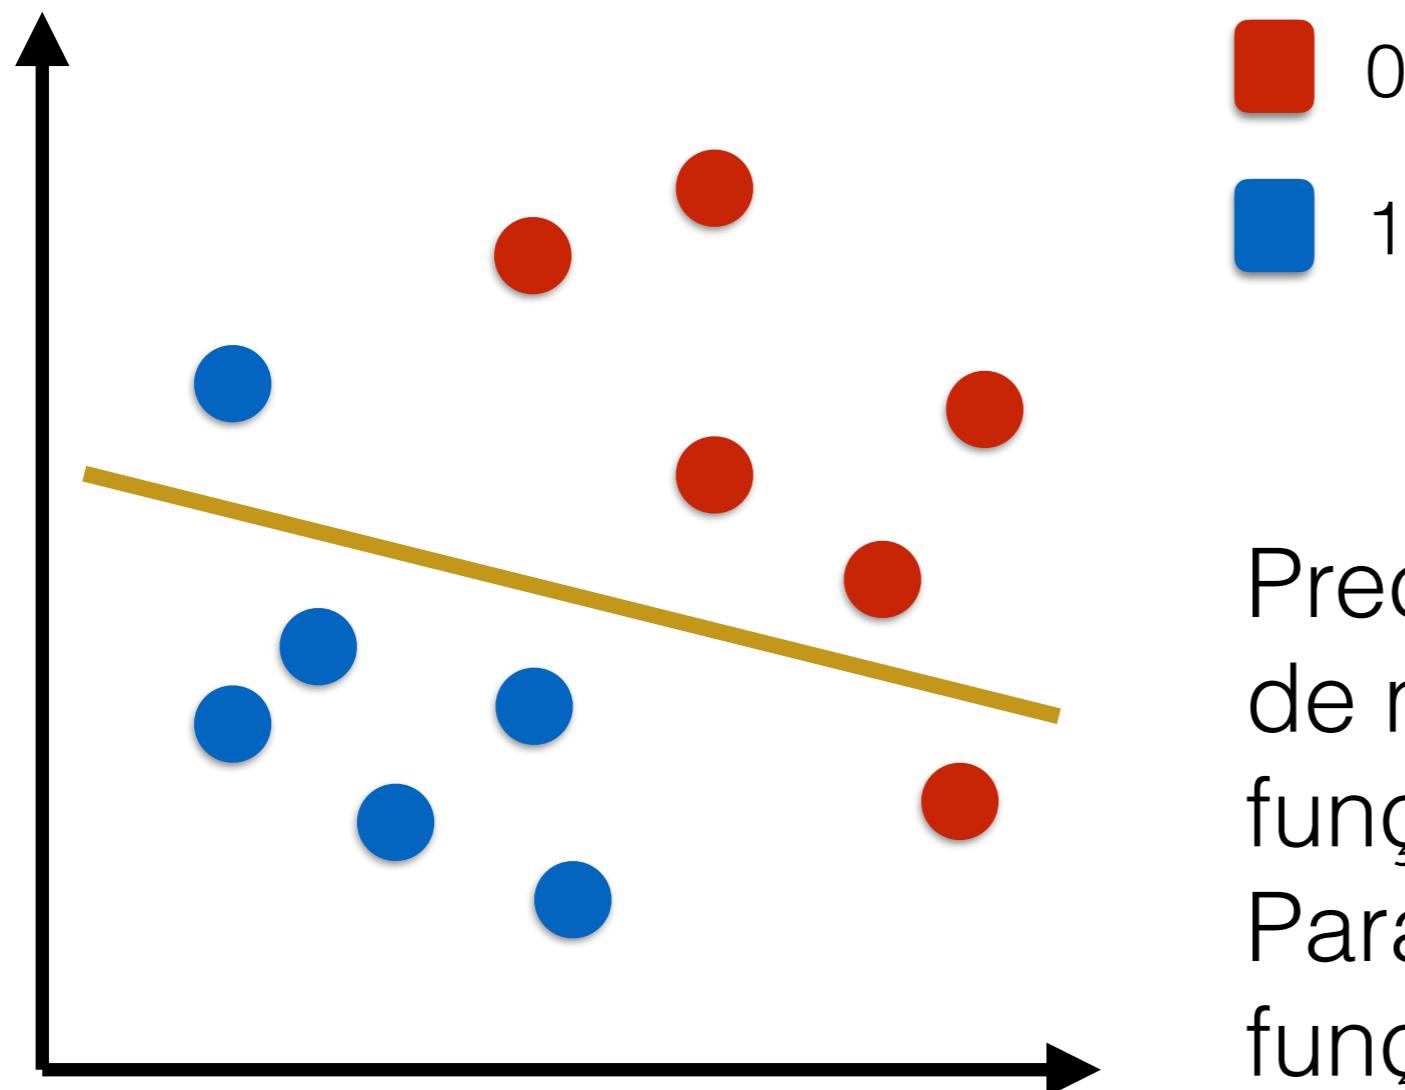
Como um algoritmo
escolhe a função $f(\cdot)$ ao
invés da função $g(\cdot)$?

Funções de Custo



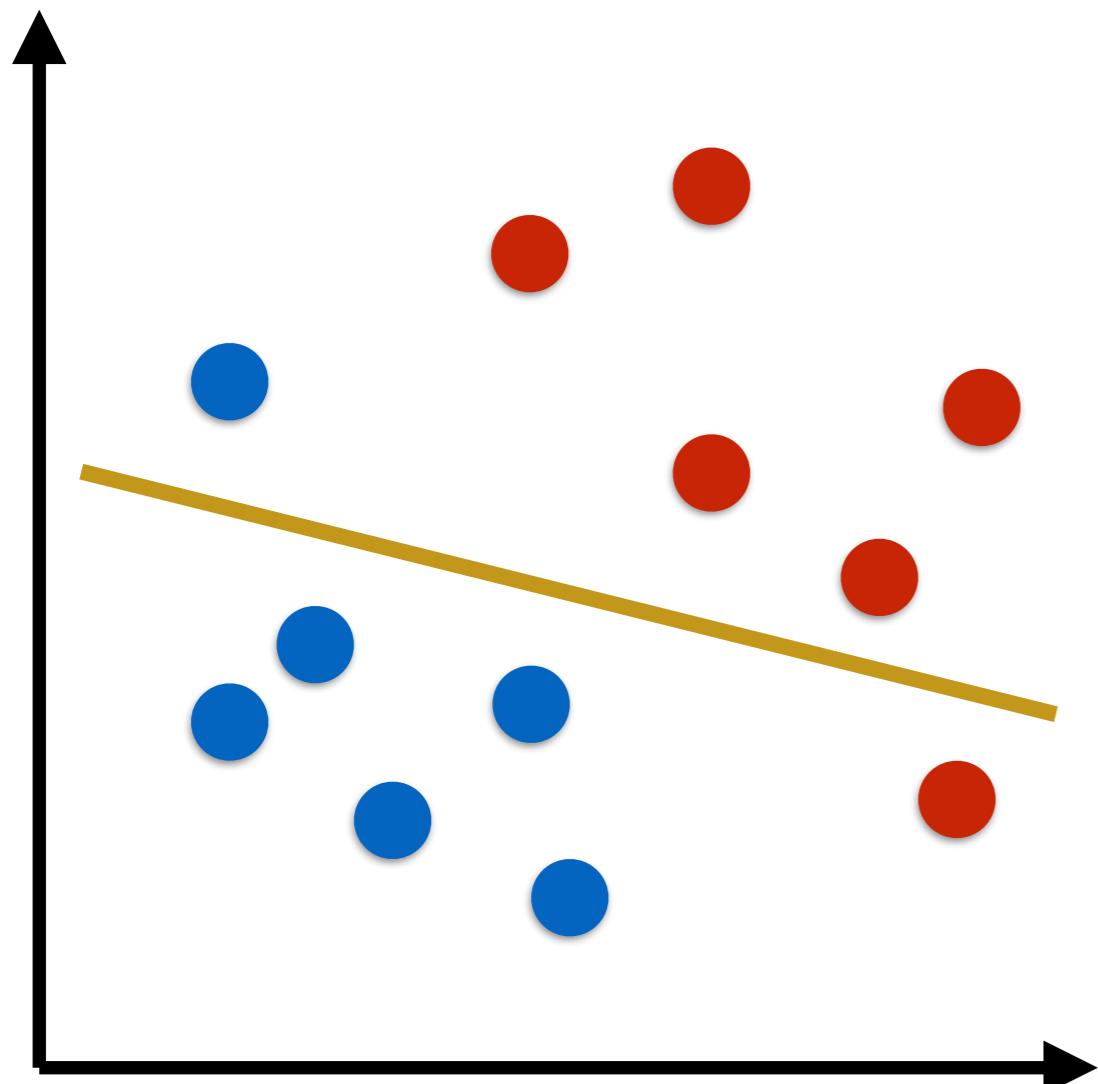
Precisamos de uma forma de medir a qualidade da função classificadora.
Para isso definimos uma função de custo

Funções de Custo



Precisamos de uma forma de medir a qualidade da função classificadora. Para isso definimos uma função de custo

Funções de Custo

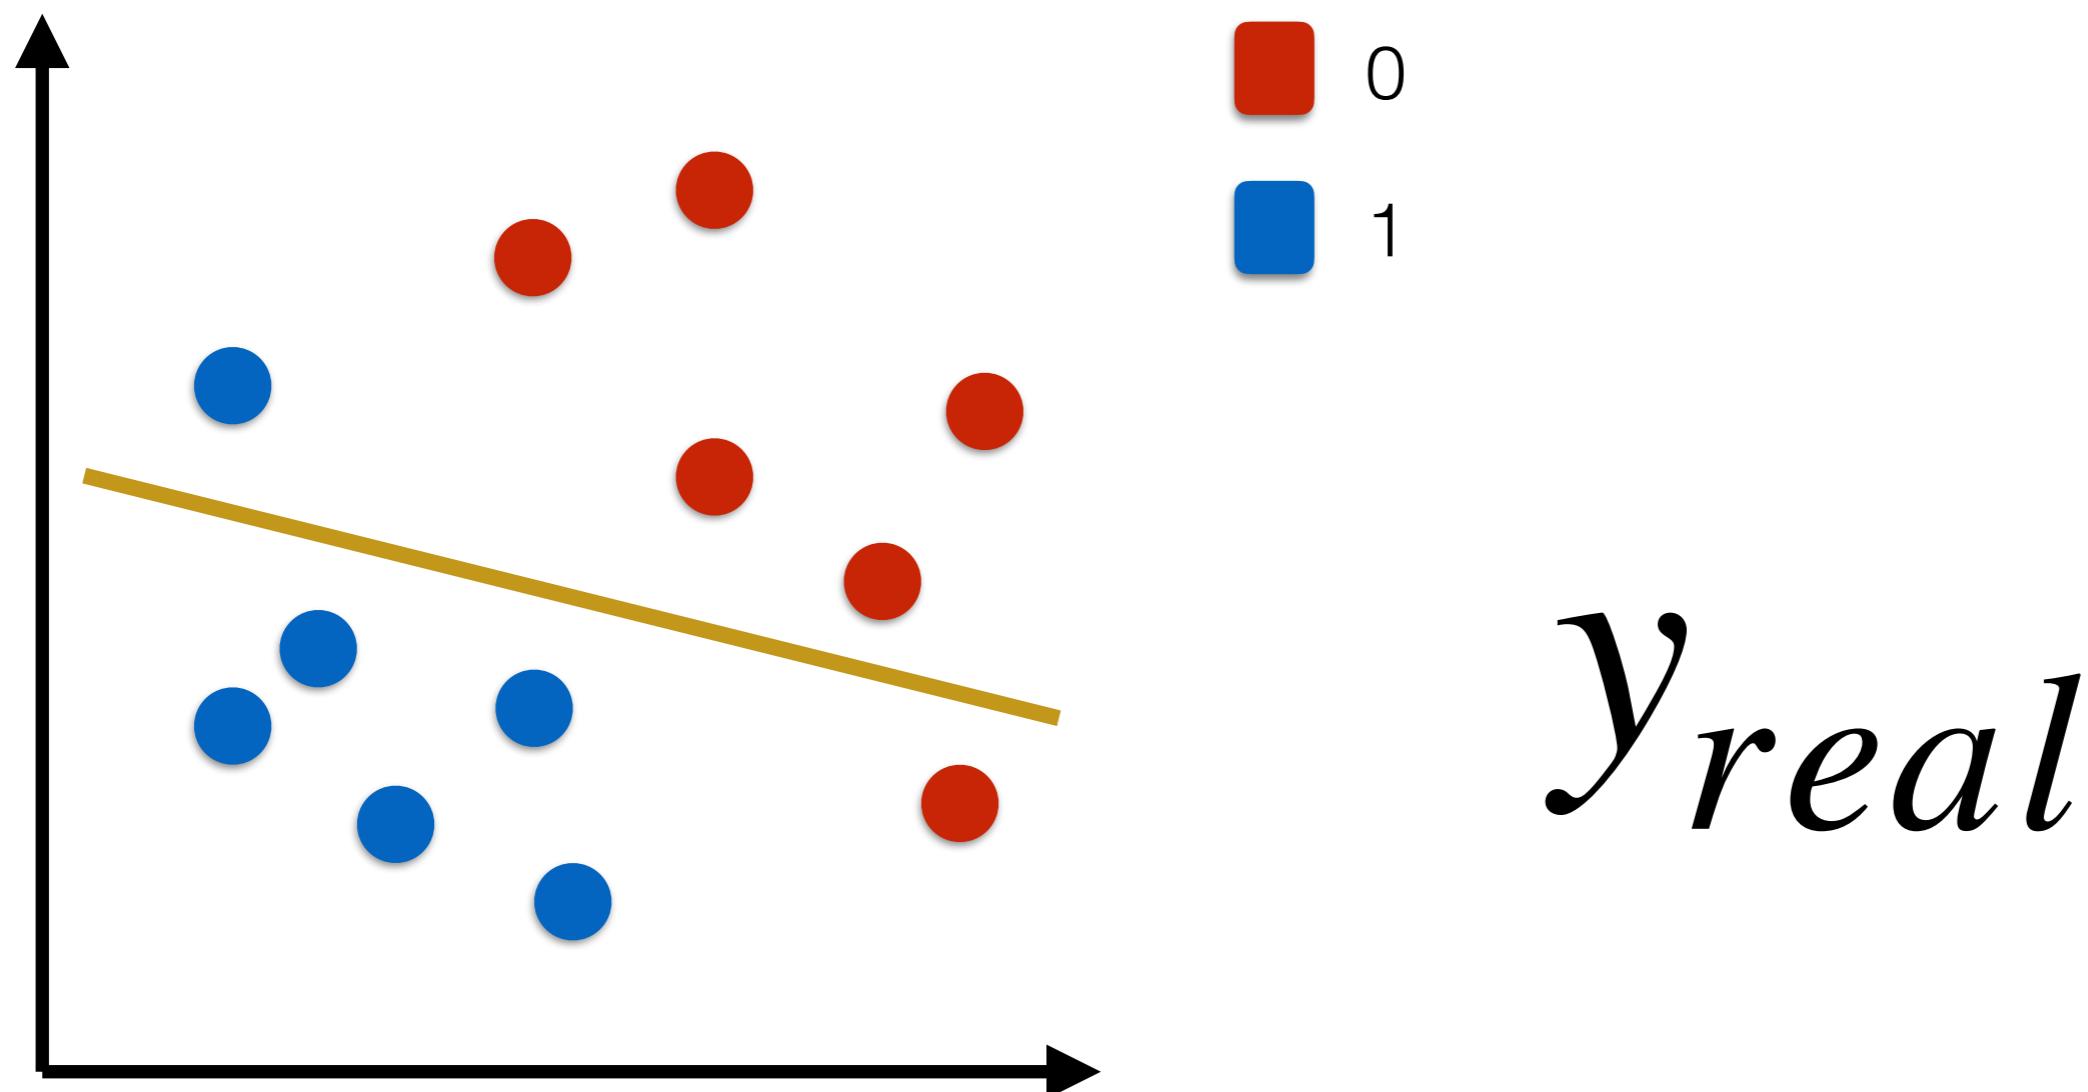


- 0
- 1

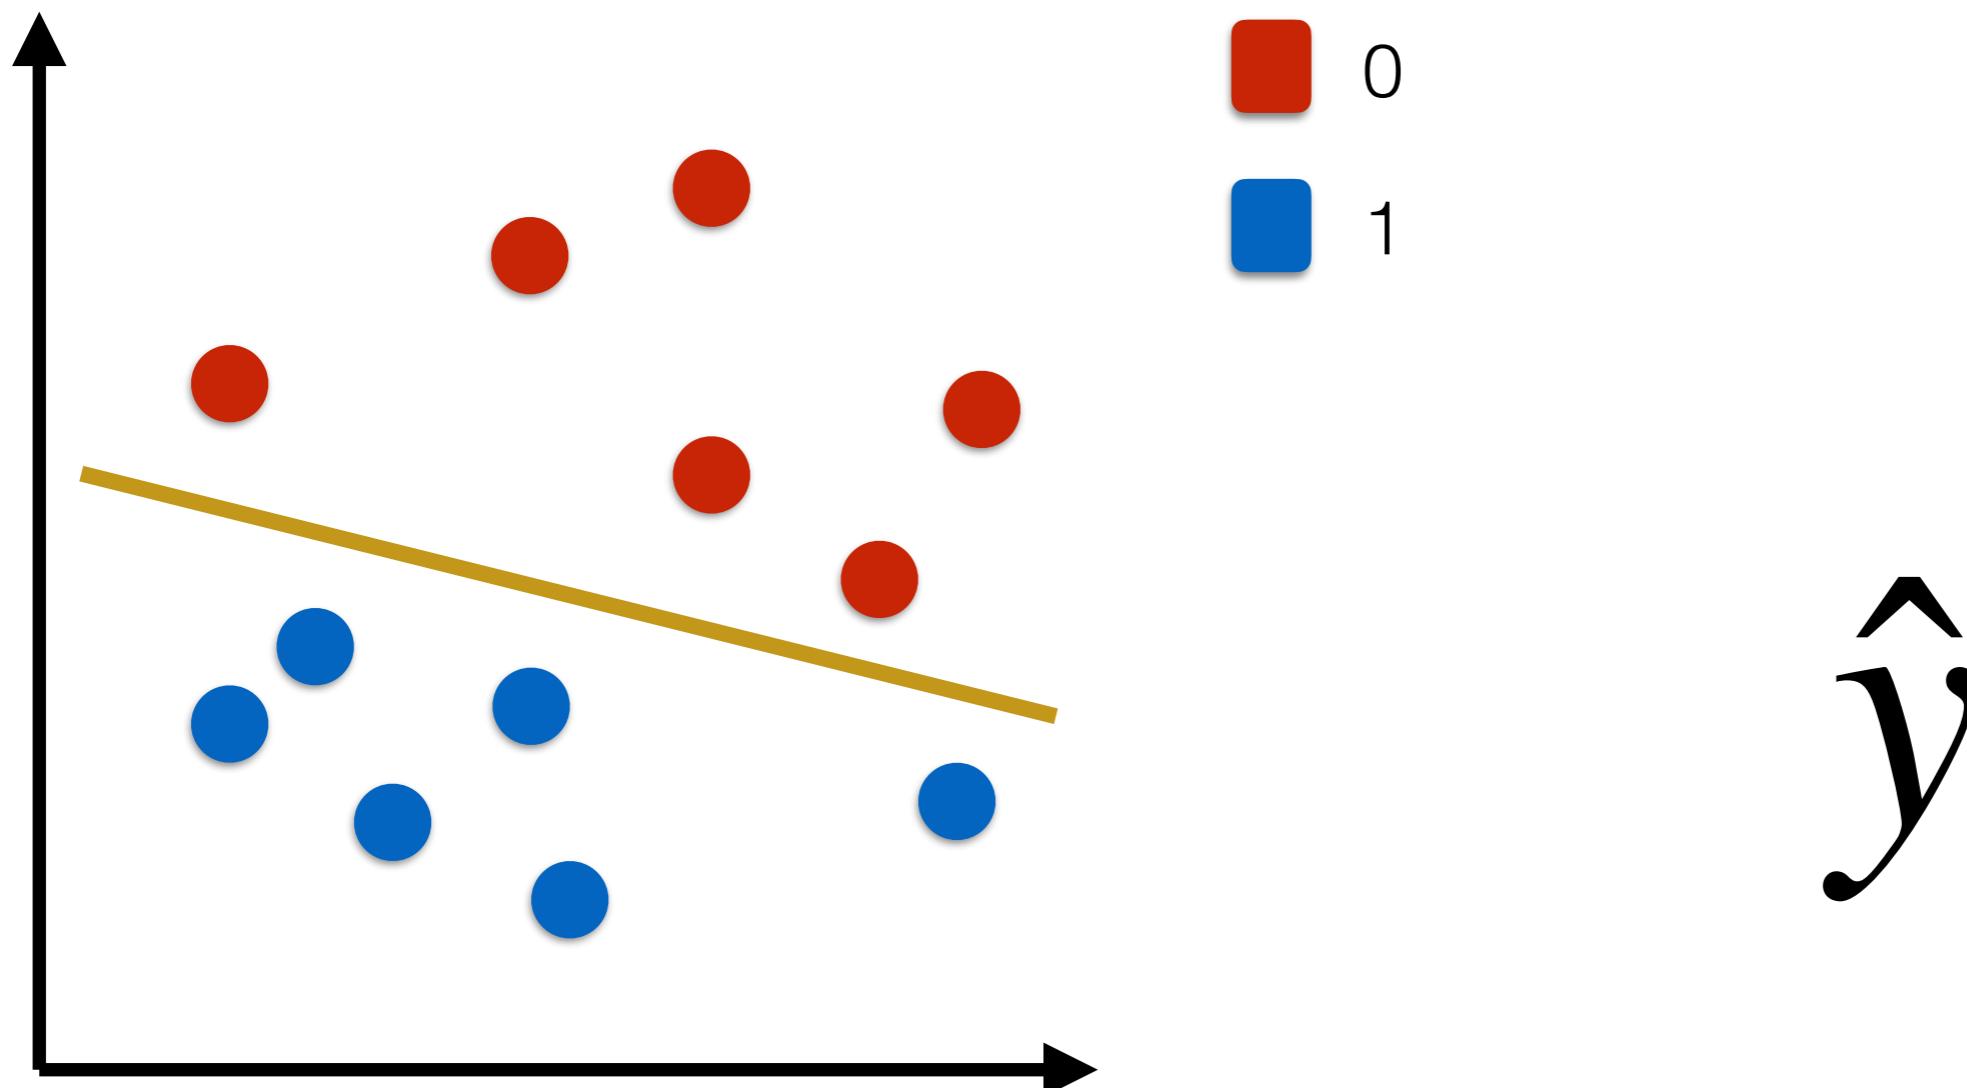
Para este caso,
podemos usar a simples
e conhecida **0-1 loss**:

$$L(\hat{y}, y_{real}) = \begin{cases} 0 & \hat{y} = y_{real} \\ 1 & \hat{y} \neq y_{real} \end{cases}$$

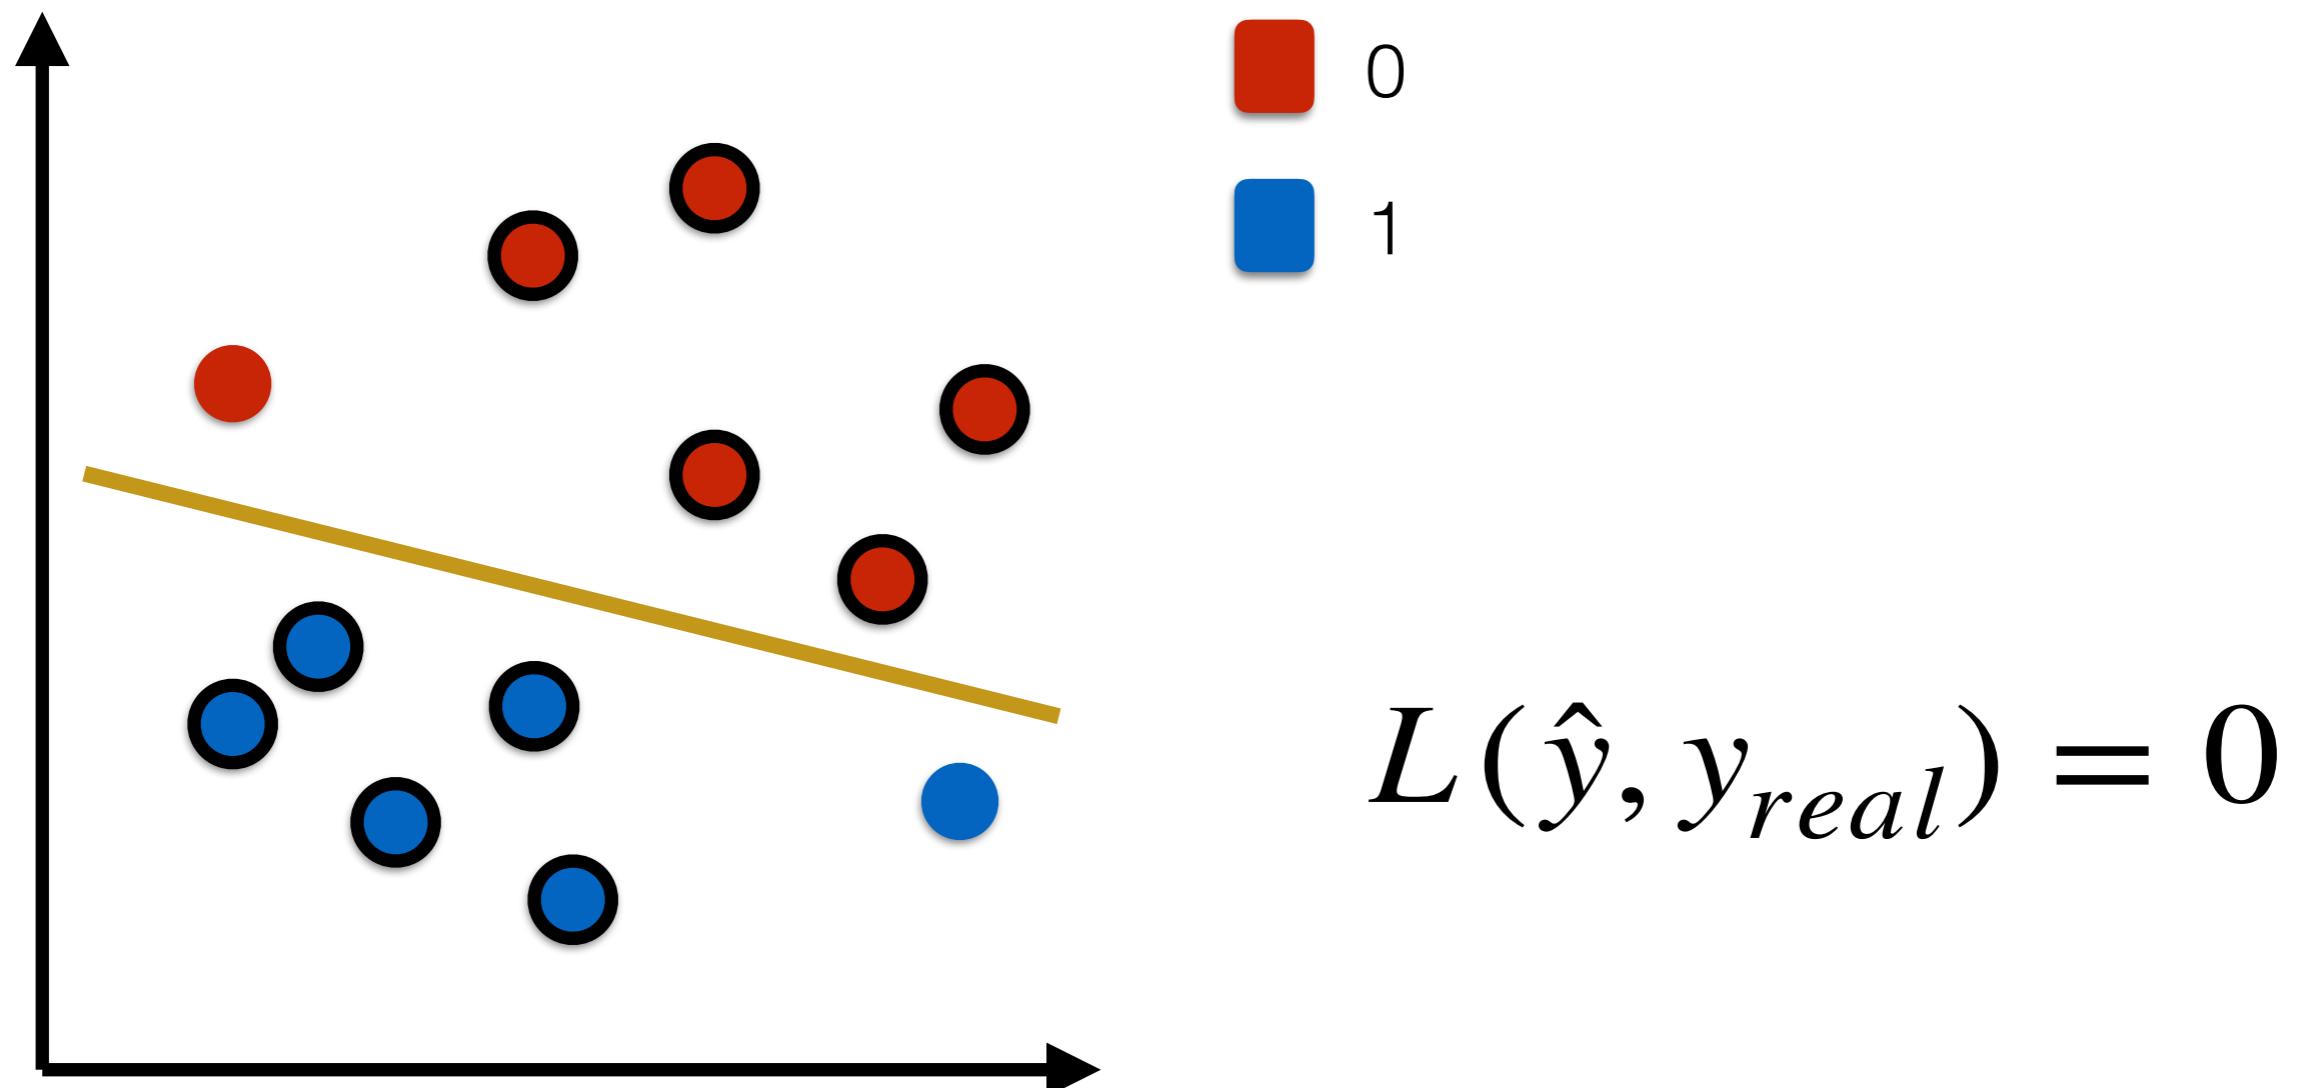
Funções de Custo



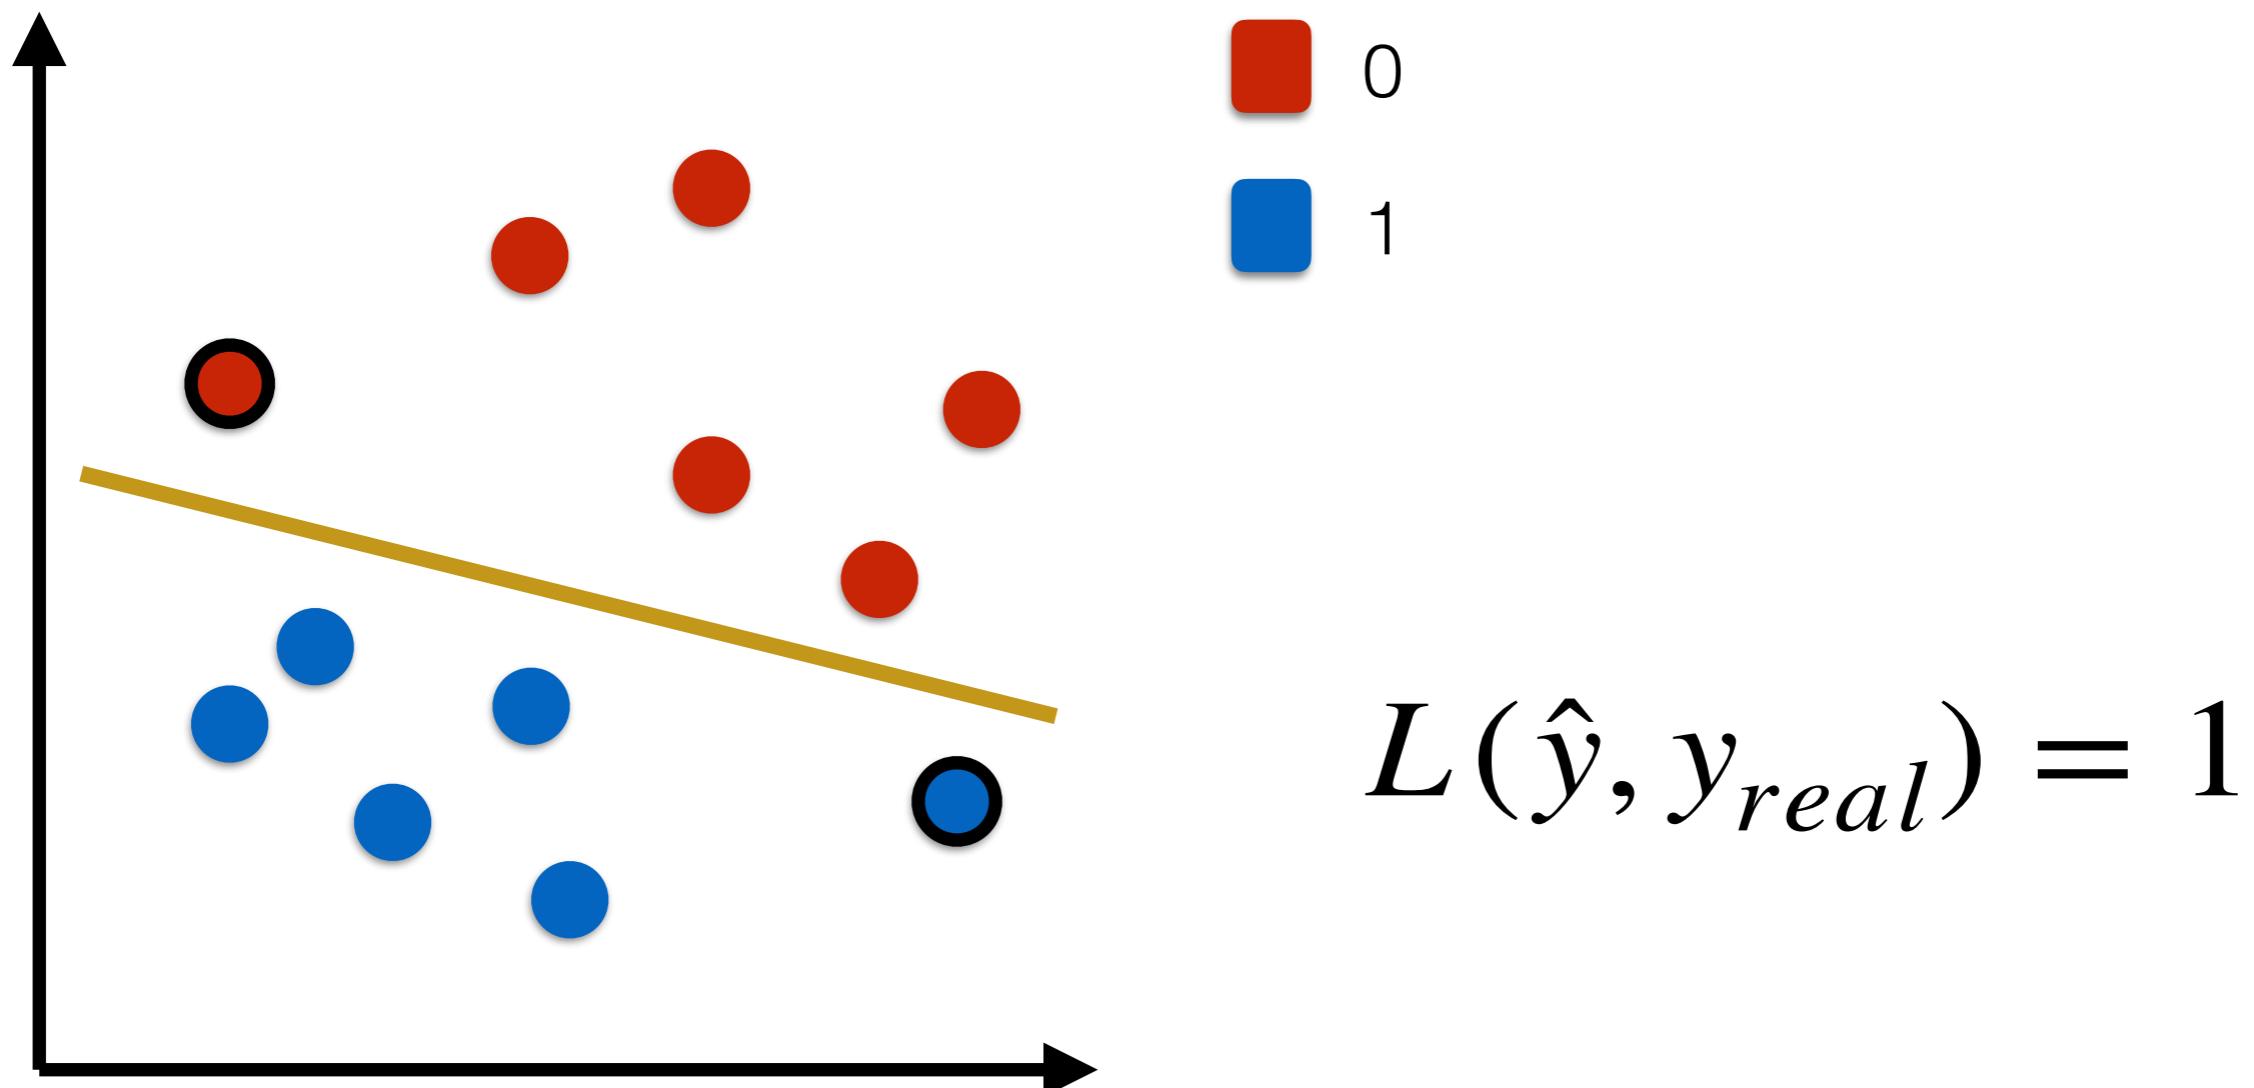
Funções de Custo



Funções de Custo



Funções de Custo



Risco de um Classificador

$$R_{emp}(f) = \frac{1}{m} \sum_{i=1}^m L(f(x_i), y_i)$$

O risco de um classificador é a soma do valor da função de custo em todos os pontos.

Risco de um Classificador

$$\arg \min_{f \in \mathbb{F}} R_{emp}(f) = \frac{1}{m} \sum_{i=1}^m L(f(x_i), y_i)$$

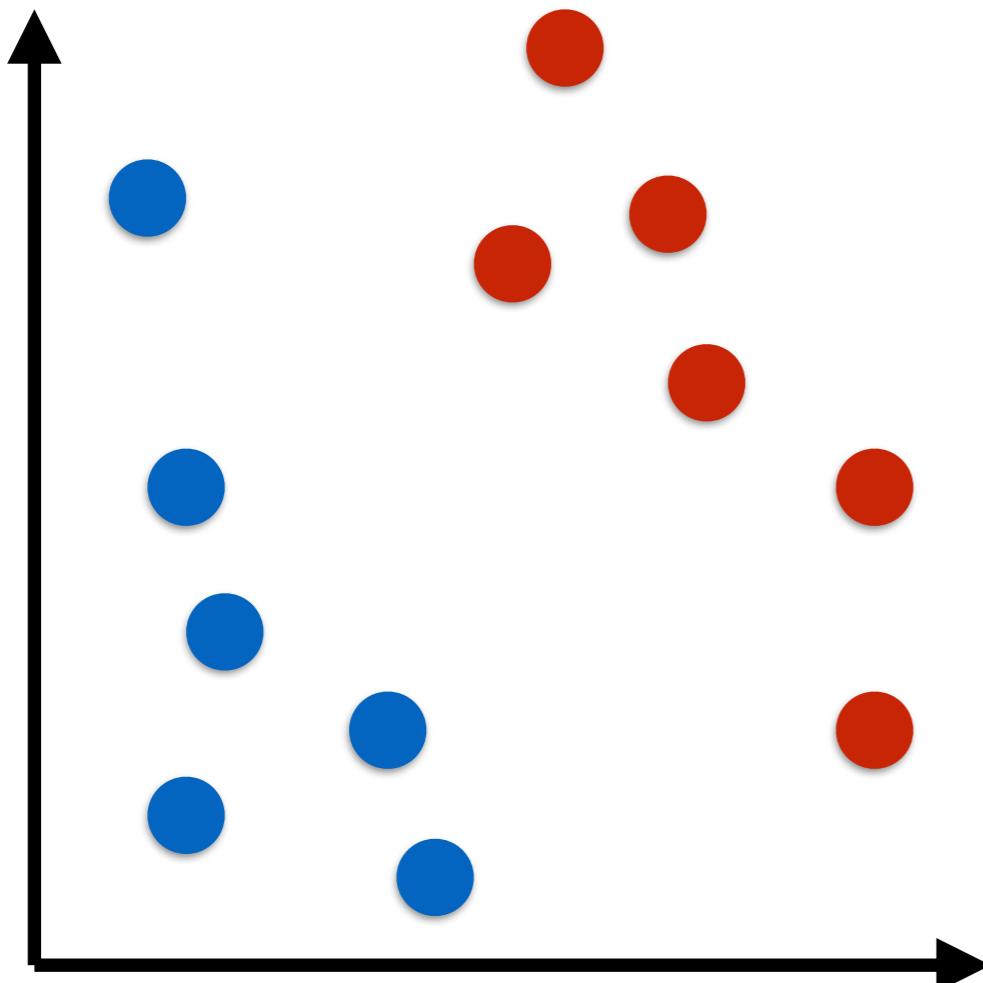
O objetivo de um algoritmo de classificação é tentar ao máximo diminuir esse risco (Princípio do *Empirical Risk Minimization*)

Generalização

$$G(f) = |R_{emp} - R_{real}|$$

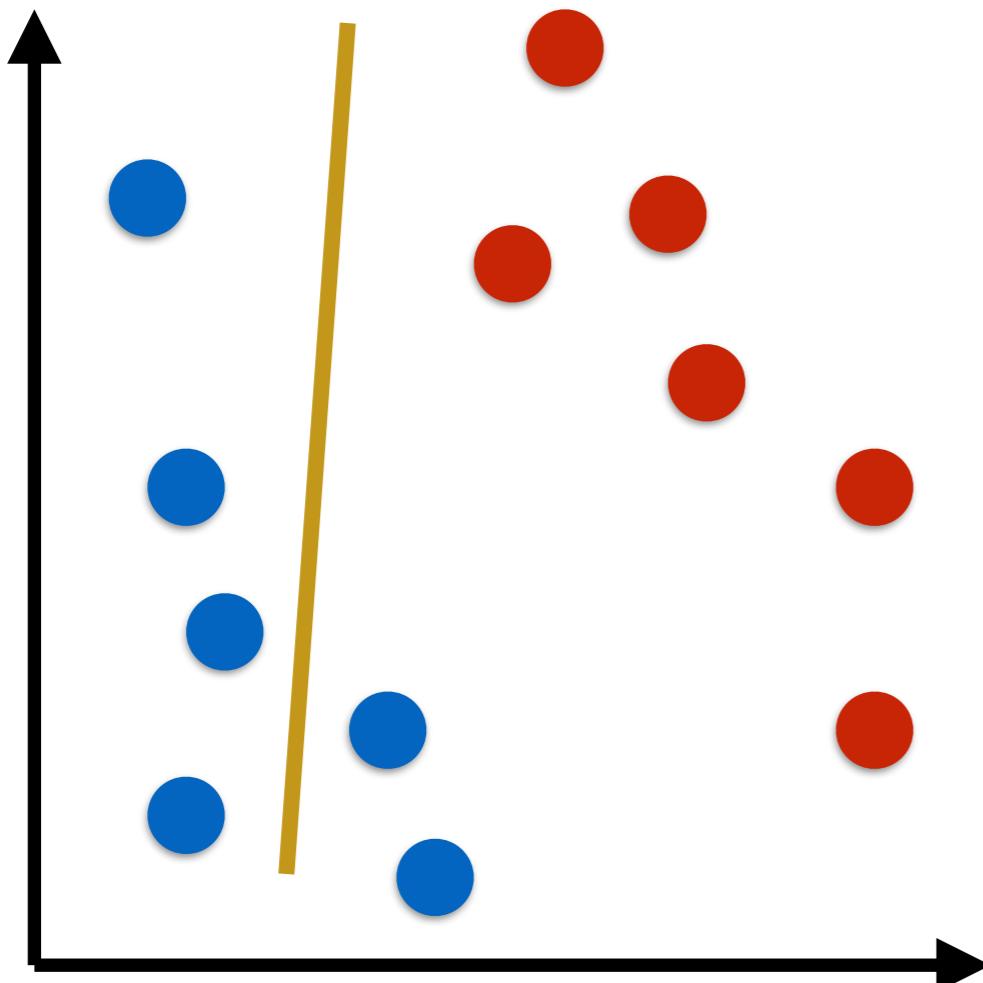
Esperamos que o risco empírico seja próximo do risco real (erros do classificador escolhido no mundo real).
Este é o conceito de Generalização

Underfitting



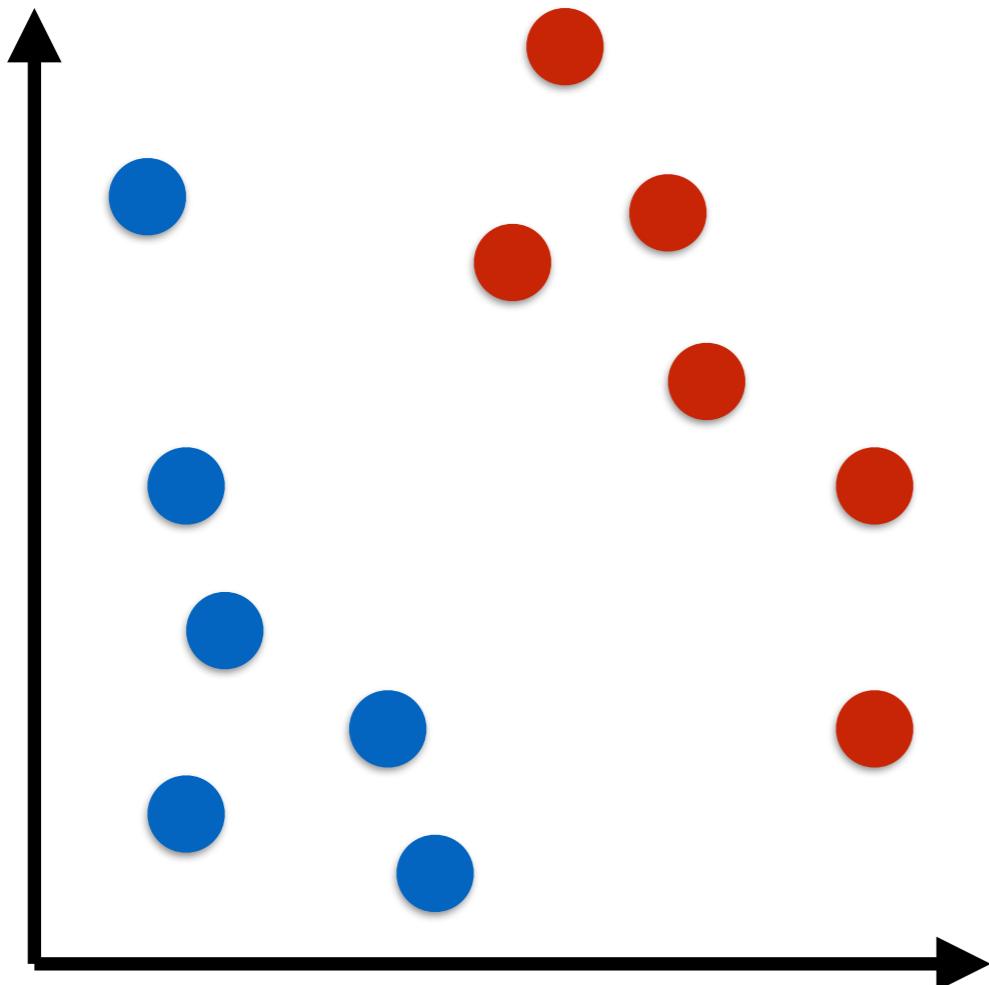
Comportamento
caracterizado por alto
risco empírico. Faltou
treinar mais?

Underfitting



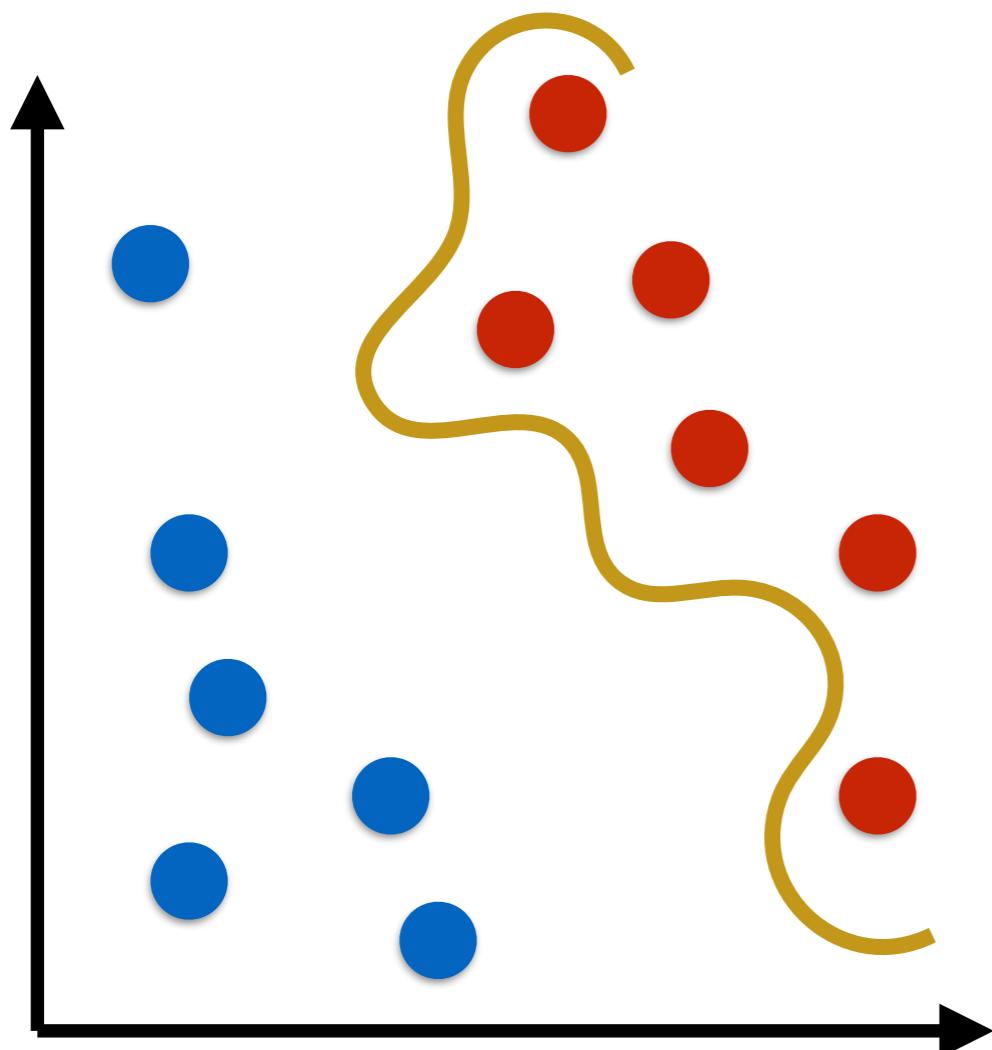
Comportamento
caracterizado por alto
risco empírico. Faltou
treinar mais?

Overfitting



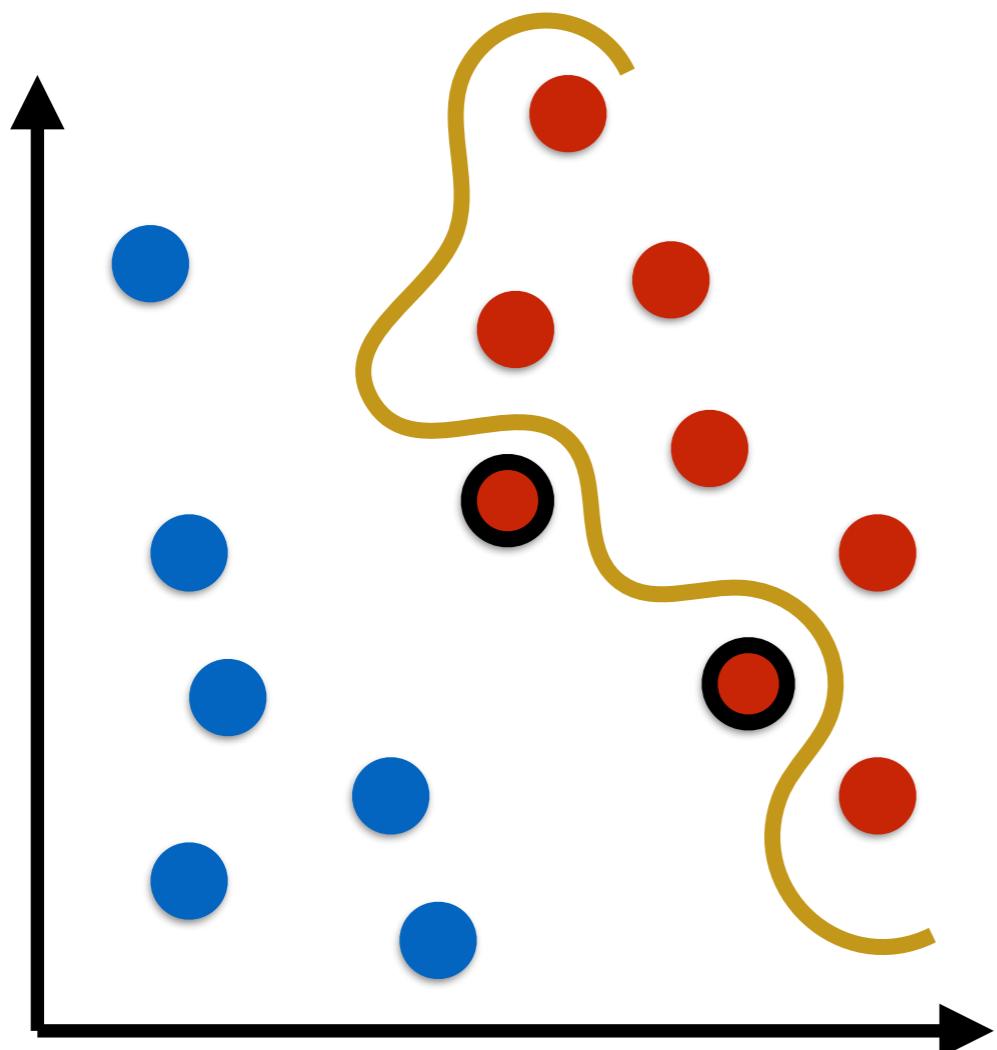
Caracterizado por
aderência muito forte aos
dados, memorização,
baixa generalização

Overfitting



Caracterizado por
aderência muito forte aos
dados, memorização,
baixa generalização

Overfitting



Caracterizado por
aderência muito forte aos
dados, memorização,
baixa **generalização**

DEMO

Ferramentas



Ferramentas



Python é uma linguagem de programação de alto nível, interpretada, de script, imperativa, orientada a objetos, funcional, de tipagem dinâmica e forte.

Ferramentas



Tensorflow é uma biblioteca de computação numérica baseada em grafos de fluxo de dados

Ferramentas



Keras é uma API de alto nível para redes neurais, escrita em Python e capaz de rodar sobre TensorFlow, CNTK ou Theano.

Como serão os DEMO's

Códigos dos DEMO's e versões de exercício para casa, bem como todos os slides, estão em:

<https://github.com/leosampaio/eri-deep-learning-course.git>

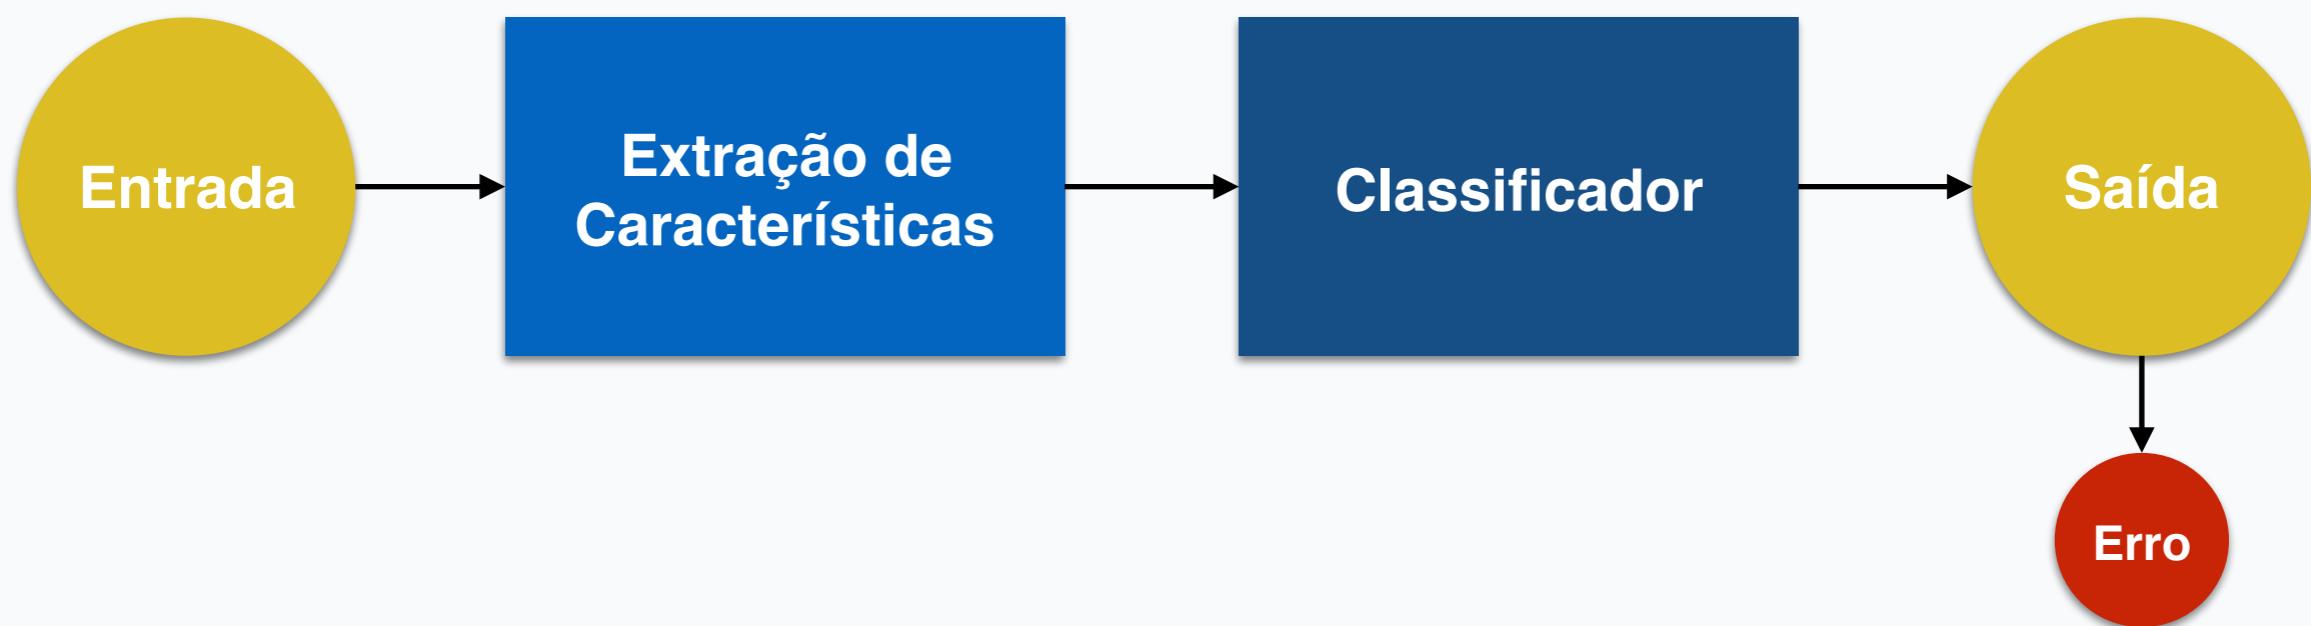
git.io/vxvUI

DEMO #1

Introdução a Machine Learning

DEMO #1

Introdução a Machine Learning



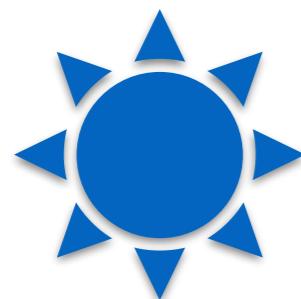
Aprendizagem de Máquina

Breve (e simplificada) História

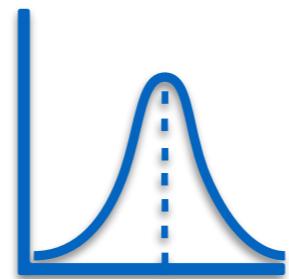


Aprendizagem de Máquina

Breve (e simplificada) História



~1960



1960~1970



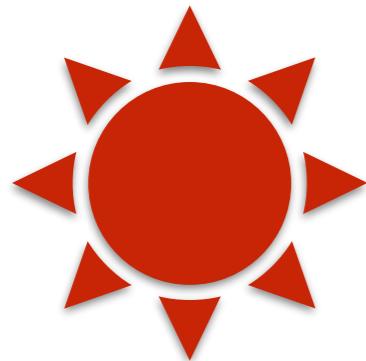
1970~1980



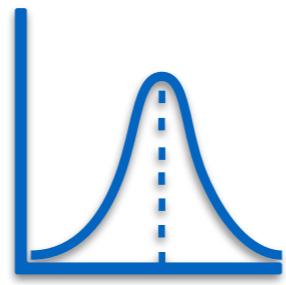
1980~2000

Aprendizagem de Máquina

Breve (e simplificada) História



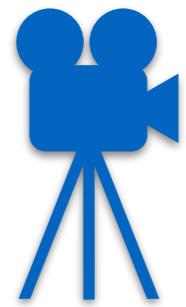
~1960



1960~1970



1970~1980

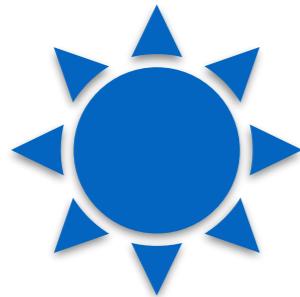


1980~2000

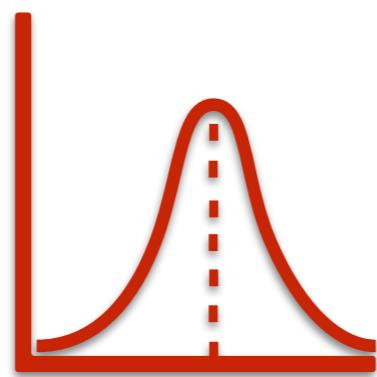
Primeiros algoritmos de IA guiados pelos dados, entre eles a primeira Rede Neural, o Perceptron (que discutiremos depois) e o alg. *k-Nearest Neighbours*

Aprendizagem de Máquina

Breve (e simplificada) História



~1960



1960~1970



1970~1980

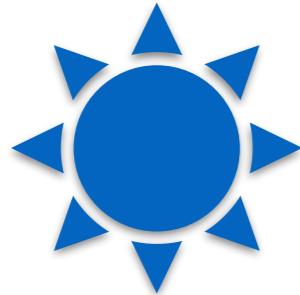


1980~2000

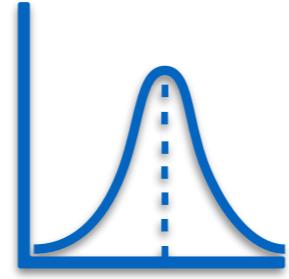
Métodos bayesianos são introduzidos, em conjunto com eles, pesquisadores da área exploram perspectivas estatísticas para o aprendizado guiado pelos dados

Aprendizagem de Máquina

Breve (e simplificada) História



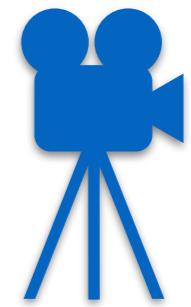
~1960



1960~1970



1970~1980

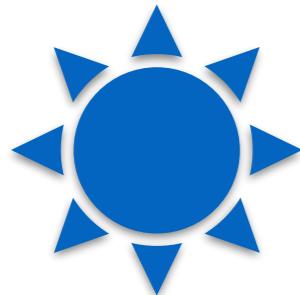


1980~2000

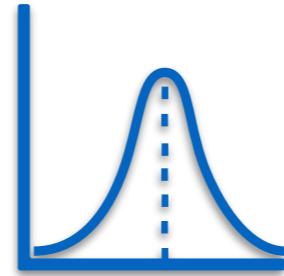
A área de ML passa por um período de pouca pesquisa, com IA focada em métodos baseados em *conhecimento* e programação lógica.

Aprendizagem de Máquina

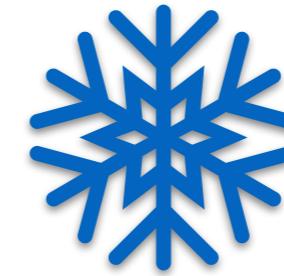
Breve (e simplificada) História



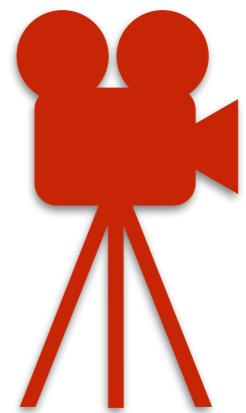
~1960



1960~1970



1970~1980

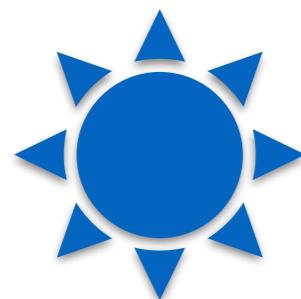


1980~2000

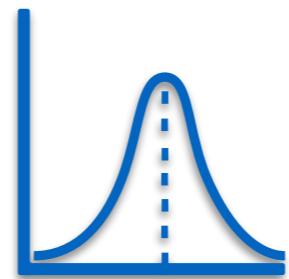
Novos métodos de ML surgem, a área ganha força novamente graças a grandes contribuições como a Teoria do Aprendizado Estatístico e *Support Vector Machines*.

Aprendizagem de Máquina

Breve (e simplificada) História



~1960



1960~1970



1970~1980



1980~2000

Aprendizagem de Máquina

Breve (e simplificada) História



para ressaltar a beleza e
importância do desenvolvimento
das SVMs

Aprendizagem de Máquina

Breve (e simplificada) História



para ressaltar a beleza e
importância do desenvolvimento
das SVMs

Anos de desenvolvimento por parte da equipe de Vapnick e contribuidores culminaram na SVM, o algoritmo de classificação linear “perfeito” (se você souber usa-lo) e com forte embasamento teórico.

Aprendizagem de Máquina

Breve (e simplificada) História



2000~2005



2010~atual

Aprendizagem de Máquina

Breve (e simplificada) História



2000~2005



2010~atual

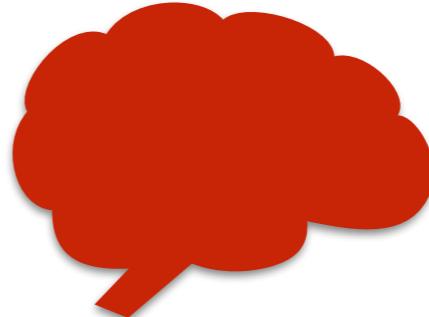
Extratores de características e métodos baseados em kernel's são muito explorados. Começam a surgir competições de ML.

Aprendizagem de Máquina

Breve (e simplificada) História



2000~2005



2010~atual

Redes Neurais Convolucionais se tornam viáveis.
Deep Learning entra “na moda” e problemas antes
insolúveis são atacados

Introdução a

Aprendizado de Máquina



Cronograma da Apresentação

Aprendizagem de
Máquina

Definição e
Conceitos
Principais

Função de Custo
e o Risco

História

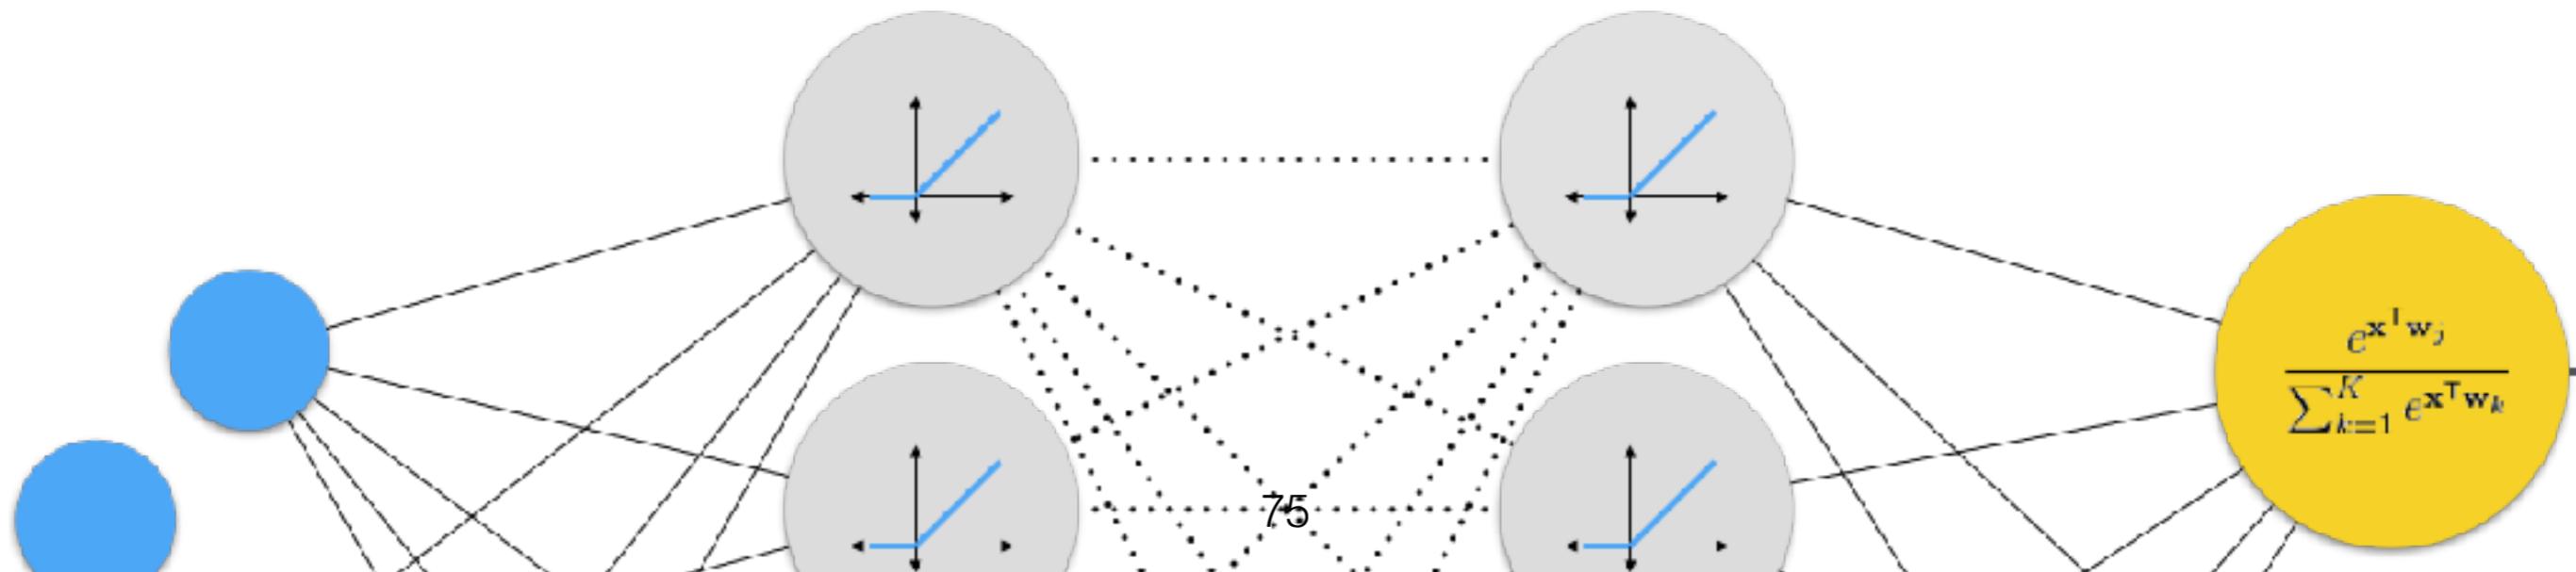
Cronograma da Apresentação

Aprendizagem de
Máquina

Perceptron

Multi-layer
Perceptron

Perceptron e Multi-layer Perceptron

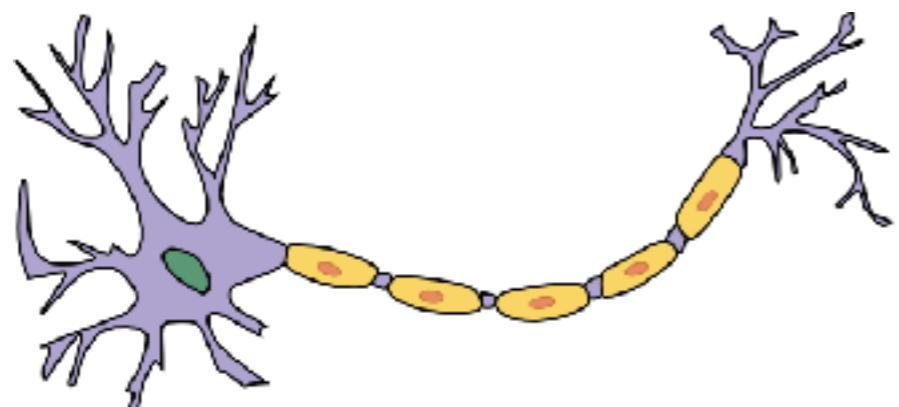


Redes Neurais Artificiais

modelo de aprendizado de máquina

Redes Neurais Artificiais

modelo de aprendizado de máquina



fracamente baseado
no sistema biológico

Redes Neurais Artificiais

modelo mais simples (Perceptron)

Redes Neurais Artificiais

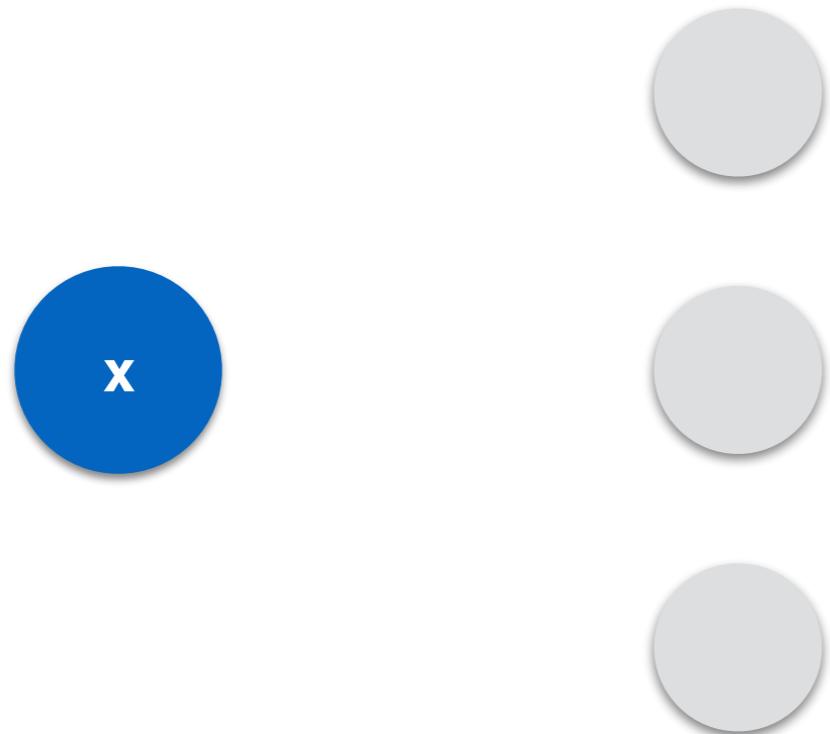
modelo mais simples (Perceptron)



entrada
(dado)

Redes Neurais Artificiais

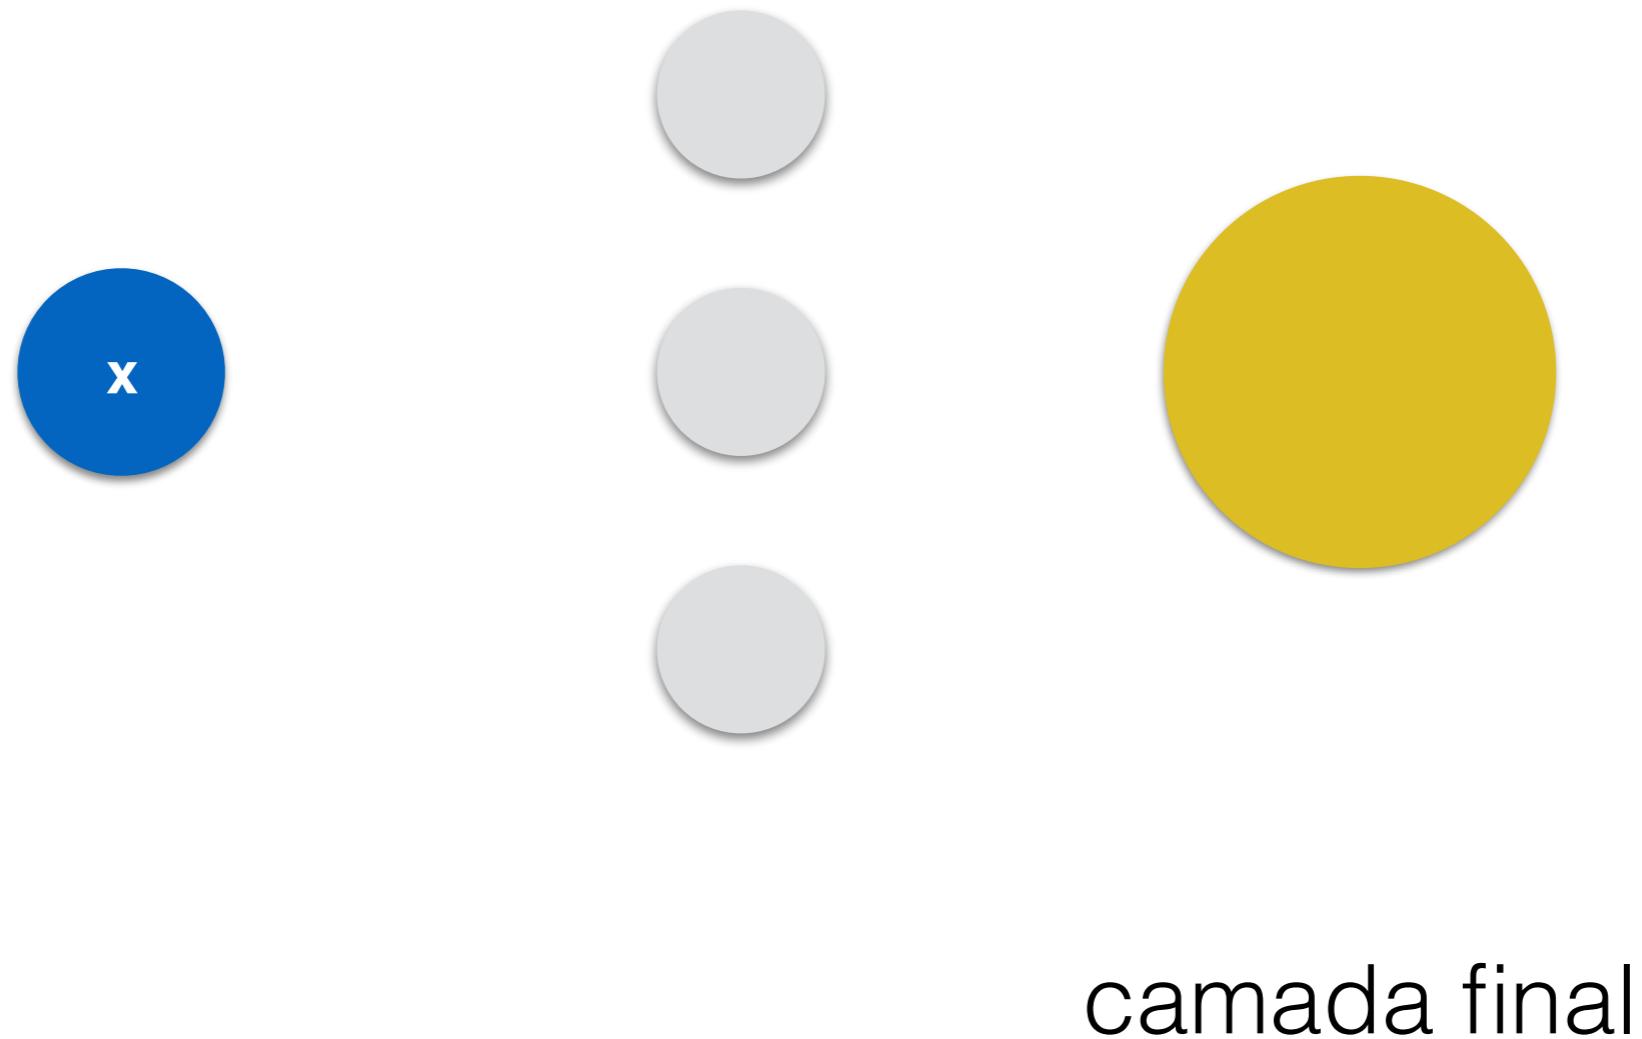
modelo mais simples (Perceptron)



camada
de neurônios

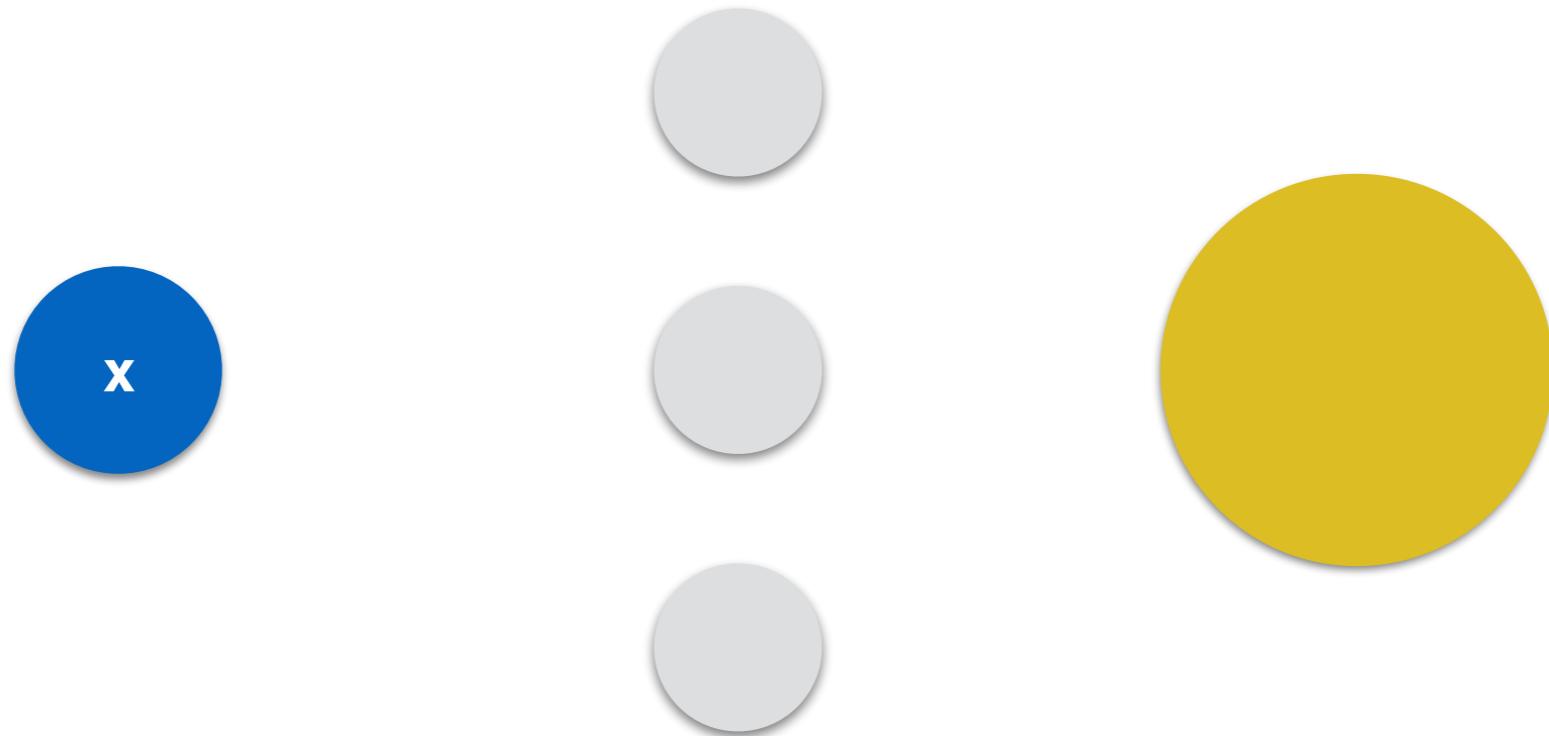
Redes Neurais Artificiais

modelo mais simples (Perceptron)



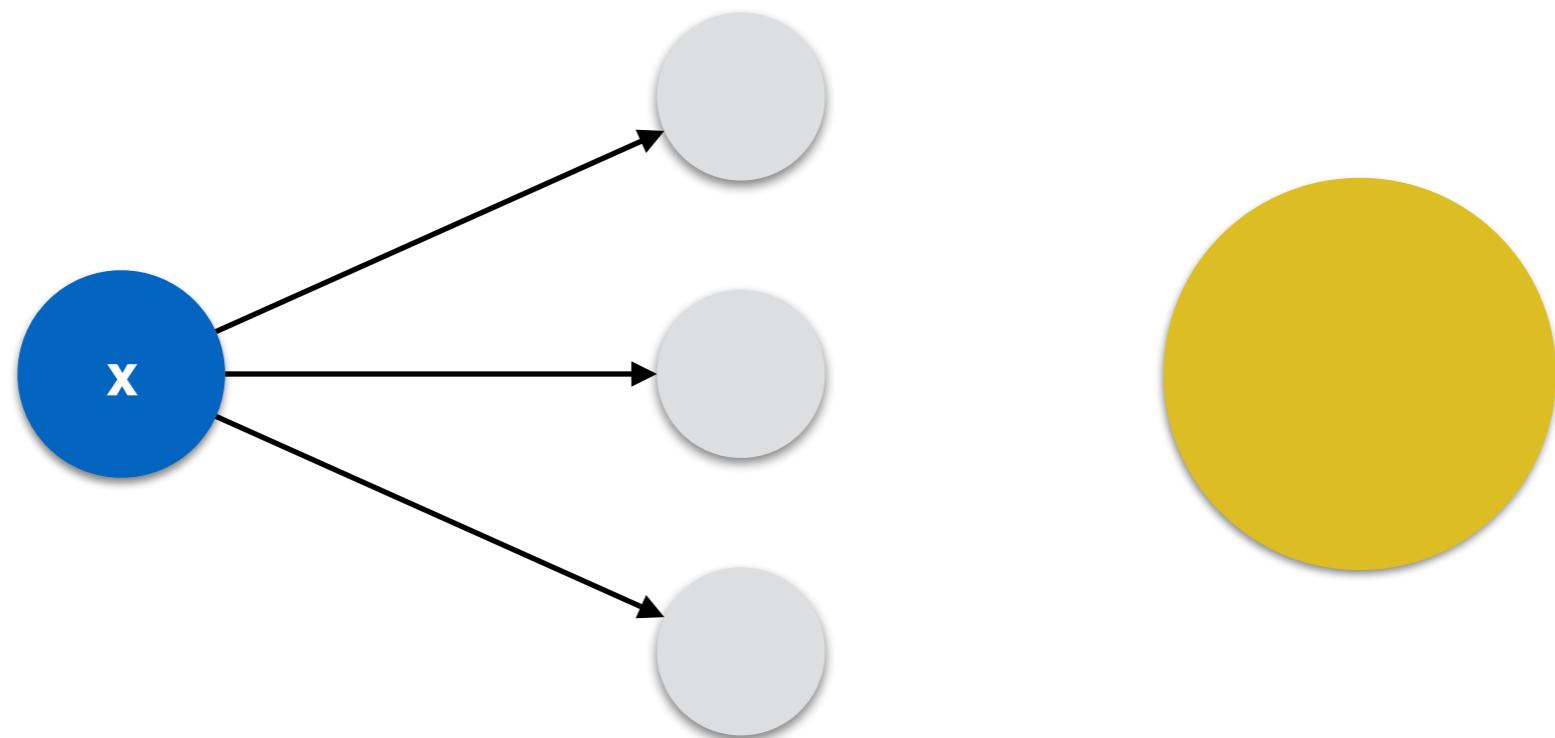
Redes Neurais Artificiais

modelo mais simples (Perceptron)



Redes Neurais Artificiais

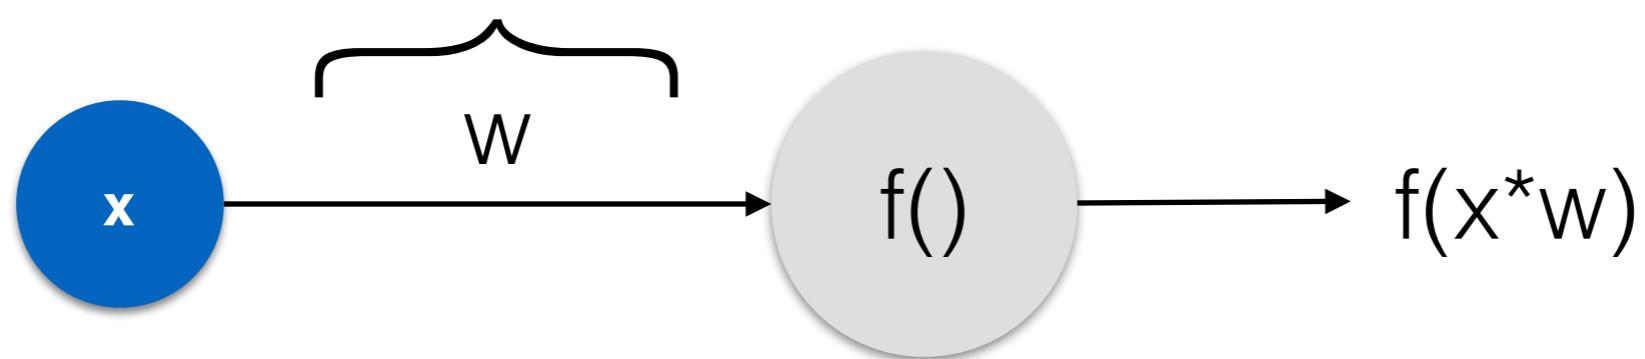
modelo mais simples (Perceptron)



Redes Neurais Artificiais

modelo mais simples (Perceptron)

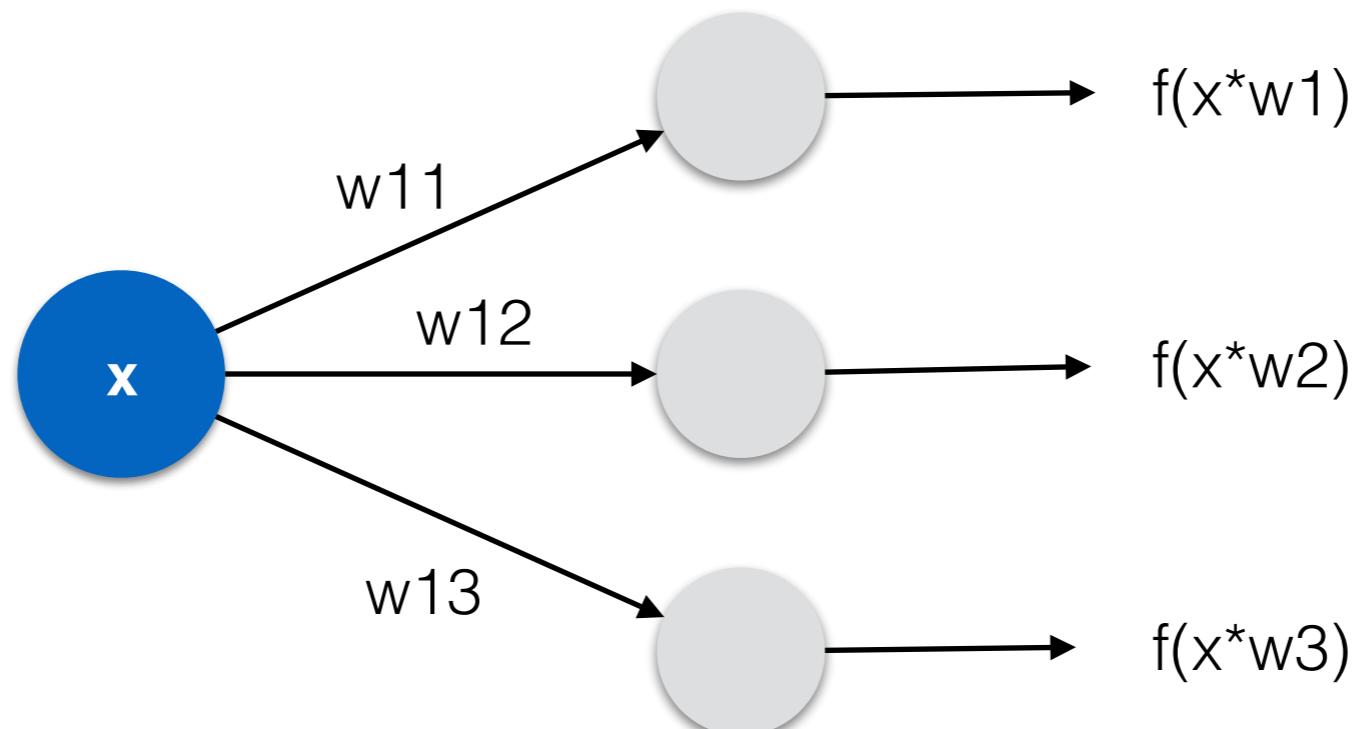
peso da conexão (multiplicador)



função de ativação

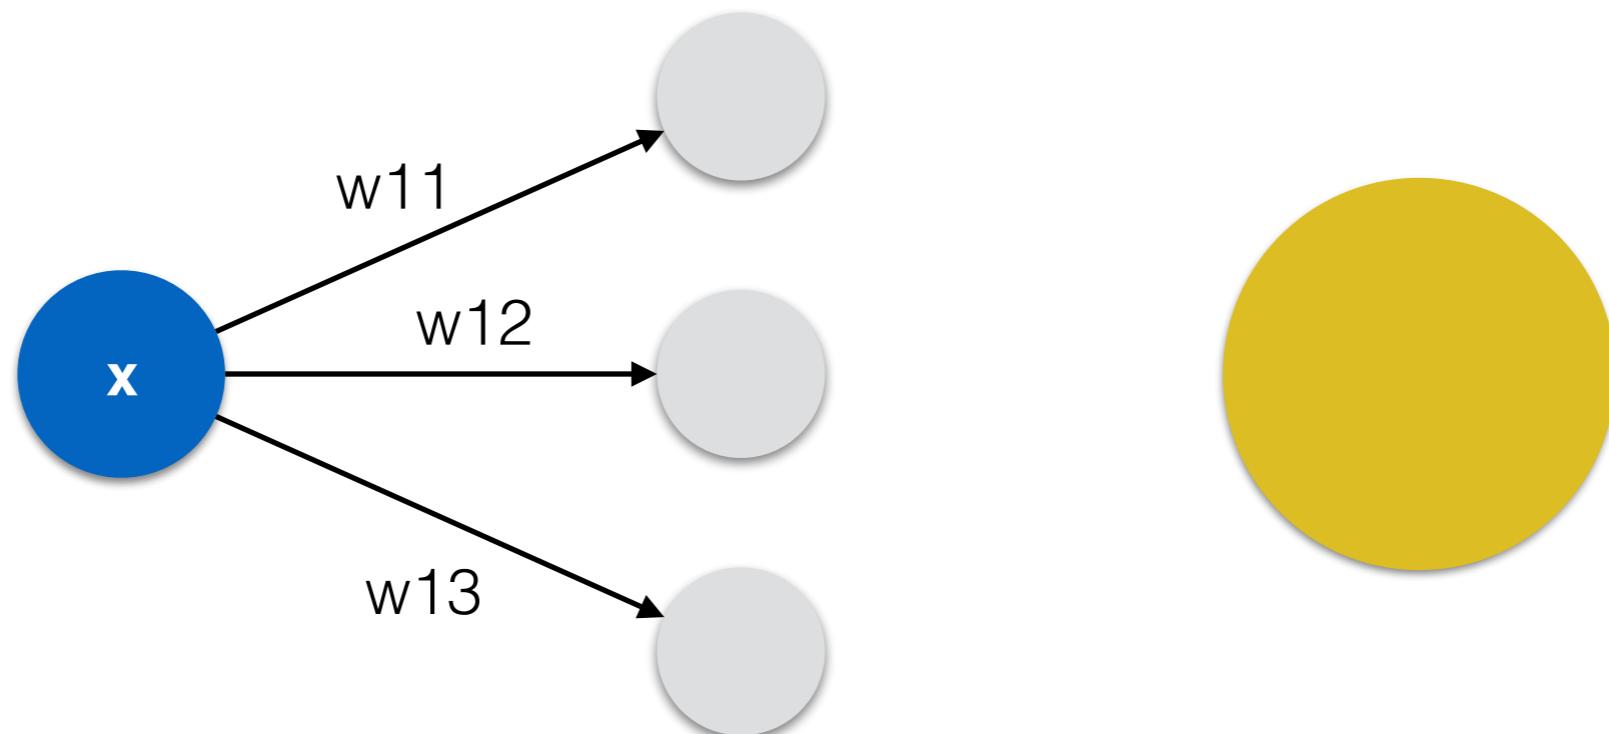
Redes Neurais Artificiais

modelo mais simples (Perceptron)



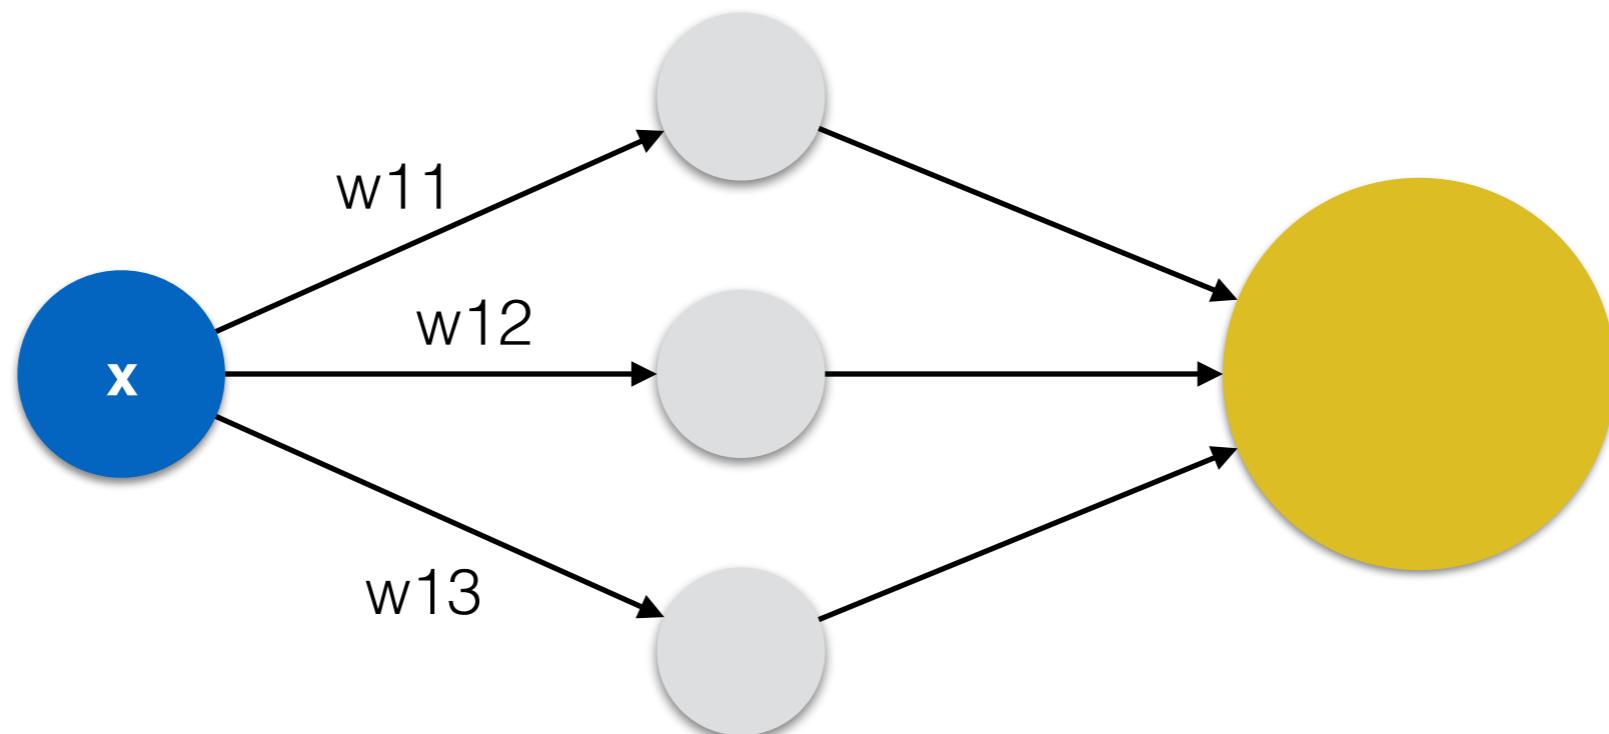
Redes Neurais Artificiais

modelo mais simples (Perceptron)



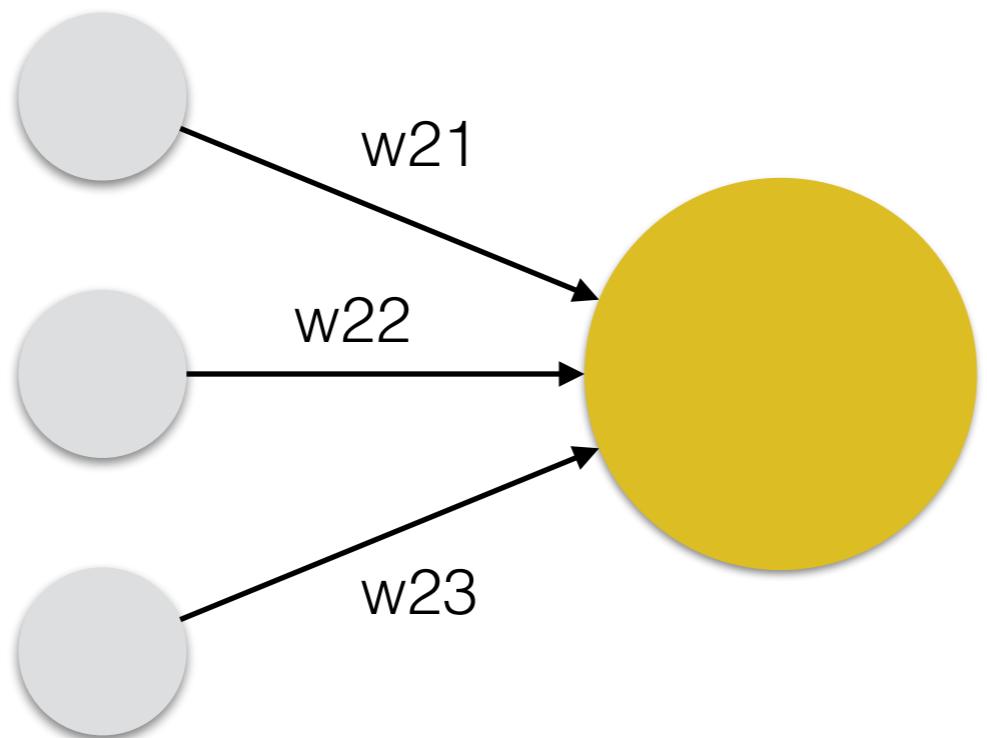
Redes Neurais Artificiais

modelo mais simples (Perceptron)



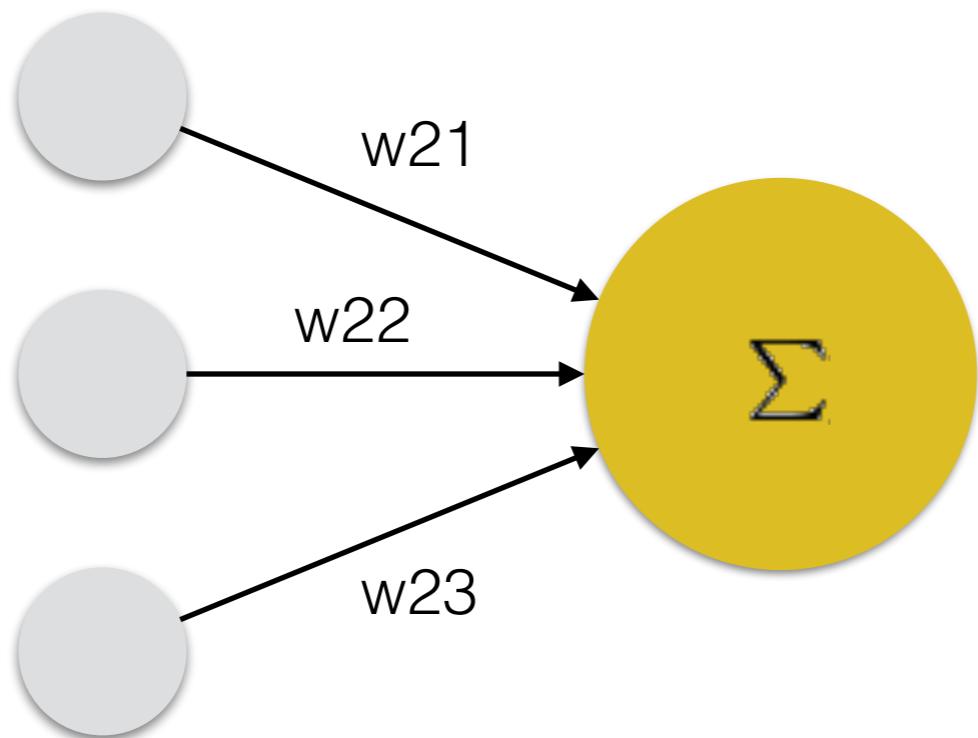
Redes Neurais Artificiais

modelo mais simples (Perceptron)



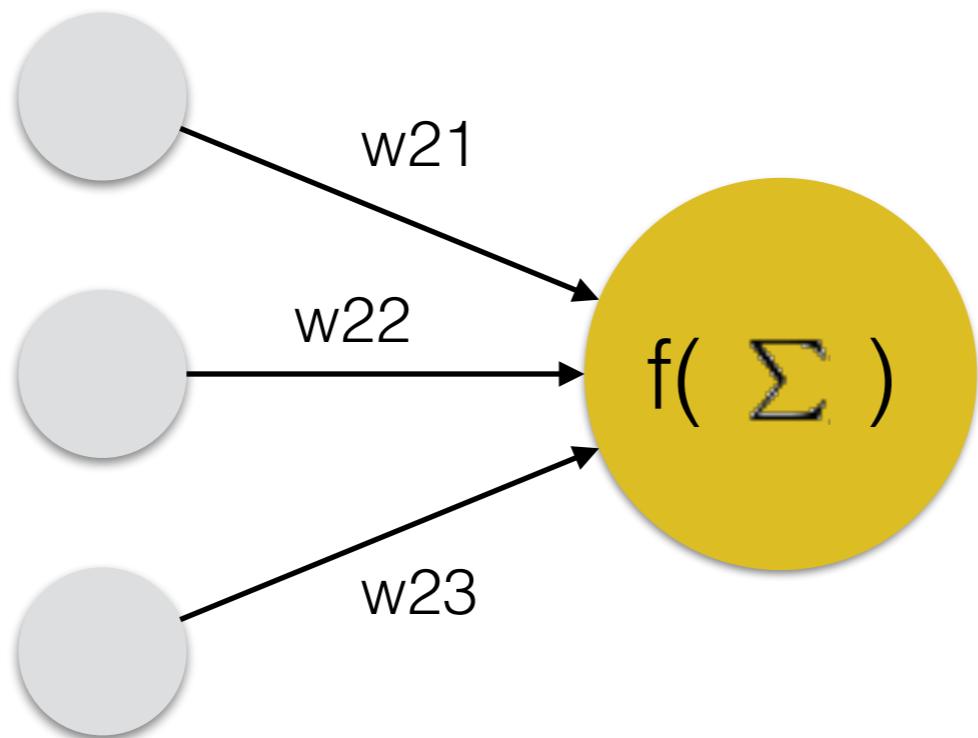
Redes Neurais Artificiais

modelo mais simples (Perceptron)



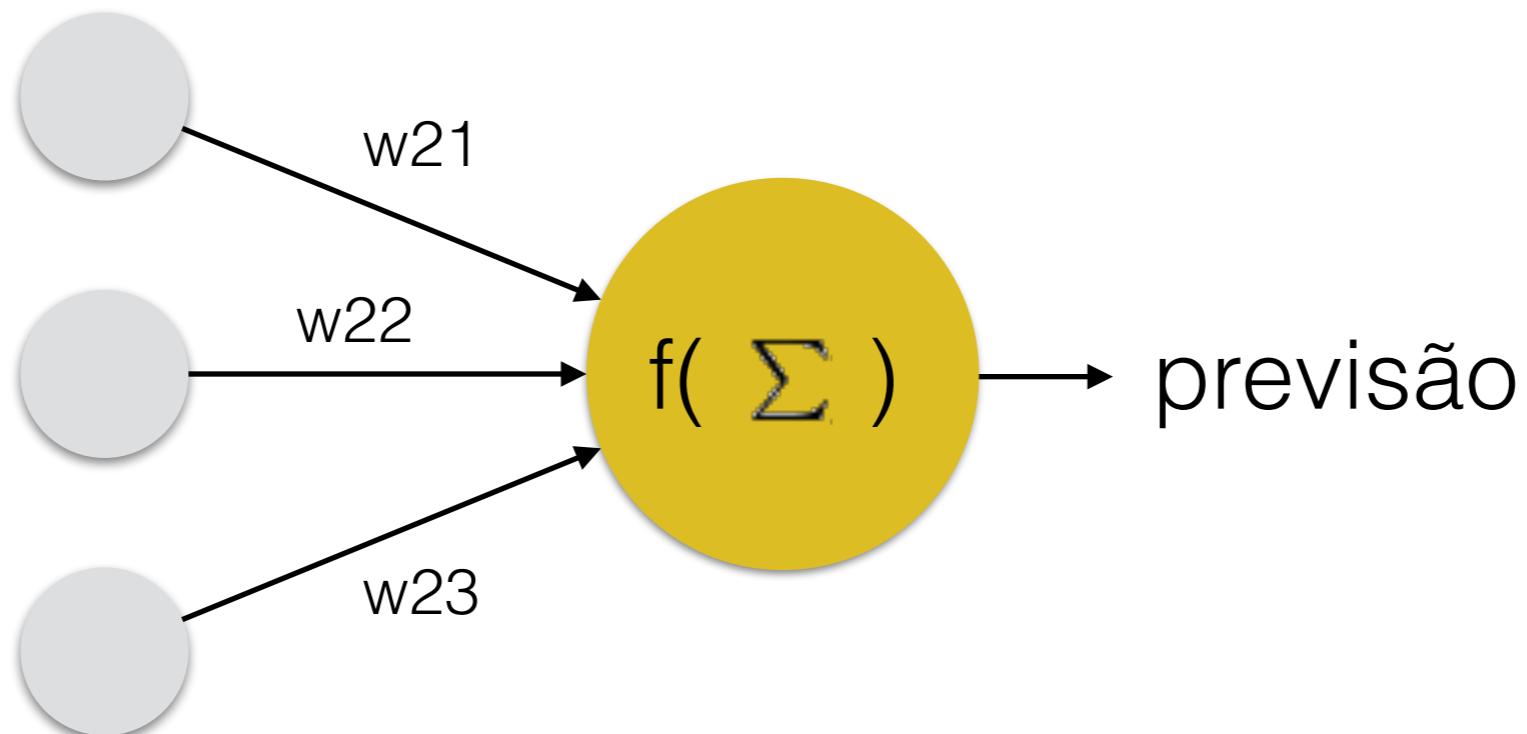
Redes Neurais Artificiais

modelo mais simples (Perceptron)



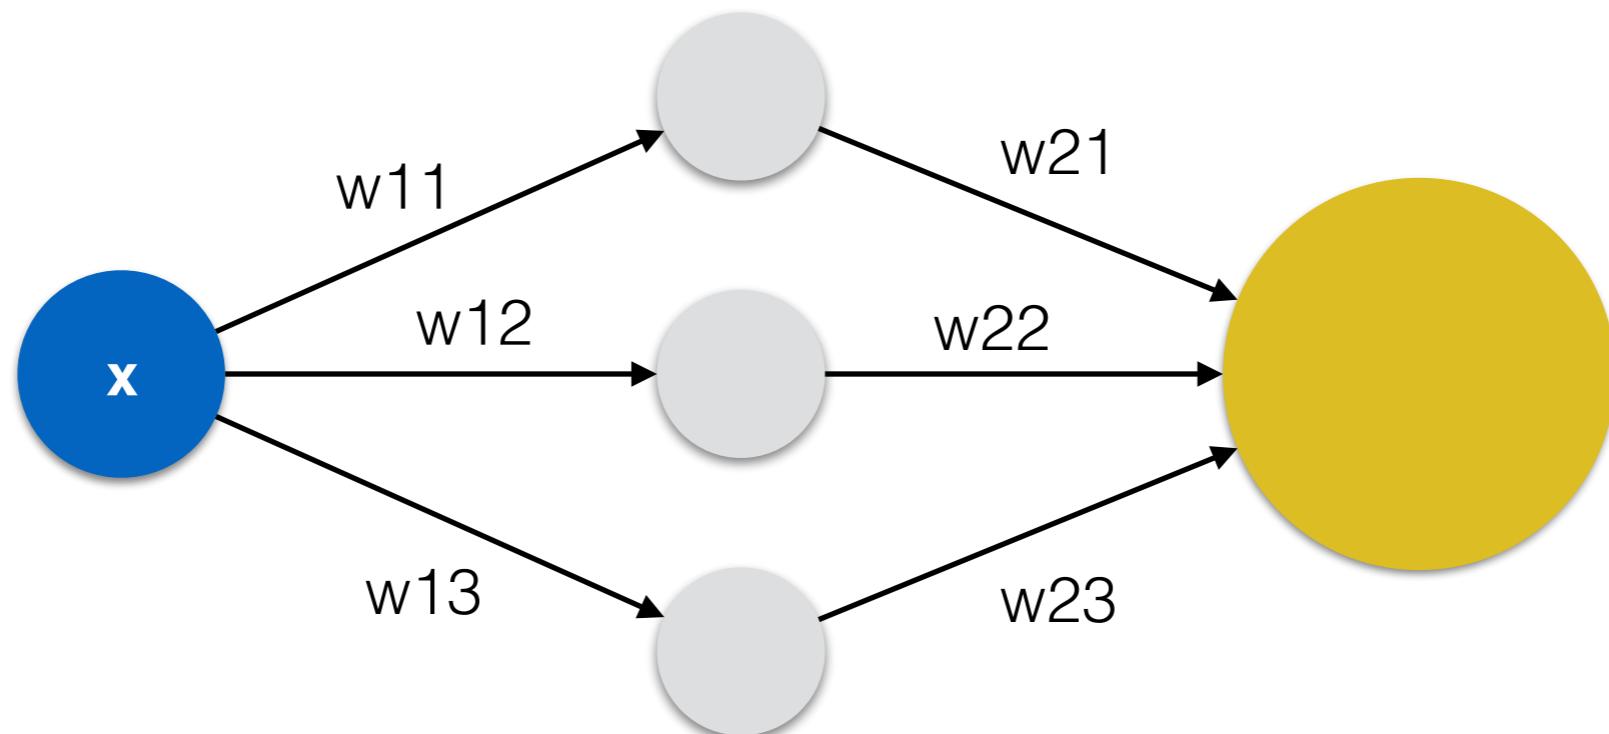
Redes Neurais Artificiais

modelo mais simples (Perceptron)



Redes Neurais Artificiais

modelo mais simples (Perceptron)



Redes Neurais Artificiais

o classificador de frutas



Redes Neurais Artificiais

o classificador de frutas



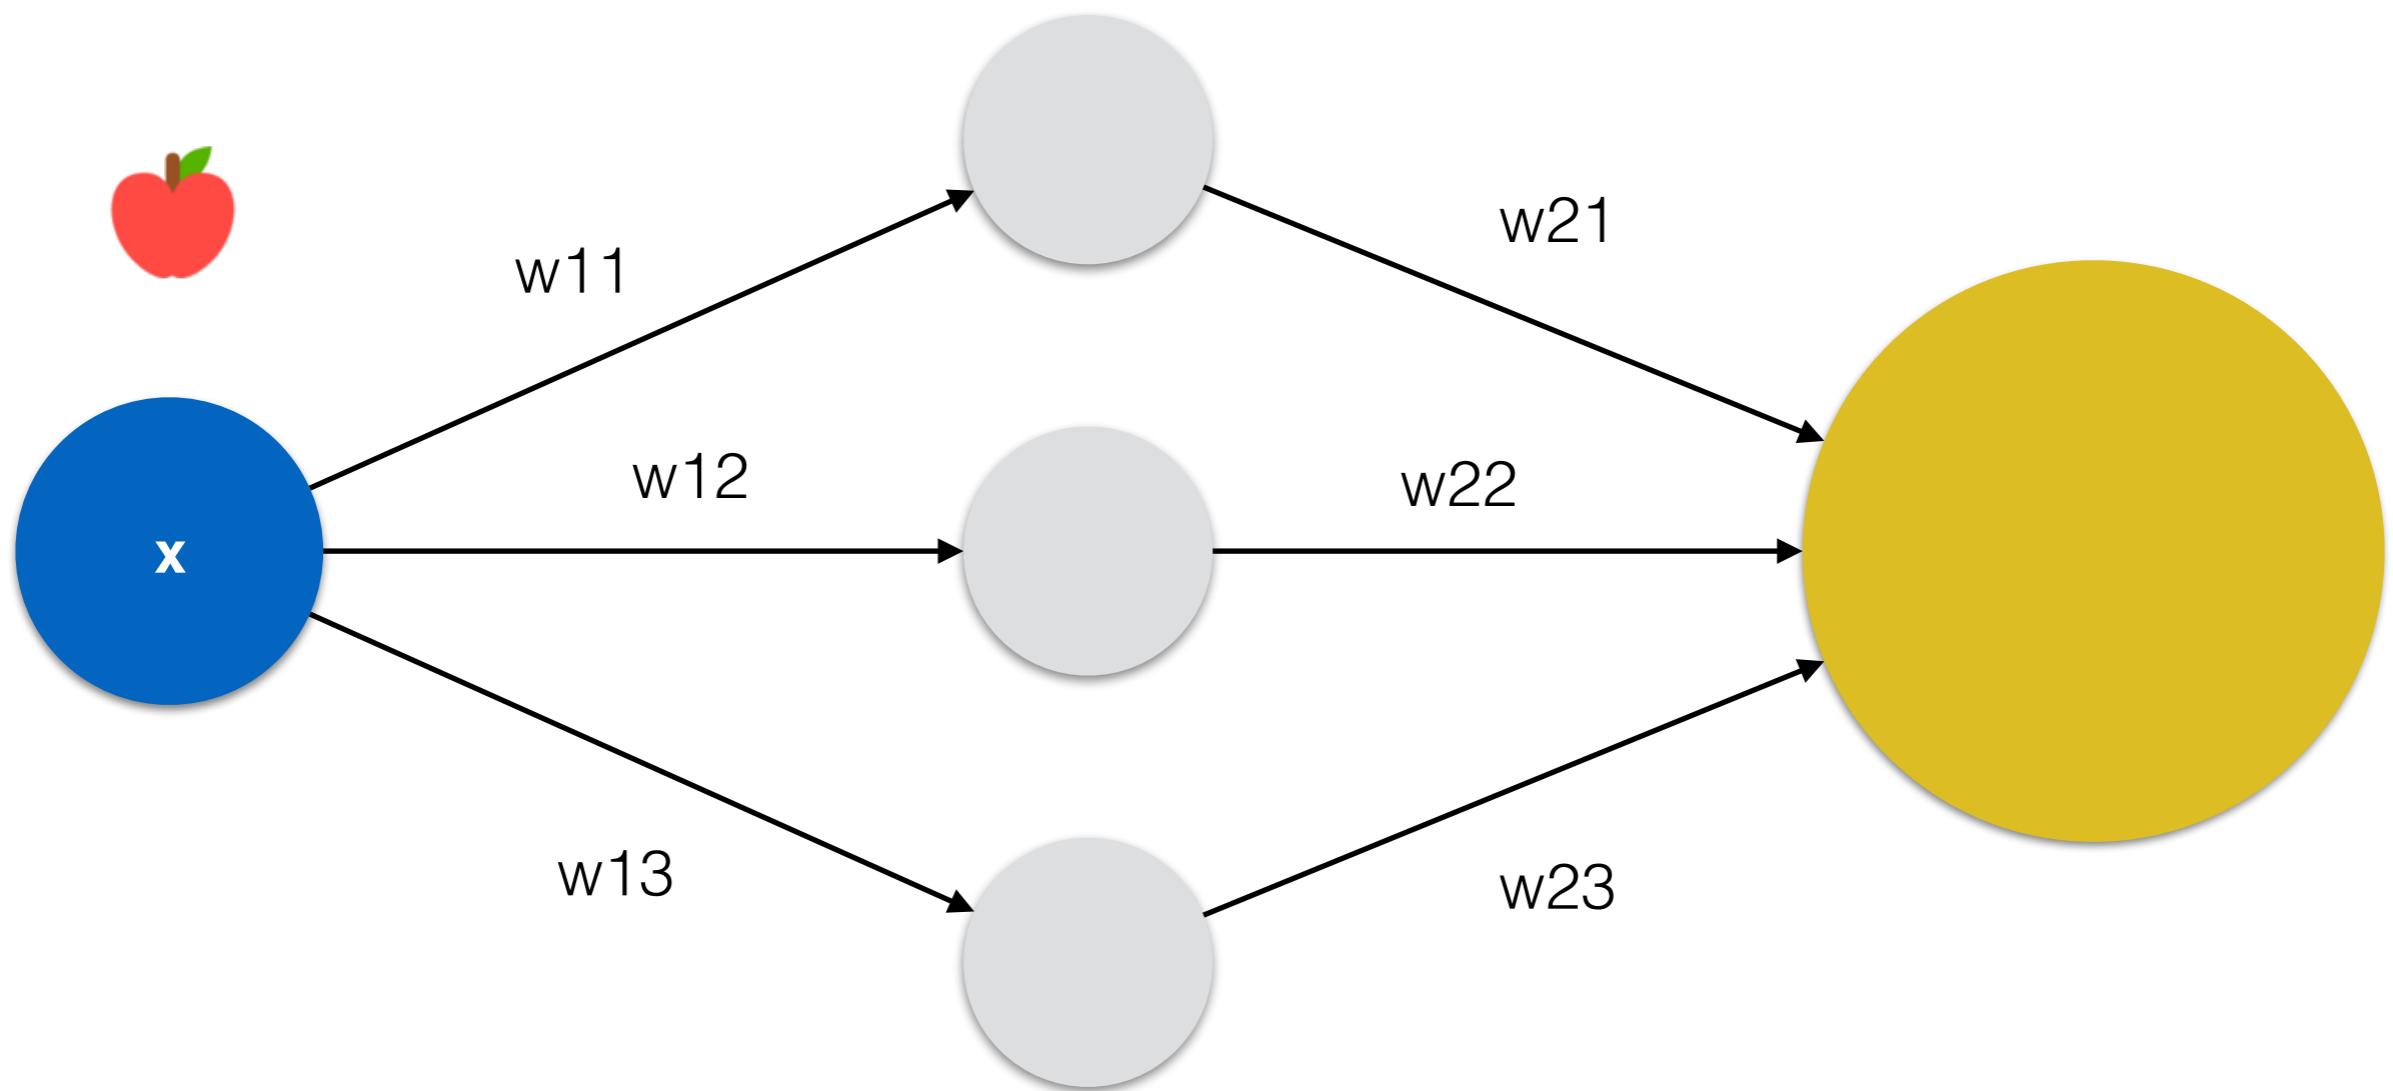
1



0

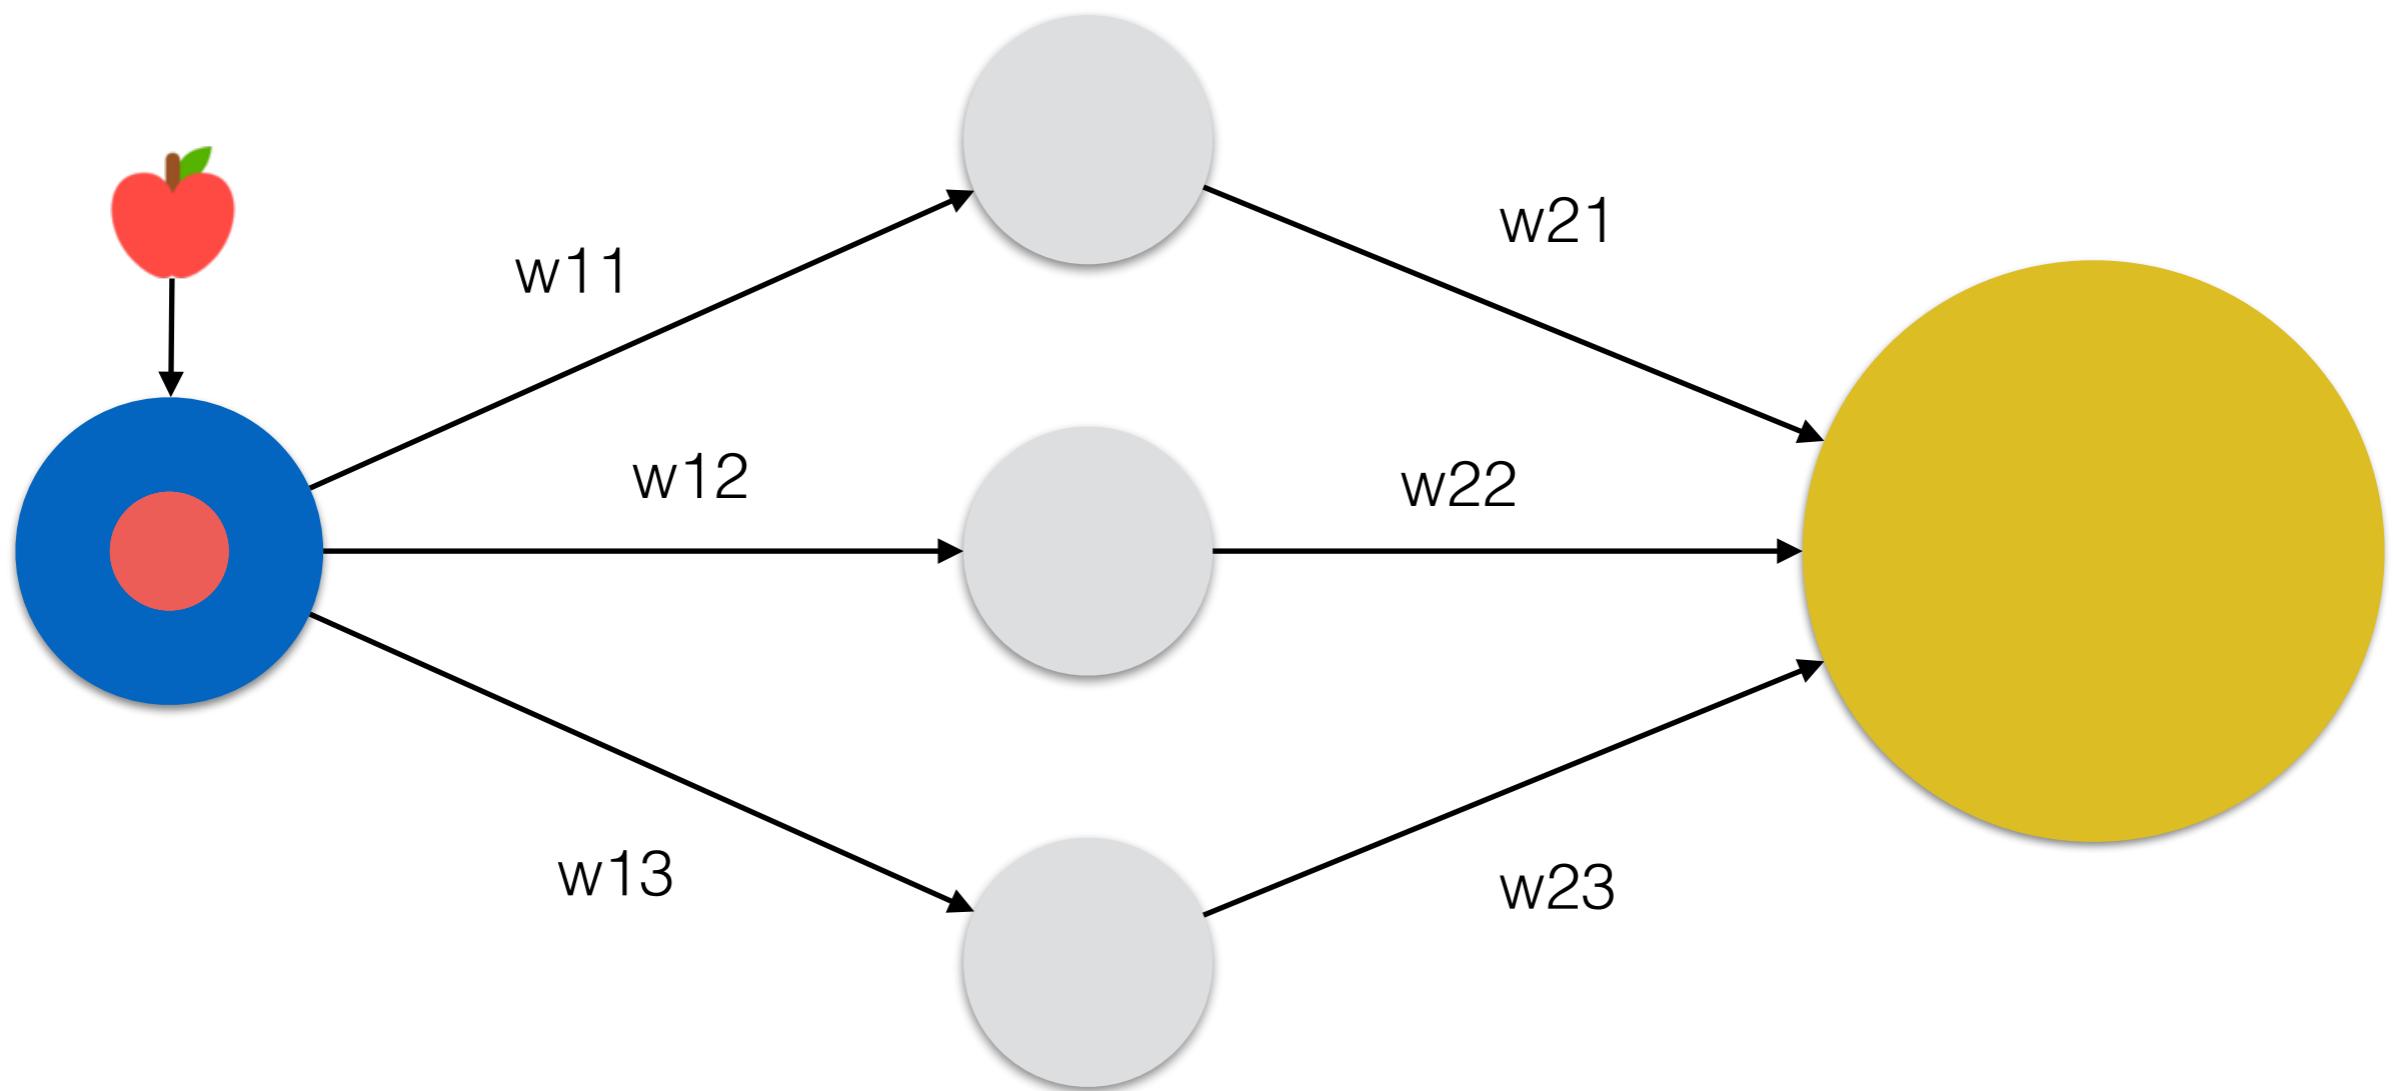
Redes Neurais Artificiais

o classificador de frutas



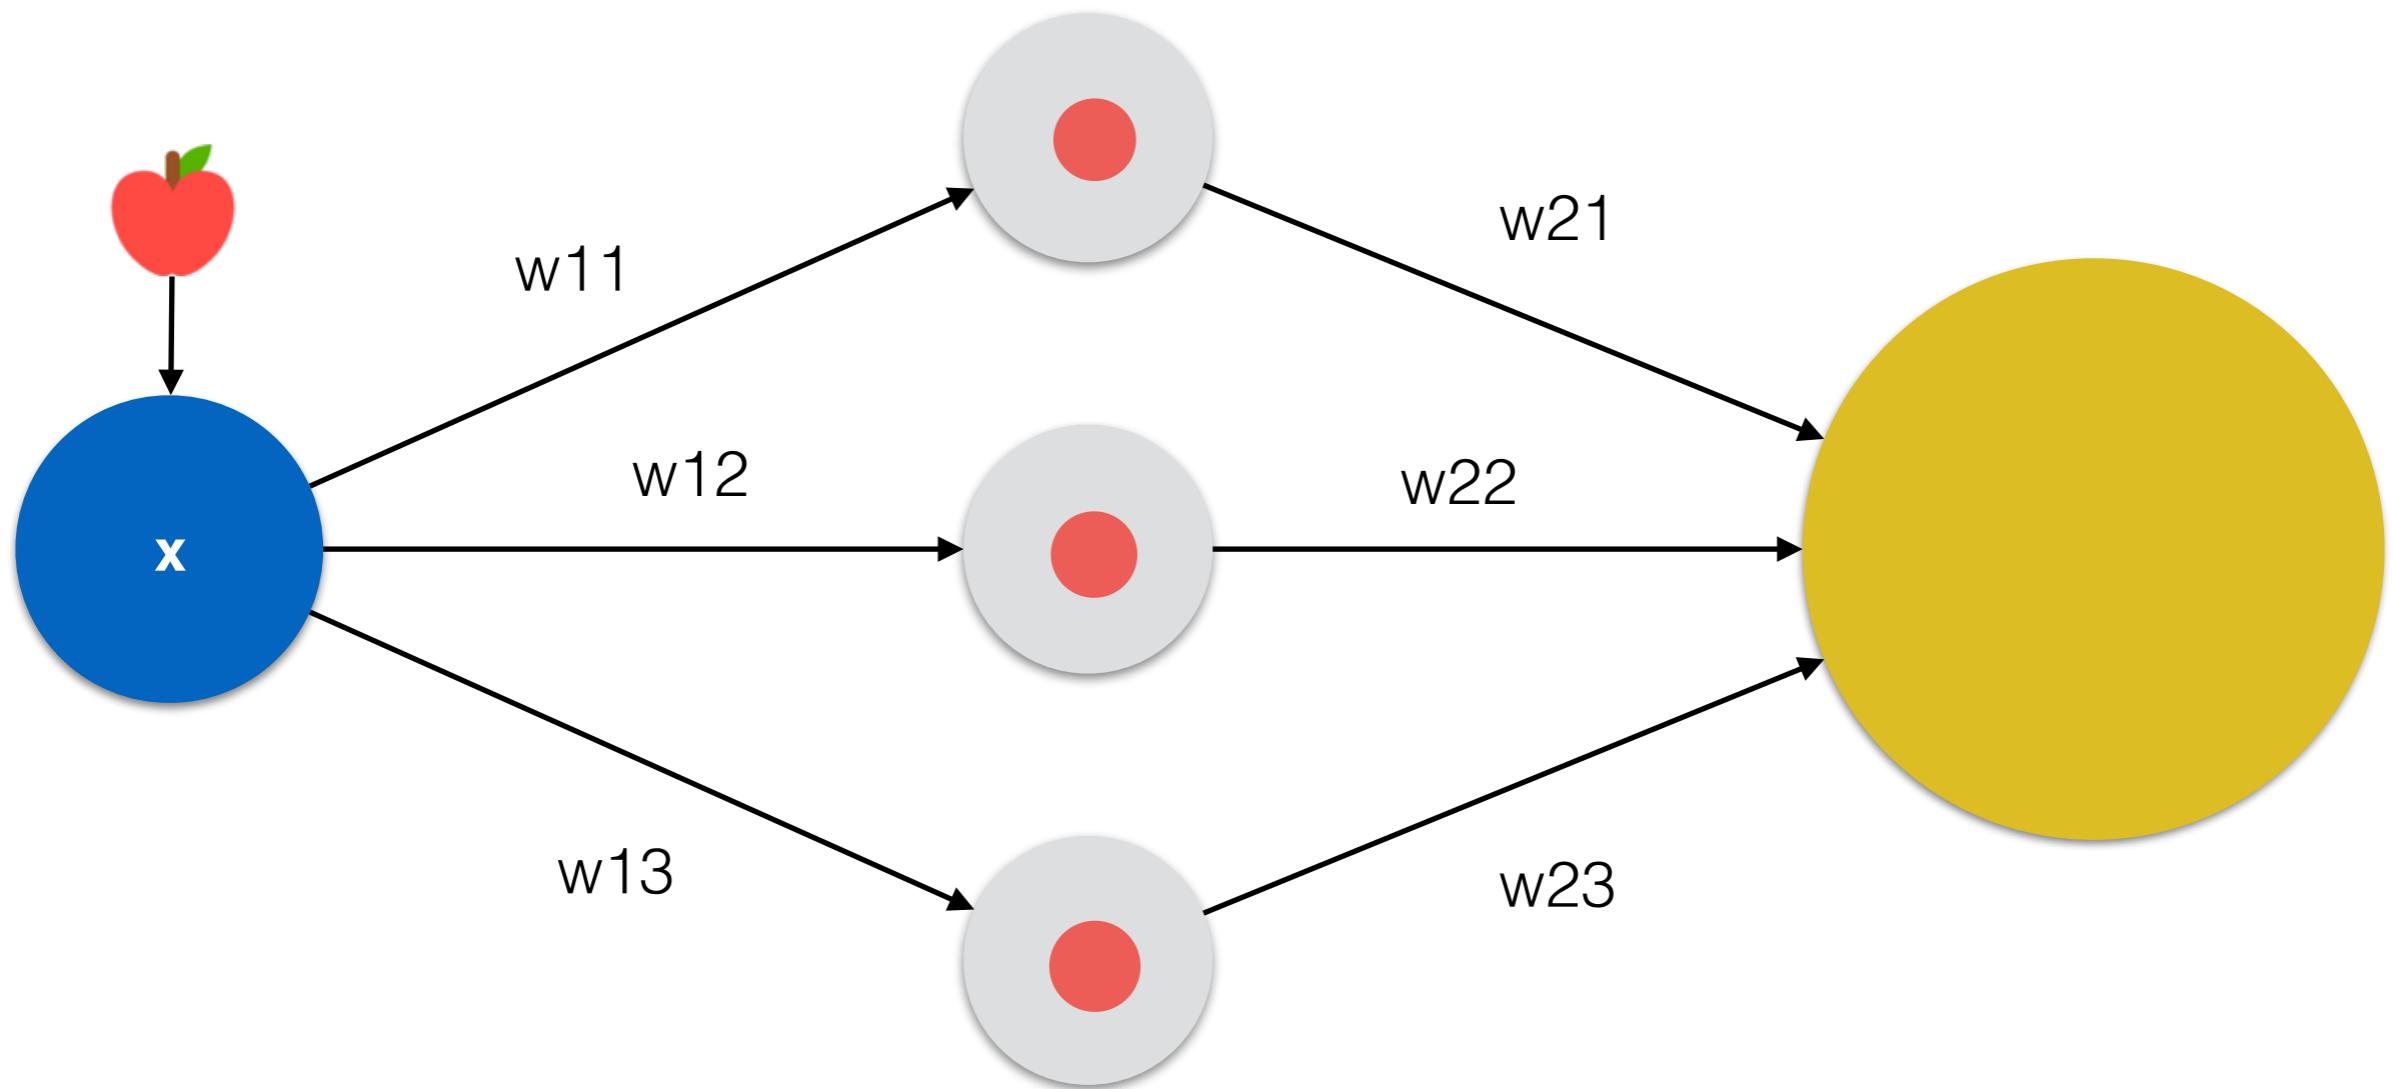
Redes Neurais Artificiais

o classificador de frutas



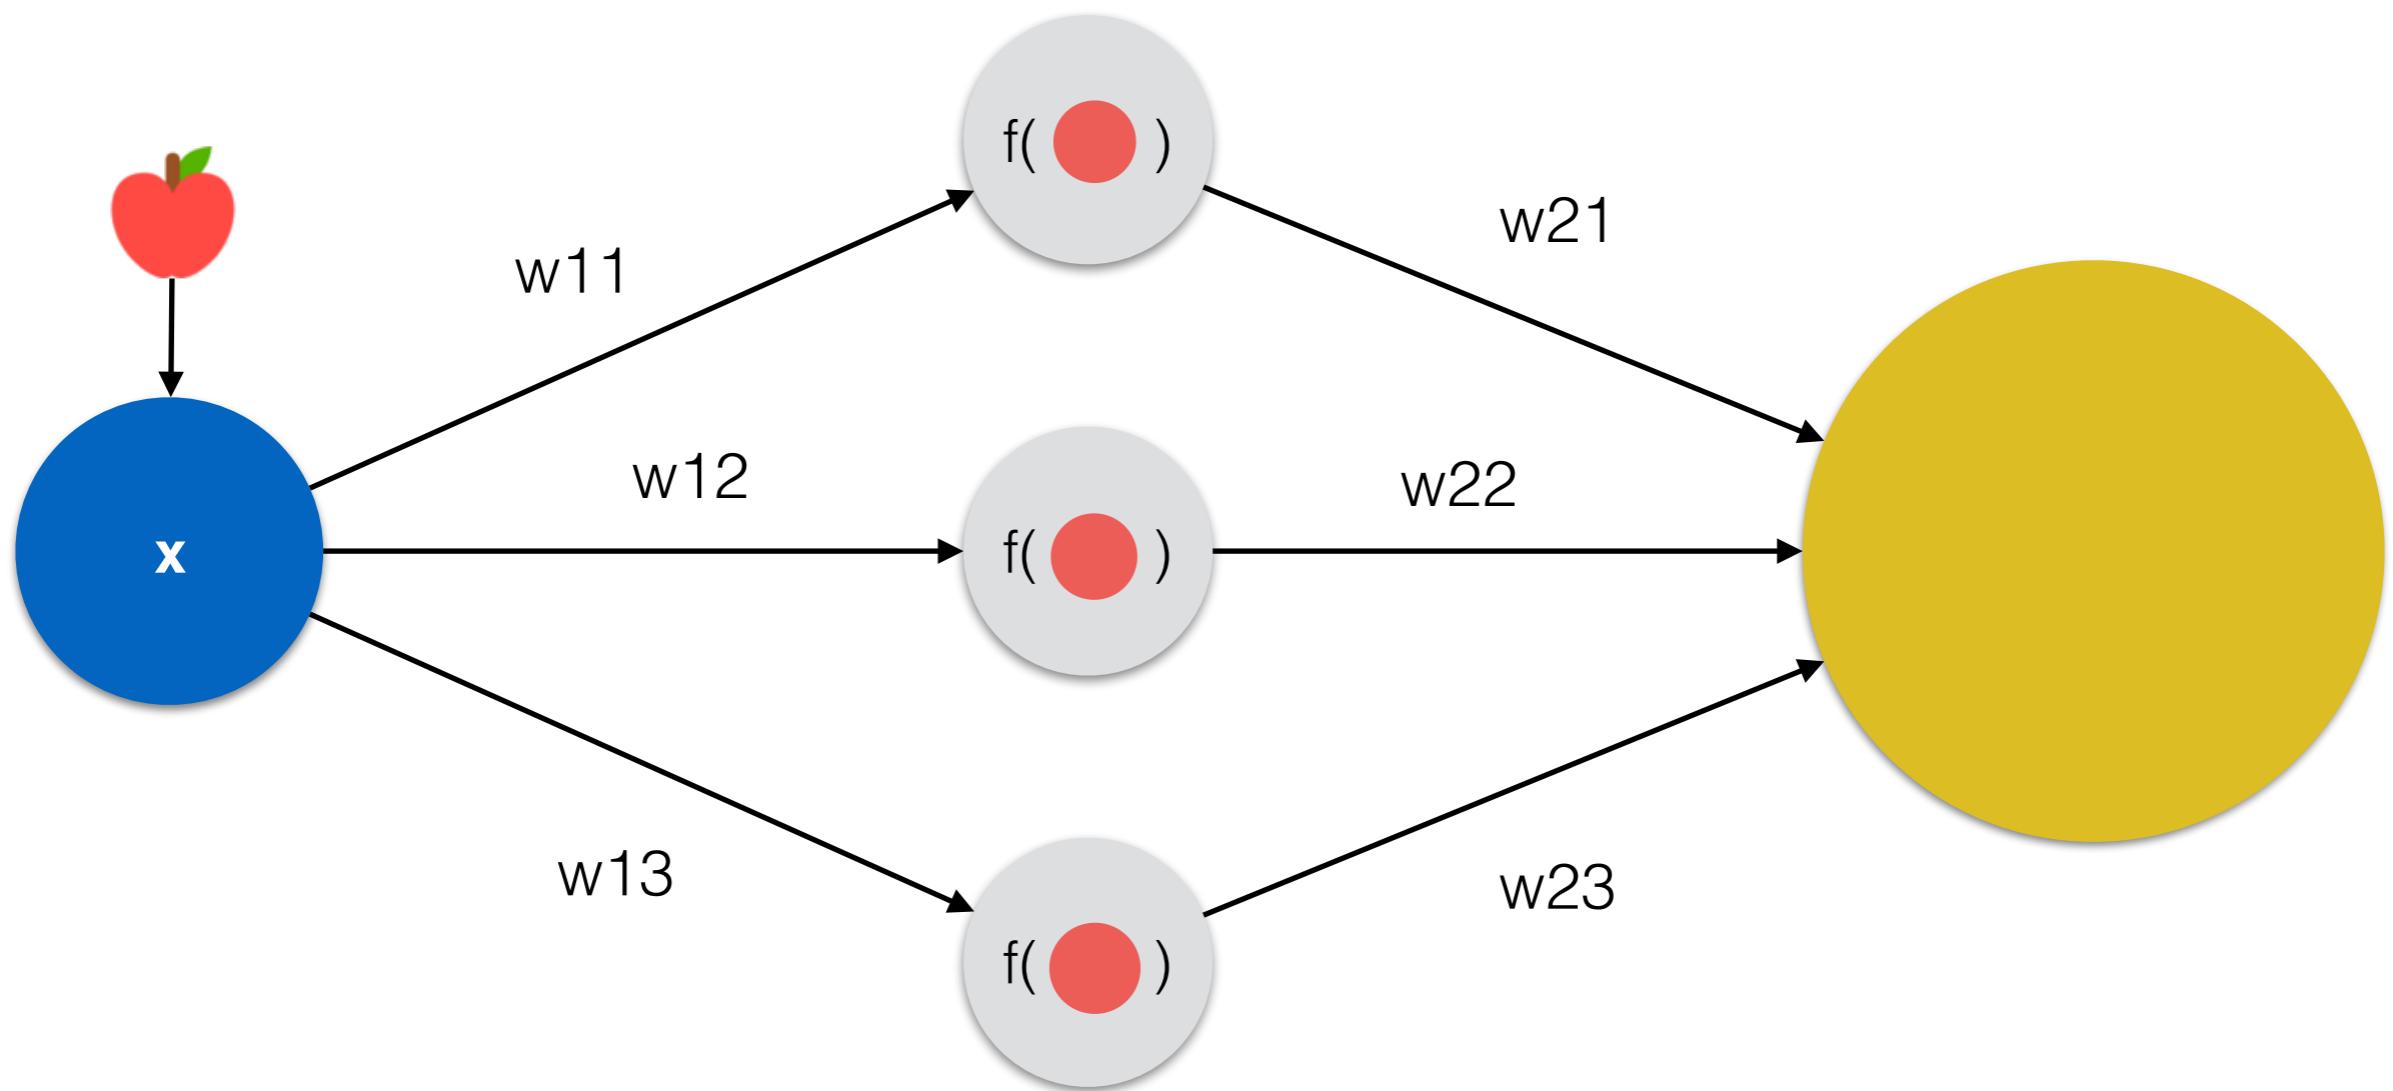
Redes Neurais Artificiais

o classificador de frutas



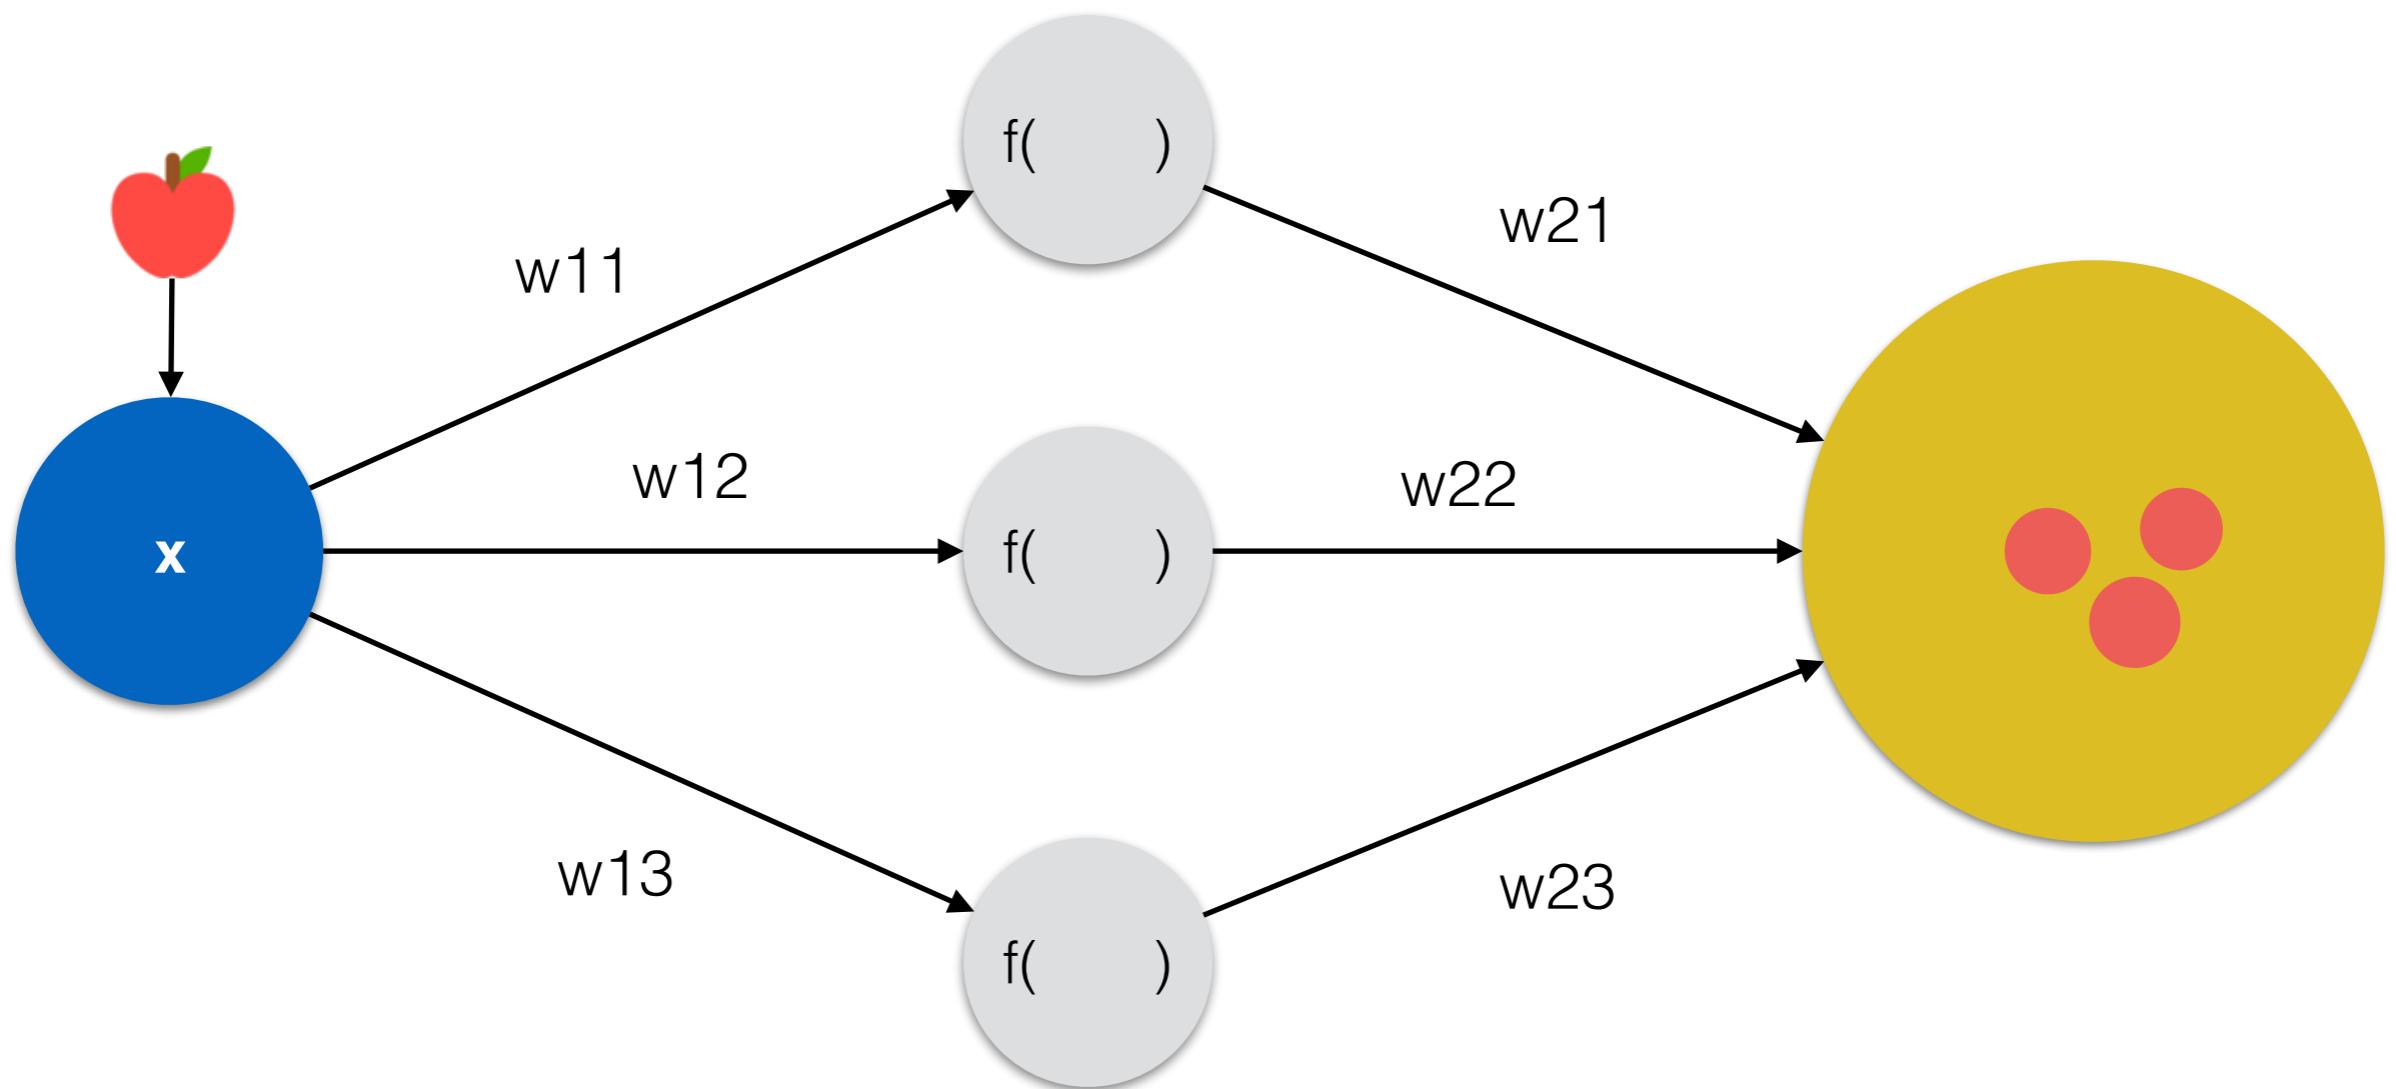
Redes Neurais Artificiais

o classificador de frutas



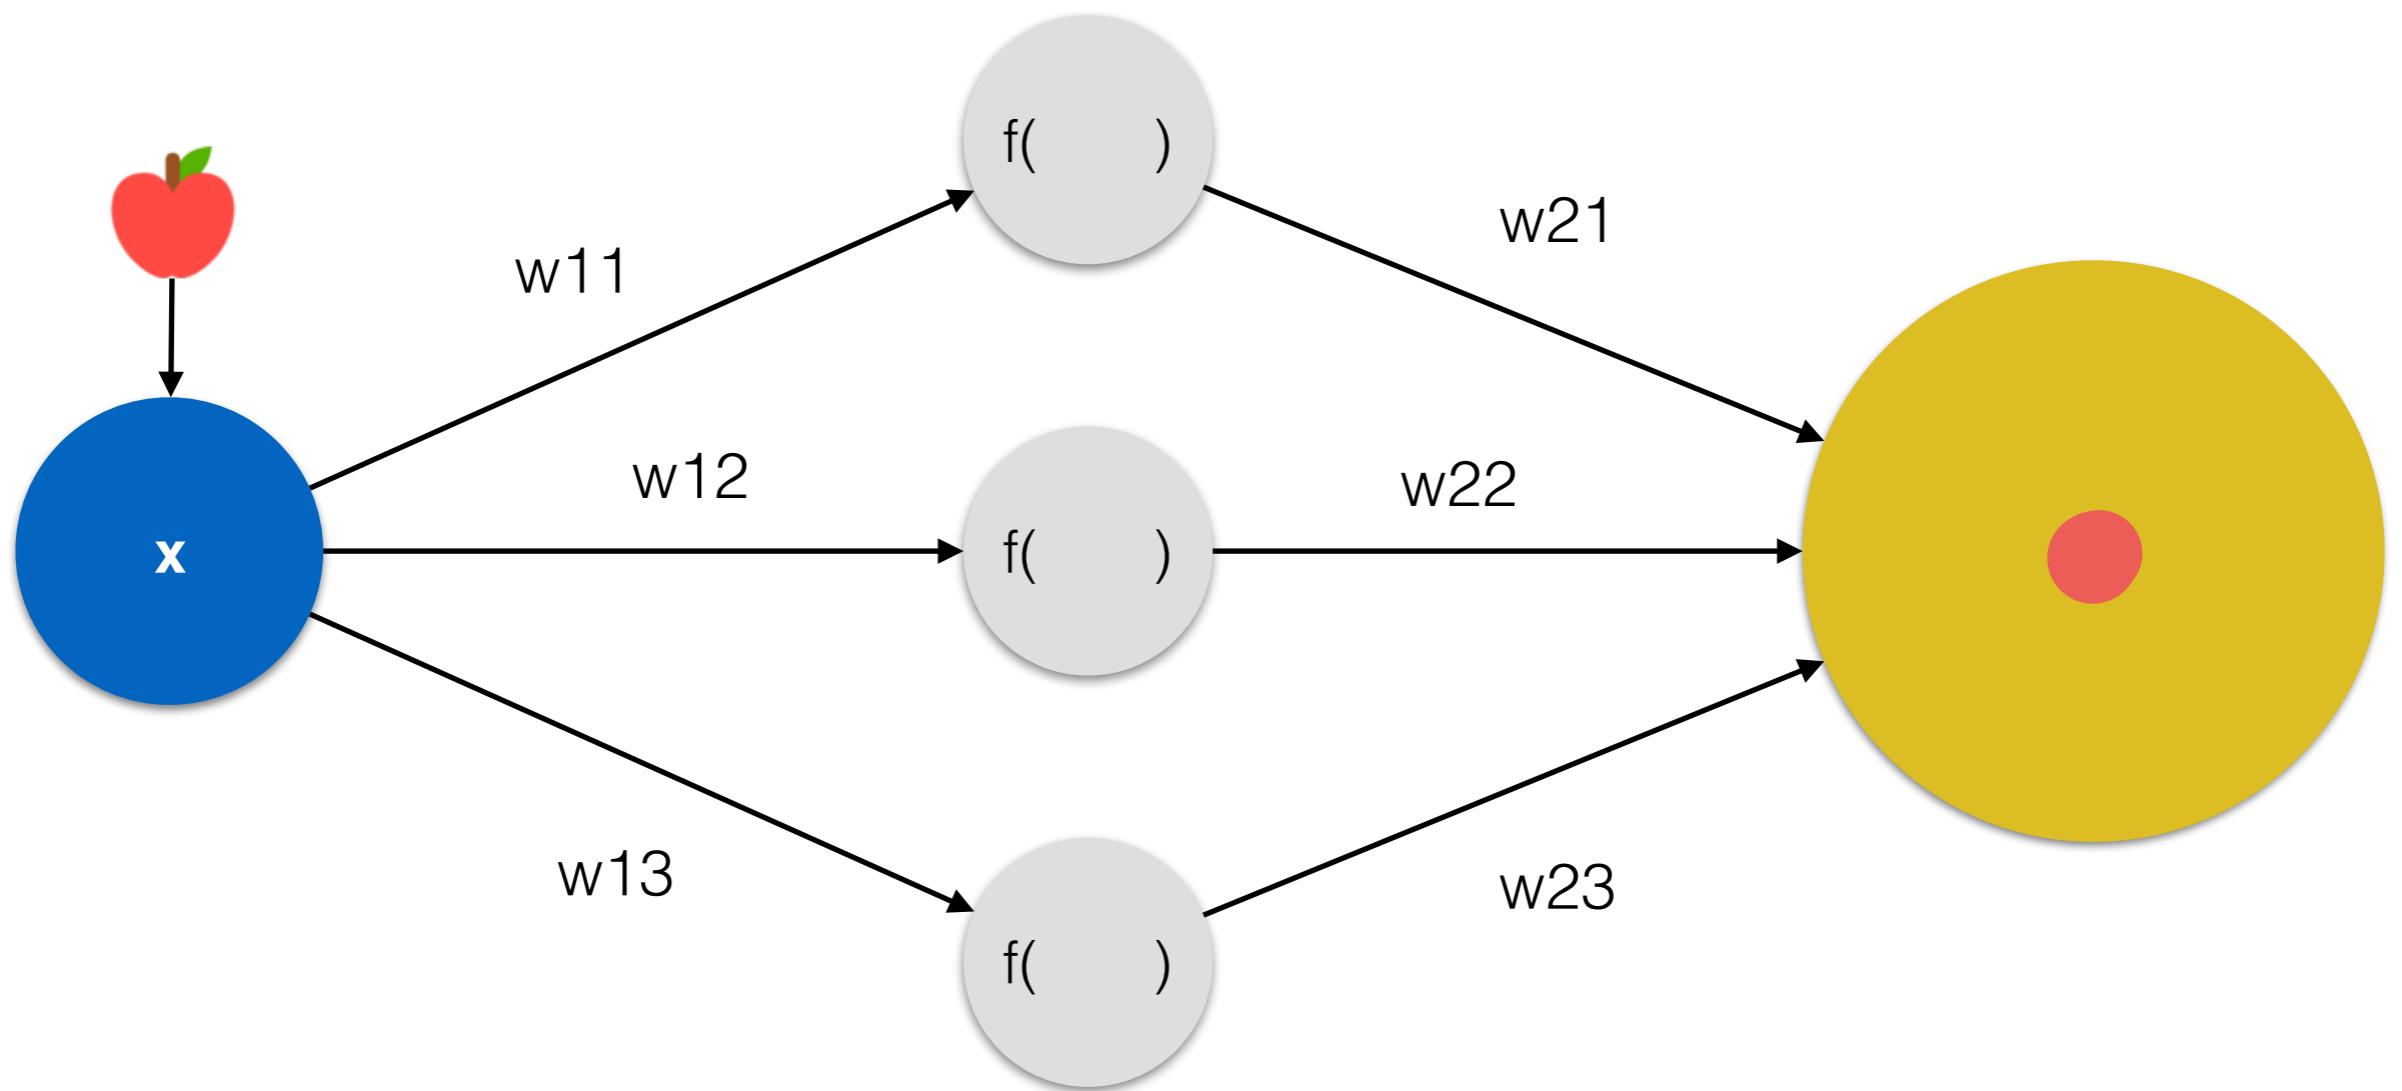
Redes Neurais Artificiais

o classificador de frutas



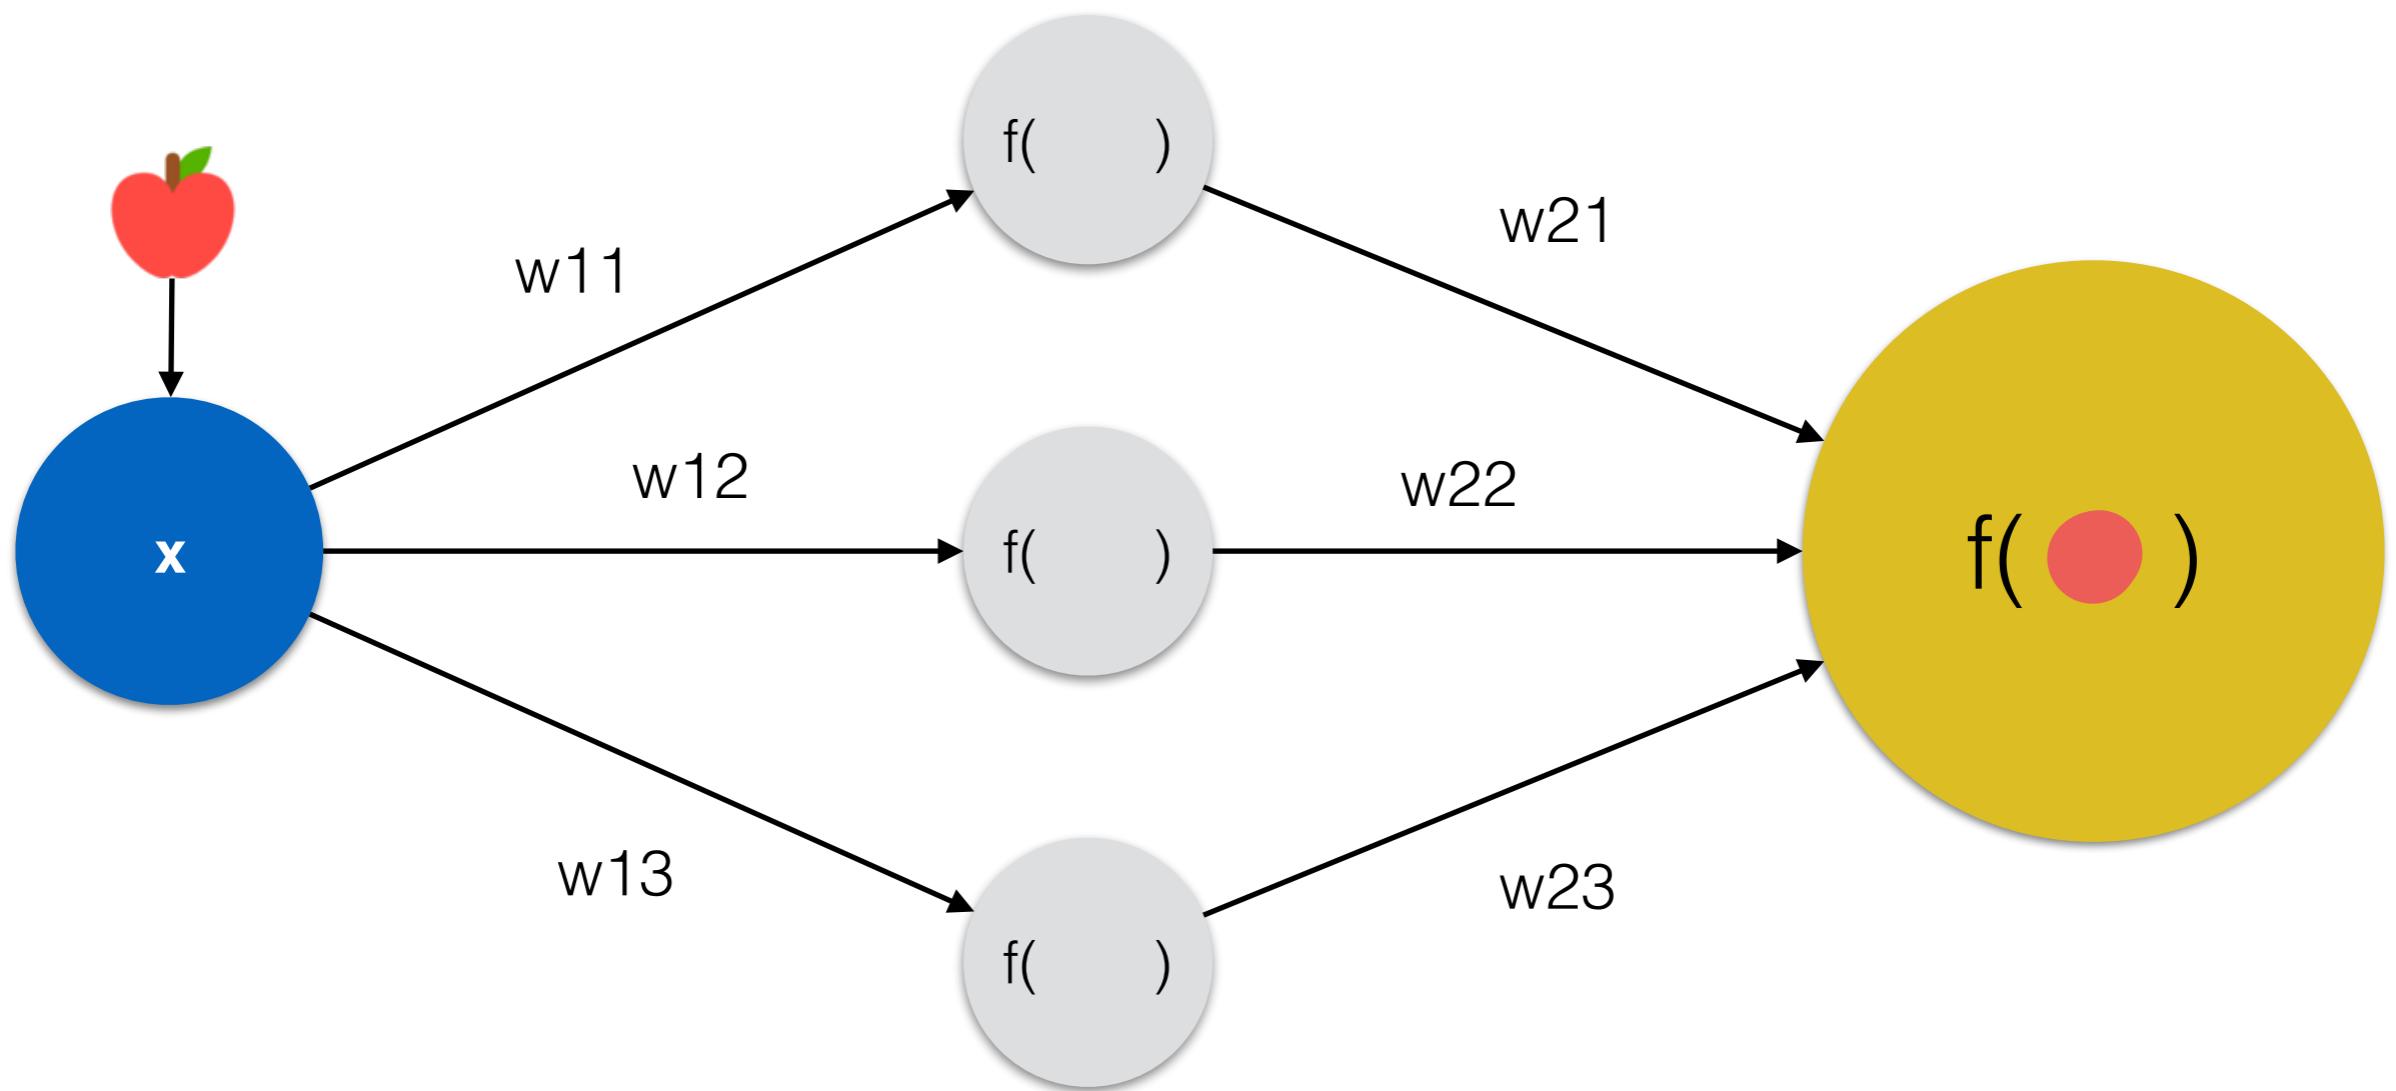
Redes Neurais Artificiais

o classificador de frutas



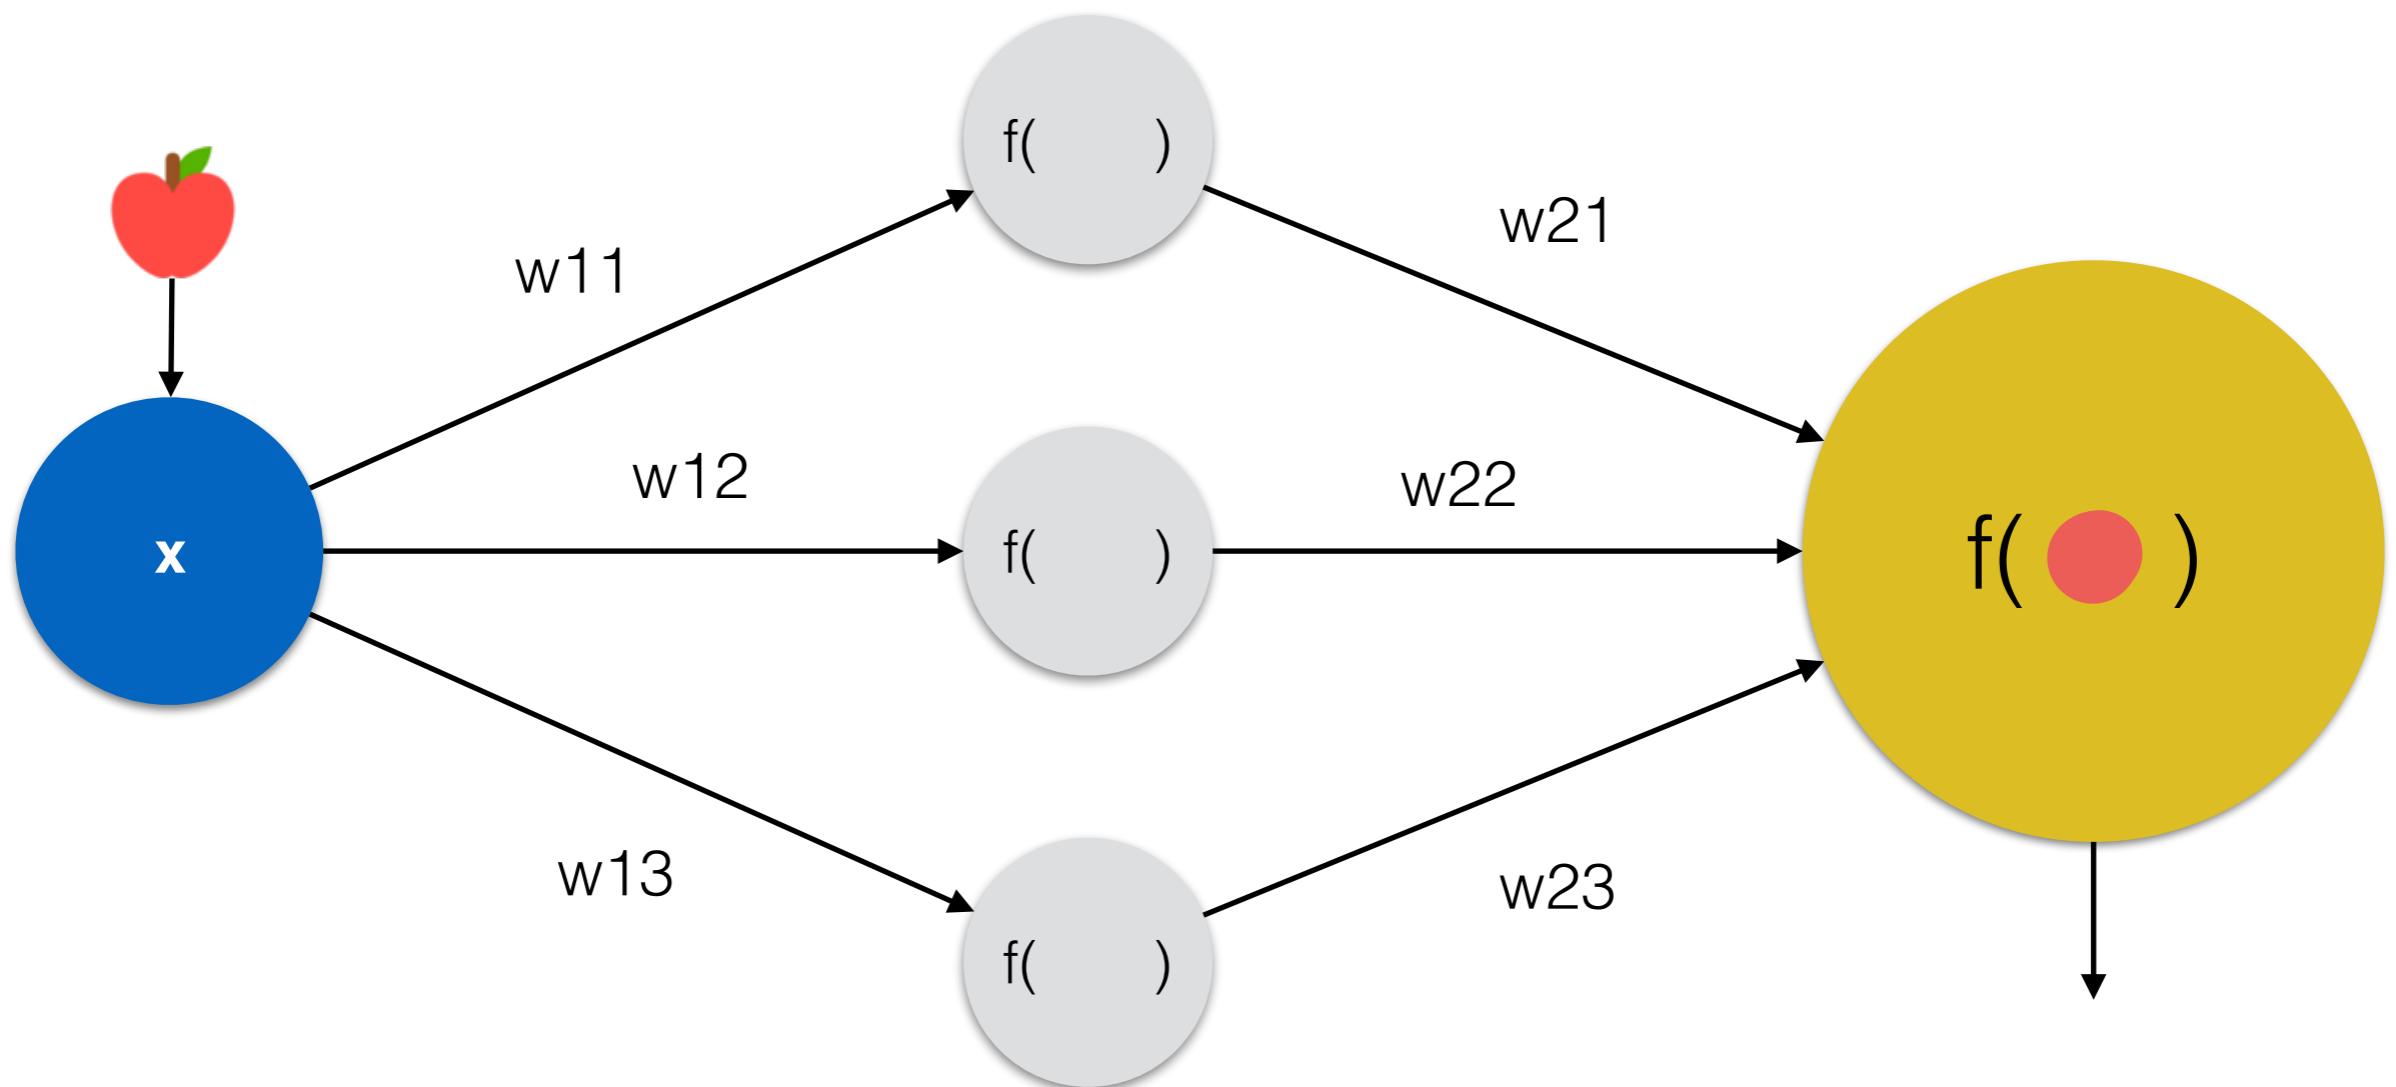
Redes Neurais Artificiais

o classificador de frutas



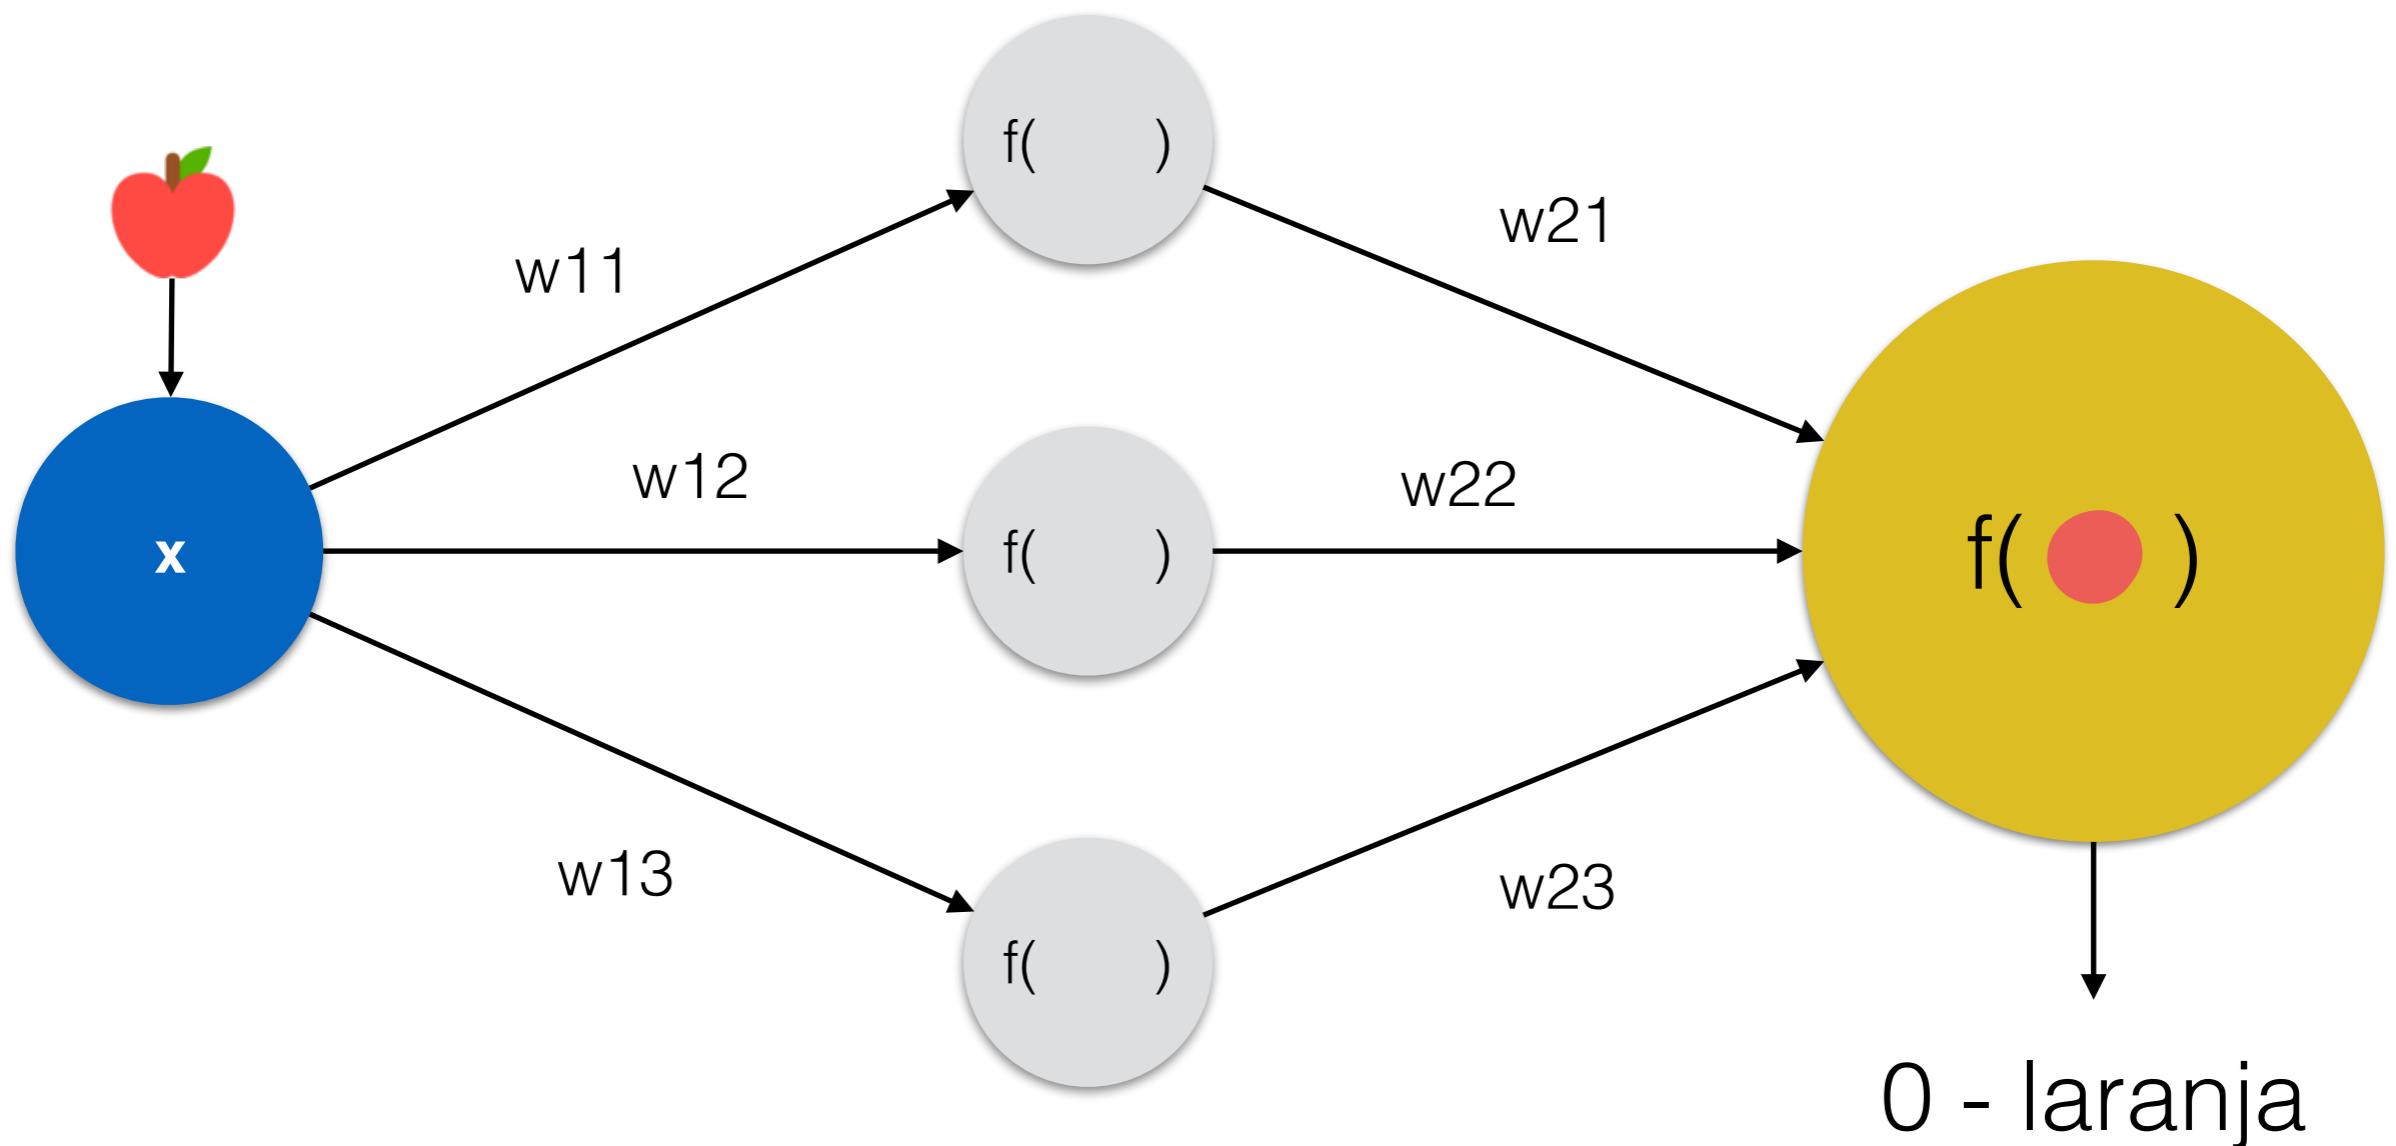
Redes Neurais Artificiais

o classificador de frutas



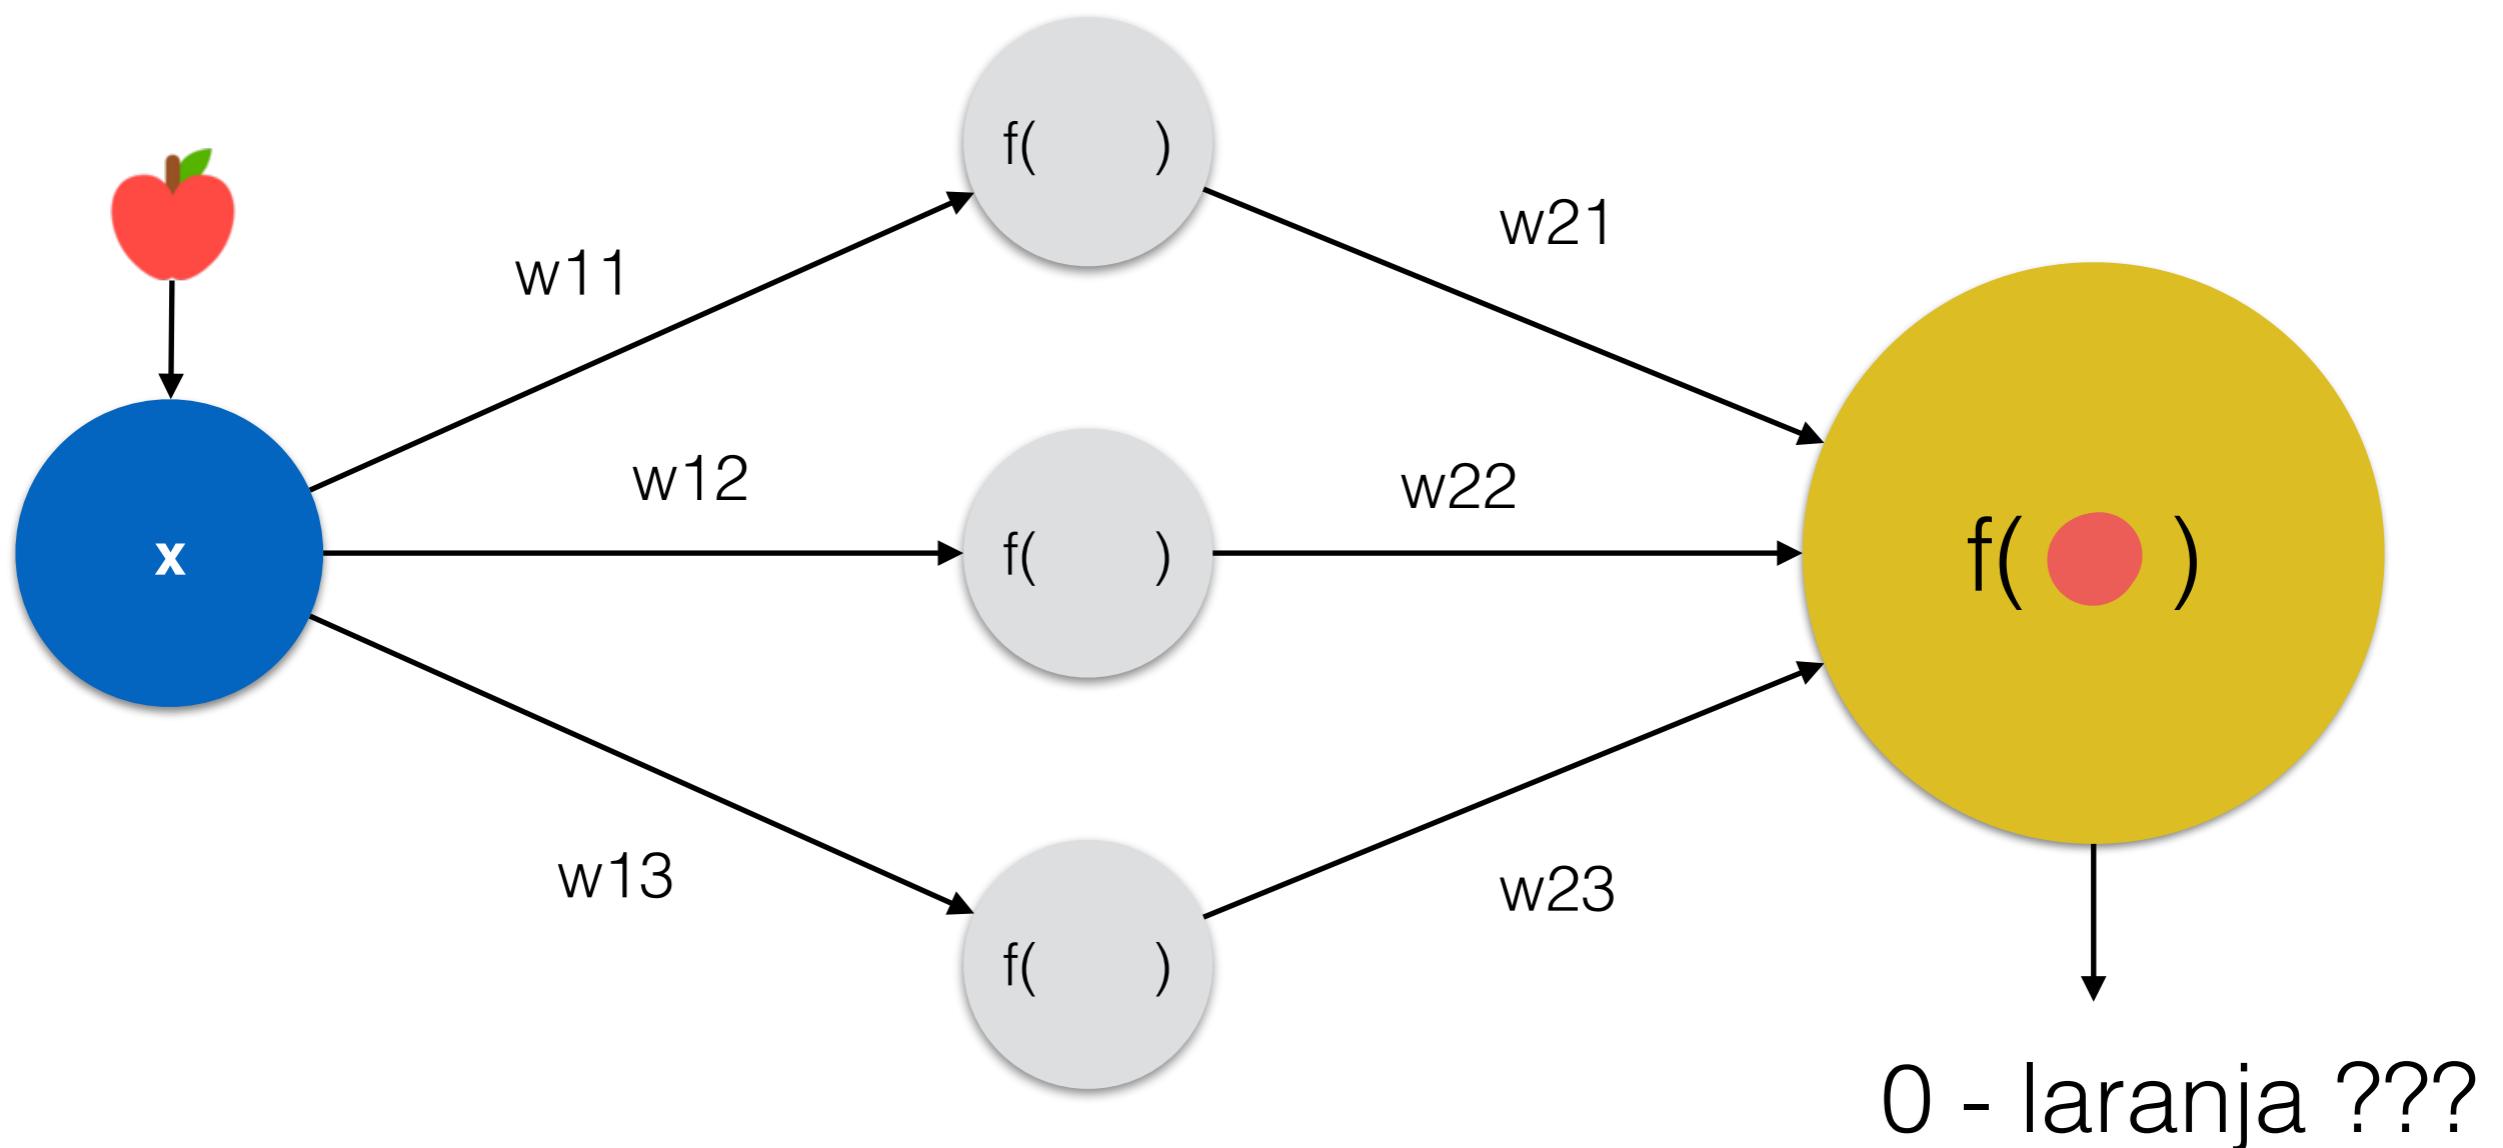
Redes Neurais Artificiais

o classificador de frutas



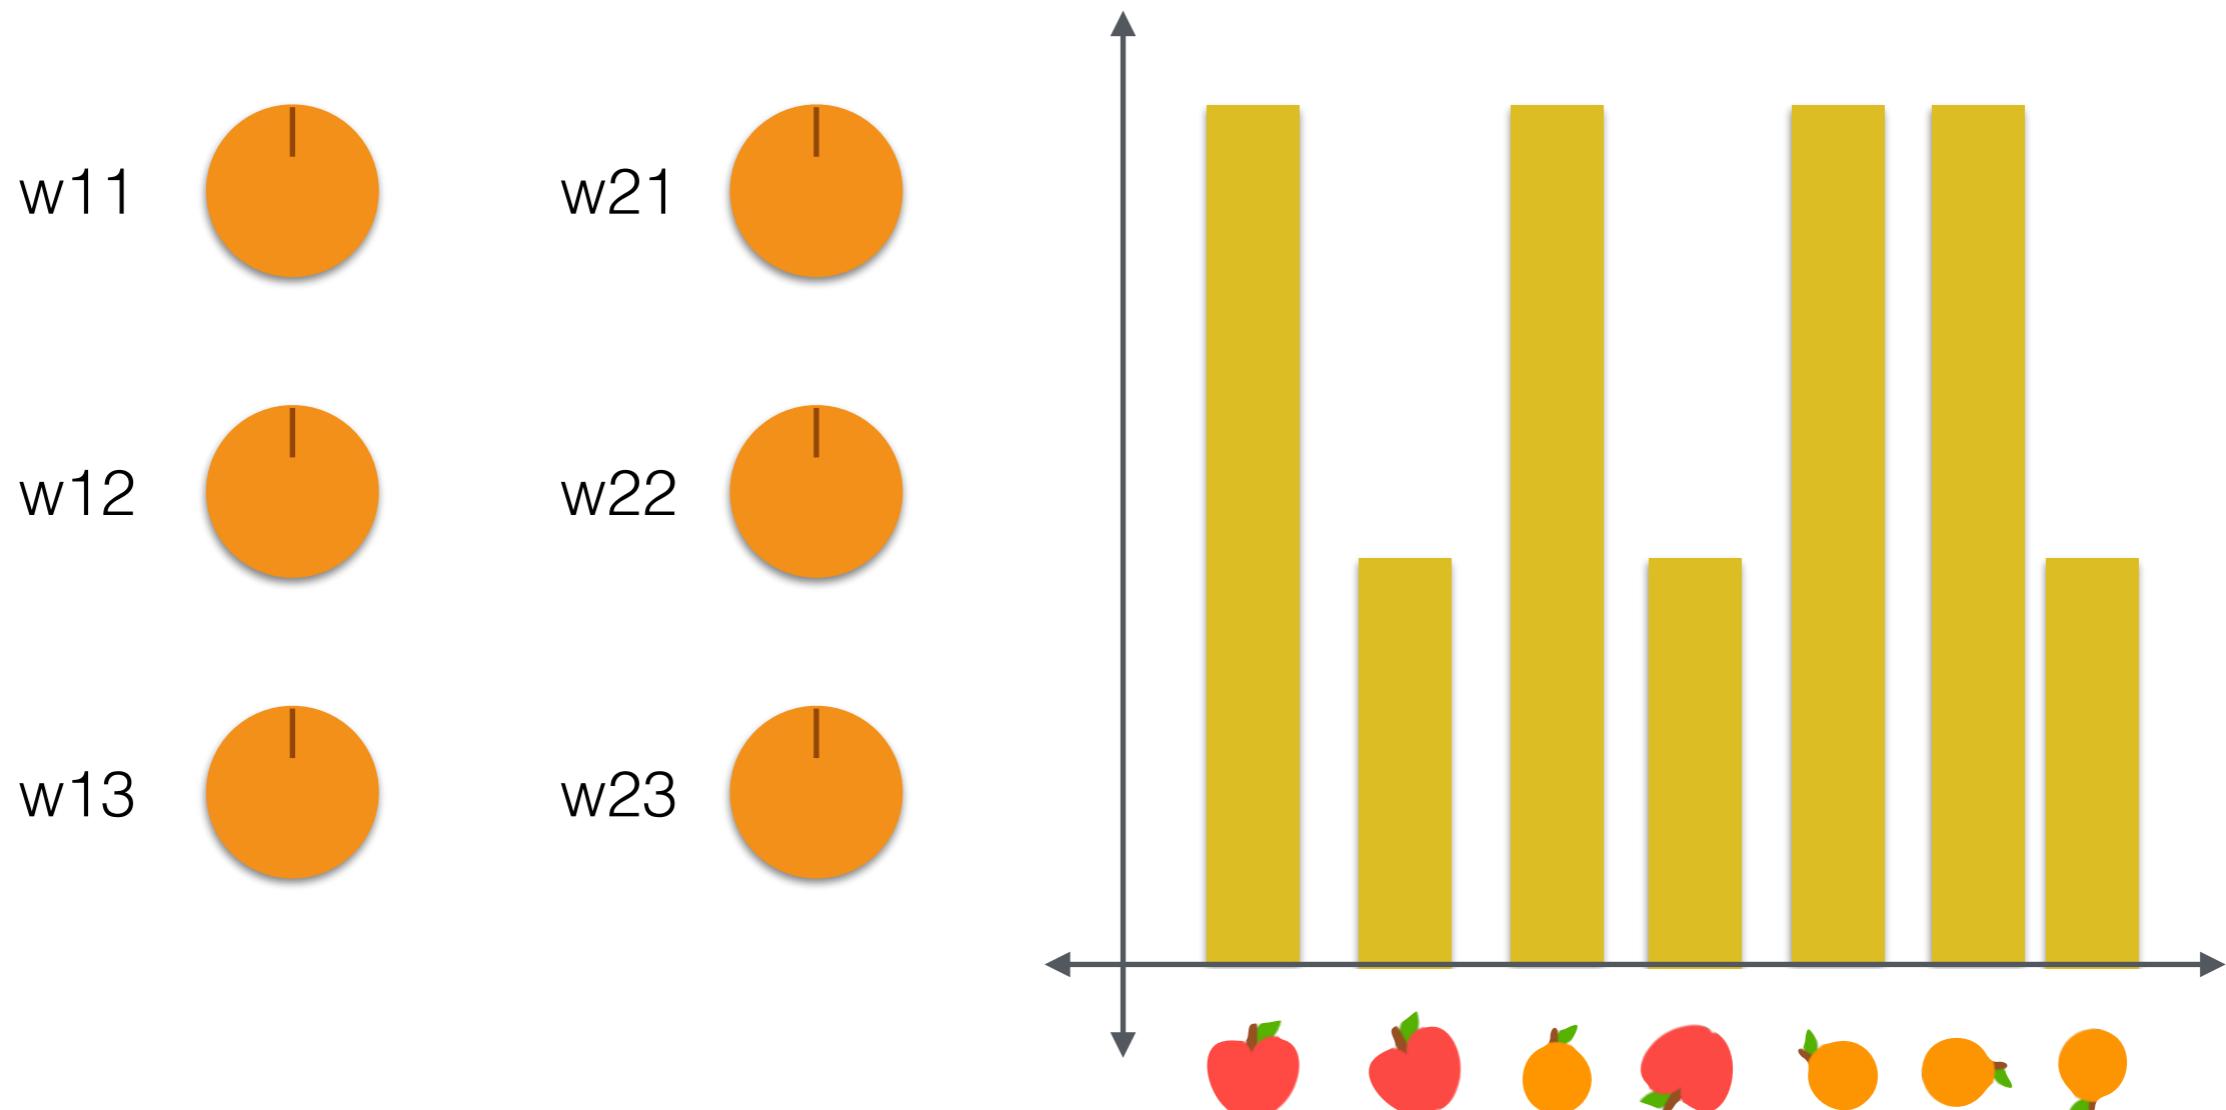
Redes Neurais Artificiais

o classificador de frutas



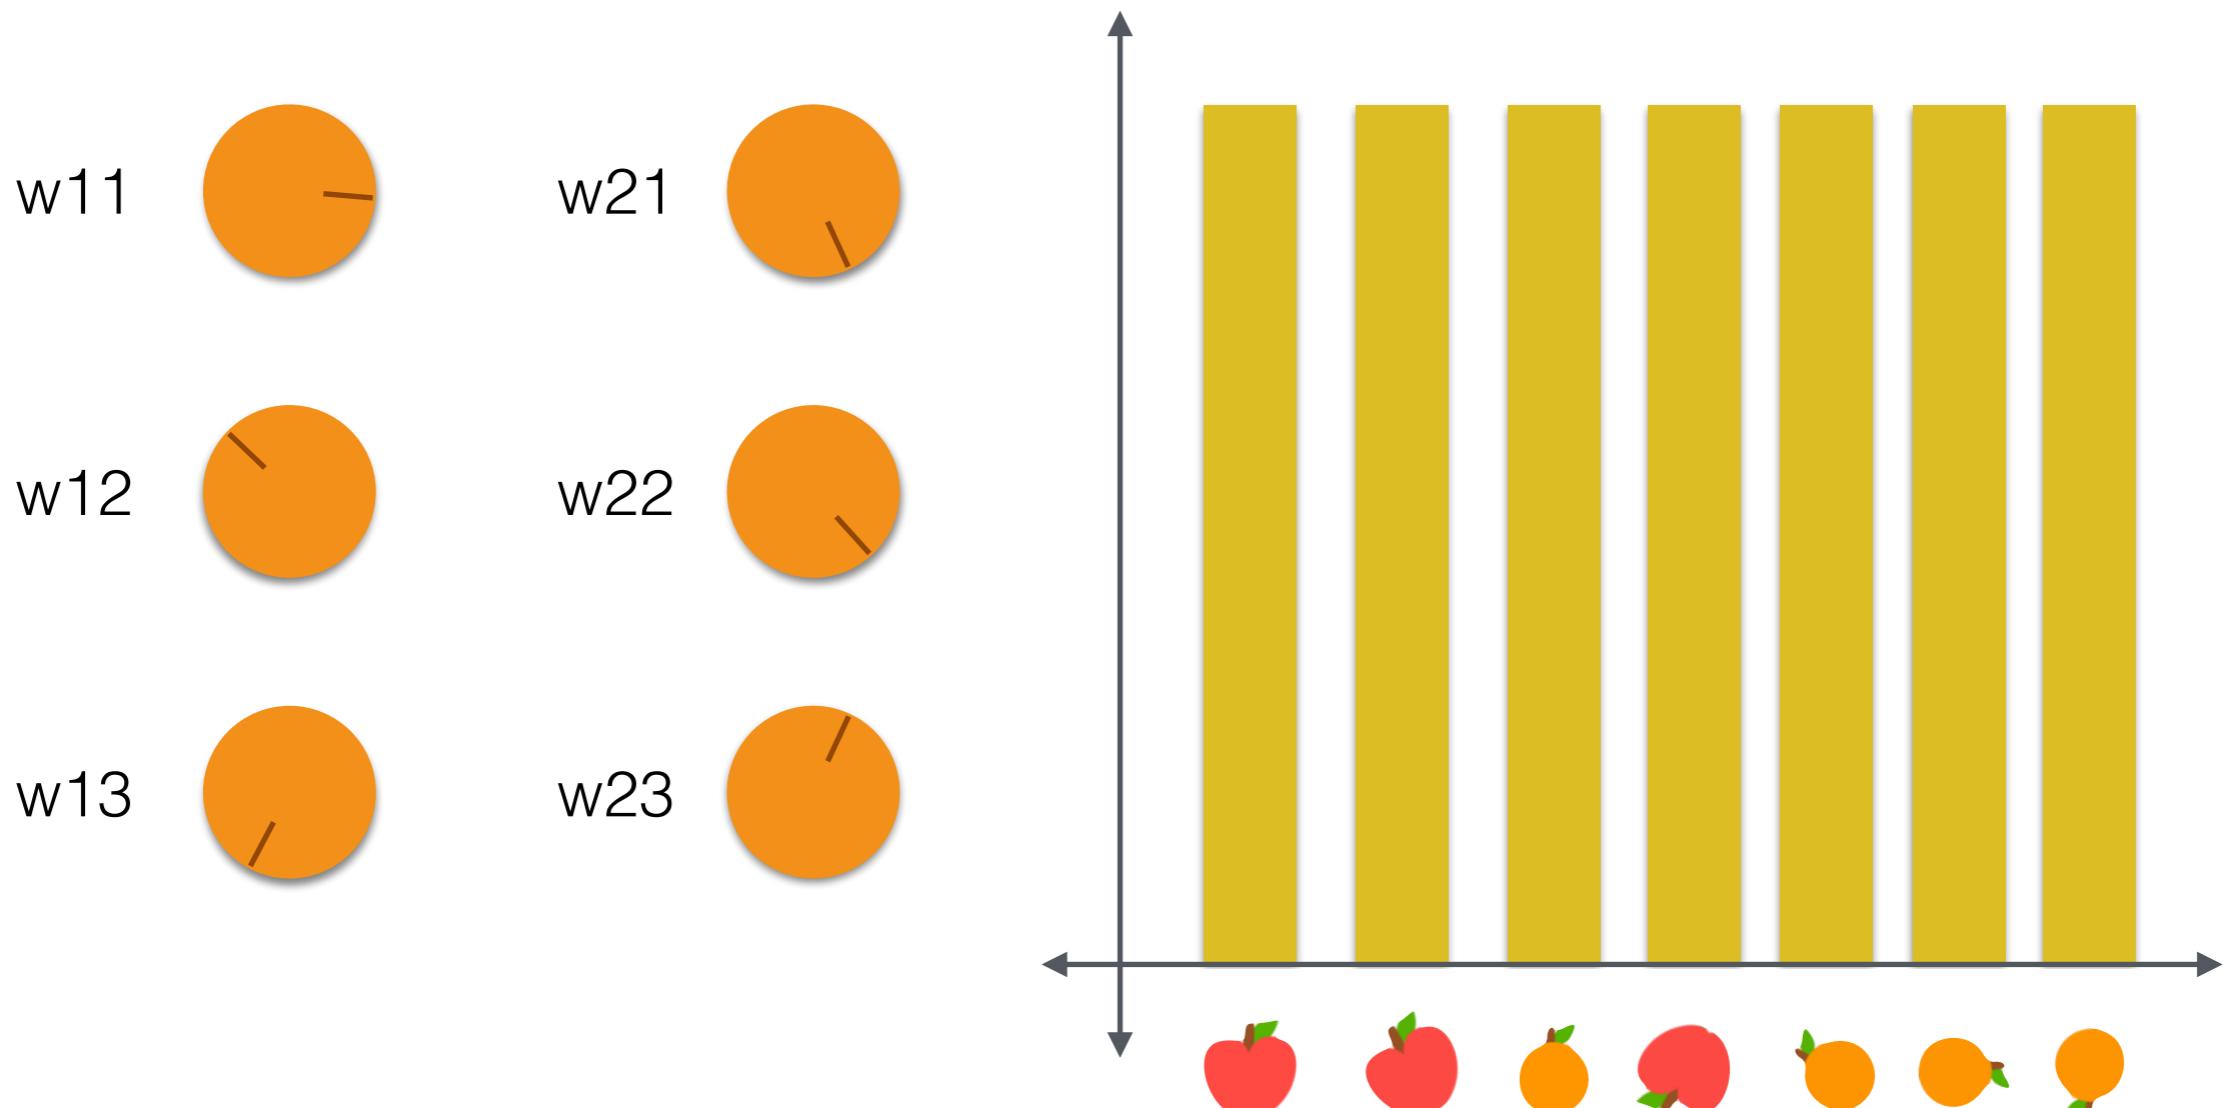
Redes Neurais Artificiais

treinamento



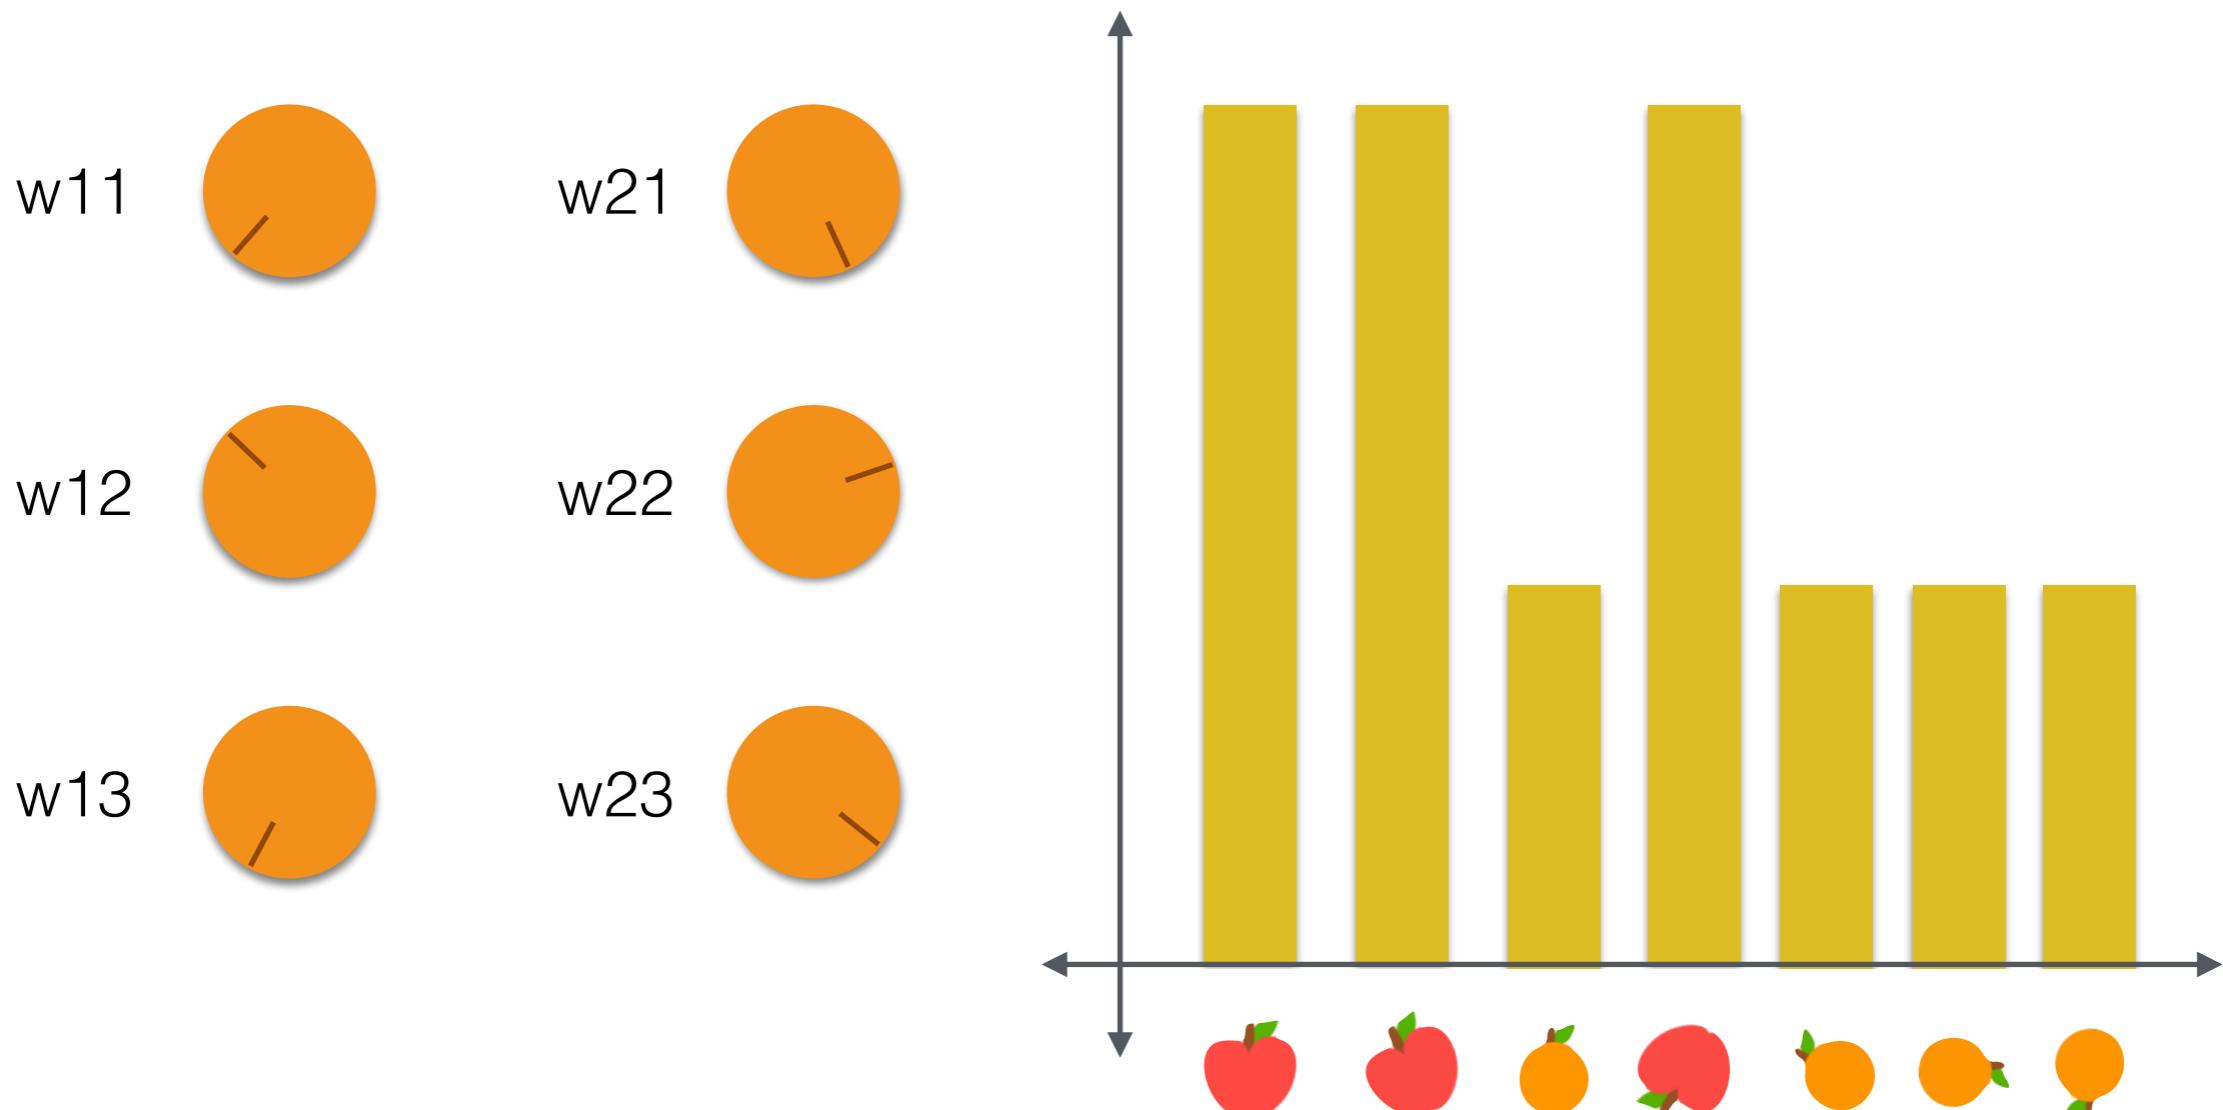
Redes Neurais Artificiais

treinamento



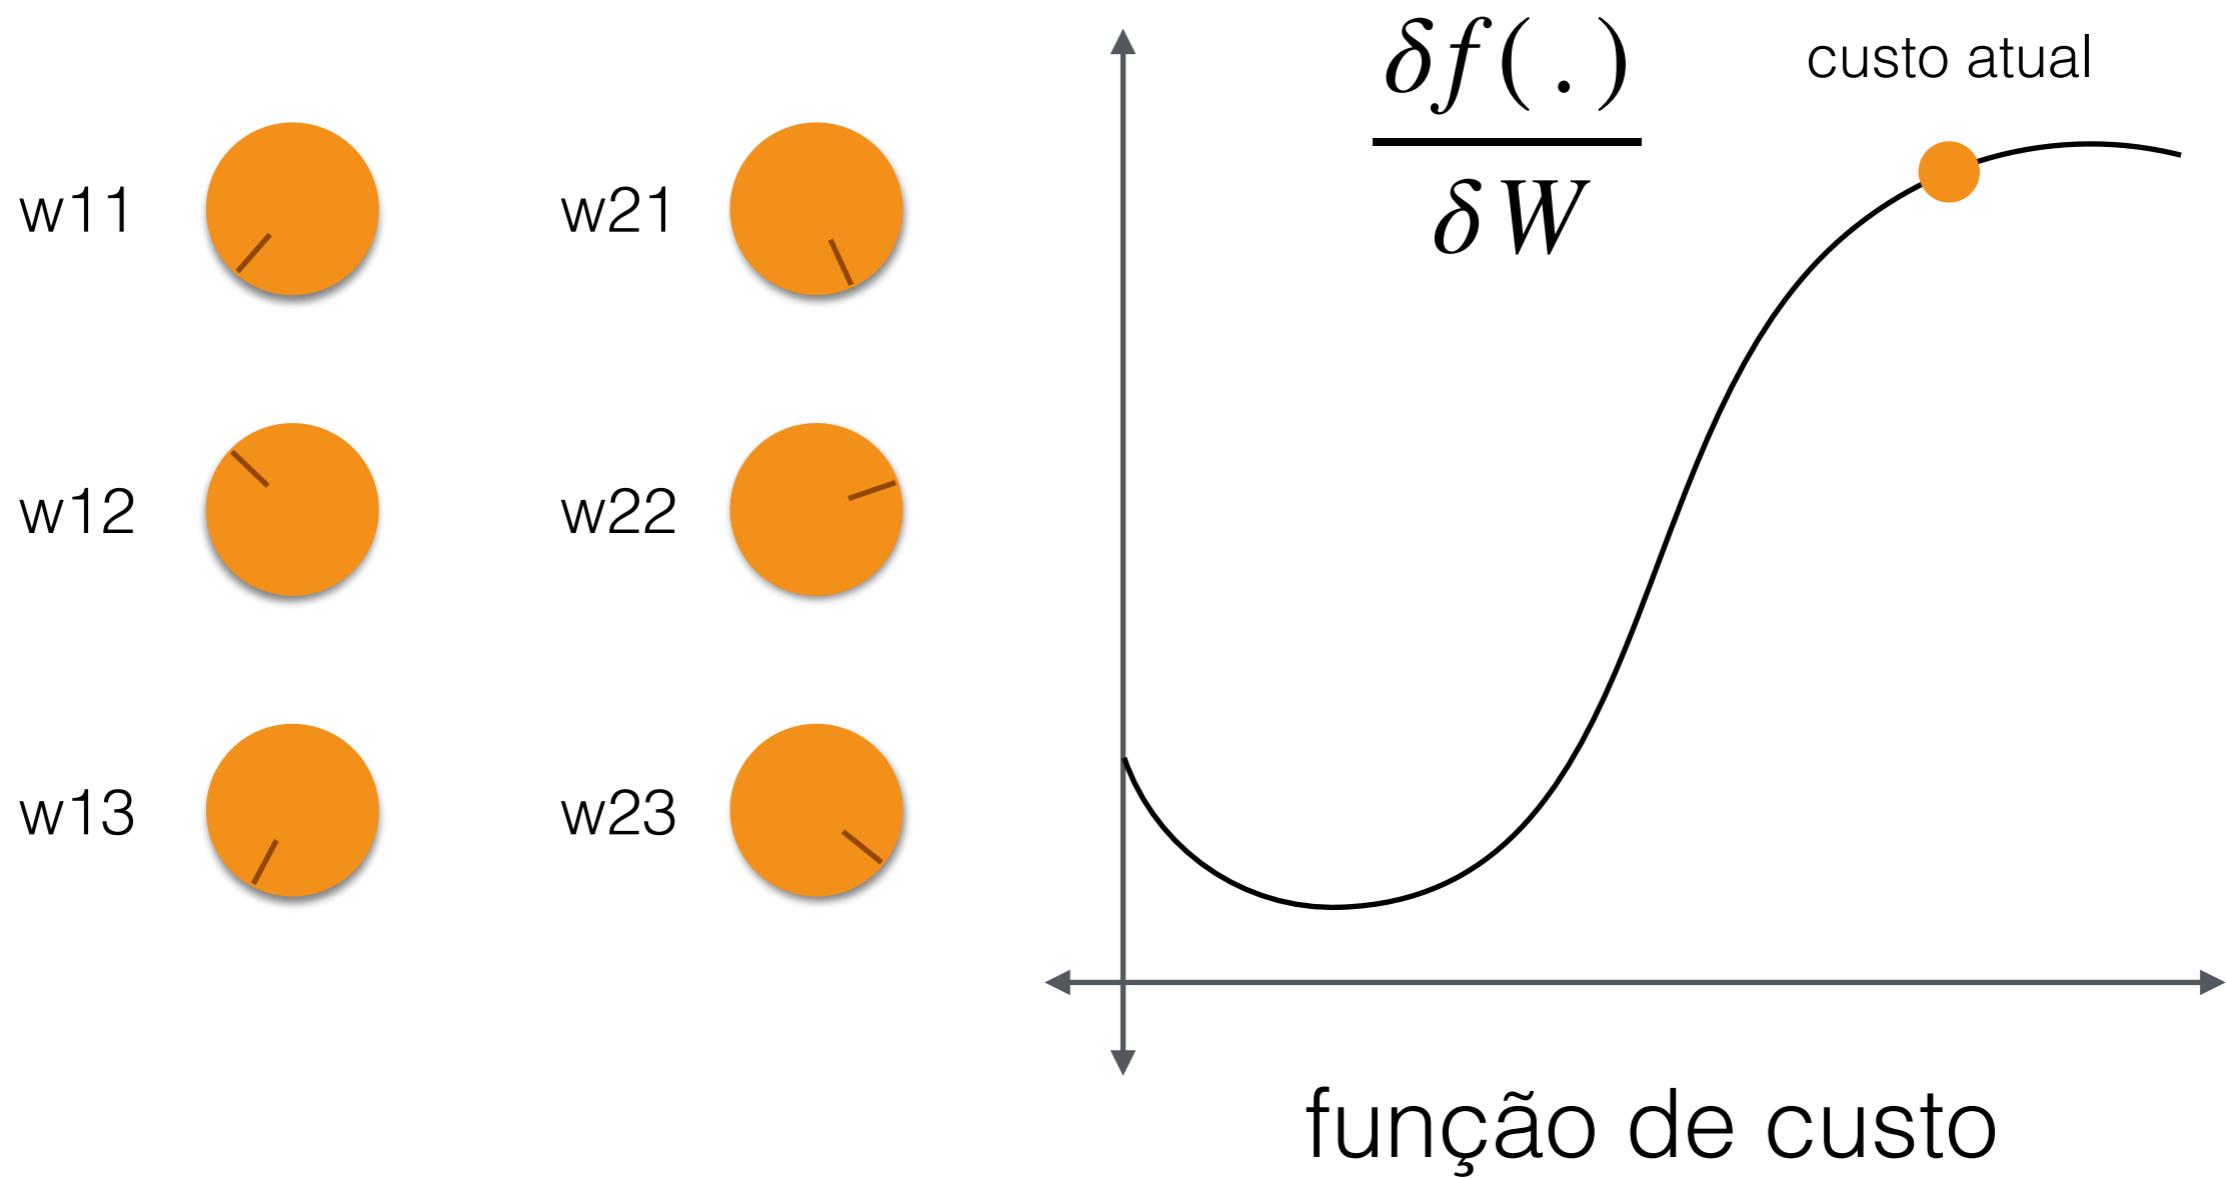
Redes Neurais Artificiais

treinamento



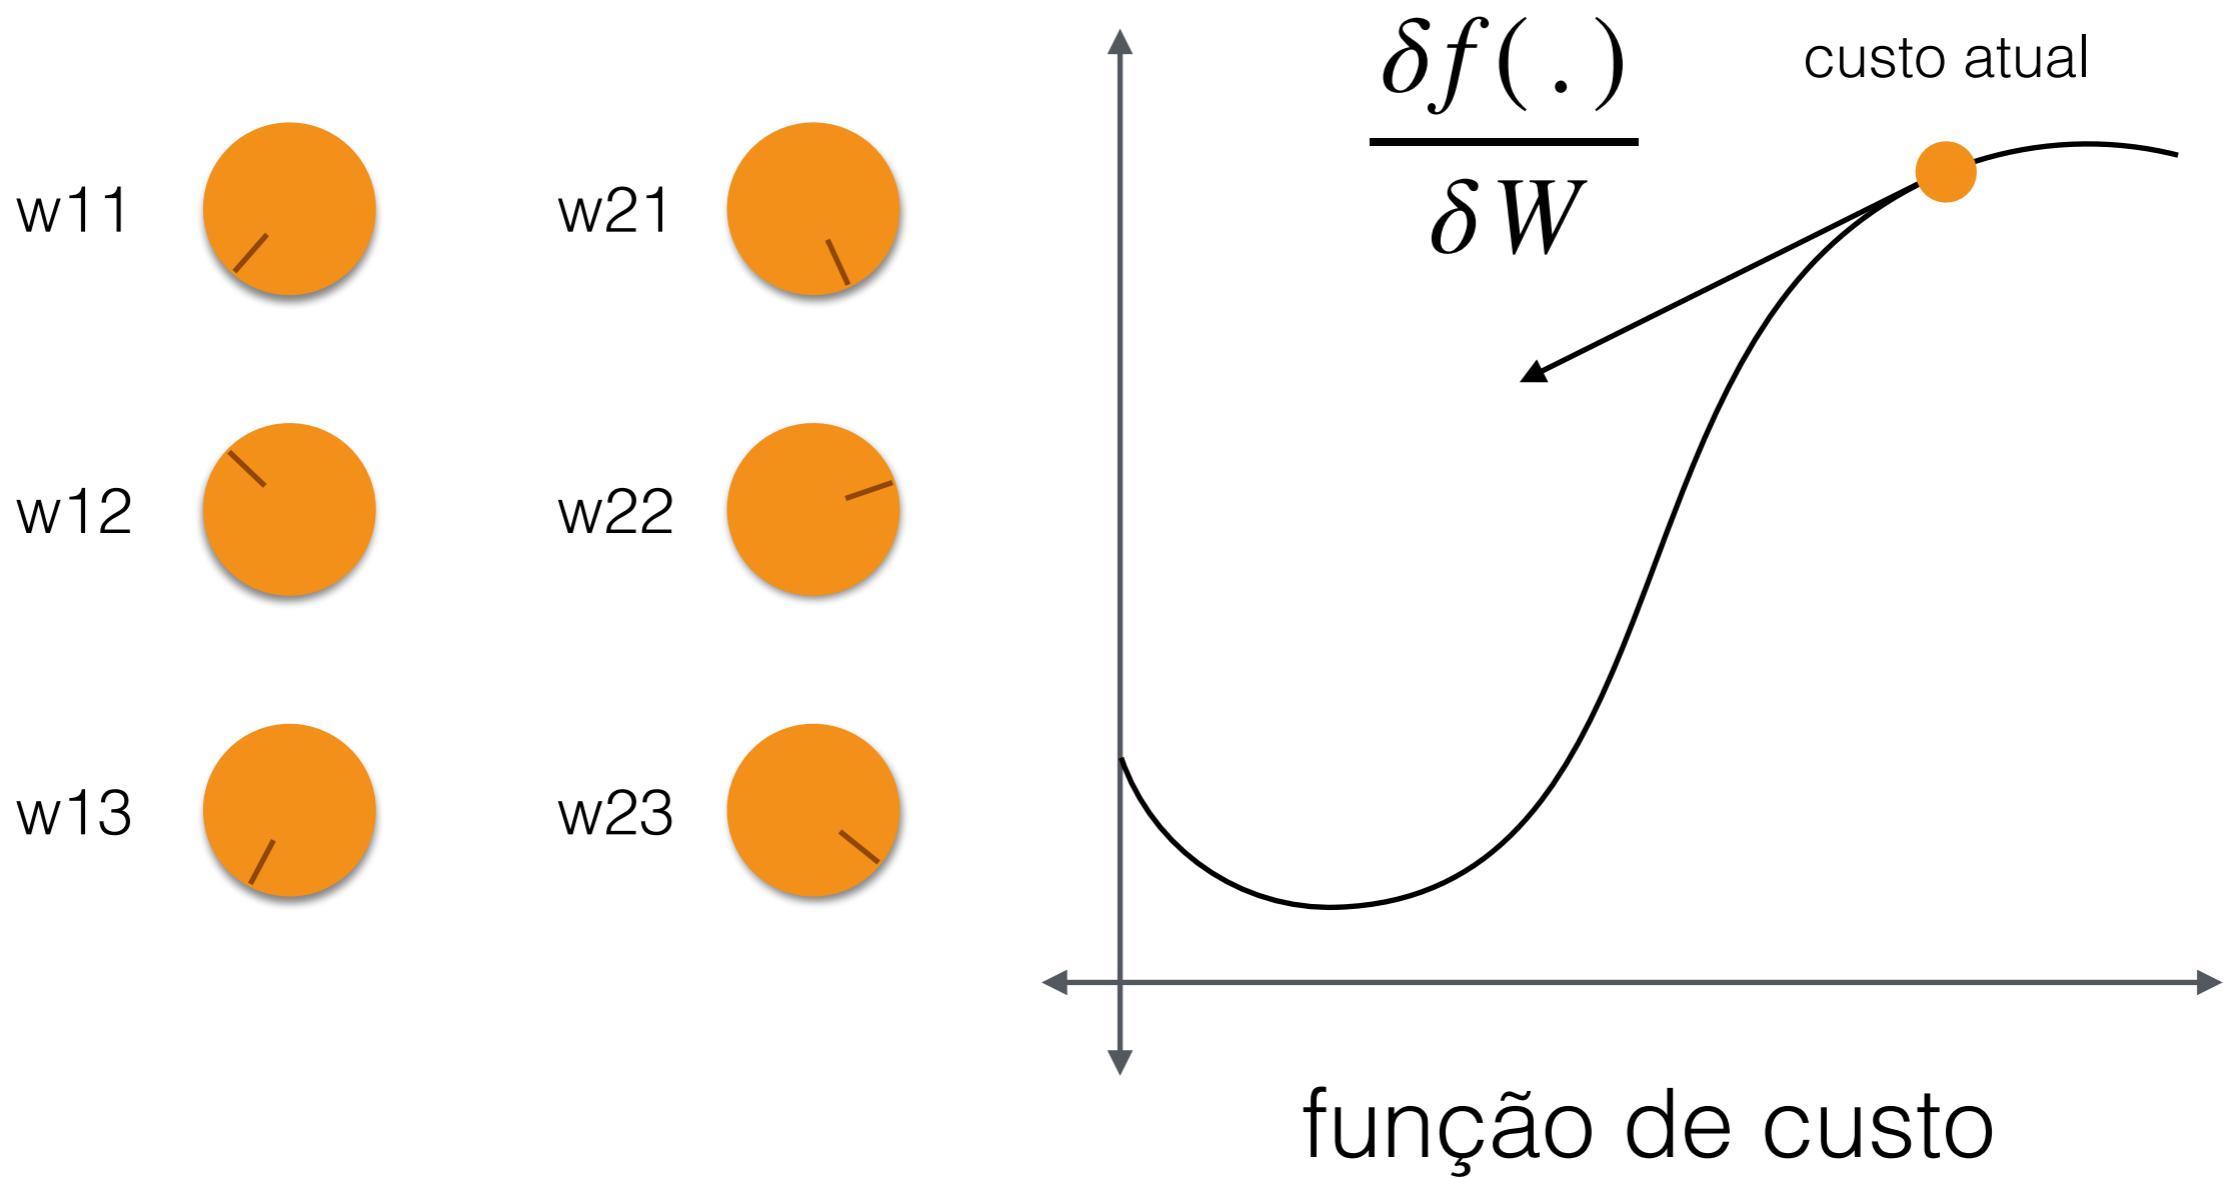
Redes Neurais Artificiais

treinamento



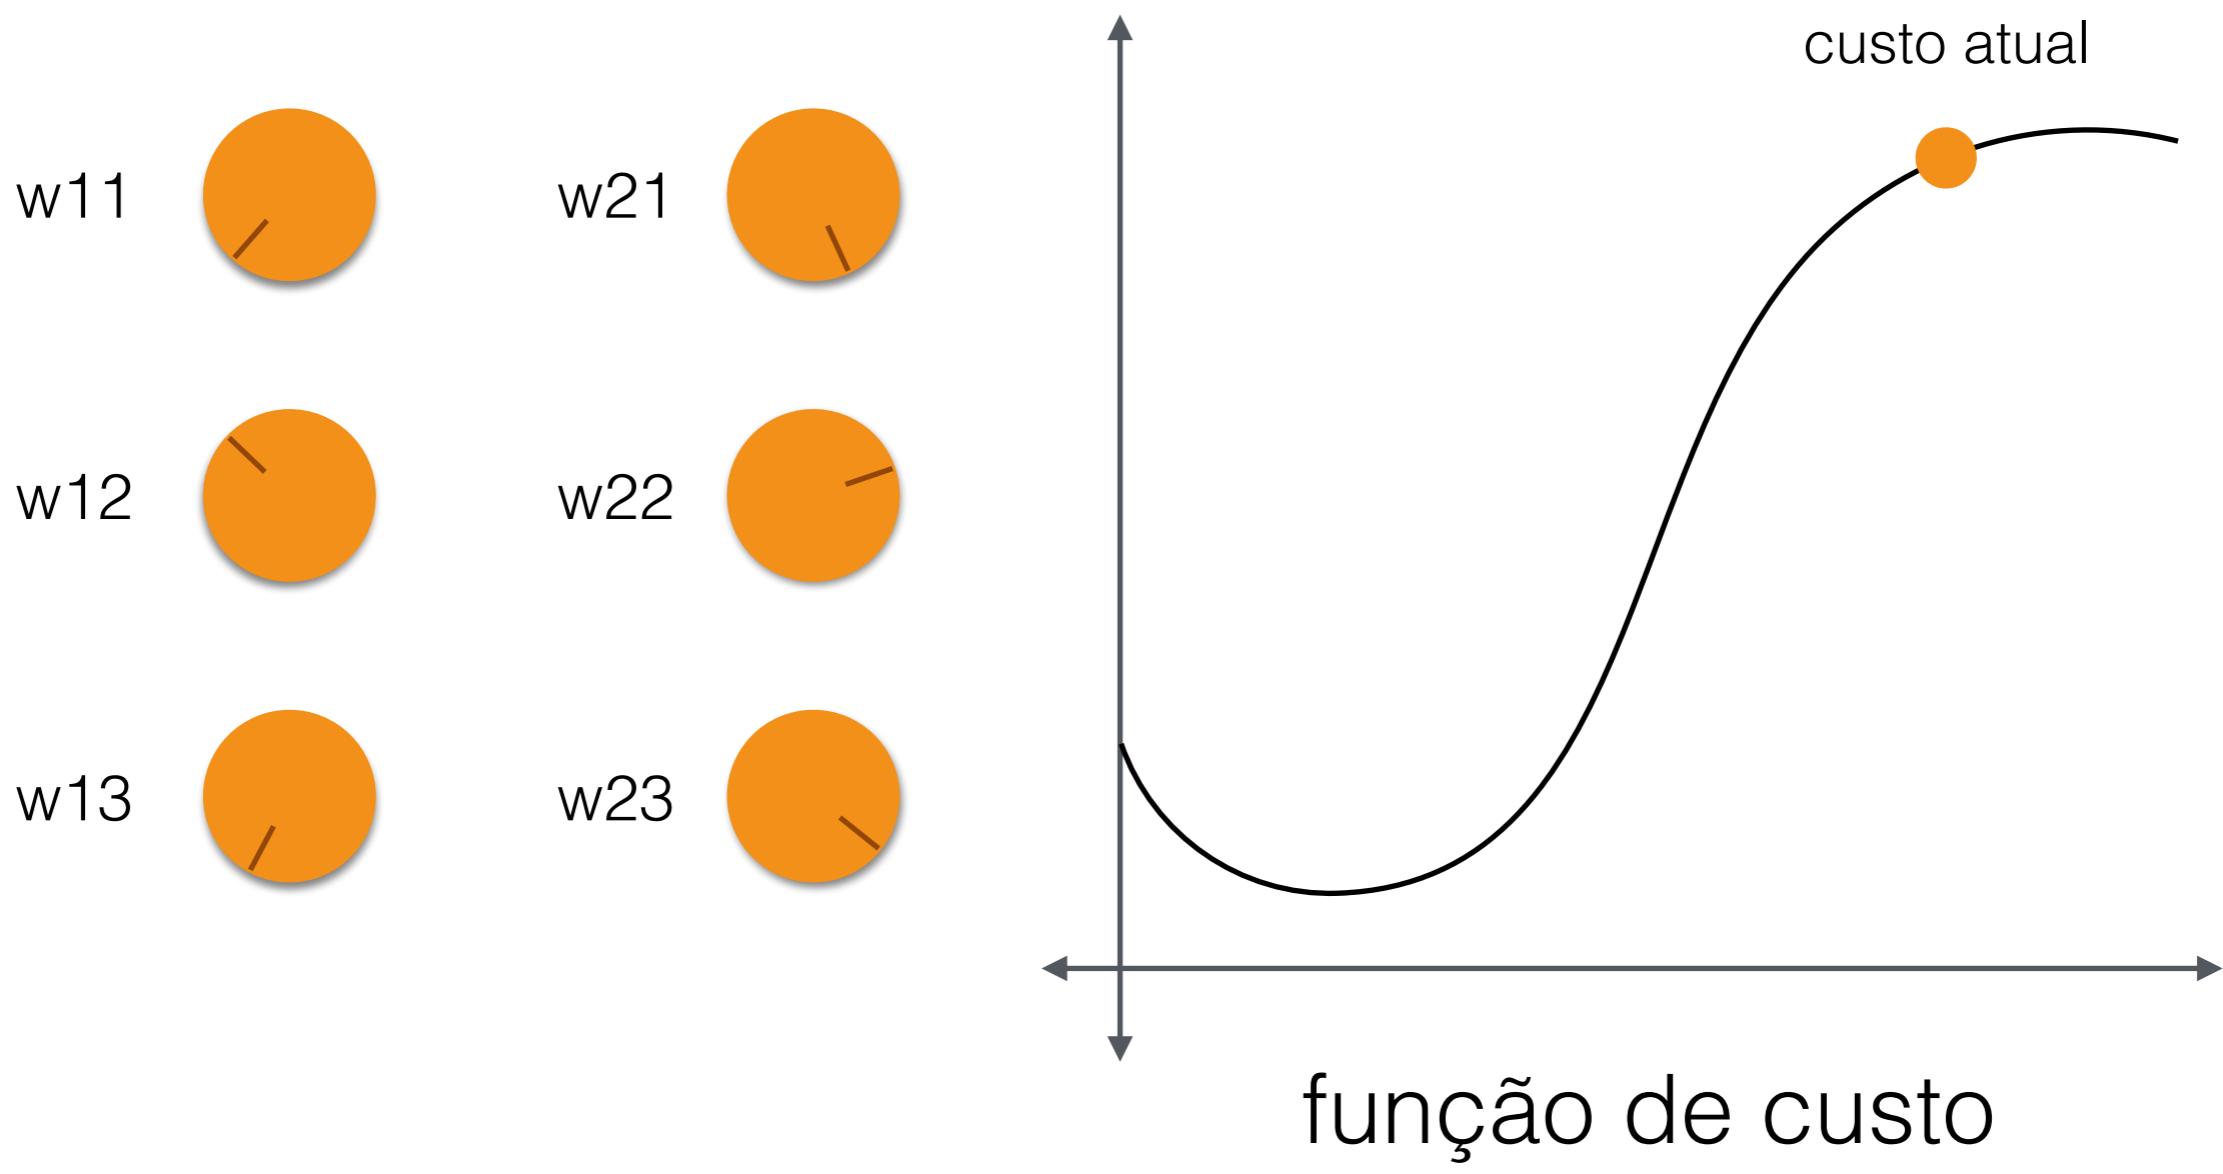
Redes Neurais Artificiais

treinamento



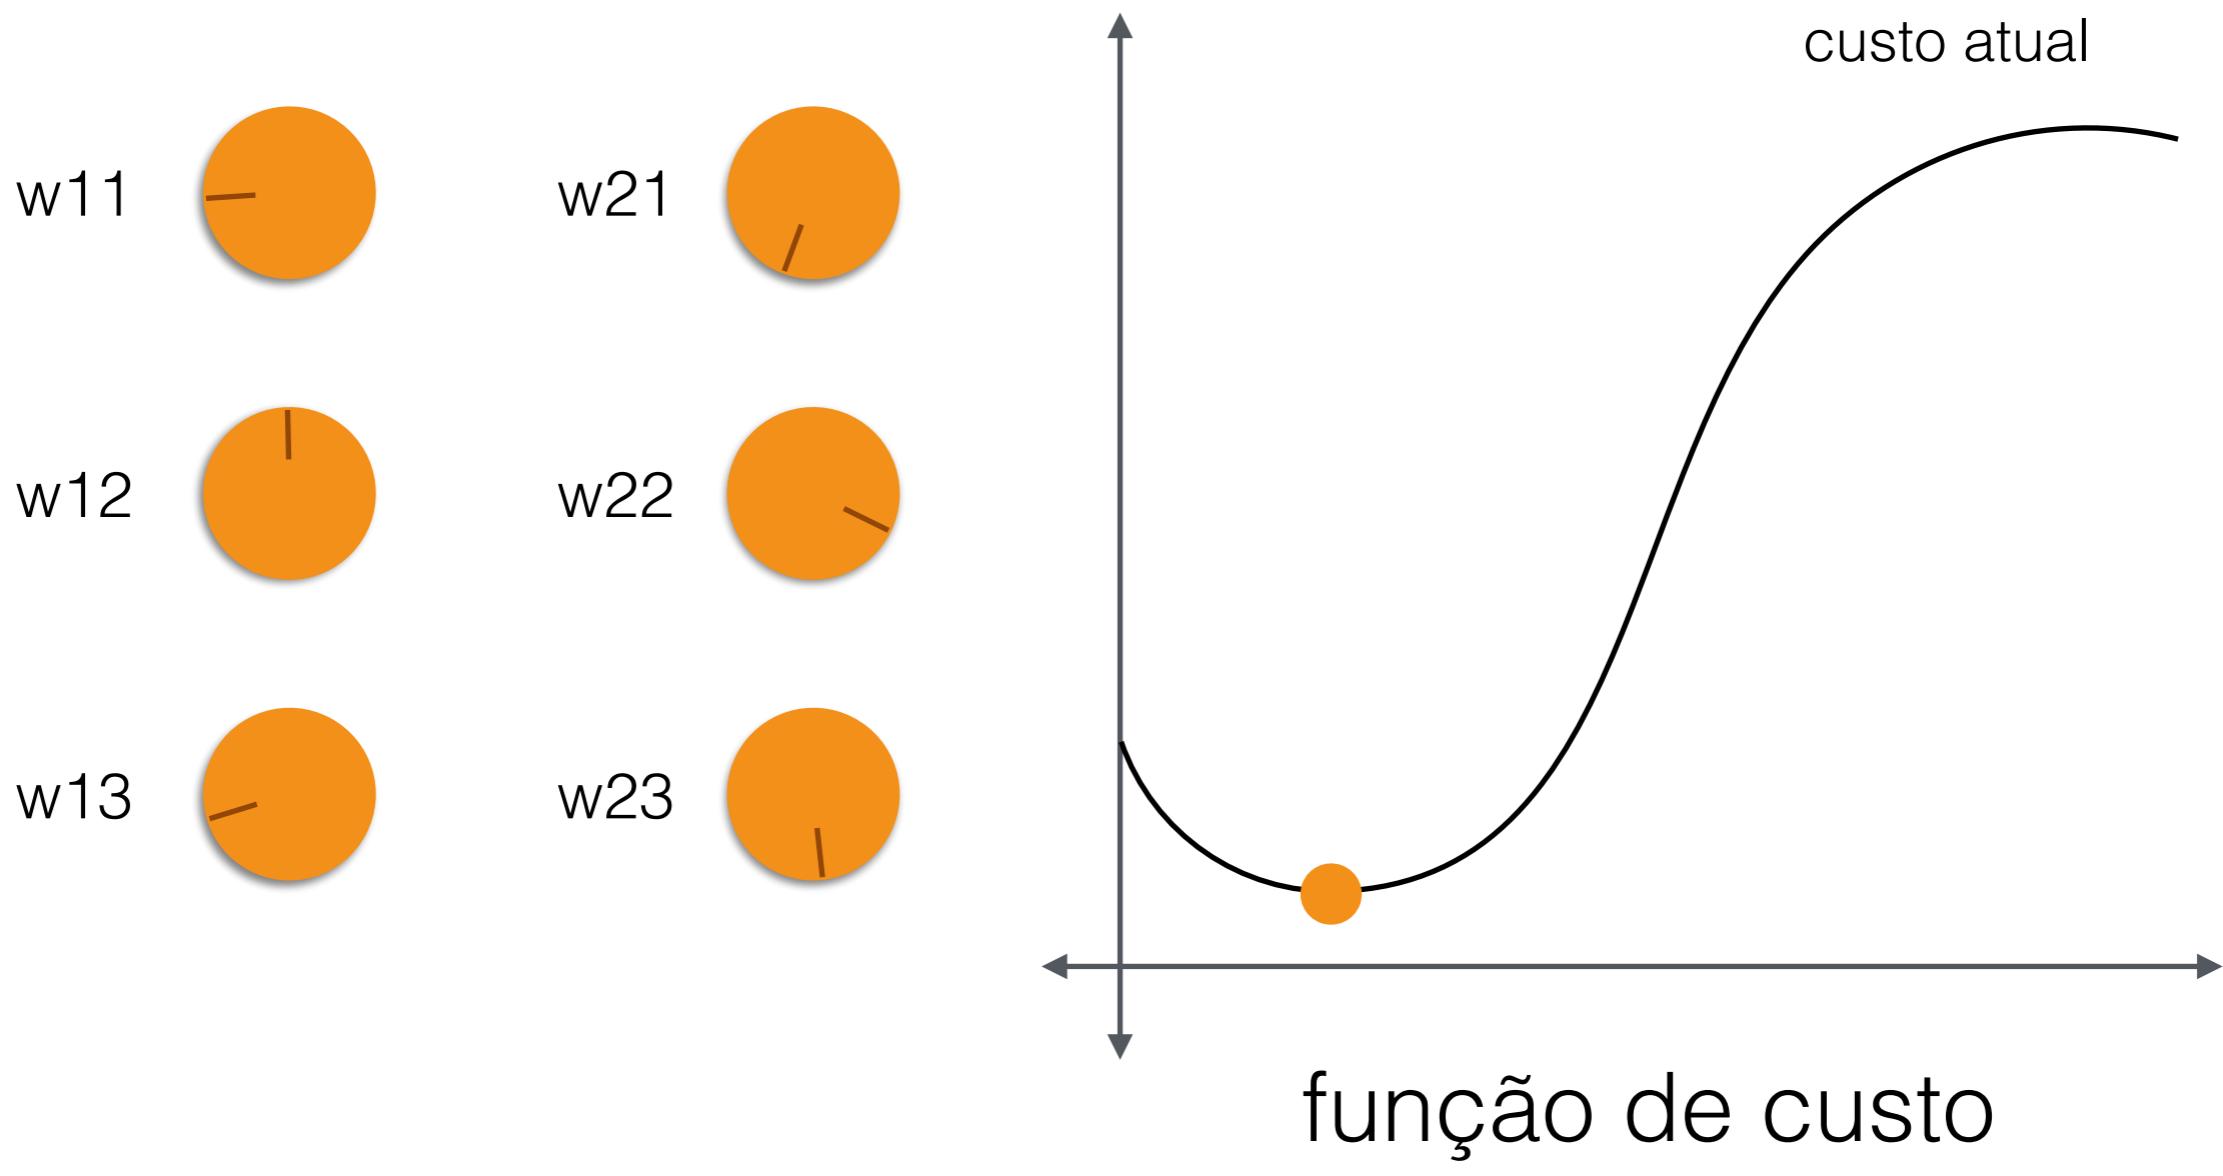
Redes Neurais Artificiais

treinamento



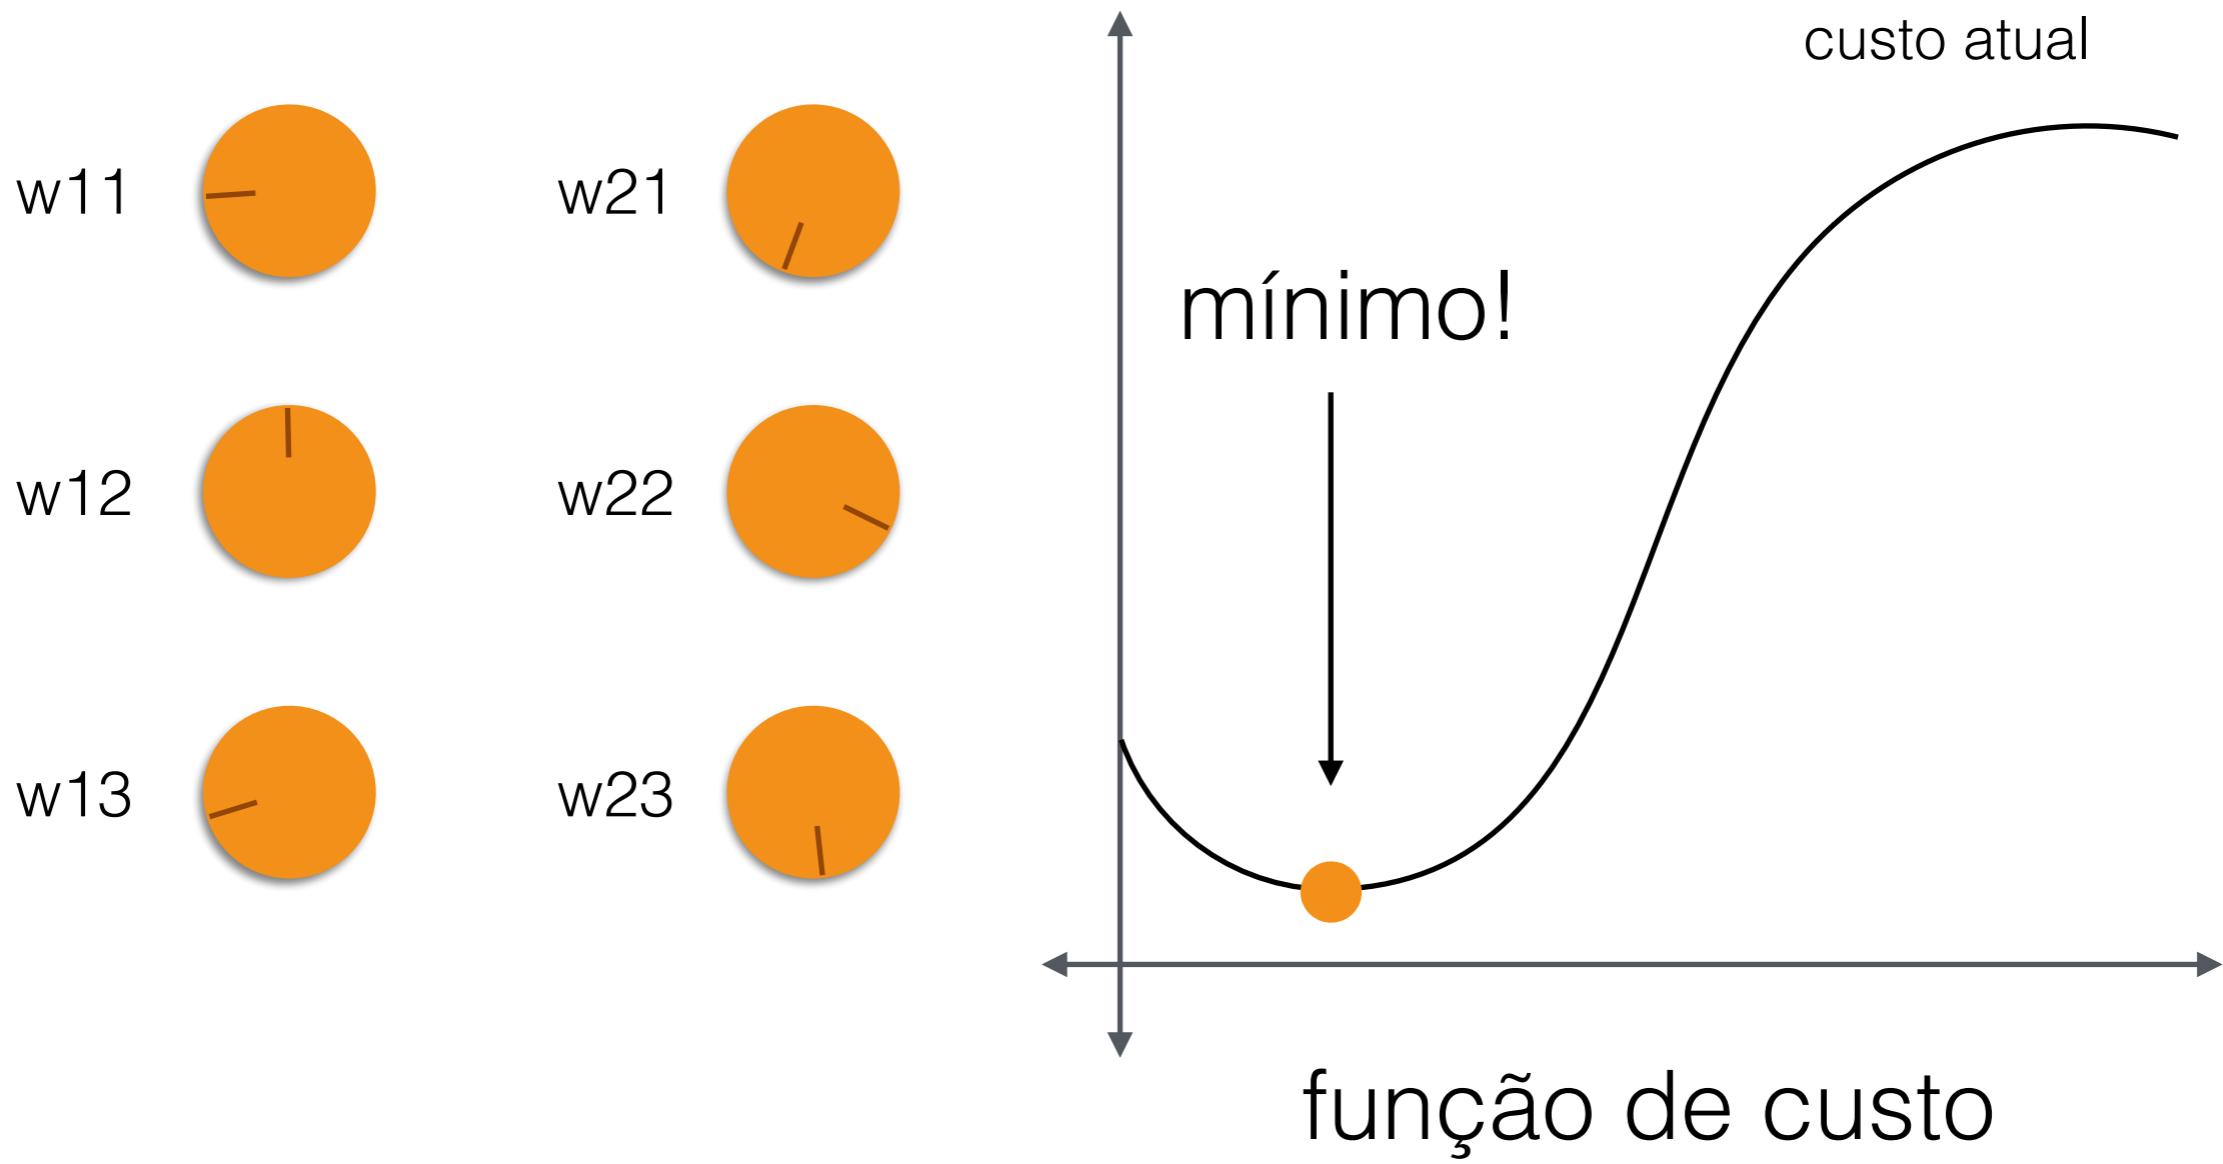
Redes Neurais Artificiais

treinamento



Redes Neurais Artificiais

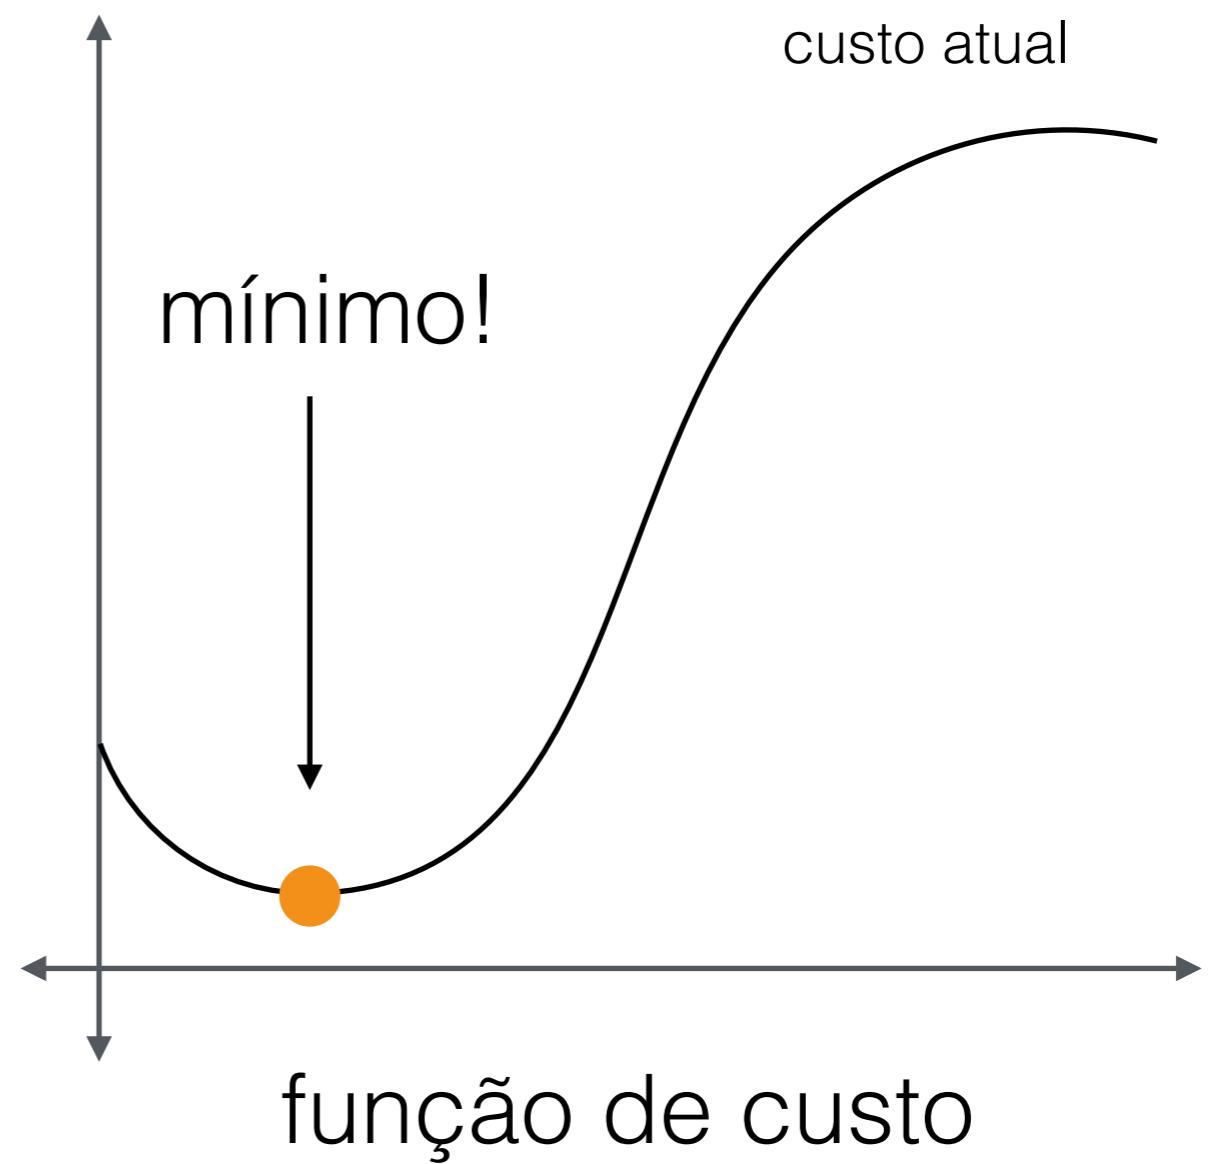
treinamento



Redes Neurais Artificiais

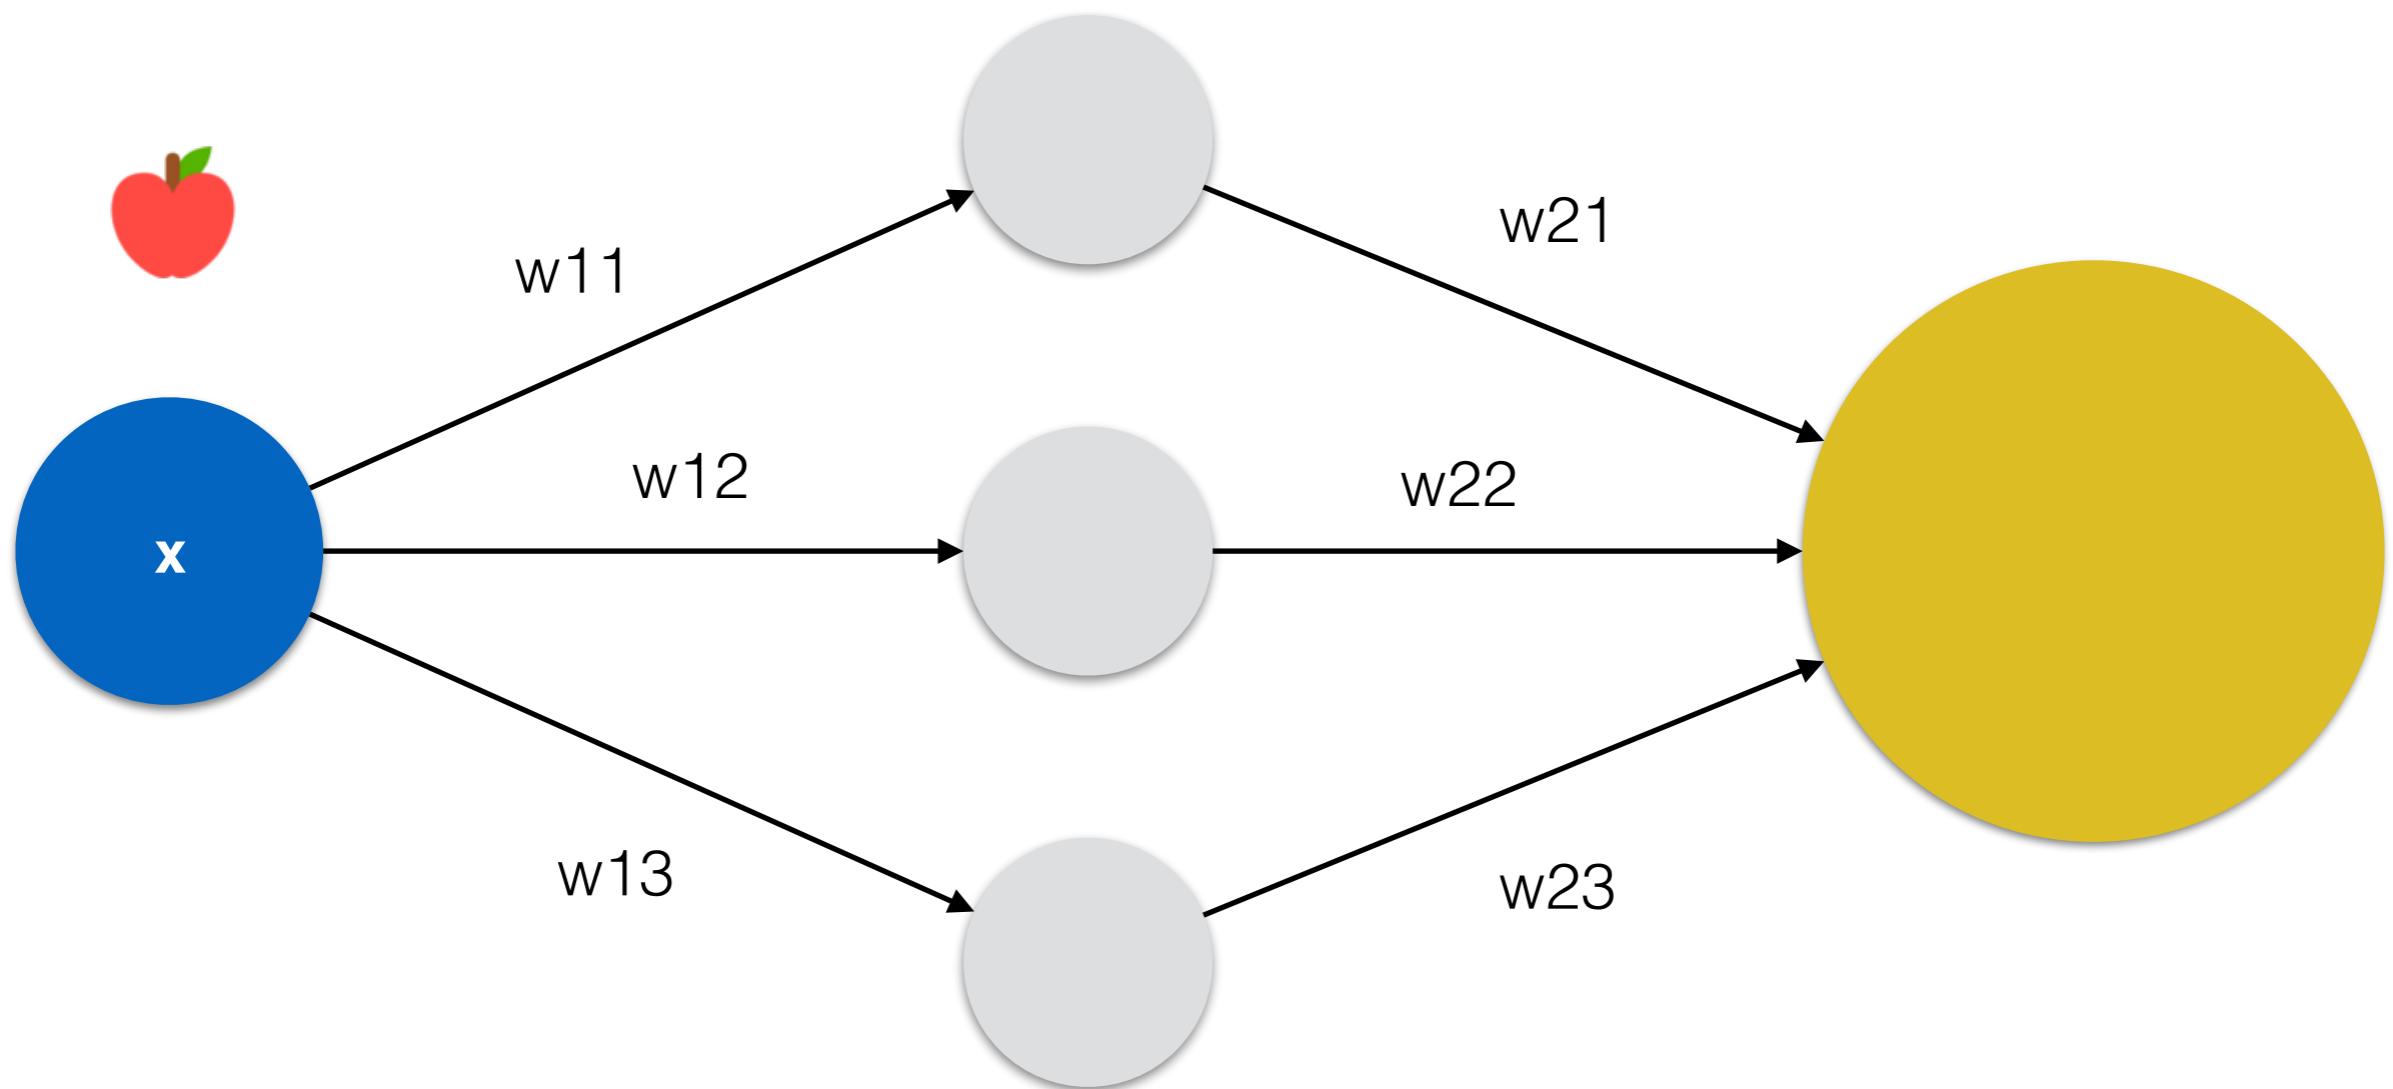
treinamento

Esse processo de treinamento é conhecido como Gradiente Descendente (*Gradient Descent*)



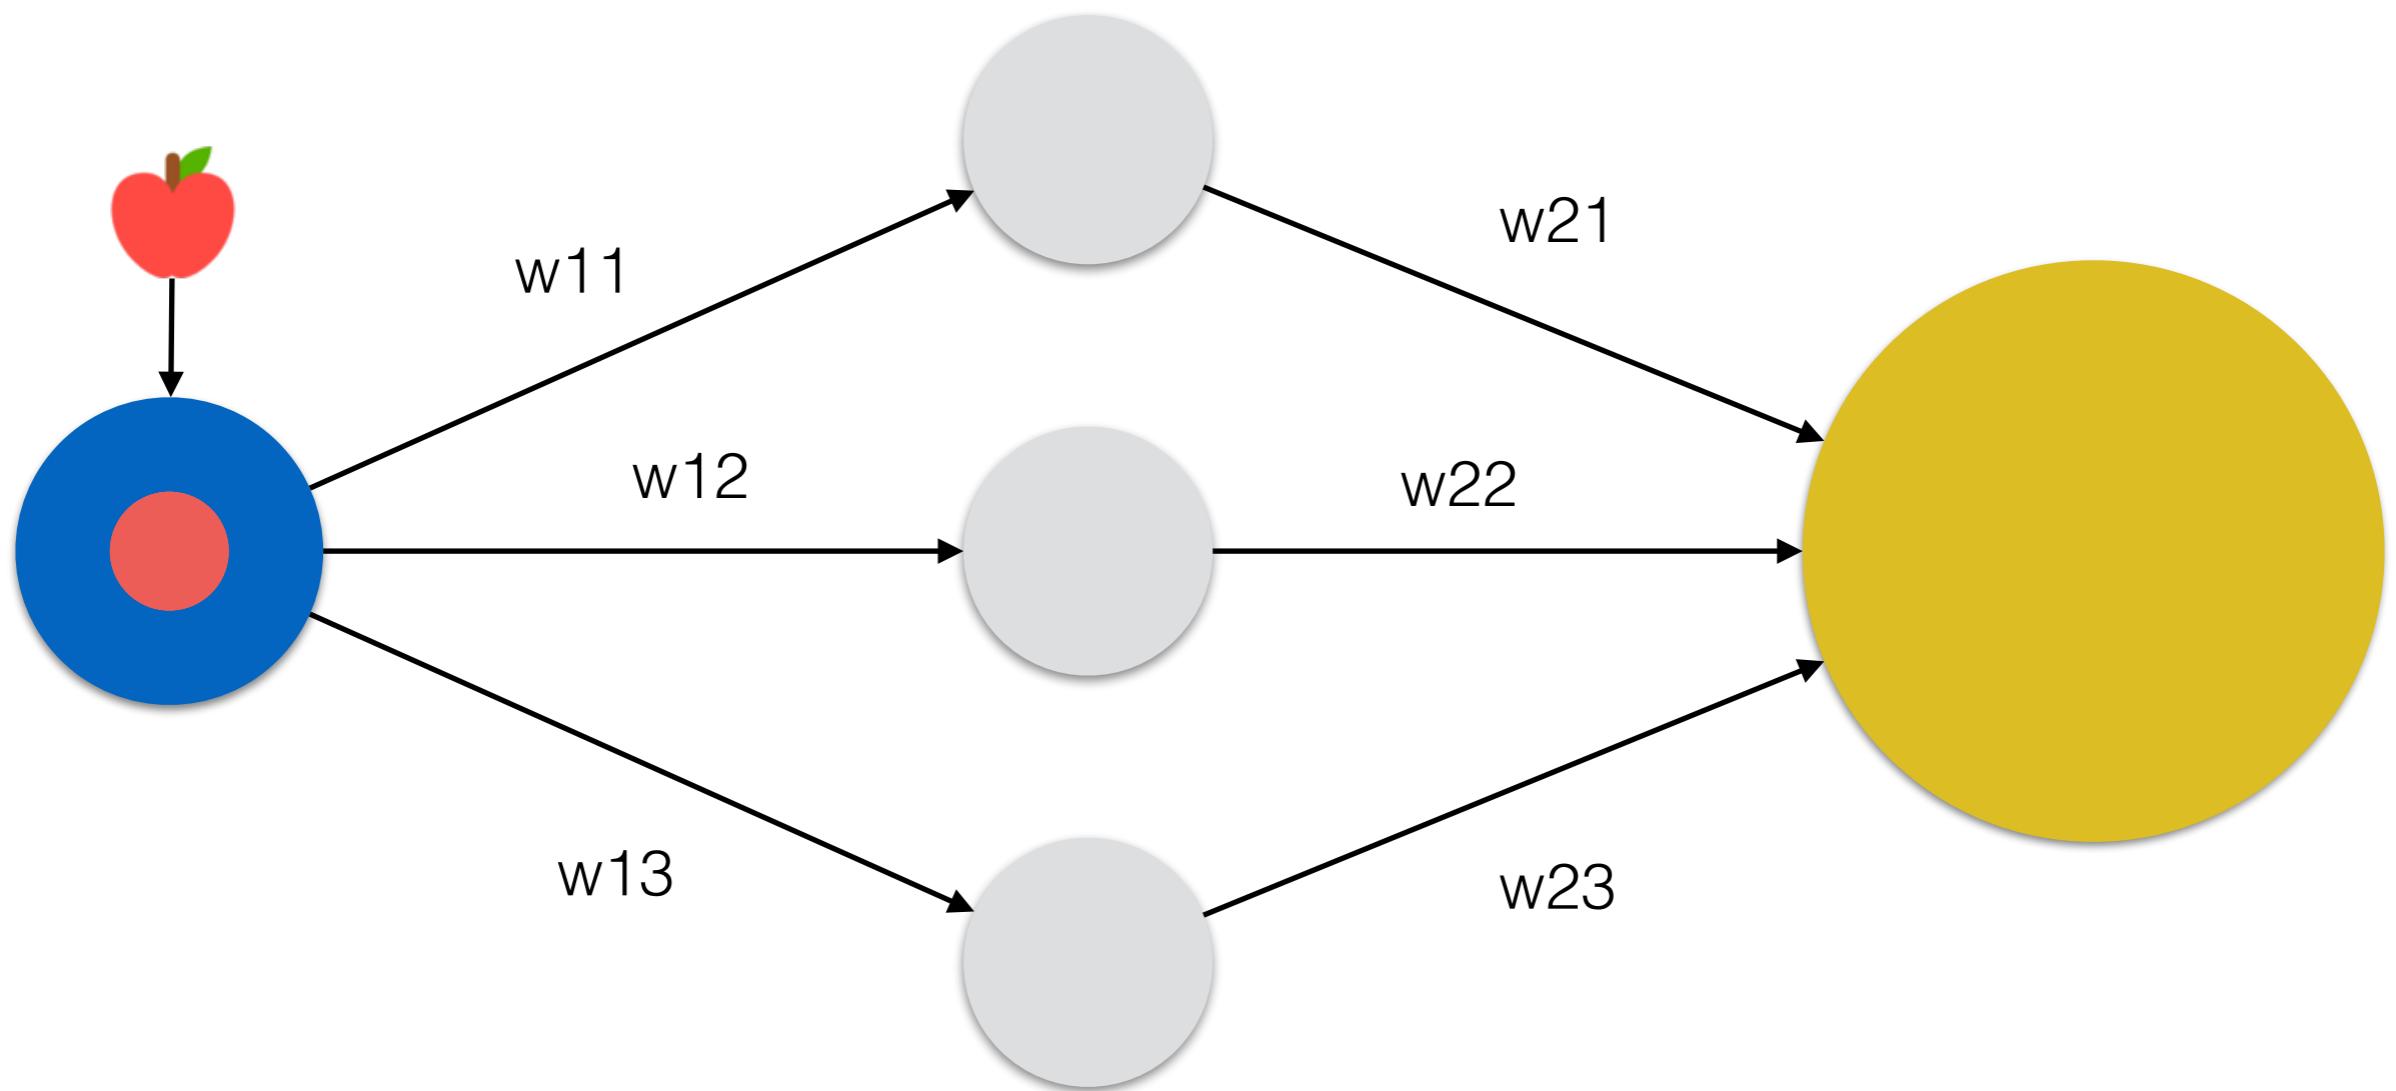
Redes Neurais Artificiais

o classificador de frutas



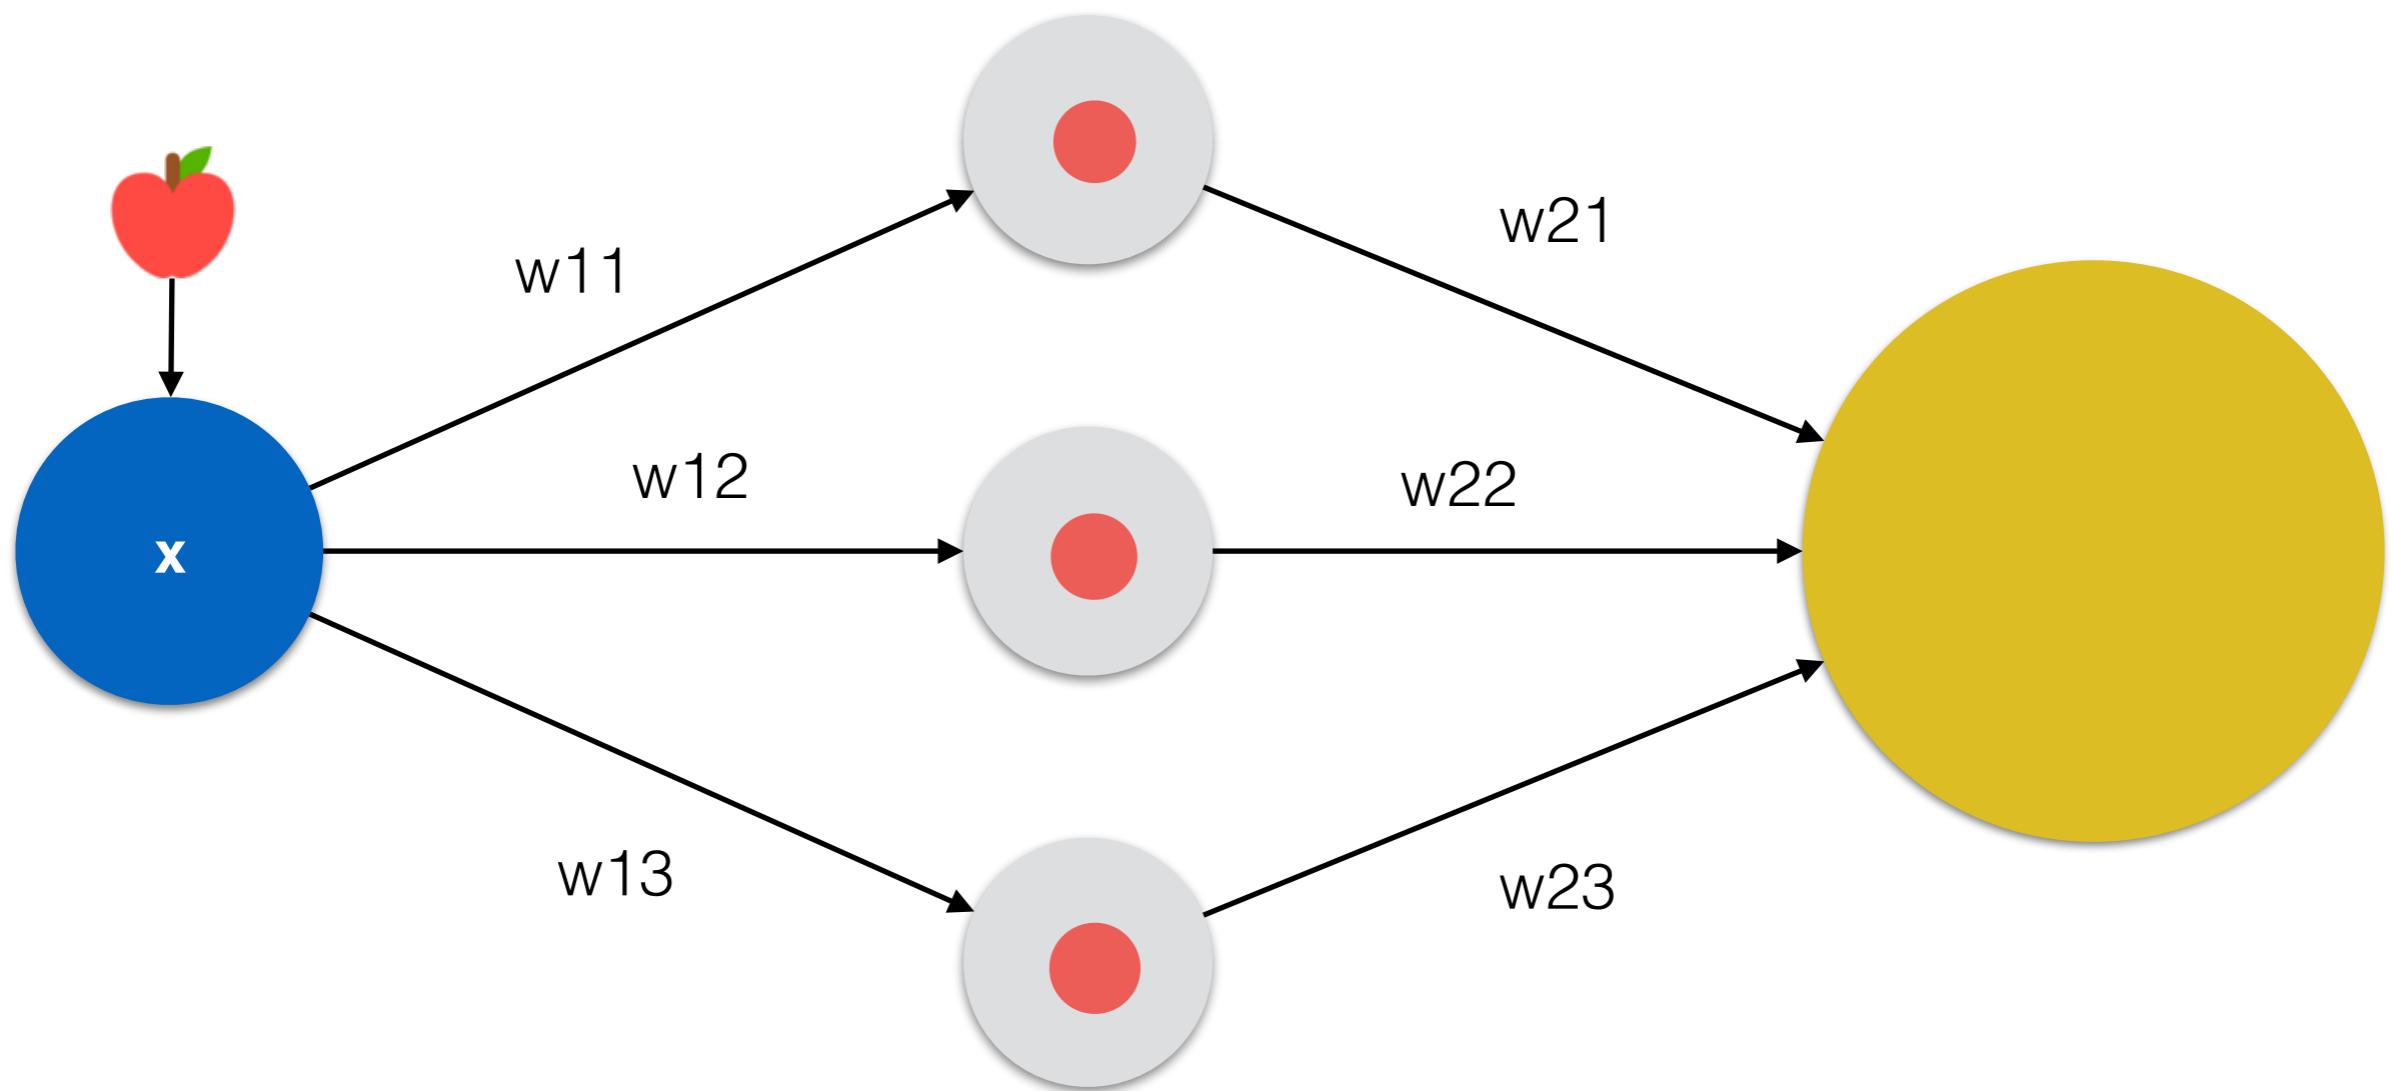
Redes Neurais Artificiais

o classificador de frutas



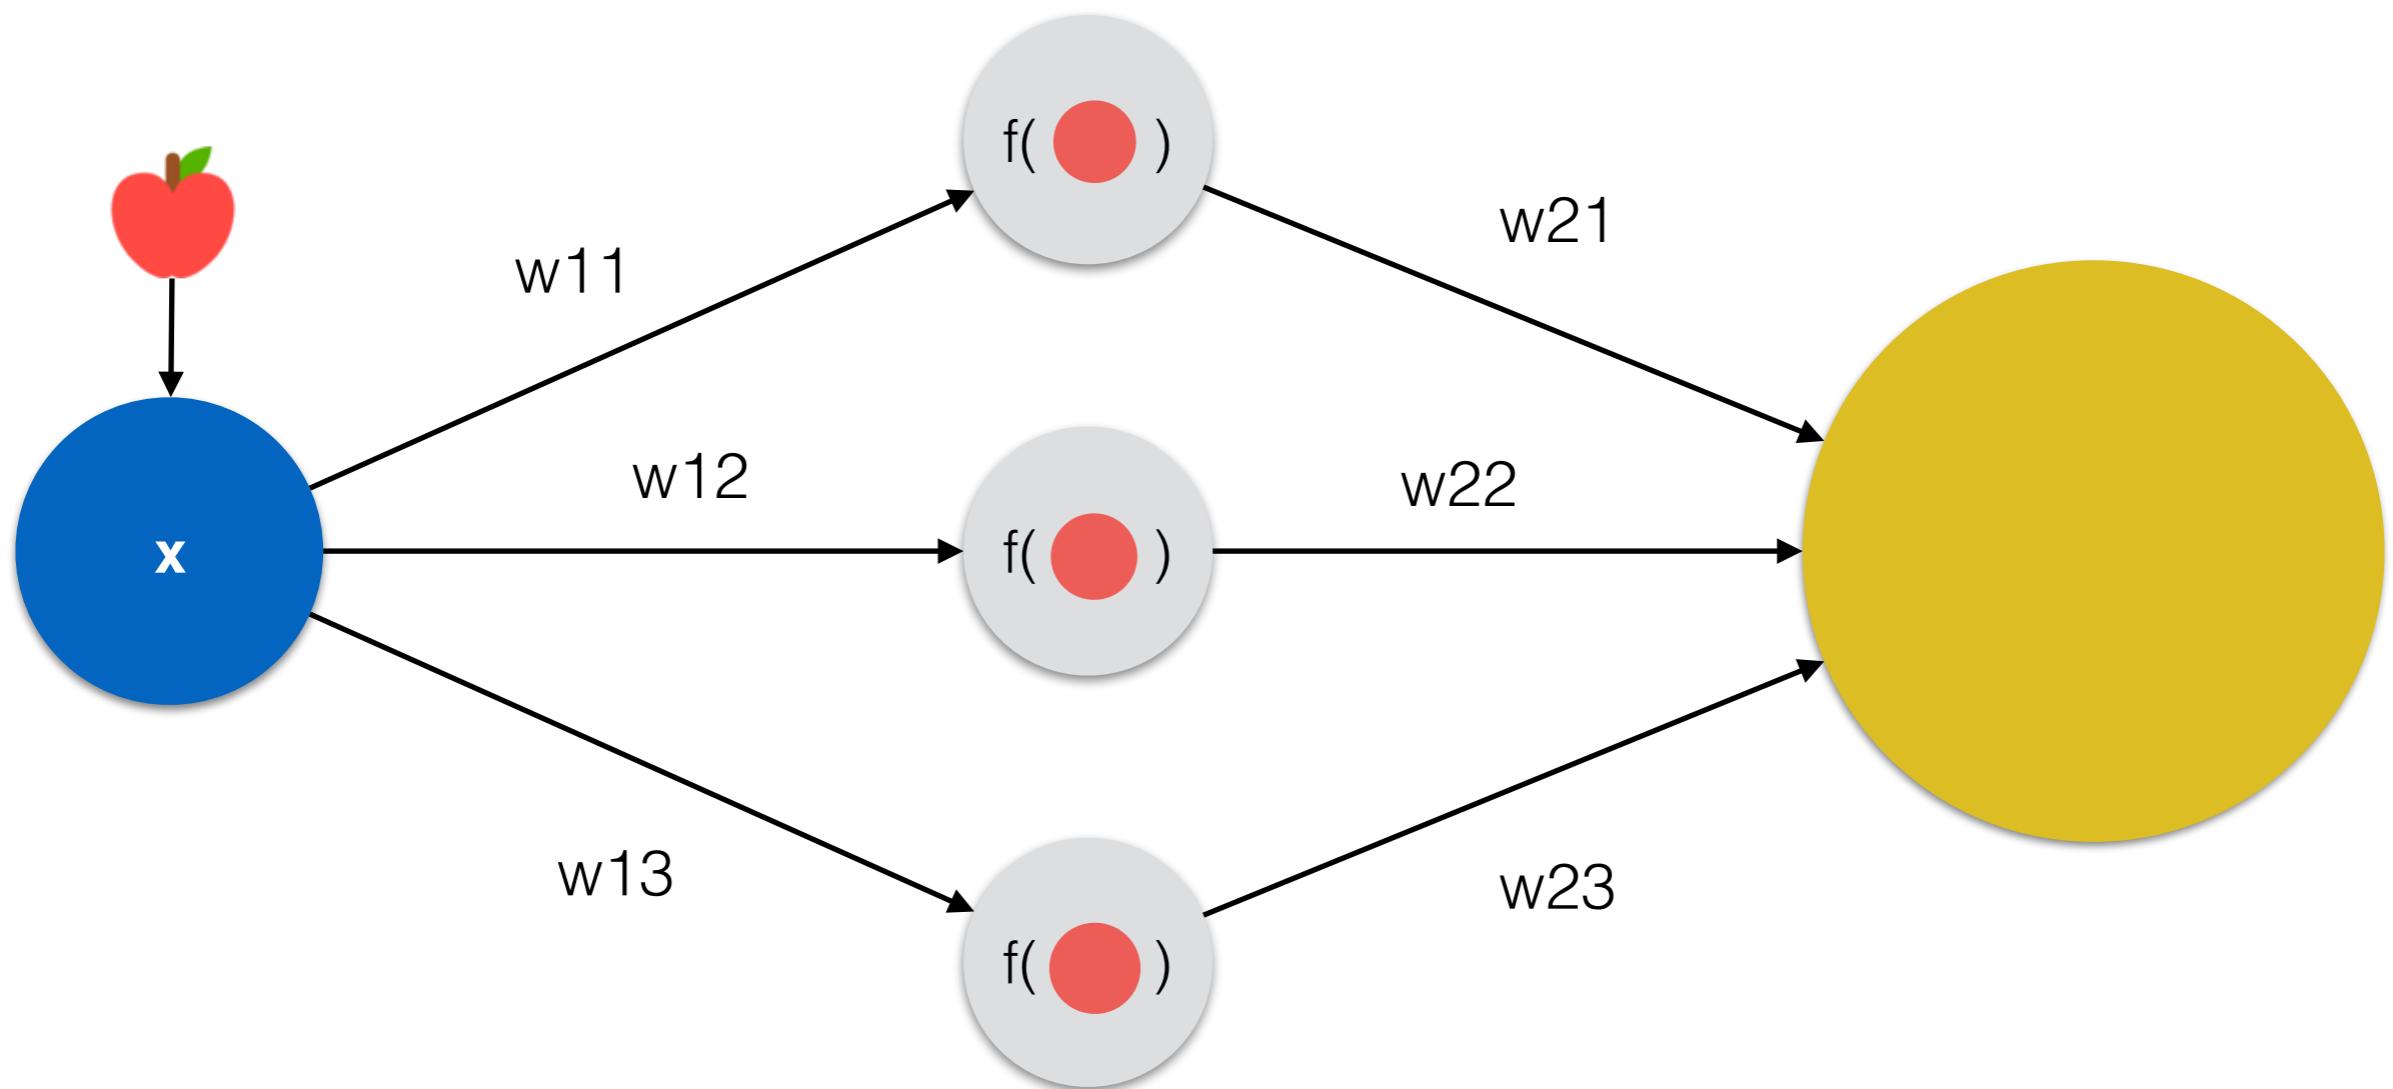
Redes Neurais Artificiais

o classificador de frutas



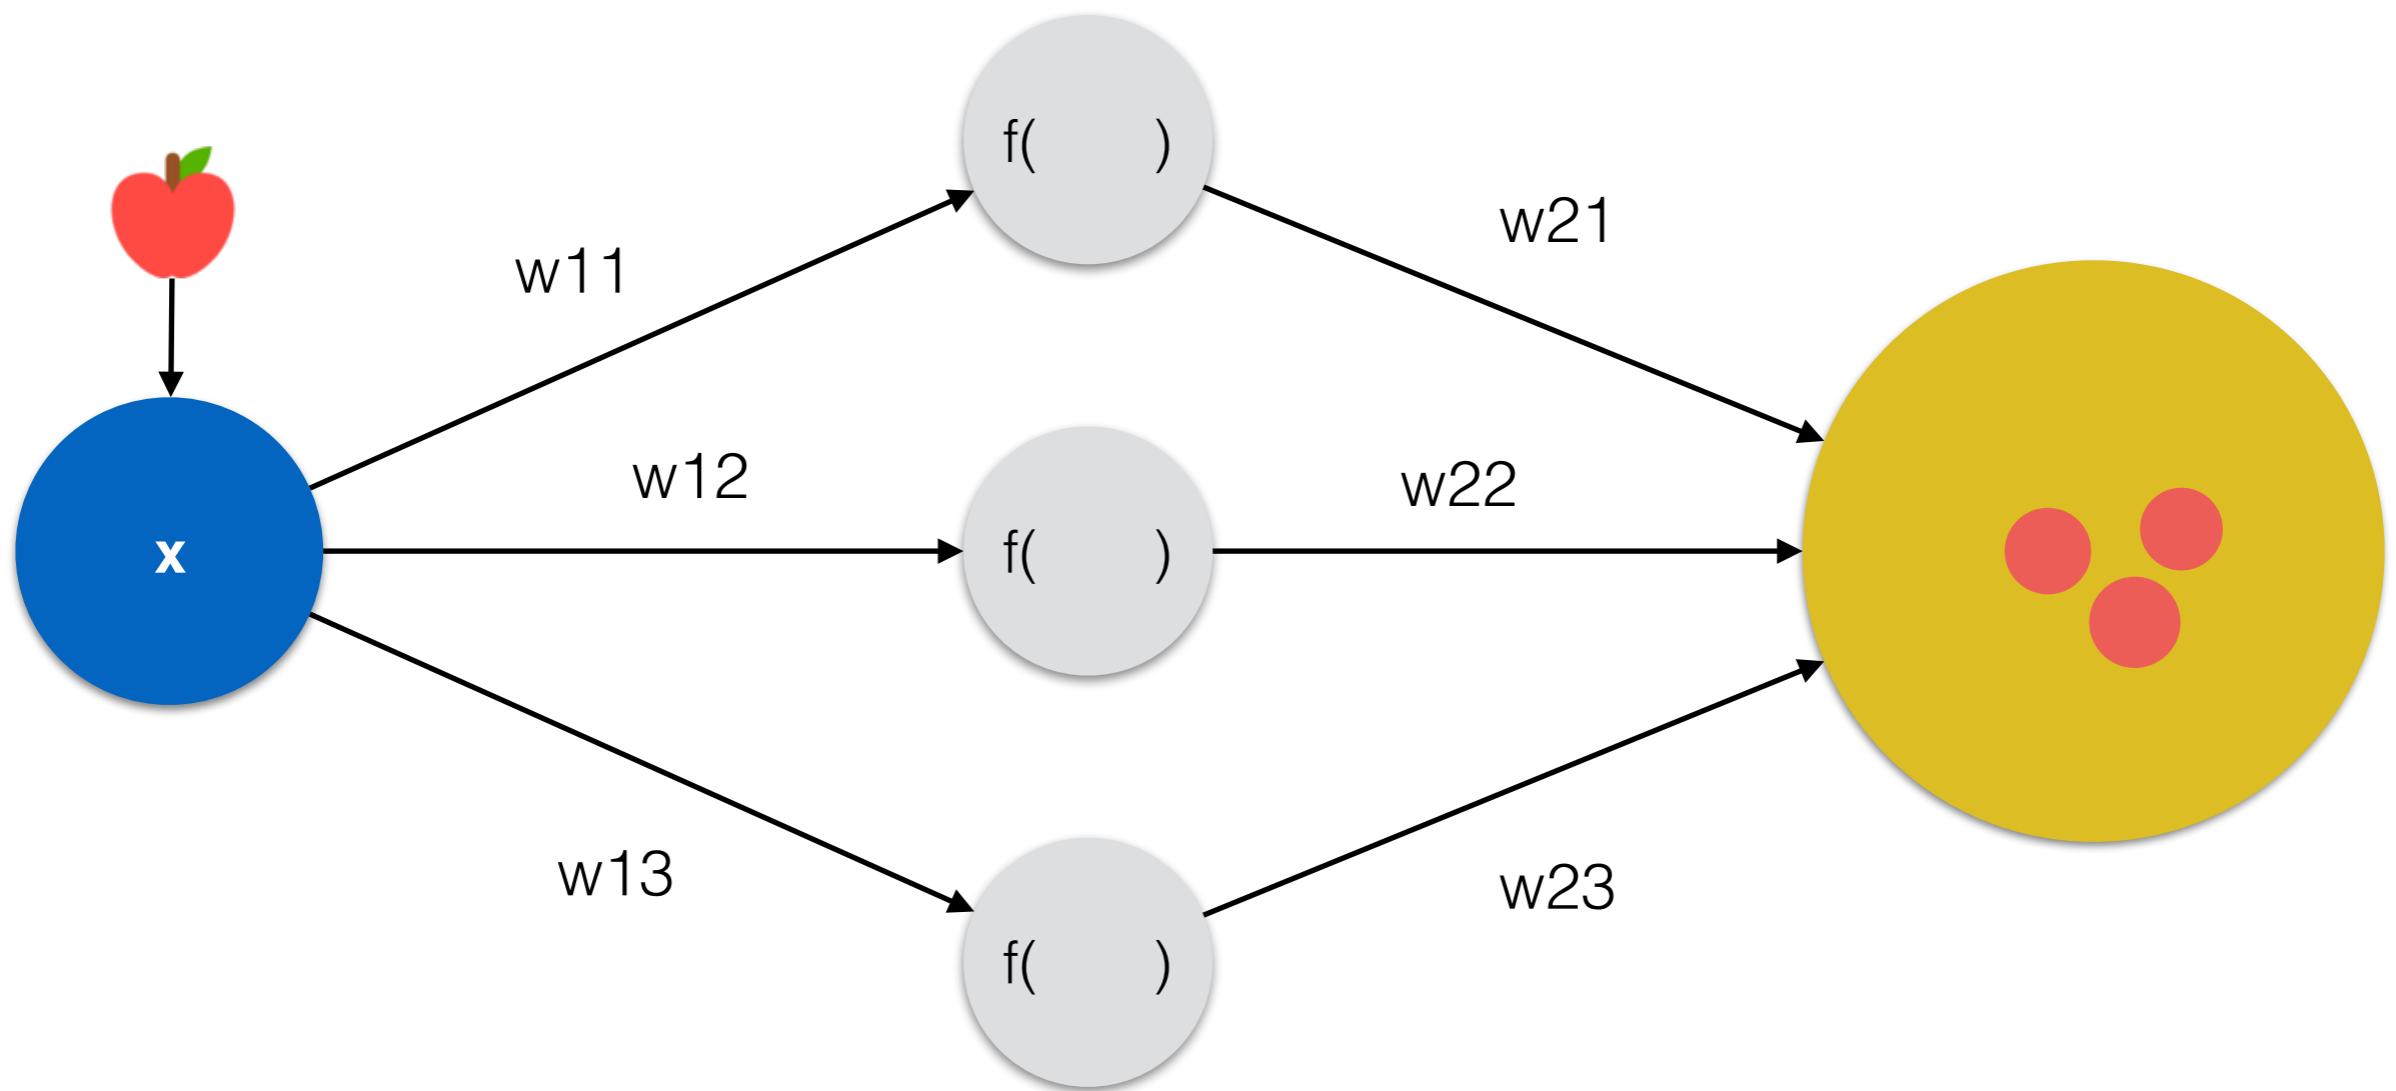
Redes Neurais Artificiais

o classificador de frutas



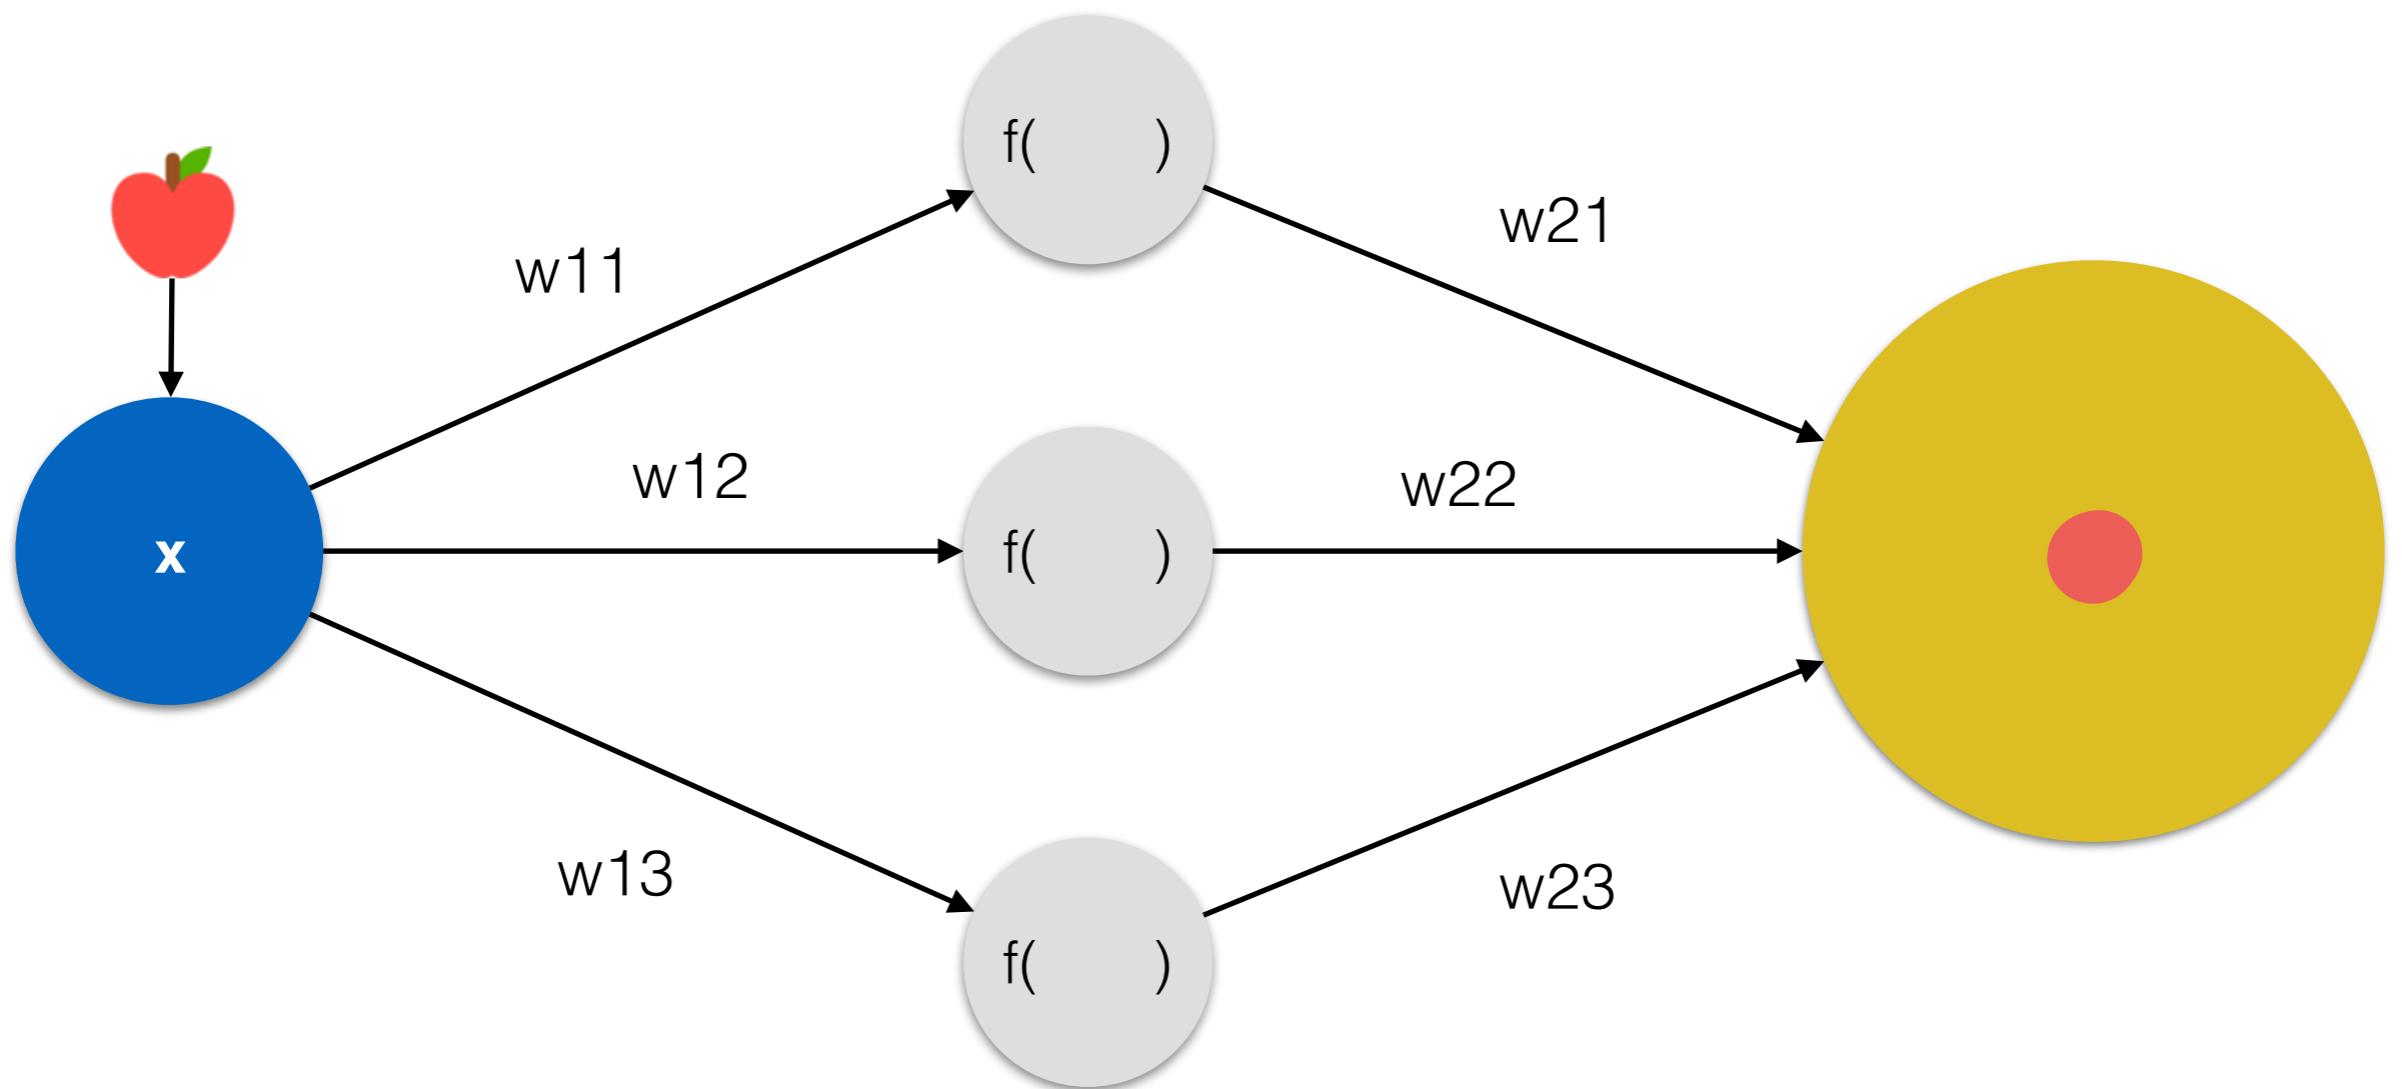
Redes Neurais Artificiais

o classificador de frutas



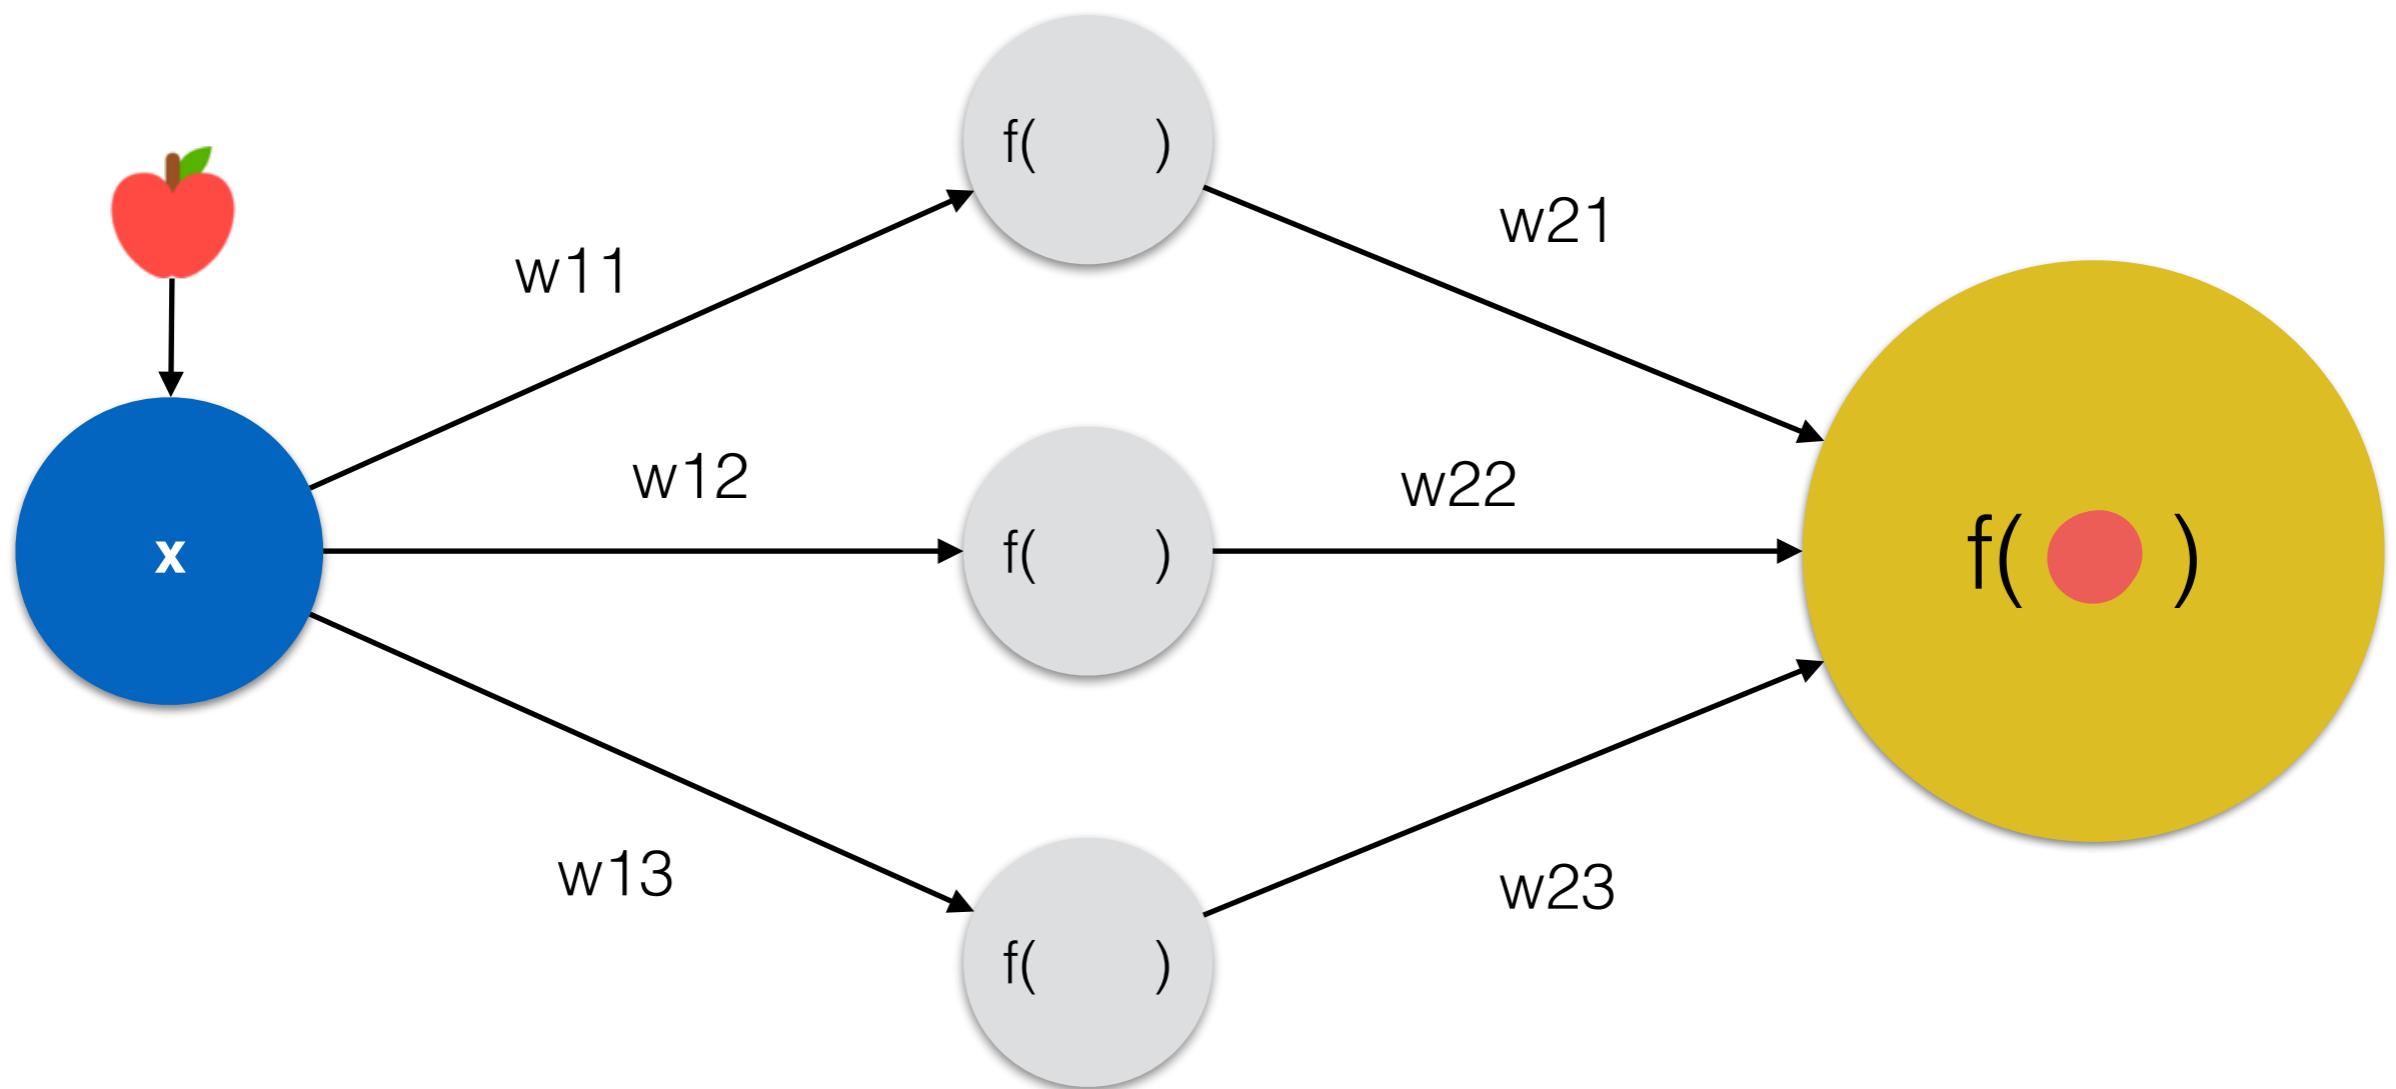
Redes Neurais Artificiais

o classificador de frutas



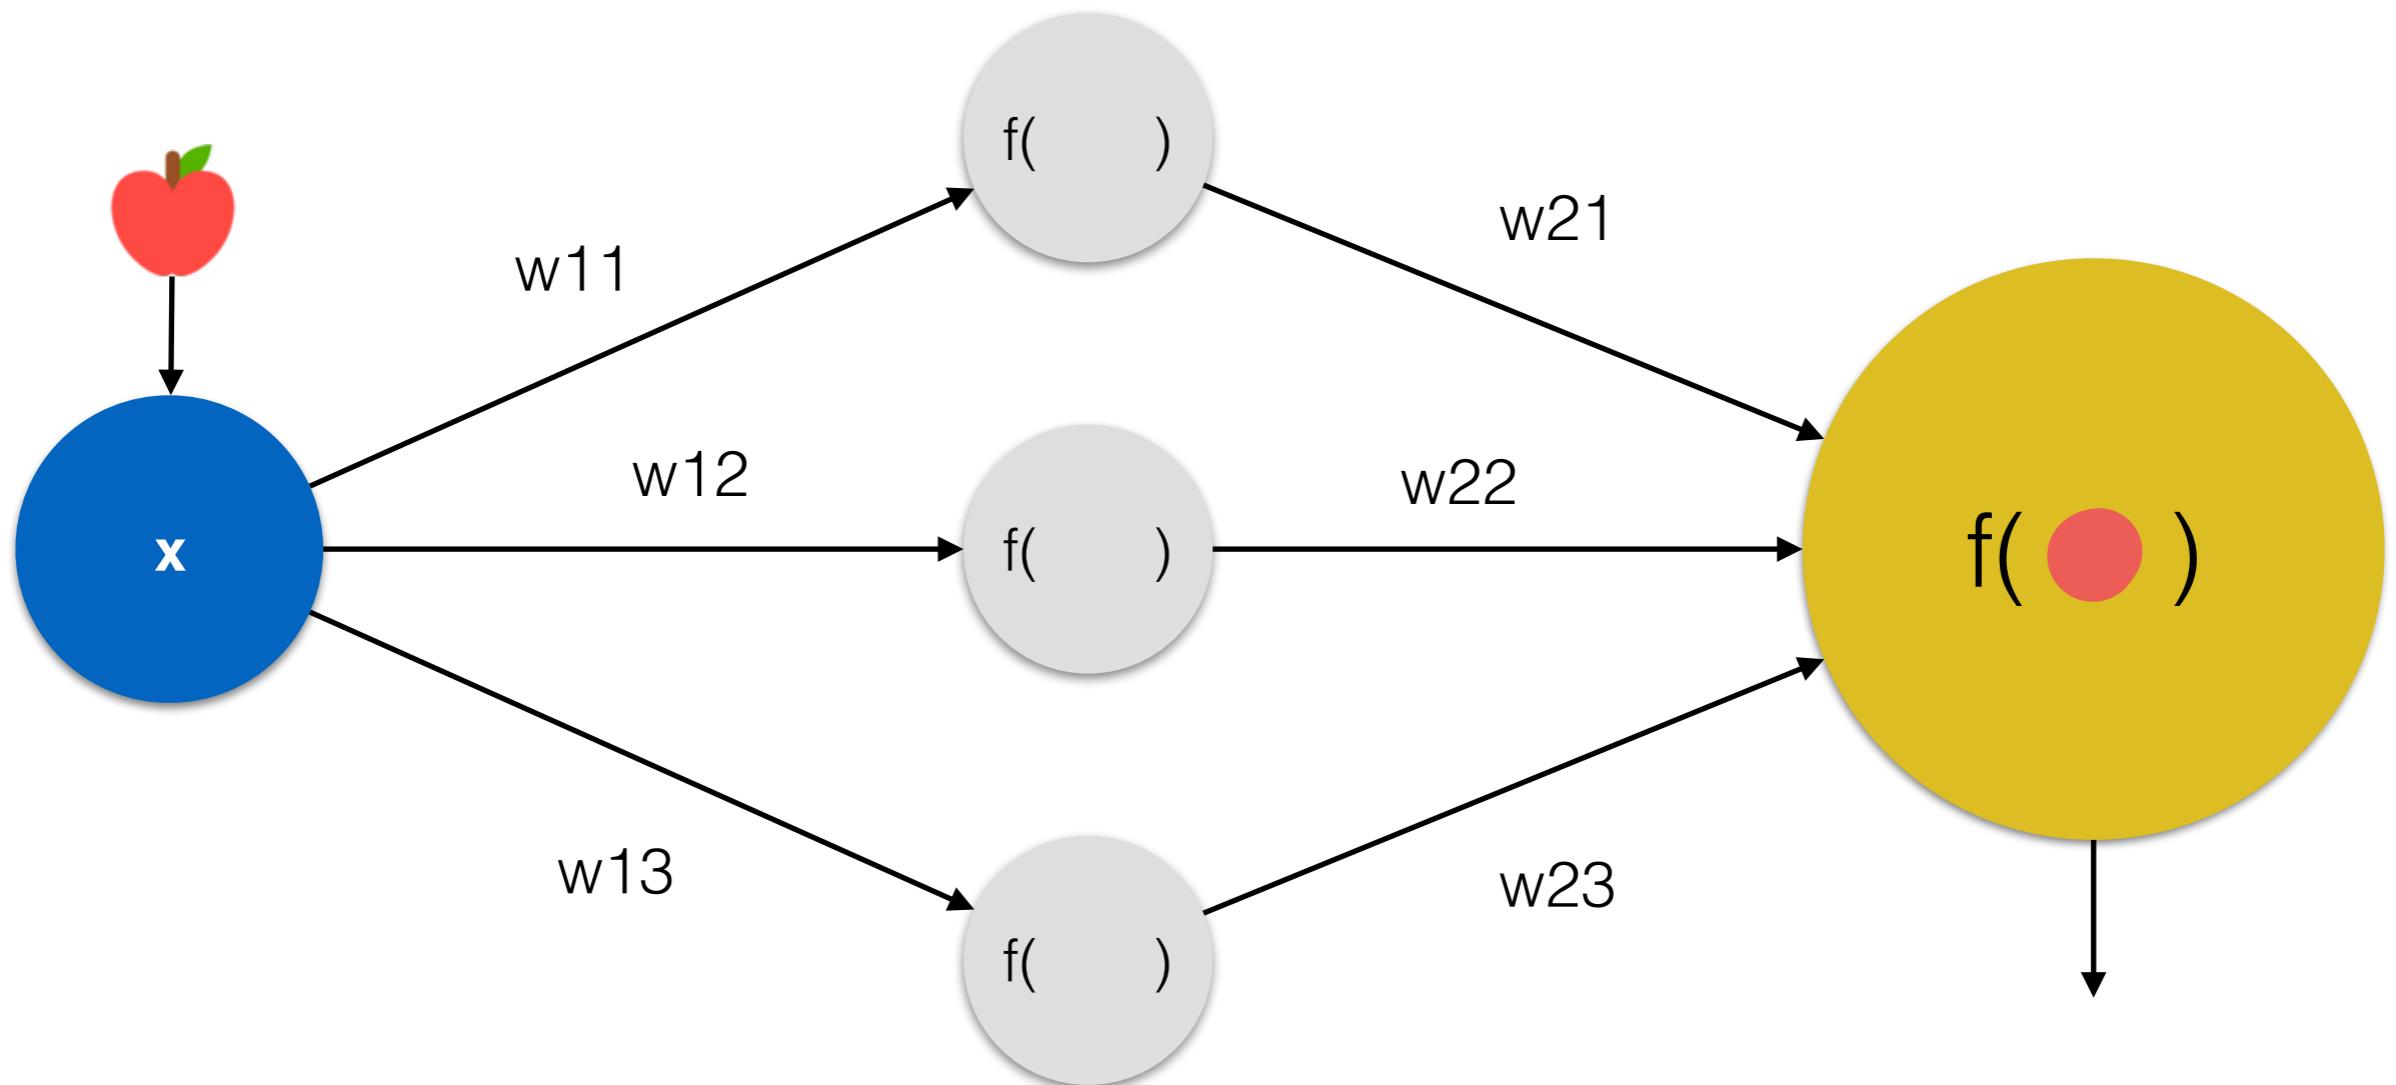
Redes Neurais Artificiais

o classificador de frutas



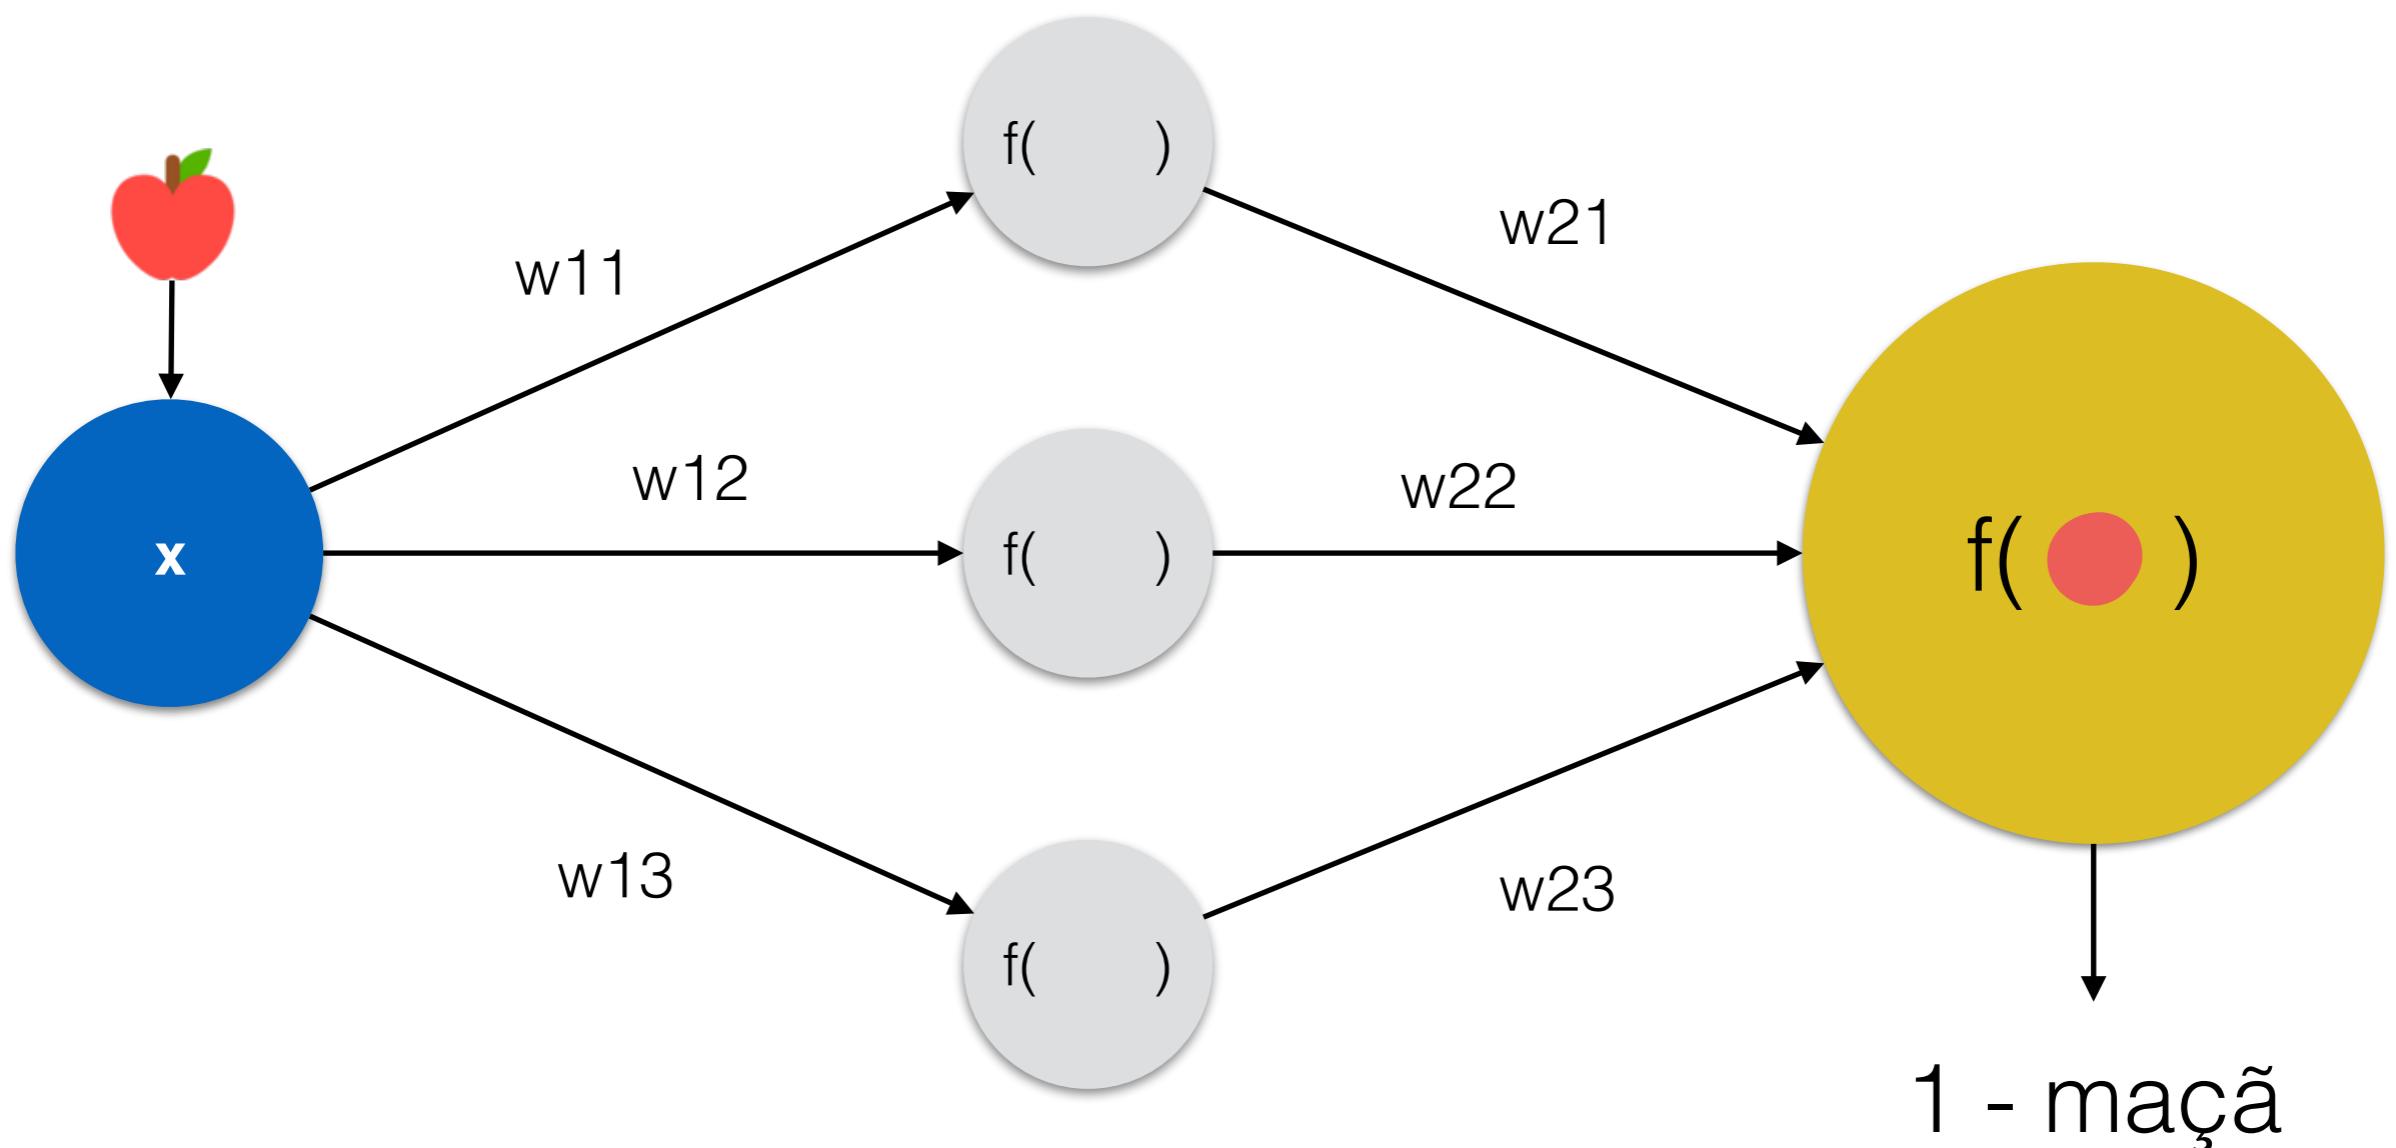
Redes Neurais Artificiais

o classificador de frutas



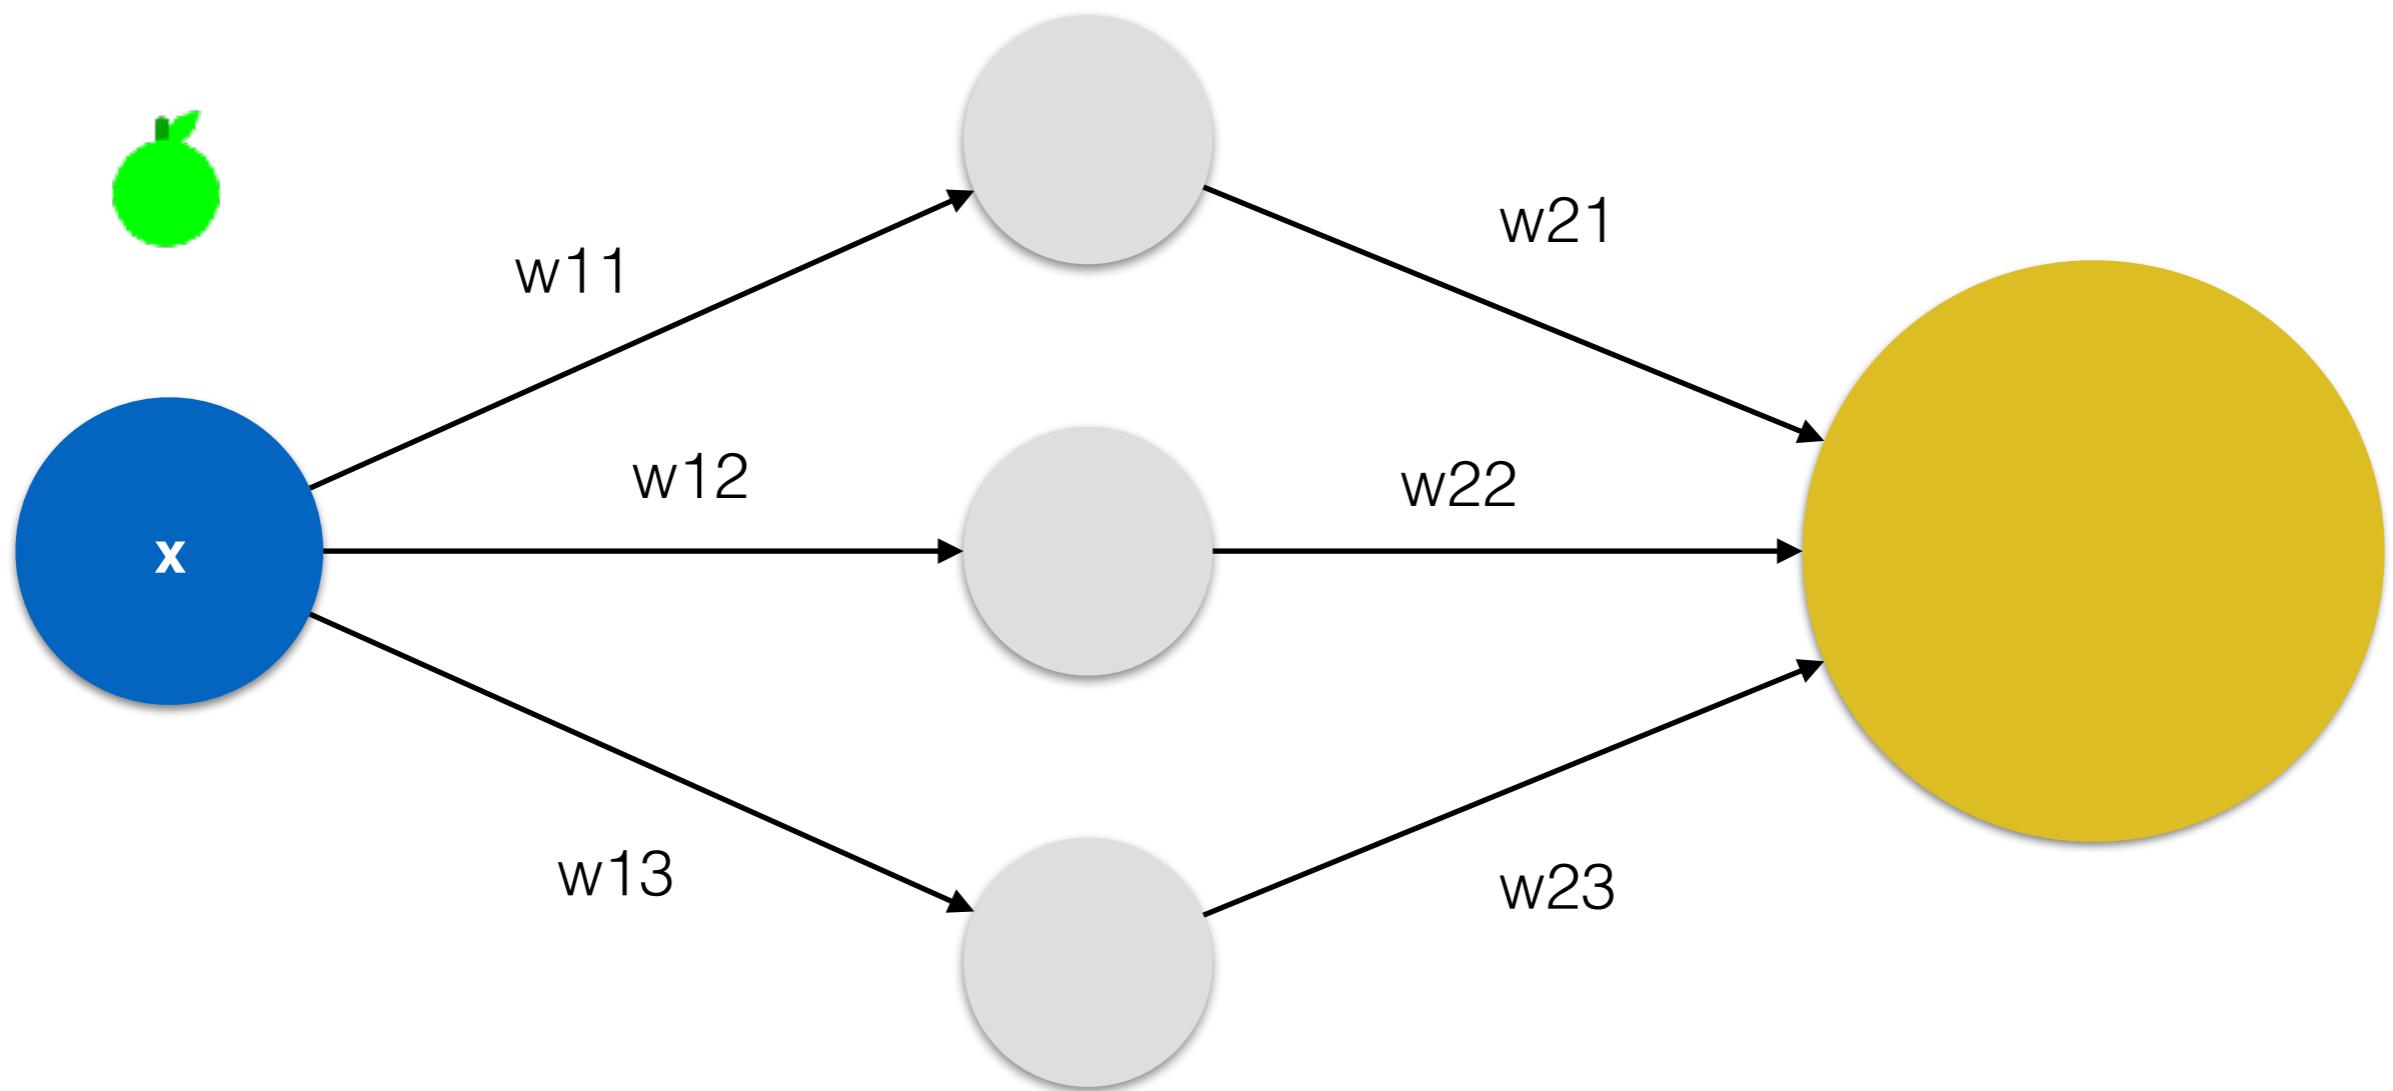
Redes Neurais Artificiais

o classificador de frutas



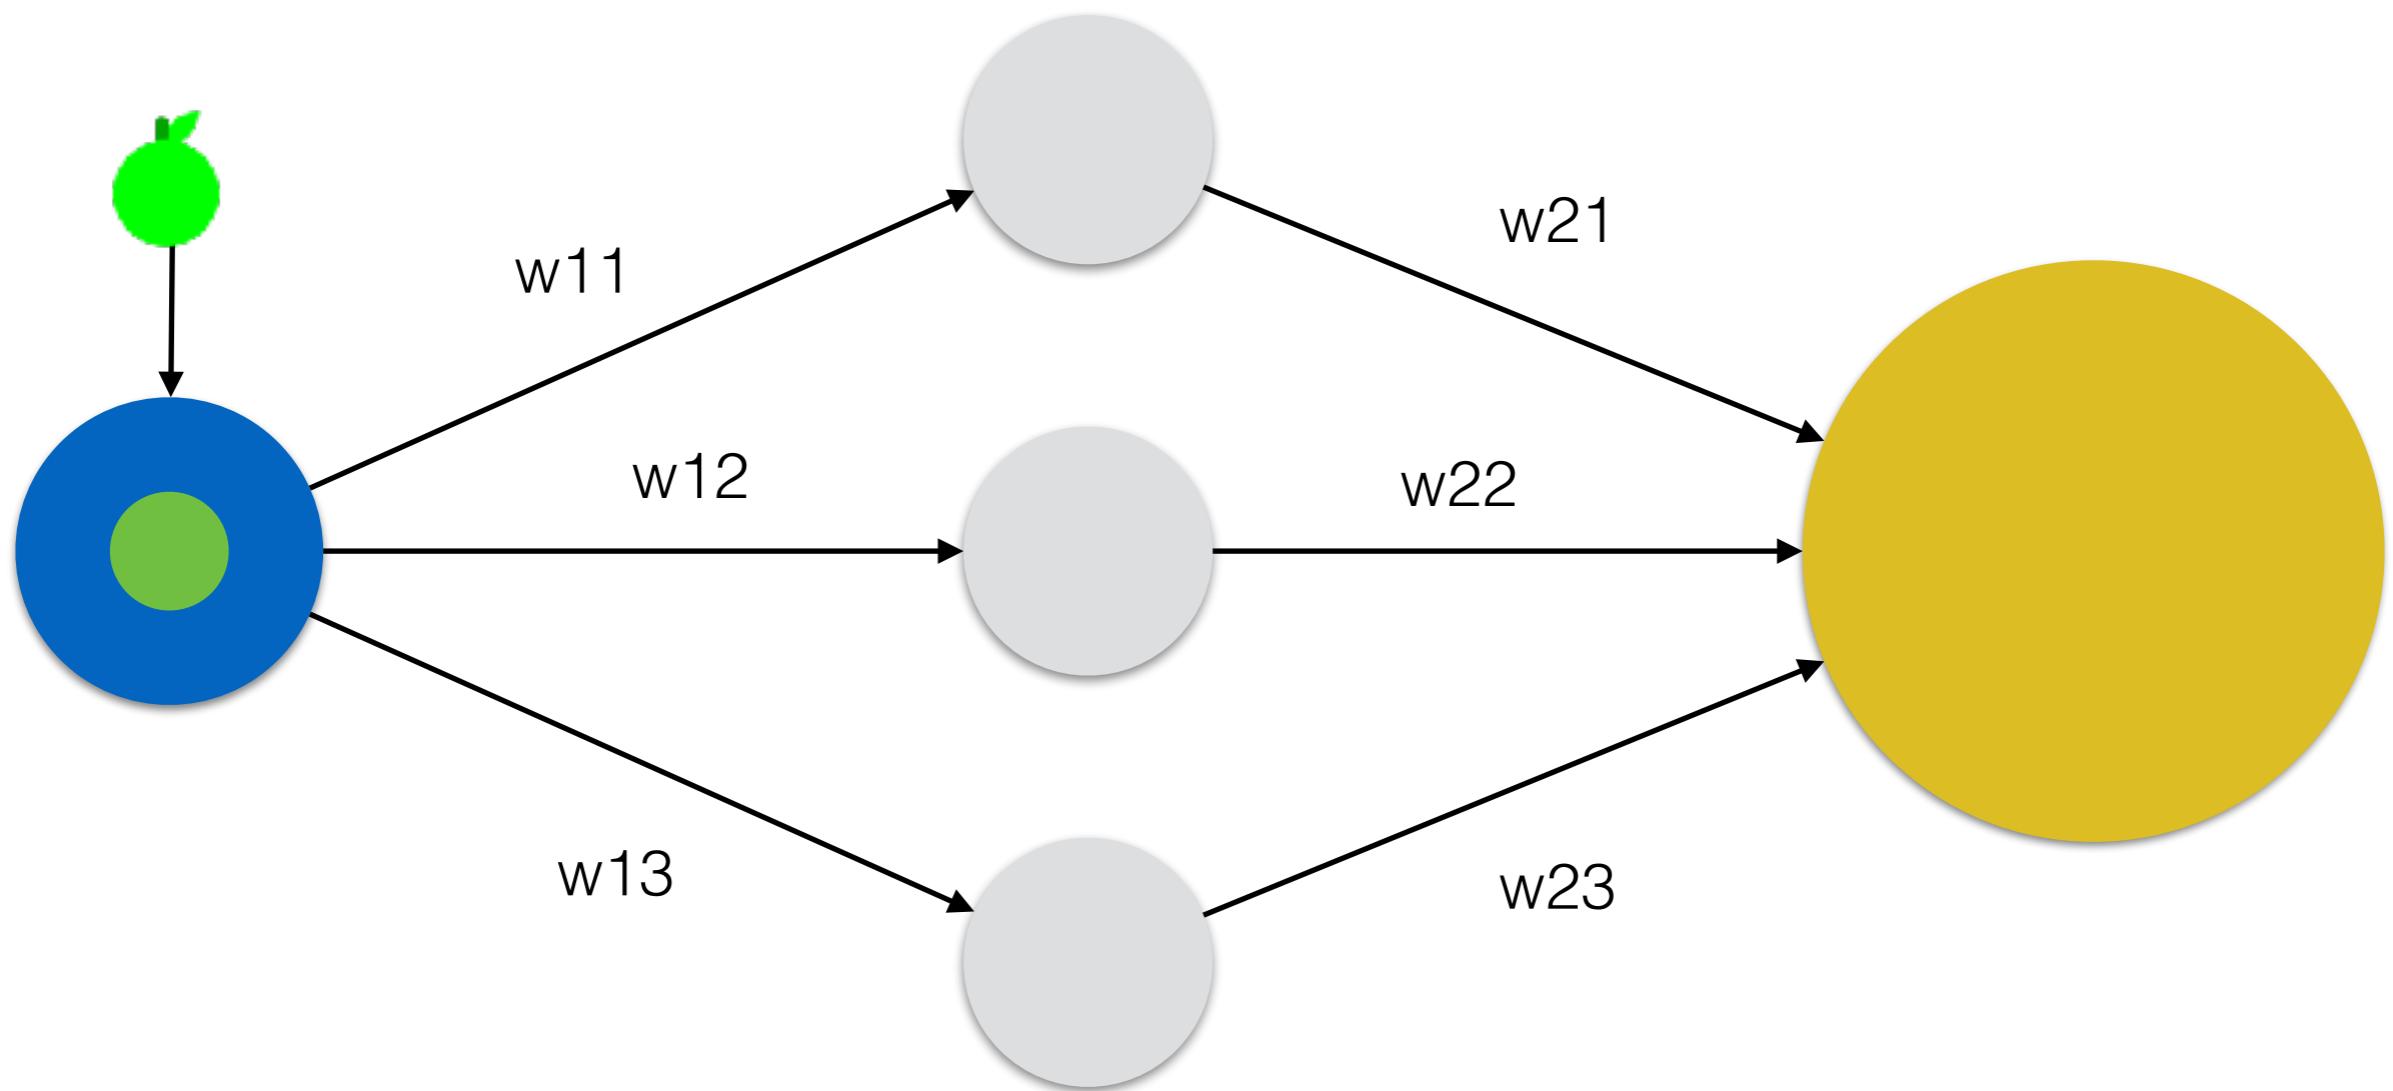
Redes Neurais Artificiais

o classificador de frutas



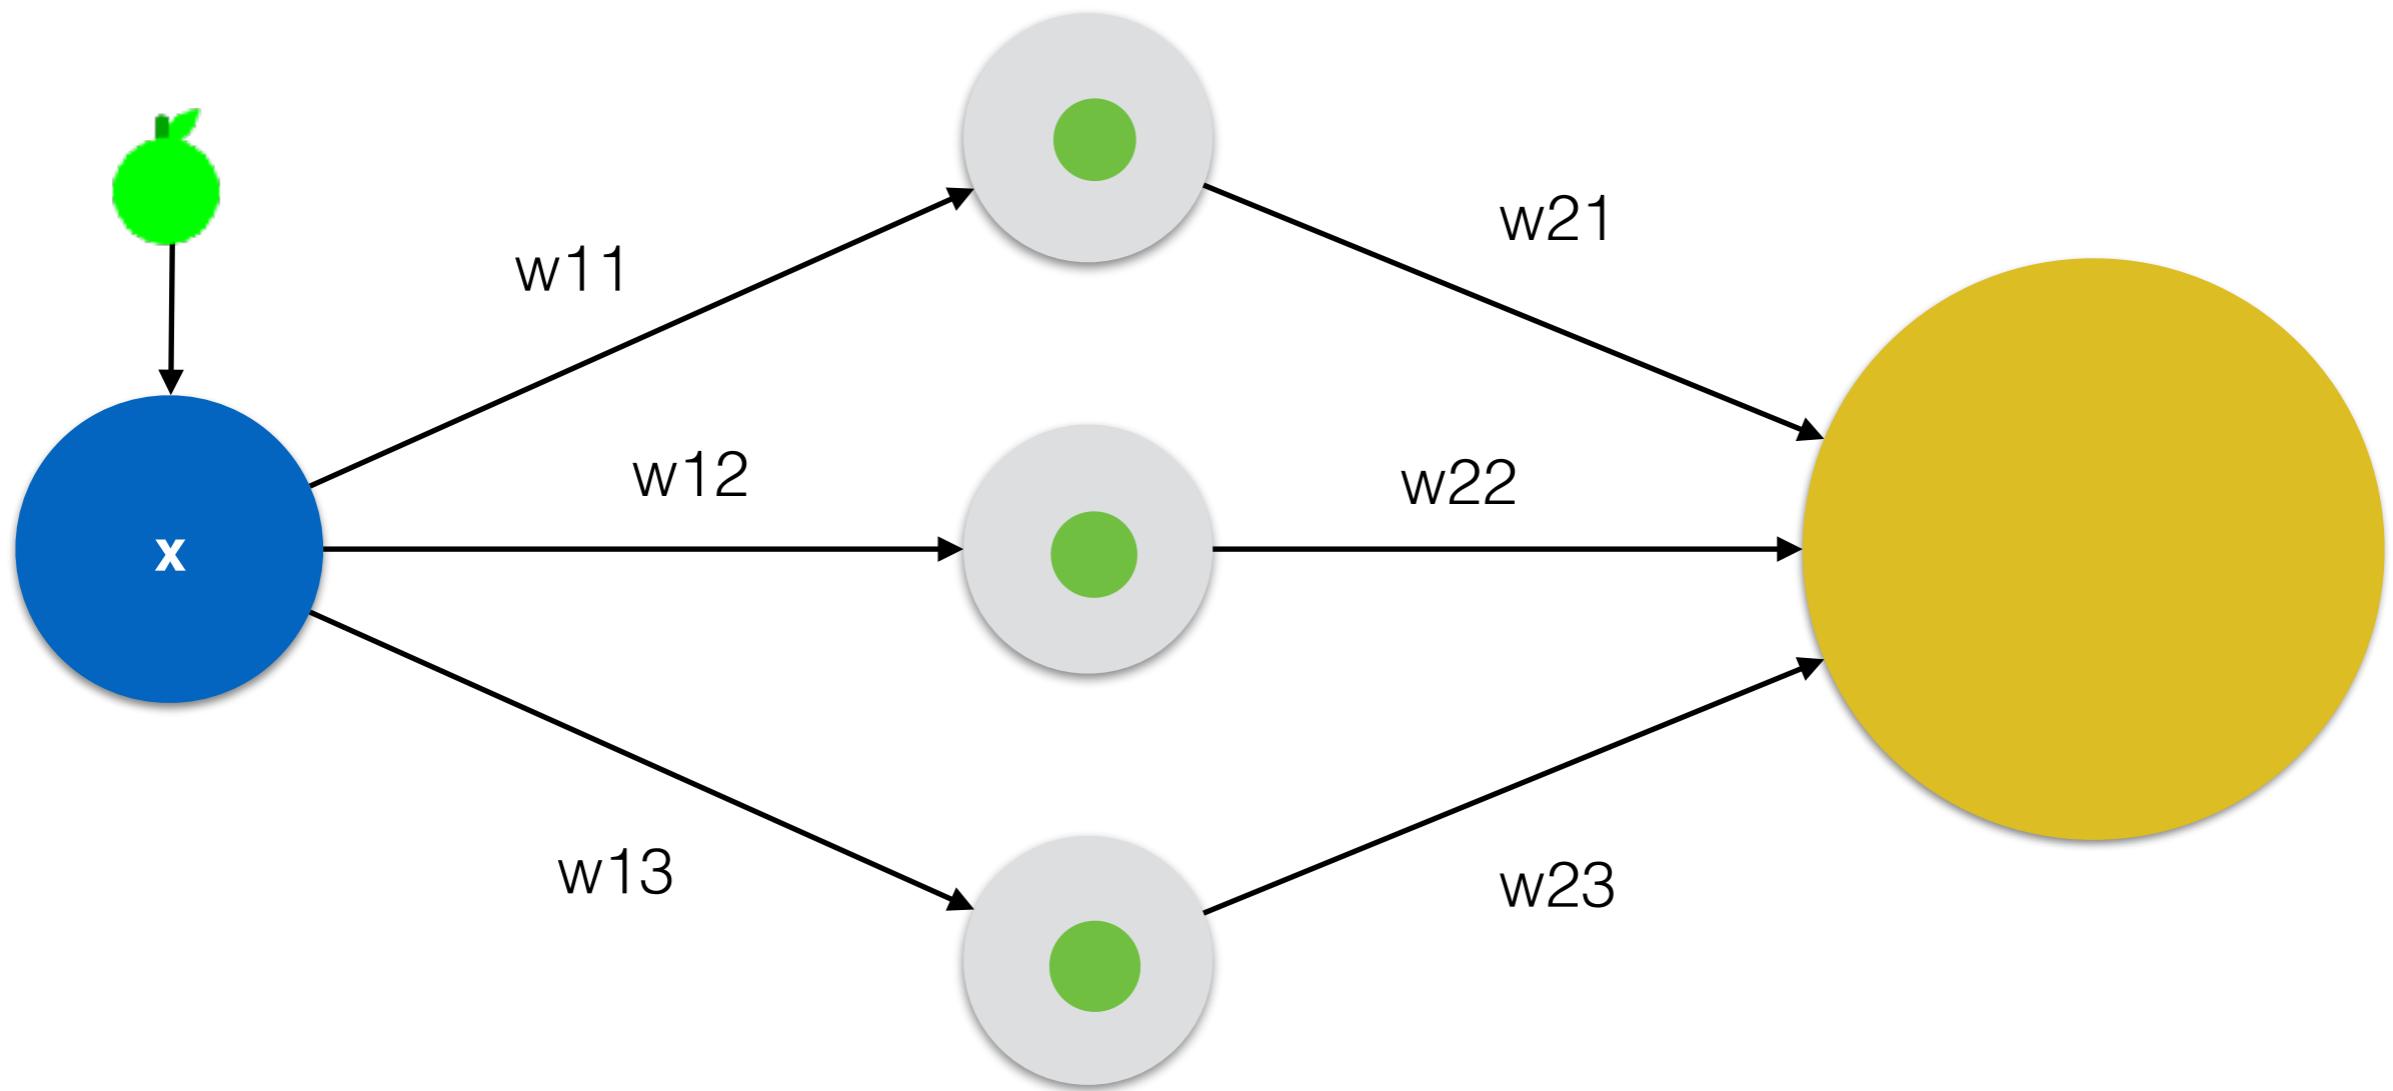
Redes Neurais Artificiais

o classificador de frutas



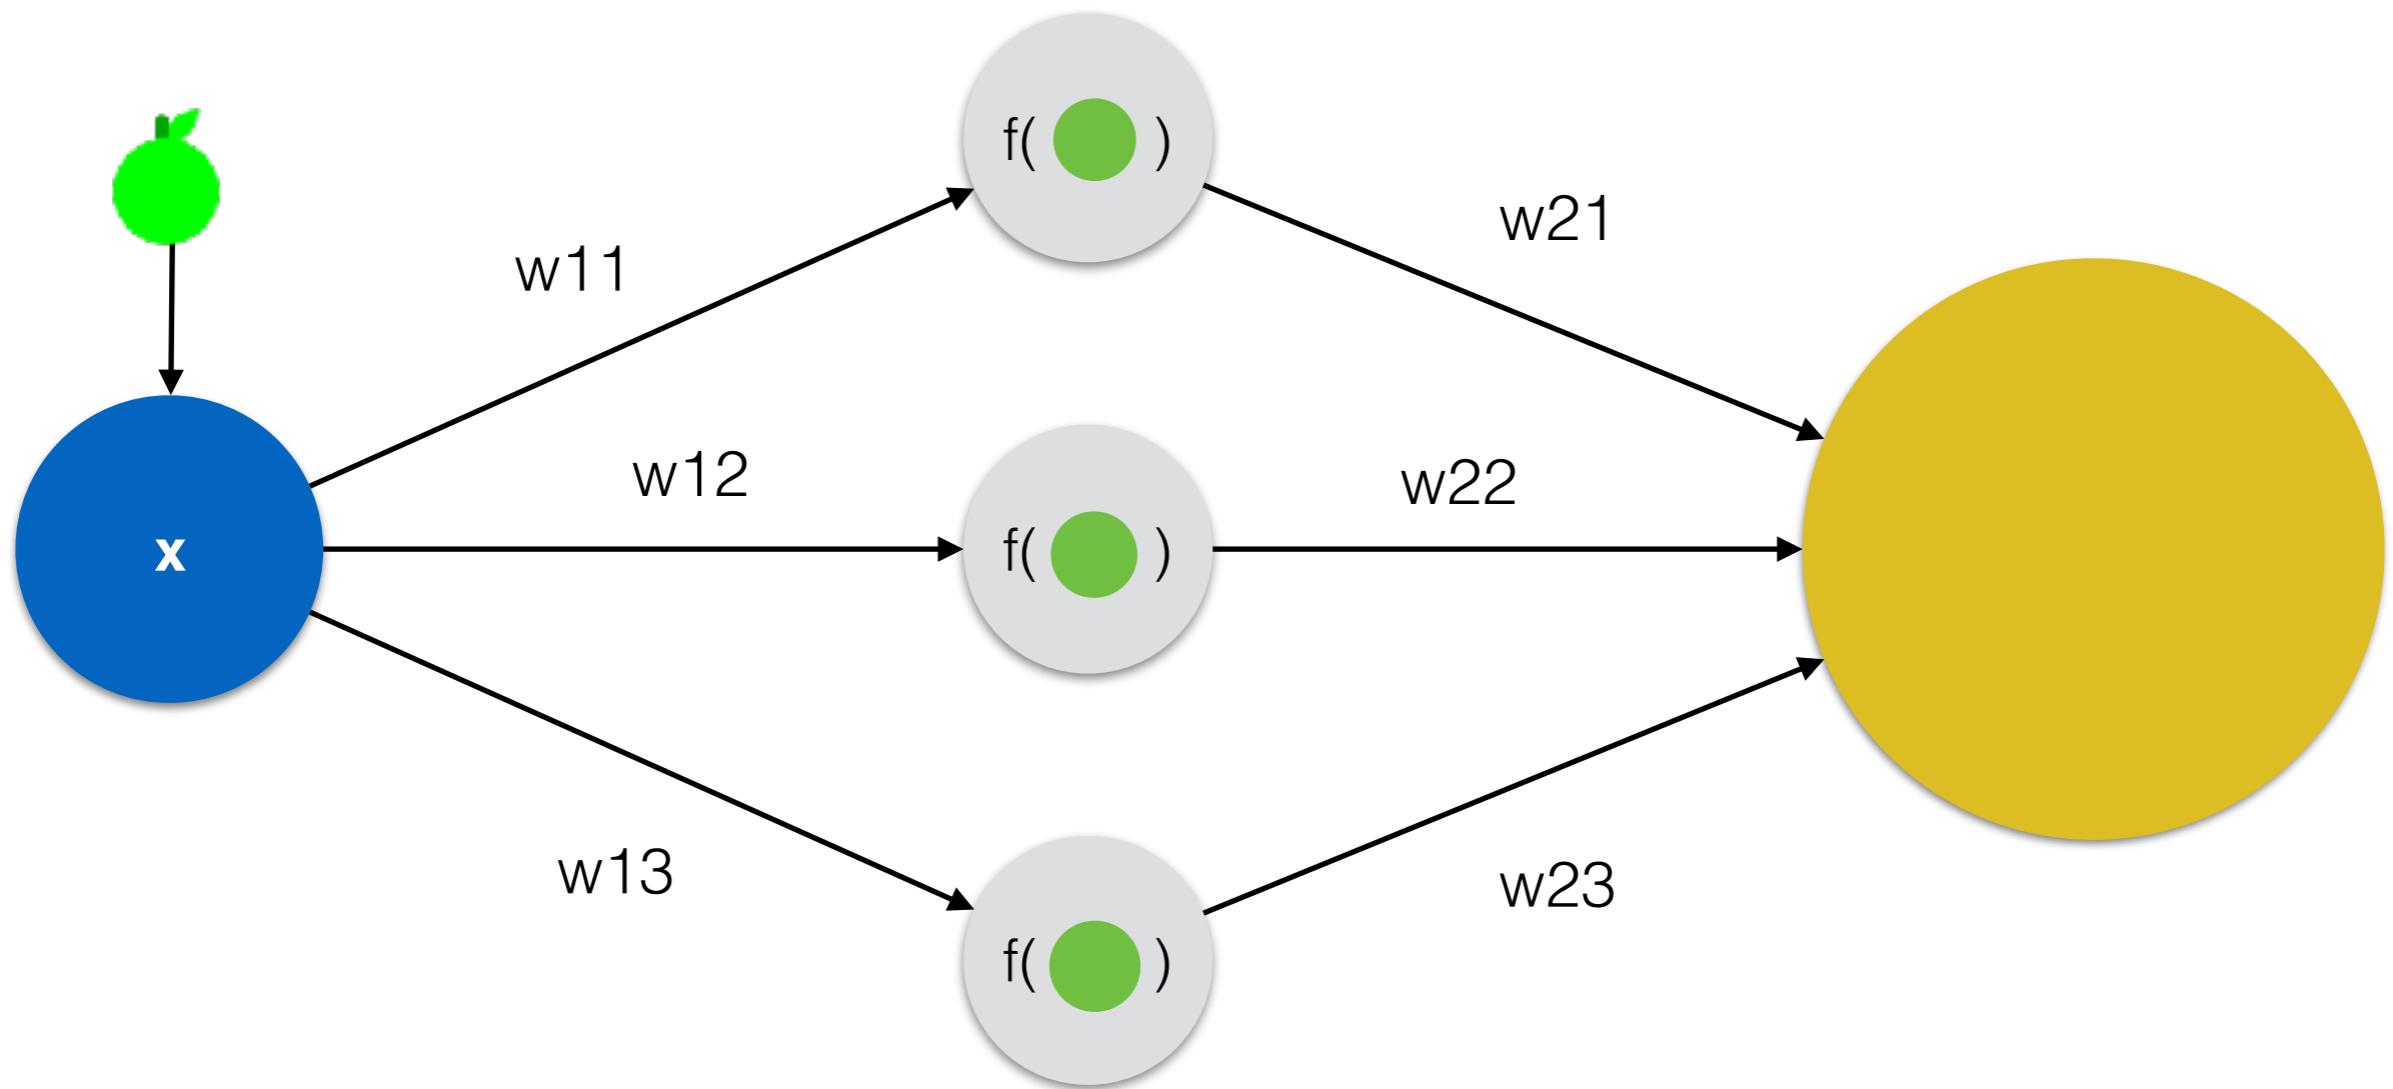
Redes Neurais Artificiais

o classificador de frutas



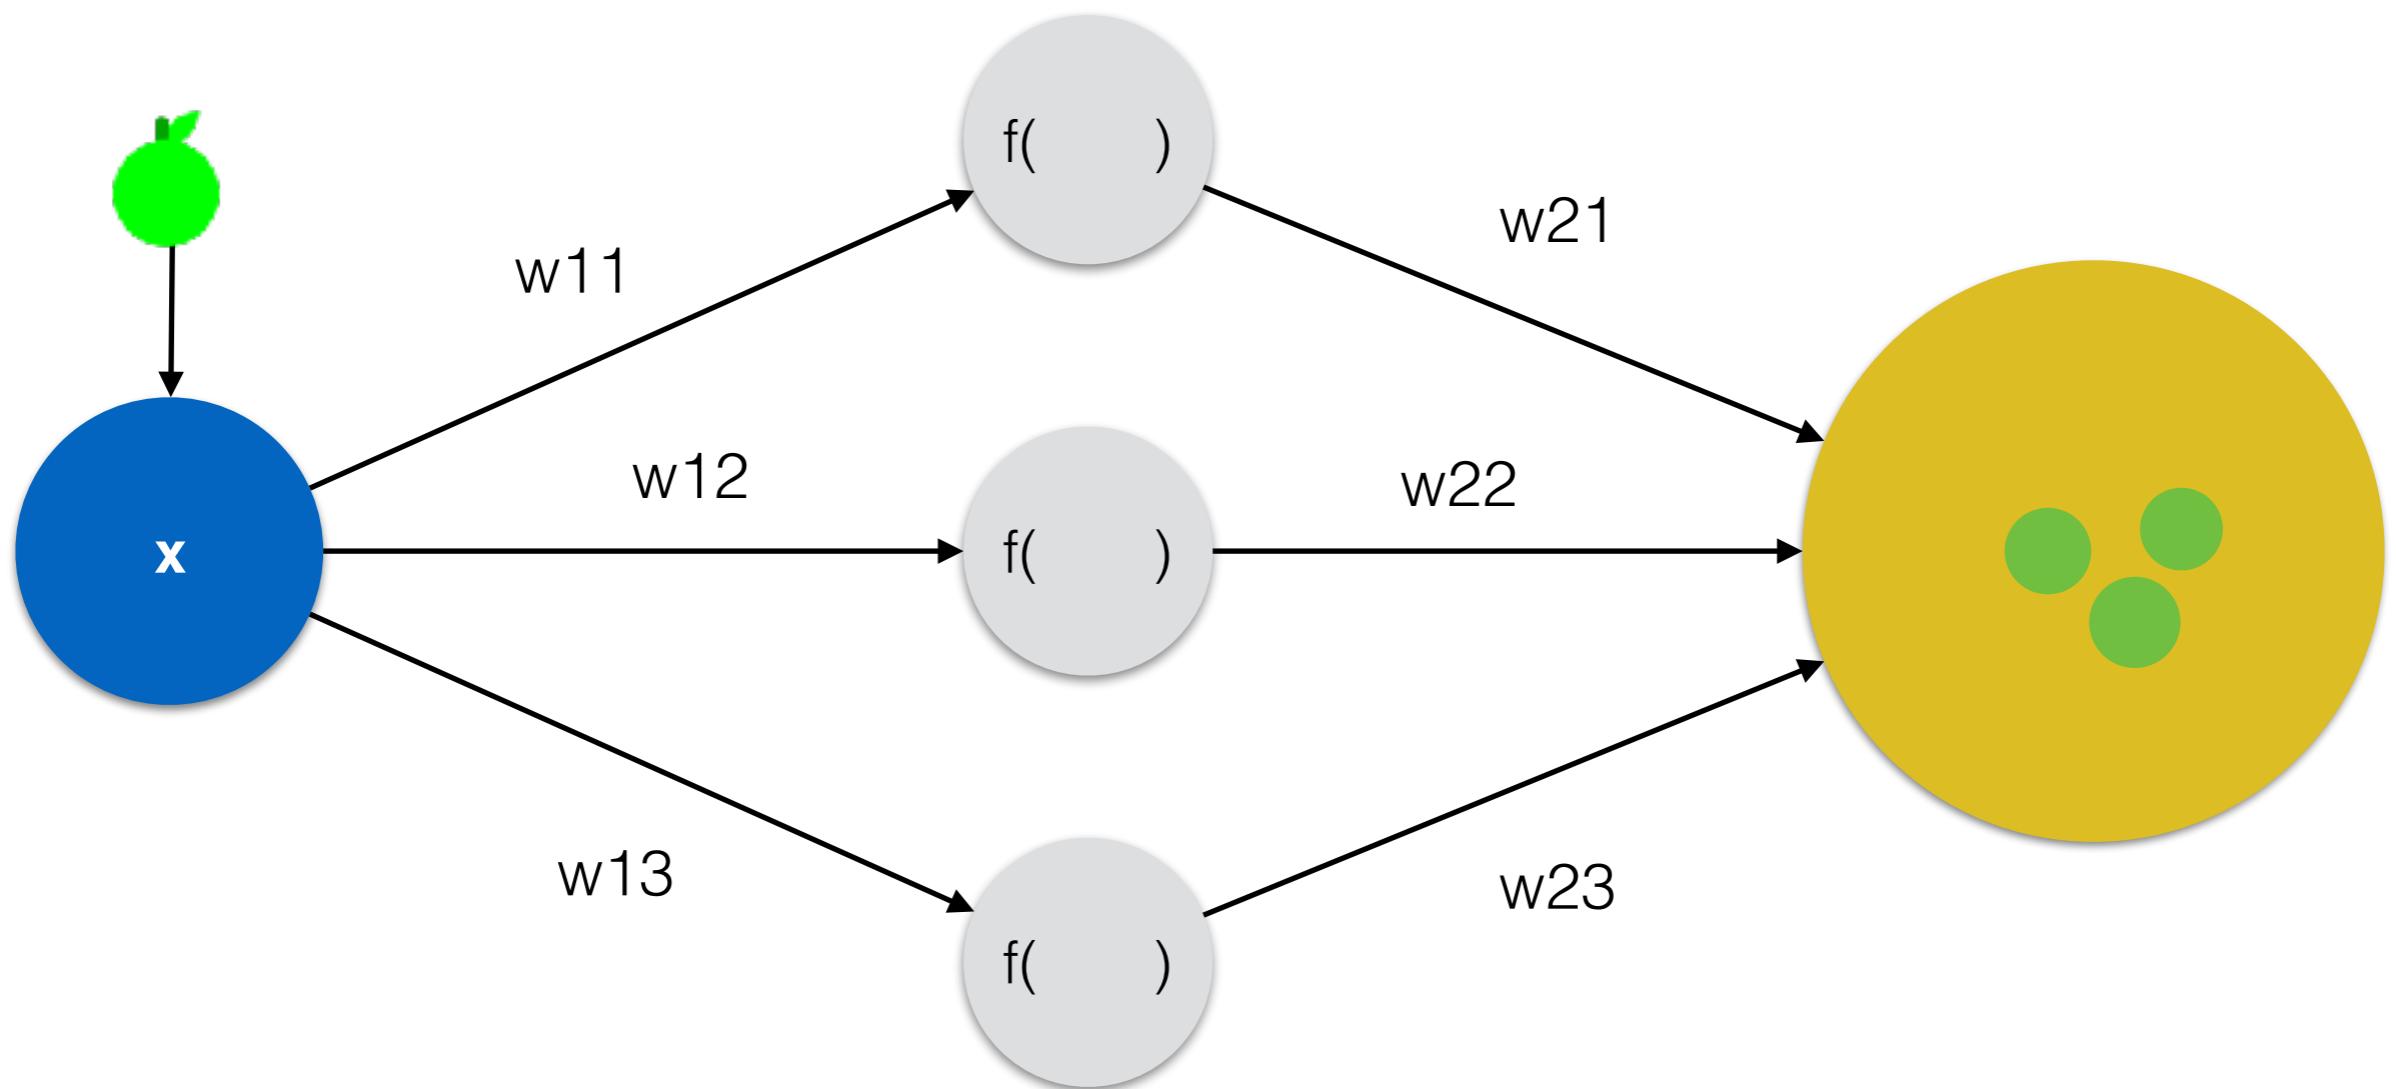
Redes Neurais Artificiais

o classificador de frutas



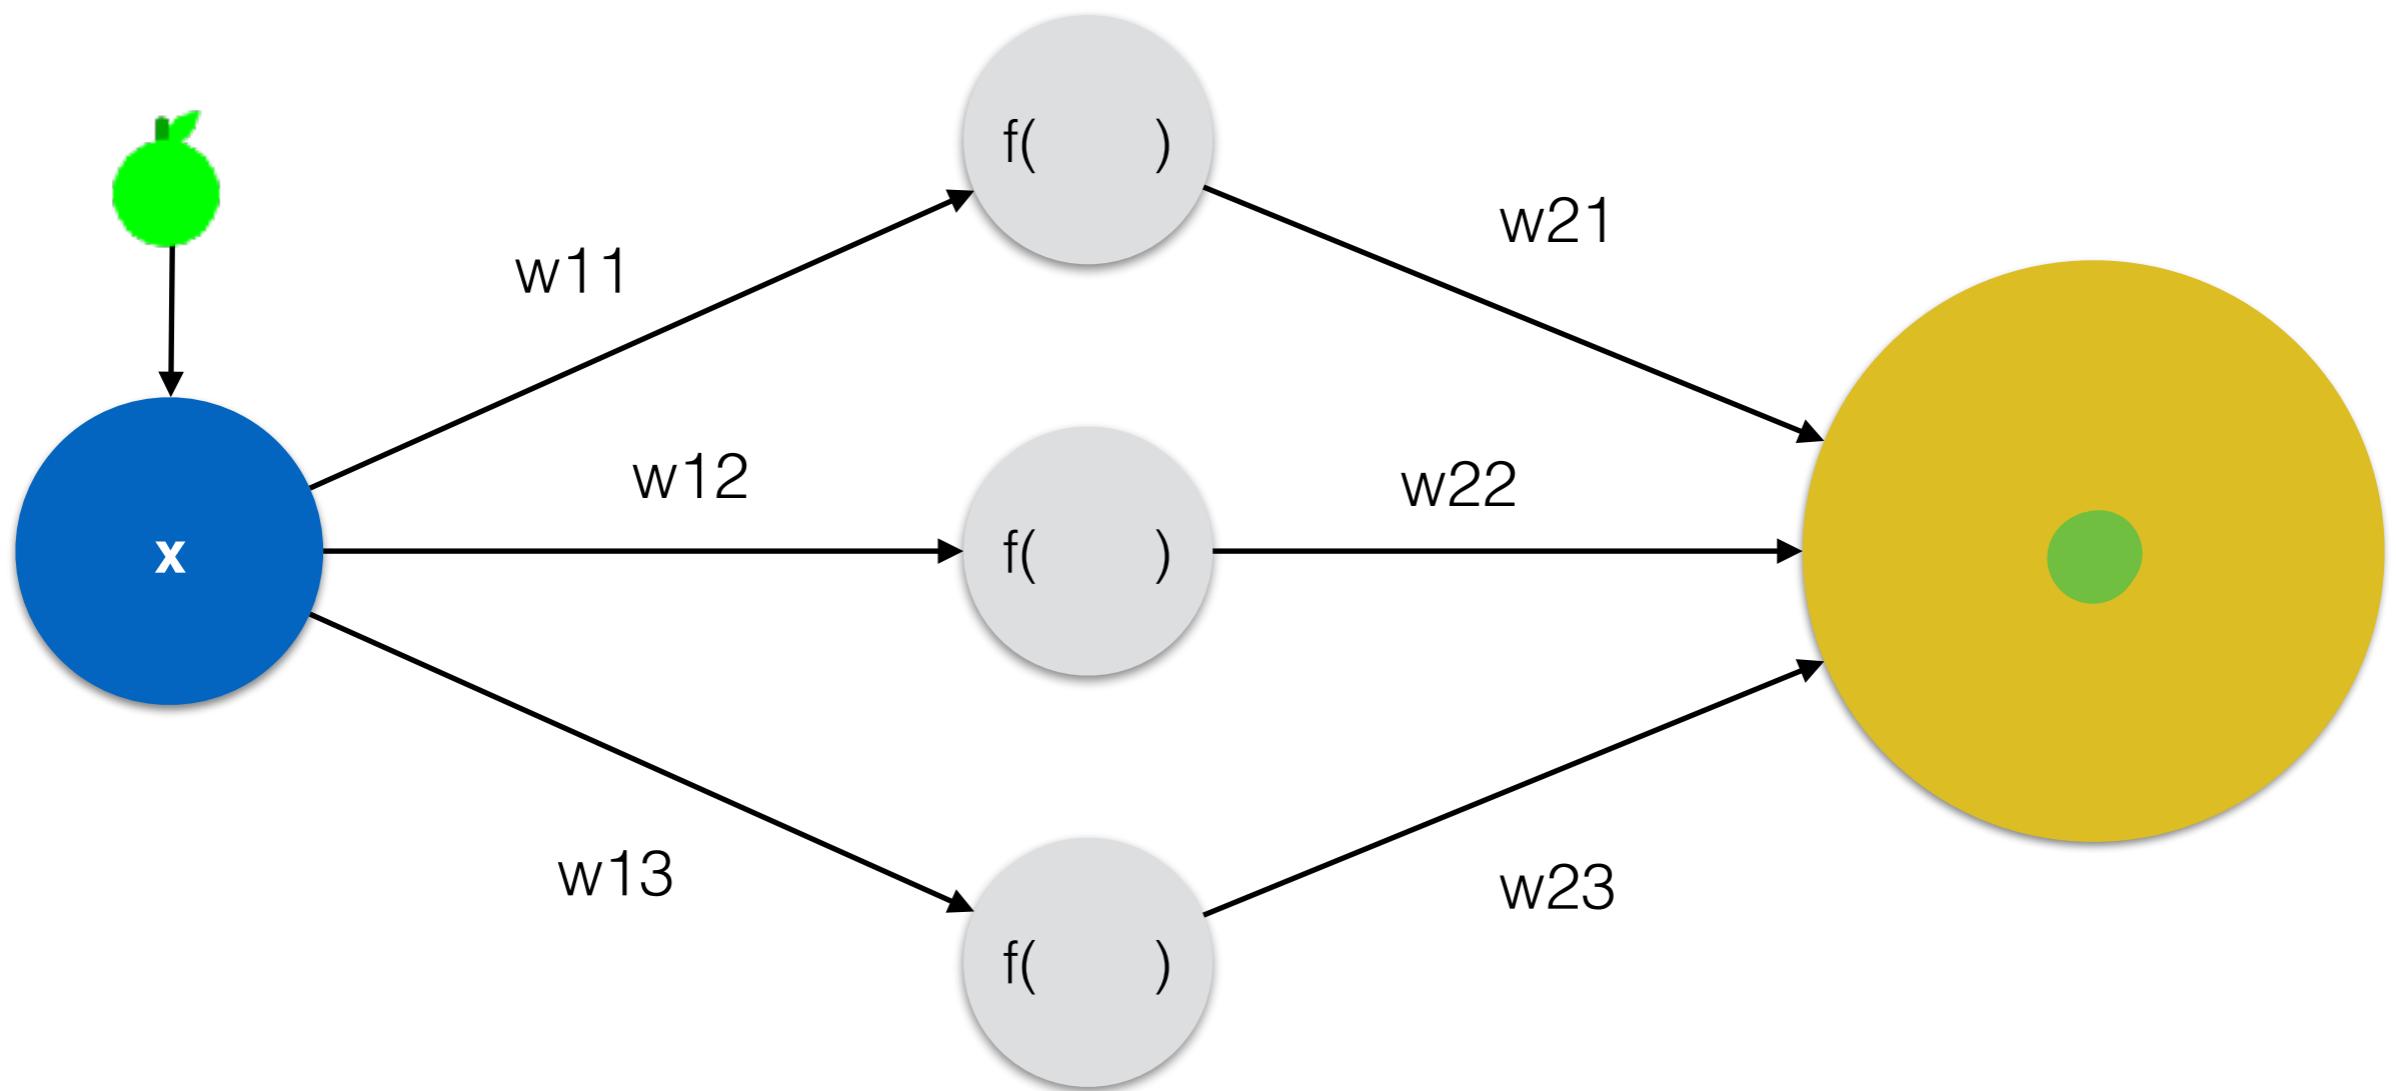
Redes Neurais Artificiais

o classificador de frutas



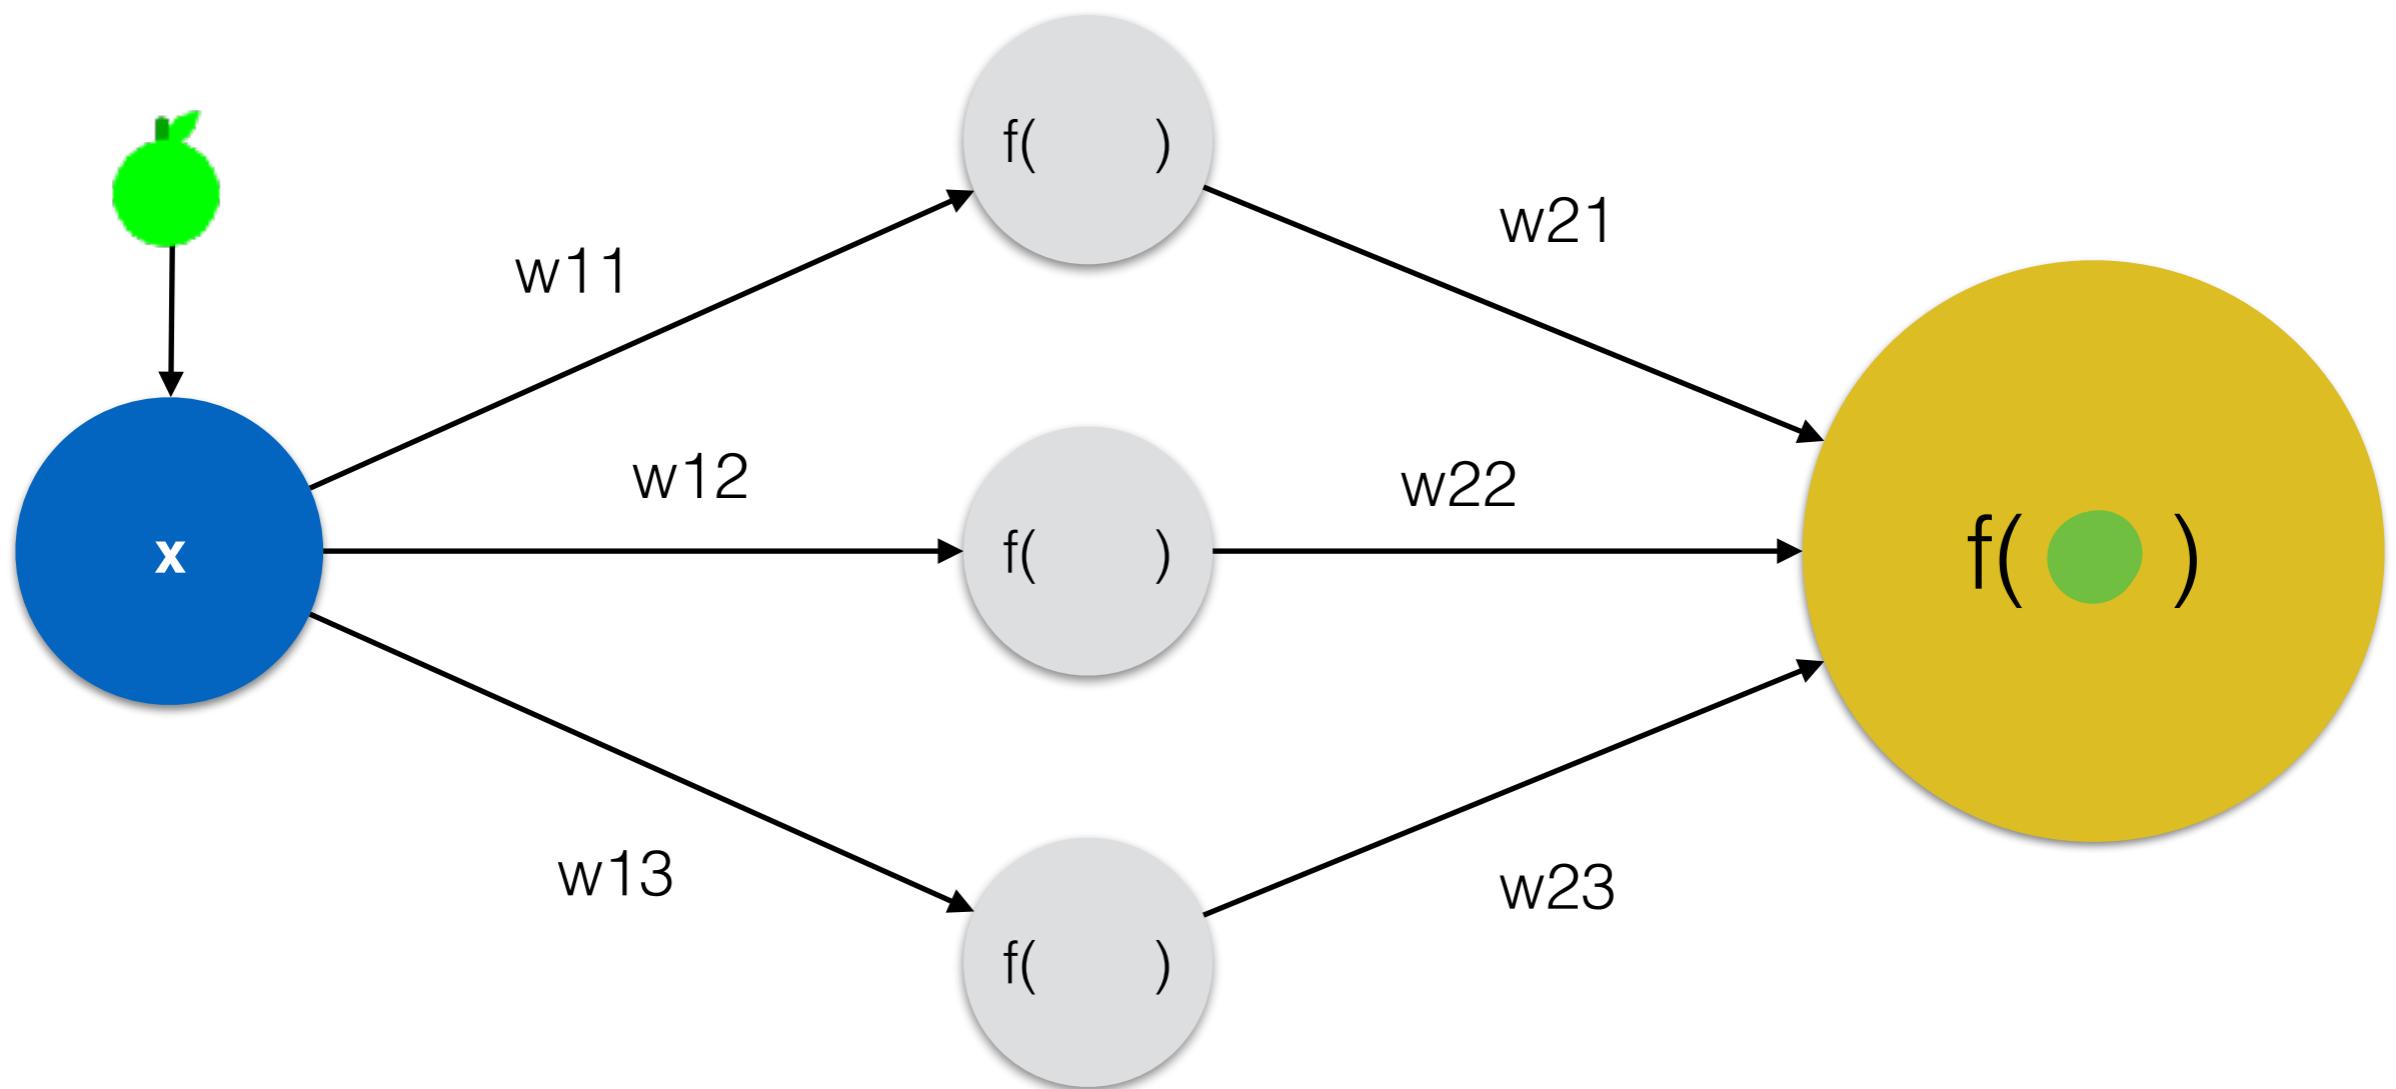
Redes Neurais Artificiais

o classificador de frutas



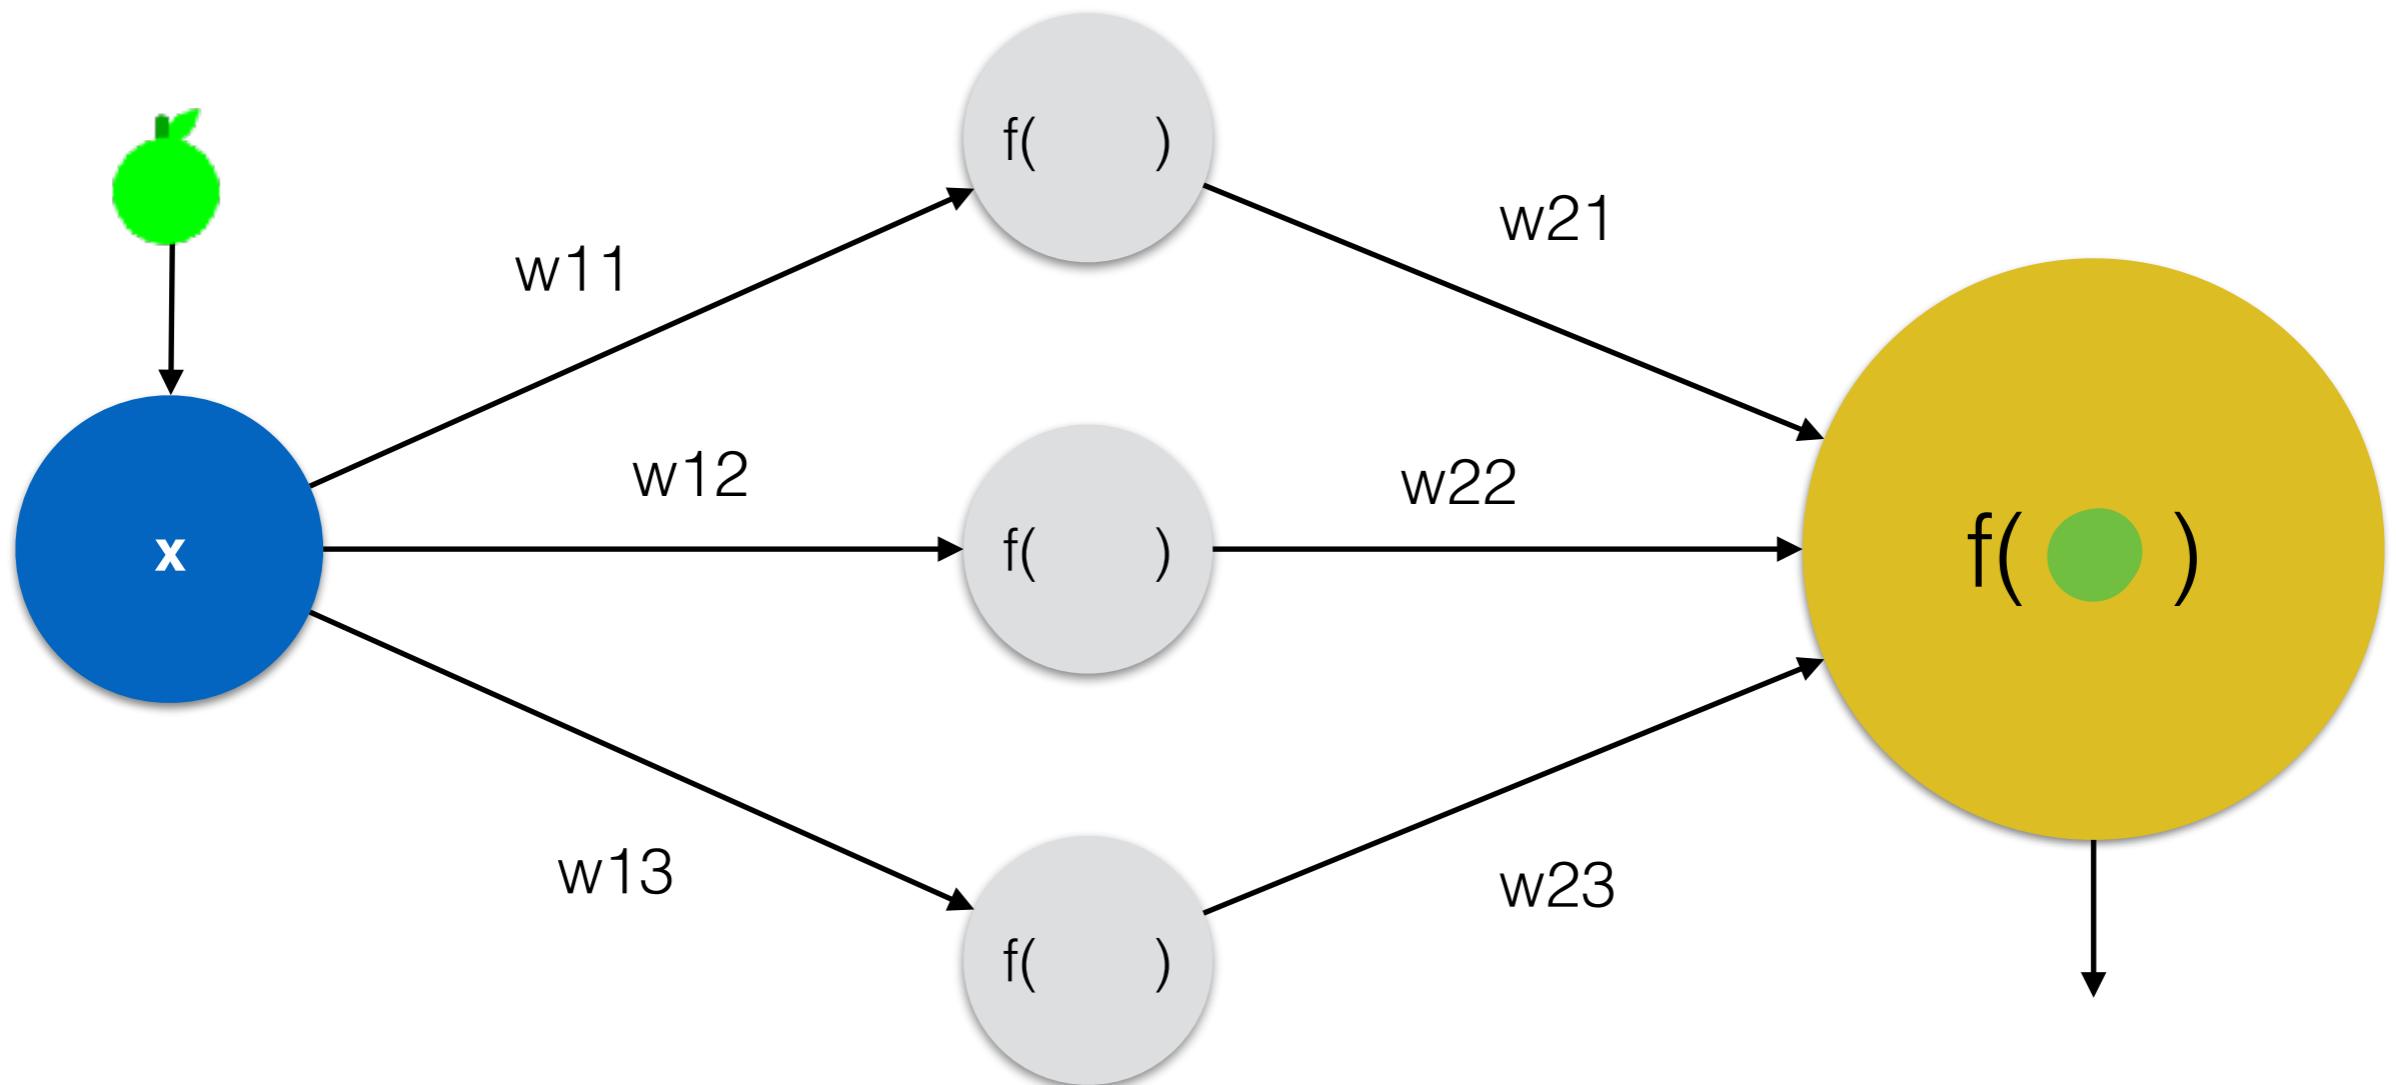
Redes Neurais Artificiais

o classificador de frutas



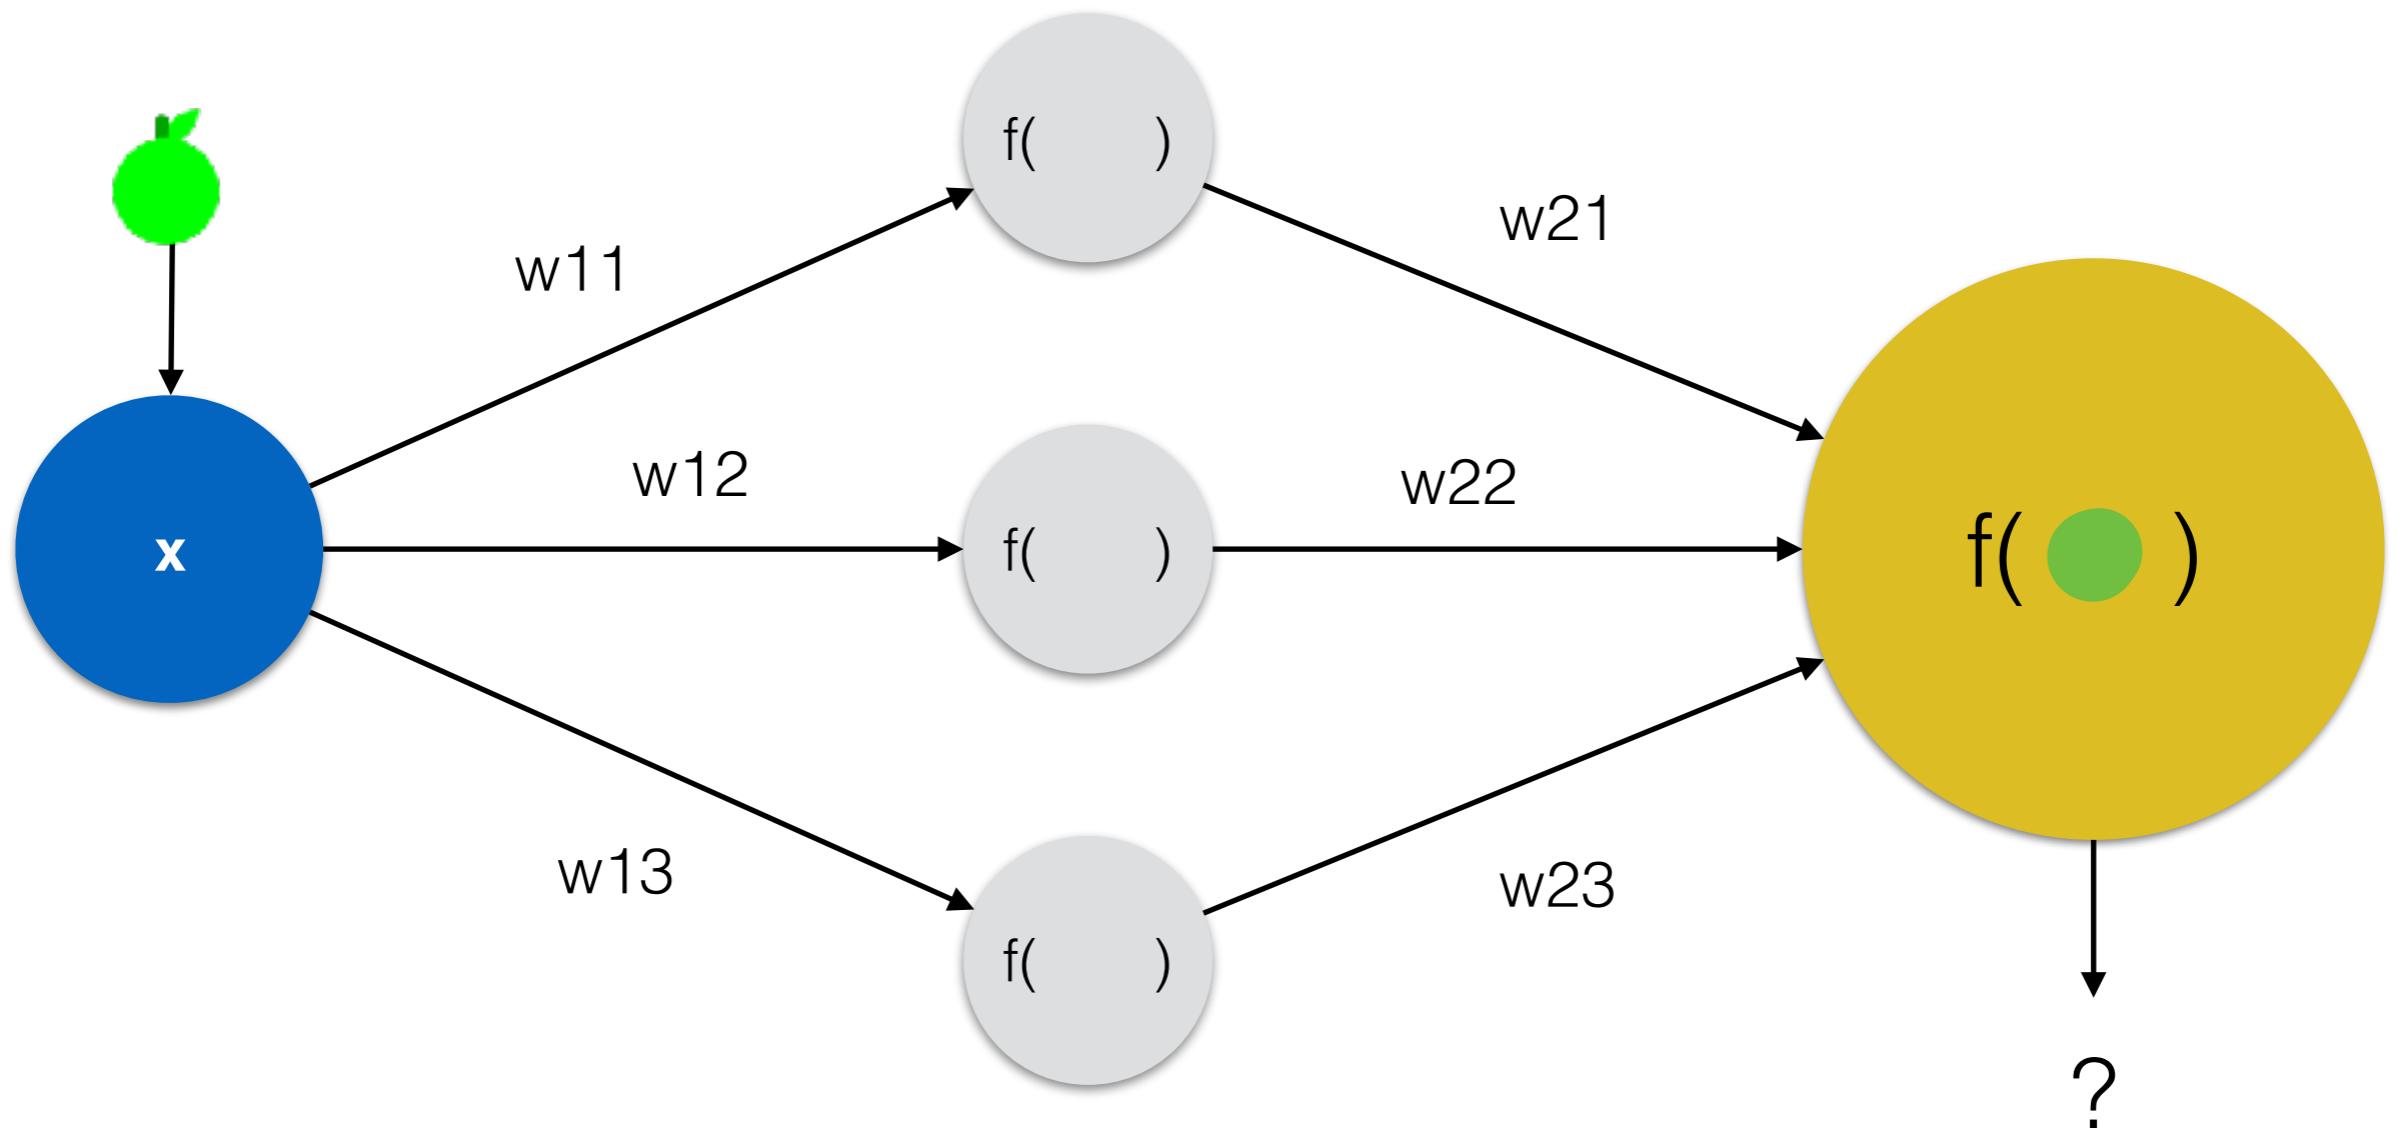
Redes Neurais Artificiais

o classificador de frutas



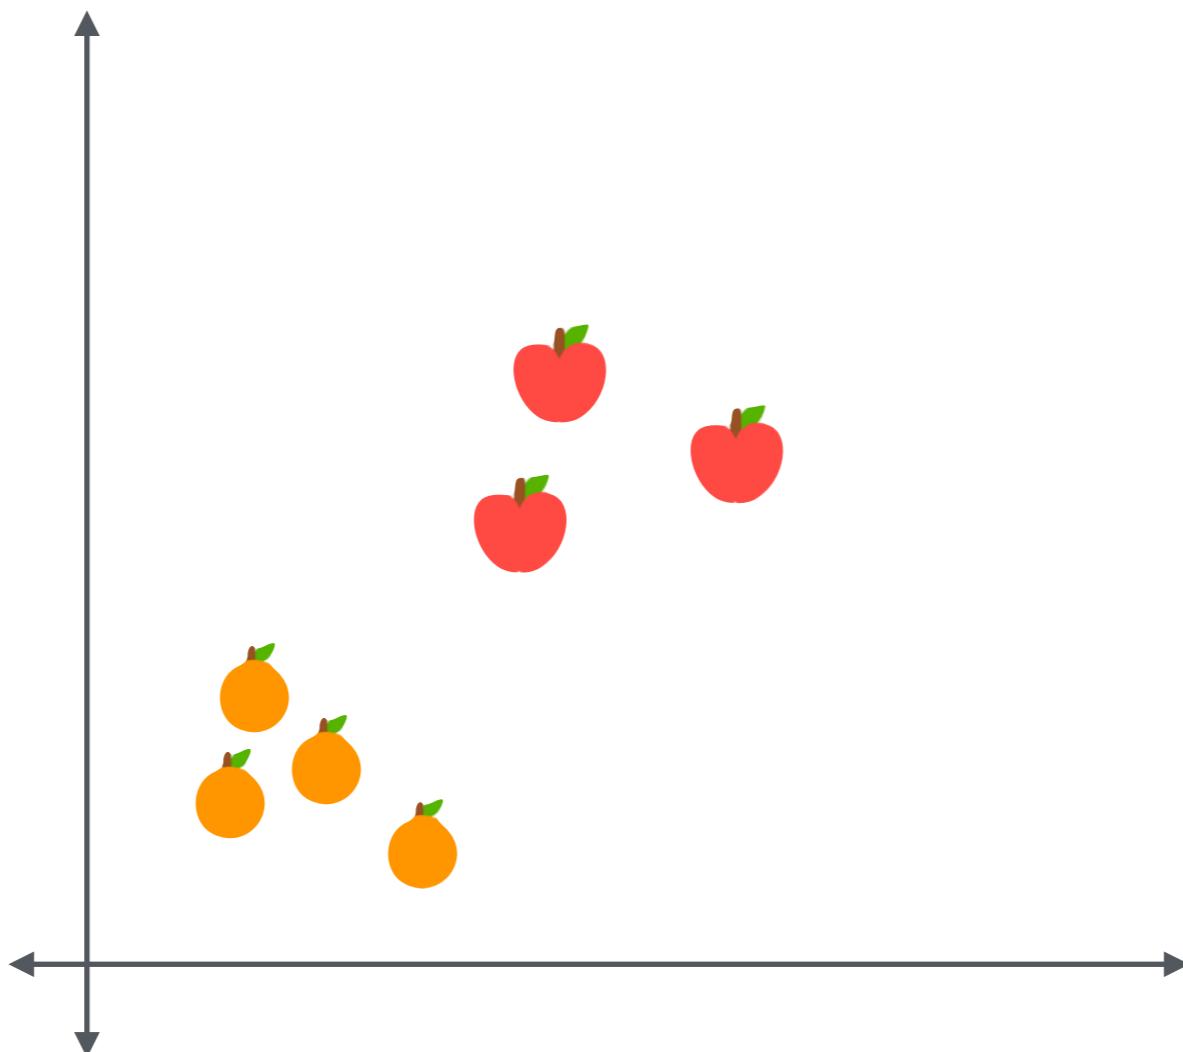
Redes Neurais Artificiais

o classificador de frutas



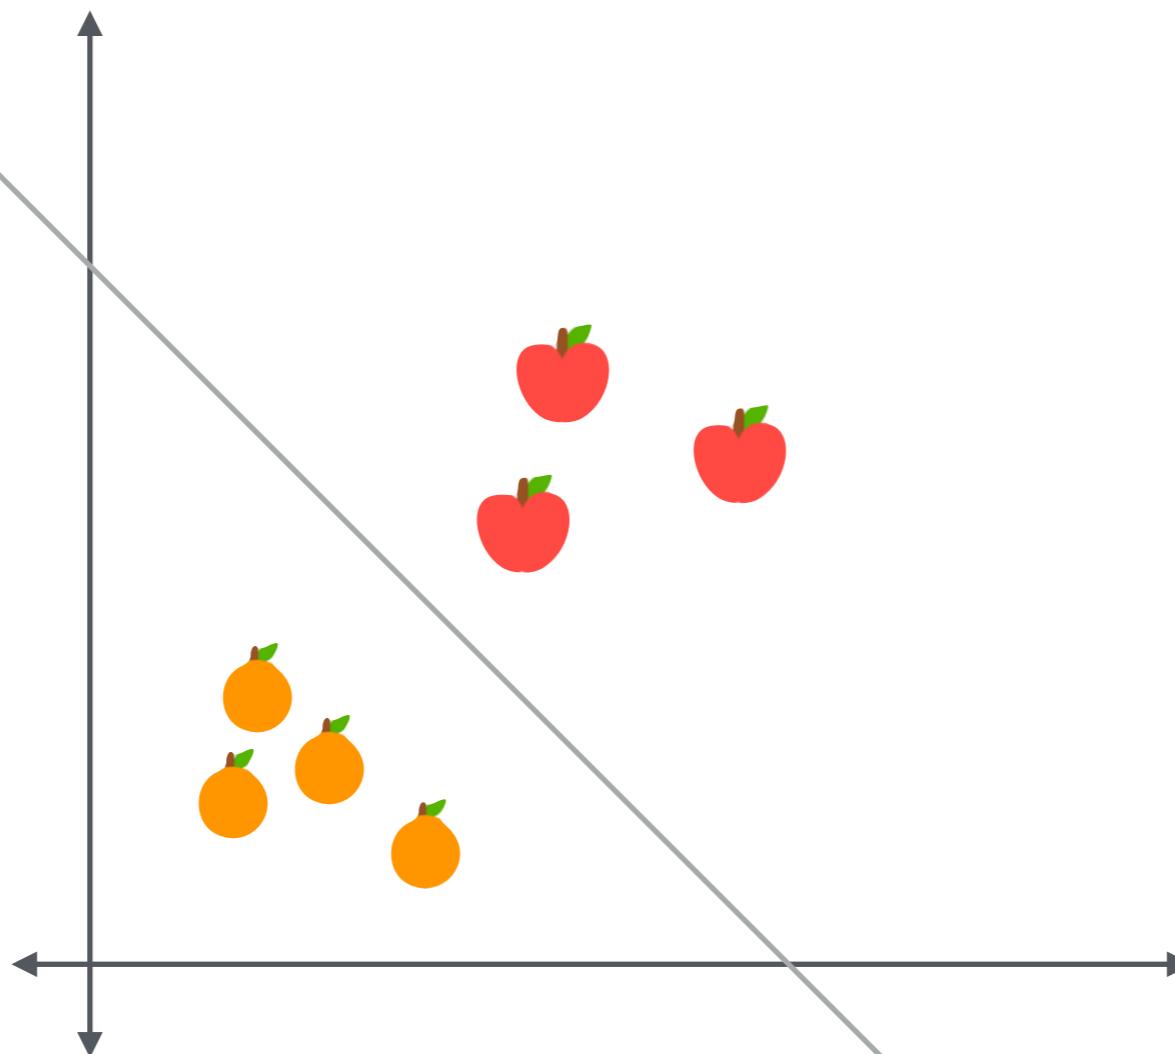
Redes Neurais Artificiais

multi-camadas



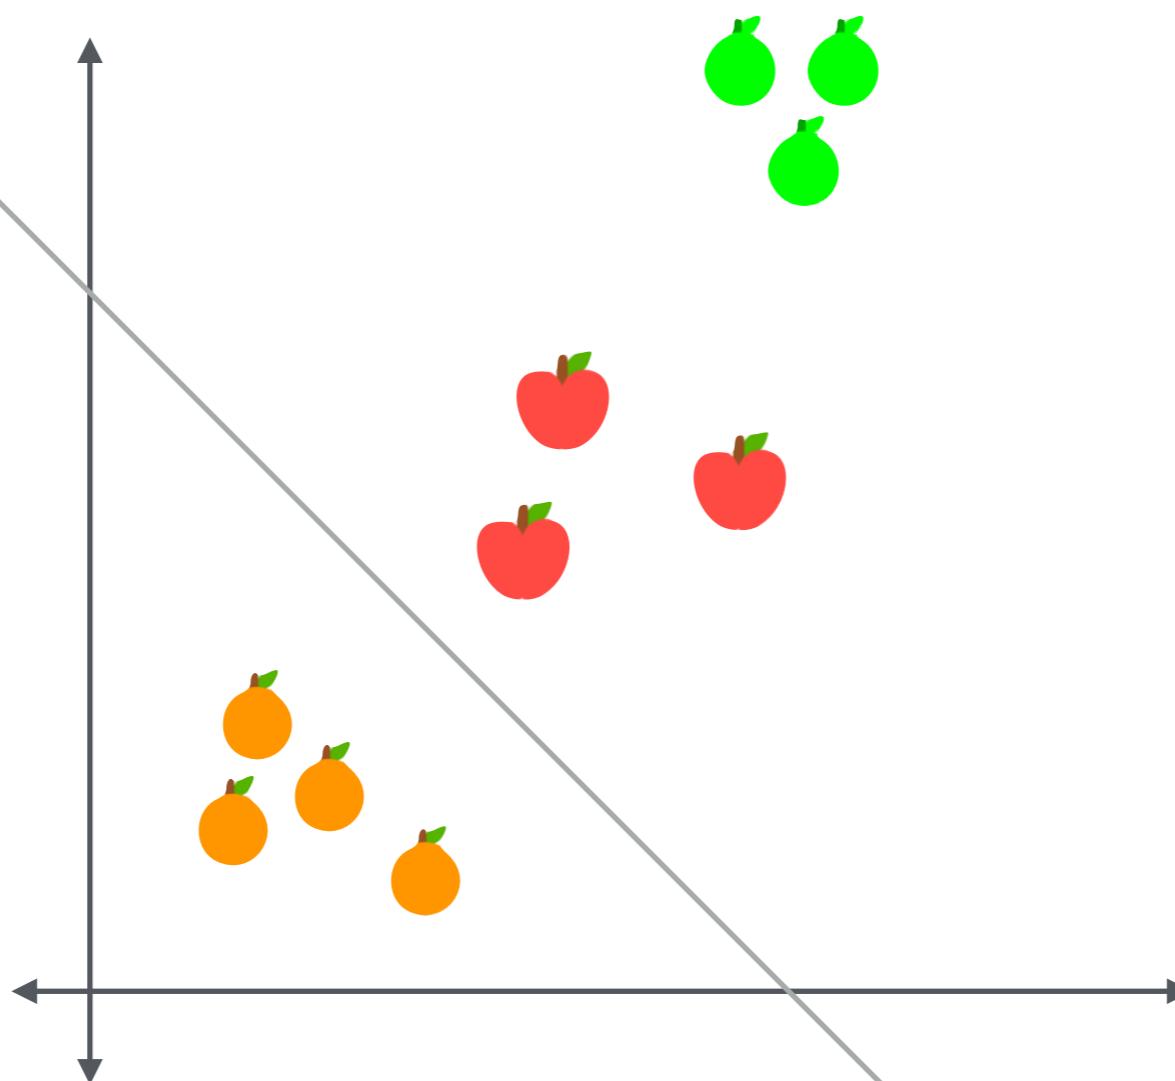
Redes Neurais Artificiais

multi-camadas



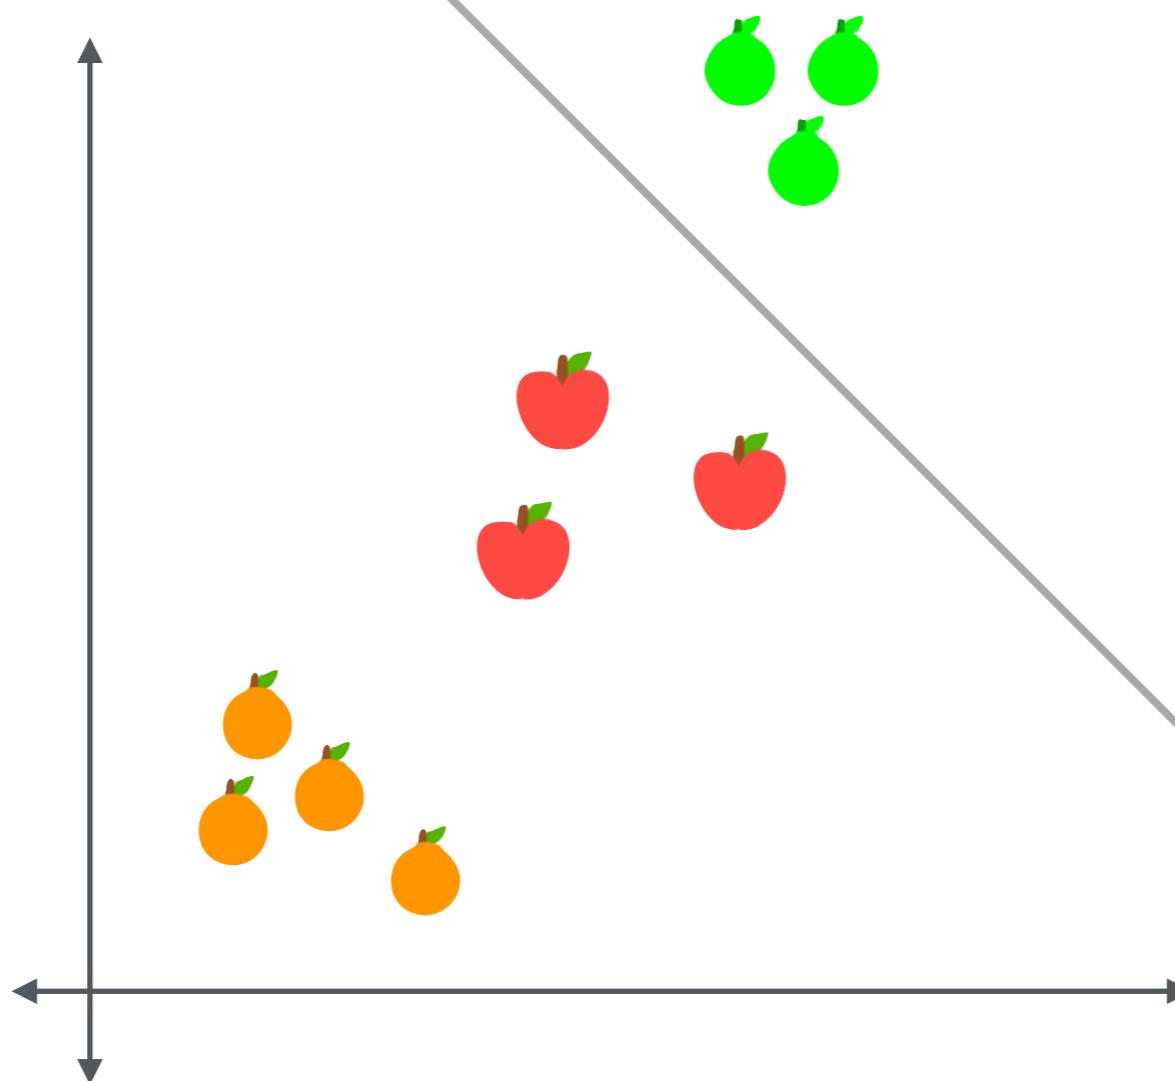
Redes Neurais Artificiais

multi-camadas



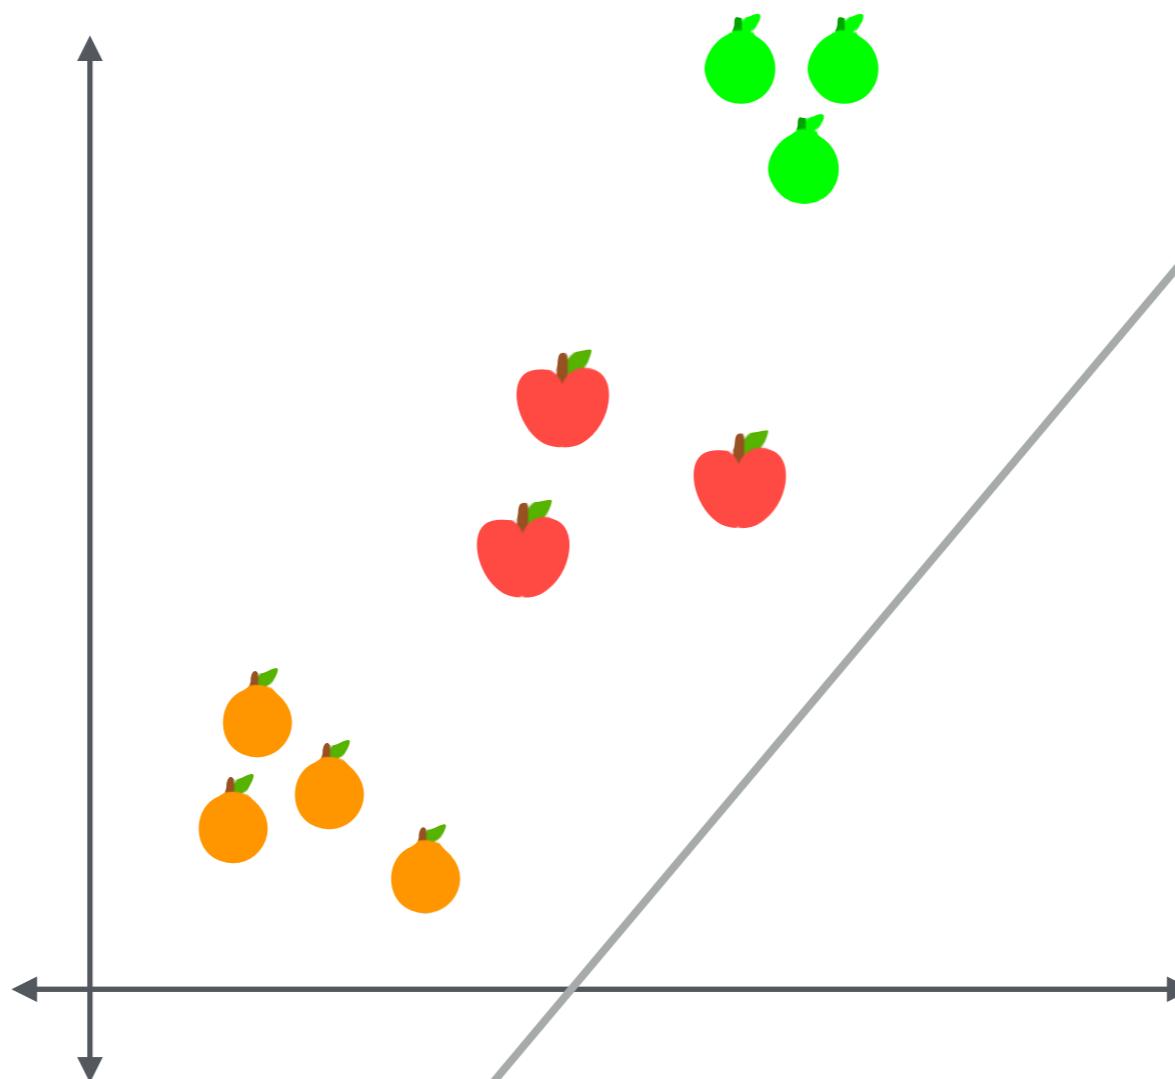
Redes Neurais Artificiais

multi-camadas



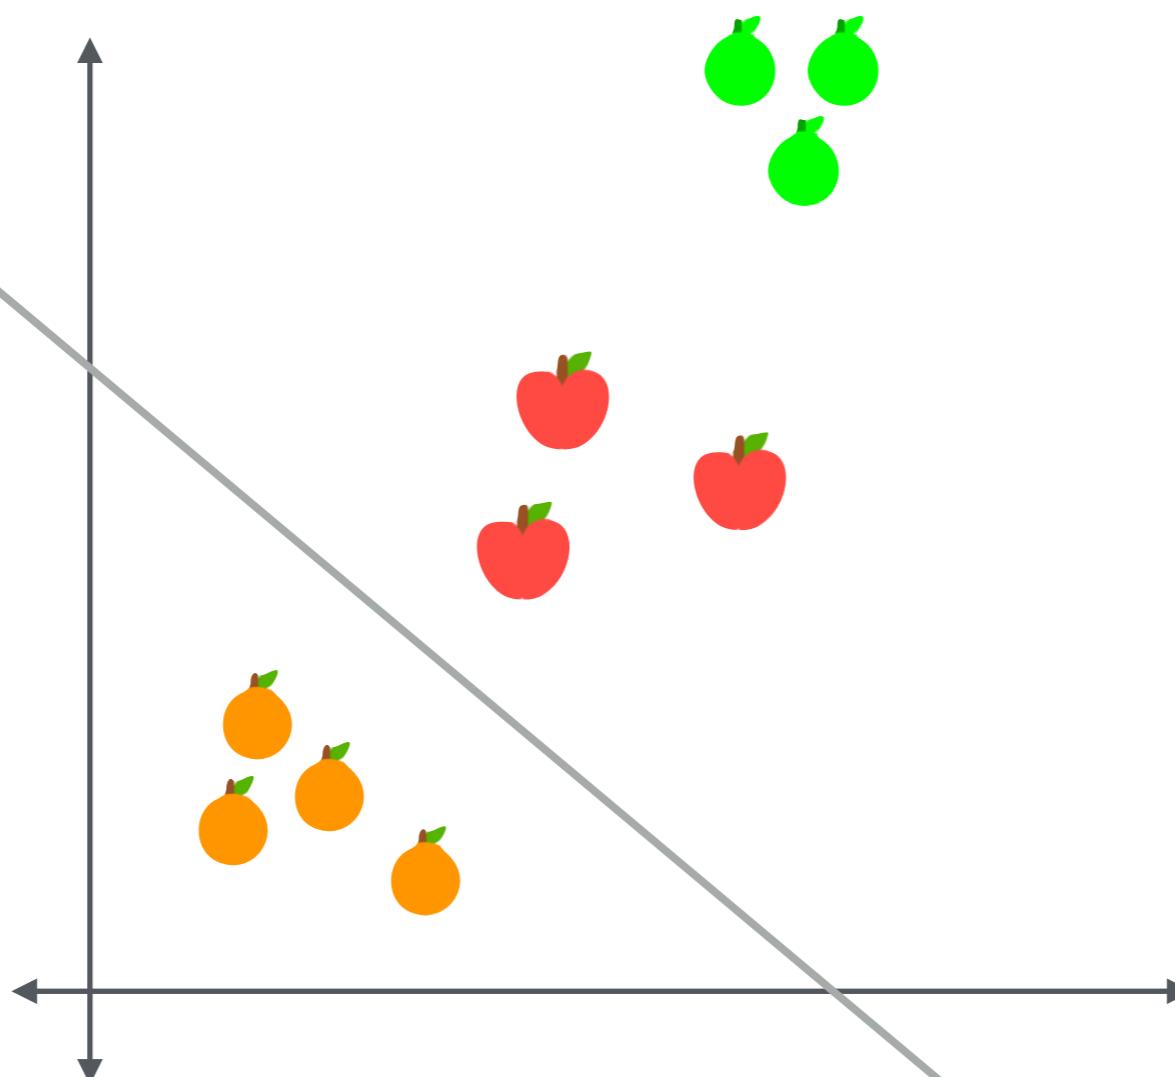
Redes Neurais Artificiais

multi-camadas



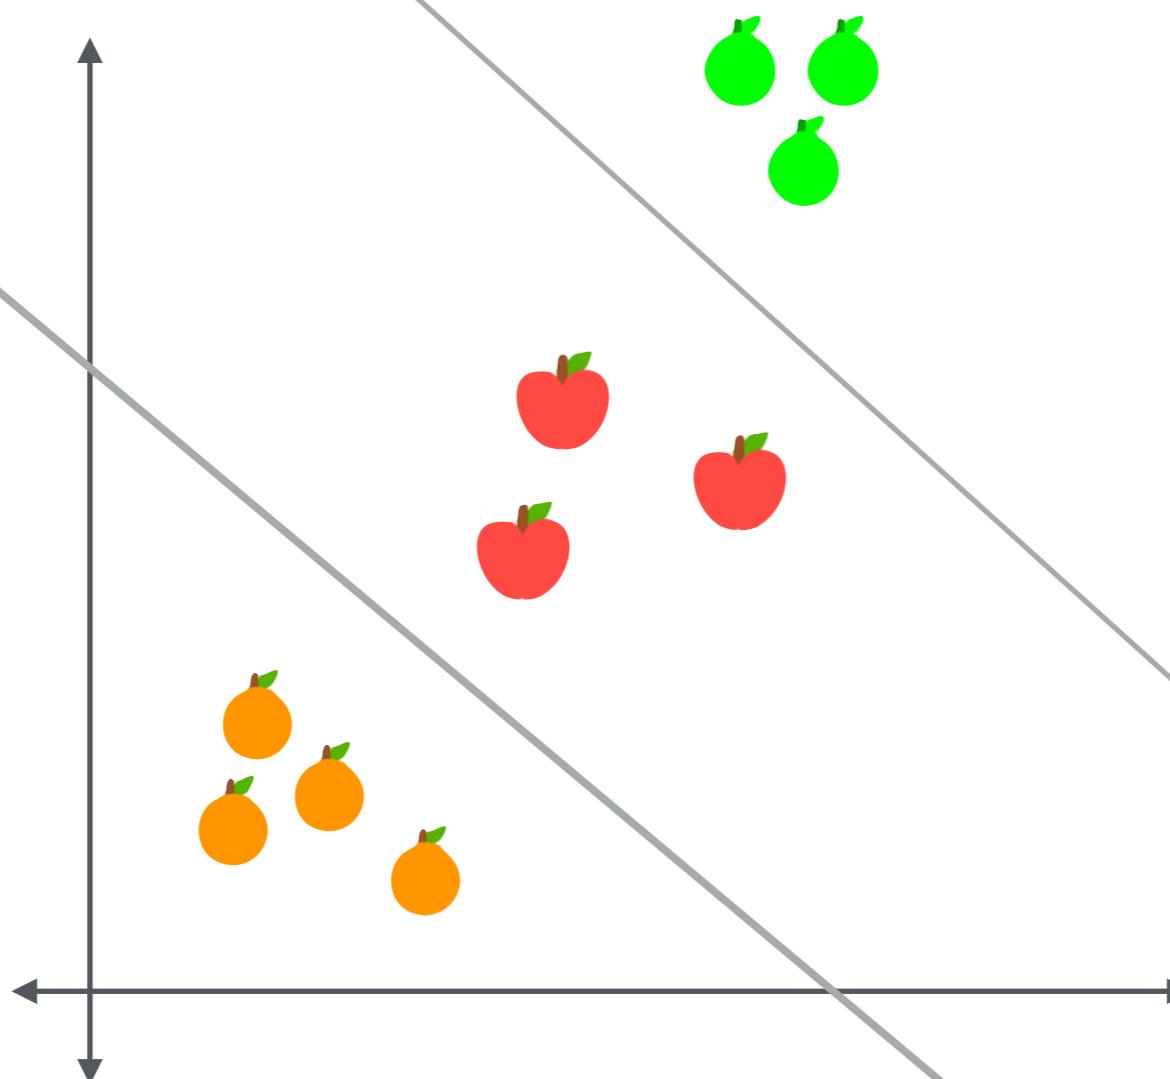
Redes Neurais Artificiais

multi-camadas



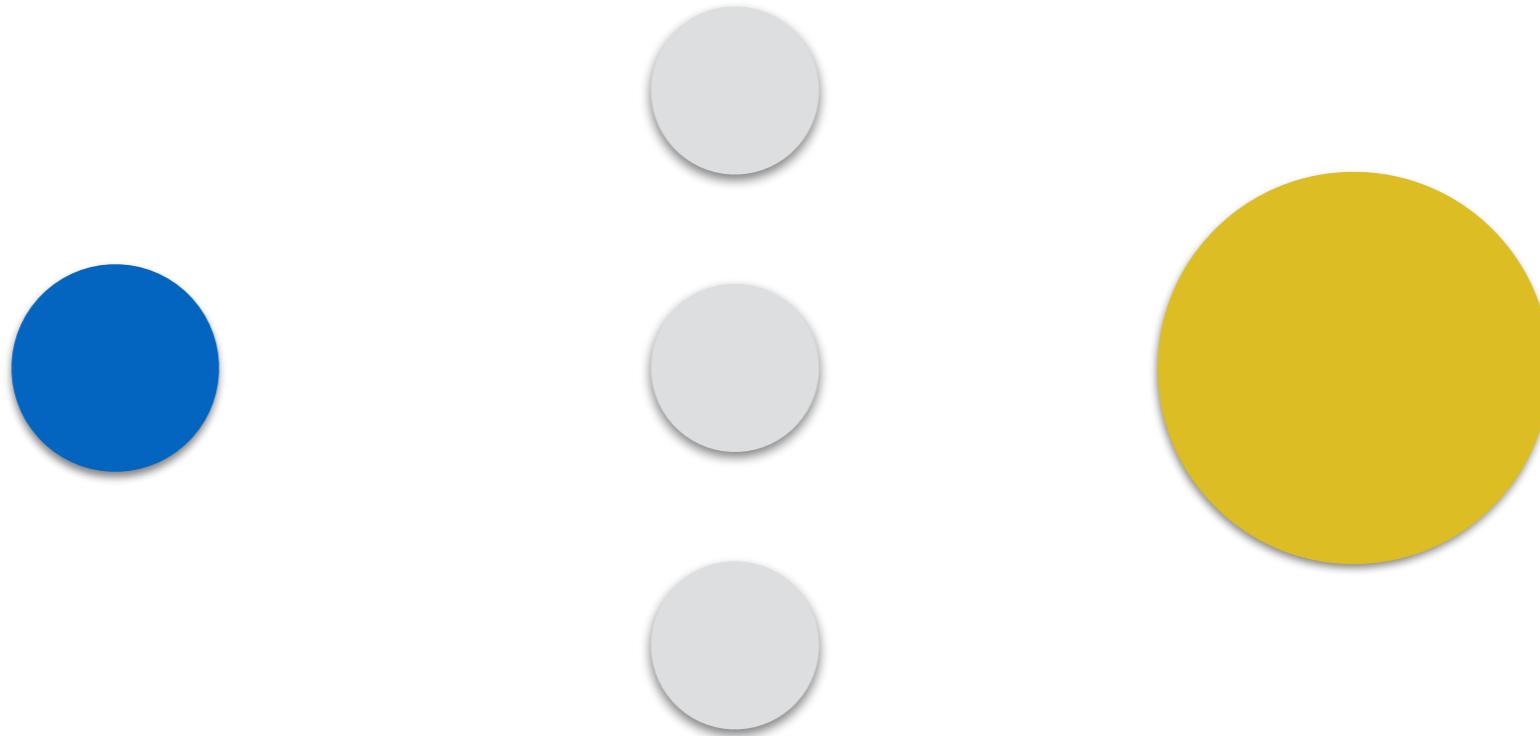
Redes Neurais Artificiais

multi-camadas



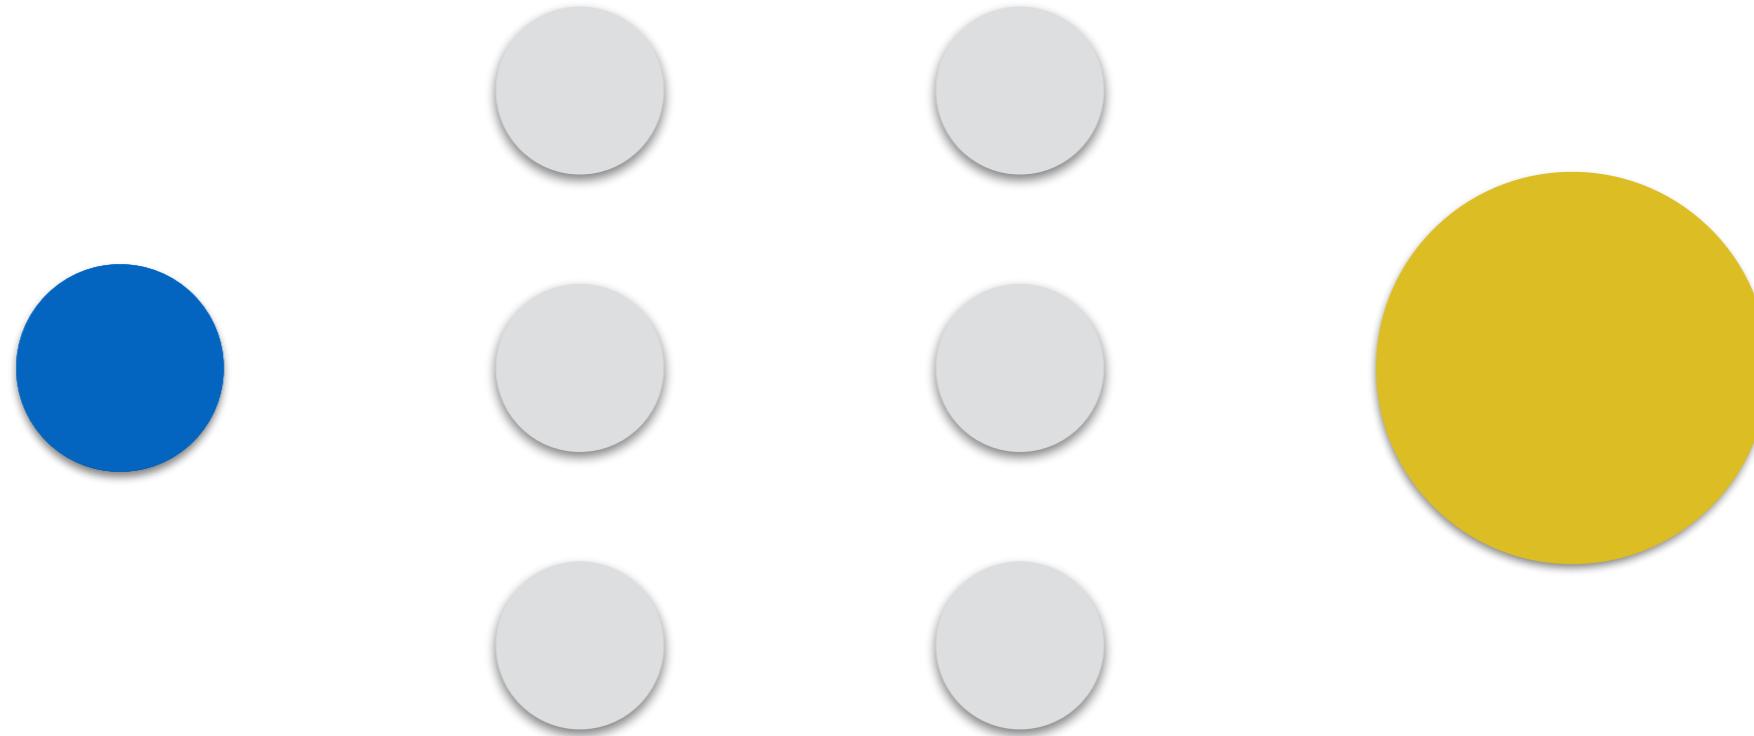
Redes Neurais Artificiais

multi-camadas



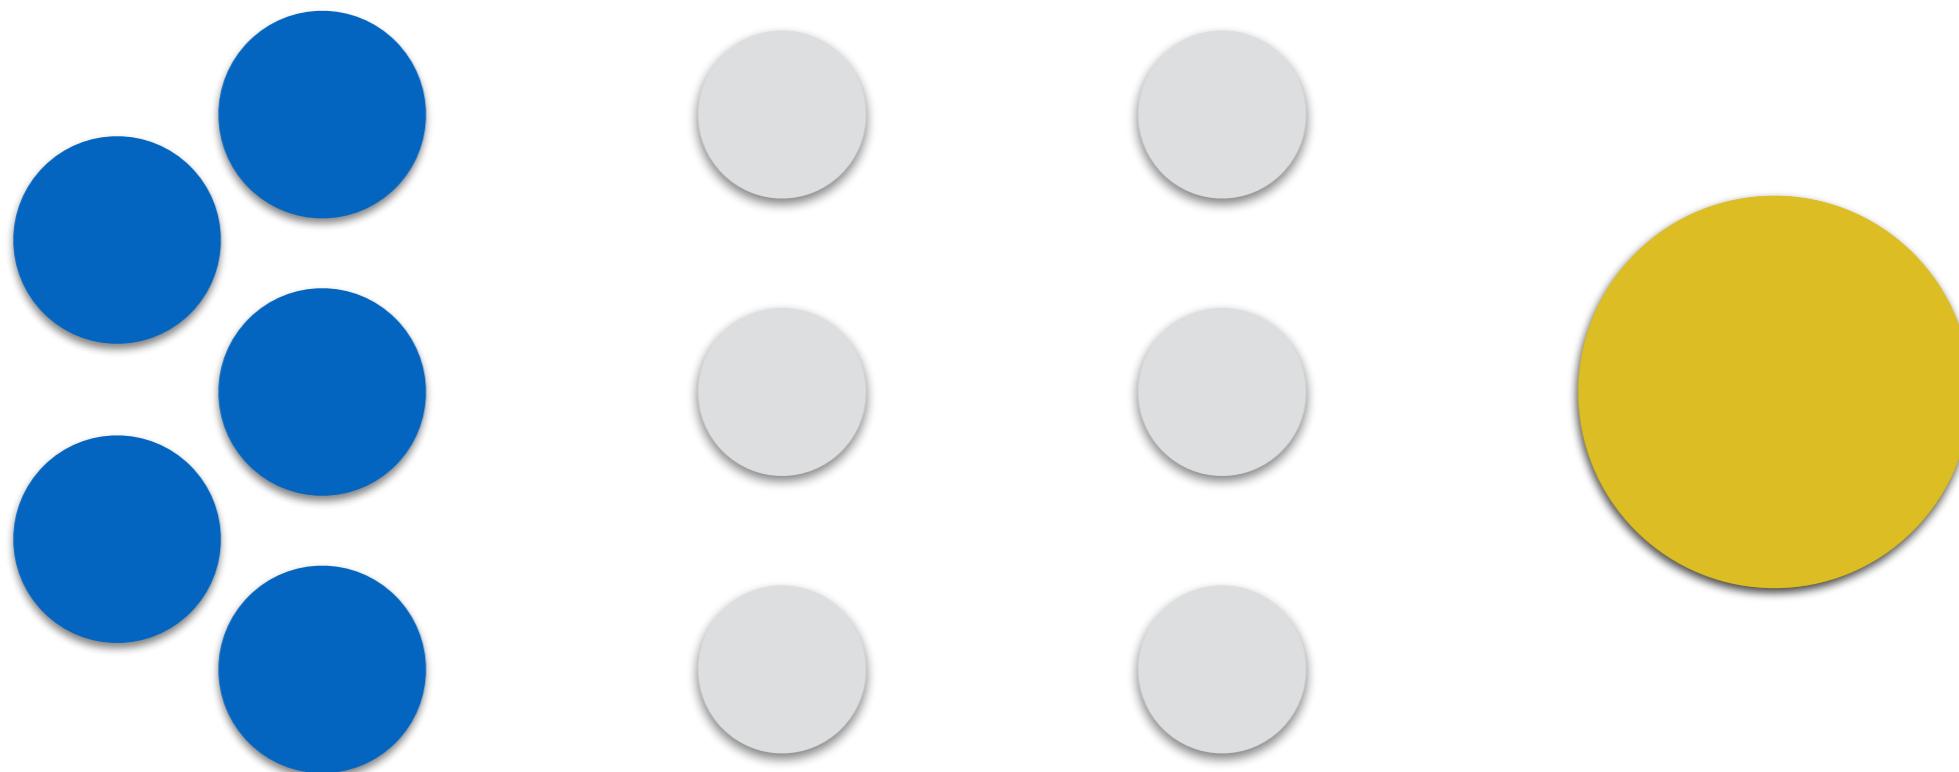
Redes Neurais Artificiais

multi-camadas



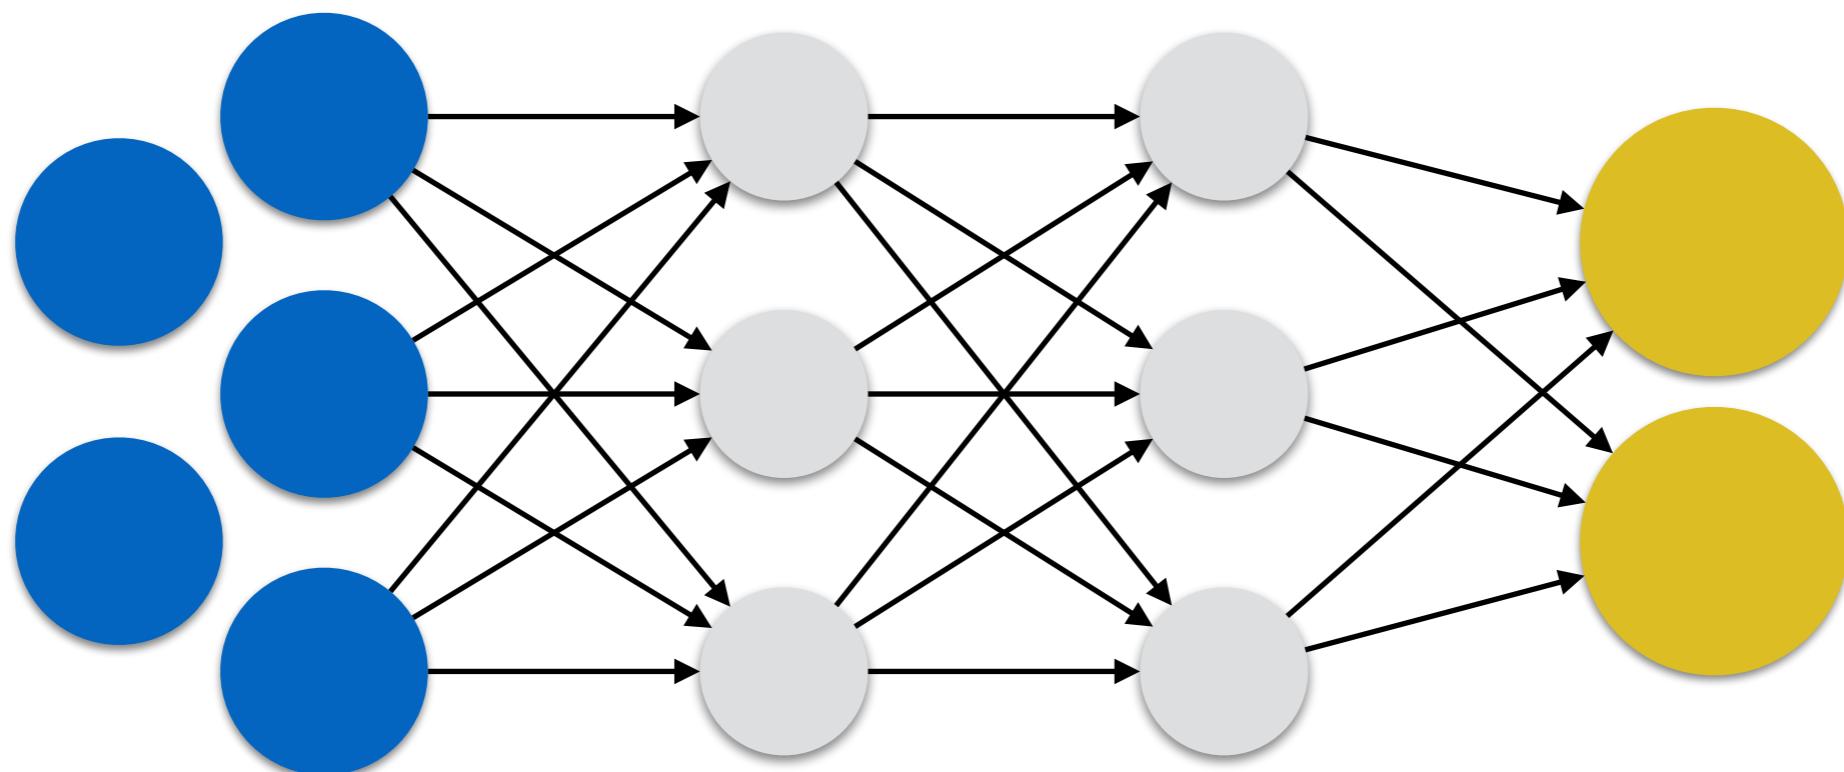
Redes Neurais Artificiais

multi-camadas



Redes Neurais Artificiais

multi-camadas



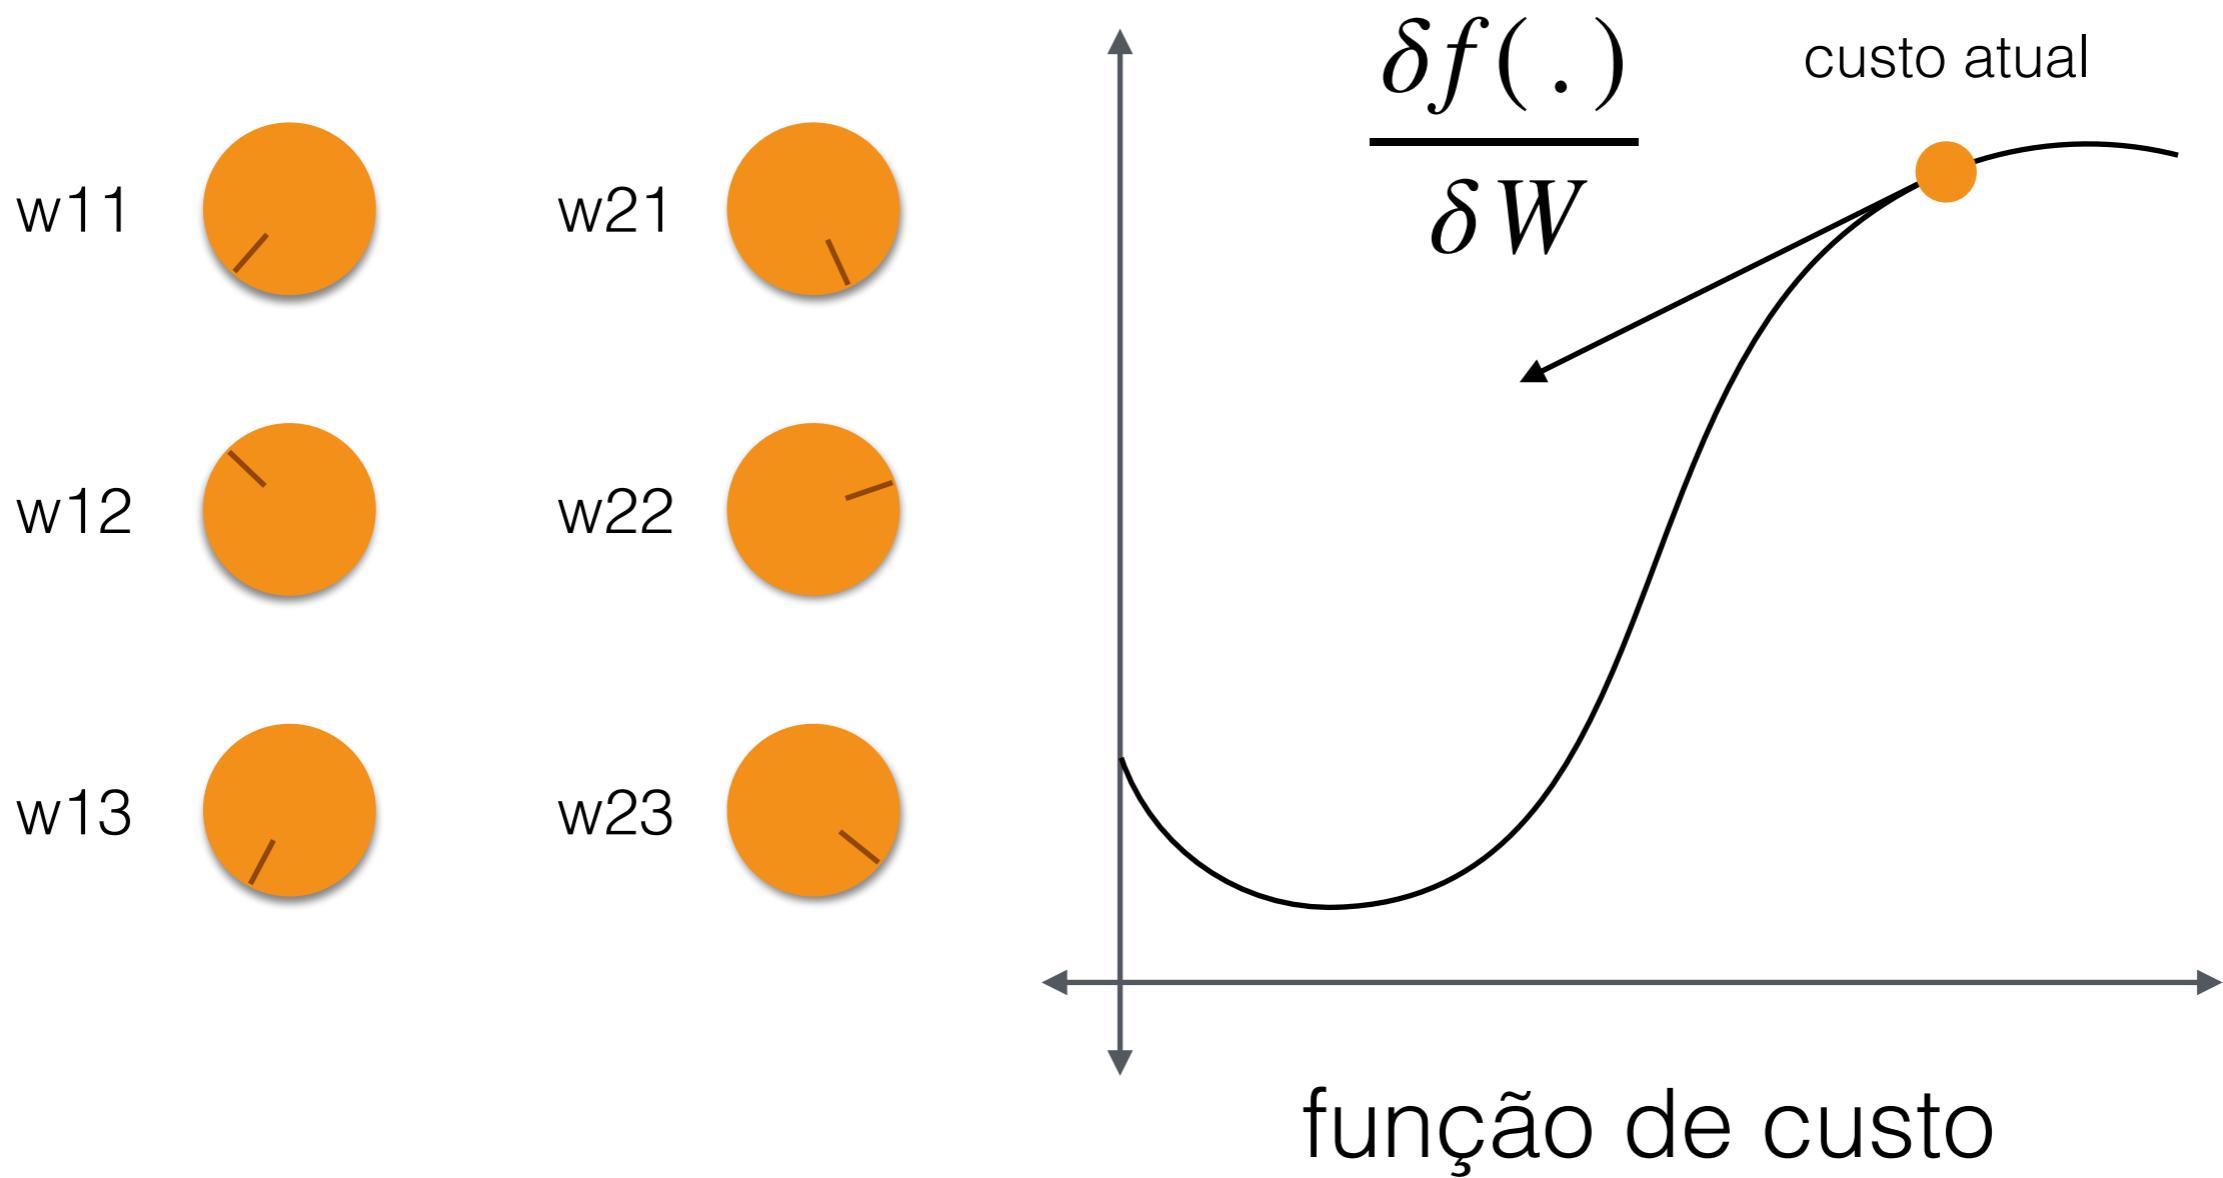
Entrada

Cam. Escondidas

Saída

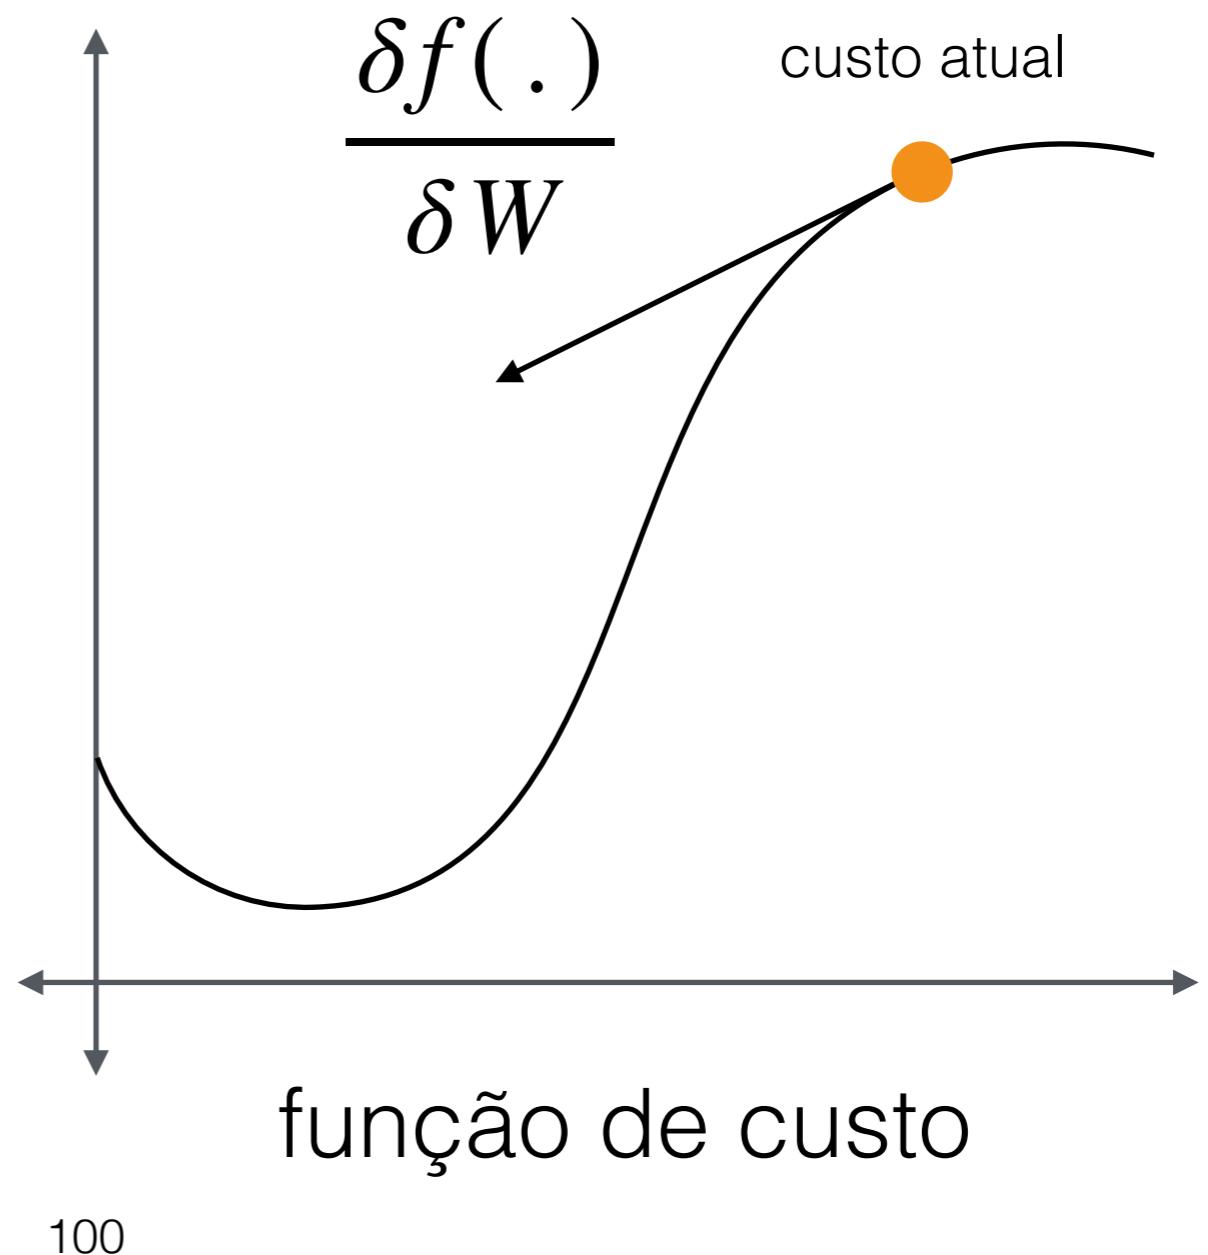
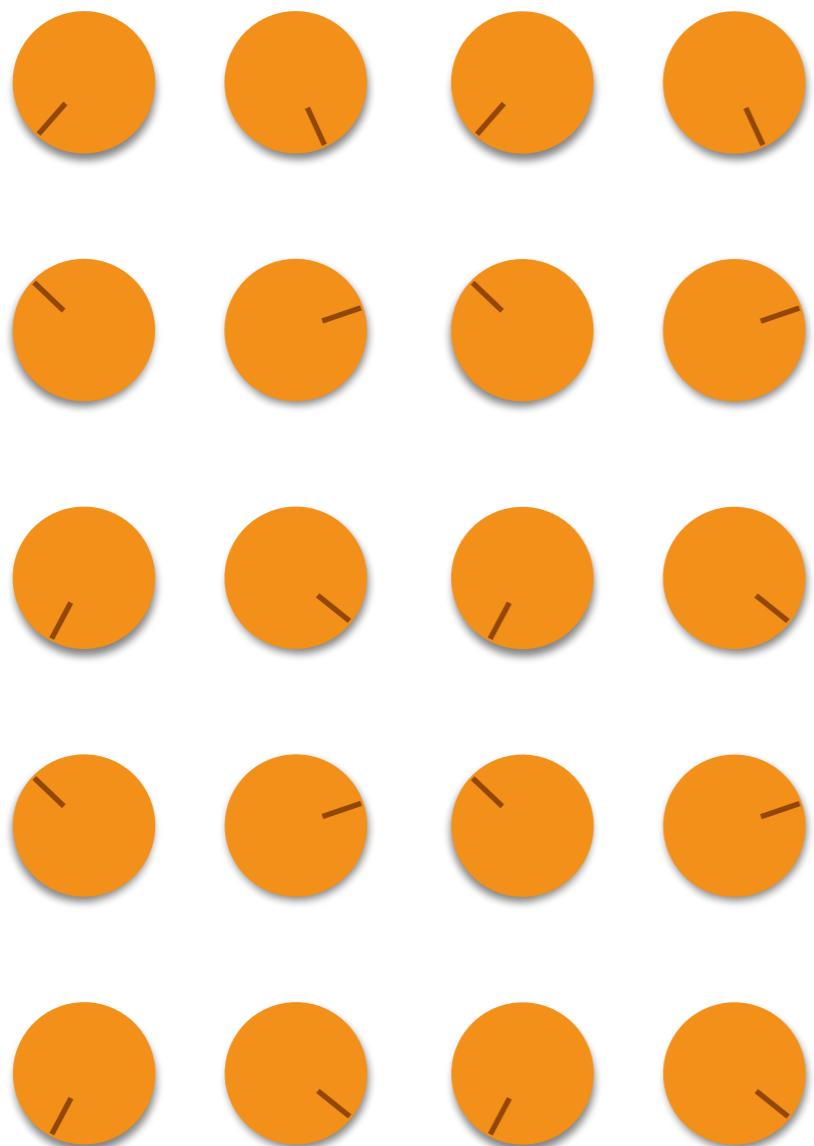
Redes Neurais Artificiais

Multicamadas



Redes Neurais Artificiais

Multicamadas



Redes Neurais Artificiais

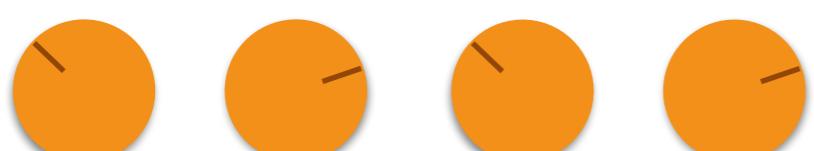
Multicamadas



Maior quantidade de pesos



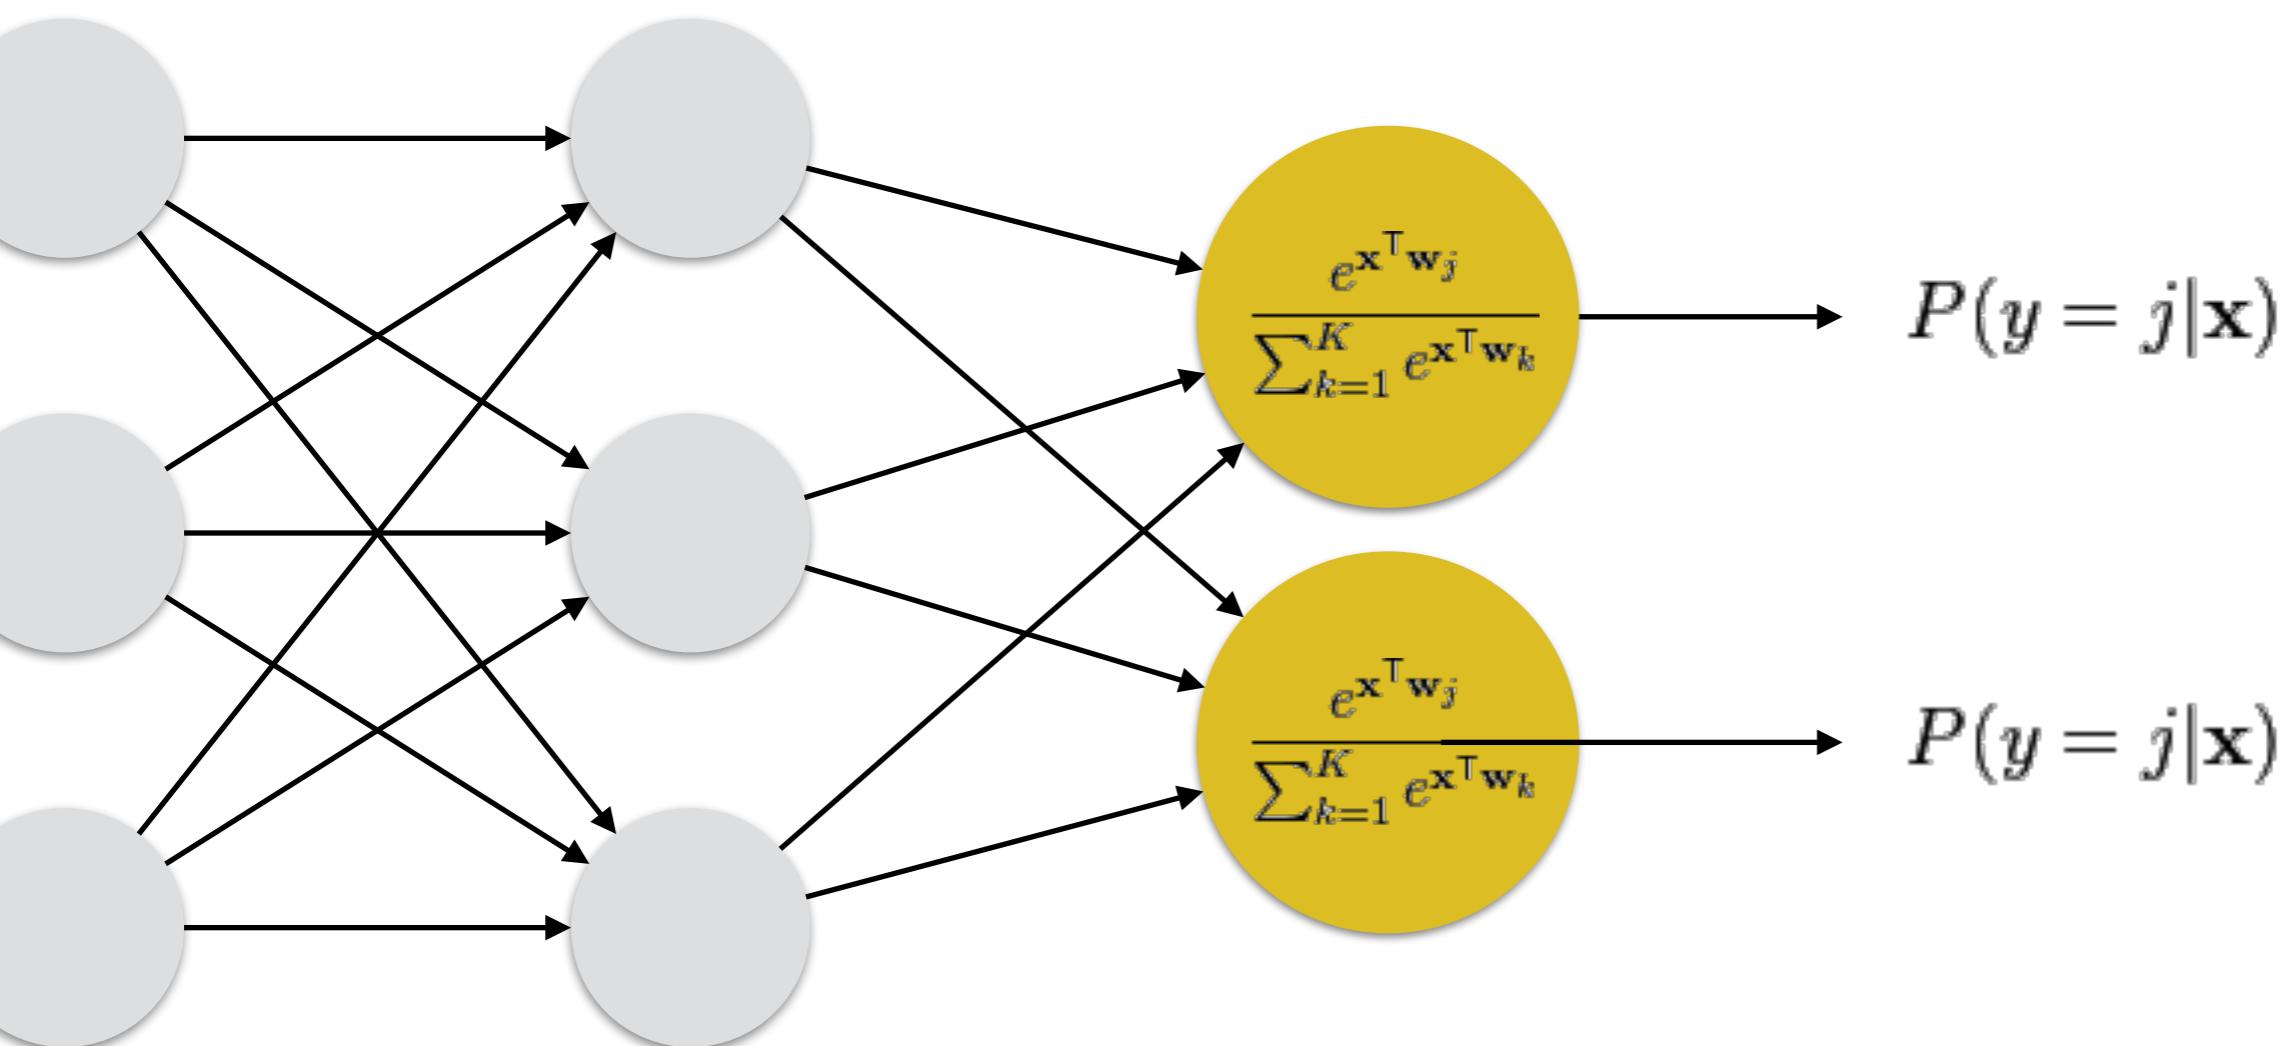
Gradiente Descendente
realizado com a ajuda de
backpropagation



$$\frac{\delta f(\cdot)}{\delta W} ? \text{ Regra da Cadeia}$$

Redes Neurais Artificiais

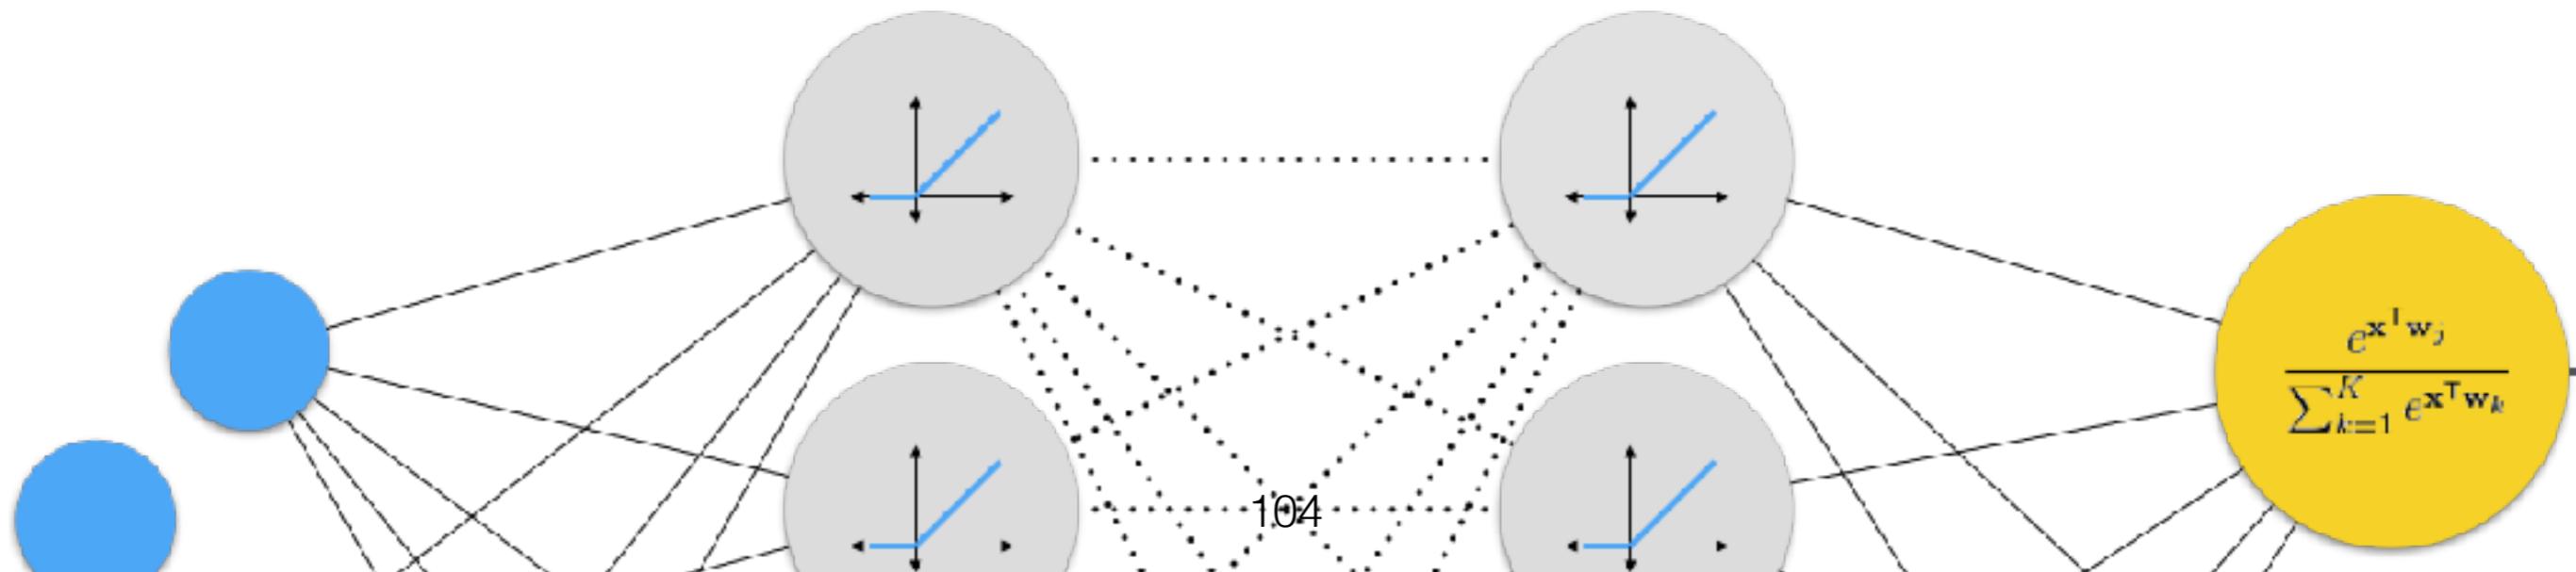
multi-camadas



DEMO #2

Perceptron e Multi-layer Perceptron

Perceptron e Multi-layer Perceptron



Introdução a

Aprendizagem de Máquina



Cronograma da Apresentação

Aprendizagem de
Máquina

Perceptron

Multi-layer
Perceptron

Cronograma da Apresentação



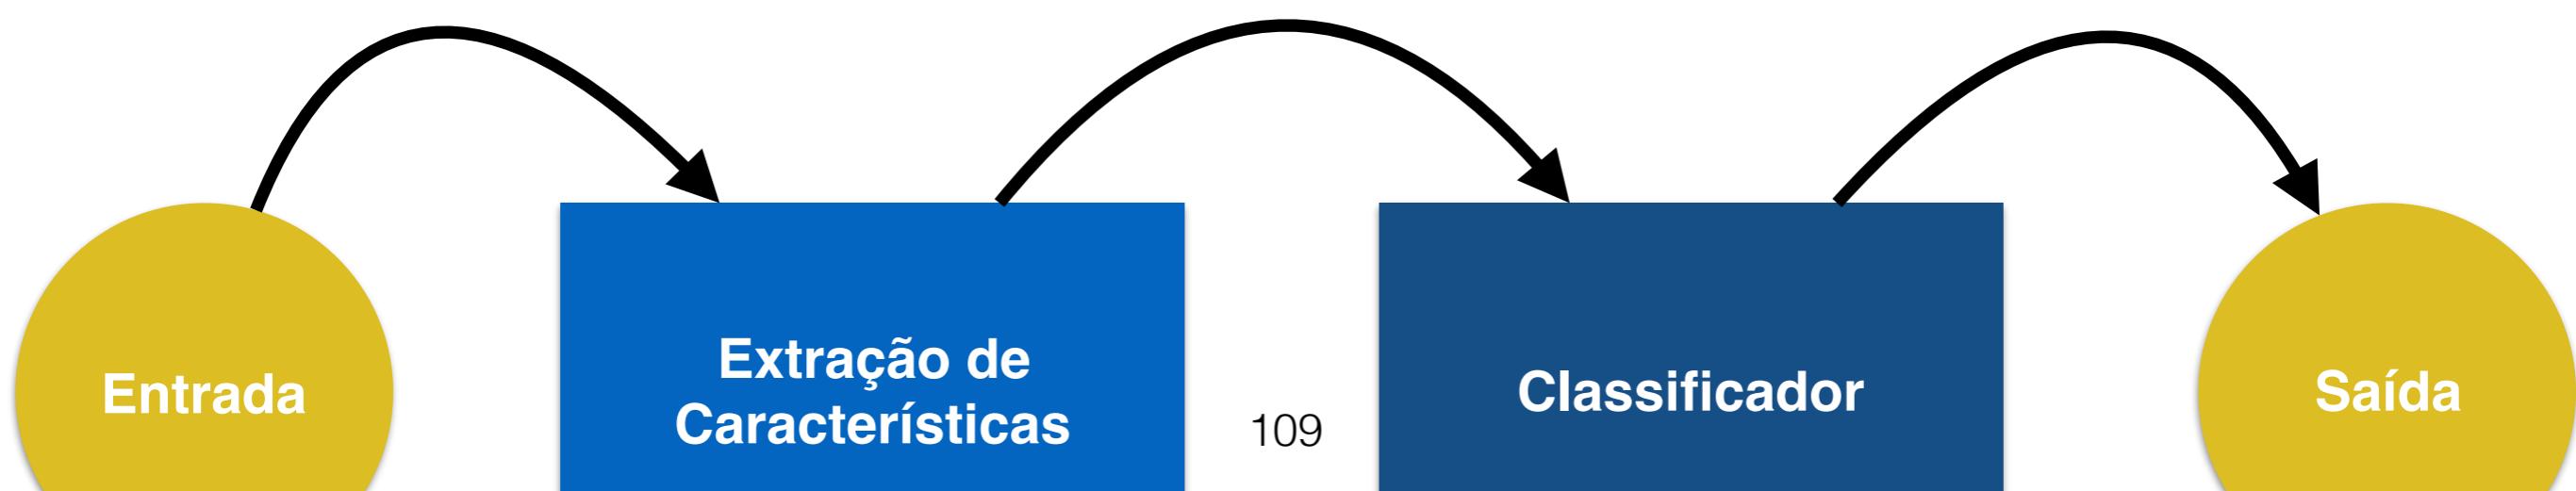
Cronograma da Apresentação

Aprendizagem de Representação

Importância da Representação

Extratores de Características

Importância da Representação e Extratores de Características



Entrada

Extração de
Características

109

Classificador

Saída

Outros Classificadores

Outros Classificadores

Redes Neurais Artificiais

Outros Classificadores

Redes Neurais Artificiais

k-Nearest Neighbors

Outros Classificadores

Redes Neurais Artificiais

Support Vector Machines

k-Nearest Neighbors

Outros Classificadores

Redes Neurais Artificiais

Support Vector Machines

k-Nearest Neighbors

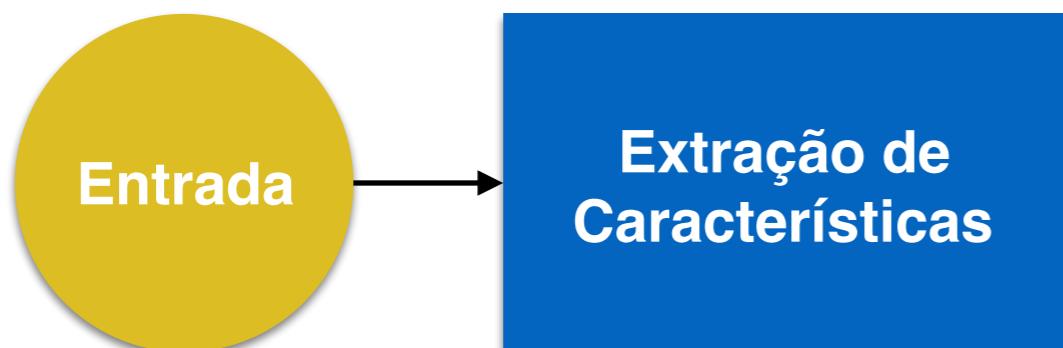
Decision Trees

Pipeline Comum

Pipeline Comum



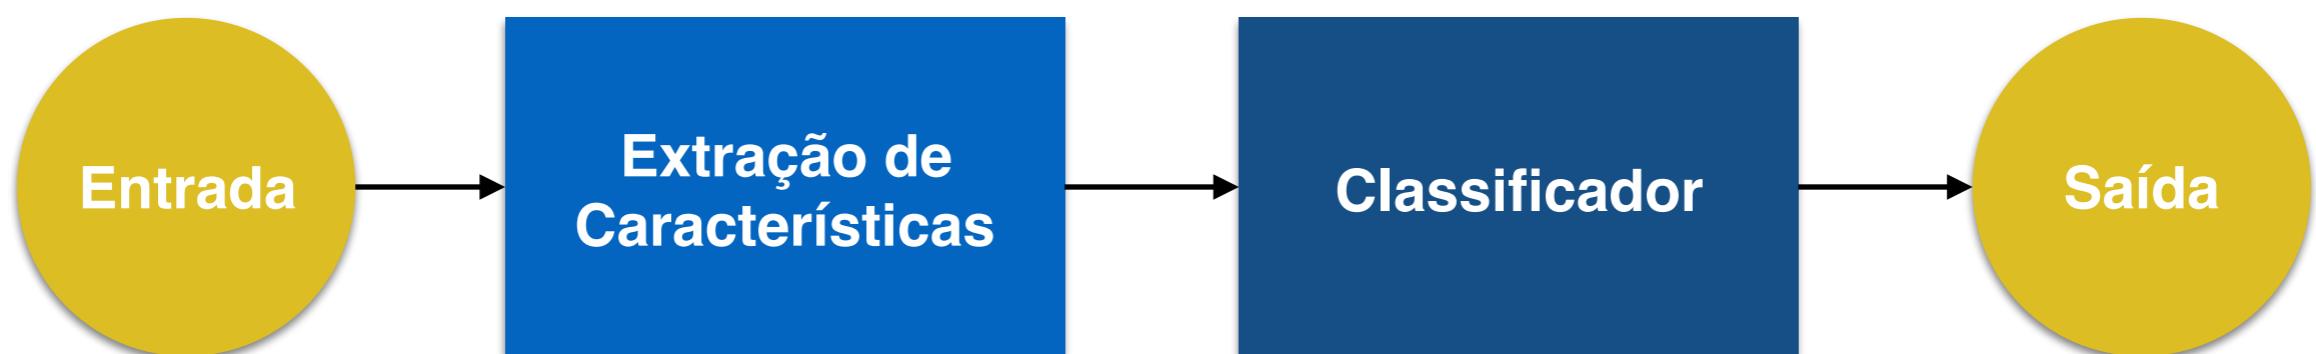
Pipeline Comum



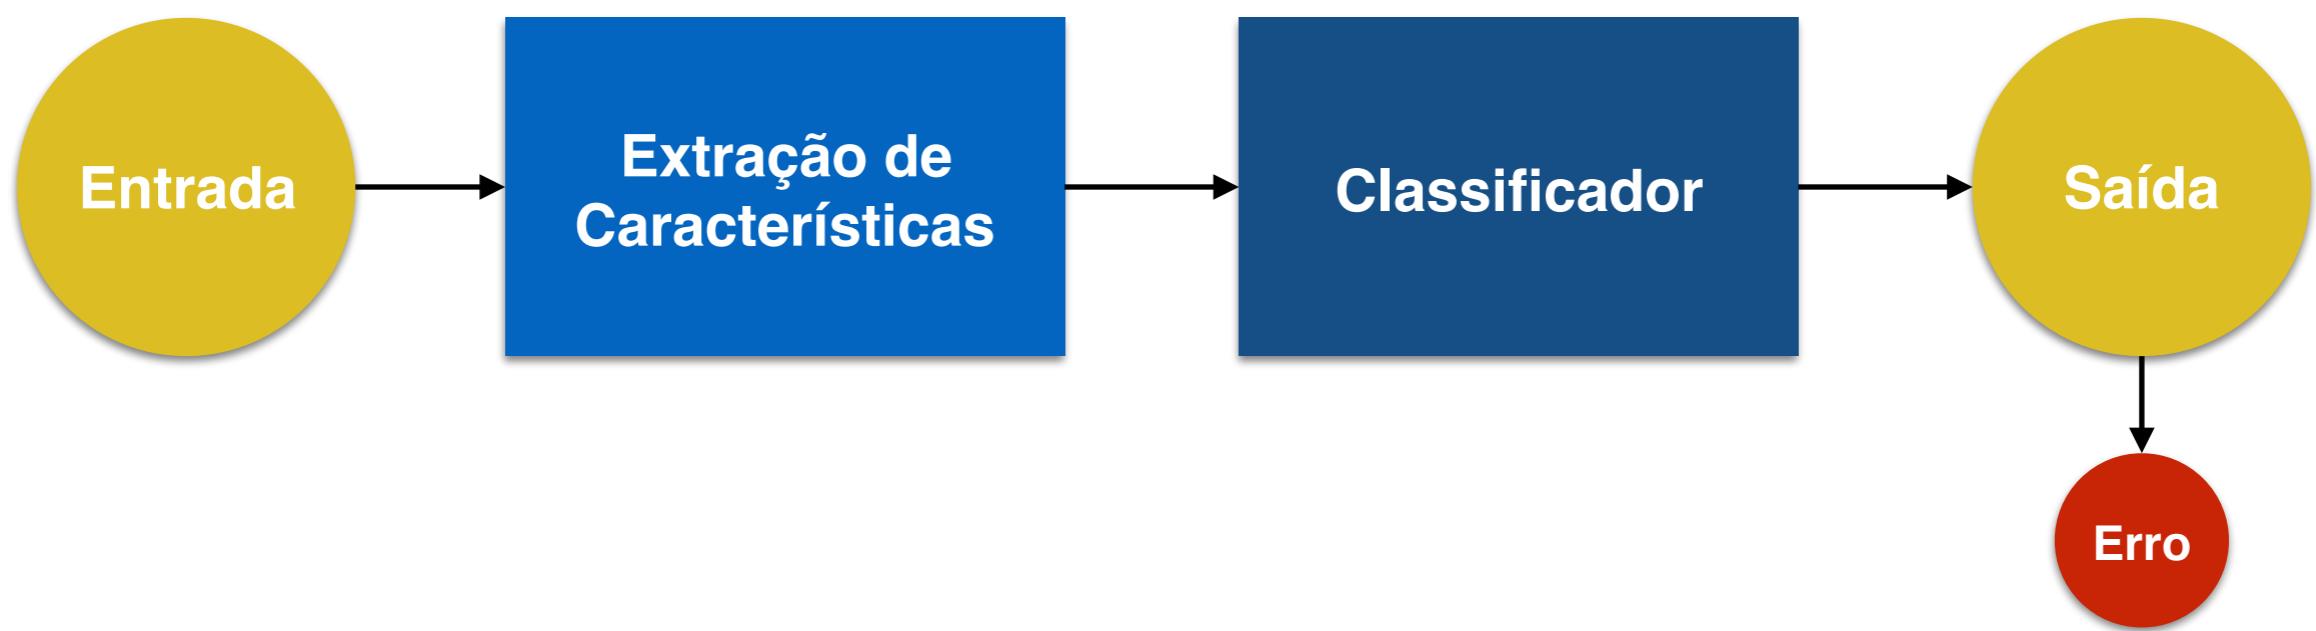
Pipeline Comum



Pipeline Comum

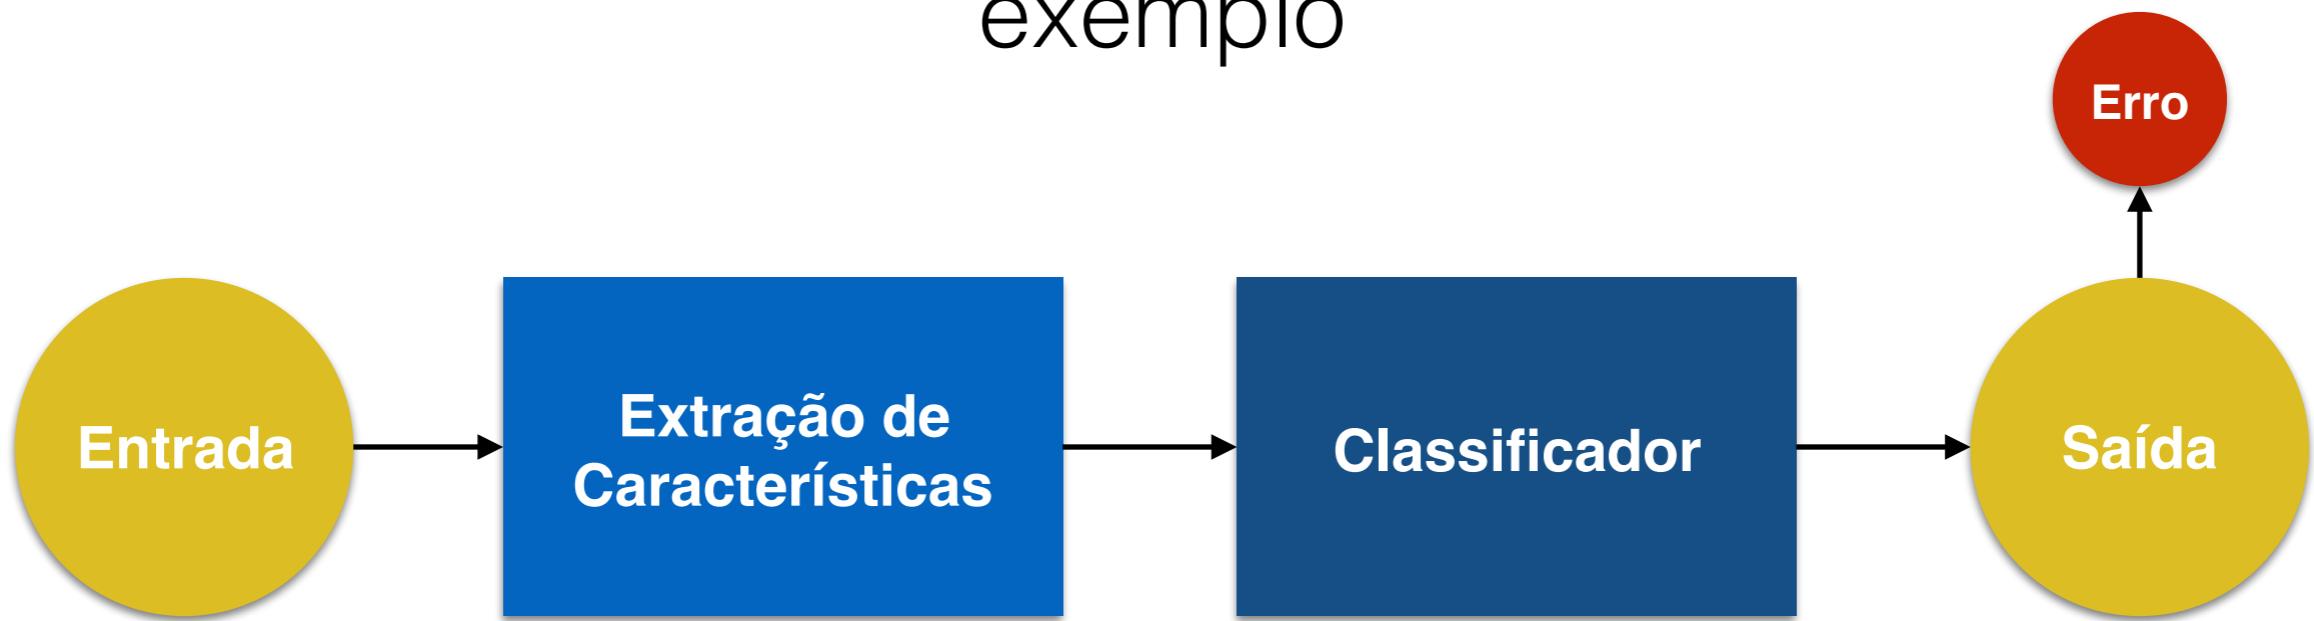


Pipeline Comum



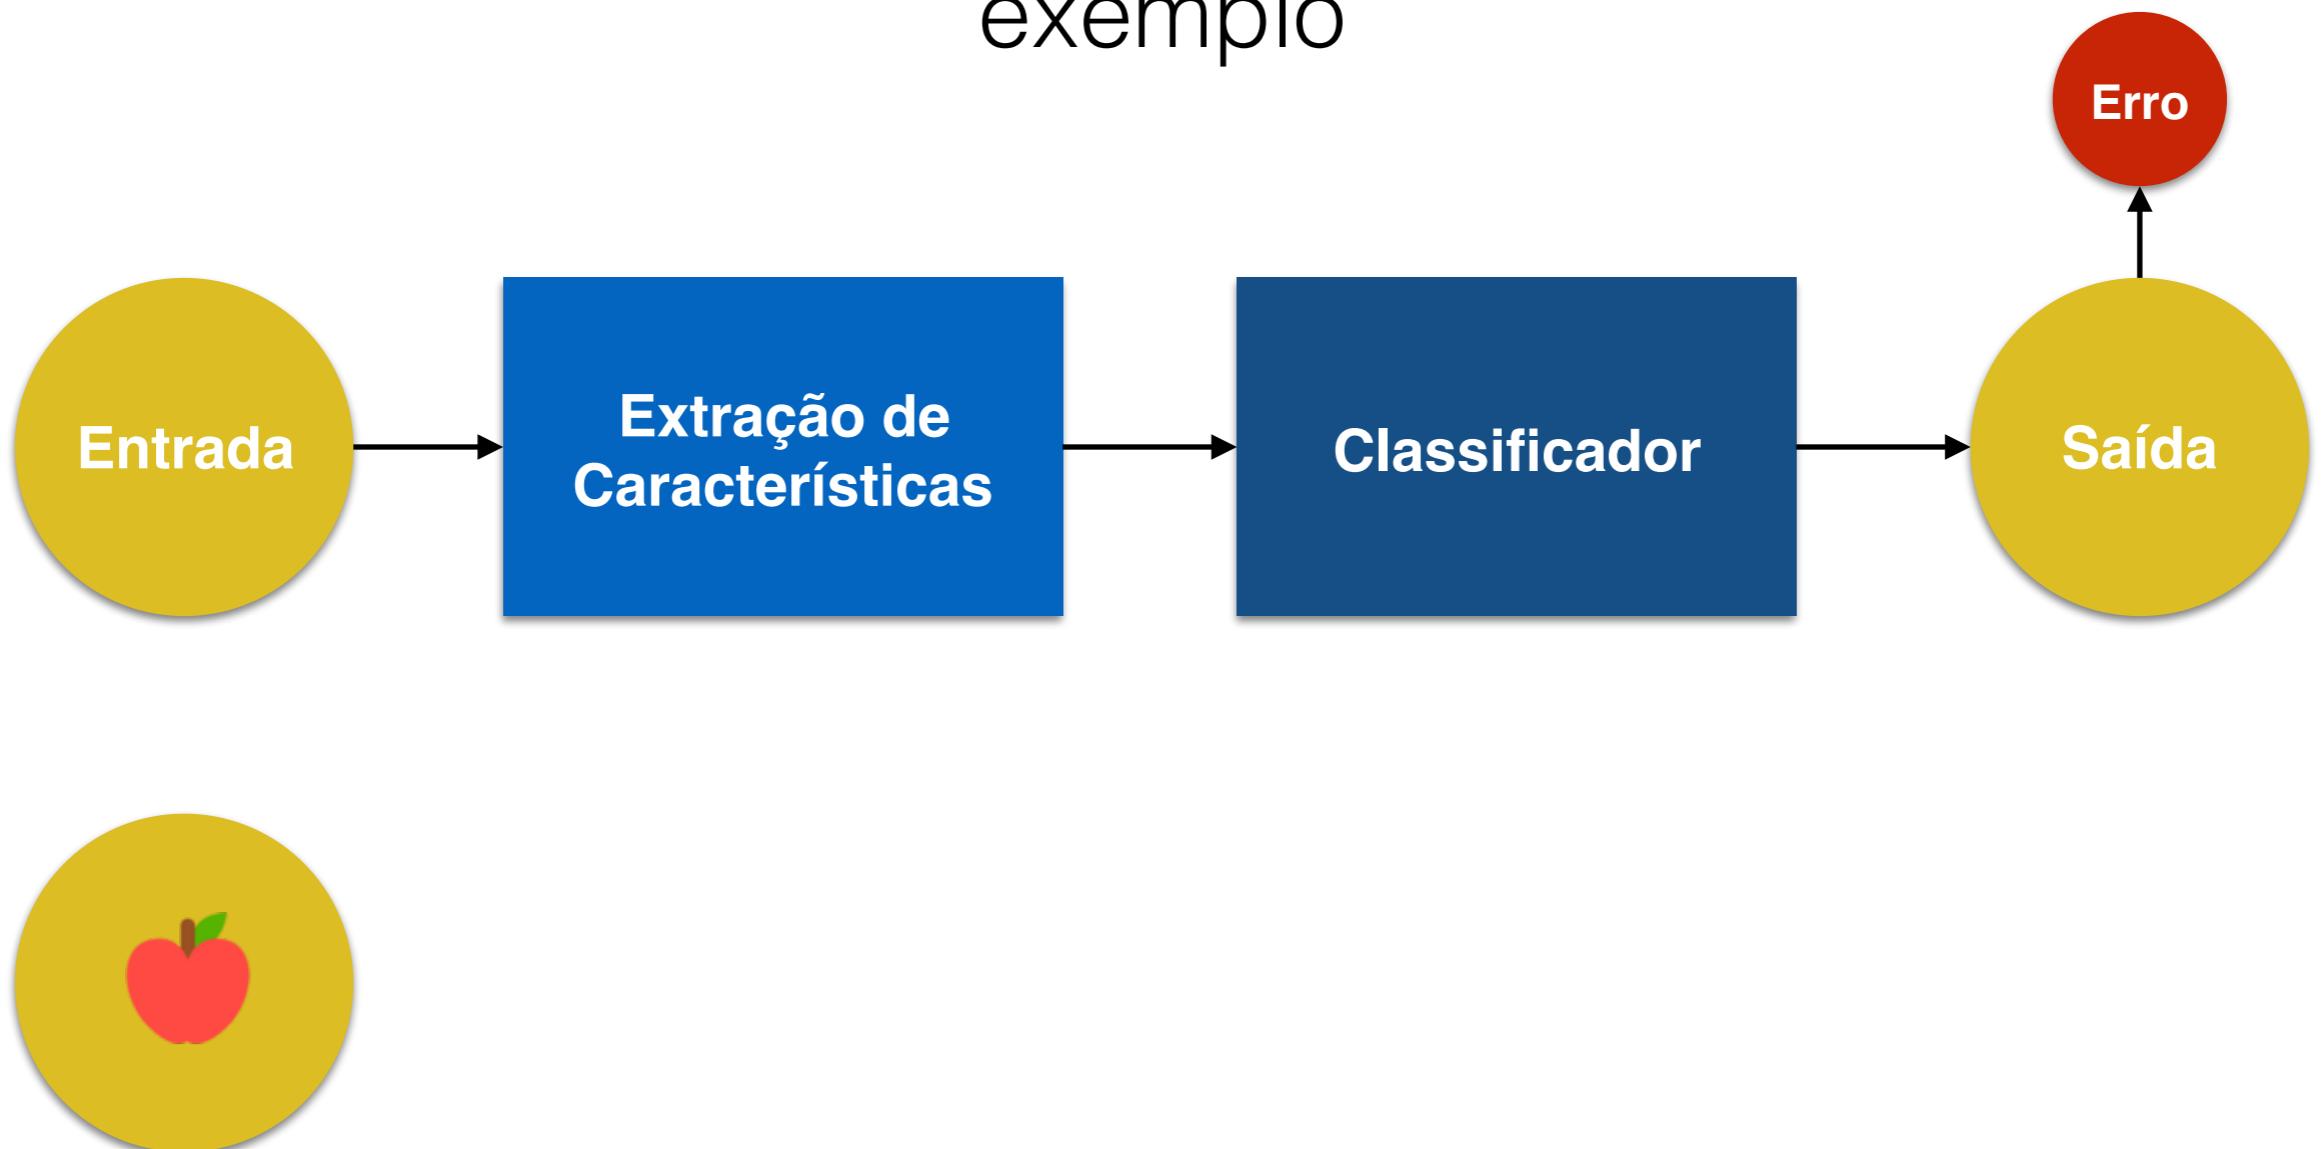
Pipeline Comum

exemplo



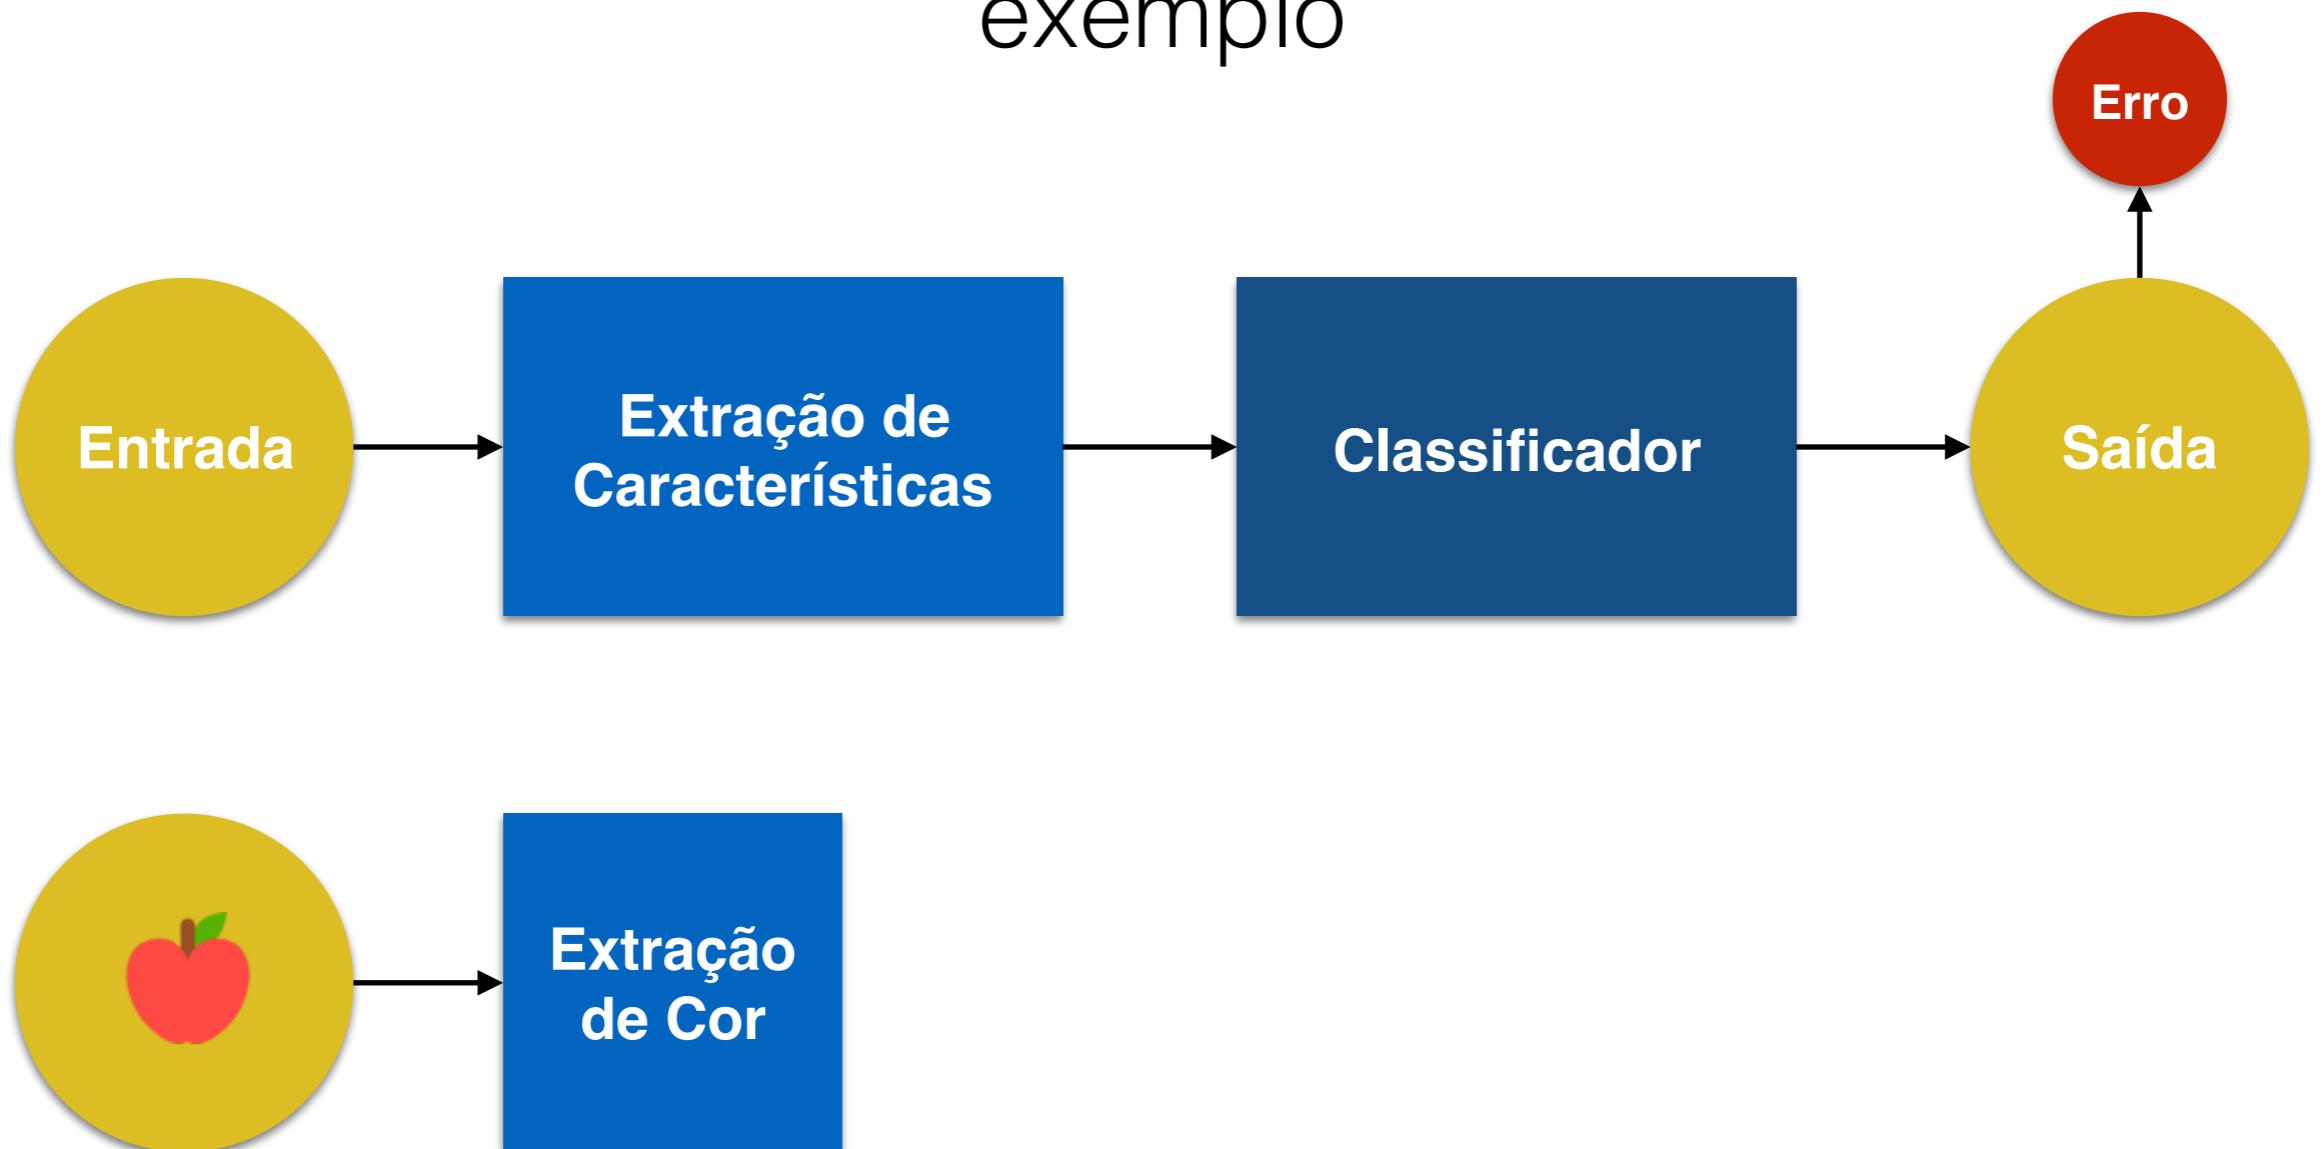
Pipeline Comum

exemplo



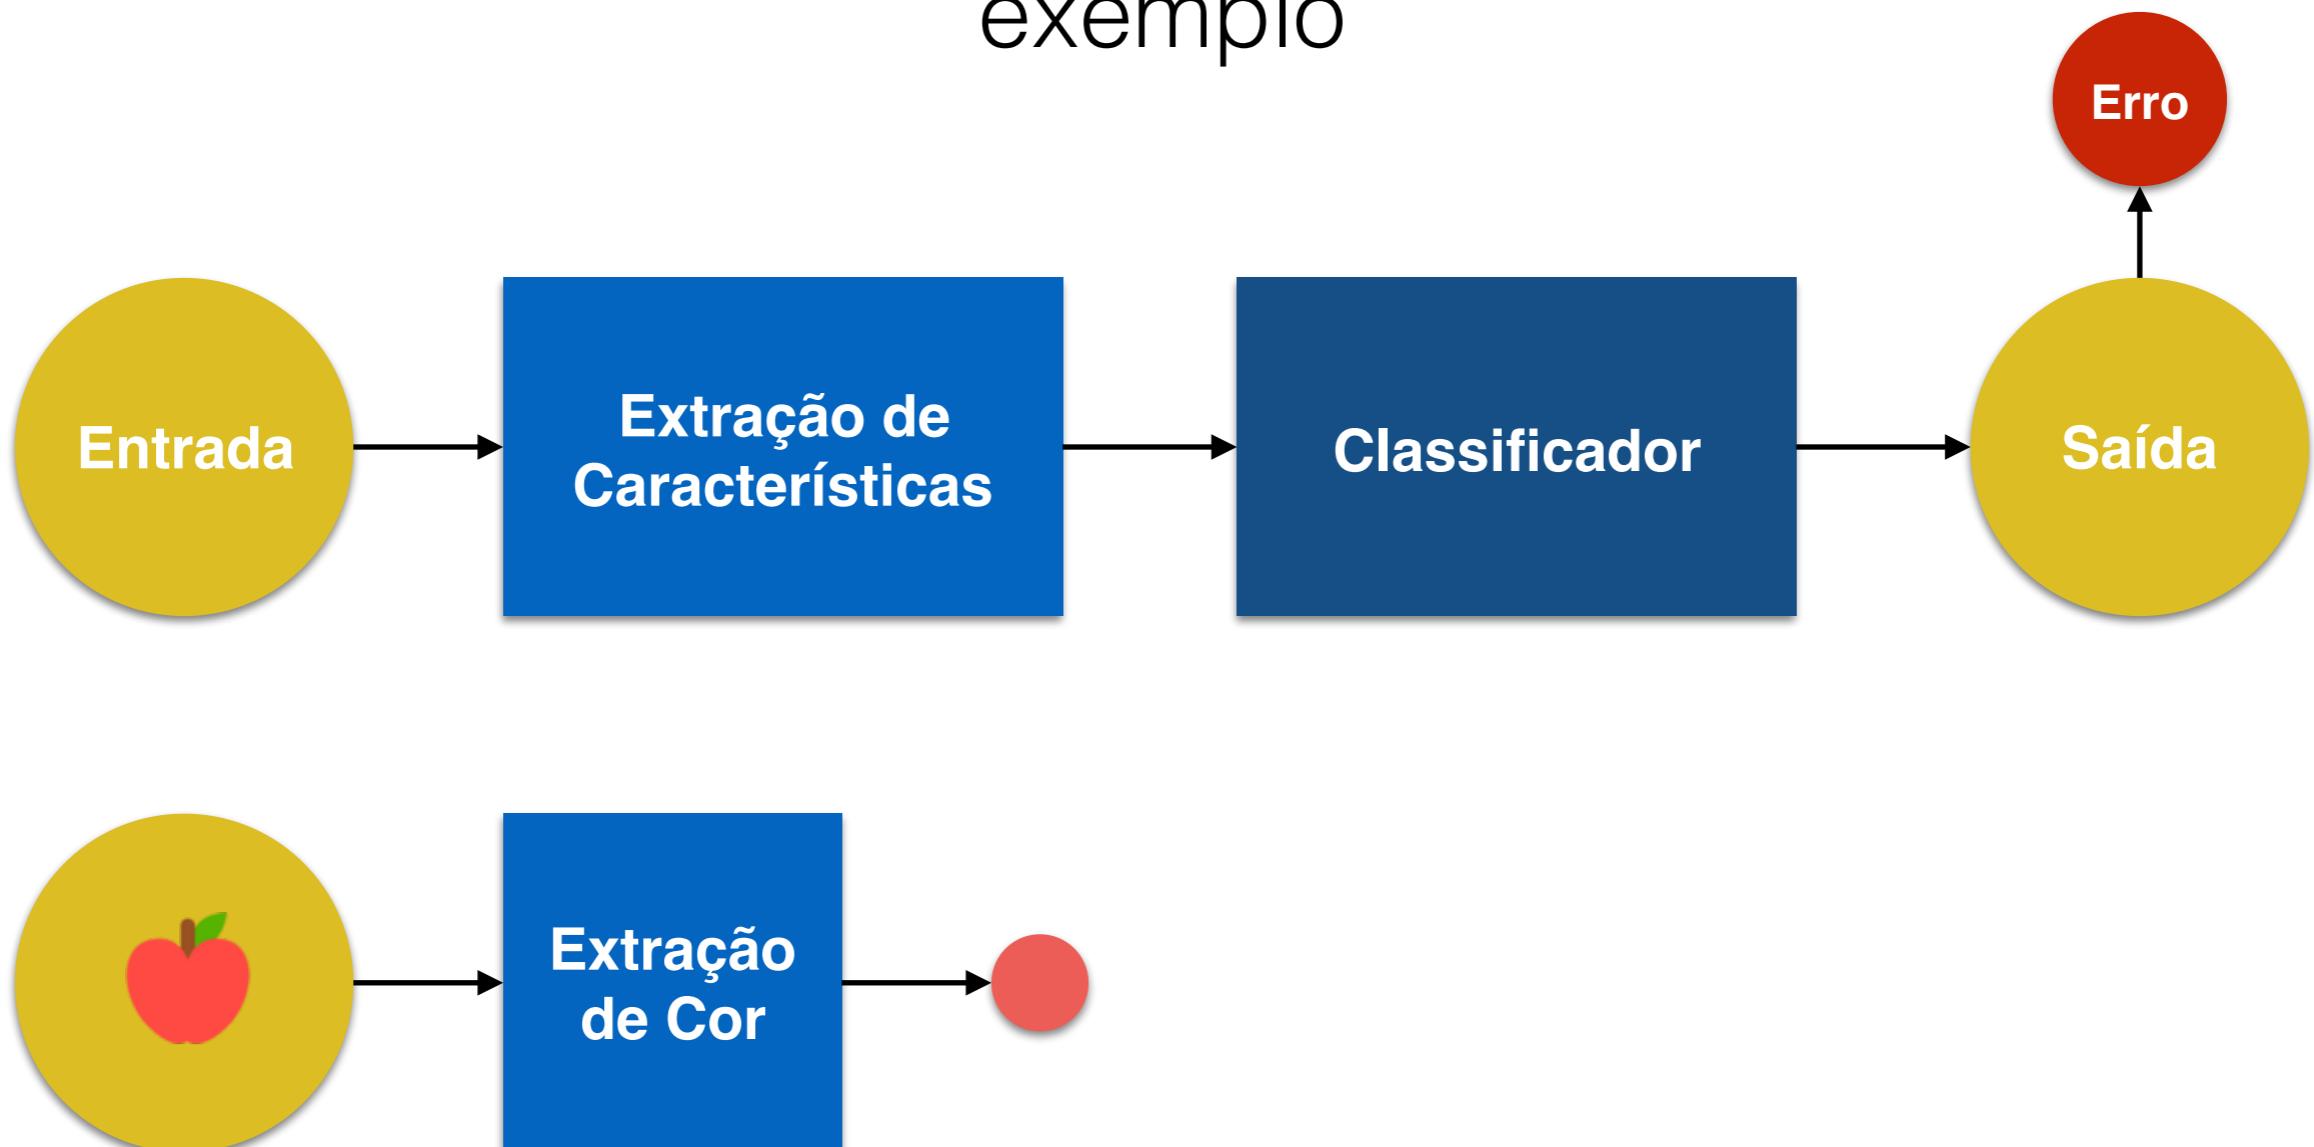
Pipeline Comum

exemplo



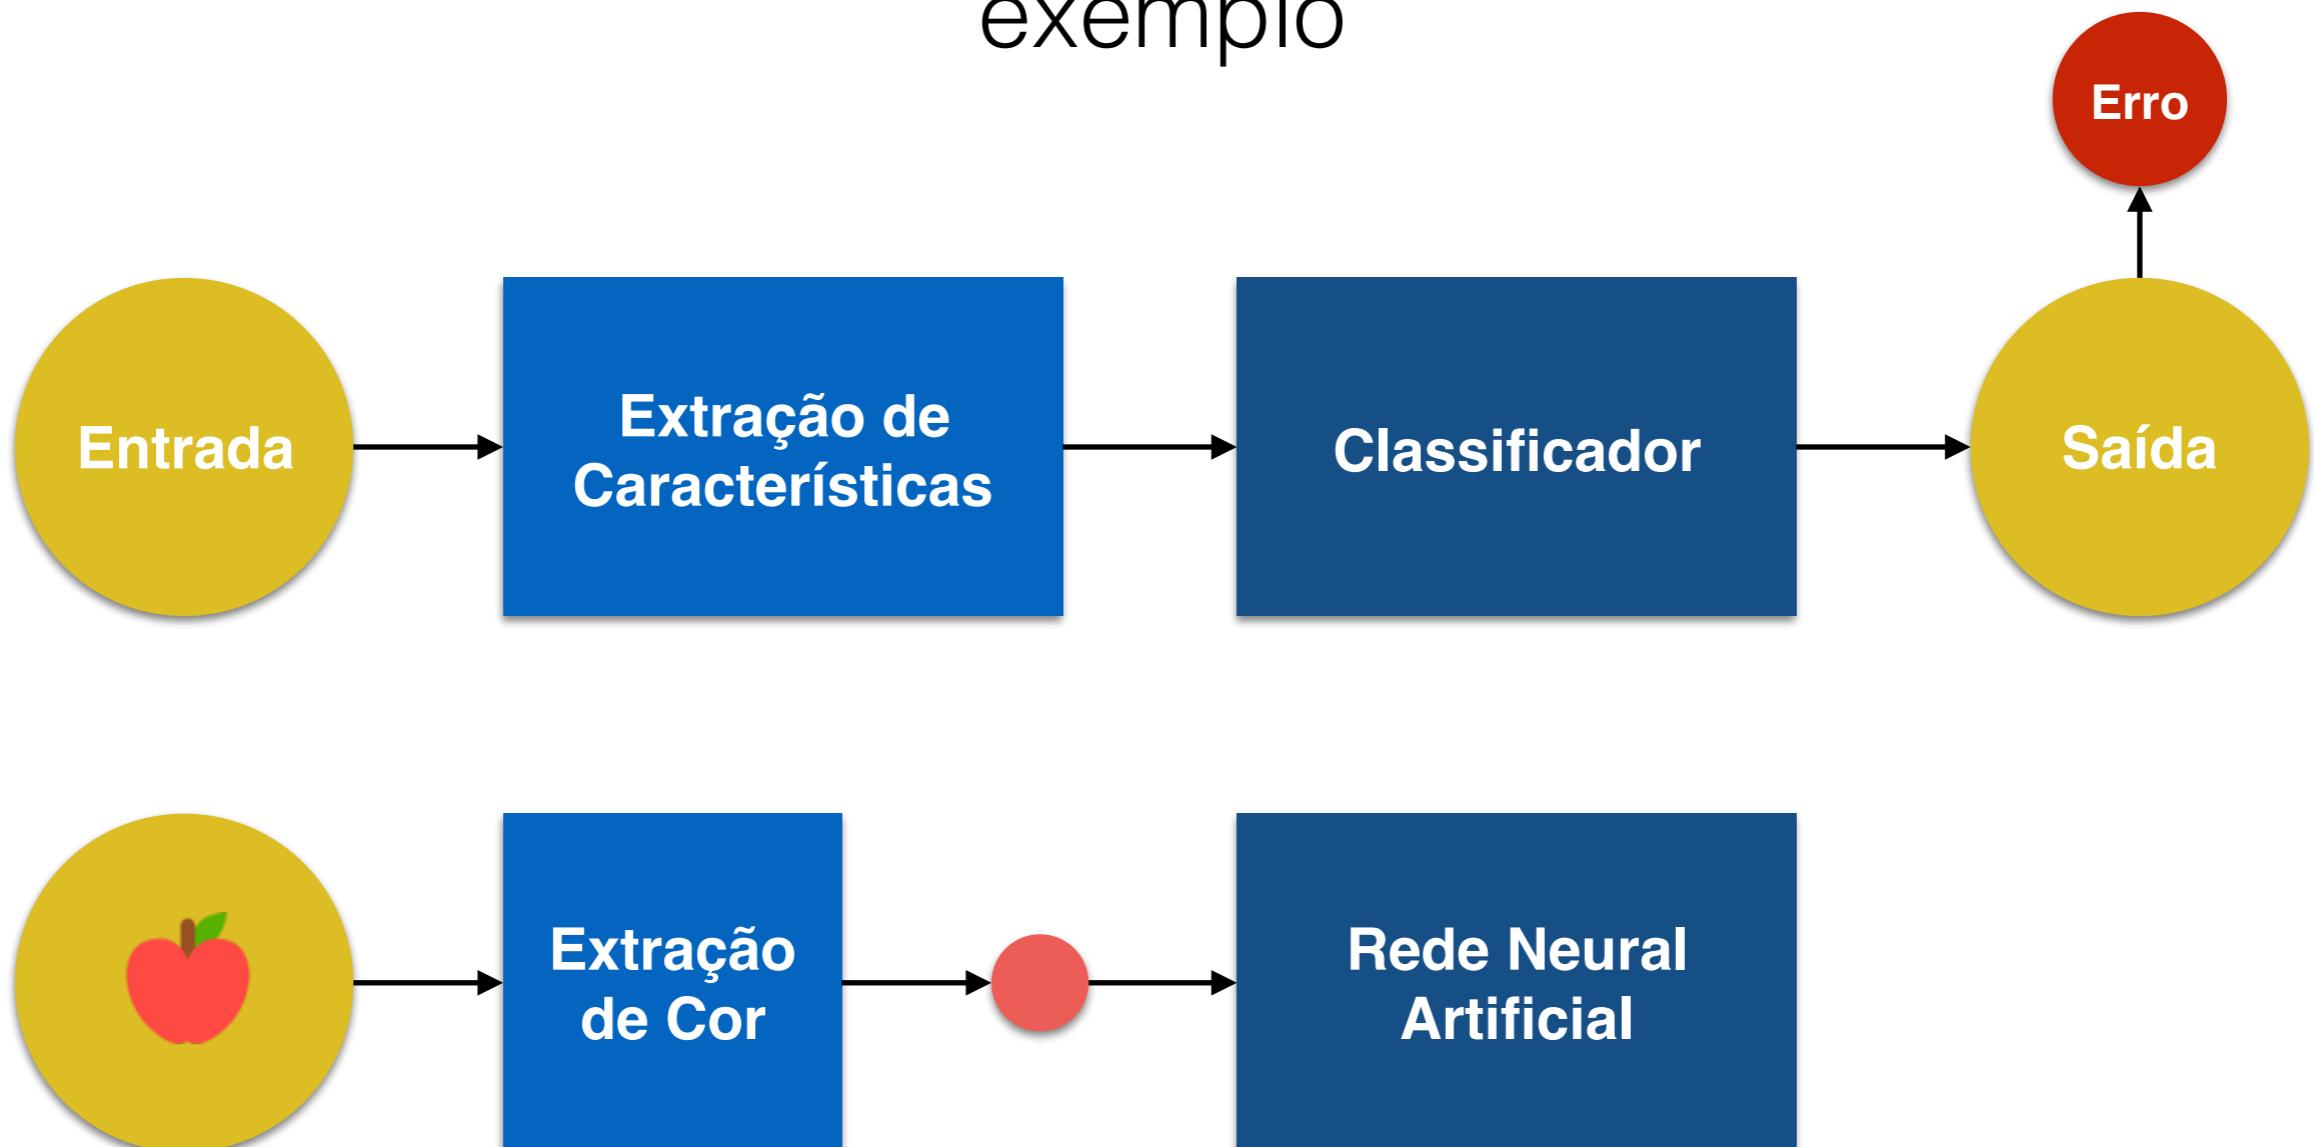
Pipeline Comum

exemplo



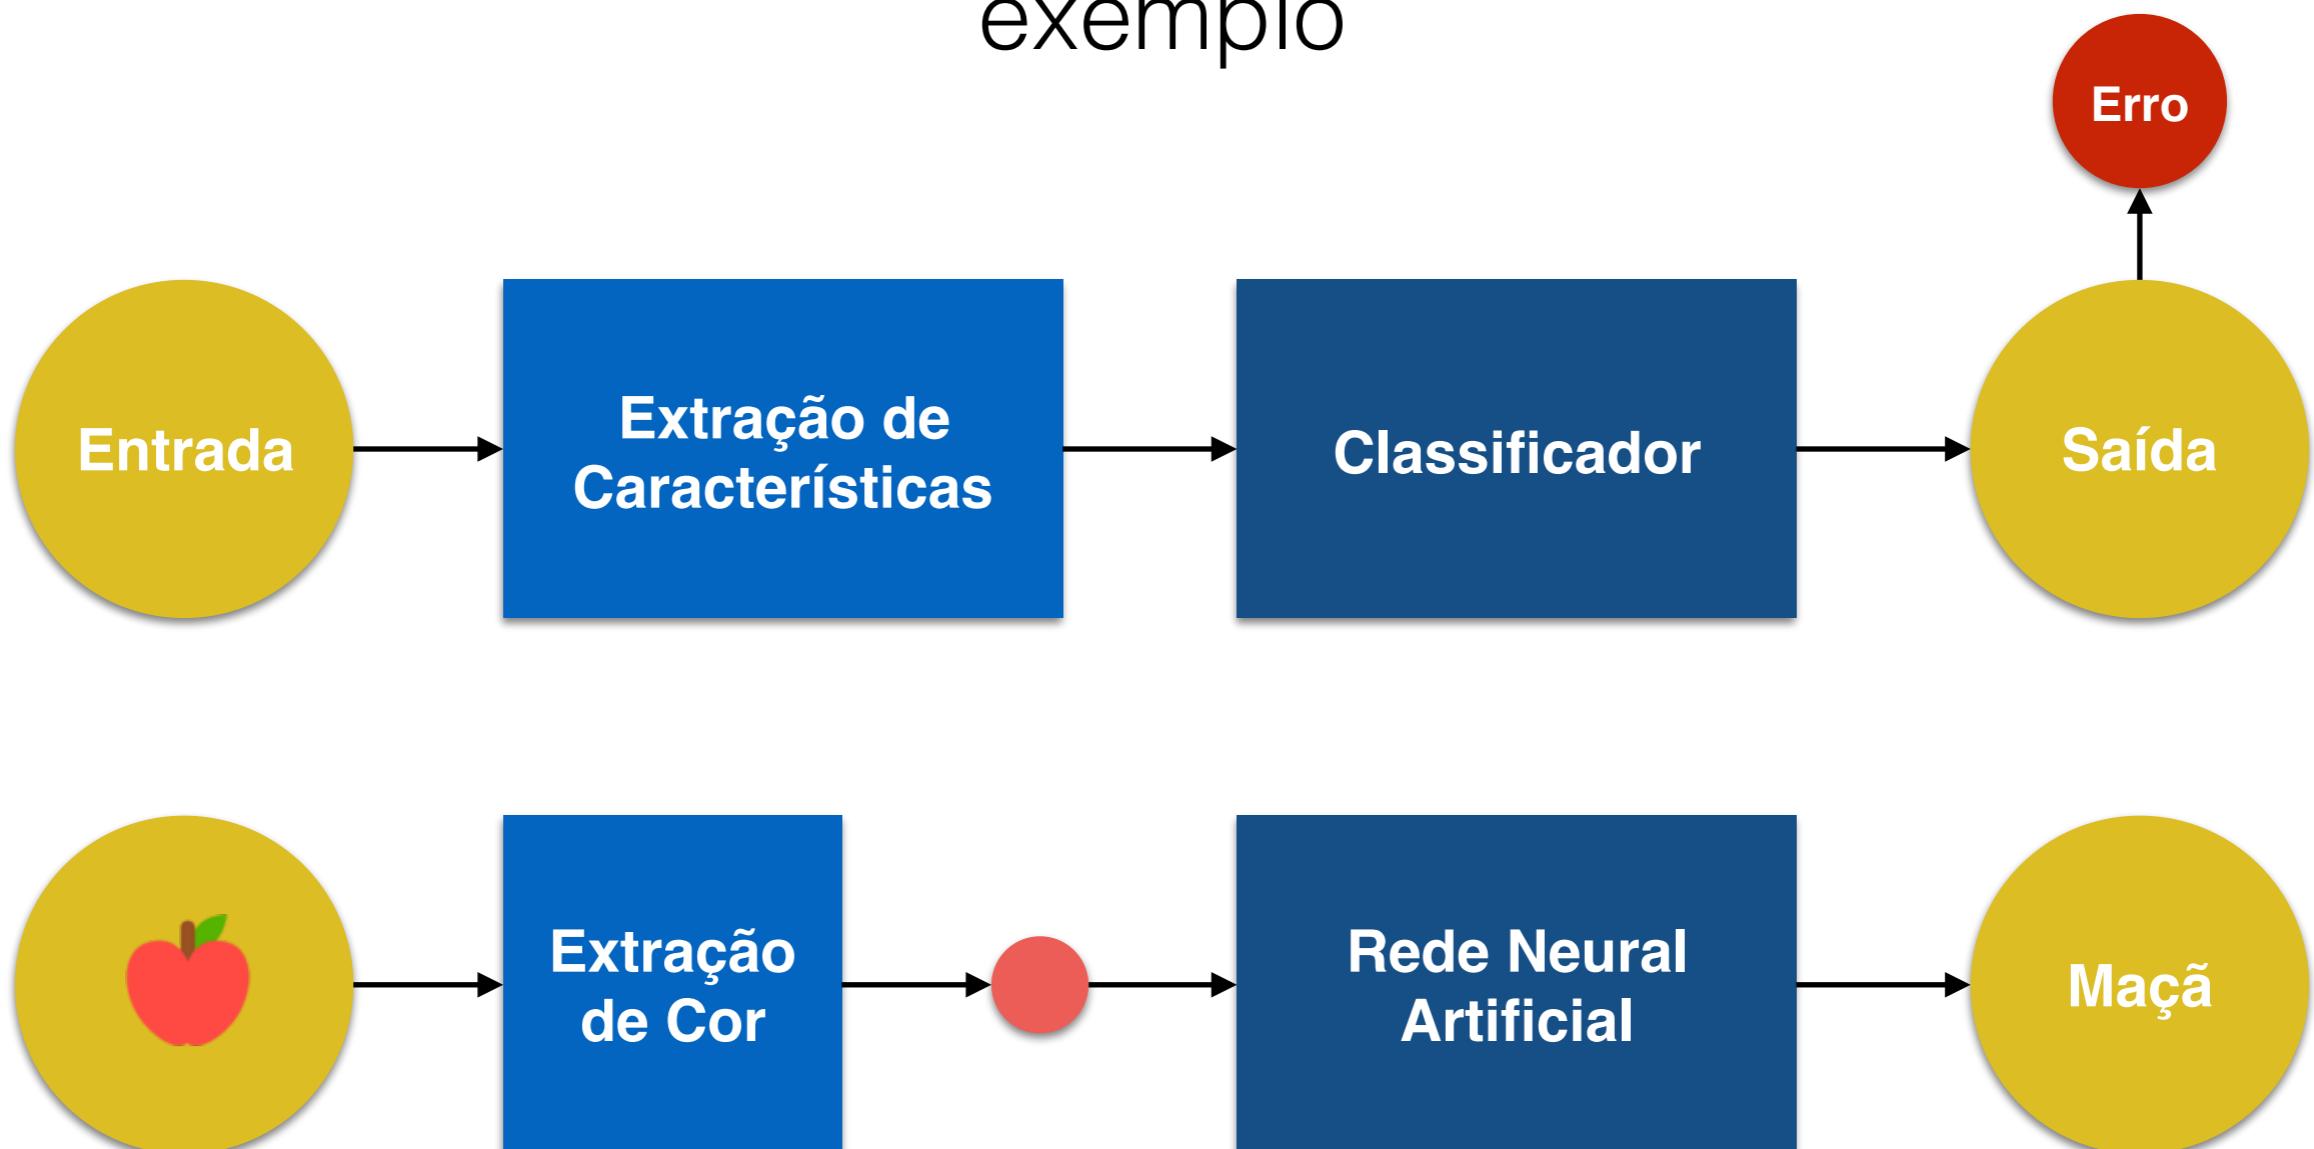
Pipeline Comum

exemplo



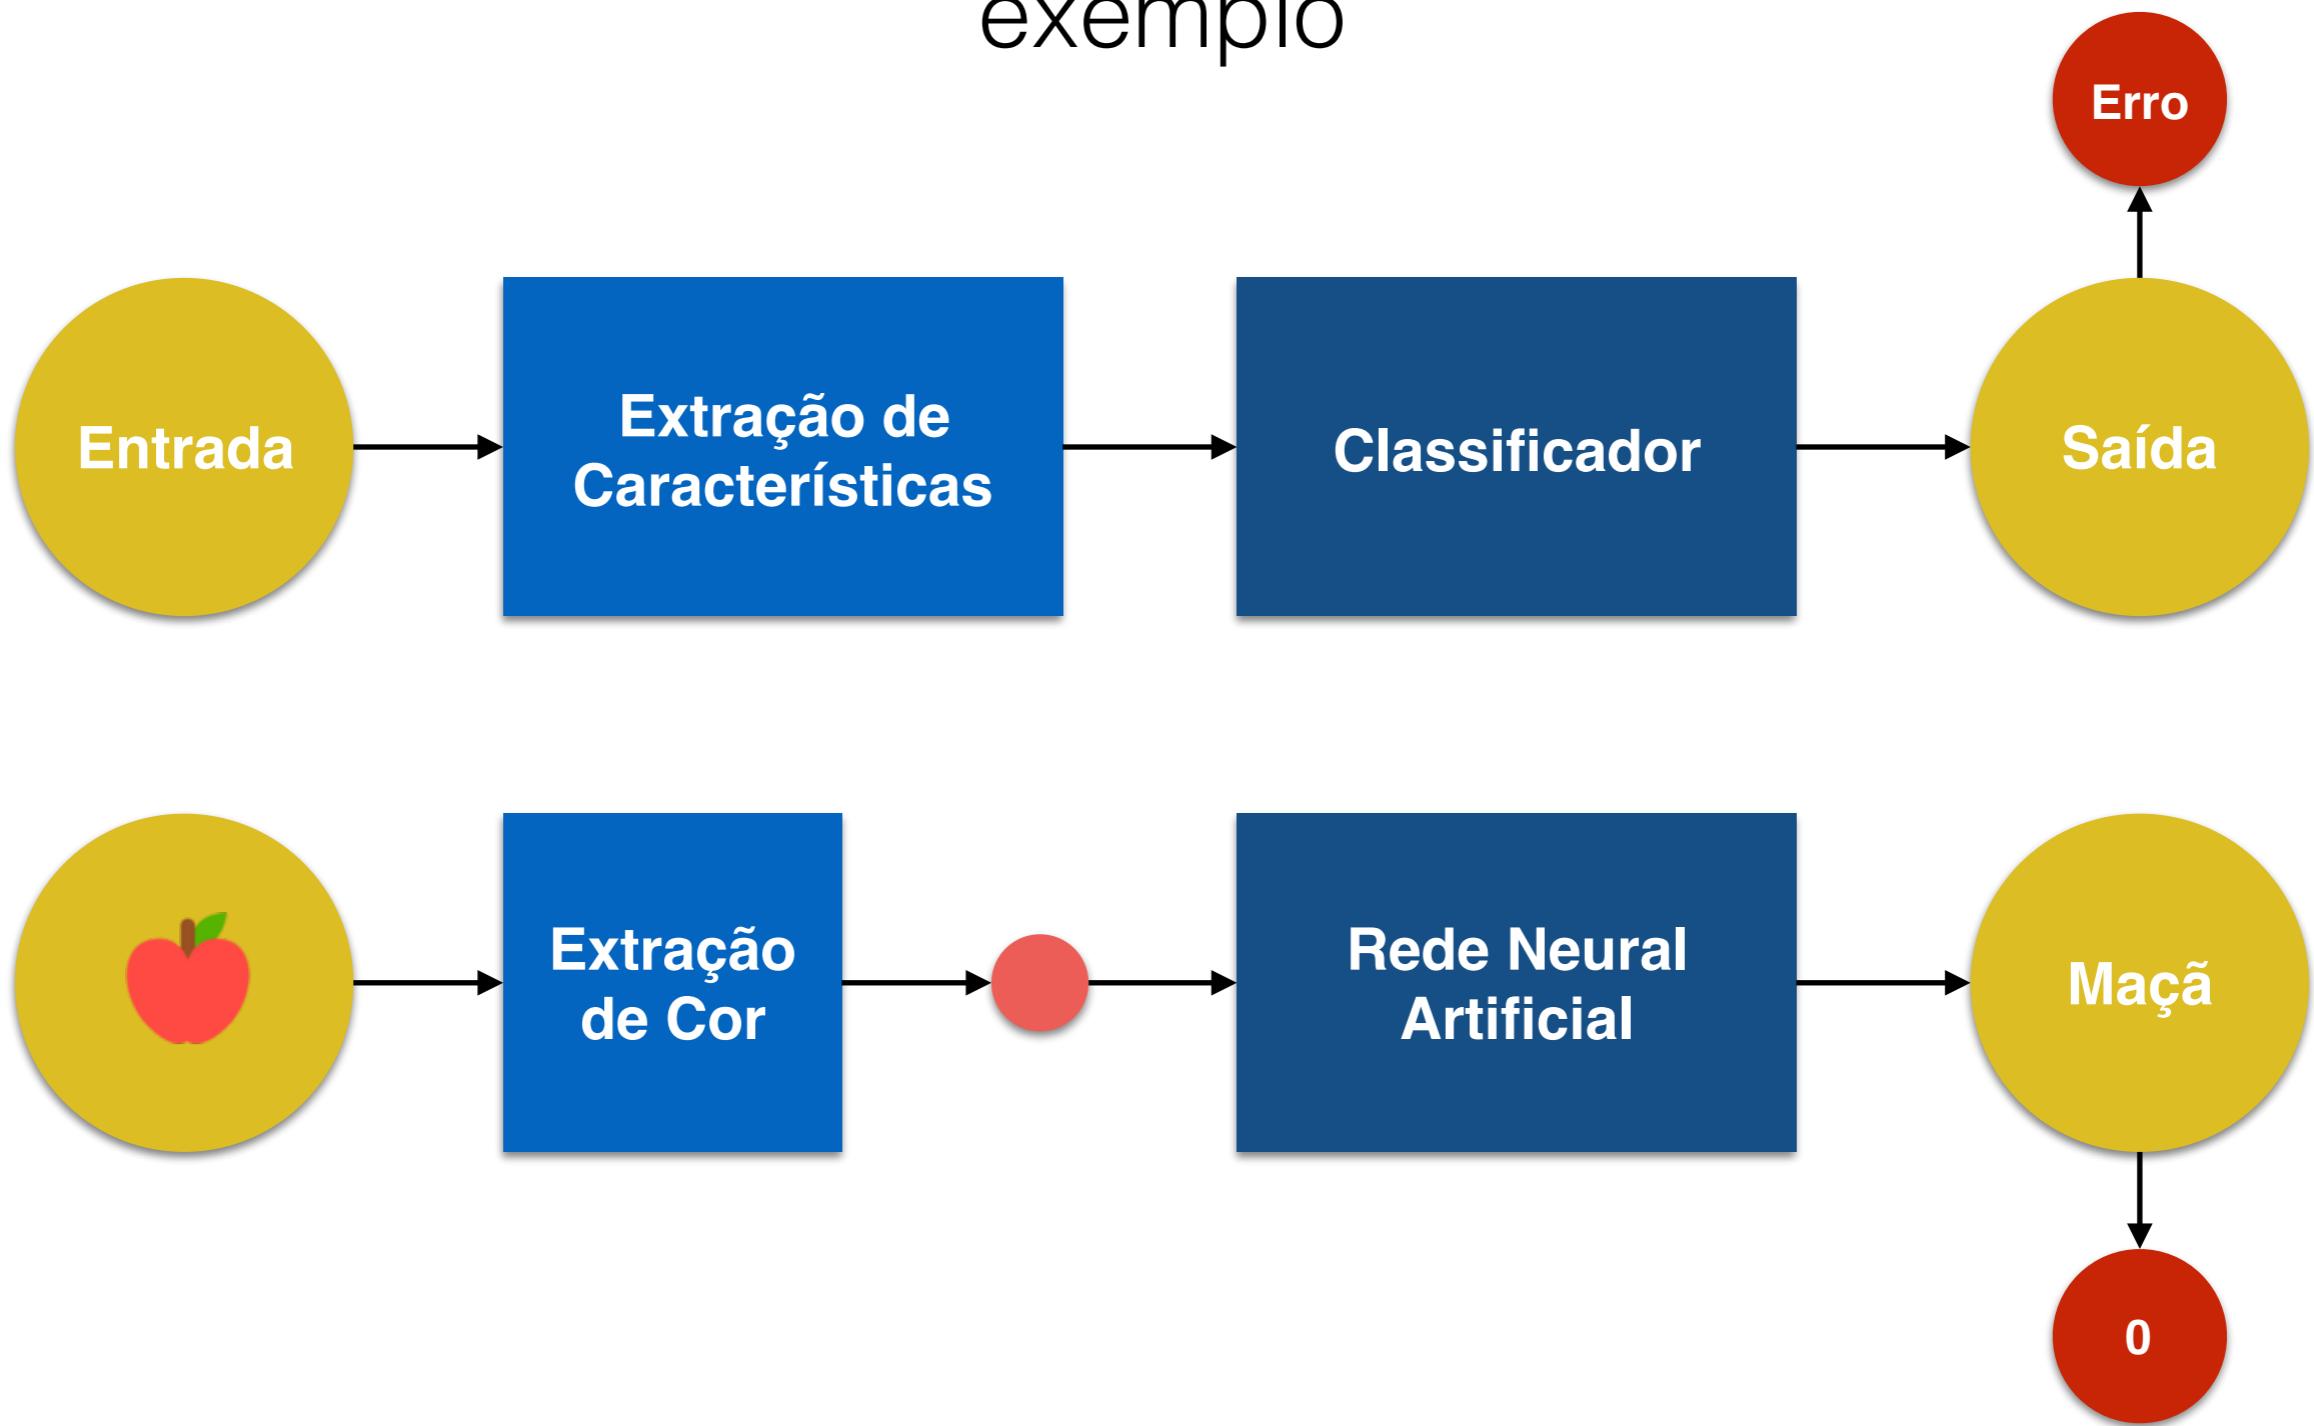
Pipeline Comum

exemplo



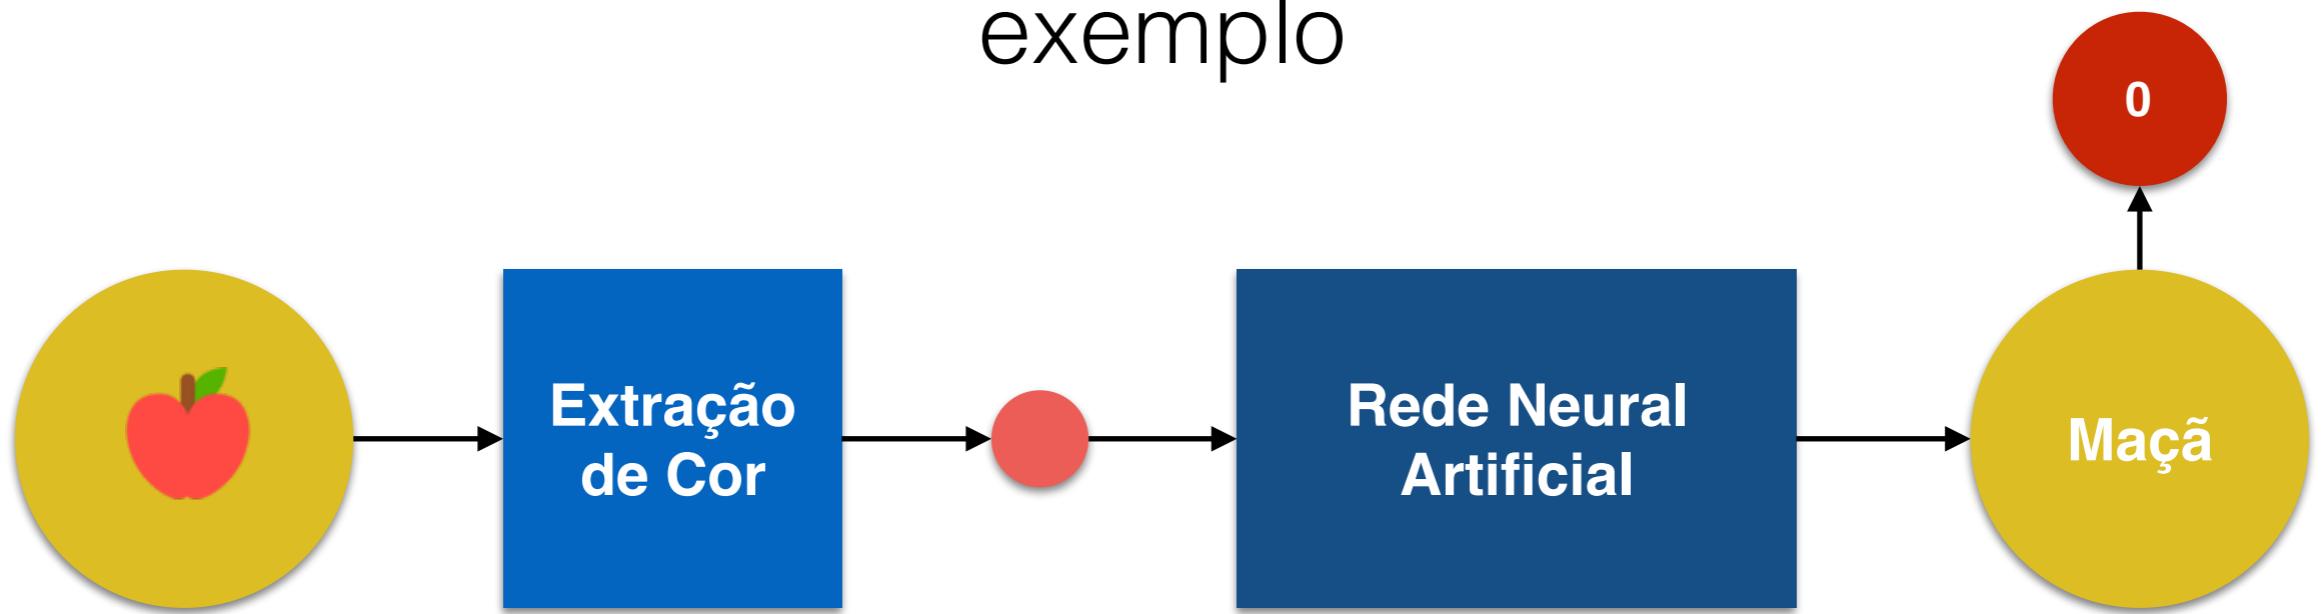
Pipeline Comum

exemplo



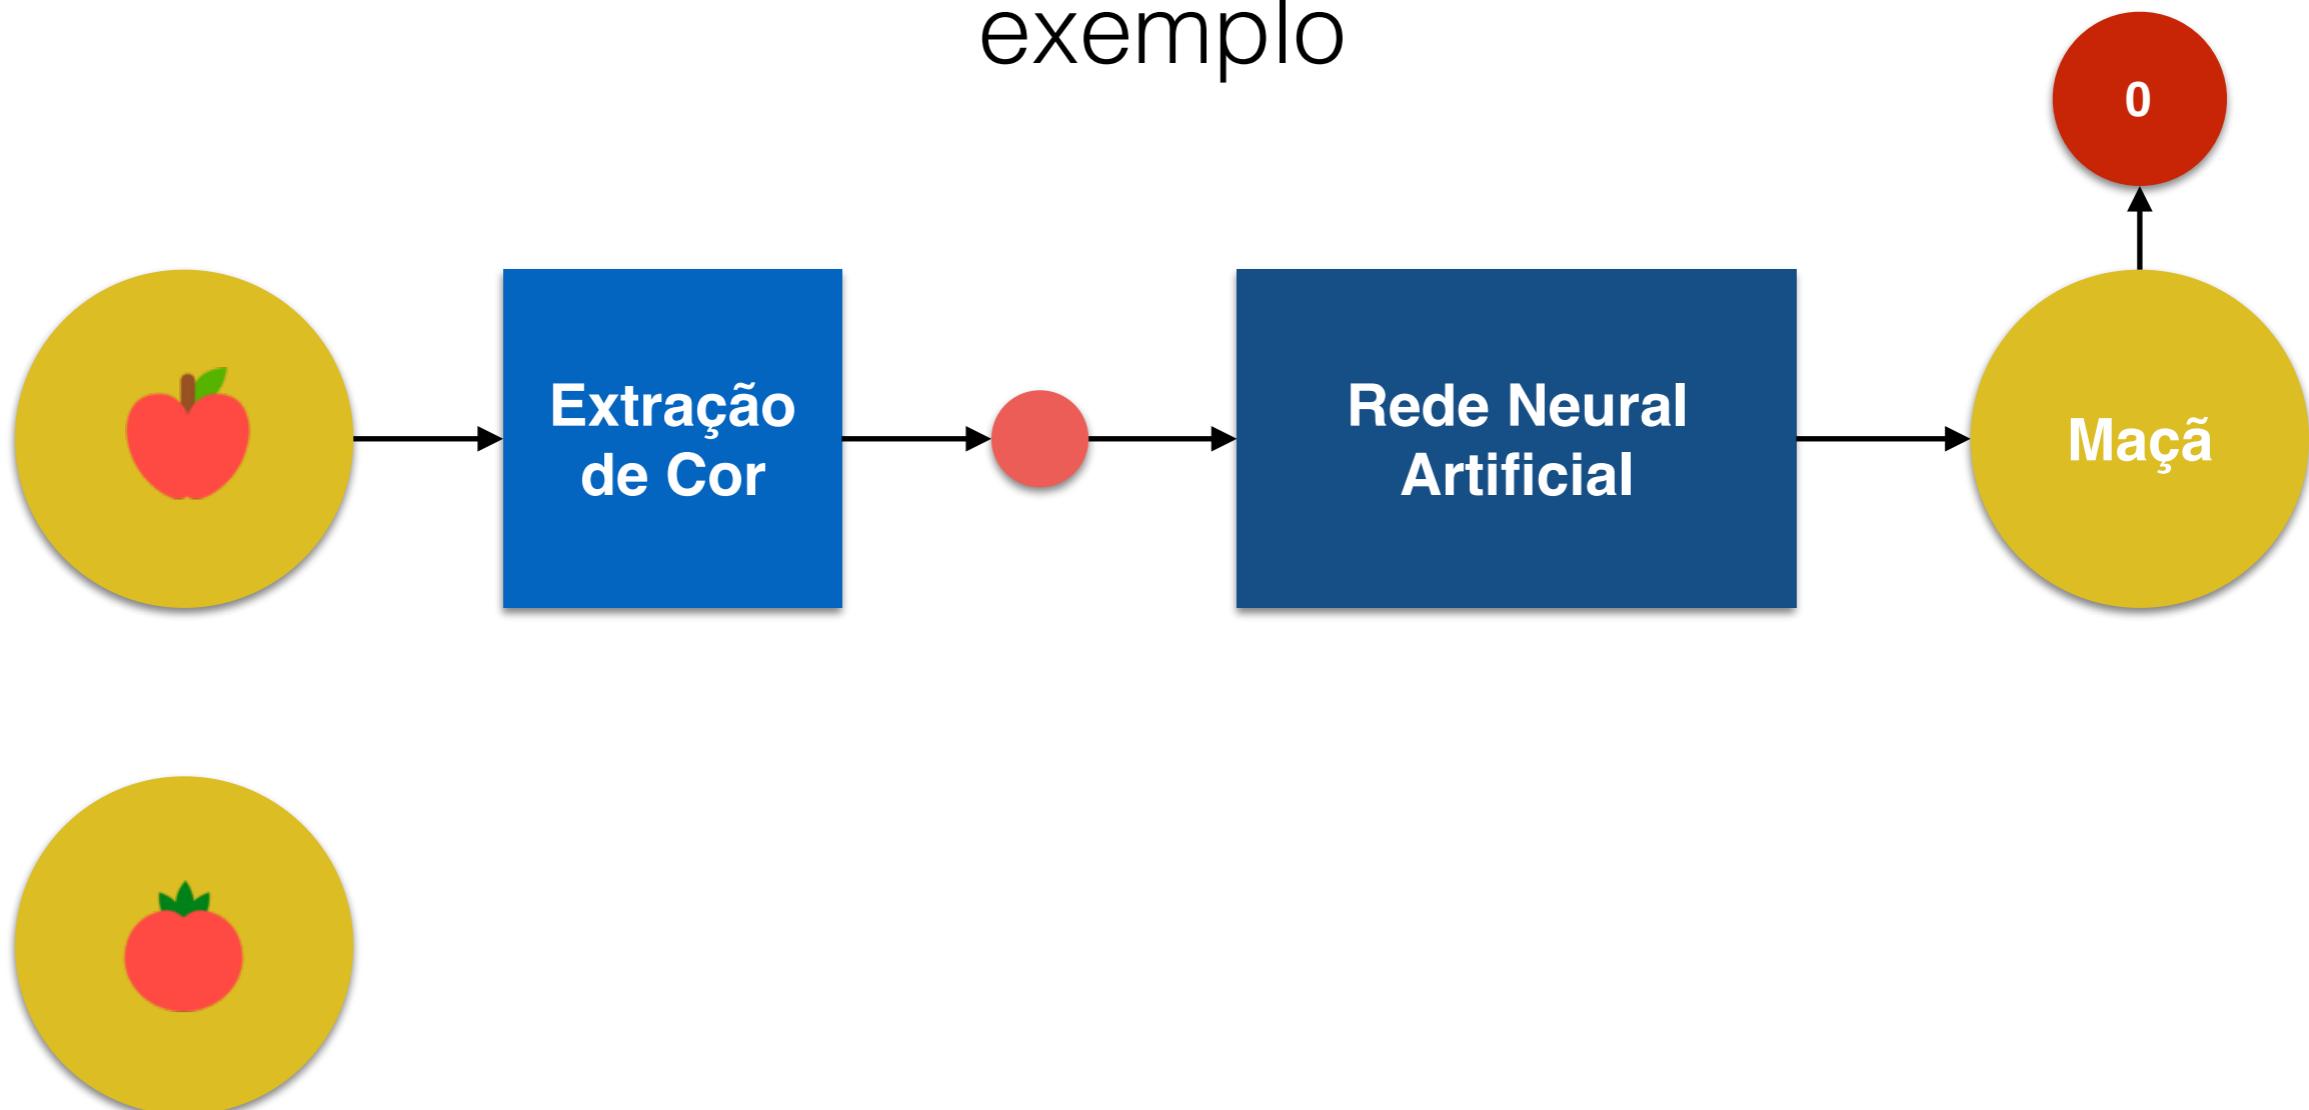
Pipeline Comum

exemplo



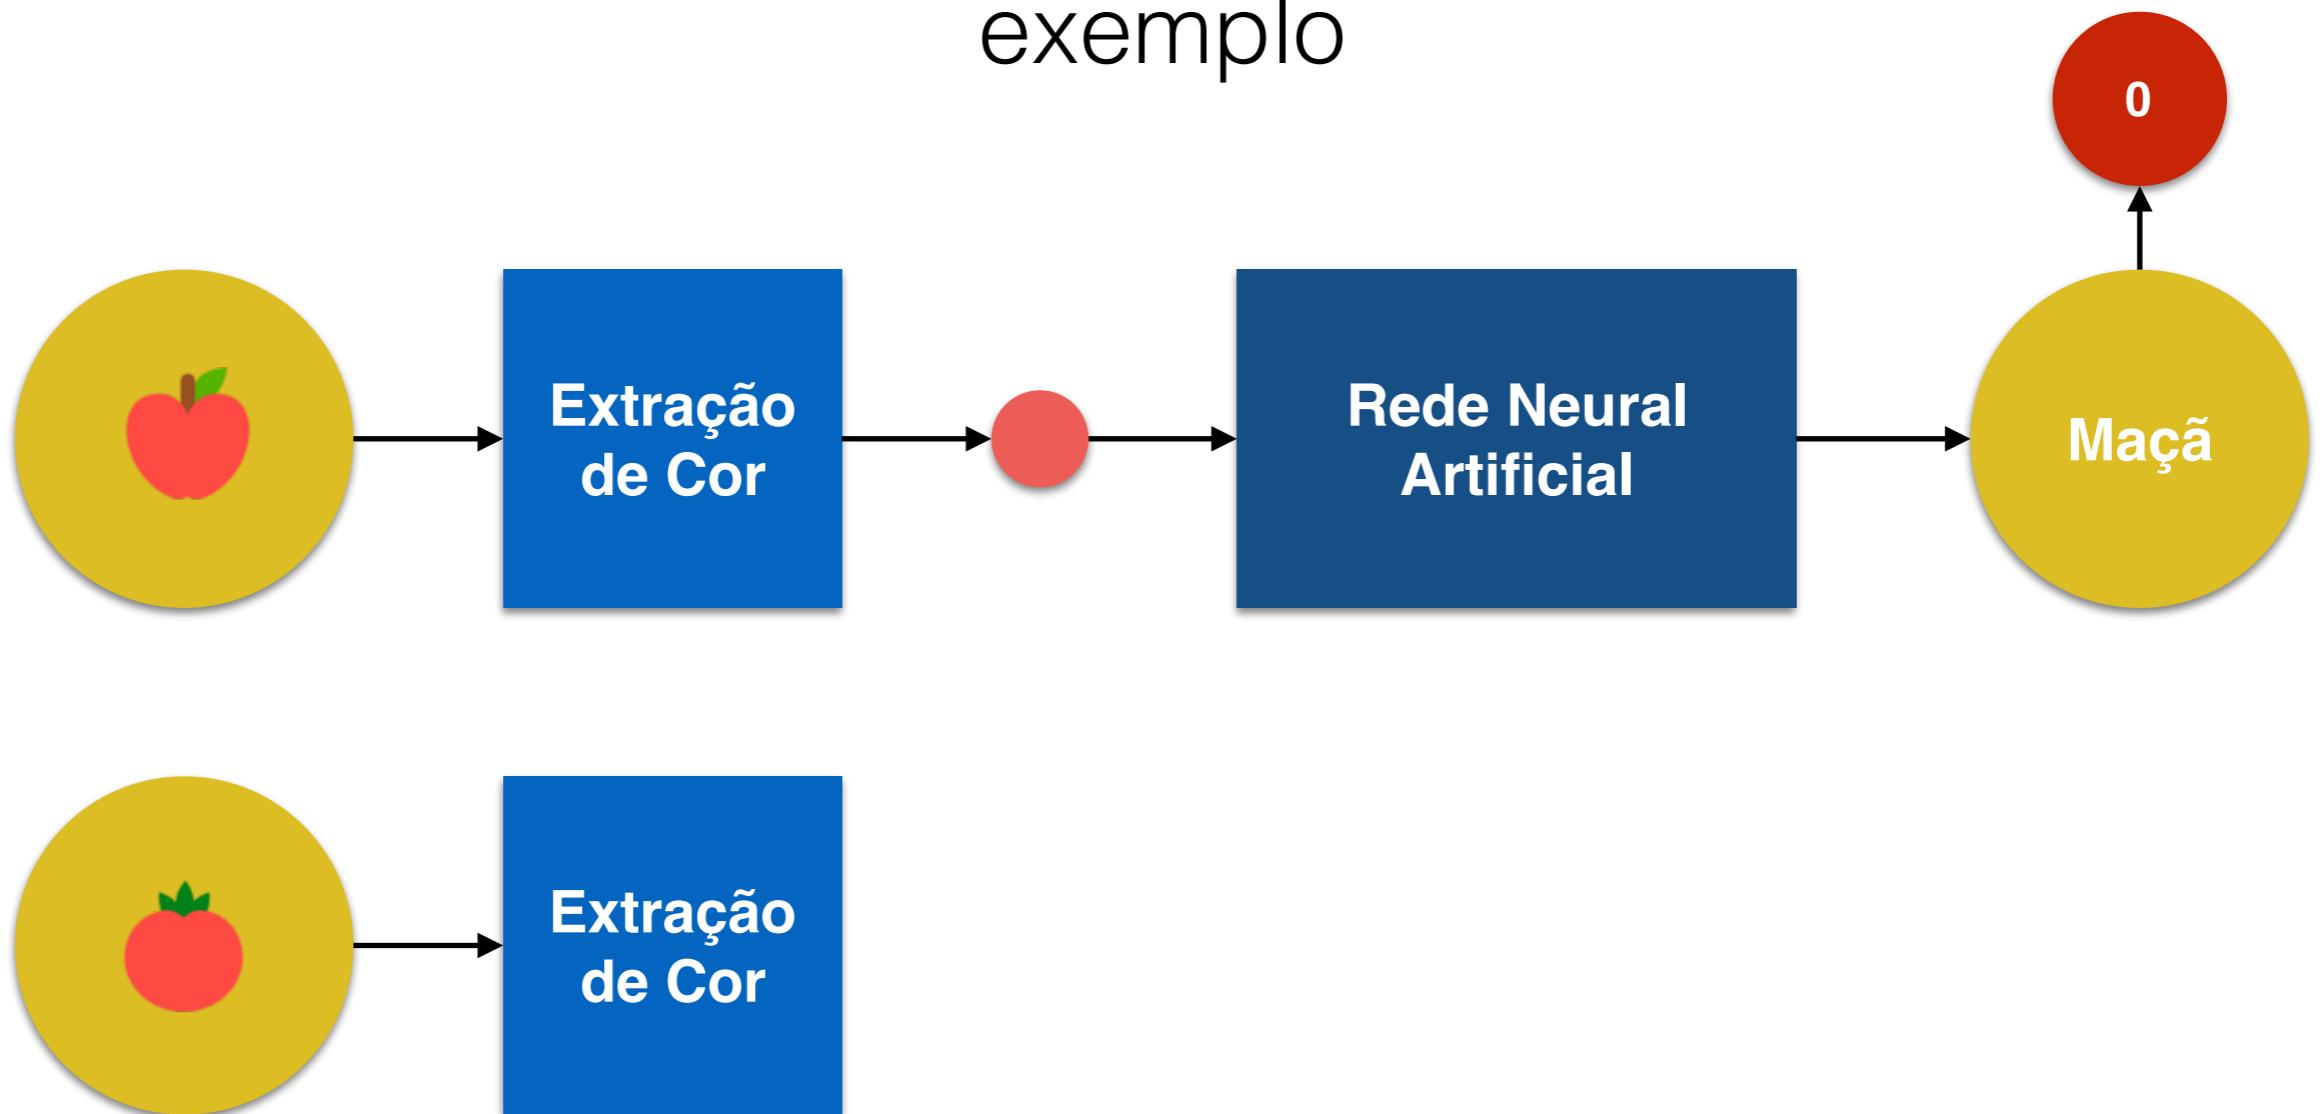
Pipeline Comum

exemplo



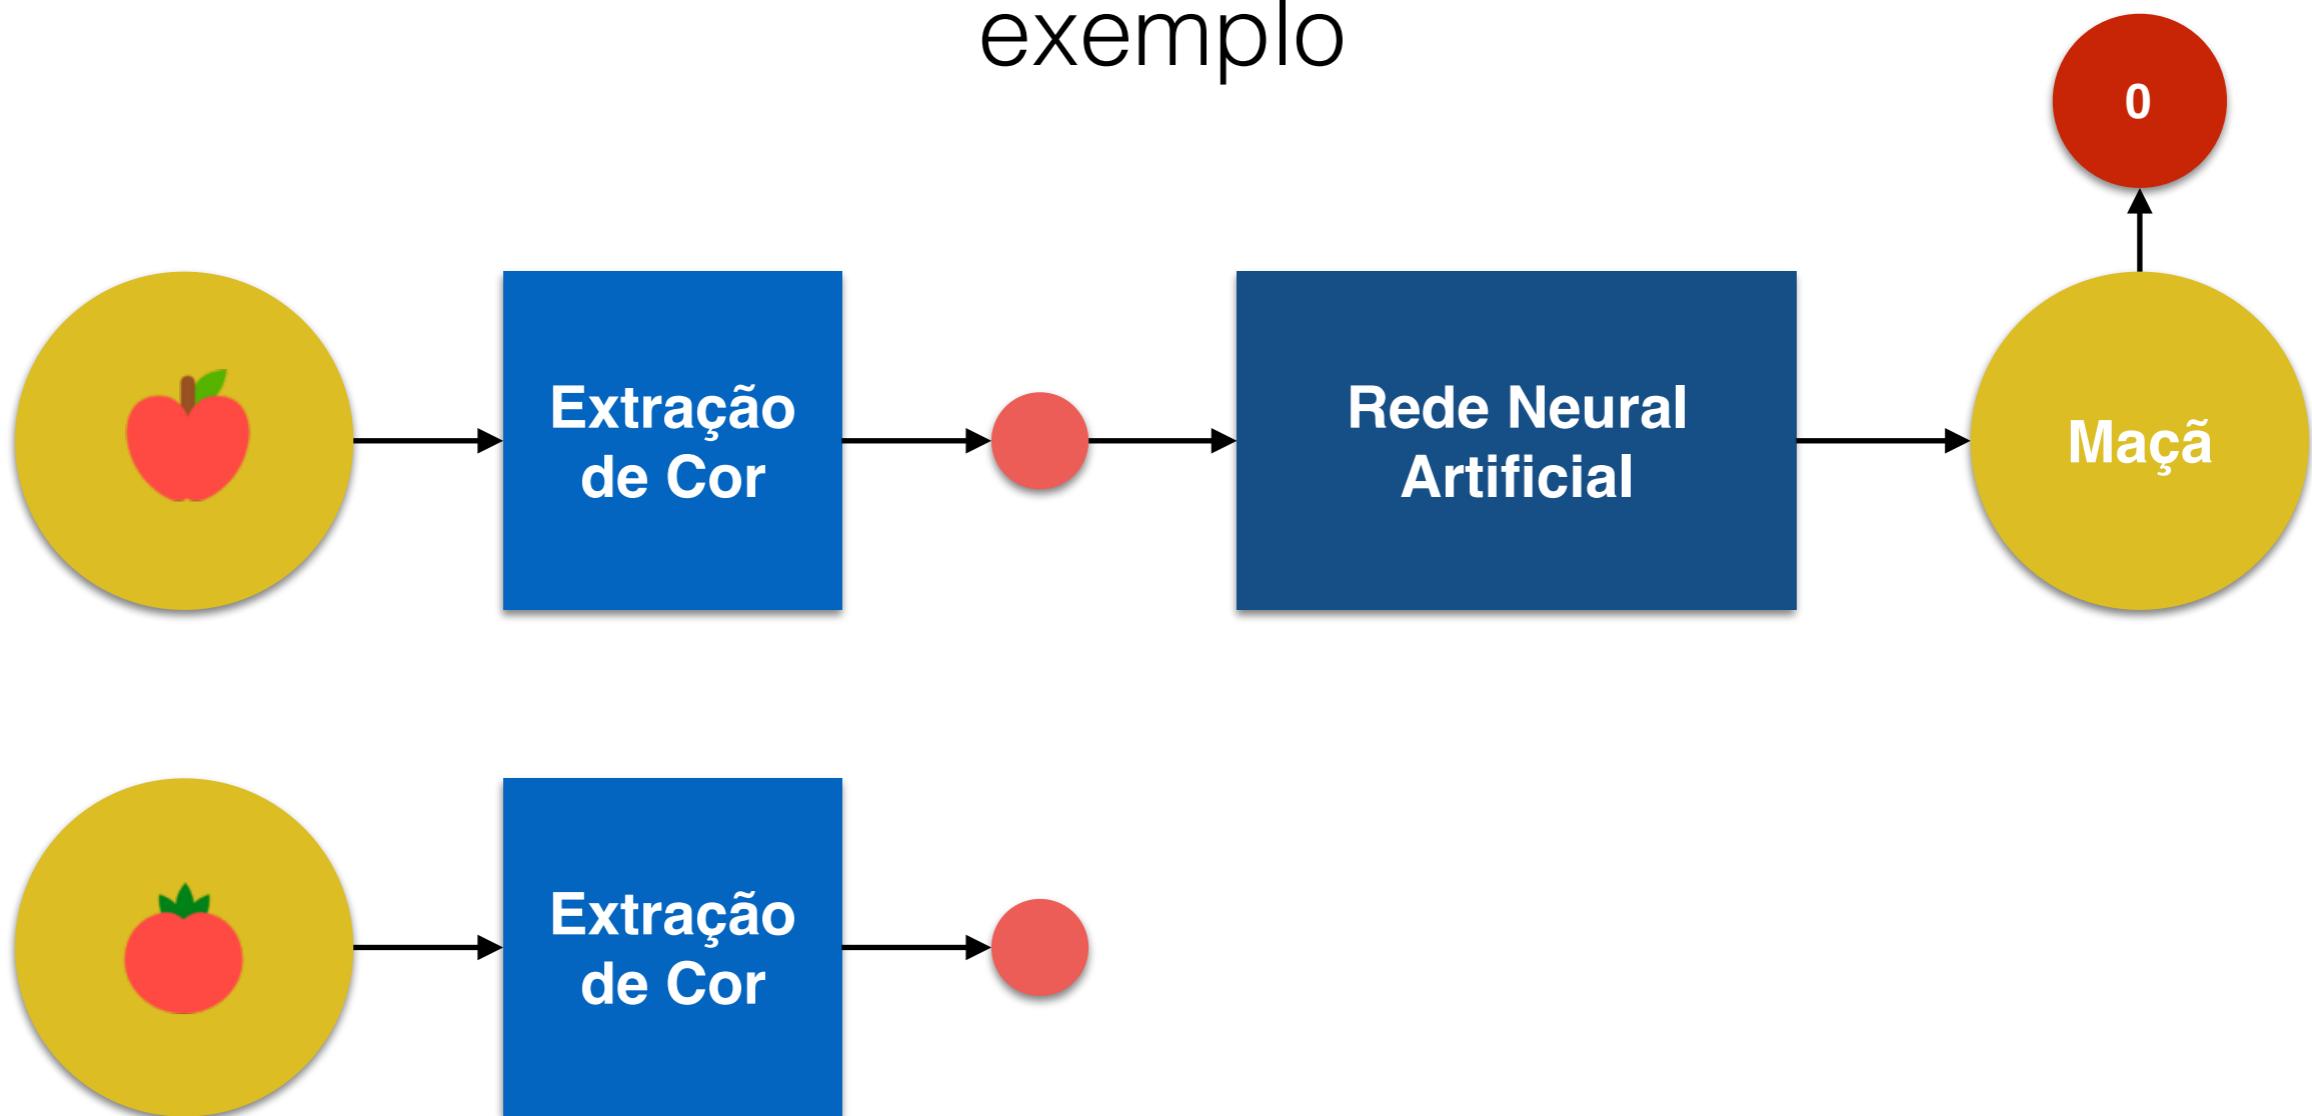
Pipeline Comum

exemplo



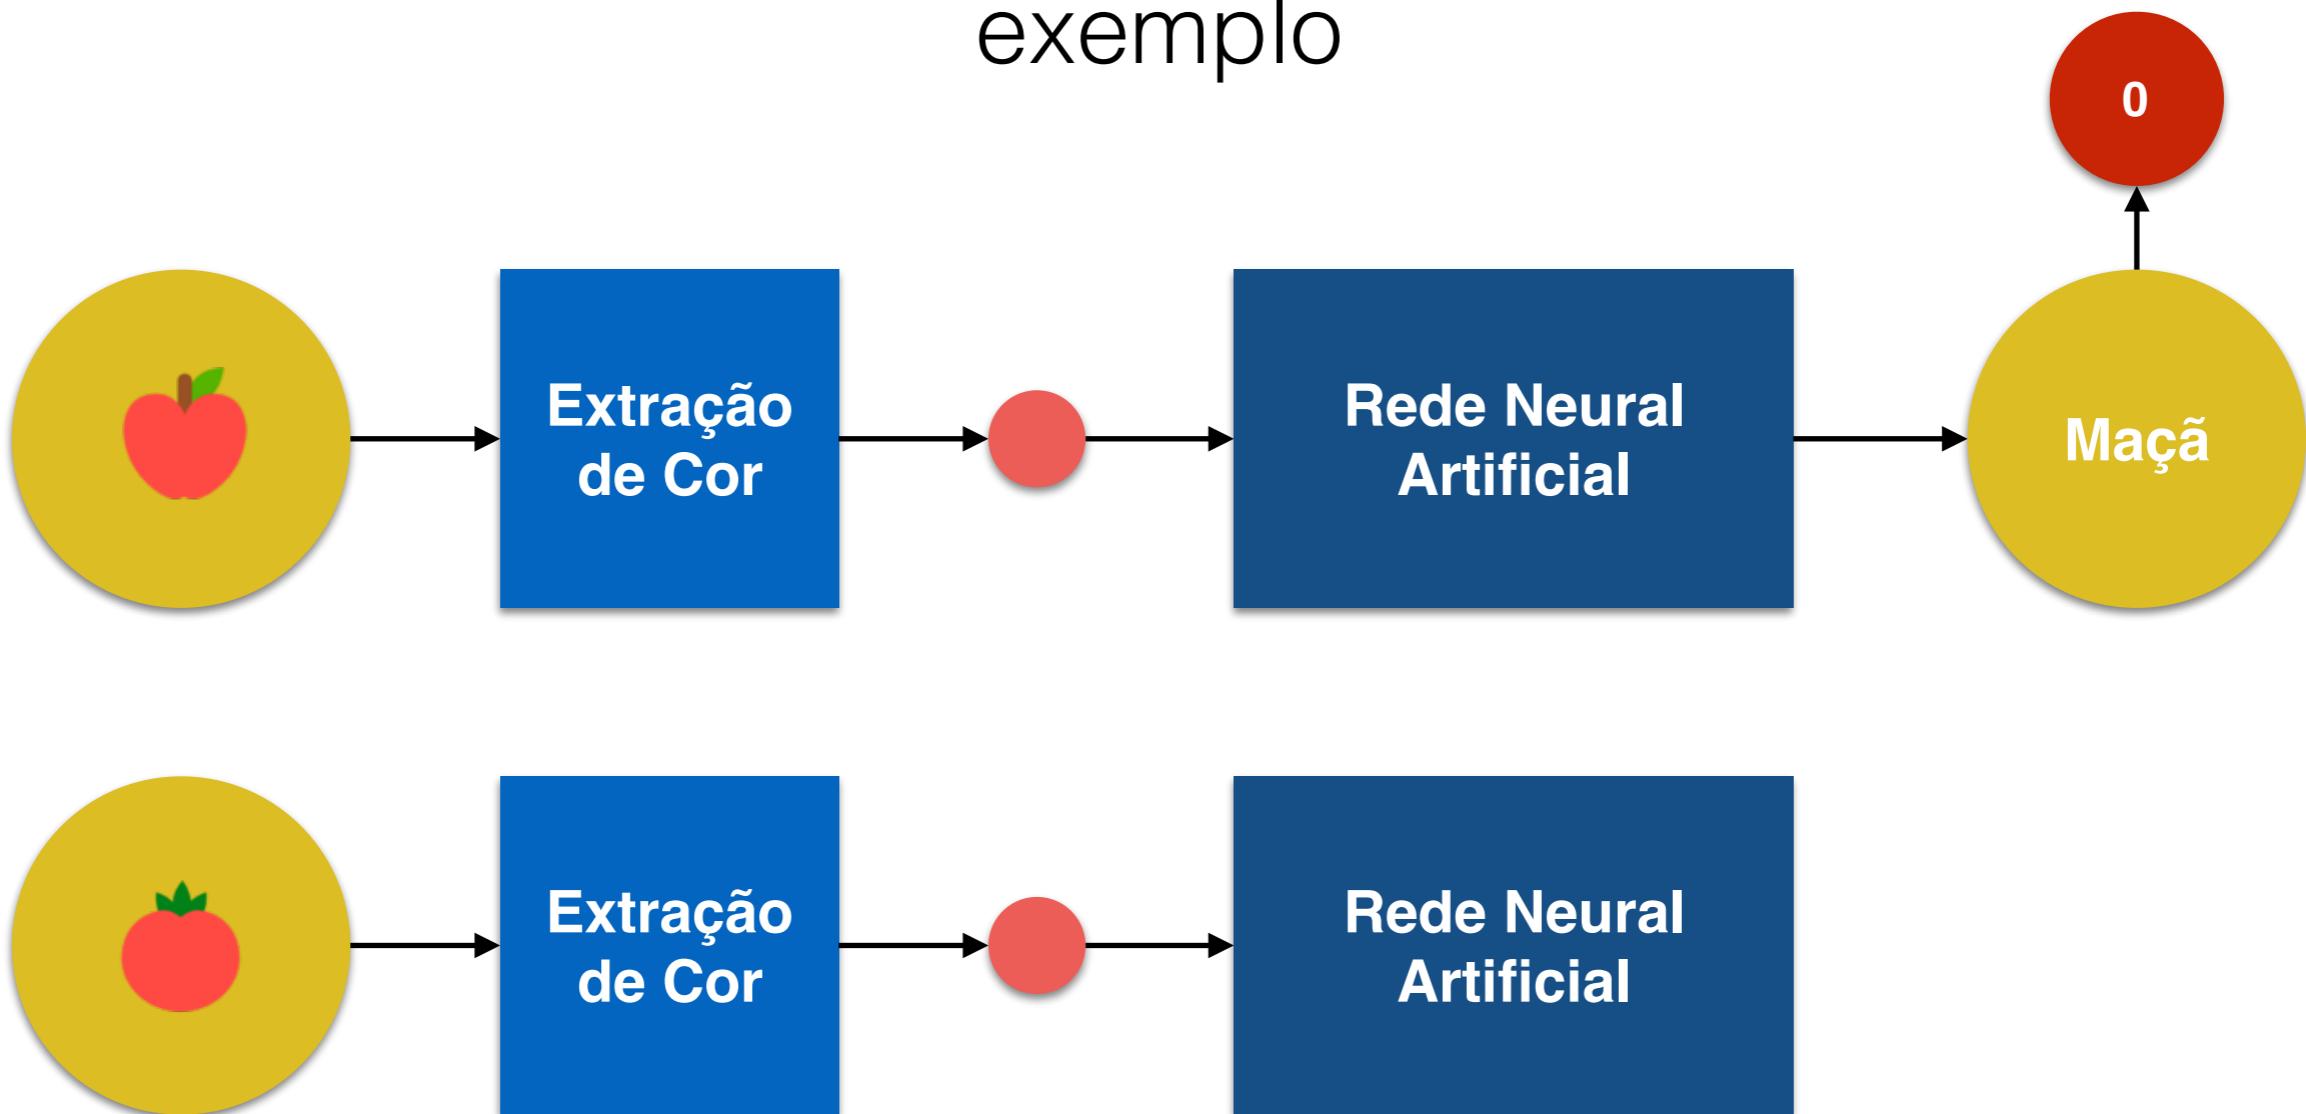
Pipeline Comum

exemplo



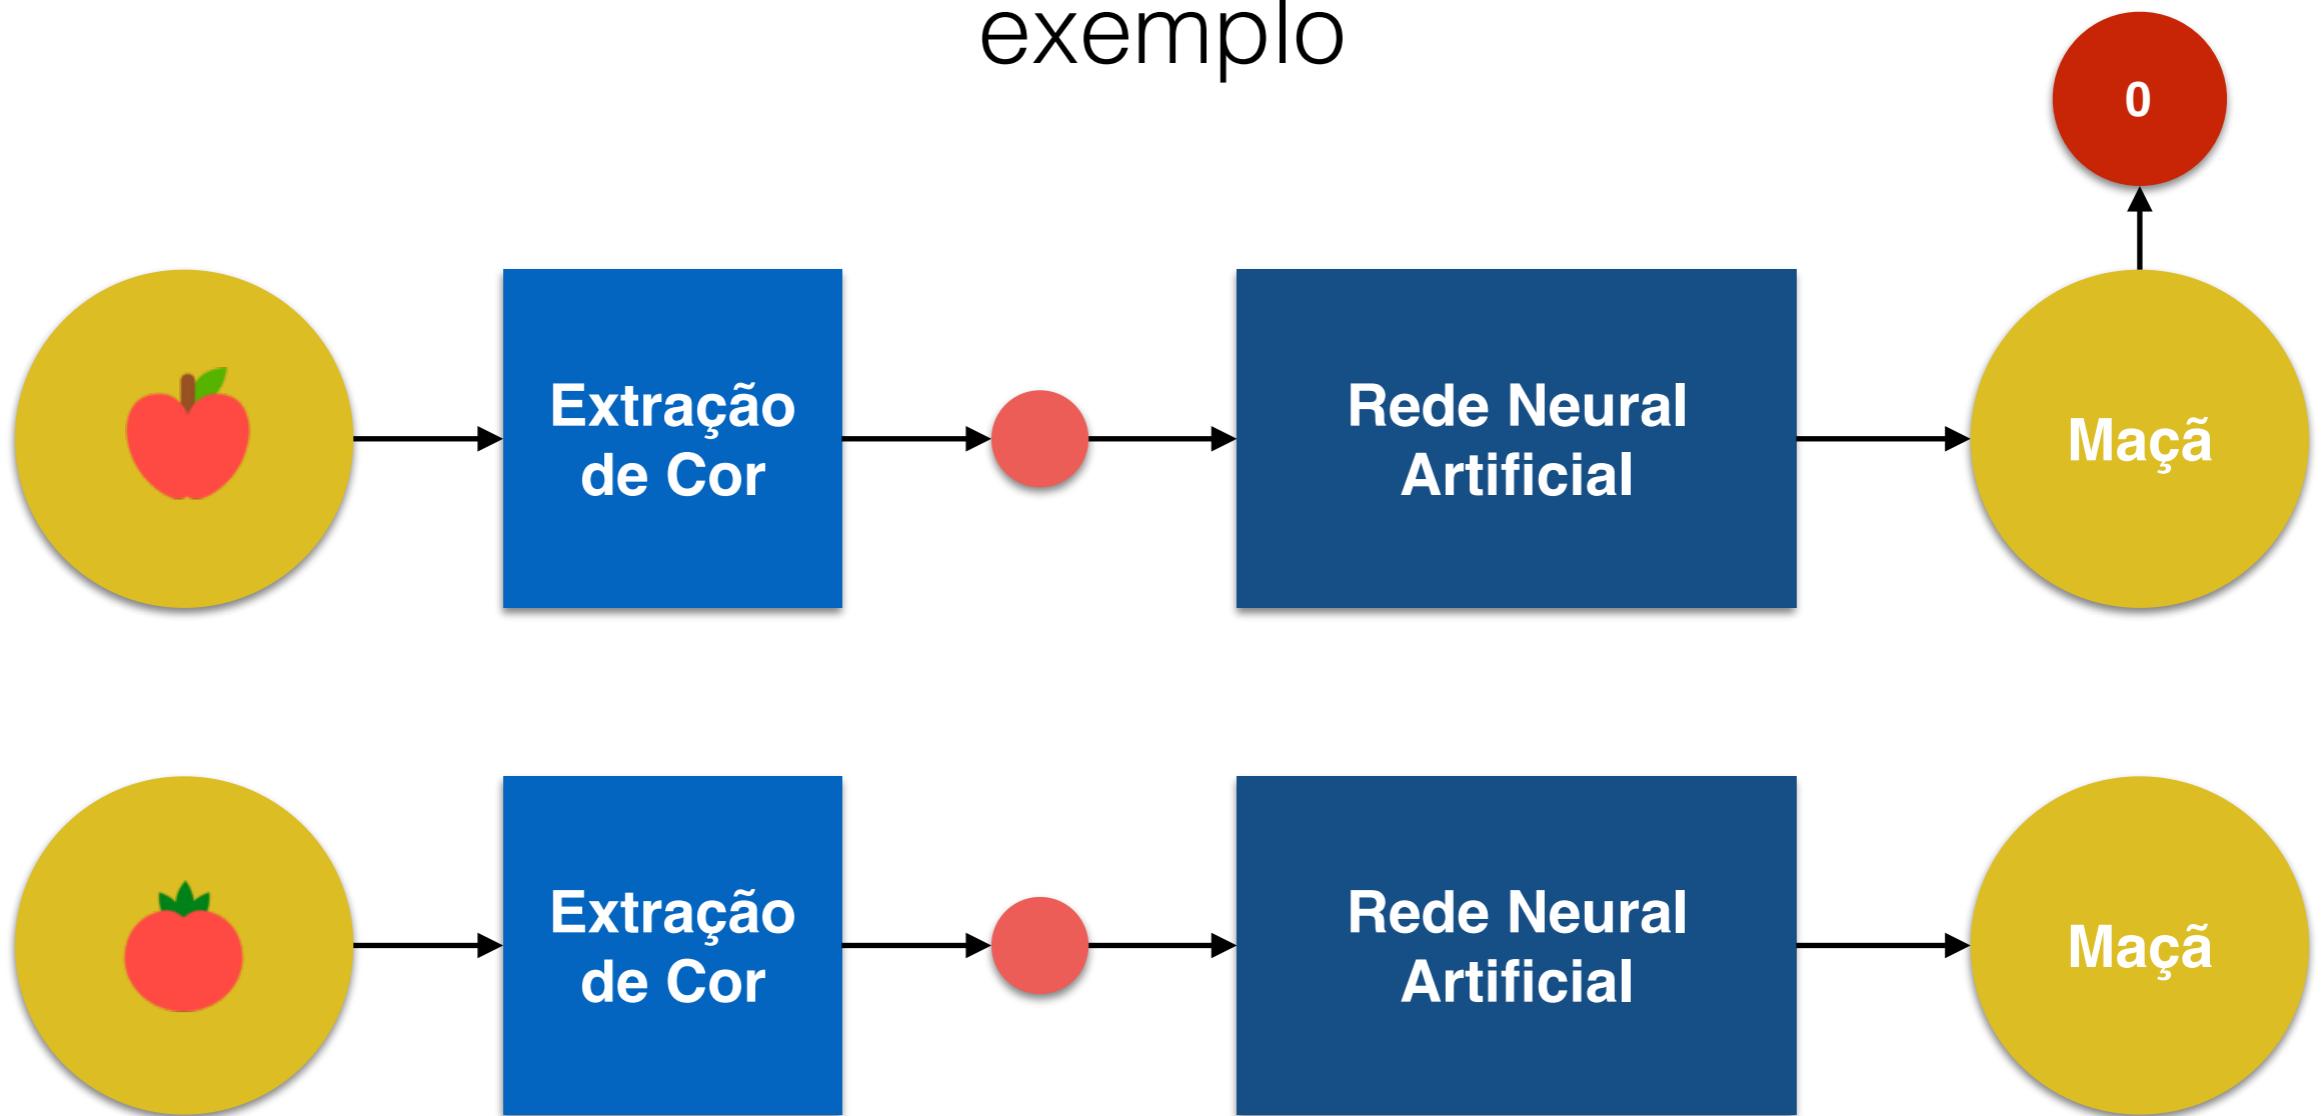
Pipeline Comum

exemplo



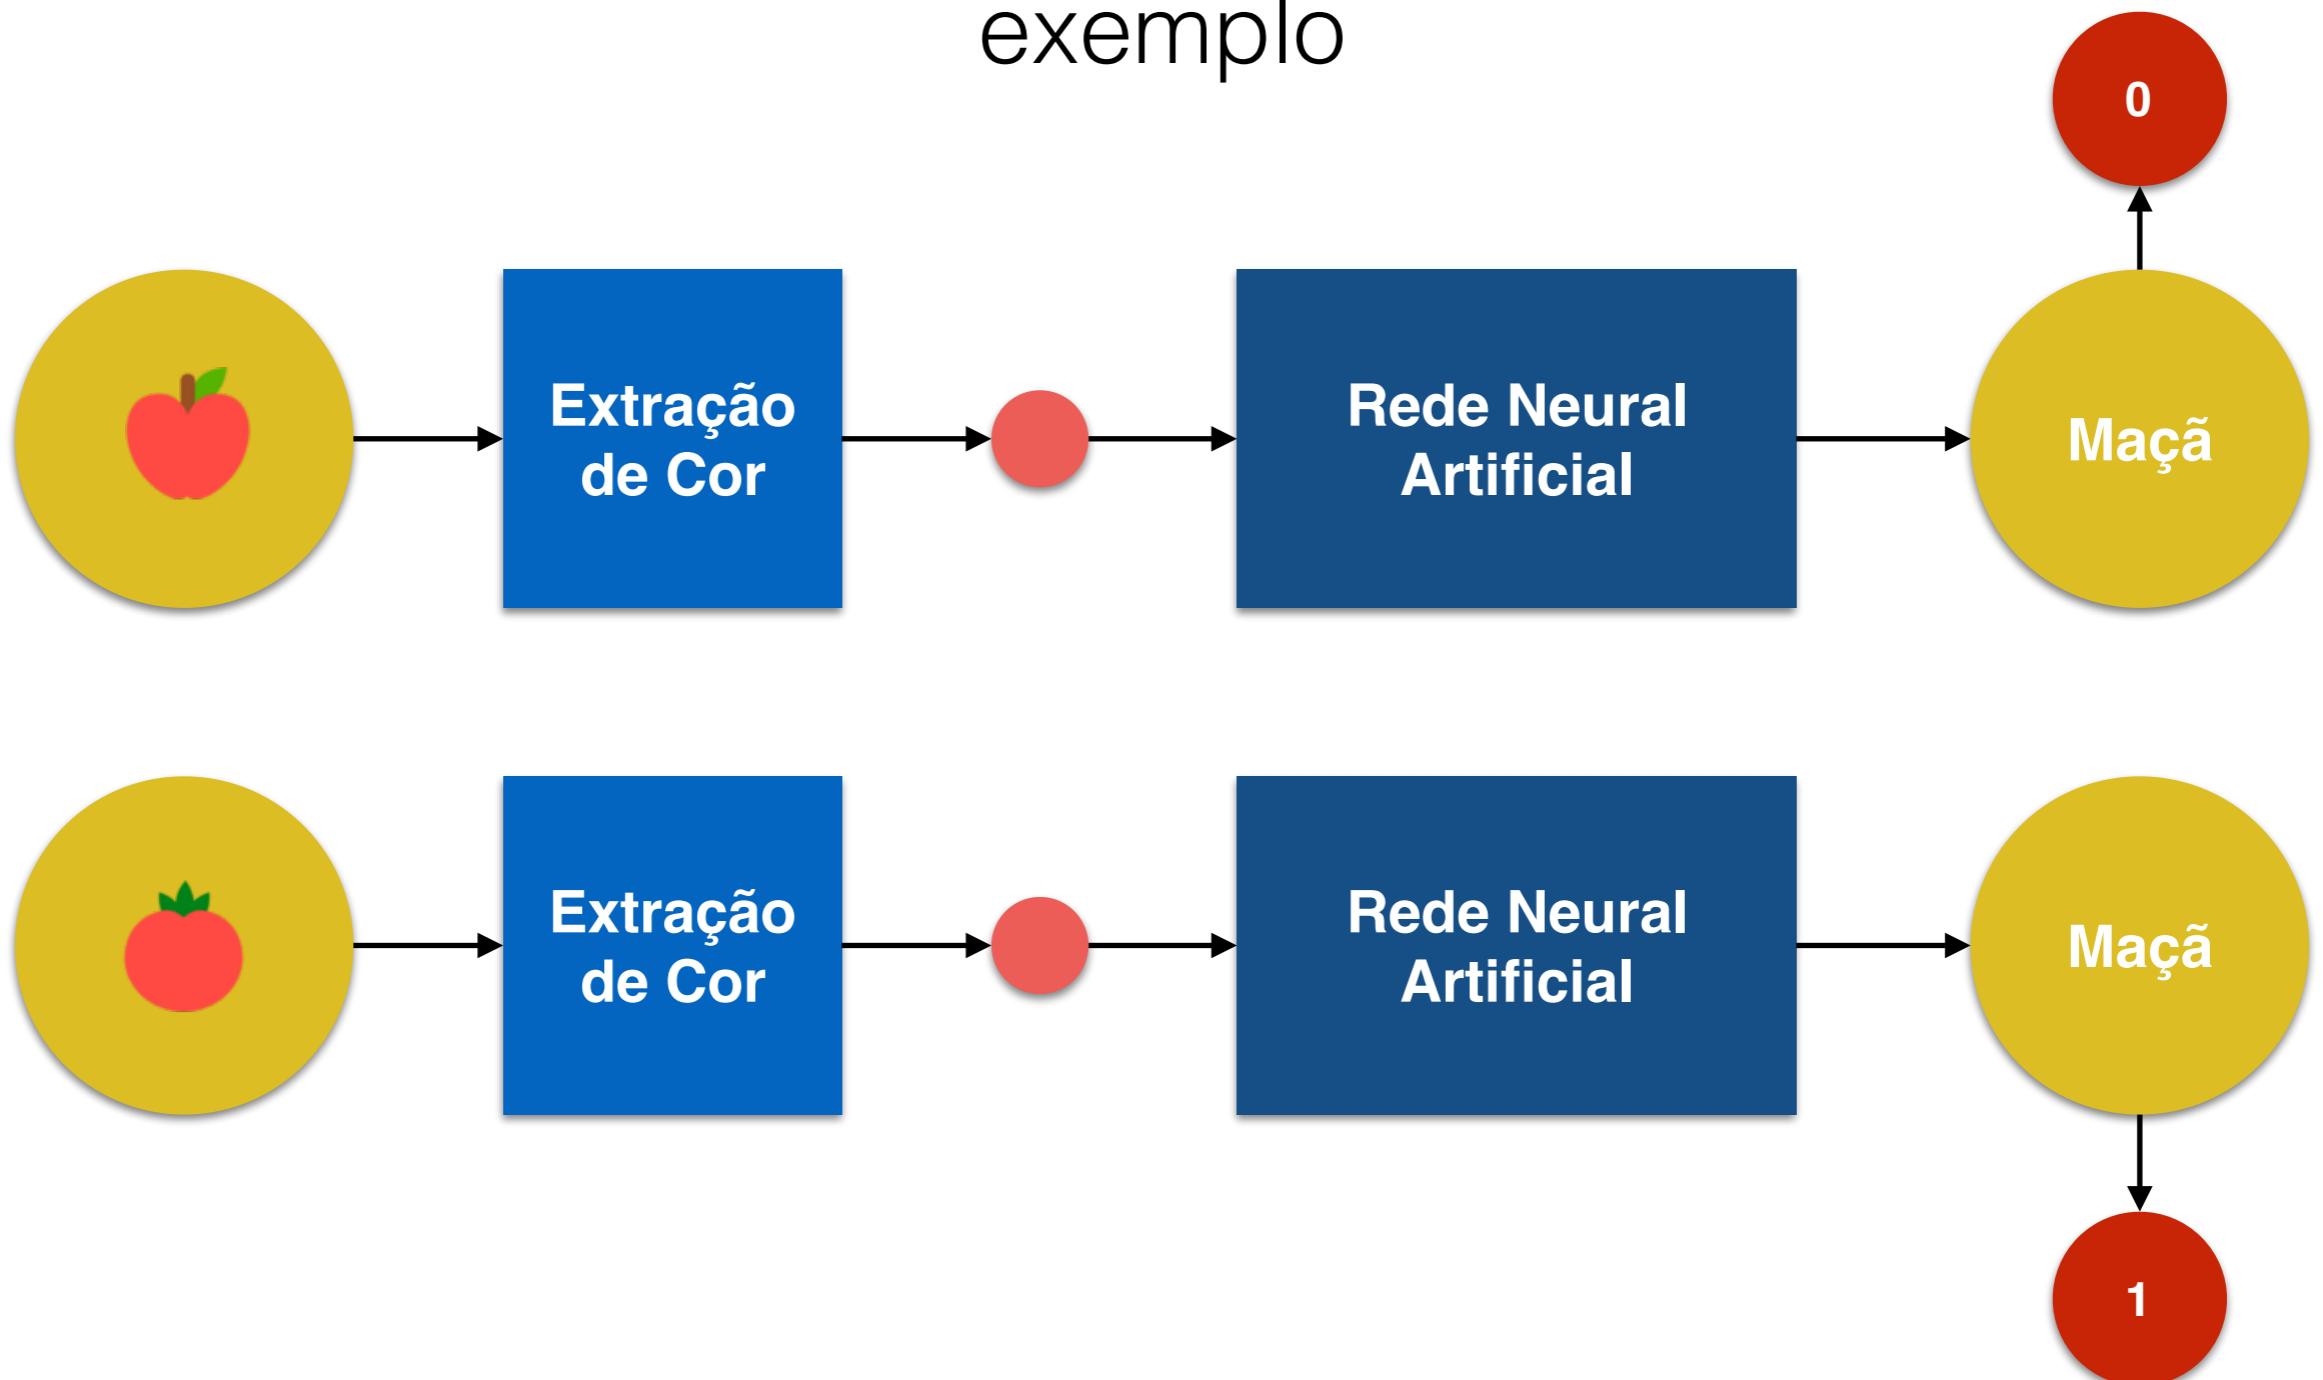
Pipeline Comum

exemplo



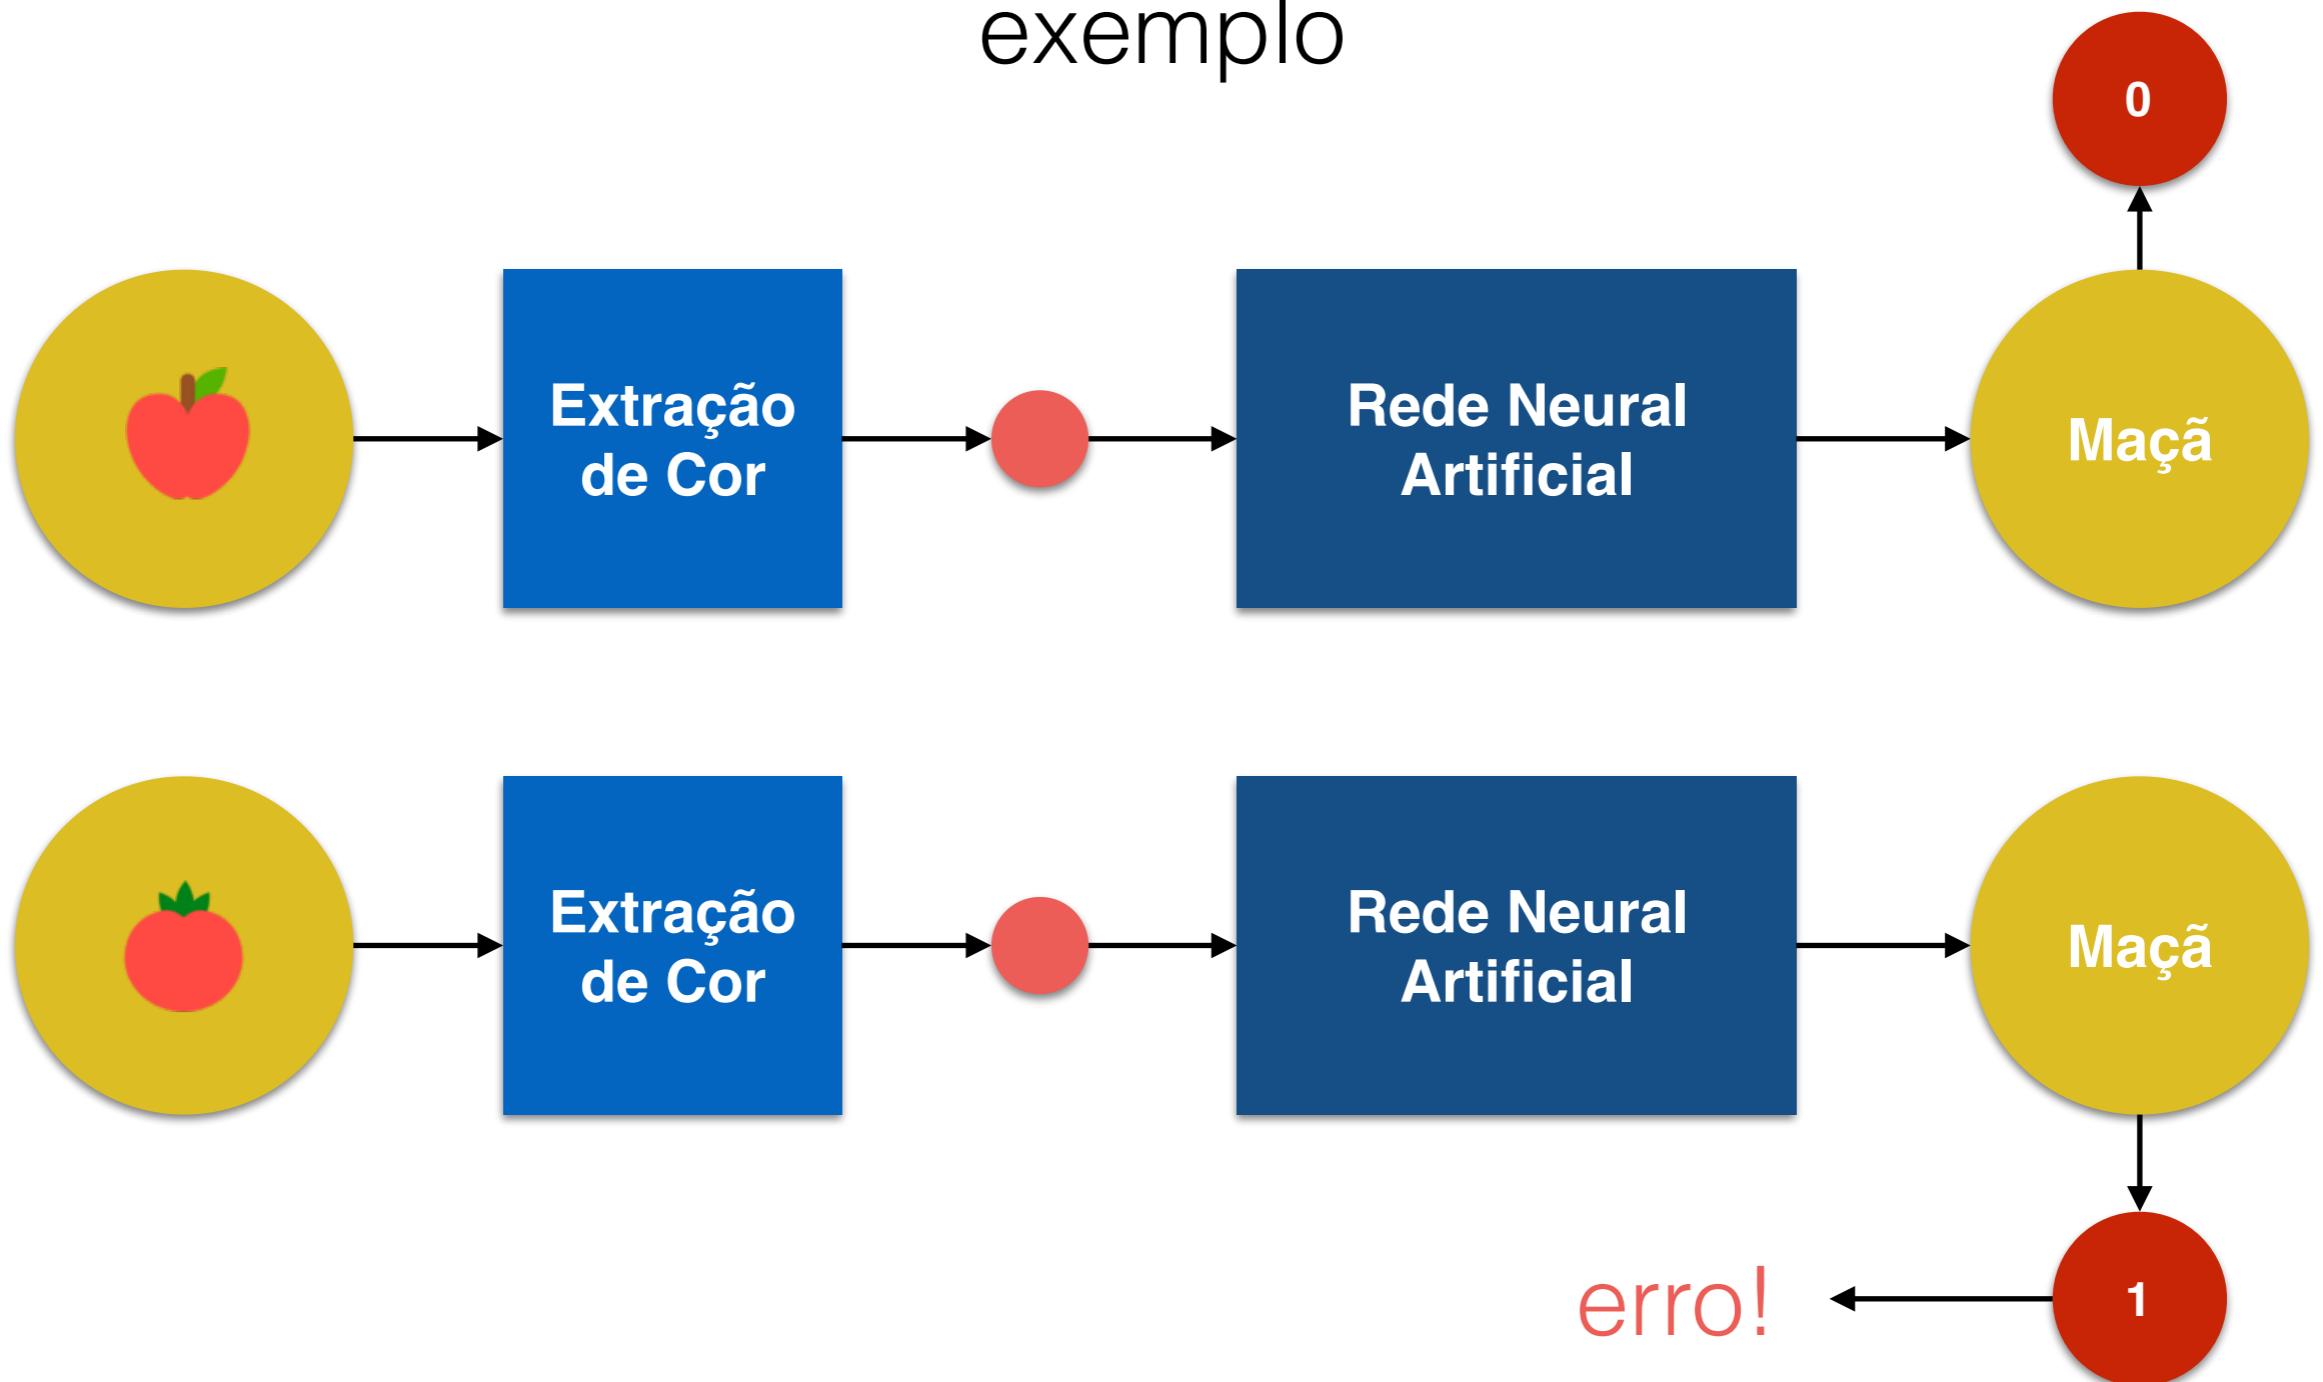
Pipeline Comum

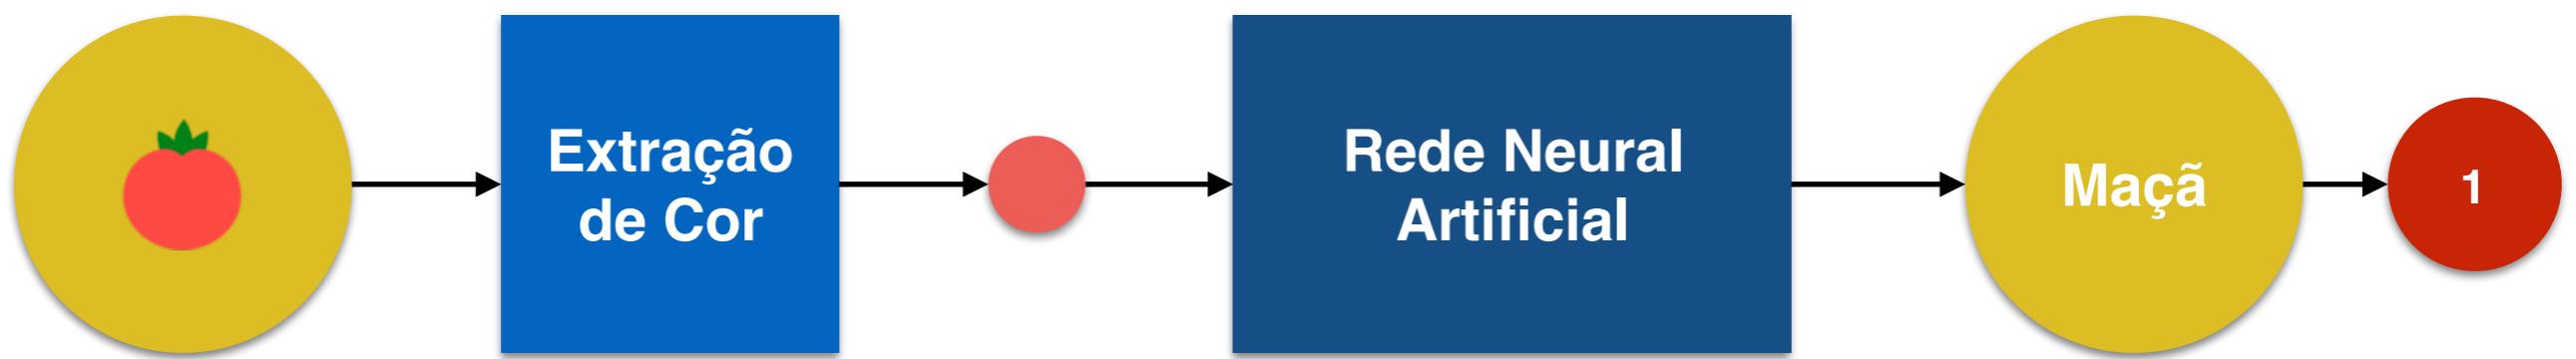
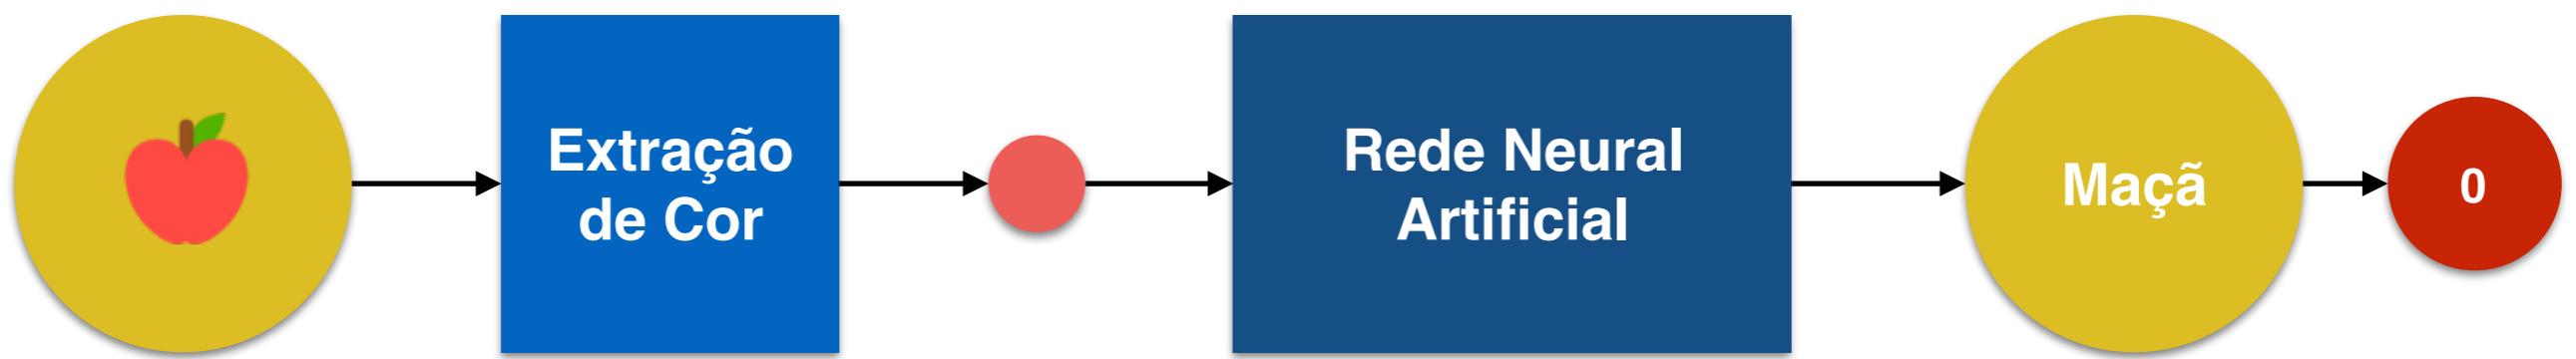
exemplo

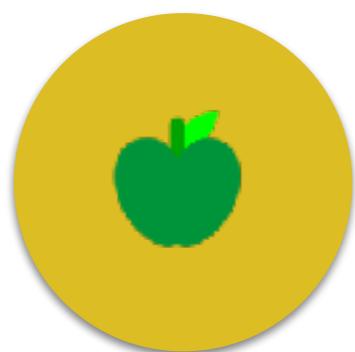
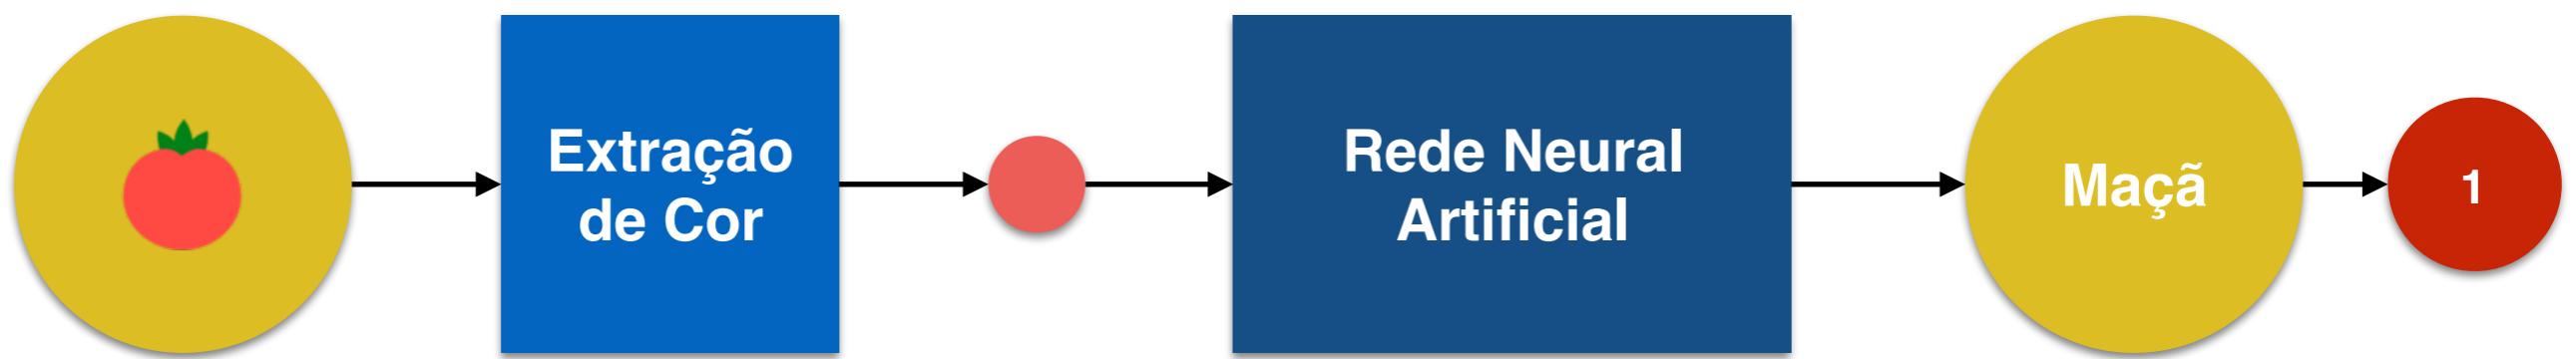
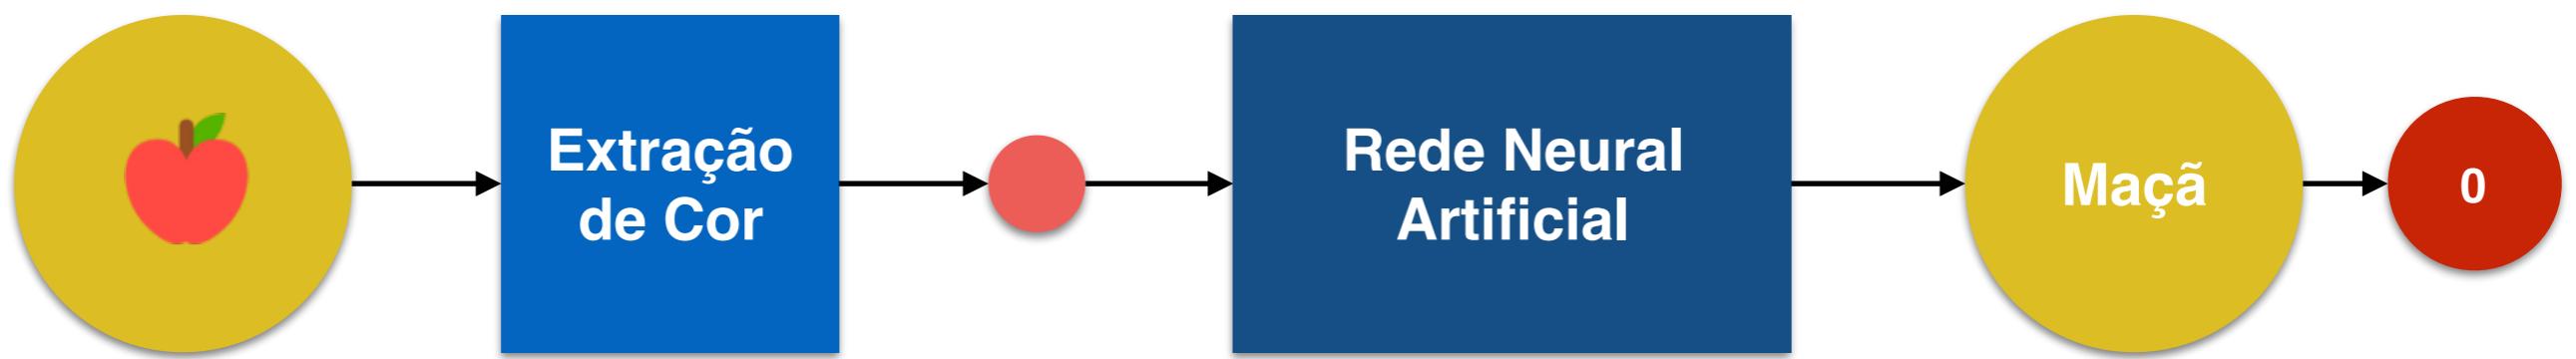


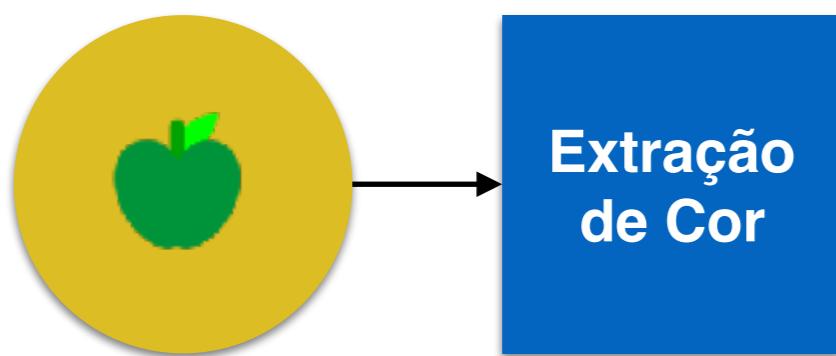
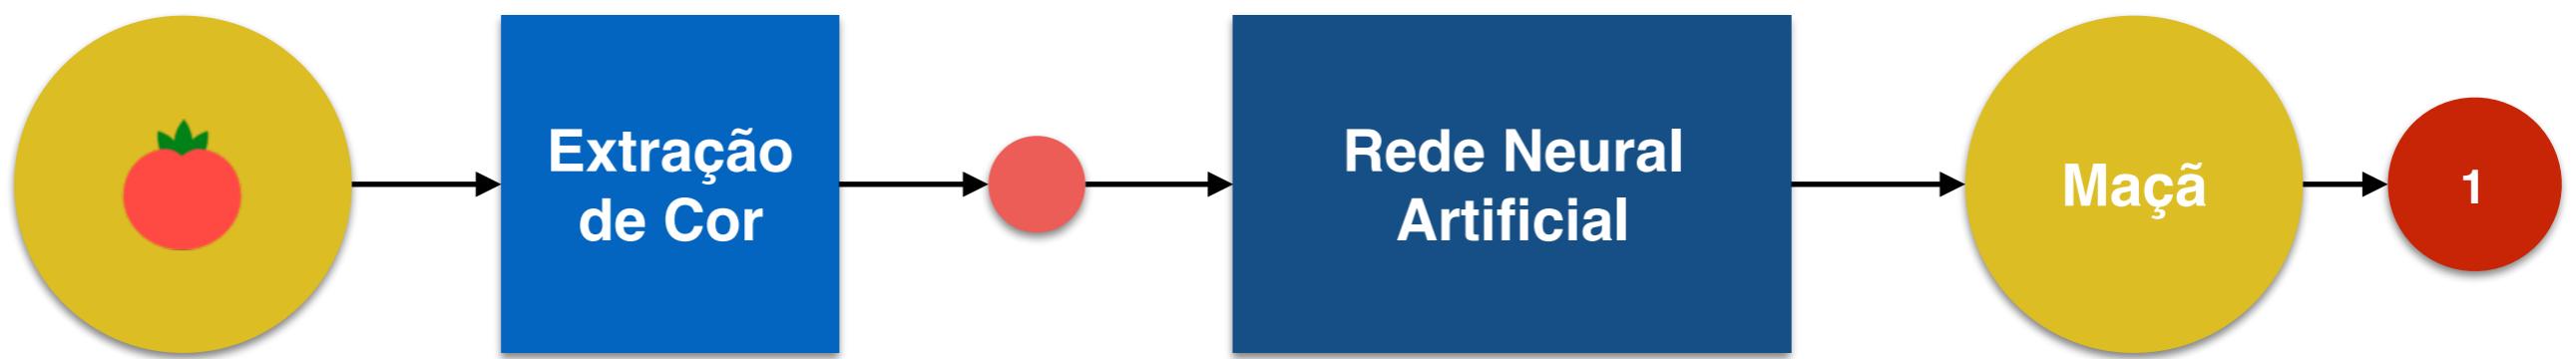
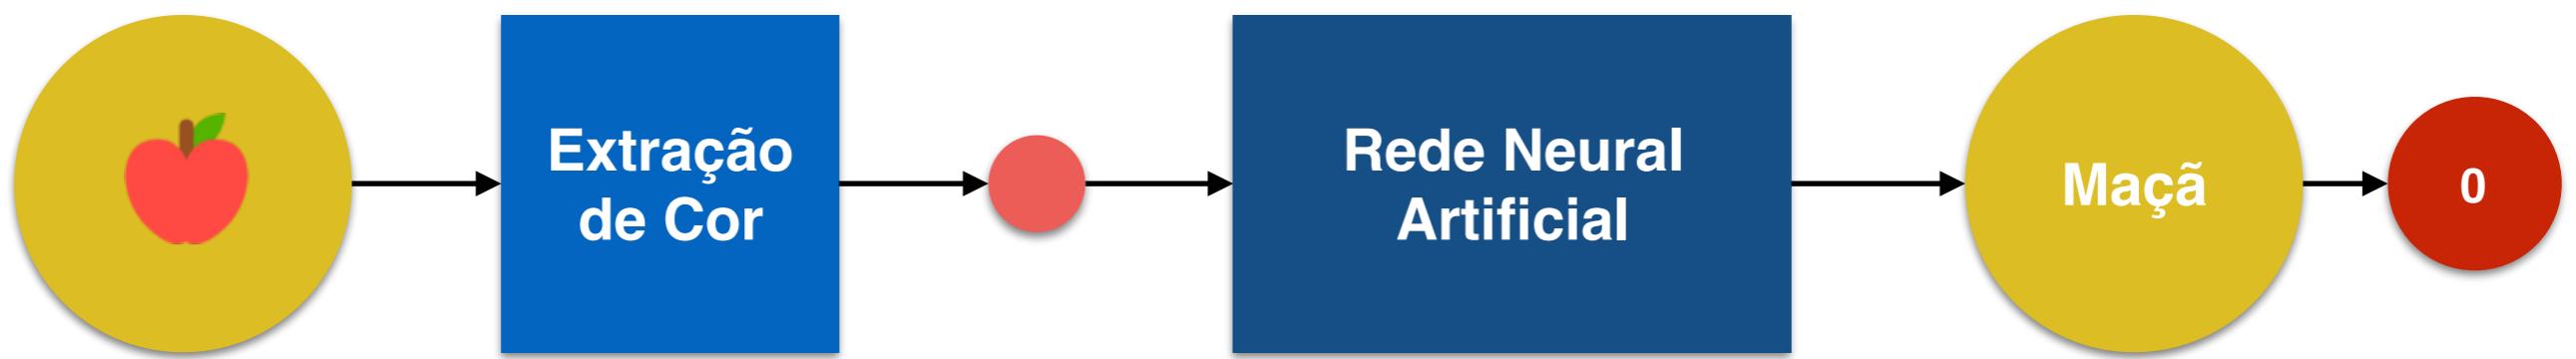
Pipeline Comum

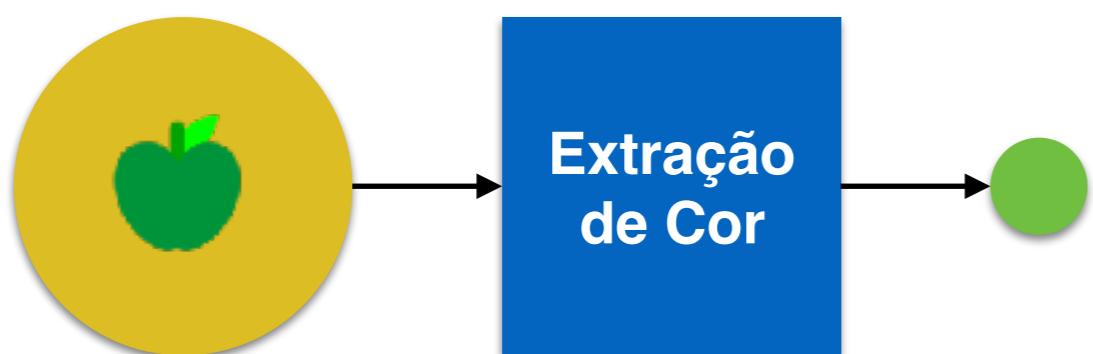
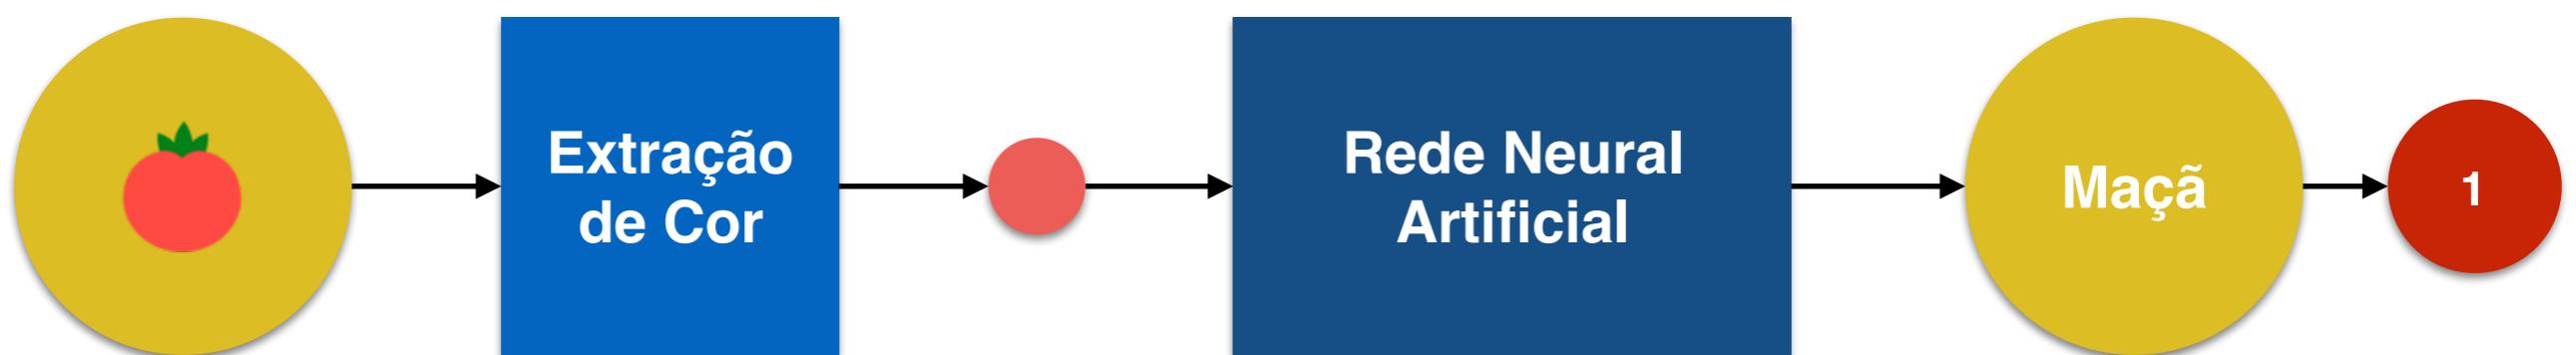
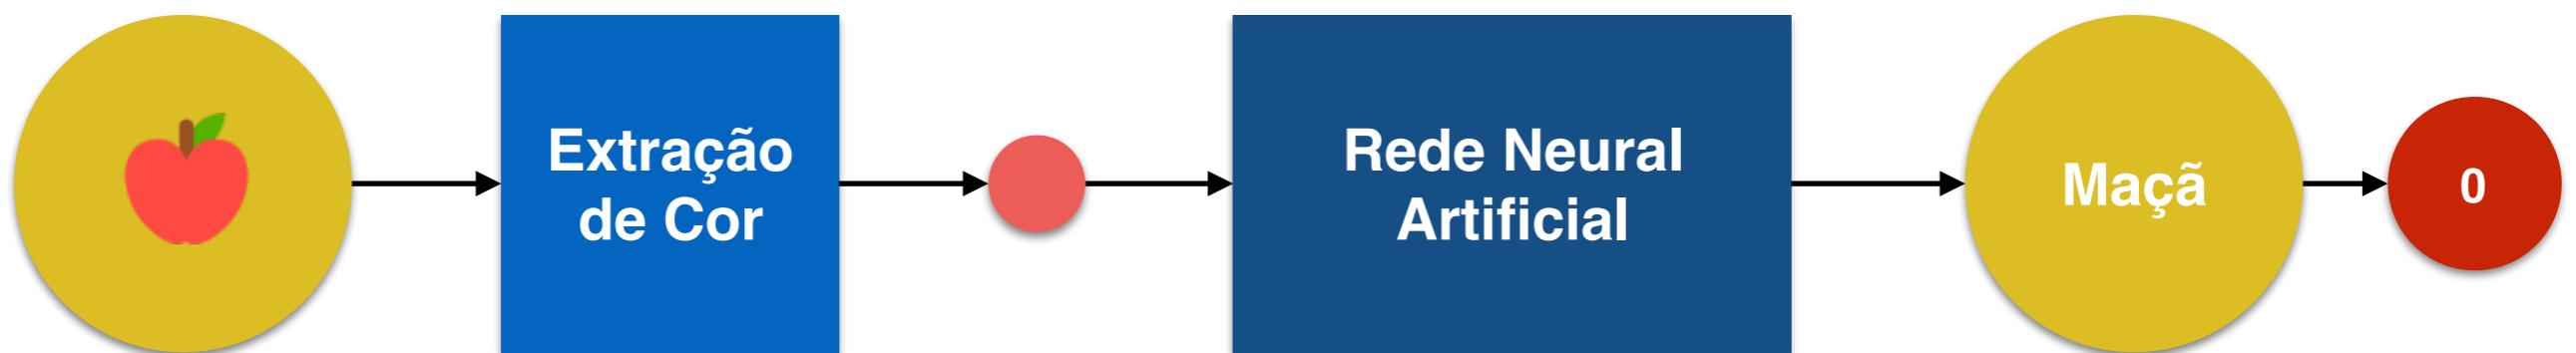
exemplo

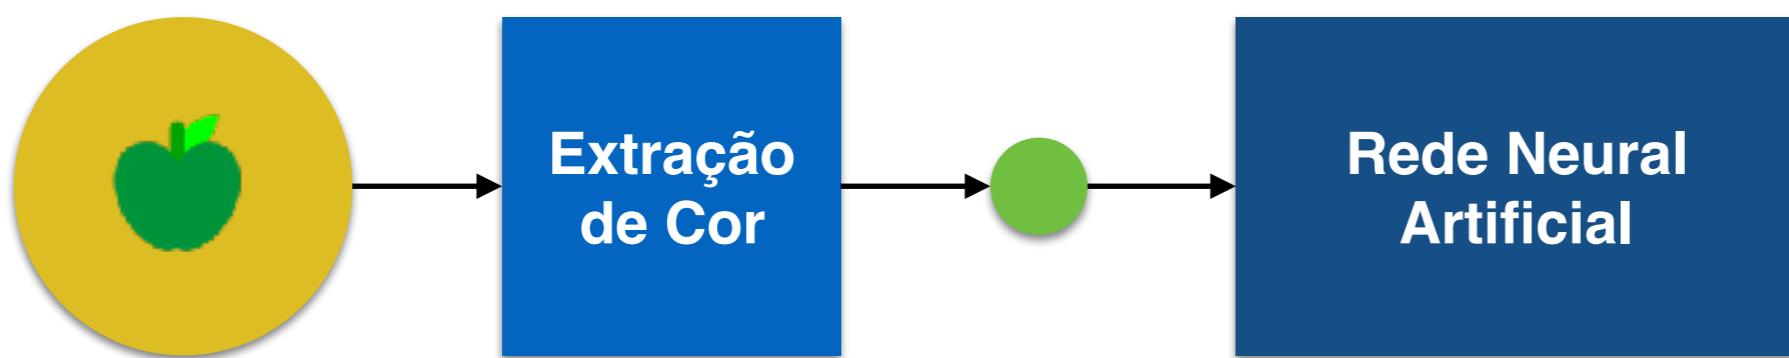
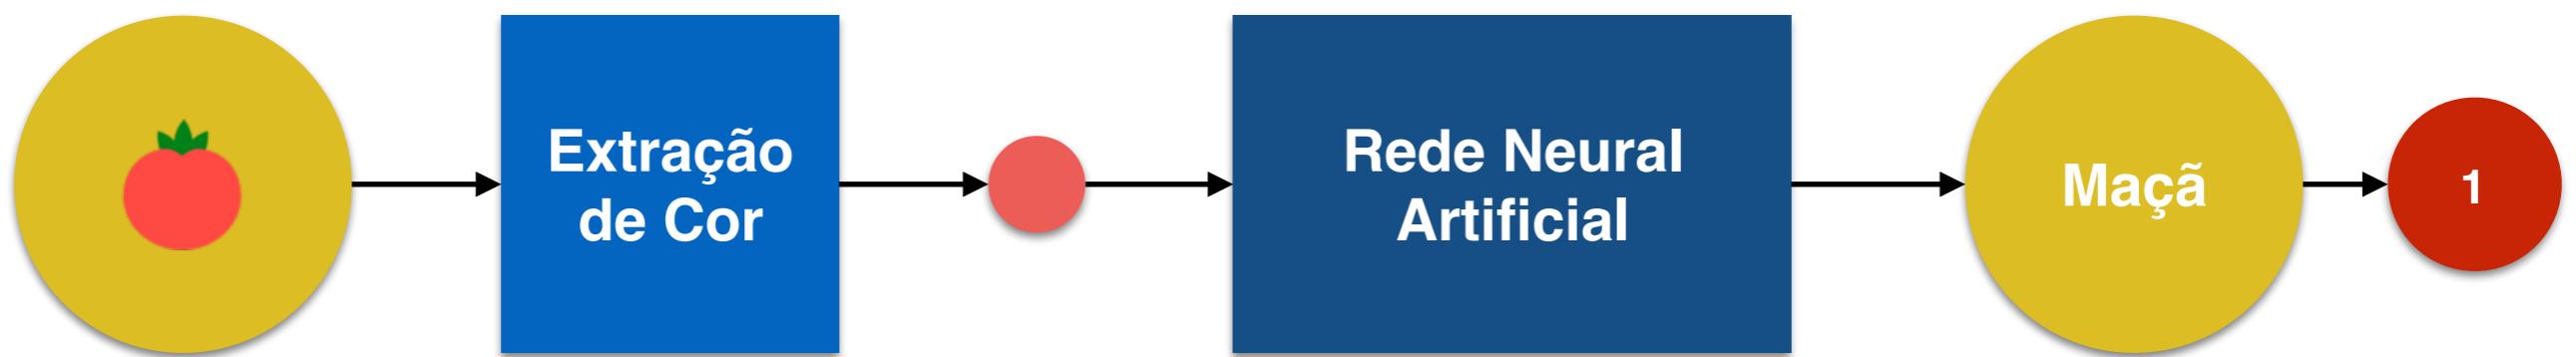
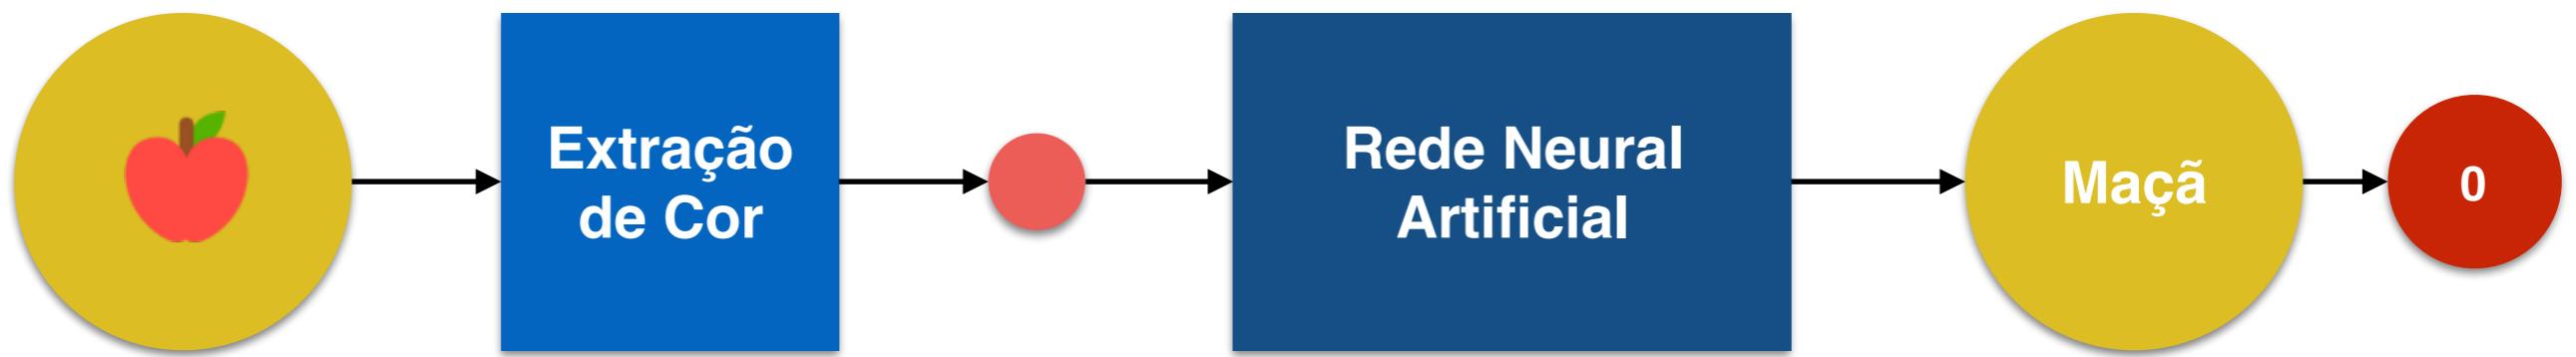


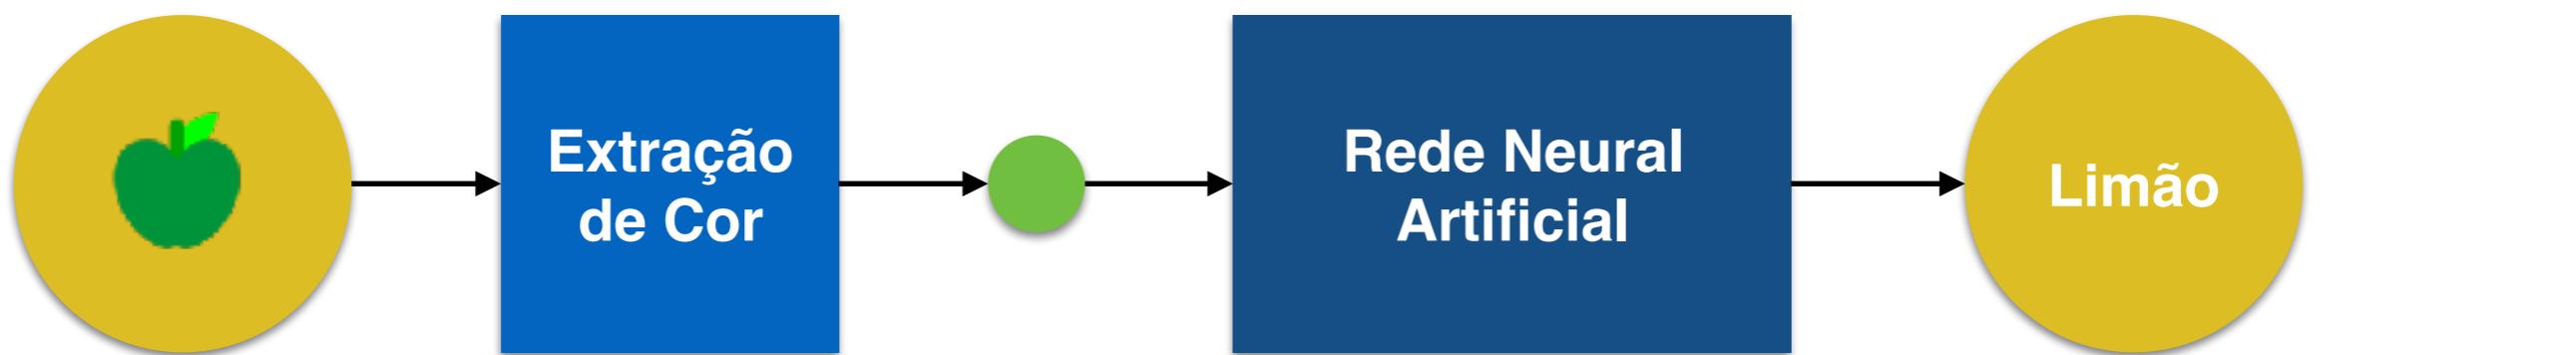
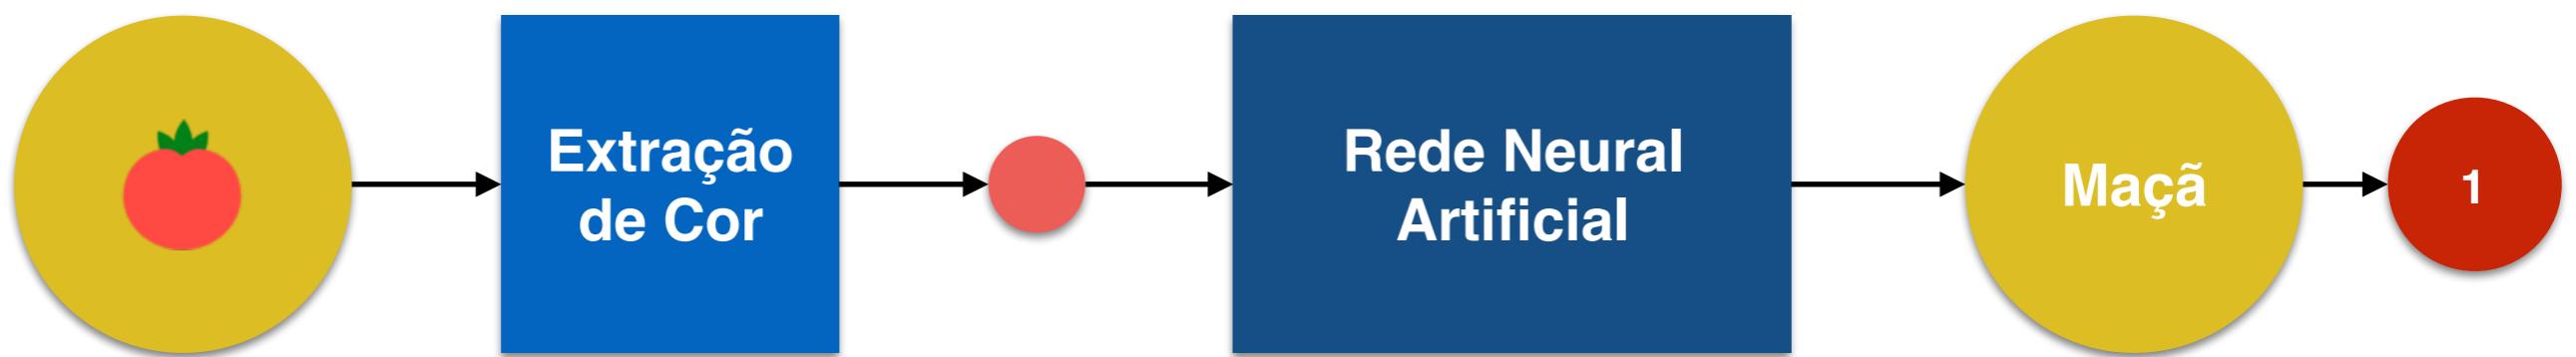
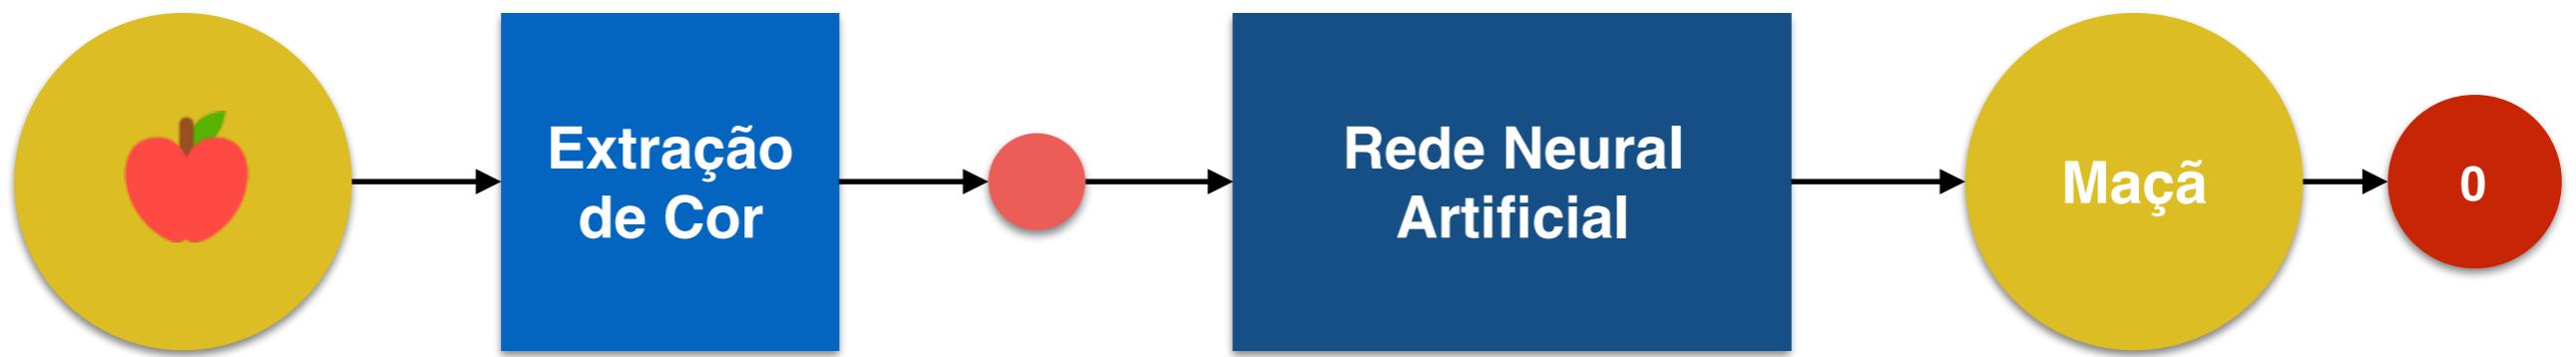


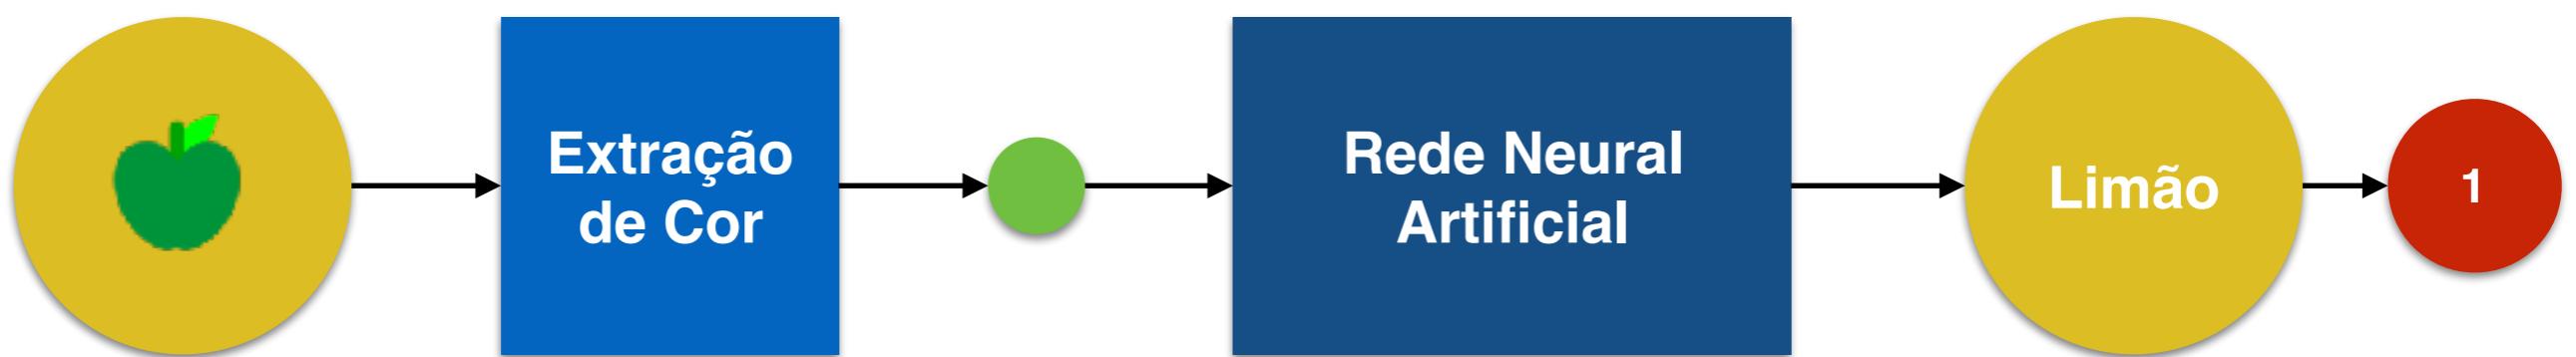
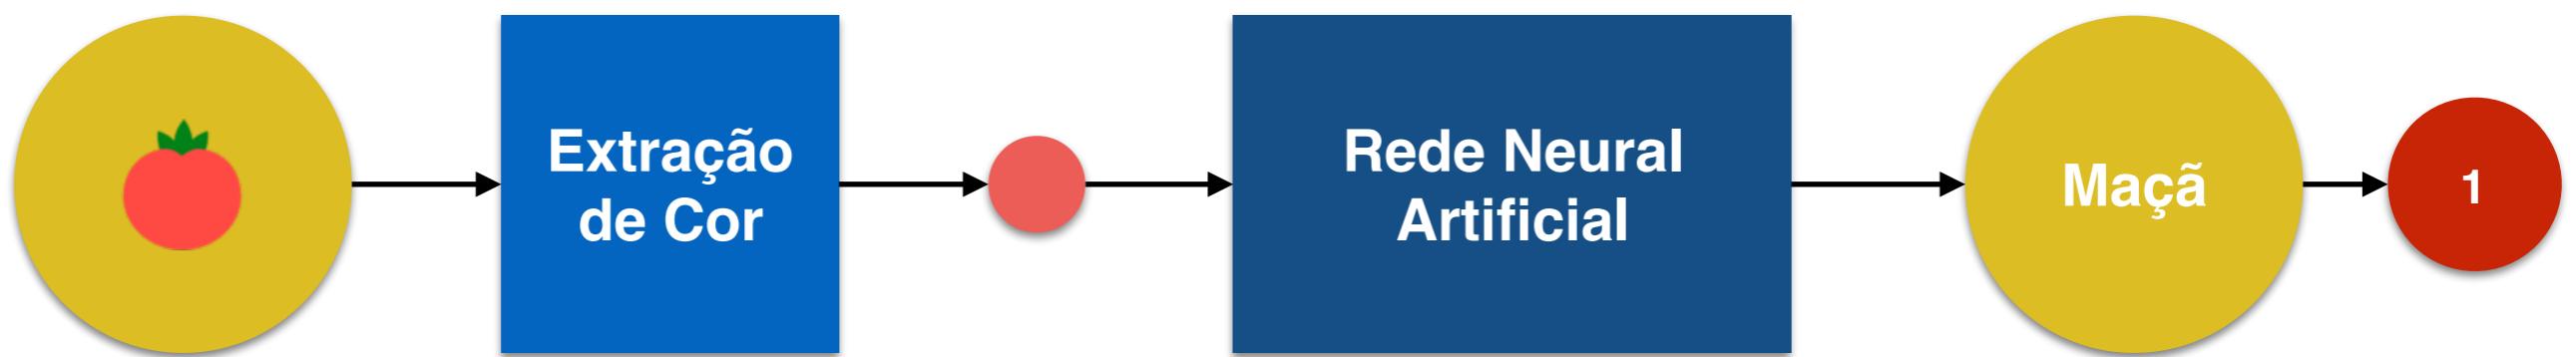
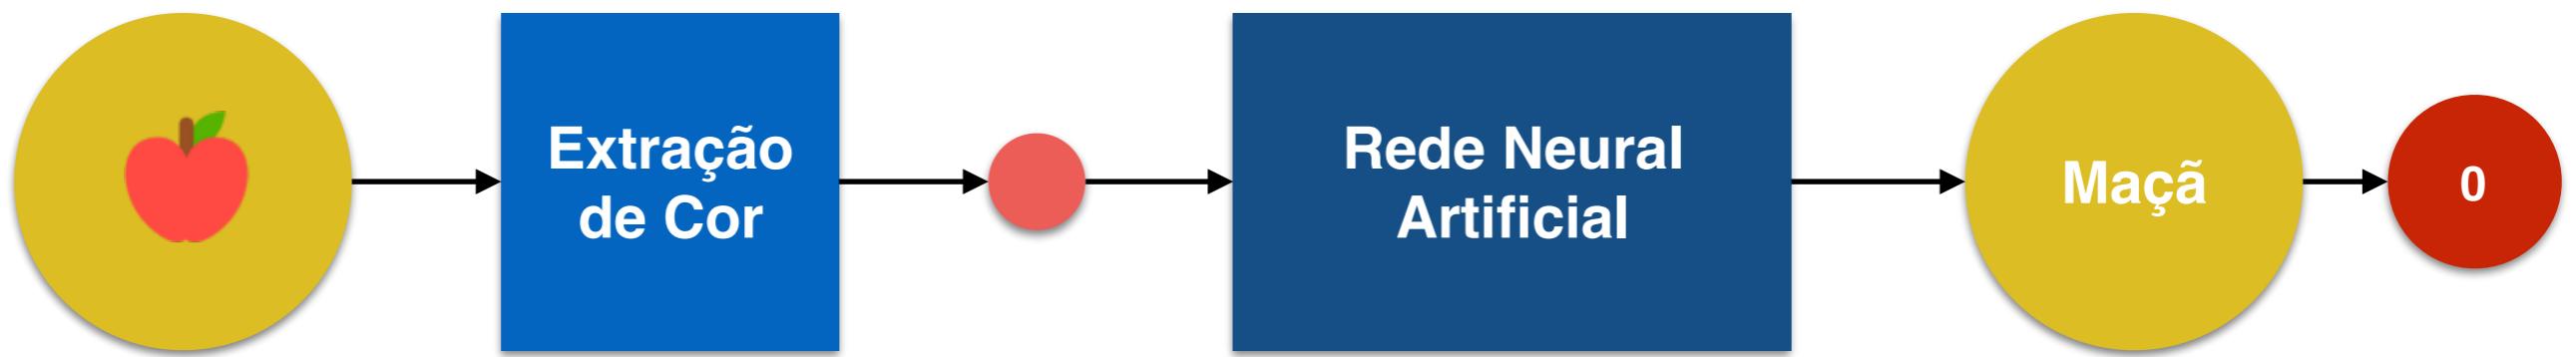


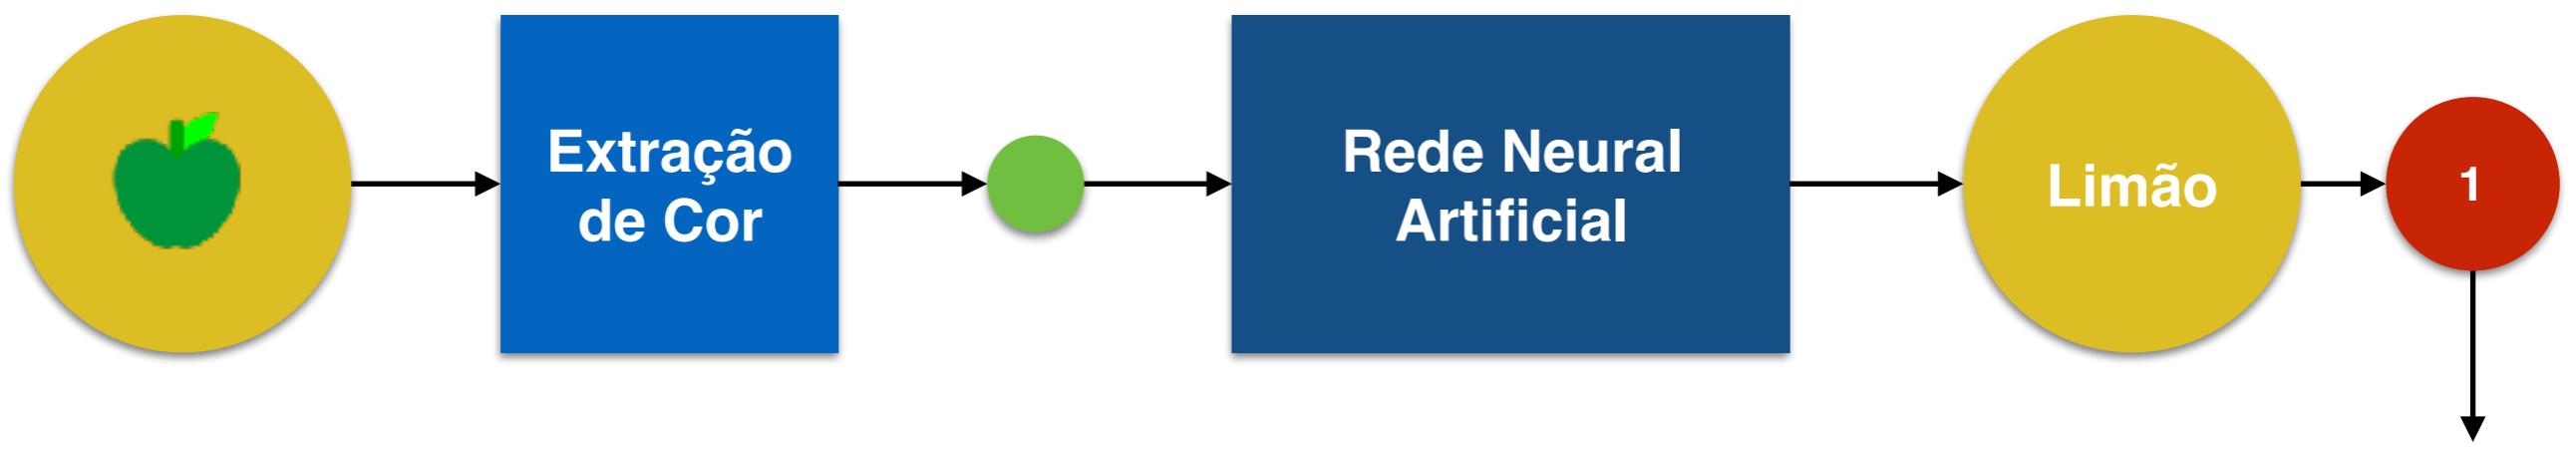
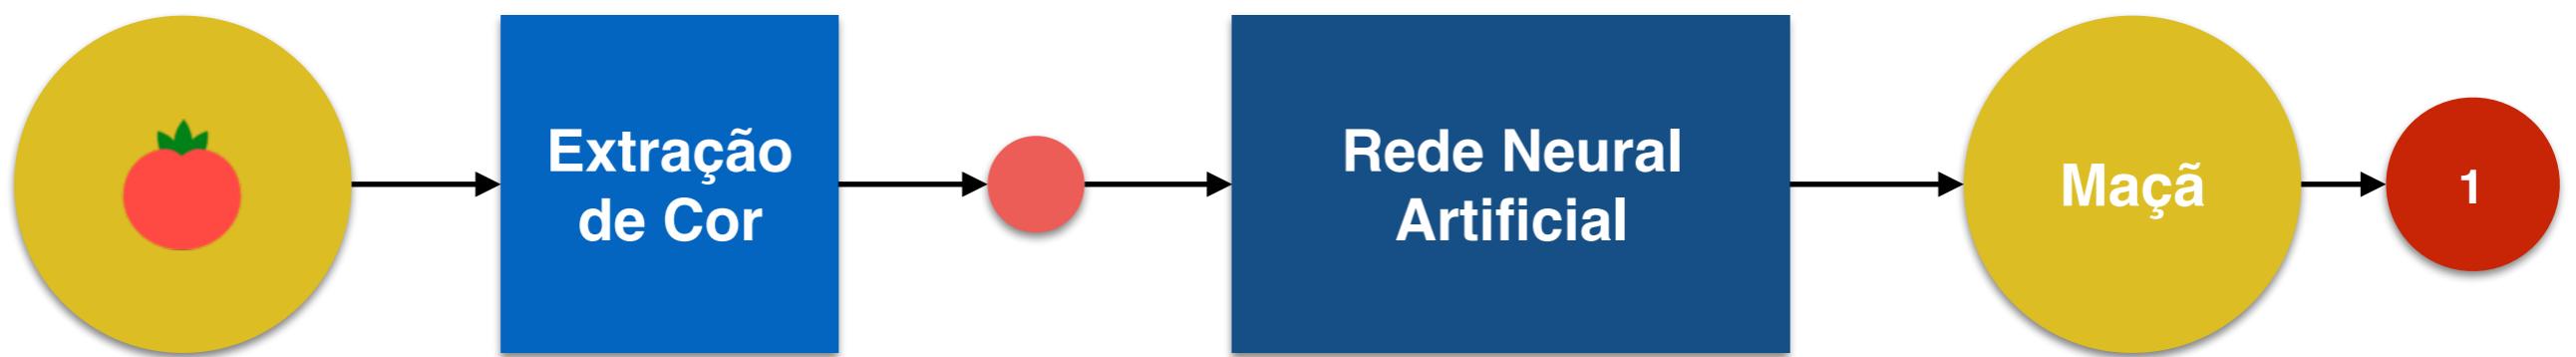
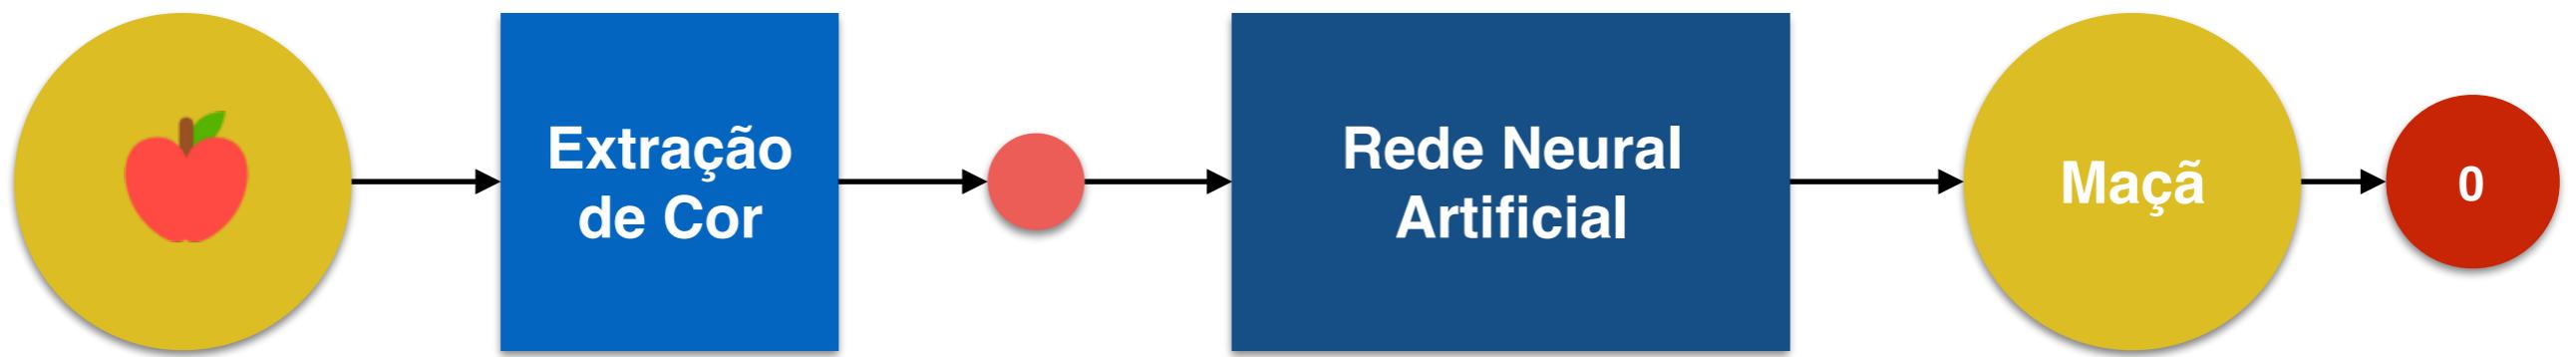












Flashback

Aprendizagem de Máquina

Breve (e simplificada) História



para ressaltar a beleza e
importância do desenvolvimento
das SVMs

Anos de desenvolvimento por parte da equipe de Vapnick e contribuidores culminaram na SVM, o algoritmo de classificação linear “perfeito” (se você souber usa-lo) e com forte embasamento teórico.

60

Aprendizagem de Máquina

Breve (e simplificada) História



2000~2005



2010~atual

Extratores de características e métodos baseados em kernel's são muito explorados. Começam a surgir competições de ML.

62

Extração de Características

Extração de Características

**Extratores
de Cor**

Extração de Características

**Extratores
de Cor**

**Extratores de
Forma**

Extração de Características

**Extratores
de Cor**

**Características de
Região**

**Extratores de
Forma**

Extração de Características

Extratores
de Cor

Características de
Região

Extratores de
Forma

Transformações no
Espaço

Extração de Características

Extratores
de Cor

Características de
Região

Extratores de
Forma

Transformações no
Espaço

Descritores de
Características

Extração de Características

Extratores
de Cor

Extratores de
Forma

Características de
Região

Transformações no Espaço

Descritores de
Características

Extração de Características

Extratores de Cor

RGB
LAB
HSL
LUV

Extratores de Forma

Canny
Sobel
Prewitt
Deriche

Características de Região

Laplacian of Gaussian
Difference of Gaussians
Determinant of Hessian

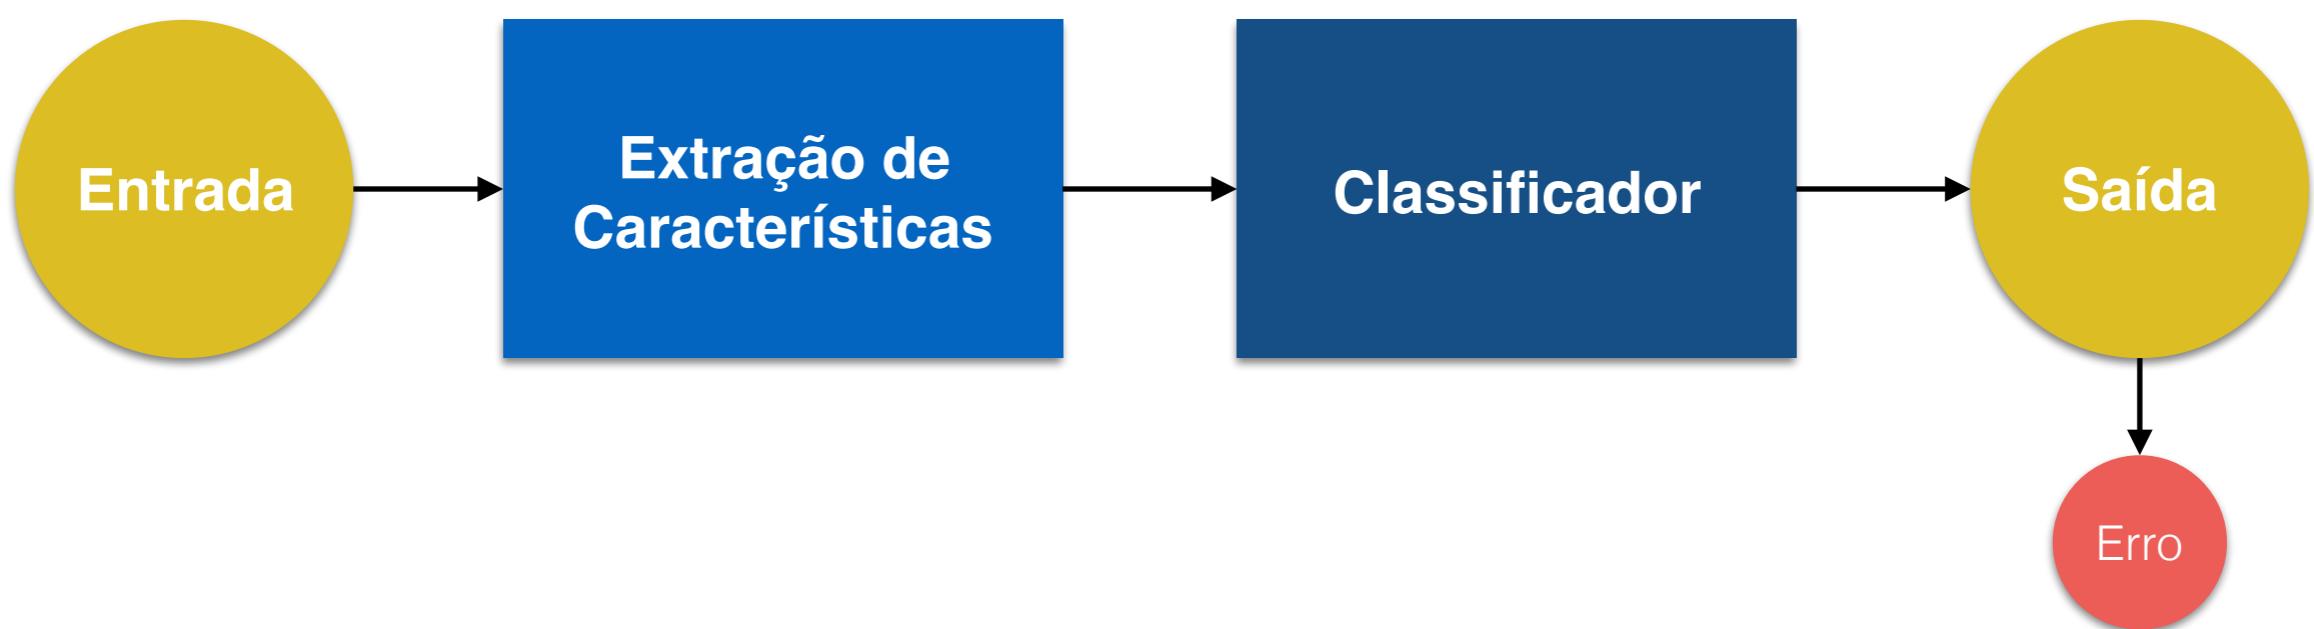
Transformações no Espaço

Hough Transform
Wavelet Transform
Distance Transform

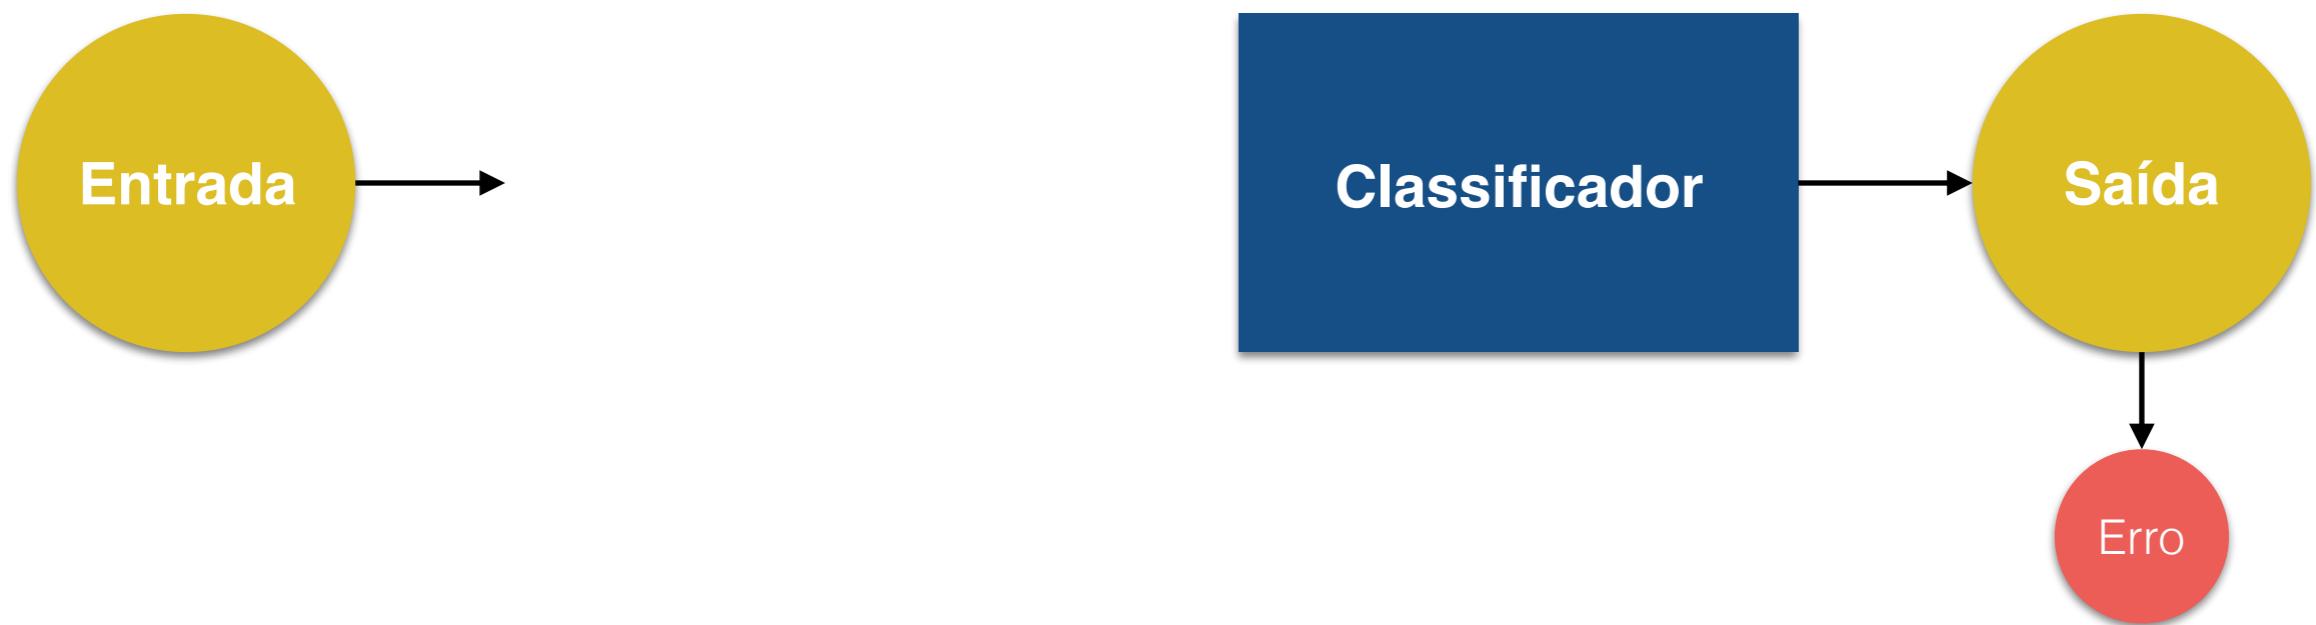
Descritores de Características

SIFT SURF
GLOH HOG

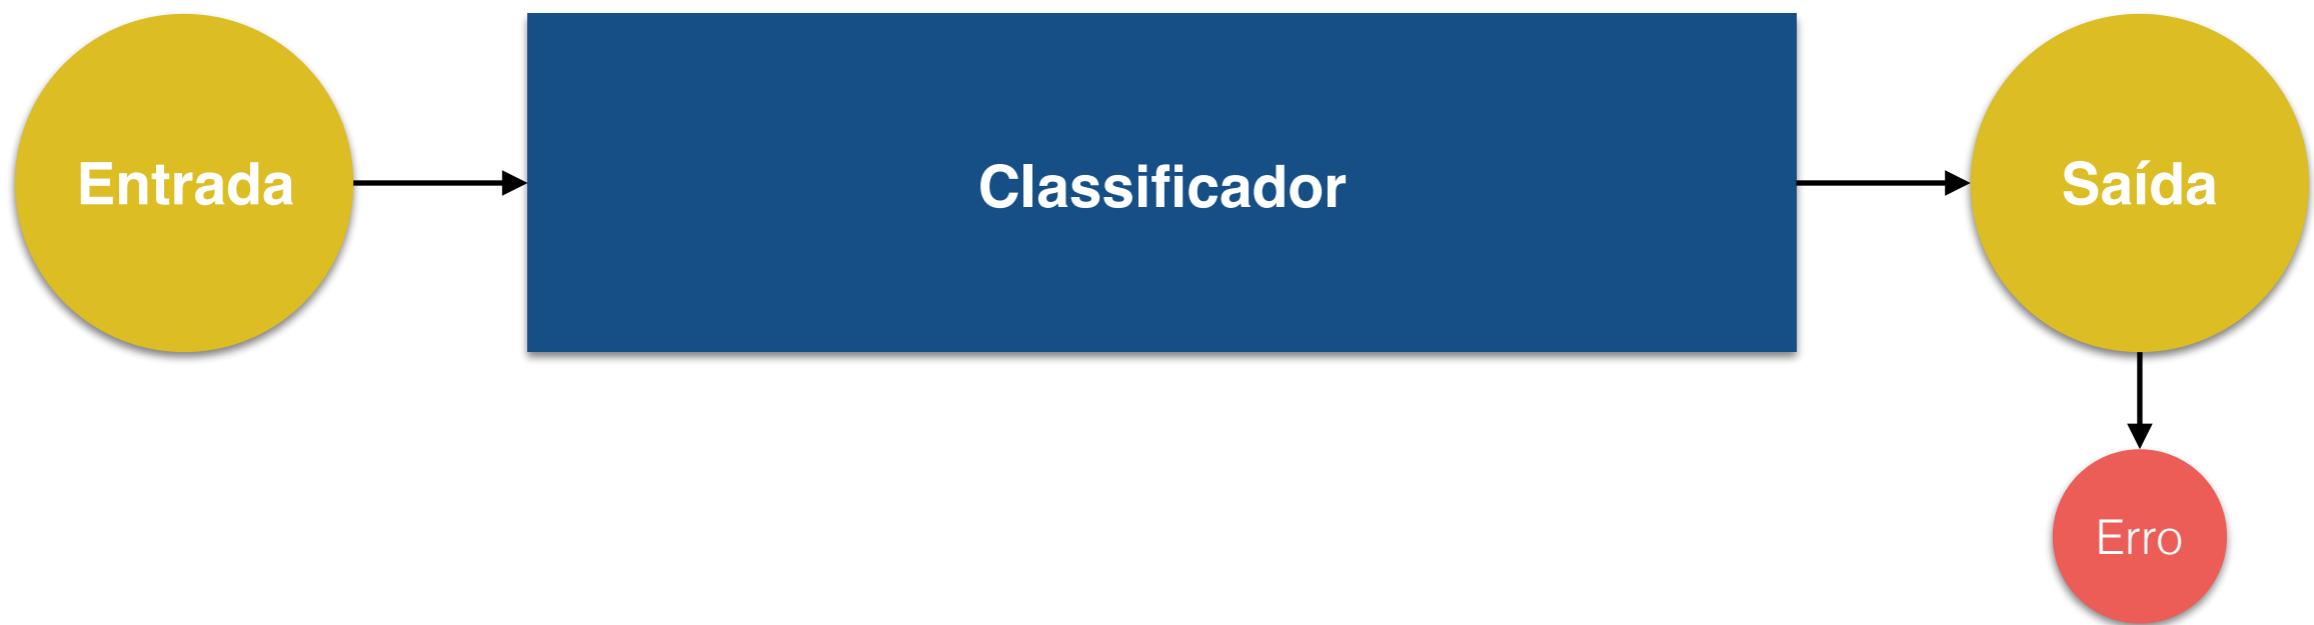
Pipeline Comum



Pipeline Comum



Aprendizagem de Representação



Aprendizagem de Representação



“Learning representations of the data that make it easier to extract useful information when building classifiers or other predictors.”

Bengio *et al.* (2013)

Cronograma da Apresentação

Aprendizagem de Representação

Importância da Representação

Extratores de Características

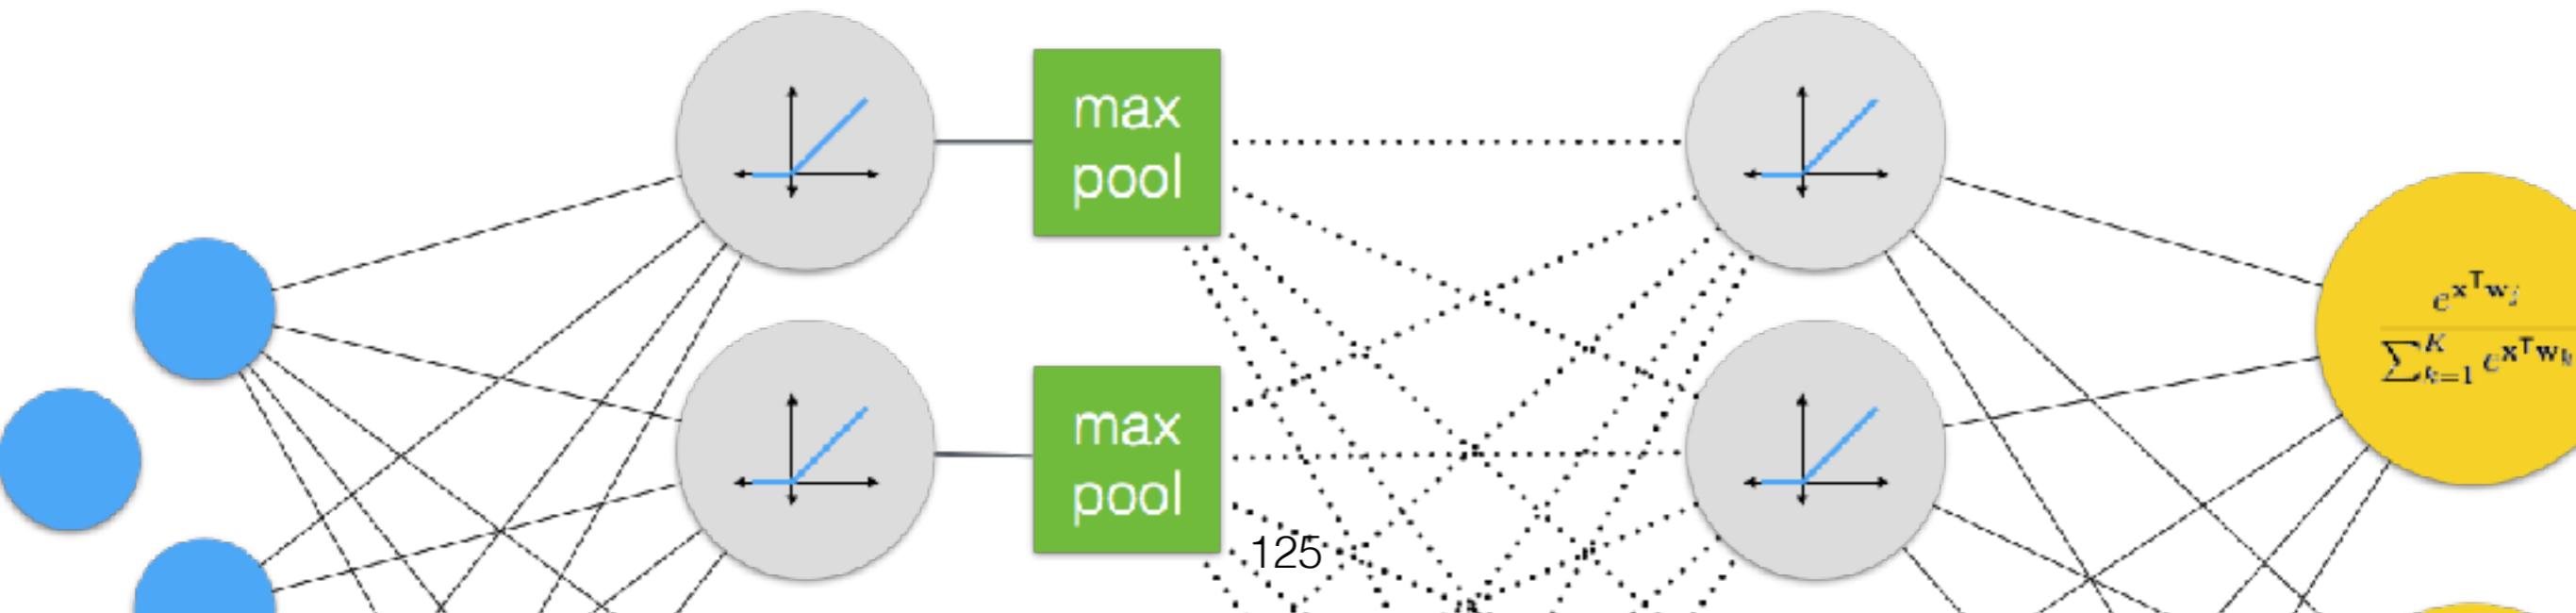
Cronograma da Apresentação



Cronograma da Apresentação



Convolução



Extração de Características

Extratores de Cor

RGB
LAB
HSL
LUV

Extratores de Forma

Canny
Sobel
Prewitt
Deriche

Características de Região

Laplacian of Gaussian
Difference of Gaussians
Determinant of Hessian

Transformações no Espaço

Hough Transform
Wavelet Transform
Distance Transform

Descritores de Características

SIFT SURF
GLOH HOG

Extração de Características

Extratores de Forma

Canny

Sobel

Prewitt

Deriche

Filtros de Convolução

Canny

Prewitt

Convolução



Convolução



Operação Matemática

Convolução



Operação Matemática

Binária

Convolução



Operação Matemática

Binária

Vetores N-Dimensionais
(1D, 2D, 3D.... ND)

Convolução



Operação Matemática

Binária

Vetores N-Dimensionais
(1D, 2D, 3D.... ND)

Convolução



Convolução

A

a1	a2	a3	a4
----	----	----	----



Convolução

A

a1	a2	a3	a4
----	----	----	----



B

b1	b2	b3	b4
----	----	----	----

Convolução

A

a1	a2	a3	a4
a5	a6	a7	a8
a9	a10	a11	a12



B

b1	b2	b3	b4
b5	b6	b7	b8
b9	b10	b11	b12

Convolução

$$A * B = \sum_{m=-\infty}^{\infty} f[n - m]g[m]$$

Convolução

Convolução

intuitivamente...

Convolução

A =

a1	a2	a3	a4	a5	a6
a7	a8	a9	a10	a11	a12
a13	a14	a15	a16	a17	a18
a19	a20	a21	a22	a23	a24
a25	a26	a27	a28	a29	a30
a31	a32	a33	a34	a35	a36

B =

b1	b2	b3
b4	b5	b6
b7	b8	b9

Convolução

A =

a1	a2	a3	a4	a5	a6
a7	a8	a9	a10	a11	a12
a13	a14	a15	a16	a17	a18
a19	a20	a21	a22	a23	a24
a25	a26	a27	a28	a29	a30
a31	a32	a33	a34	a35	a36

B =

b1	b2	b3
b4	b5	b6
b7	b8	b9

B =



Convolução

A =

a1	a2	a3	a4	a5	a6
a7	a8	a9	a10	a11	a12
a13	a14	a15	a16	a17	a18
a19	a20	a21	a22	a23	a24
a25	a26	a27	a28	a29	a30
a31	a32	a33	a34	a35	a36

B =

b1	b2	b3
b4	b5	b6
b7	b8	b9

Convolução

a1	a2	a3	a4	a5	a6
a7	a8	a9	a10	a11	a12
a13	a14	a15	a16	a17	a18
a19	a20	a21	a22	a23	a24
a25	a26	a27	a28	a29	a30
a31	a32	a33	a34	a35	a36

$$A \star\star B =$$

?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?

b1	b2	b3
b4	b5	b6
b7	b8	b9

Convolução

a1	a2	a3	a4	a5	a6
a7	a8	a9	a10	a11	a12
a13	a14	a15	a16	a17	a18
a19	a20	a21	a22	a23	a24
a25	a26	a27	a28	a29	a30
a31	a32	a33	a34	a35	a36

$A \star\star B =$

?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?

b1	b2	b3
b4	b5	b6
b7	b8	b9



Convolução

	a1	a2	a3	a4	a5	a6
	a7	a8	a9	a10	a11	a12
	a13	a14	a15	a16	a17	a18
	a19	a20	a21	a22	a23	a24
	a25	a26	a27	a28	a29	a30
	a31	a32	a33	a34	a35	a36

$$A \star\star B =$$

?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?

b1	b2	b3
b4	b5	b6
b7	b8	b9

Convolução

	a1	a2	a3	a4	a5	a6
	a7	a8	a9	a10	a11	a12
a13	a14	a15	a16	a17	a18	
a19	a20	a21	a22	a23	a24	
a25	a26	a27	a28	a29	a30	
a31	a32	a33	a34	a35	a36	

$$A^{**}B =$$

?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?

b1	b2	b3
b4	b5	b6
b7	b8	b9

$$A^{**}B[0,0] =$$

Convolução

	a1	a2	a3	a4	a5	a6
	a7	a8	a9	a10	a11	a12
a13	a14	a15	a16	a17	a18	
a19	a20	a21	a22	a23	a24	
a25	a26	a27	a28	a29	a30	
a31	a32	a33	a34	a35	a36	

$$A^{**}B =$$

?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?

b1	b2	b3
b4	b5	b6
b7	b8	b9

$$A^{**}B[0,0] =$$

0*b1	0*b2	0*b3
0*b4	a1*b5	a2*b6
0*b7	a7*b8	a8*b9

Convolução

	a1	a2	a3	a4	a5	a6
	a7	a8	a9	a10	a11	a12
a13	a14	a15	a16	a17	a18	
a19	a20	a21	a22	a23	a24	
a25	a26	a27	a28	a29	a30	
a31	a32	a33	a34	a35	a36	

$$A^{**}B =$$

?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?

b1	b2	b3
b4	b5	b6
b7	b8	b9

$$A^{**}B[0,0] =$$

y1

Convolução

	a1	a2	a3	a4	a5	a6
	a7	a8	a9	a10	a11	a12
a13	a14	a15	a16	a17	a18	
a19	a20	a21	a22	a23	a24	
a25	a26	a27	a28	a29	a30	
a31	a32	a33	a34	a35	a36	

$$A \star\star B =$$

y1	?	?	?	?	?	?
?	?	?	?	?	?	?
?	?	?	?	?	?	?
?	?	?	?	?	?	?
?	?	?	?	?	?	?

b1	b2	b3
b4	b5	b6
b7	b8	b9

$$A \star\star B[0,0] =$$

Convolução

a1	a2	a3	a4	a5	a6
a7	a8	a9	a10	a11	a12
a13	a14	a15	a16	a17	a18
a19	a20	a21	a22	a23	a24
a25	a26	a27	a28	a29	a30
a31	a32	a33	a34	a35	a36

$$A^{**}B =$$

y1	?	?	?	?	?	?
?	?	?	?	?	?	?
?	?	?	?	?	?	?
?	?	?	?	?	?	?
?	?	?	?	?	?	?

b1	b2	b3
b4	b5	b6
b7	b8	b9

$$A^{**}B[0,0] =$$

Convolução

a1	a2	a3	a4	a5	a6
a7	a8	a9	a10	a11	a12
a13	a14	a15	a16	a17	a18
a19	a20	a21	a22	a23	a24
a25	a26	a27	a28	a29	a30
a31	a32	a33	a34	a35	a36

$$A \star\star B =$$

y1	?	?	?	?	?	?
?	?	?	?	?	?	?
?	?	?	?	?	?	?
?	?	?	?	?	?	?
?	?	?	?	?	?	?

b1	b2	b3
b4	b5	b6
b7	b8	b9

$$A \star\star B[0,0] =$$

y	y	y
y	y	y
y	y	y

Convolução

a1	a2	a3	a4	a5	a6
a7	a8	a9	a10	a11	a12
a13	a14	a15	a16	a17	a18
a19	a20	a21	a22	a23	a24
a25	a26	a27	a28	a29	a30
a31	a32	a33	a34	a35	a36

$$A^{**}B =$$

y1	?	?	?	?	?	?
?	?	?	?	?	?	?
?	?	?	?	?	?	?
?	?	?	?	?	?	?
?	?	?	?	?	?	?

b1	b2	b3
b4	b5	b6
b7	b8	b9

$$A^{**}B[0,0] =$$

y2

Convolução

a1	a2	a3	a4	a5	a6
a7	a8	a9	a10	a11	a12
a13	a14	a15	a16	a17	a18
a19	a20	a21	a22	a23	a24
a25	a26	a27	a28	a29	a30
a31	a32	a33	a34	a35	a36

$$A \star\star B =$$

y1	y2	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?

b1	b2	b3
b4	b5	b6
b7	b8	b9

$$A \star\star B[0,0] =$$

Convolução

a1	a2	a3	a4	a5	a6
a7	a8	a9	a10	a11	a12
a13	a14	a15	a16	a17	a18
a19	a20	a21	a22	a23	a24
a25	a26	a27	a28	a29	a30
a31	a32	a33	a34	a35	a36

$$A^{**}B =$$

y1	y2	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?

b1	b2	b3
b4	b5	b6
b7	b8	b9

$$A^{**}B[0,0] =$$

Convolução

a1	a2	a3	a4	a5	a6
a7	a8	a9	a10	a11	a12
a13	a14	a15	a16	a17	a18
a19	a20	a21	a22	a23	a24
a25	a26	a27	a28	a29	a30
a31	a32	a33	a34	a35	a36

$$A \star\star B =$$

y1	y2	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?

b1	b2	b3
b4	b5	b6
b7	b8	b9

$$A \star\star B[0,0] =$$

y	y	y
y	y	y
y	y	y

Convolução

a1	a2	a3	a4	a5	a6
a7	a8	a9	a10	a11	a12
a13	a14	a15	a16	a17	a18
a19	a20	a21	a22	a23	a24
a25	a26	a27	a28	a29	a30
a31	a32	a33	a34	a35	a36

$$A^{**}B =$$

y1	y2	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?

b1	b2	b3
b4	b5	b6
b7	b8	b9

$$A^{**}B[0,0] =$$

y3

Convolução

a1	a2	a3	a4	a5	a6
a7	a8	a9	a10	a11	a12
a13	a14	a15	a16	a17	a18
a19	a20	a21	a22	a23	a24
a25	a26	a27	a28	a29	a30
a31	a32	a33	a34	a35	a36

$$A^{**}B =$$

y1	y2	y3	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?

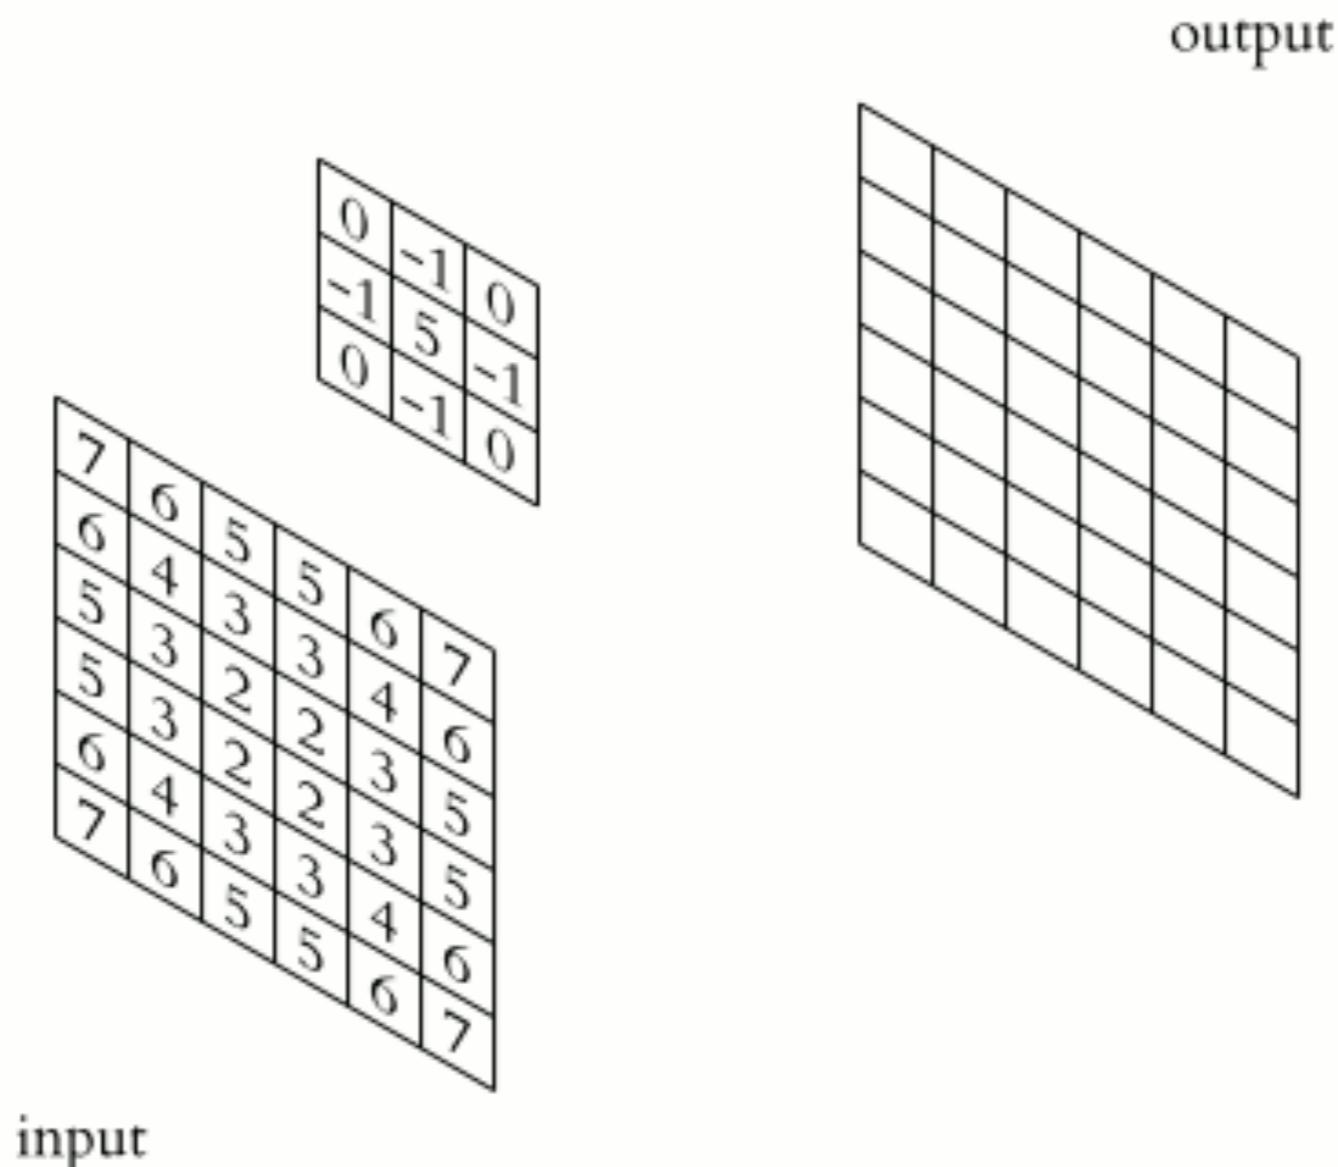
b1	b2	b3
b4	b5	b6
b7	b8	b9

$$A^{**}B[0,0] =$$

Convolução

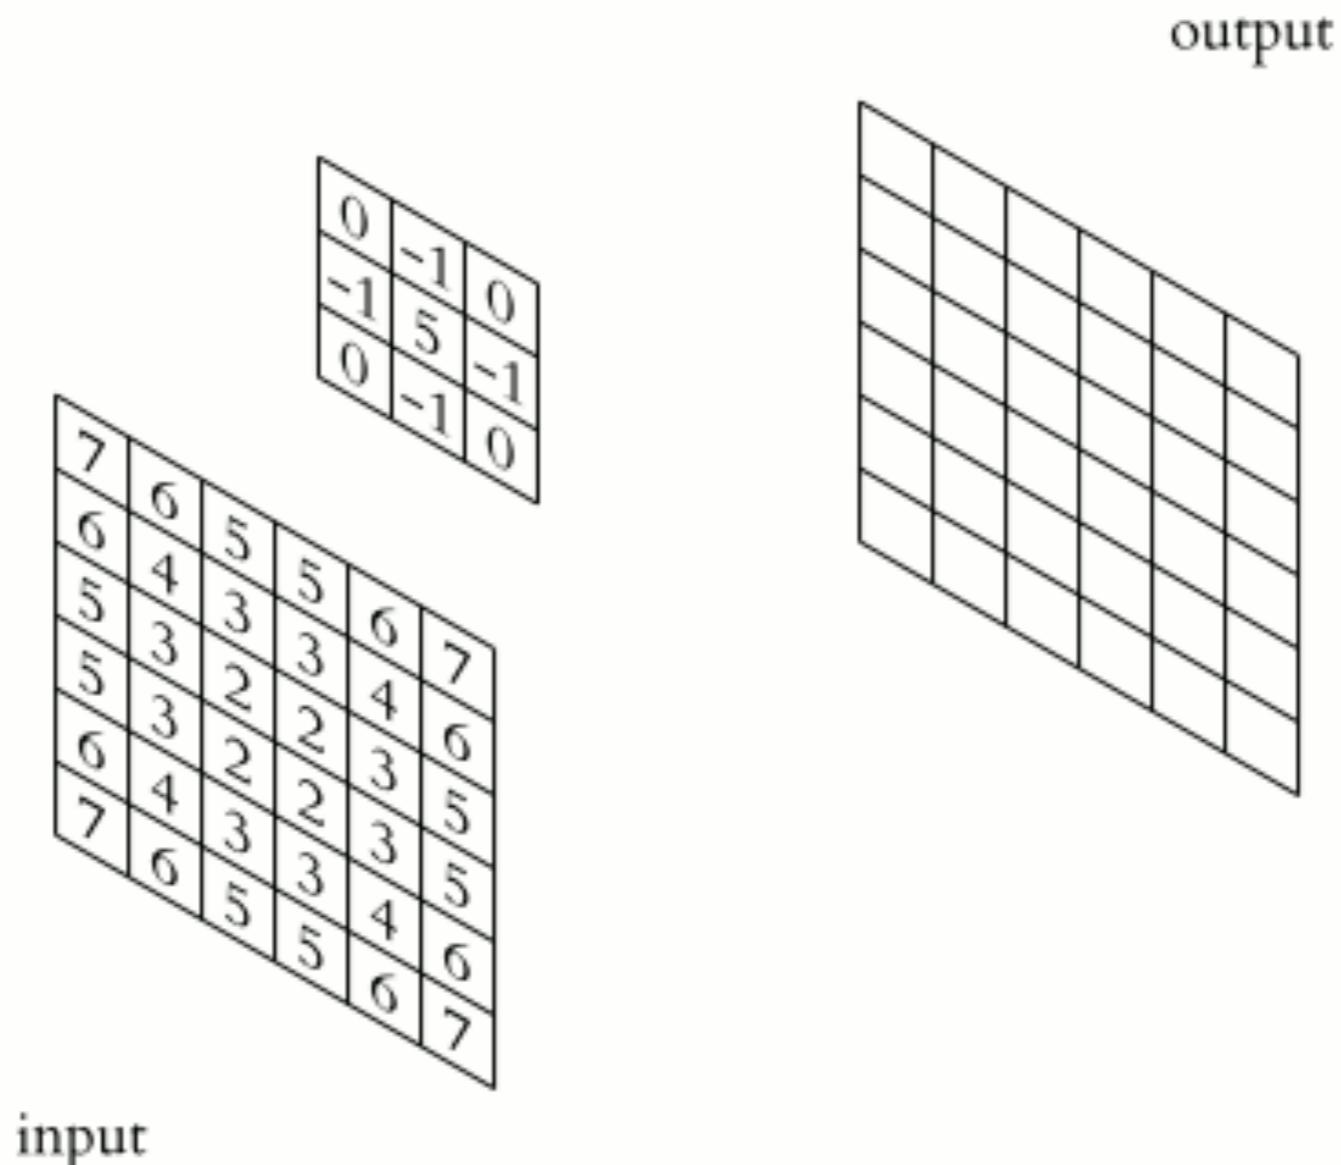
e assim por diante...

Convolução



https://it.wikipedia.org/wiki/File:3D_Convolution_Animation.gif

Convolução



https://it.wikipedia.org/wiki/File:3D_Convolution_Animation.gif

Filtros de Convolução Famosos

Filtros de Convolução Famosos

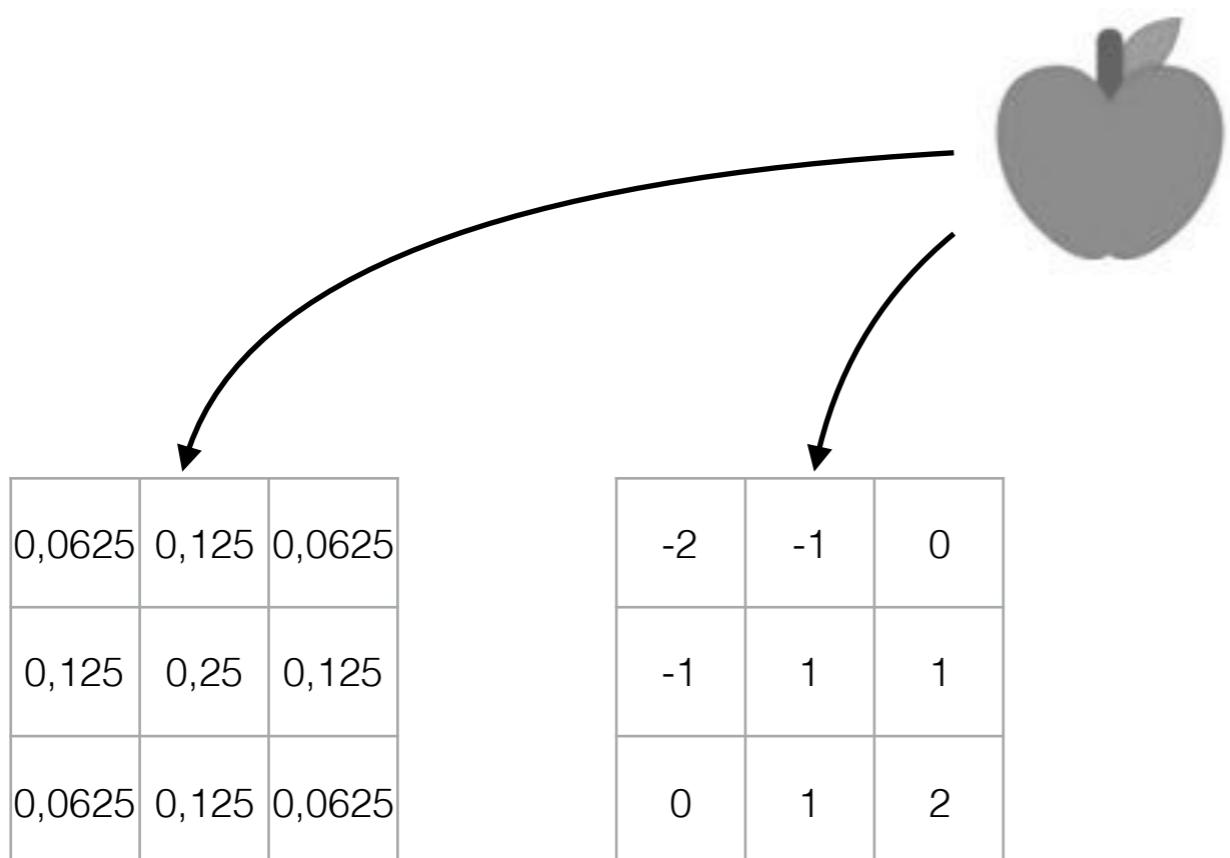


Filtros de Convolução Famosos

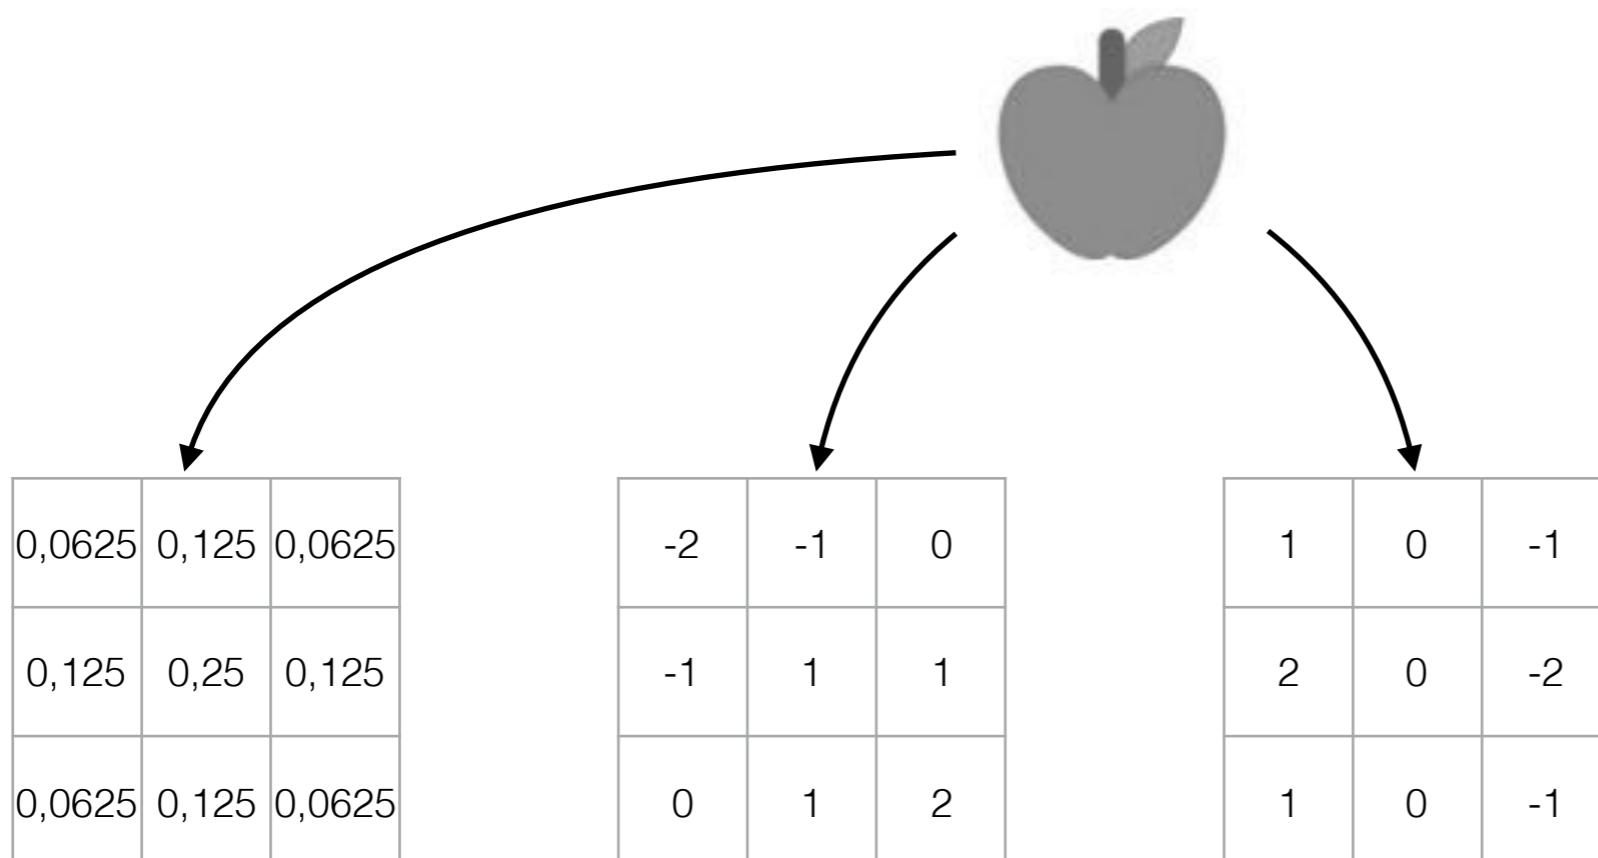


0,0625	0,125	0,0625
0,125	0,25	0,125
0,0625	0,125	0,0625

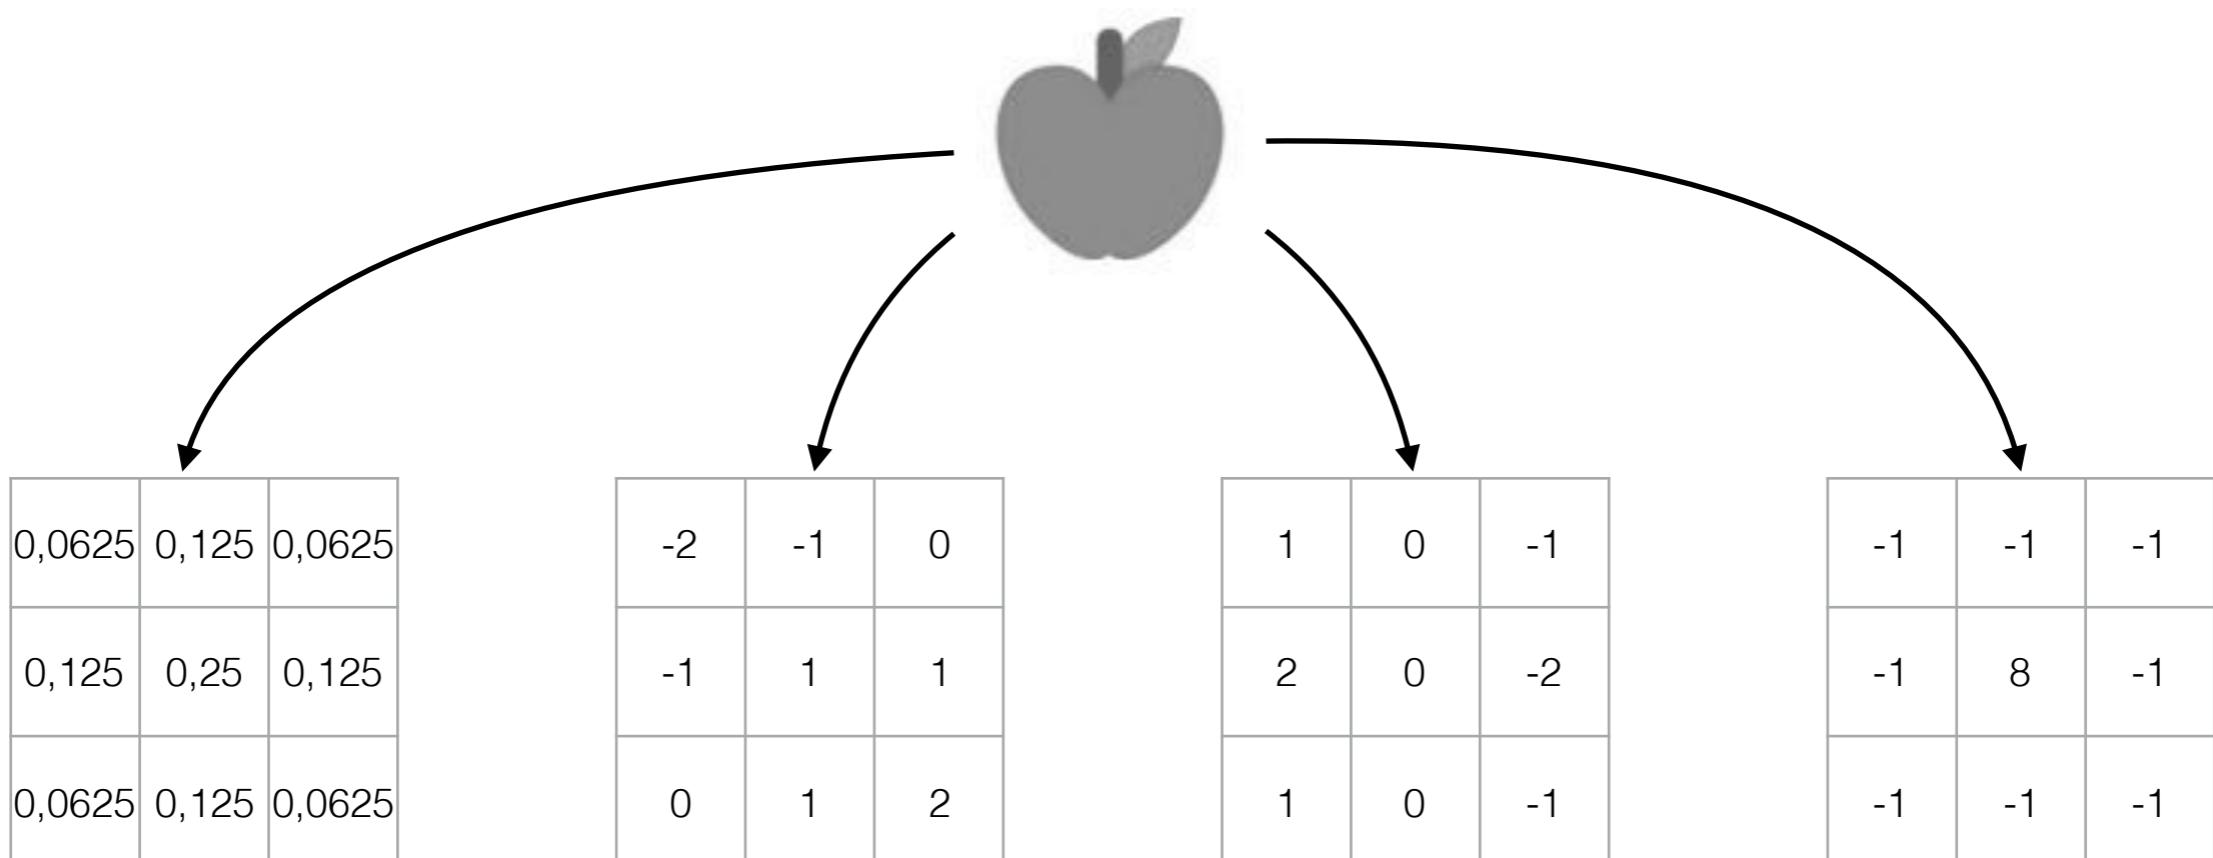
Filtros de Convolução Famosos



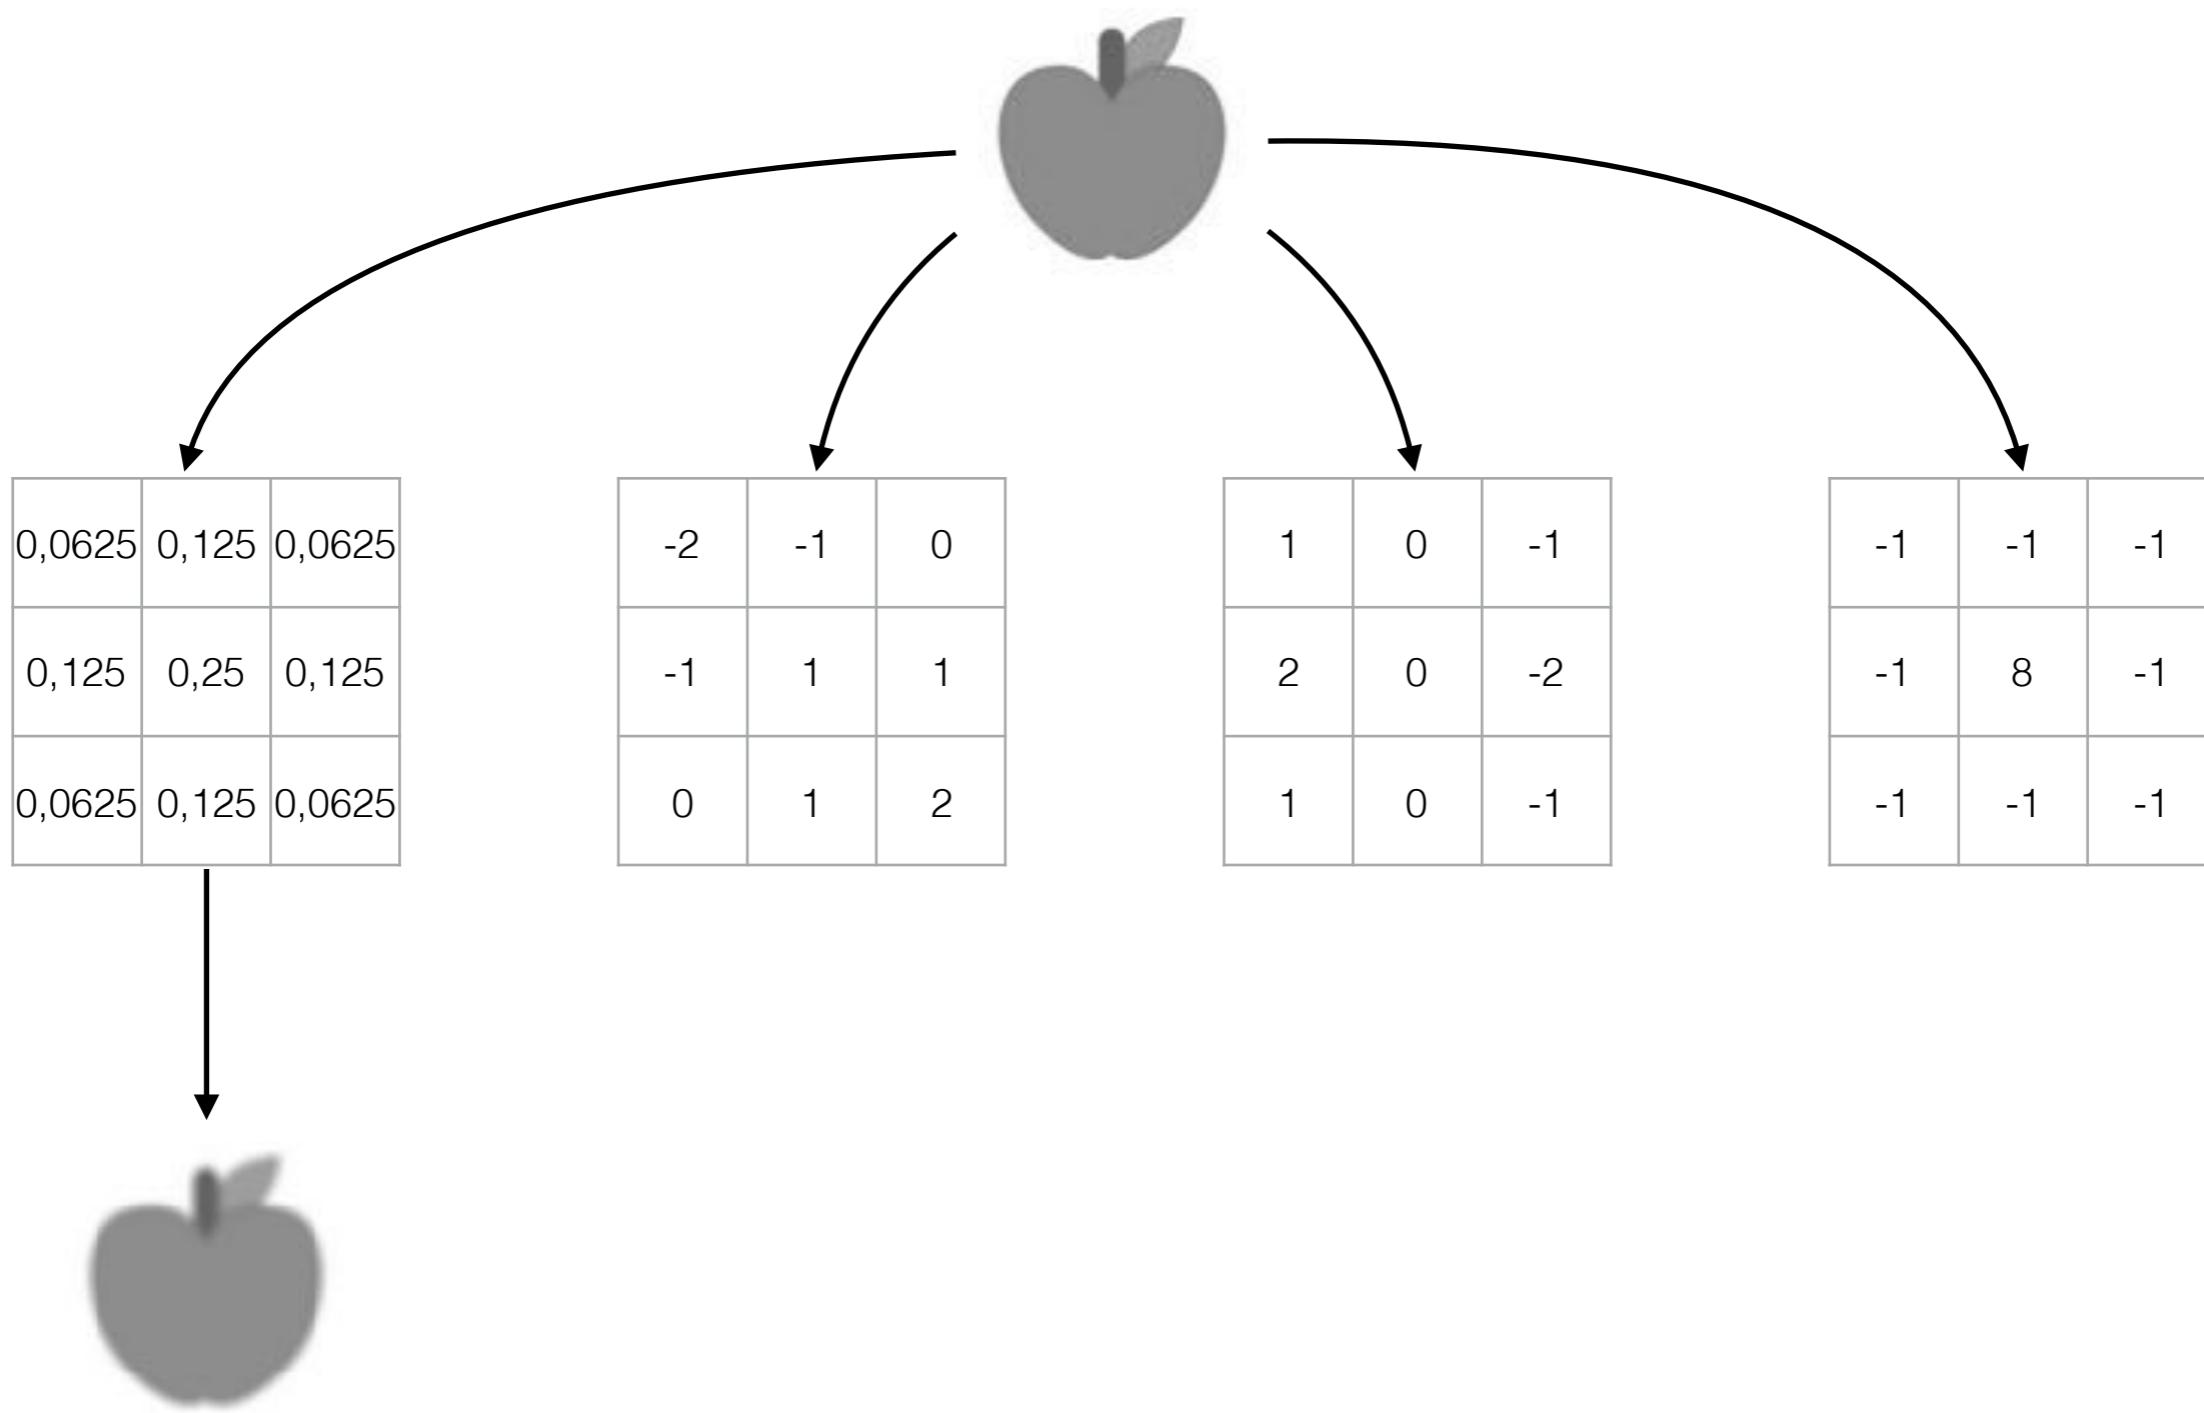
Filtros de Convolução Famosos



Filtros de Convolução Famosos

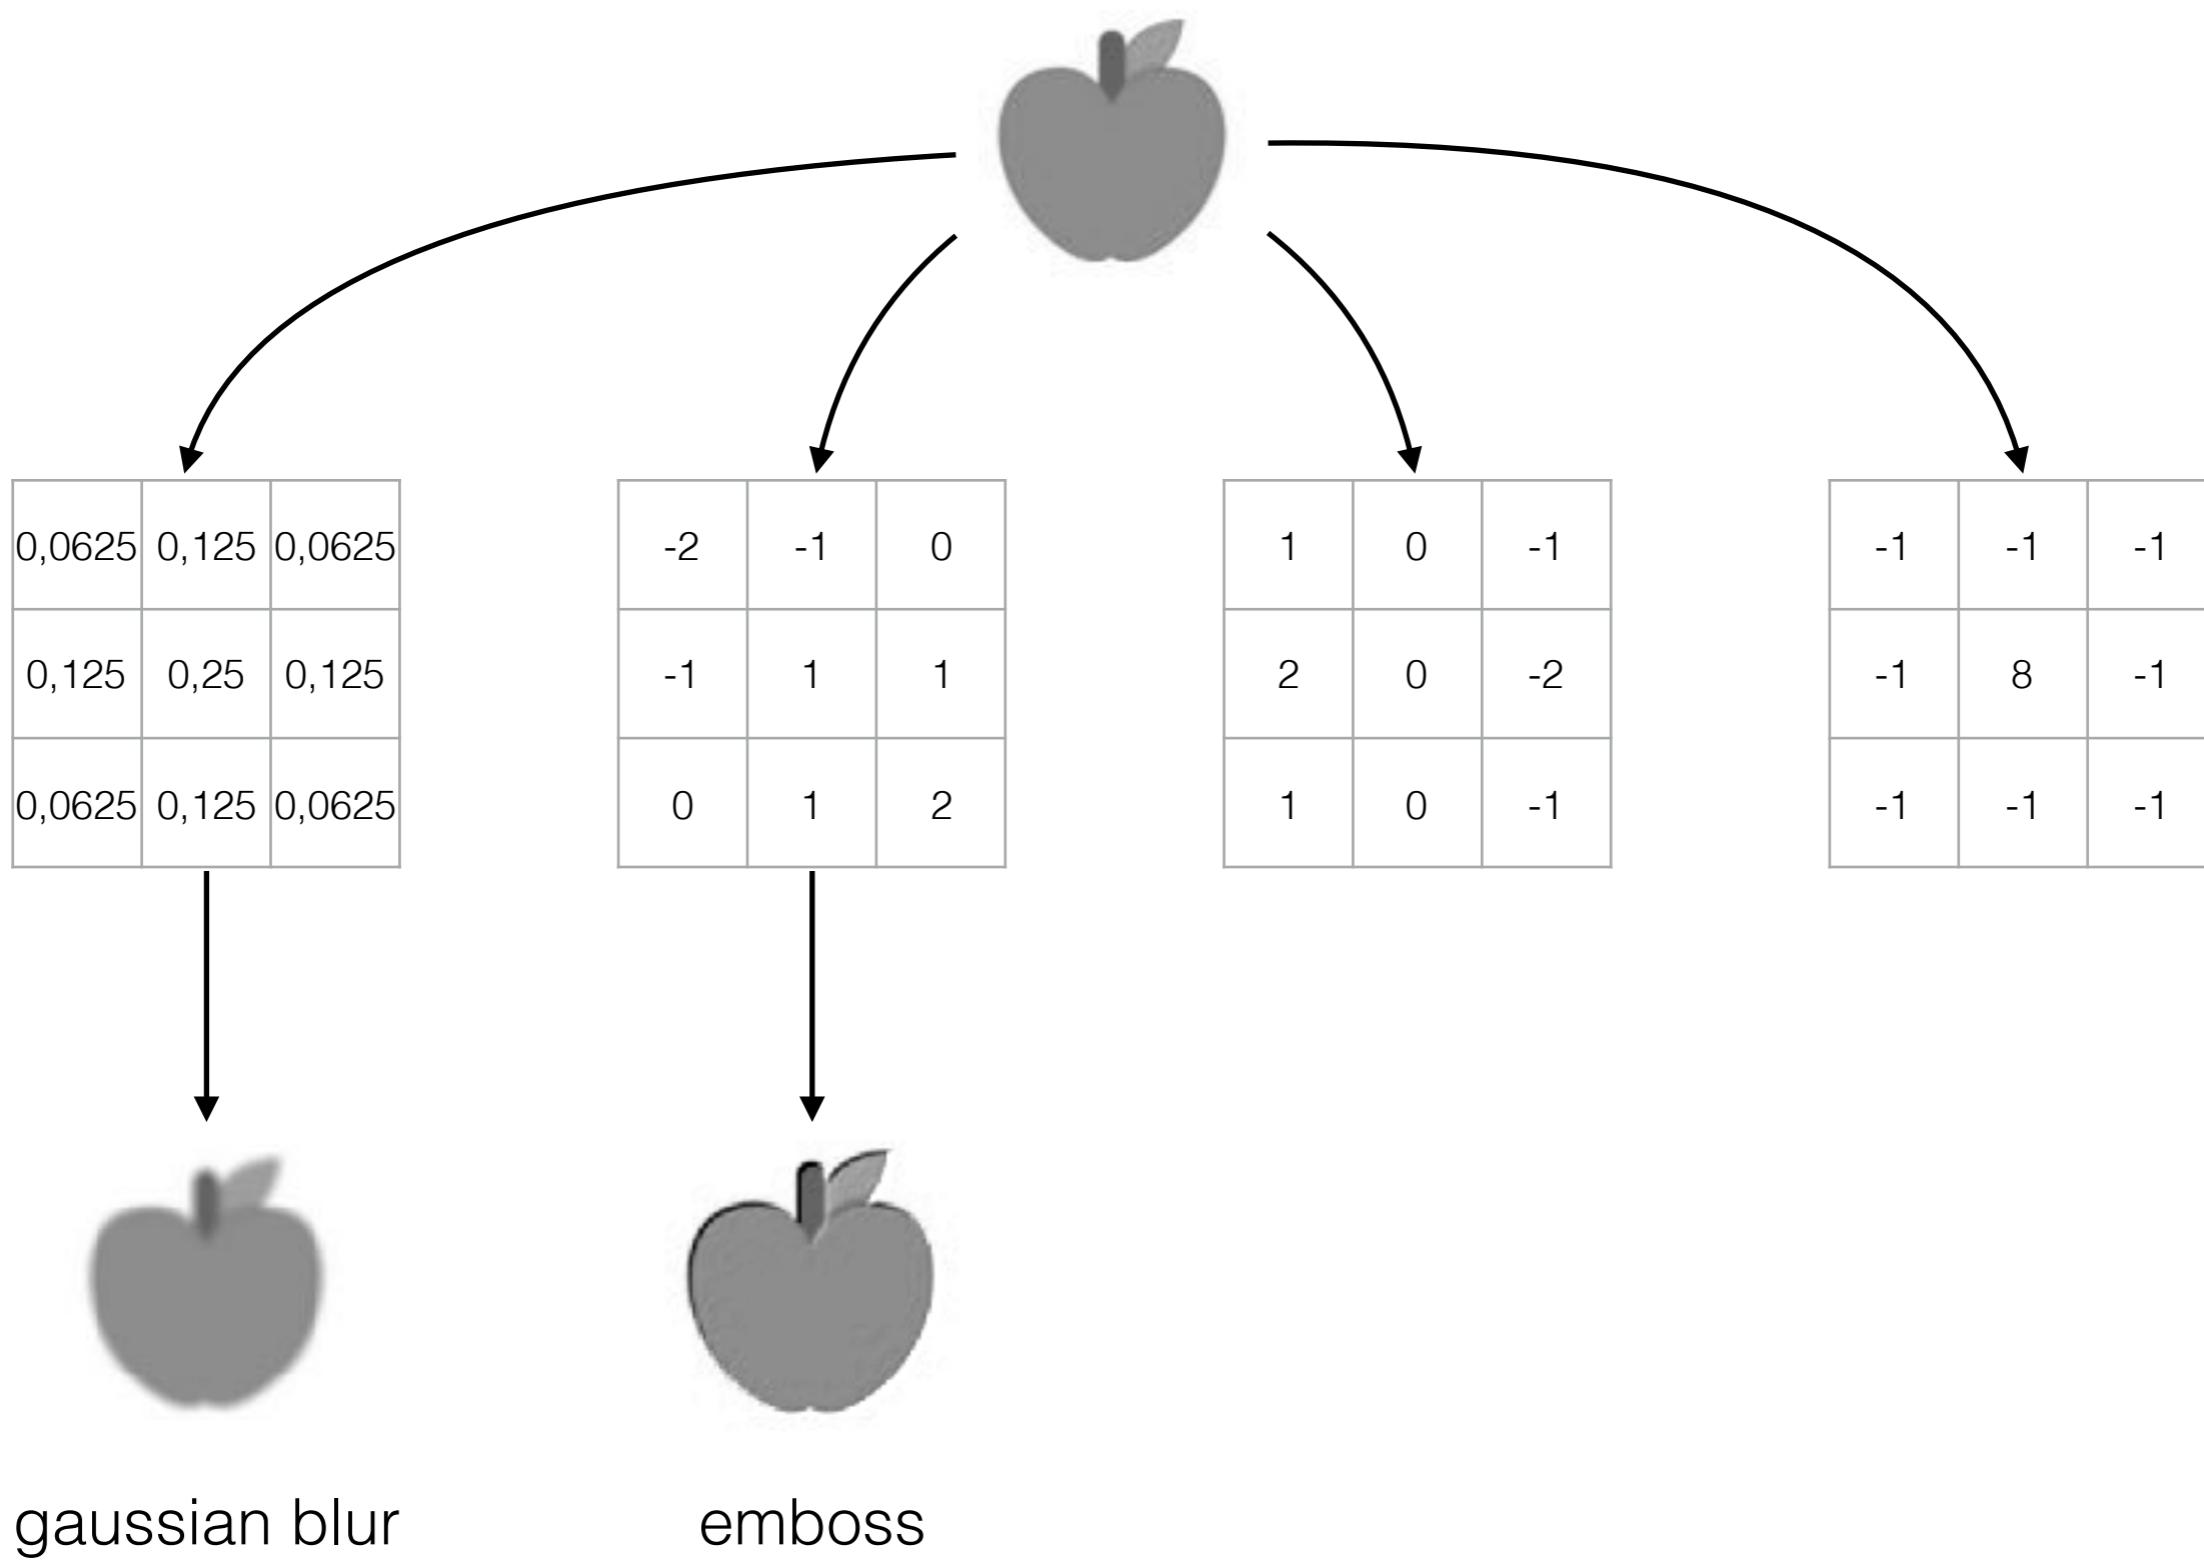


Filtros de Convolução Famosos

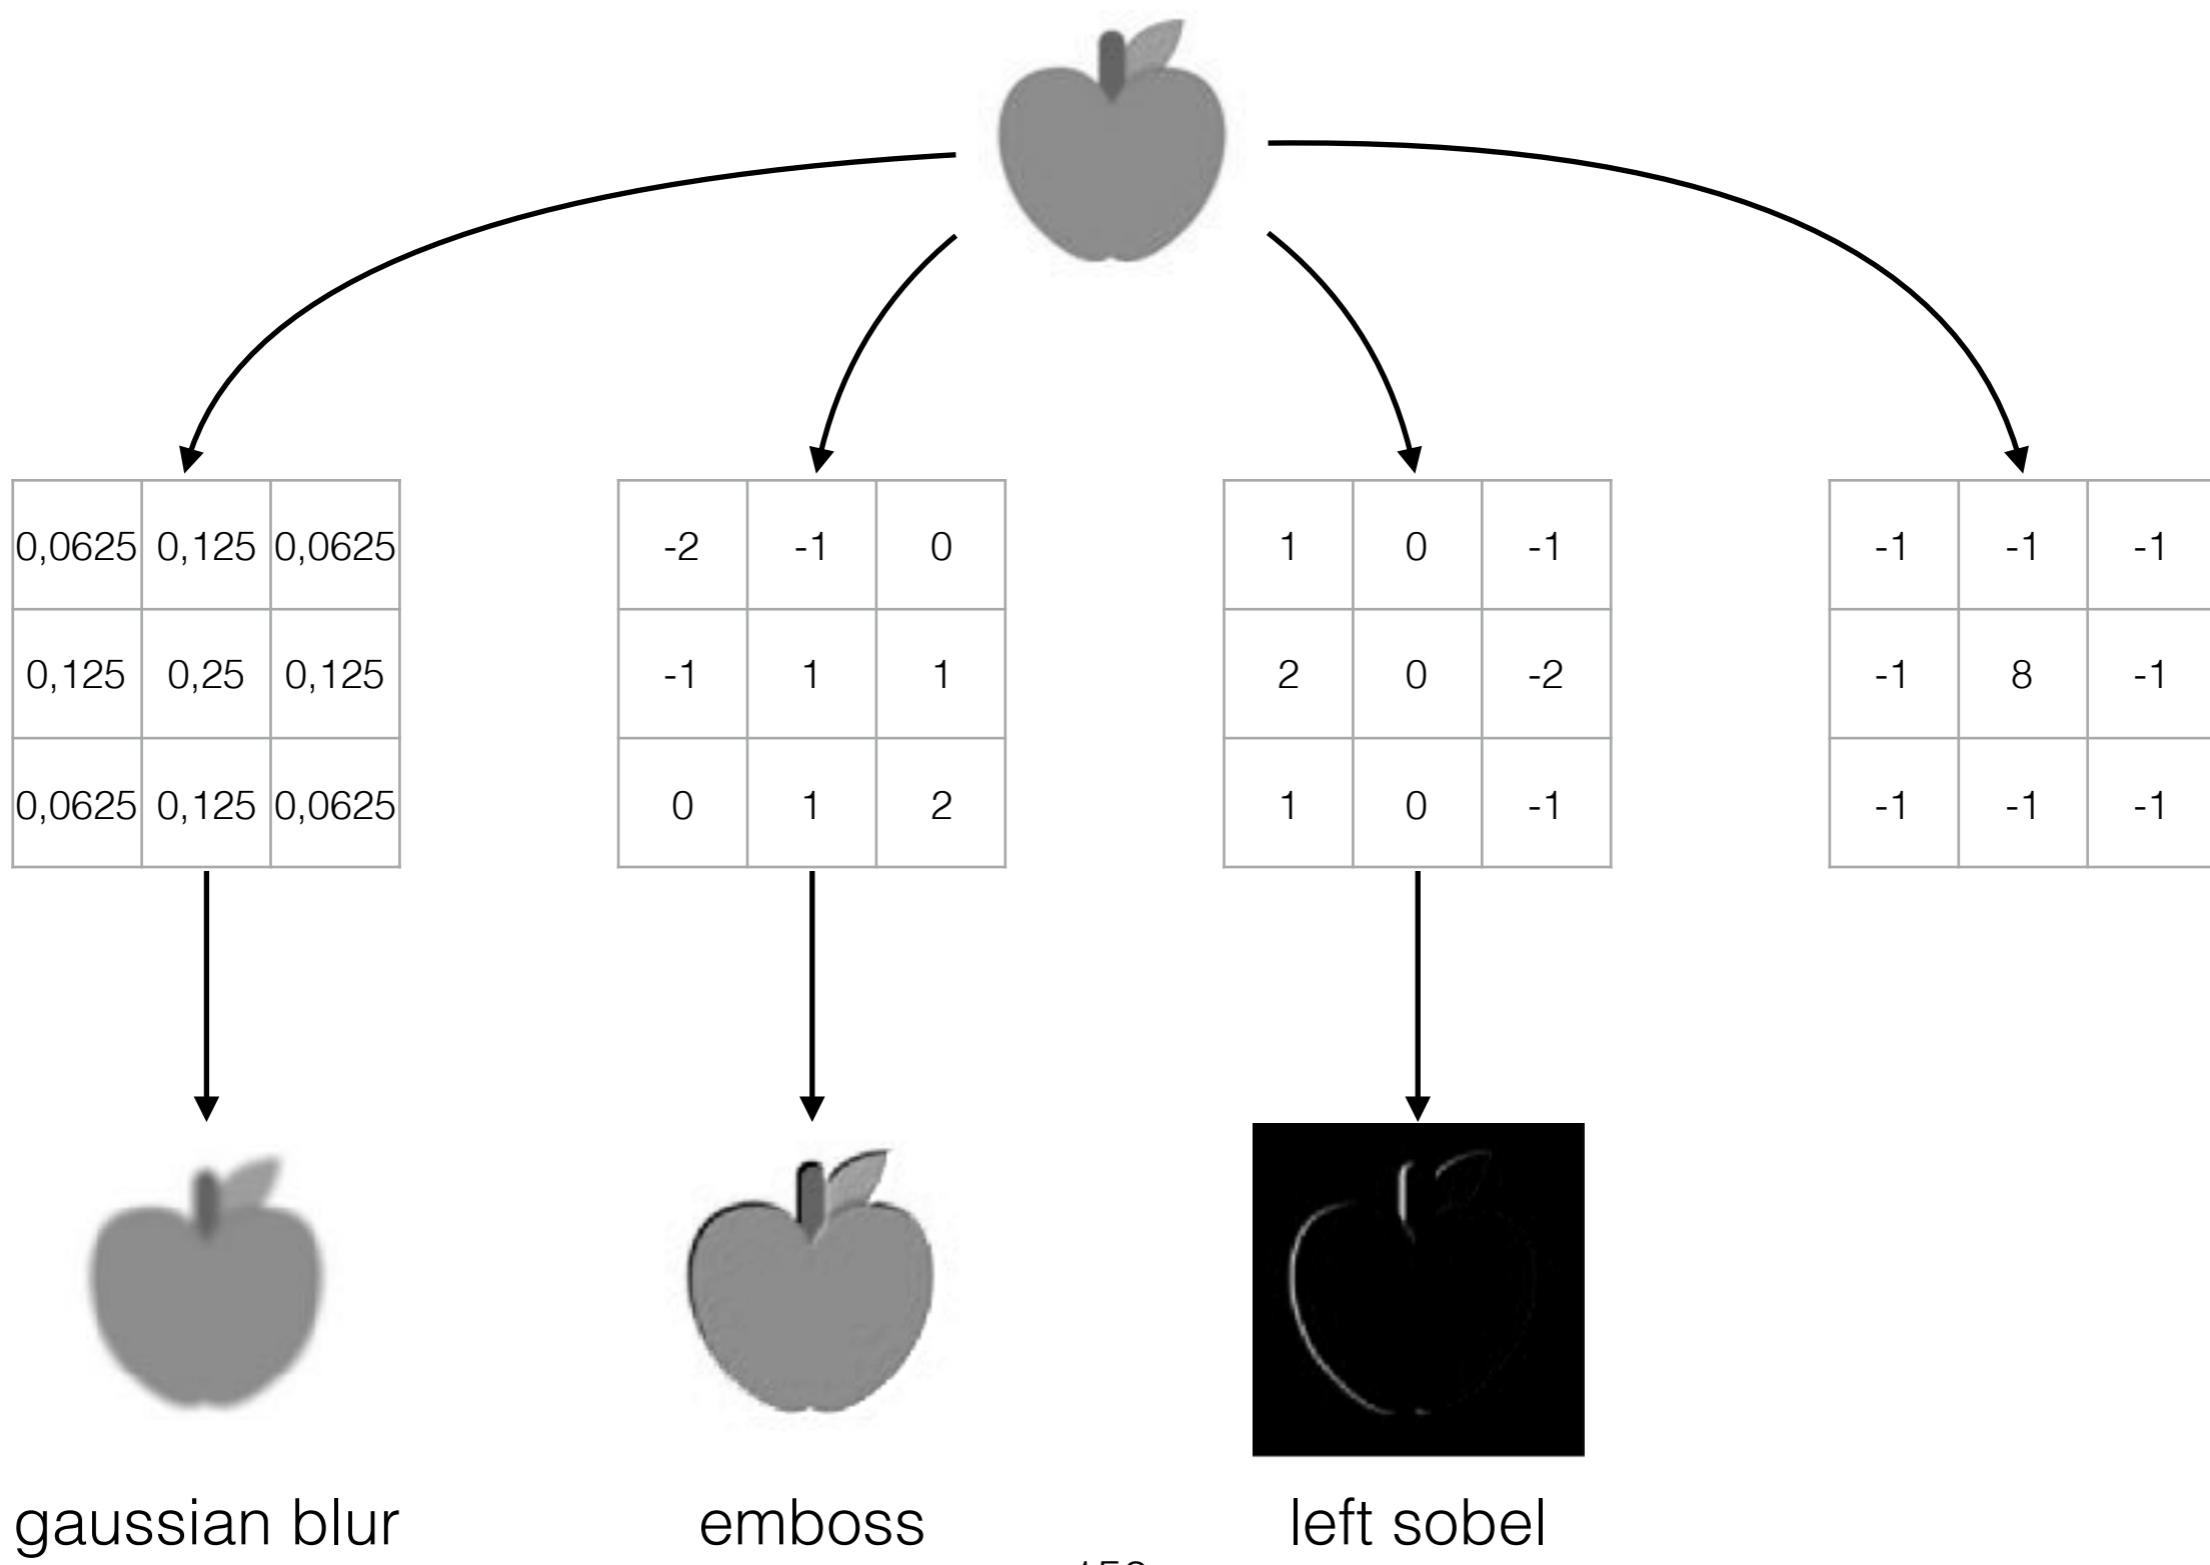


gaussian blur

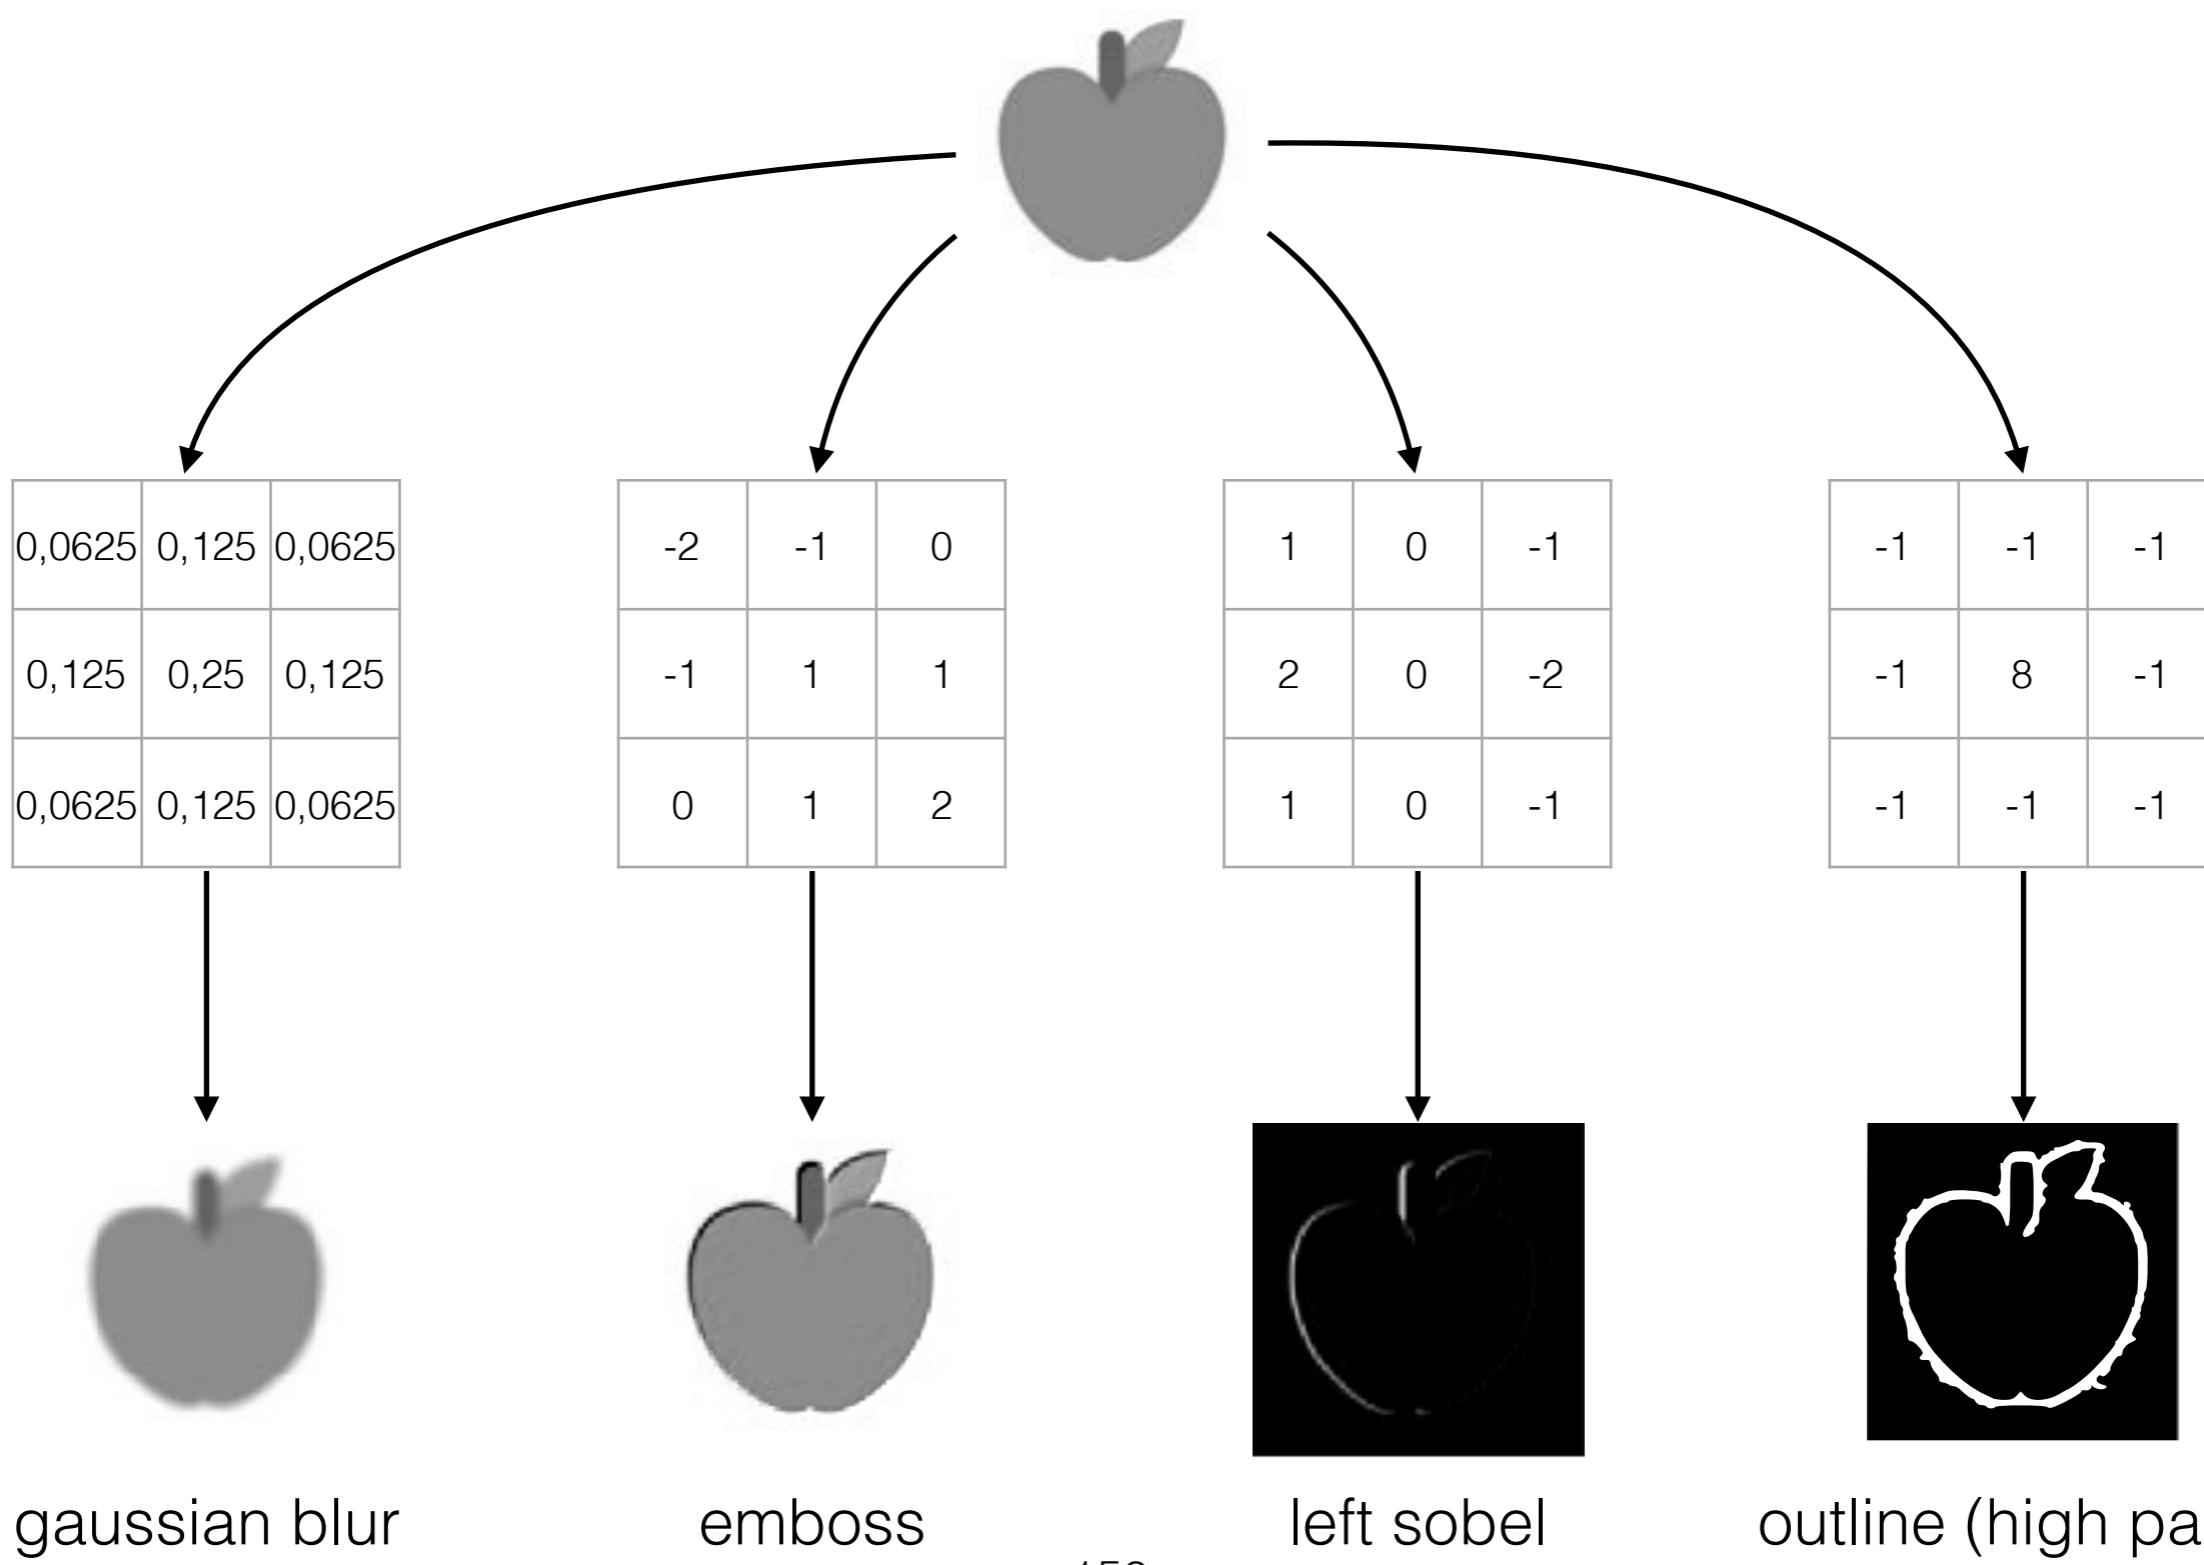
Filtros de Convolução Famosos



Filtros de Convolução Famosos



Filtros de Convolução Famosos



Filtros de Convolução Famosos

0,0625	0,125	0,0625
0,125	0,25	0,125
0,0625	0,125	0,0625

gaussian blur

-2	-1	0
-1	1	1
0	emboss	2



1	0	-1
2	0	-2
1	left sobel	1

-1	-1	-1
-1	8	-1
outline	(high pass)	

Redes Neurais Convolucionais

0,0625	0,125	0,0625
0,125	0,25	0,125
0,0625	0,125	0,0625

gaussian blur

-2	-1	0
-1	1	1
0	emboss	2

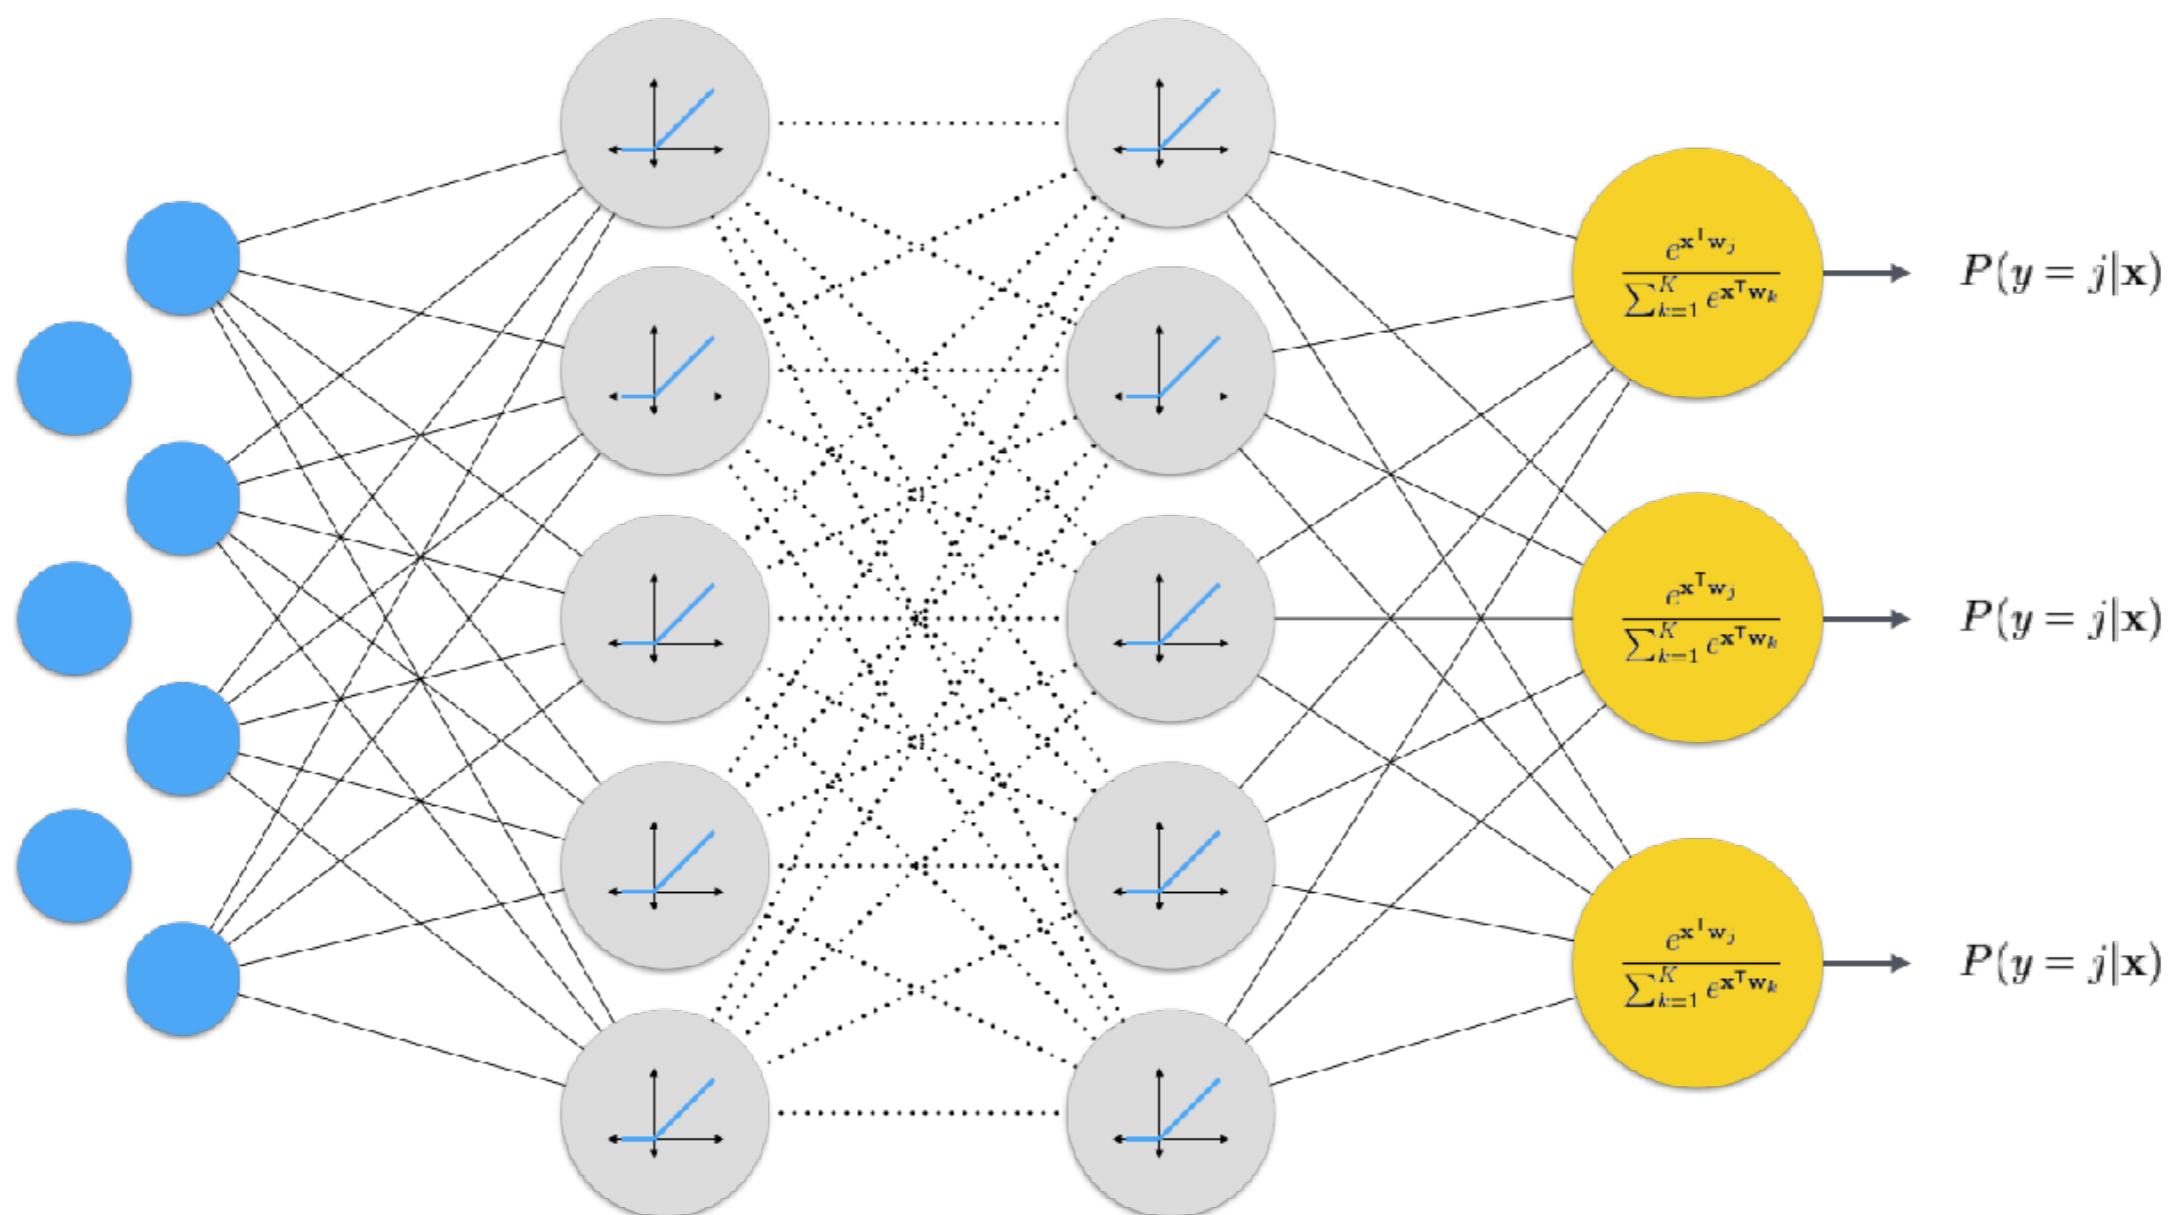


1	0	-1
2	0	-2
1	left sobel	1

-1	-1	-1
-1	8	-1
outline	(high pass)	

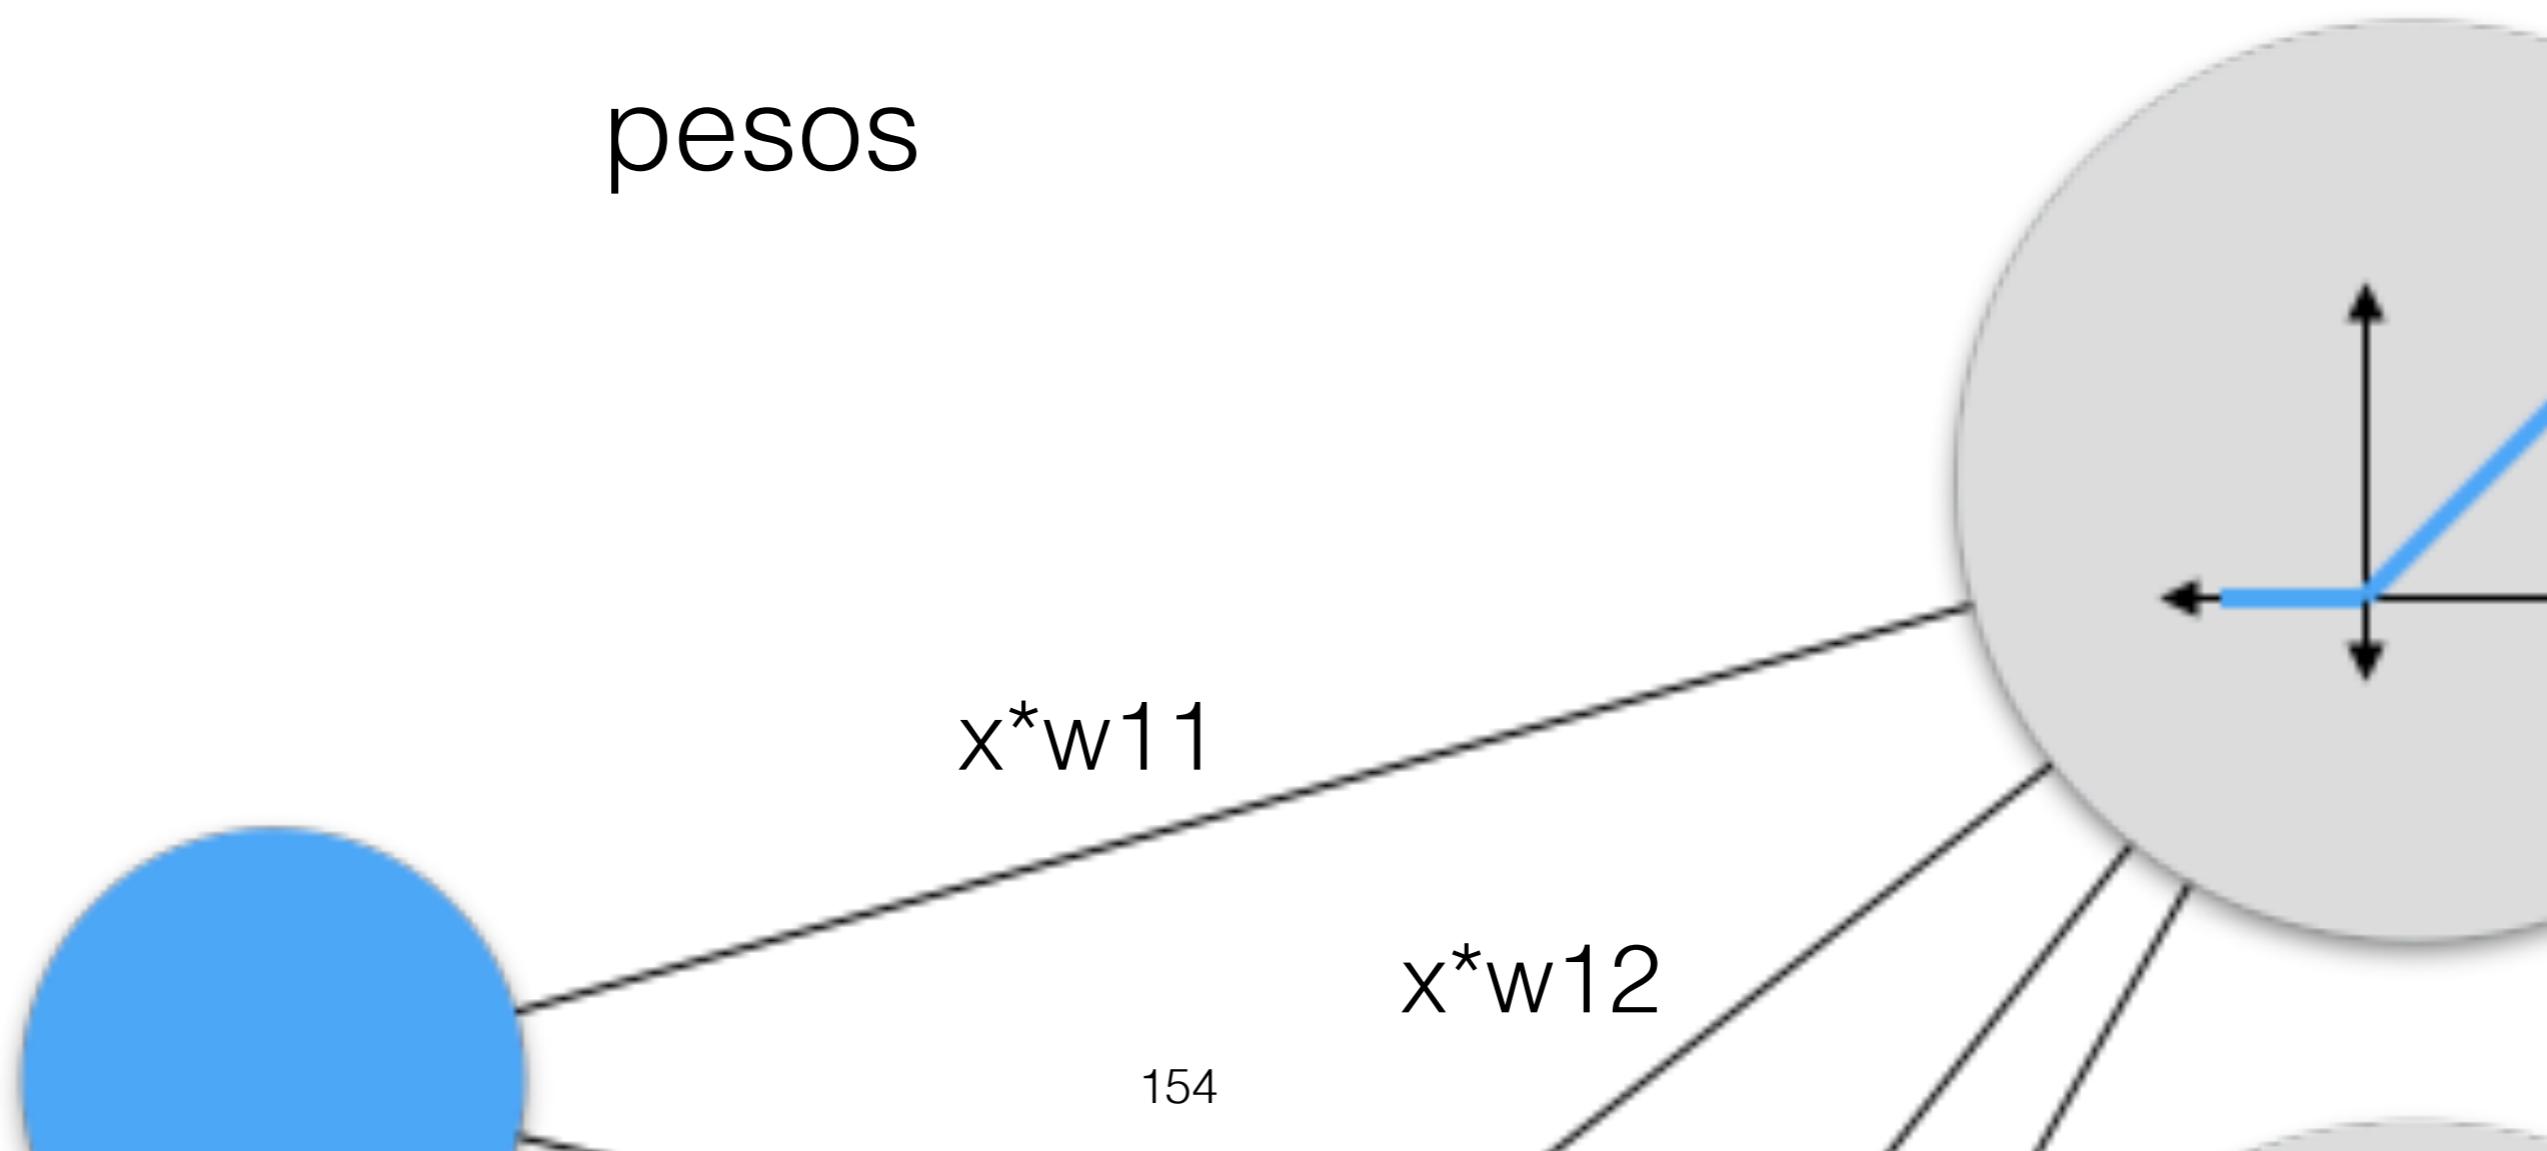
Redes Neurais Convolucionais

Redes Neurais Artificiais



Redes Neurais Artificiais

pesos

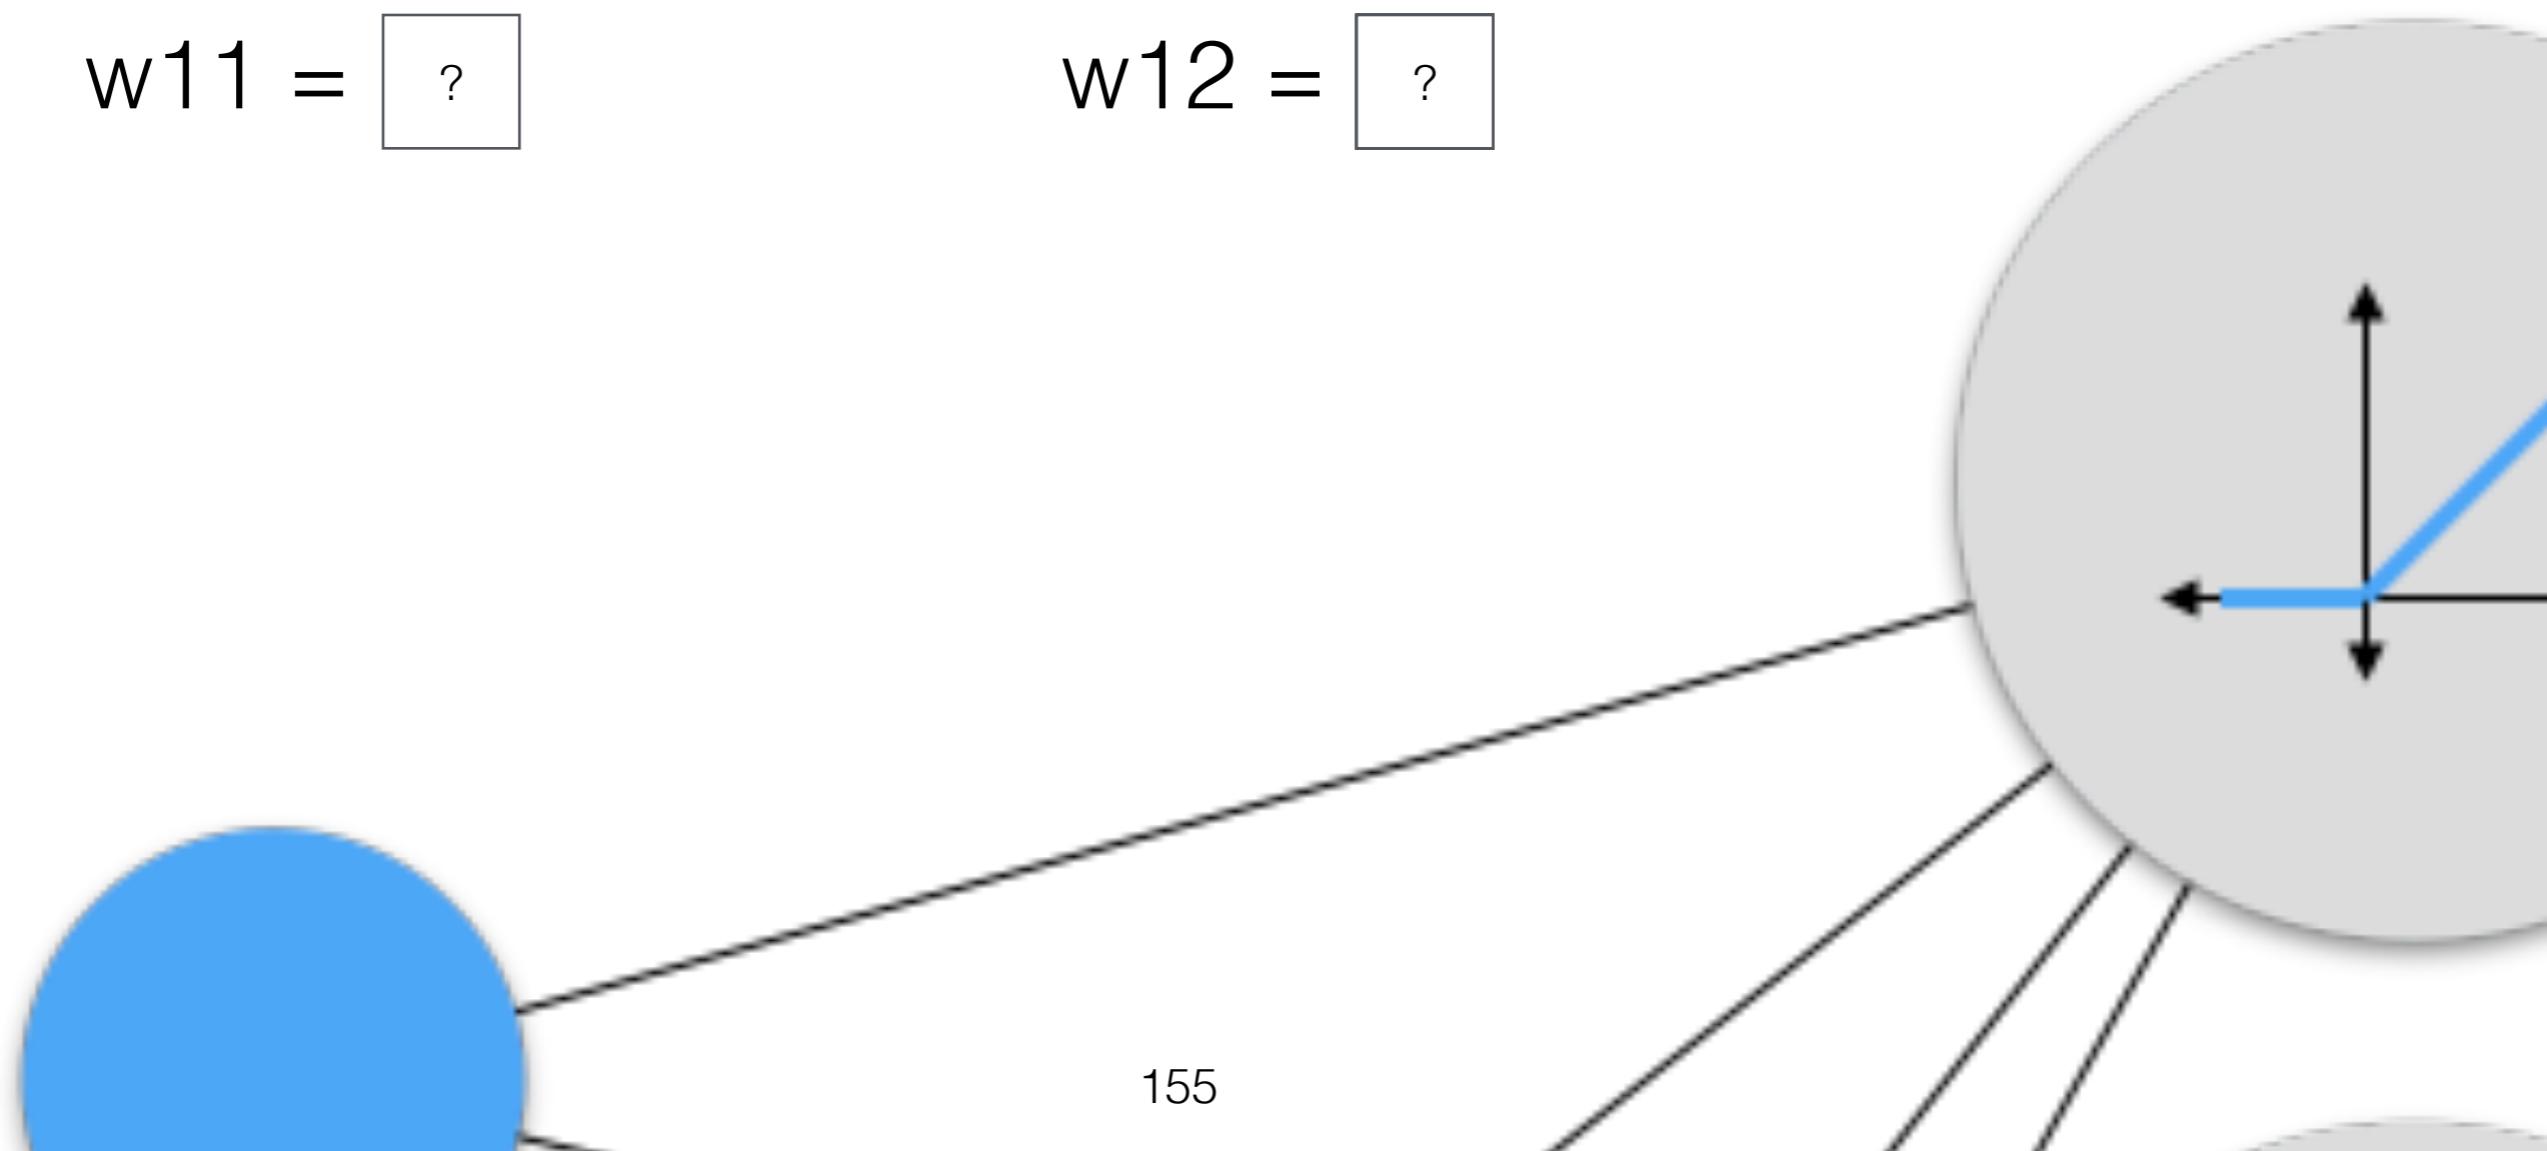


Redes Neurais Artificiais

pesos

$$w_{11} = \boxed{?}$$

$$w_{12} = \boxed{?}$$

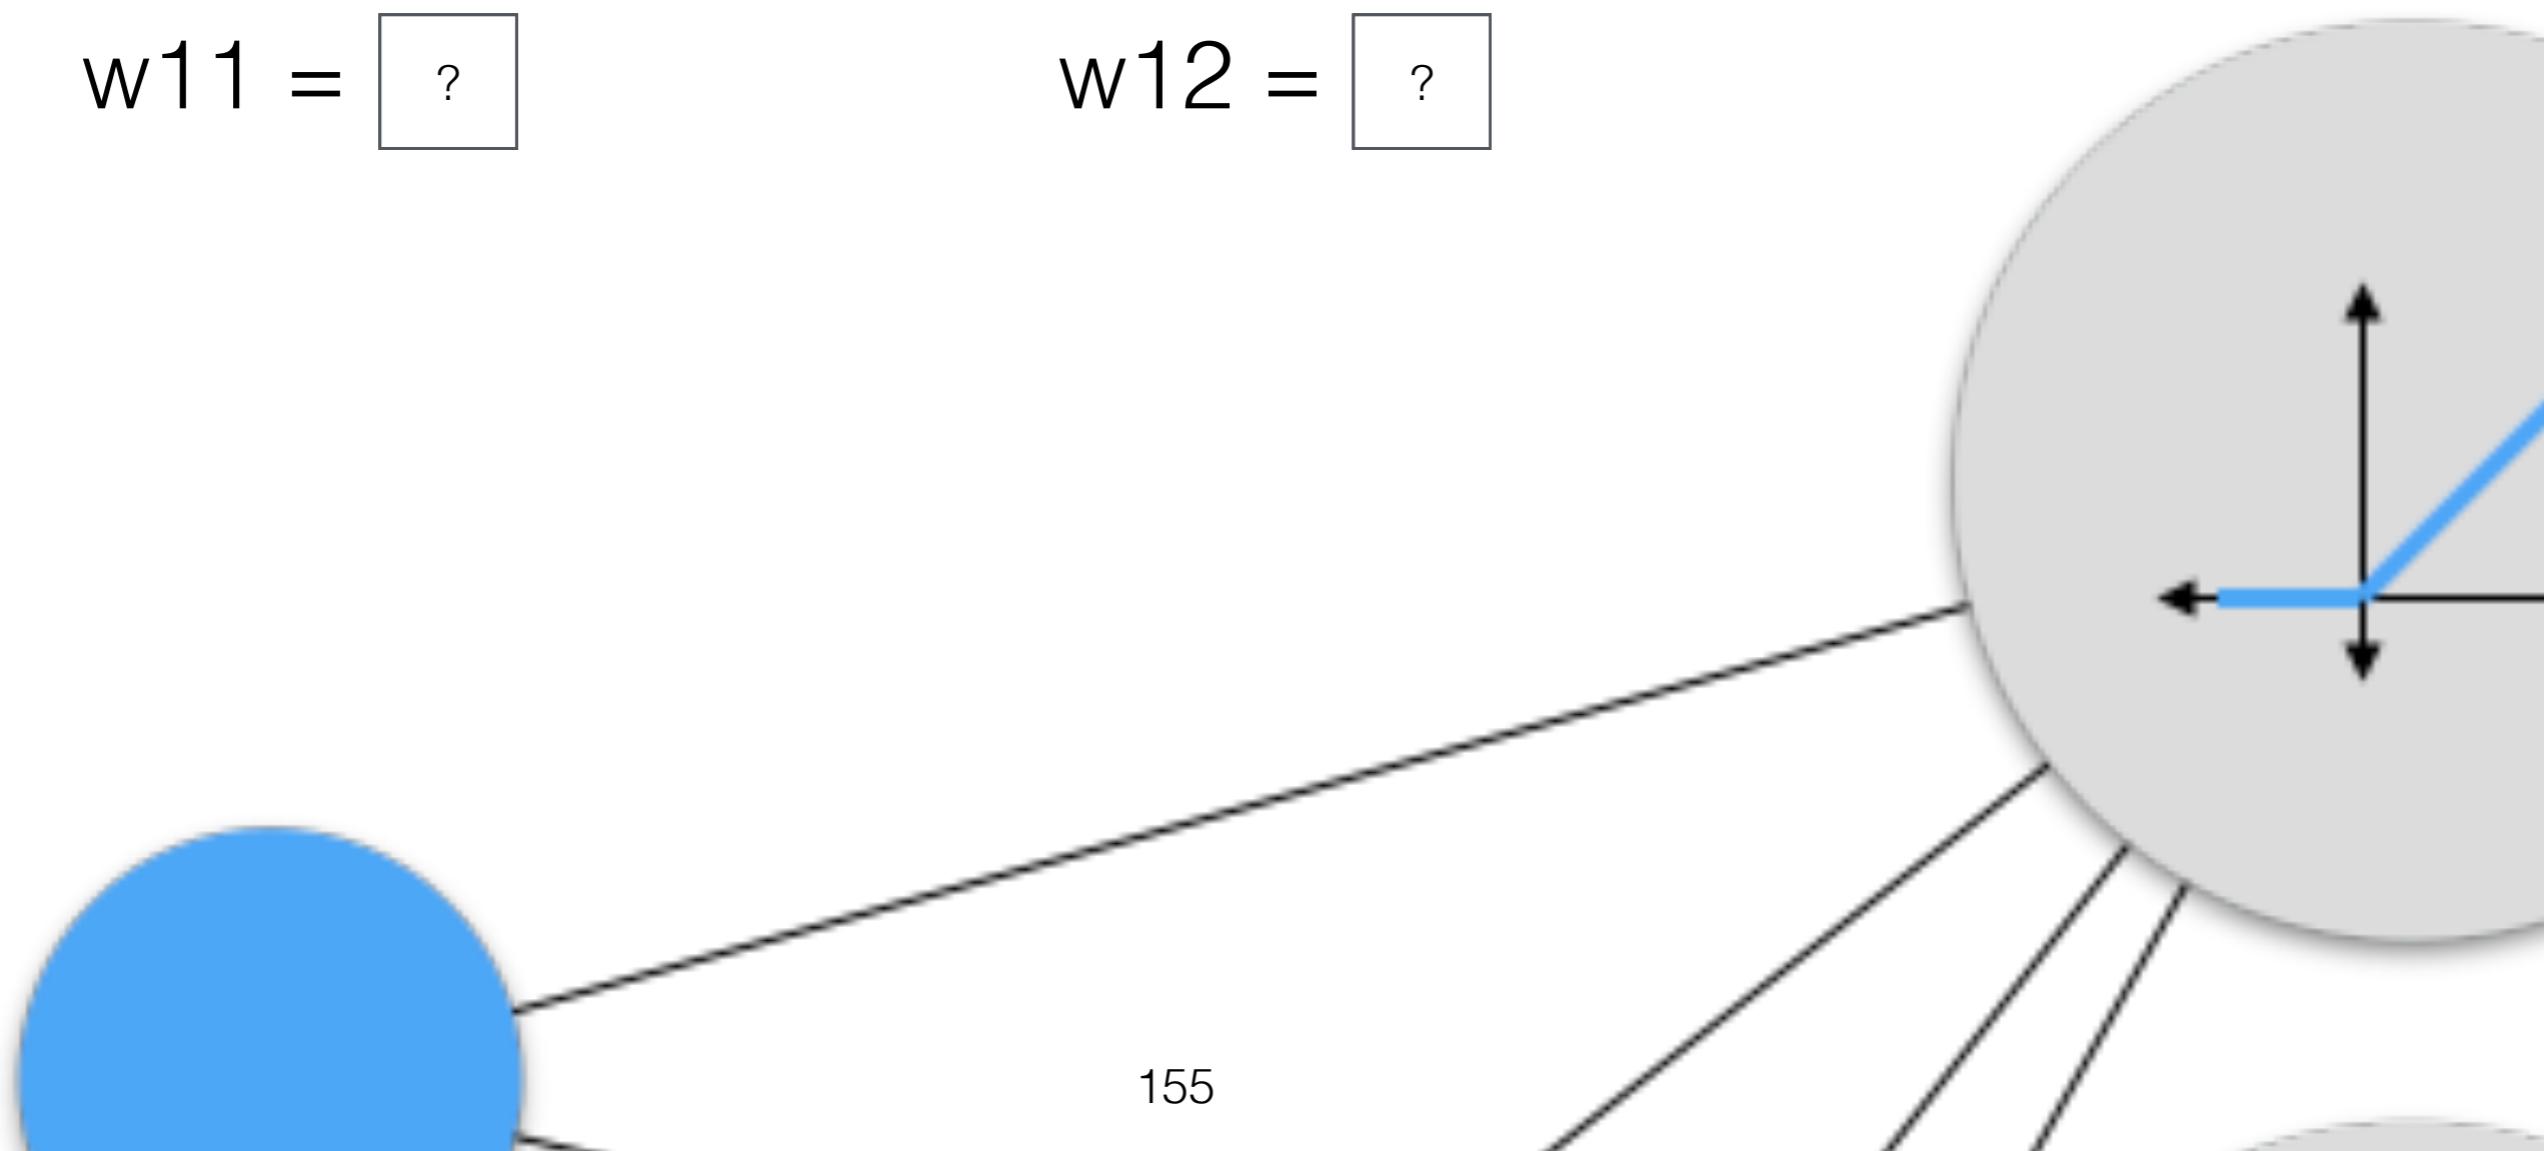


Redes Neurais Artificiais

pesos

$$w_{11} = \boxed{?}$$

$$w_{12} = \boxed{?}$$



Redes Neurais Artificiais

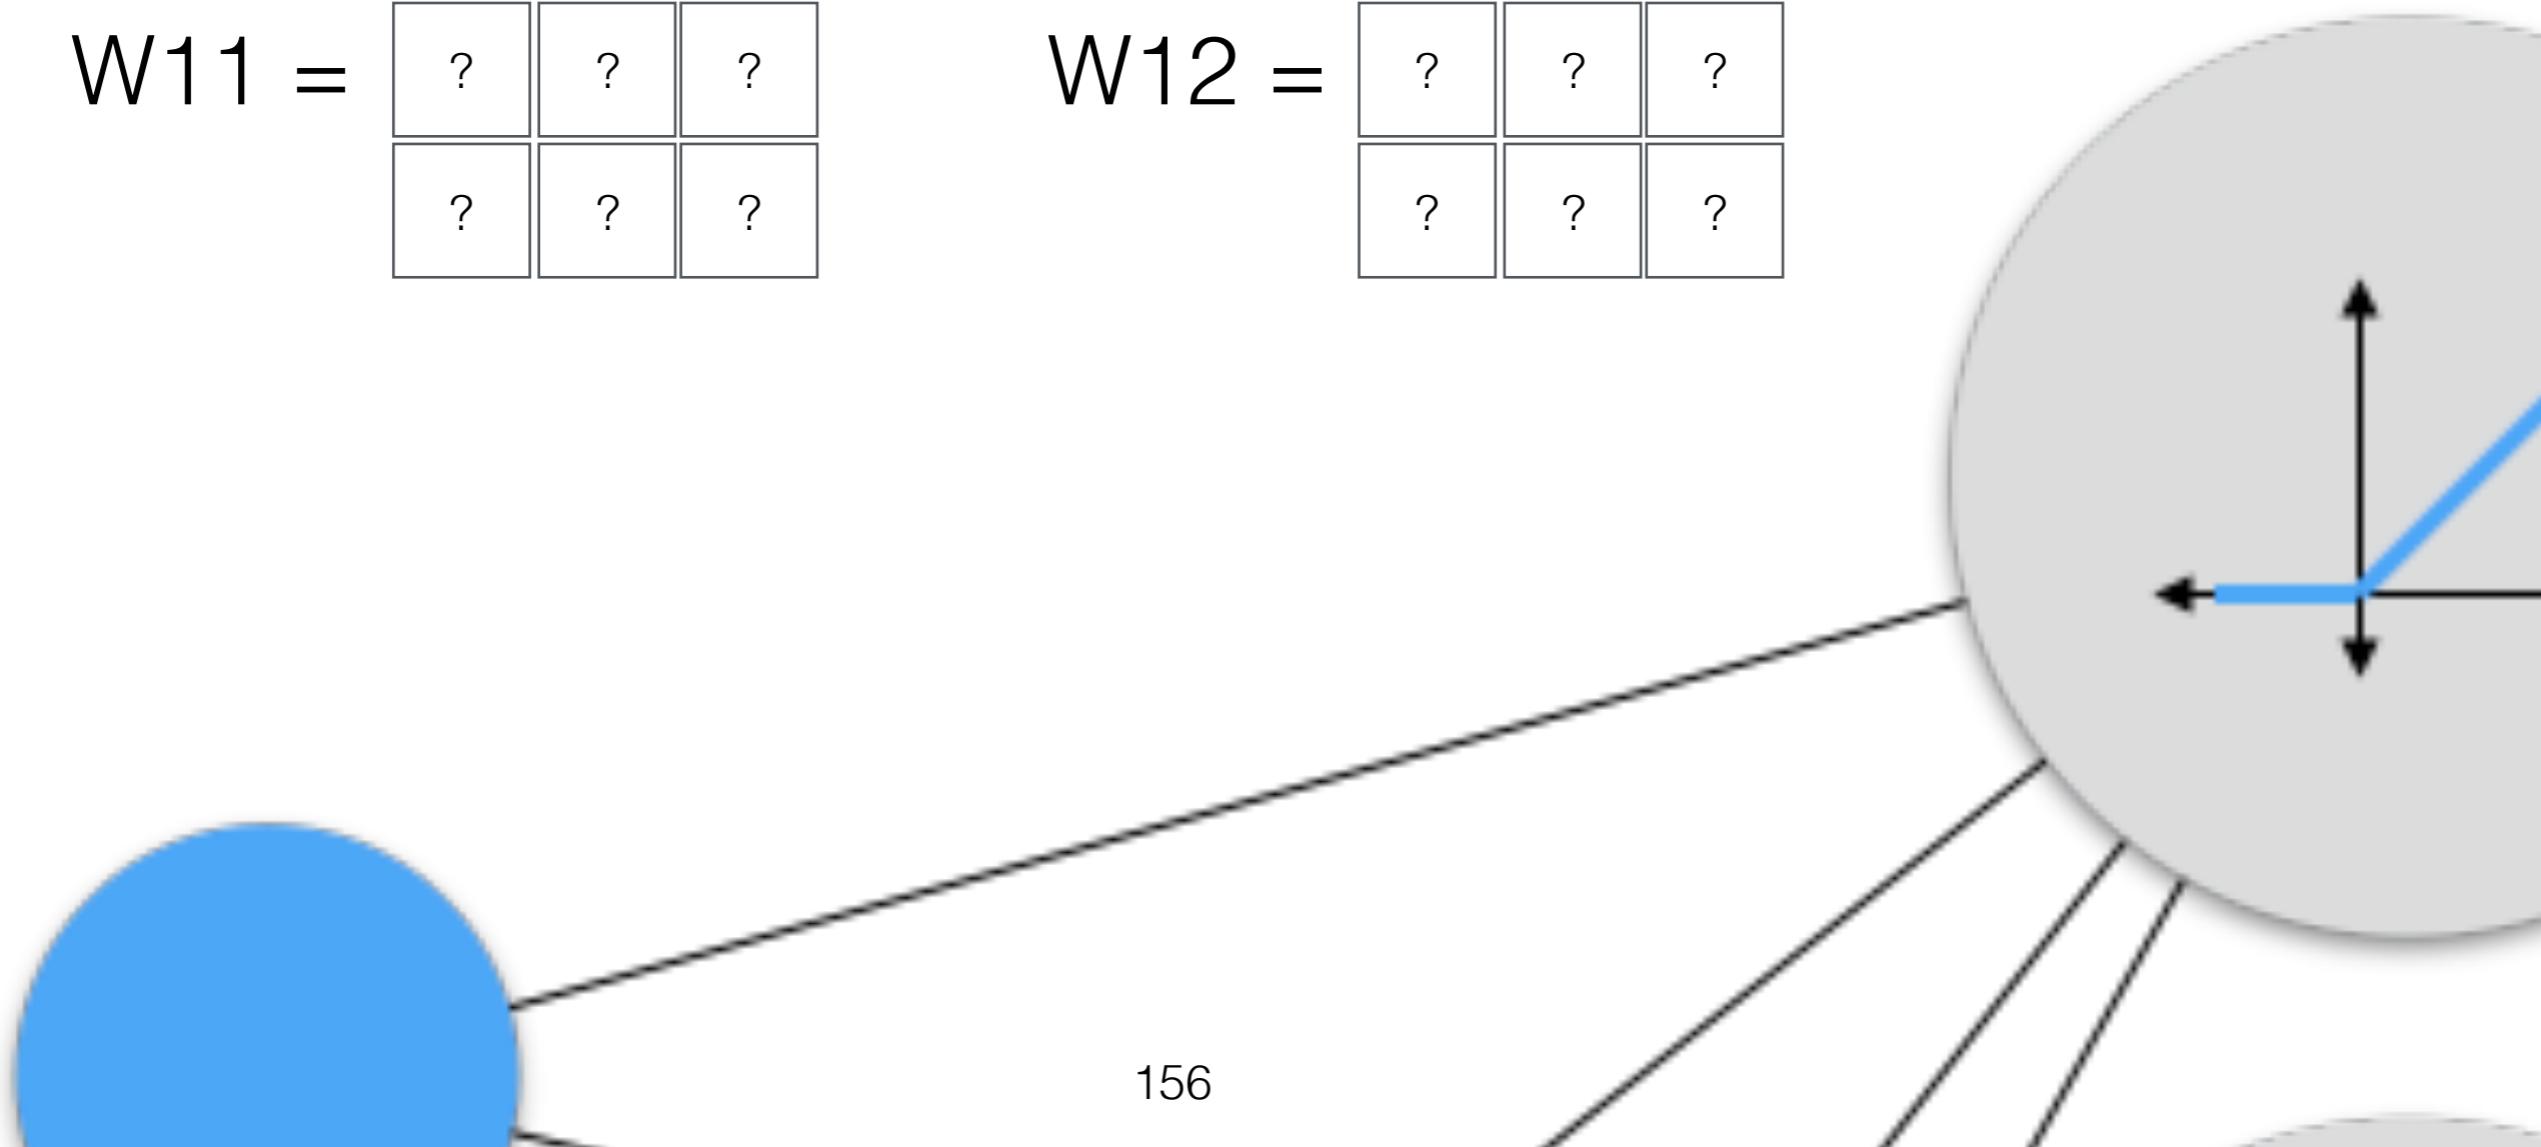
pesos

$W_{11} =$

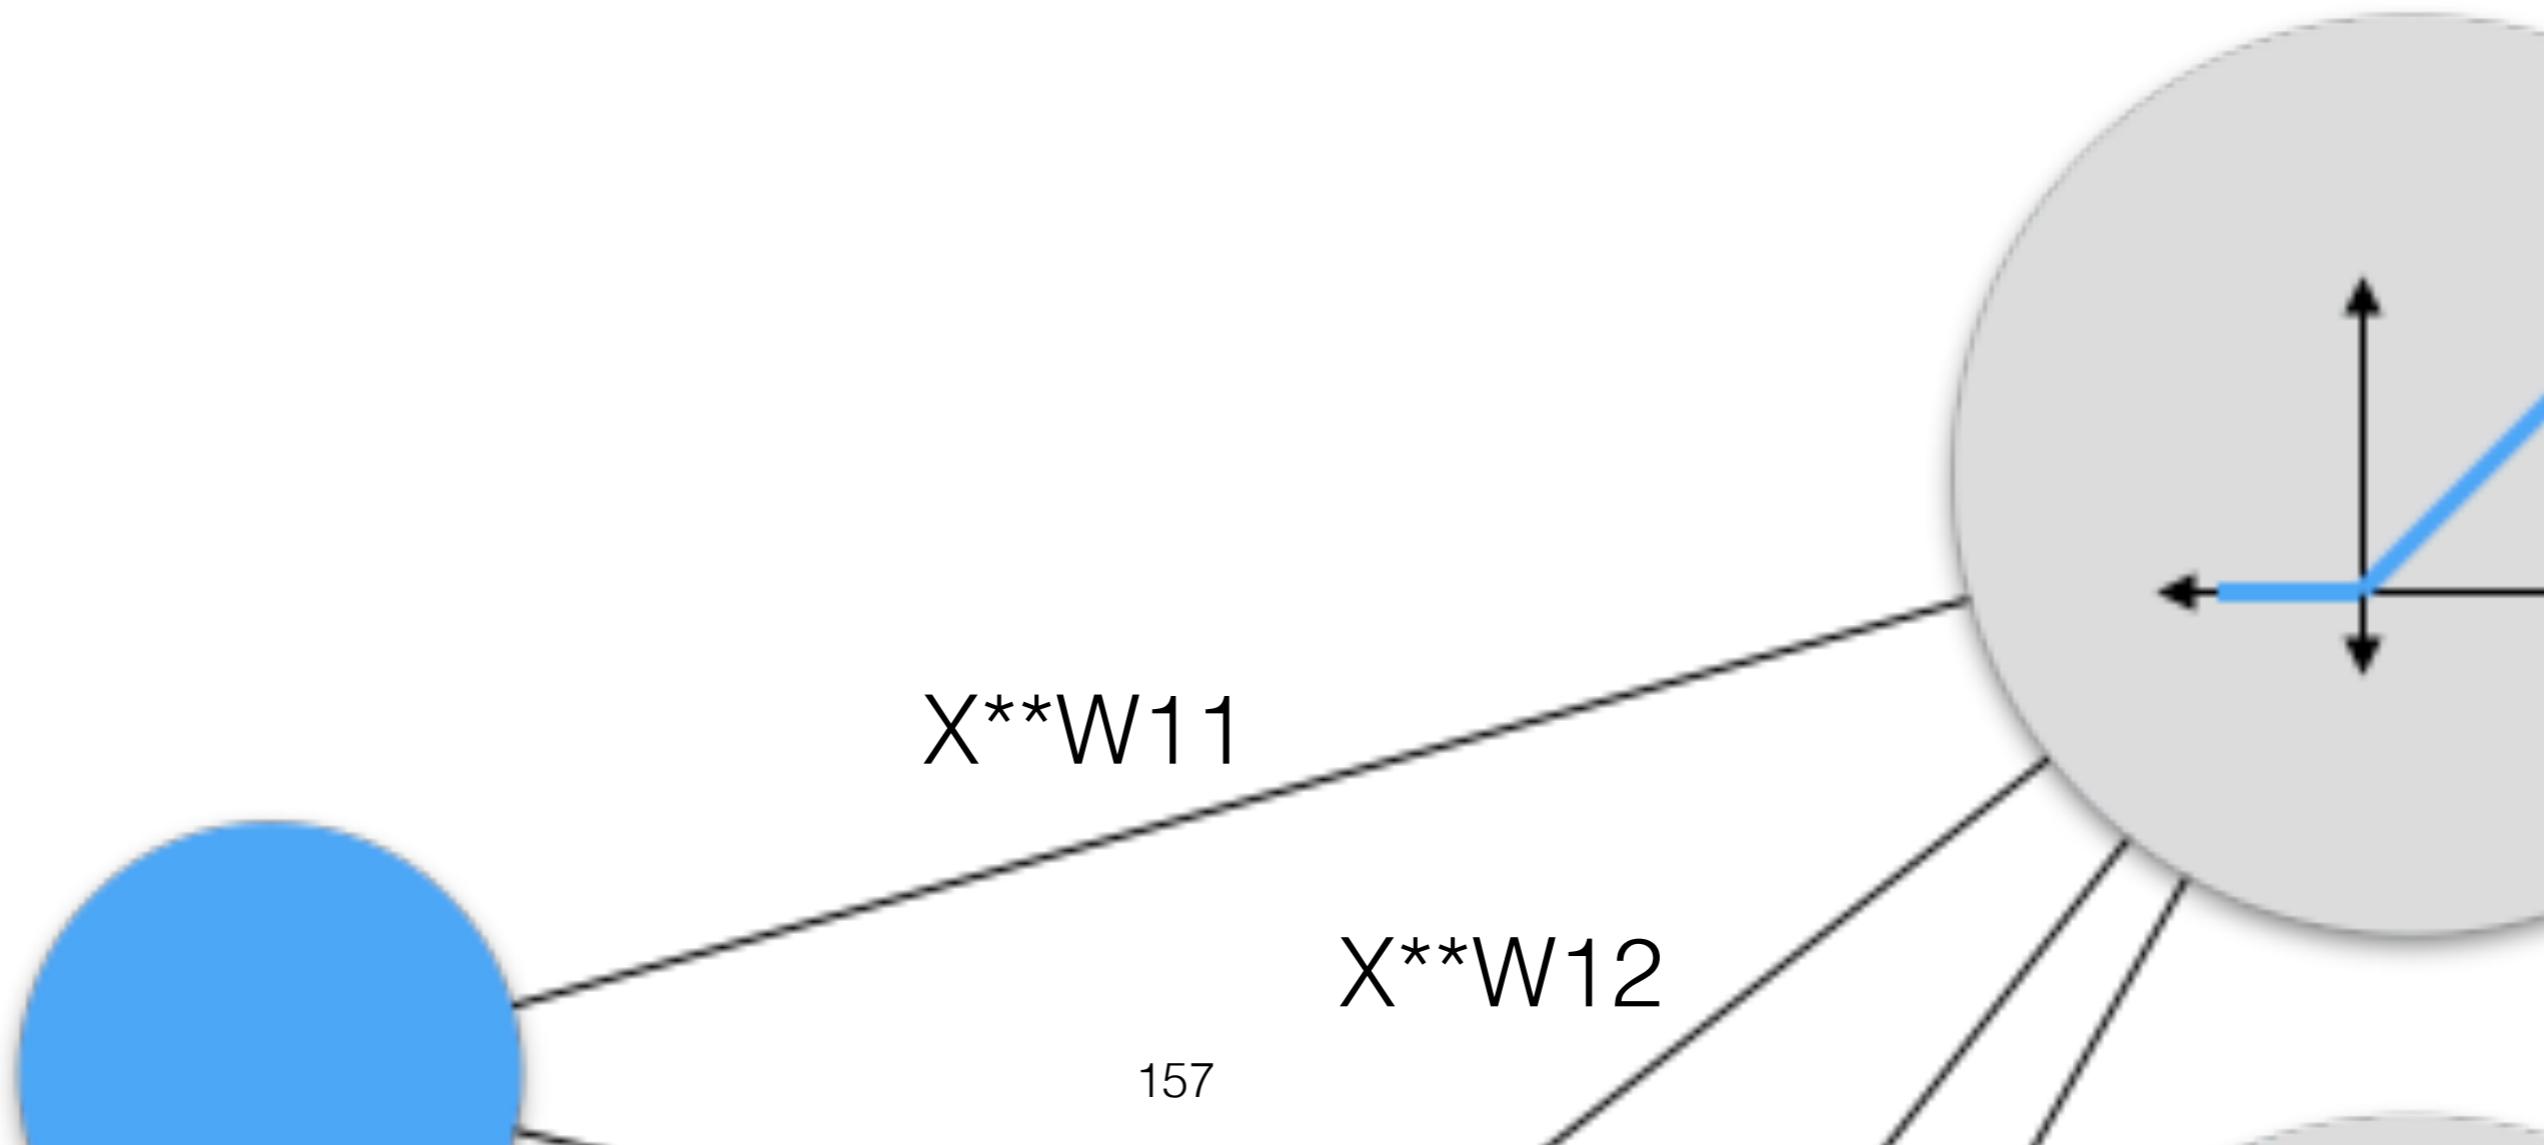
?	?	?
?	?	?
?	?	?

$W_{12} =$

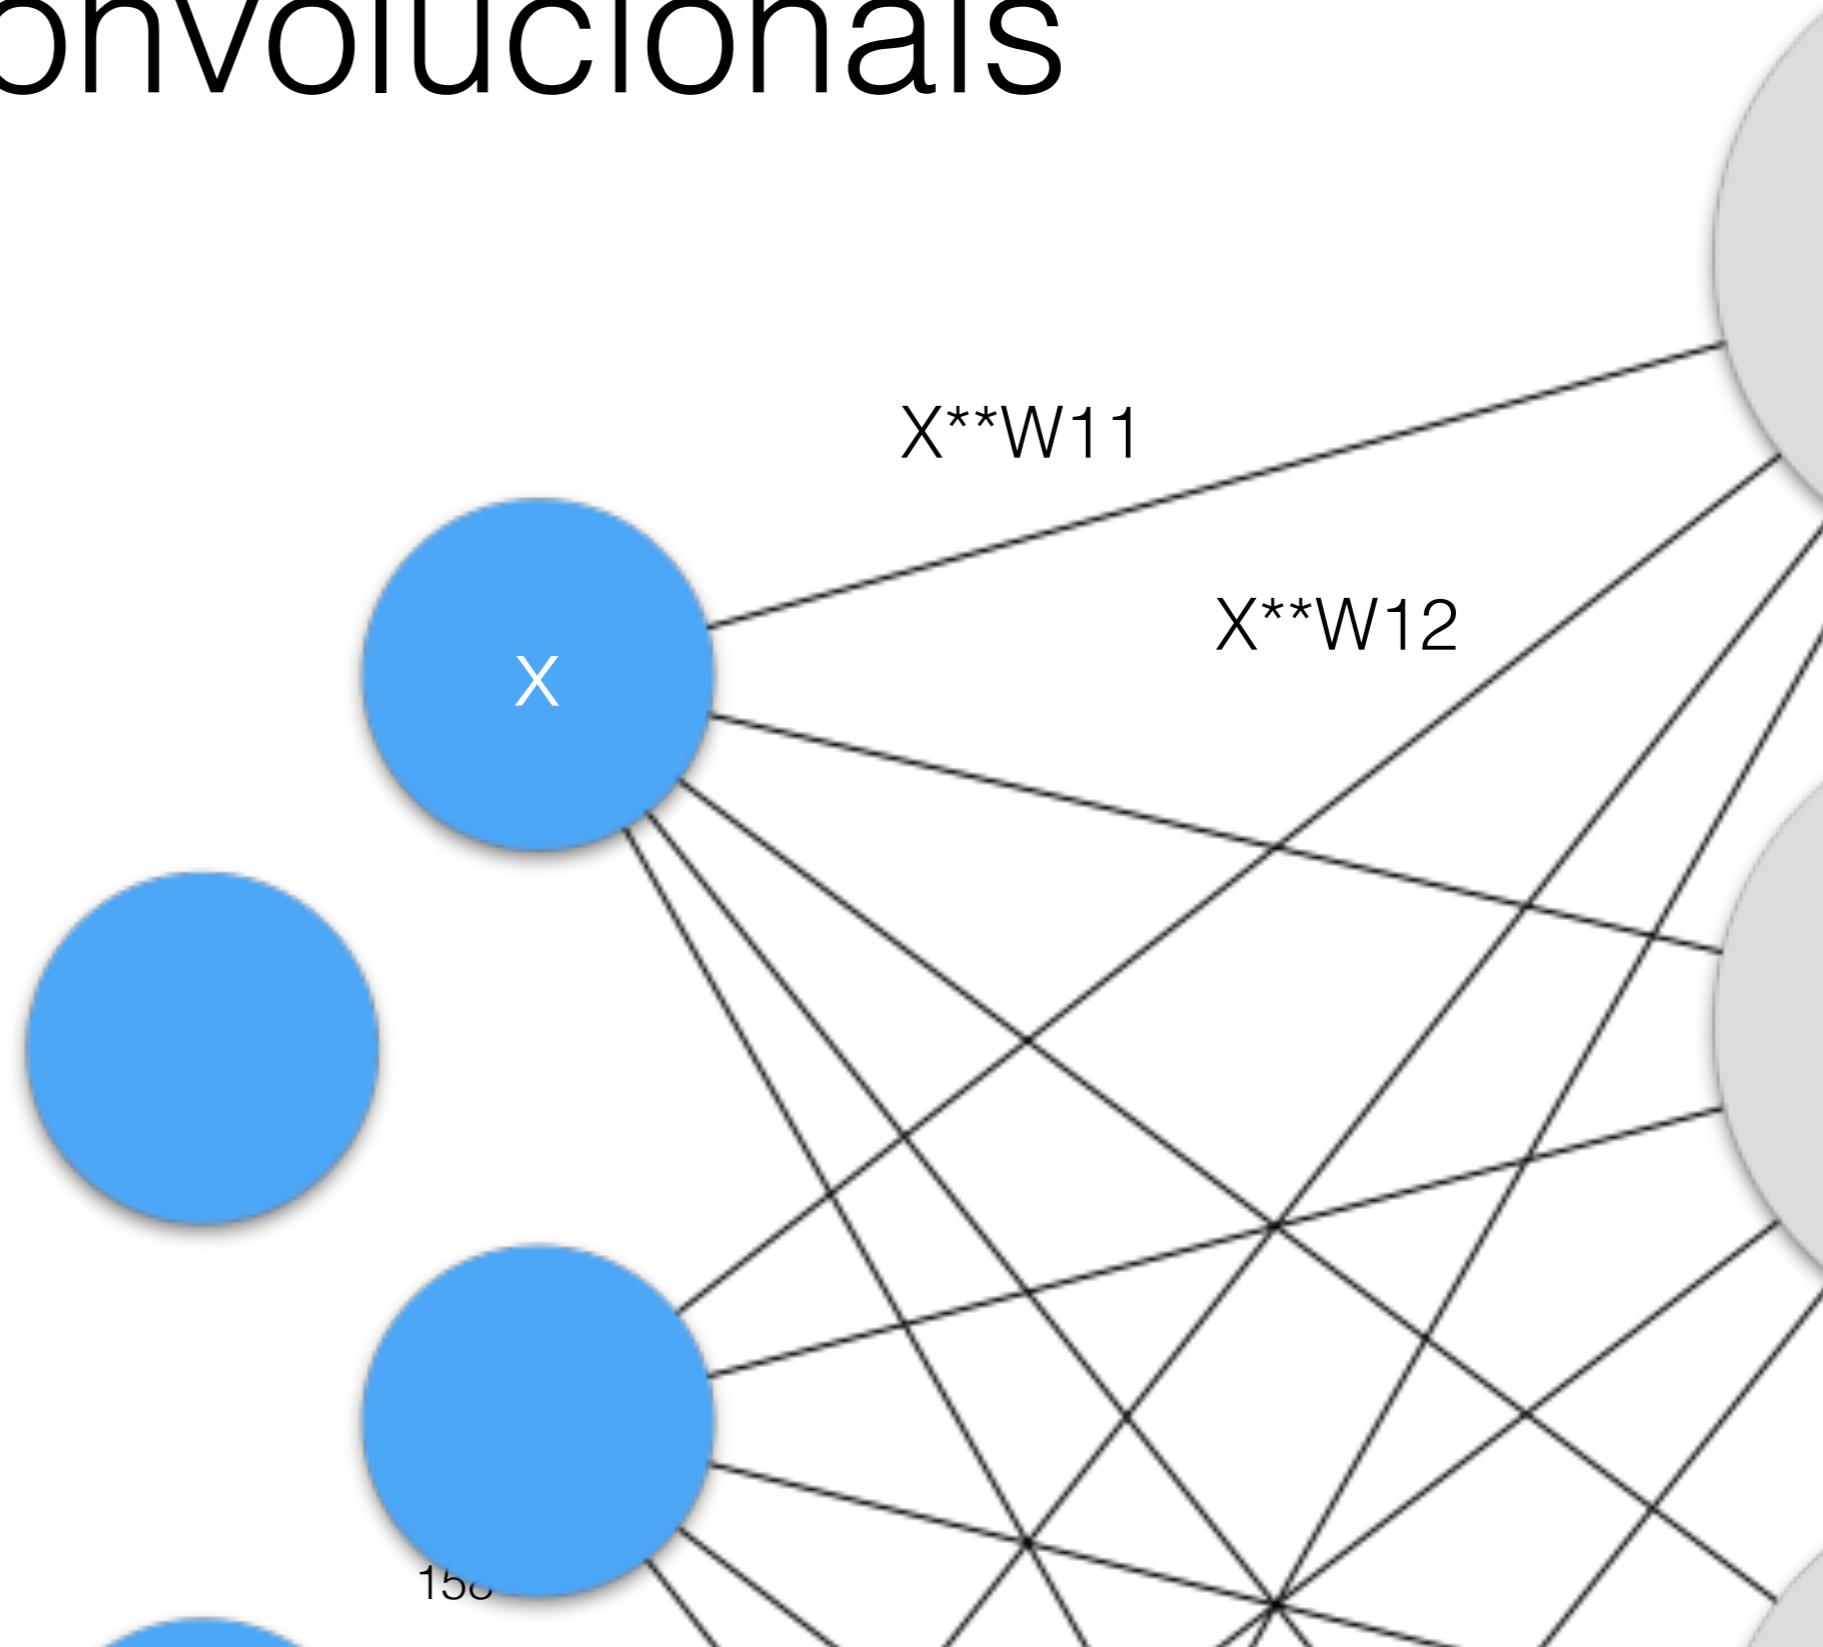
?	?	?
?	?	?
?	?	?



Redes Neurais Convolucionais

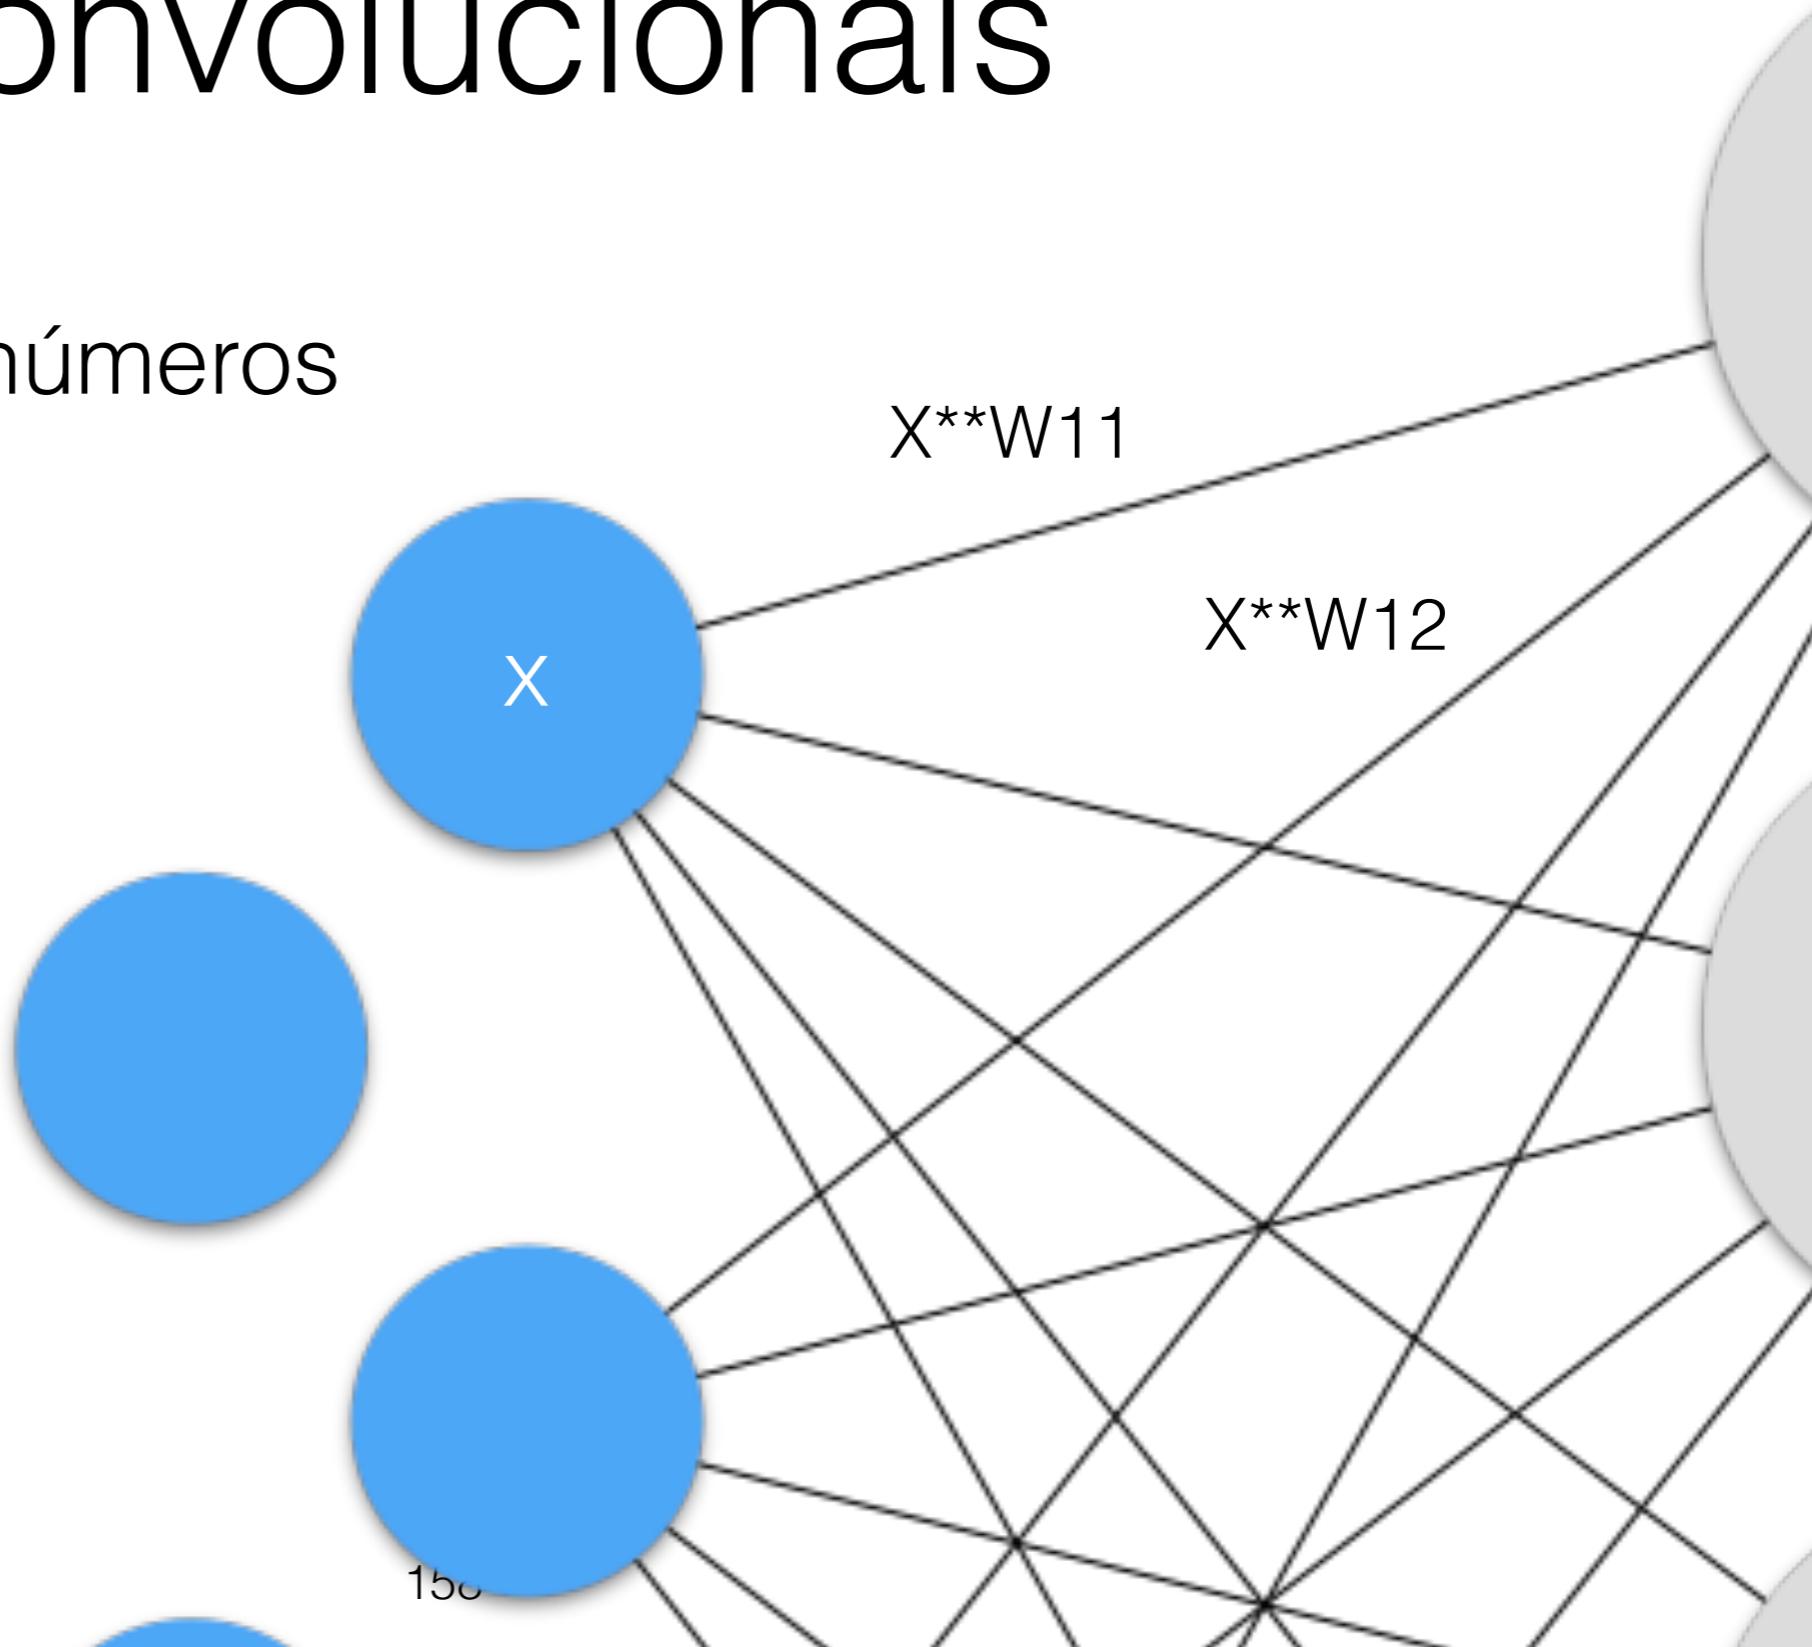


Redes Neurais Convolucionais



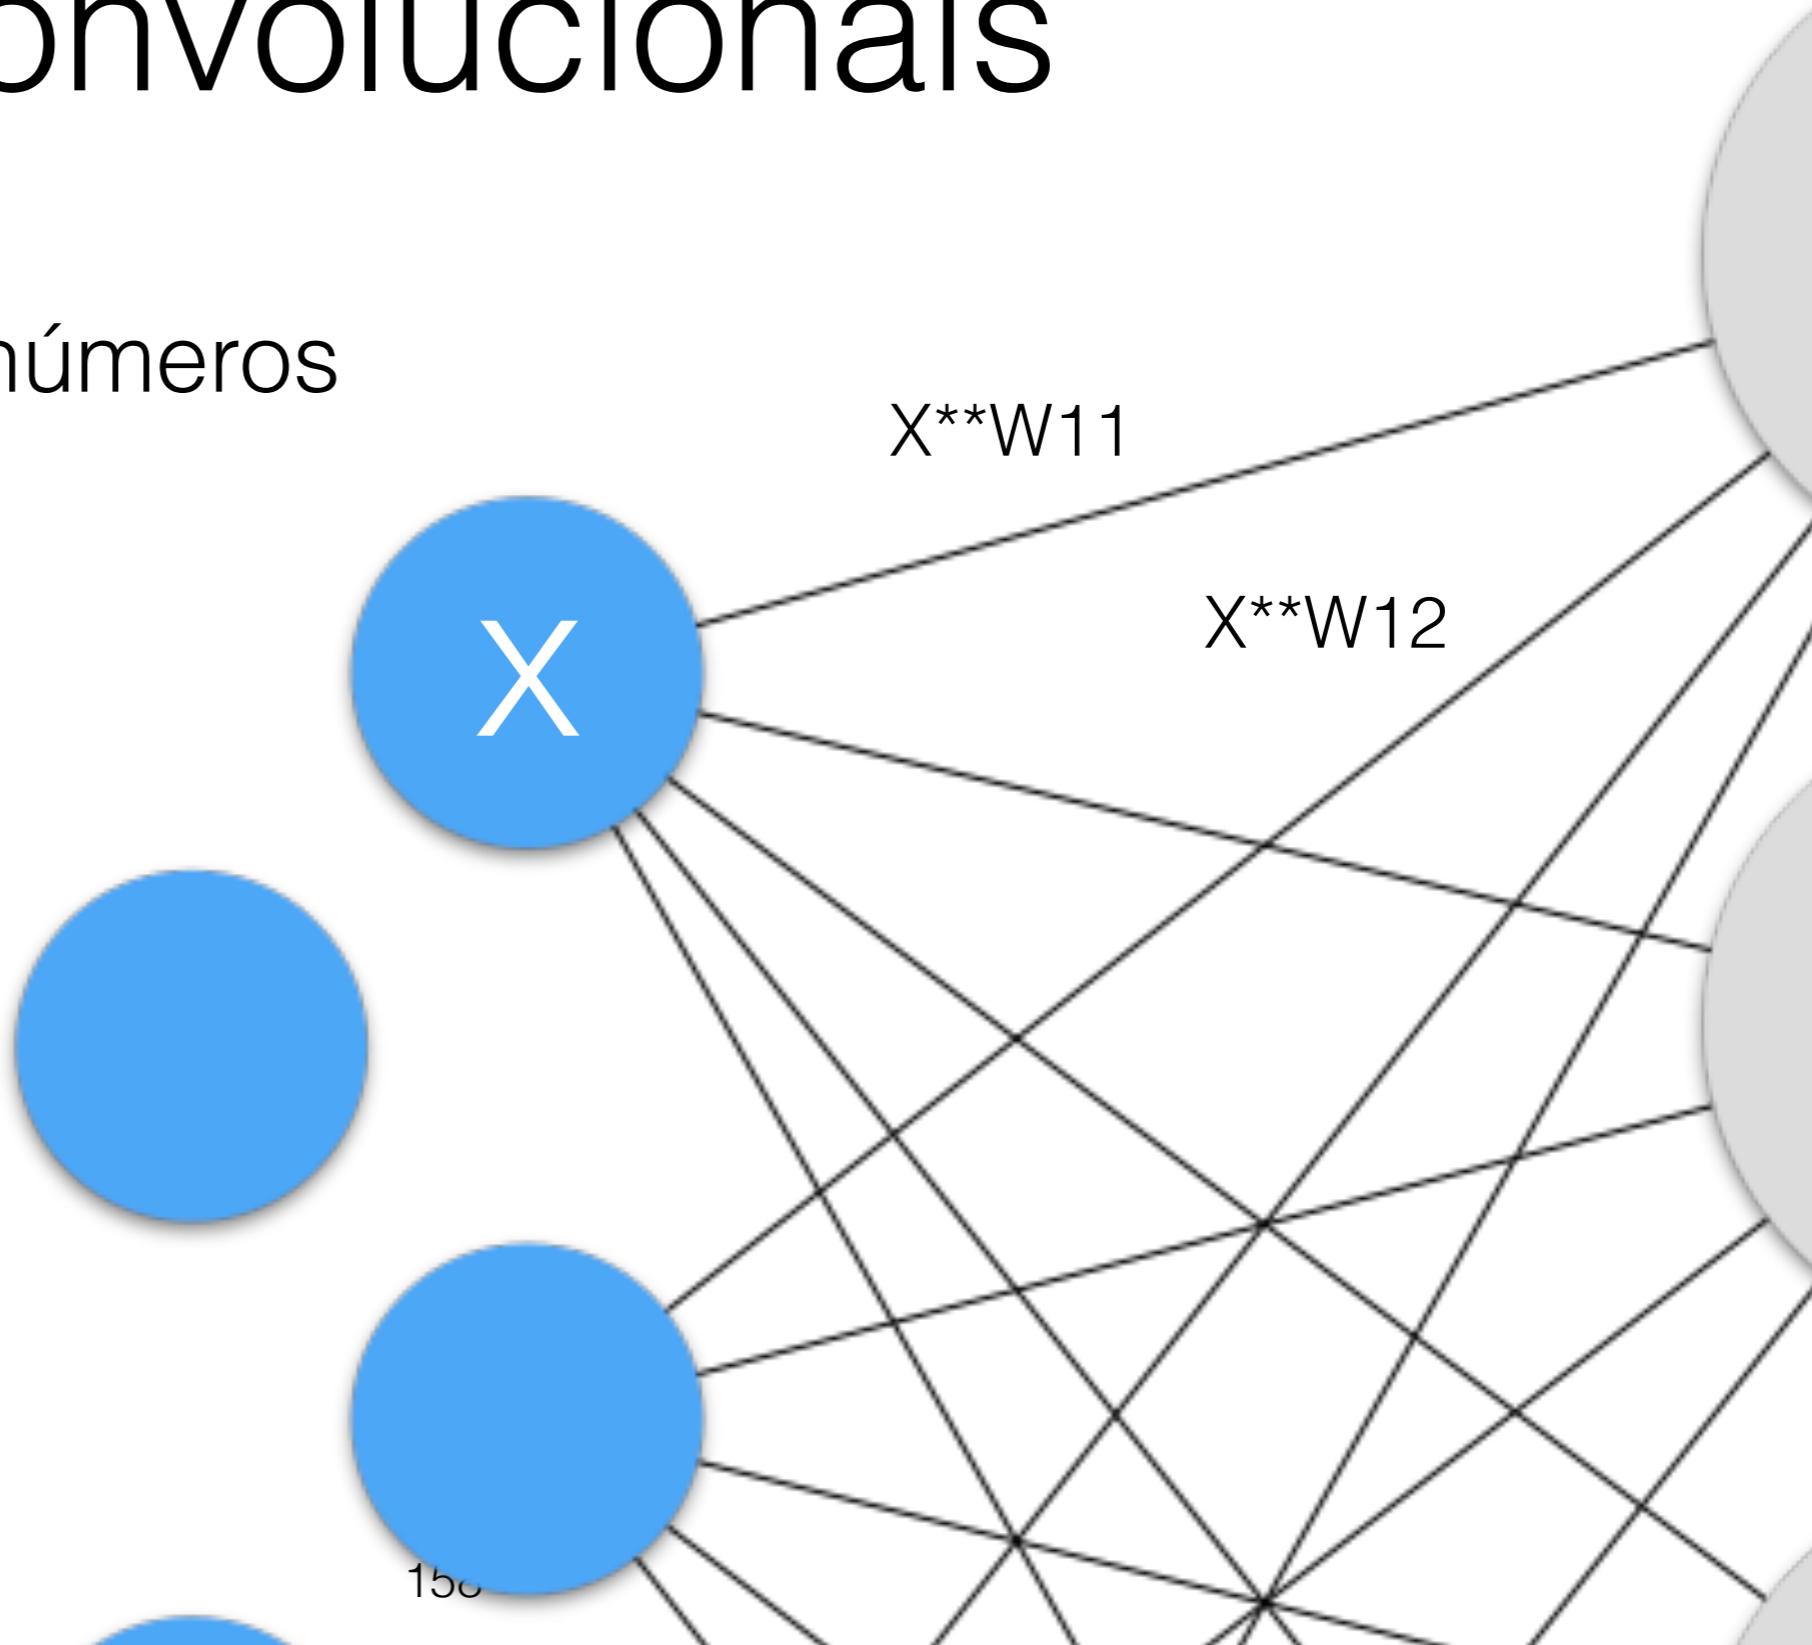
Redes Neurais Convolucionais

As entradas eram números



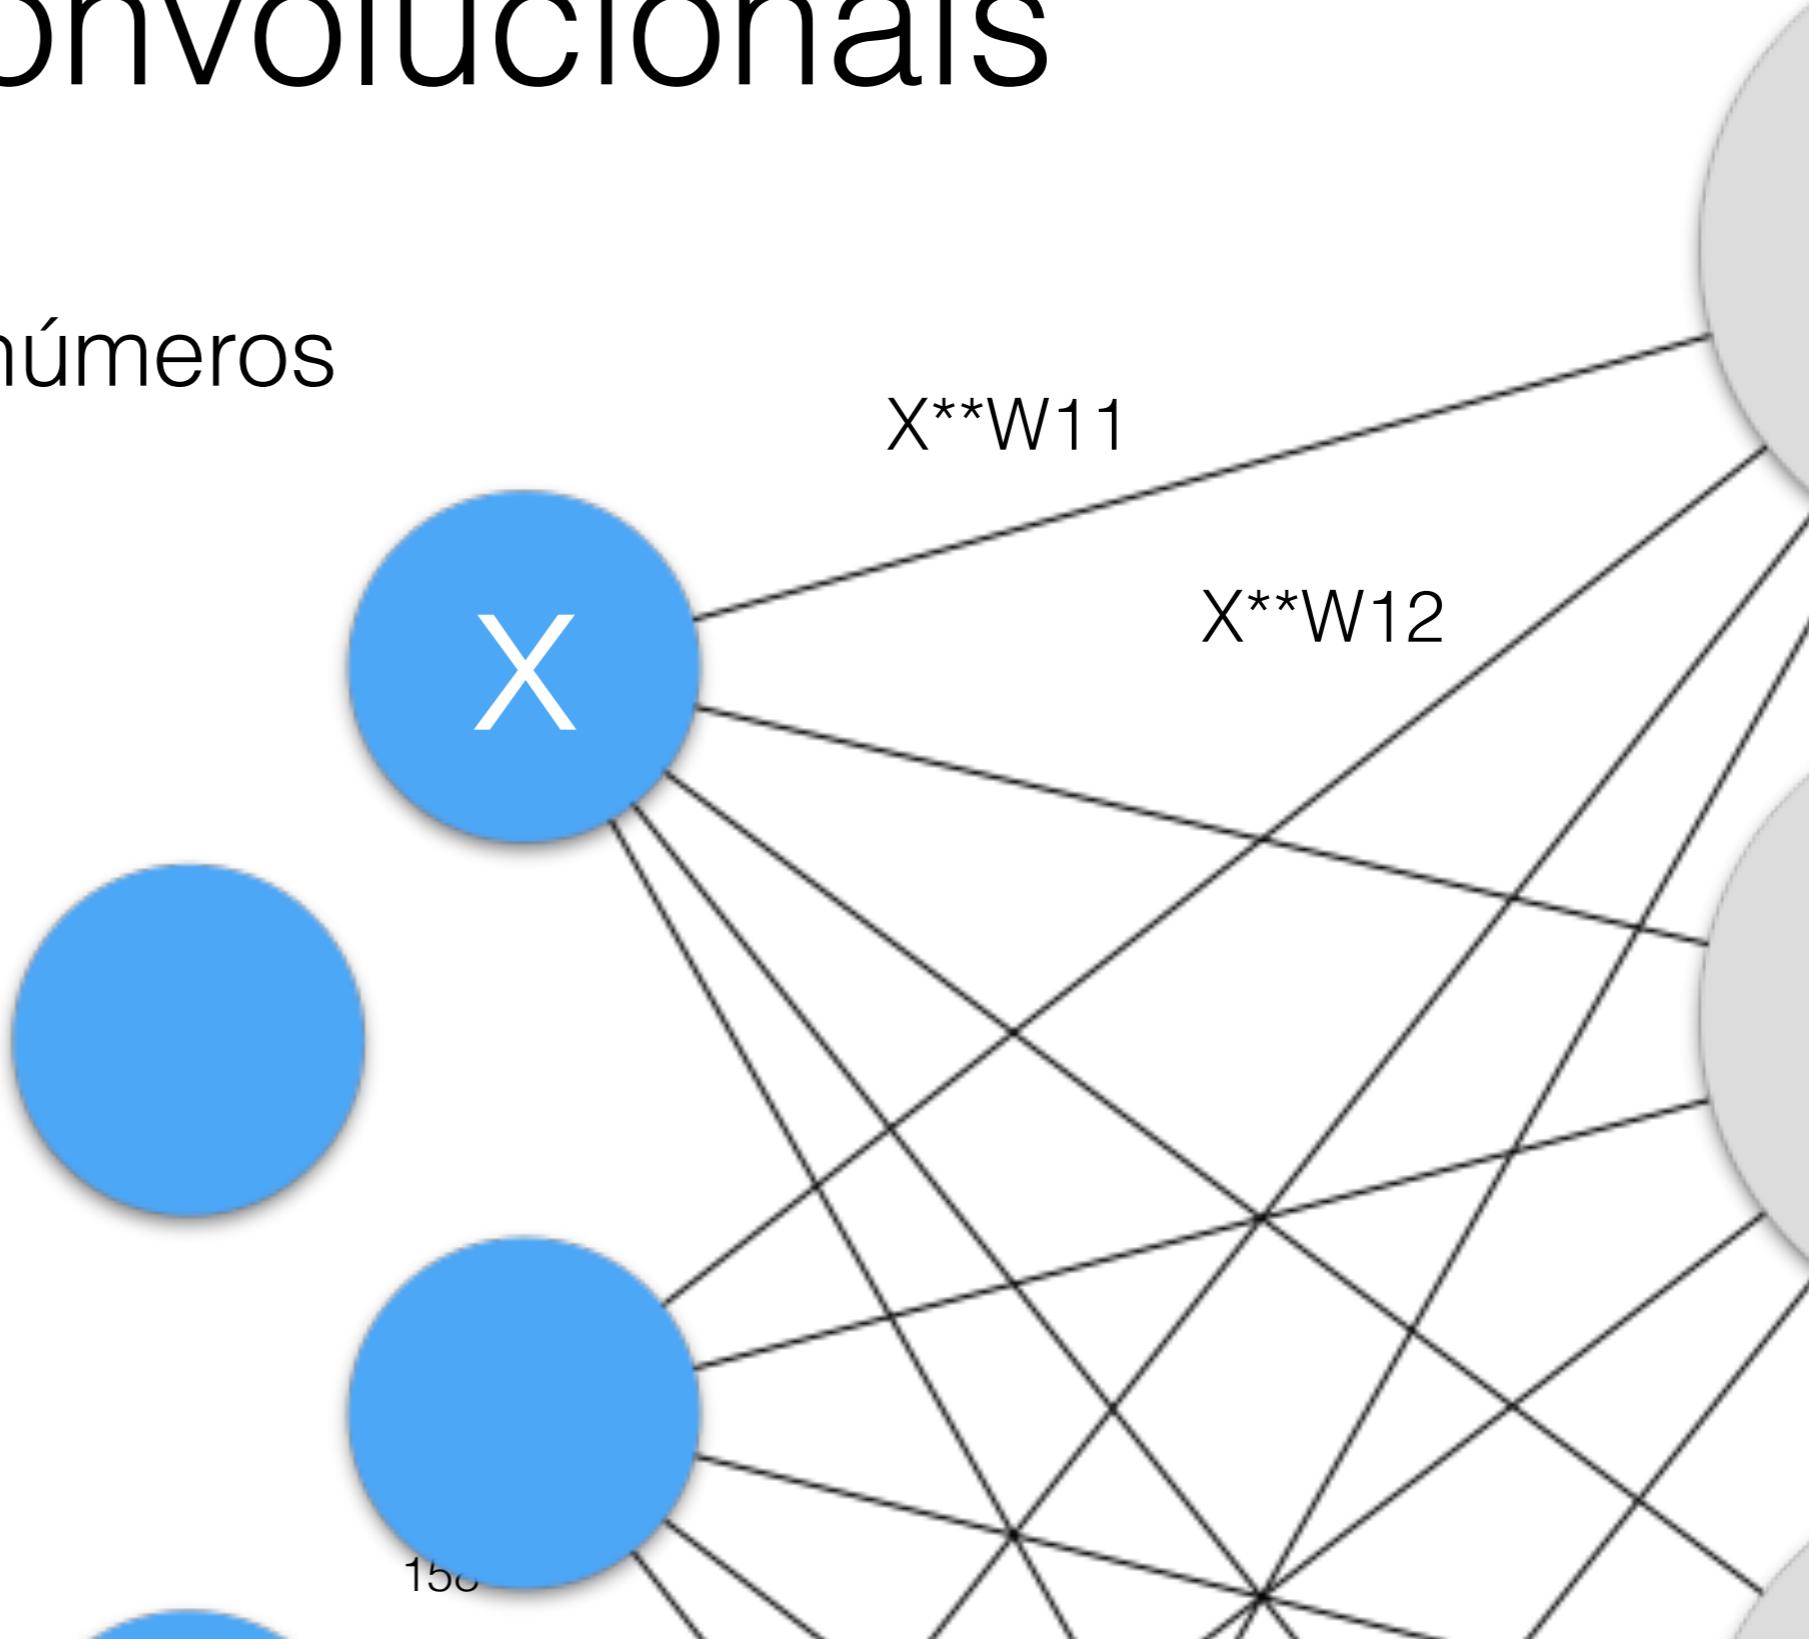
Redes Neurais Convolucionais

As entradas eram números

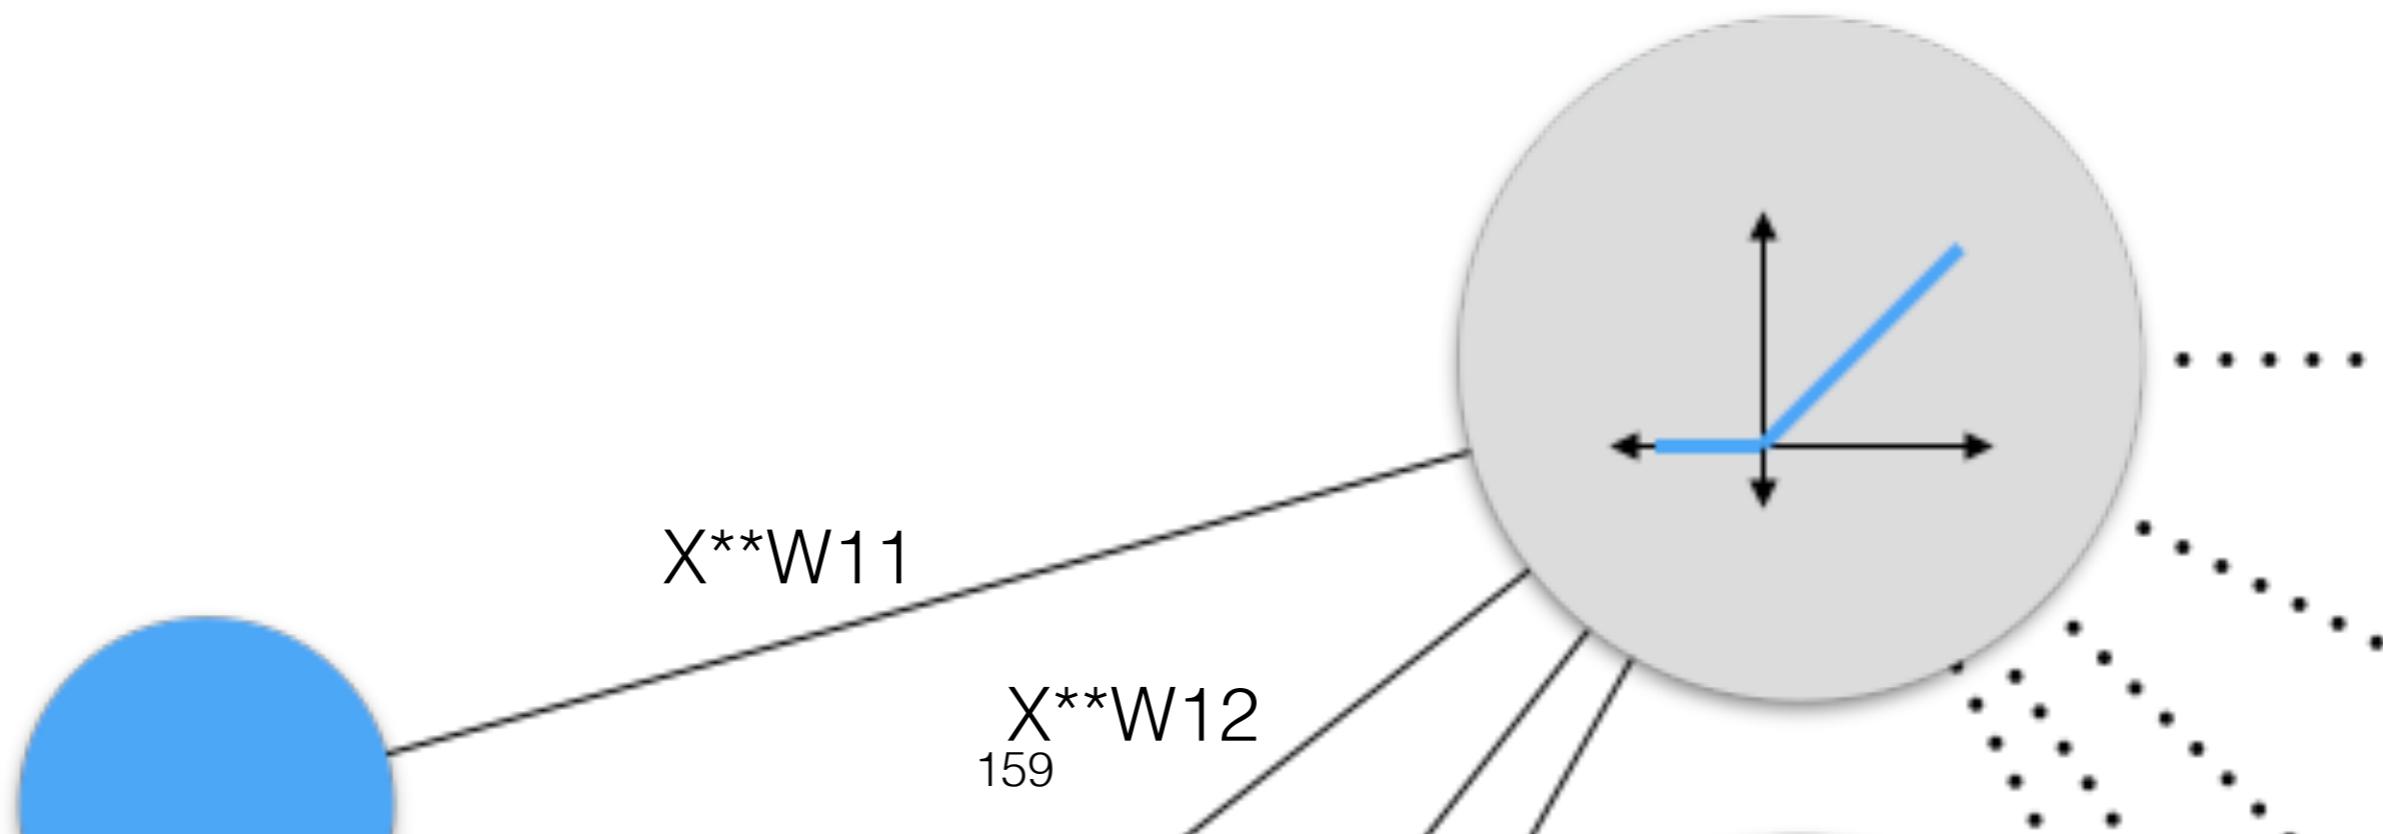


Redes Neurais Convolucionais

As entradas eram números
agora são matrizes



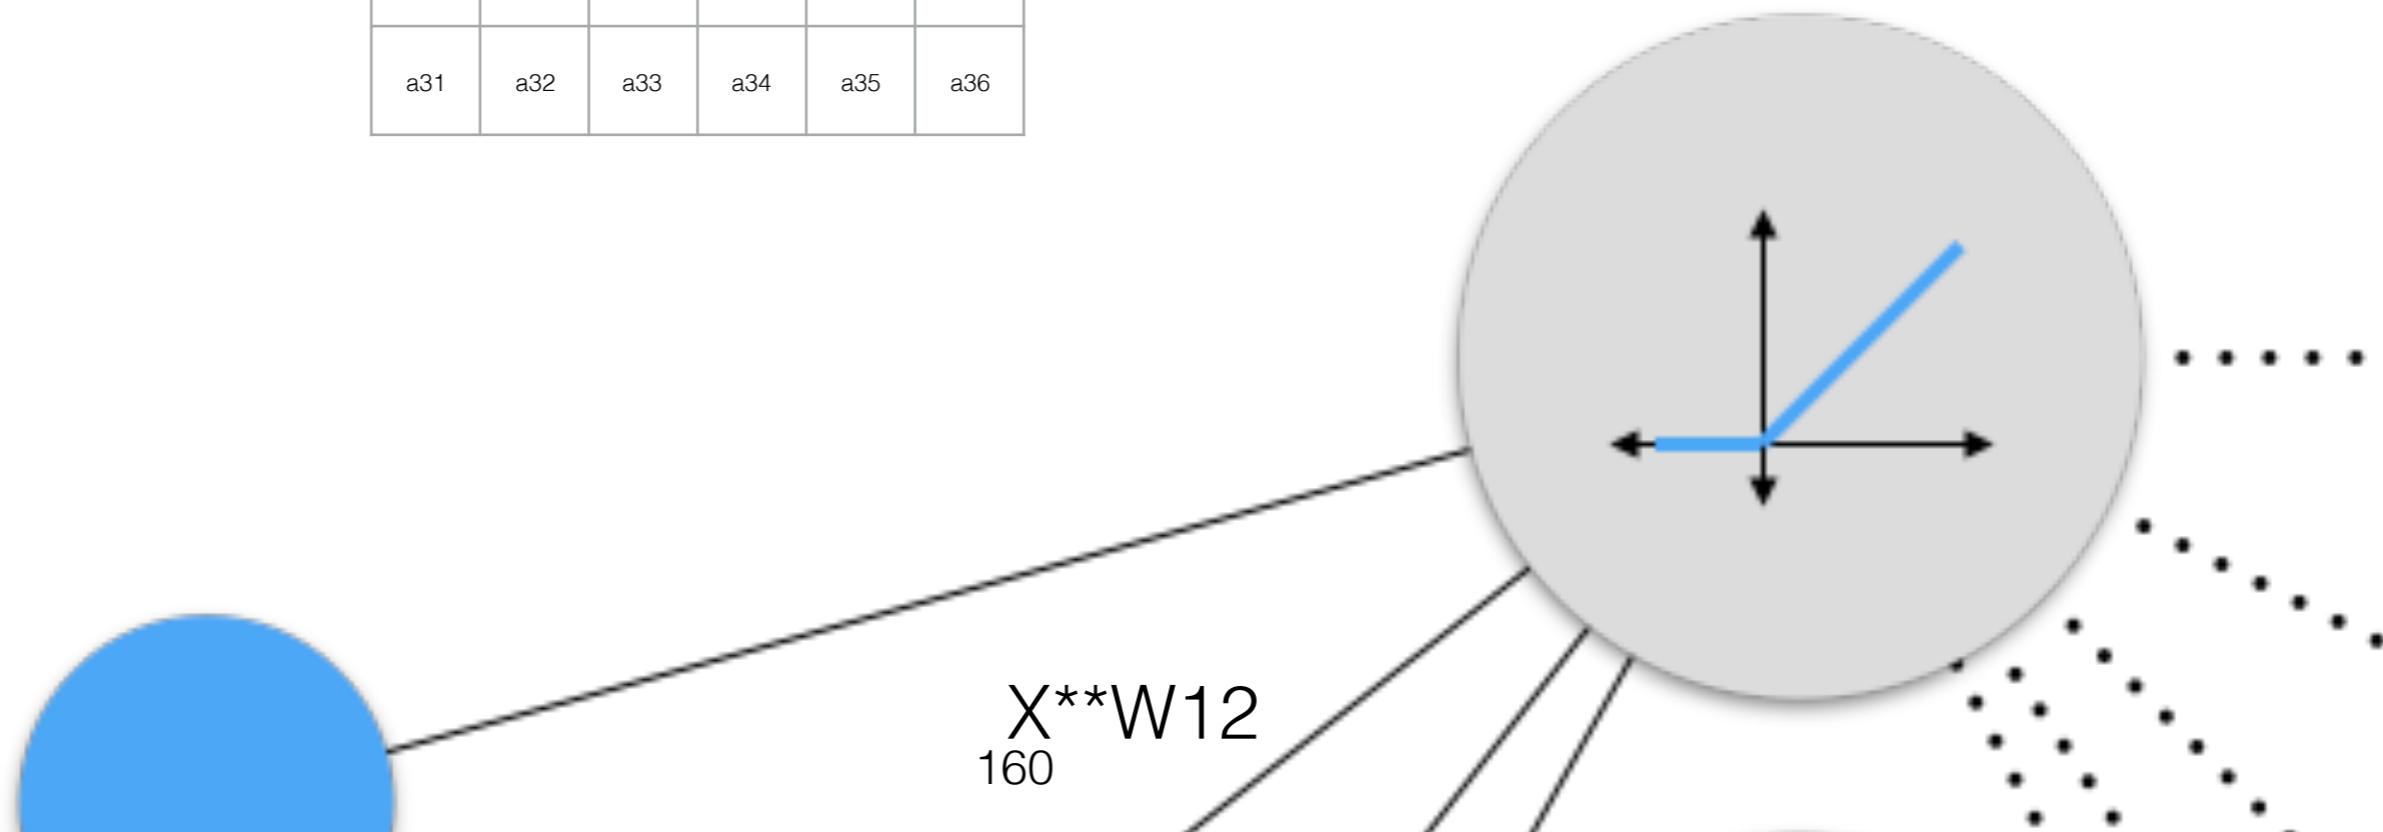
Redes Neurais Convolucionais



Redes Neurais Convolucionais

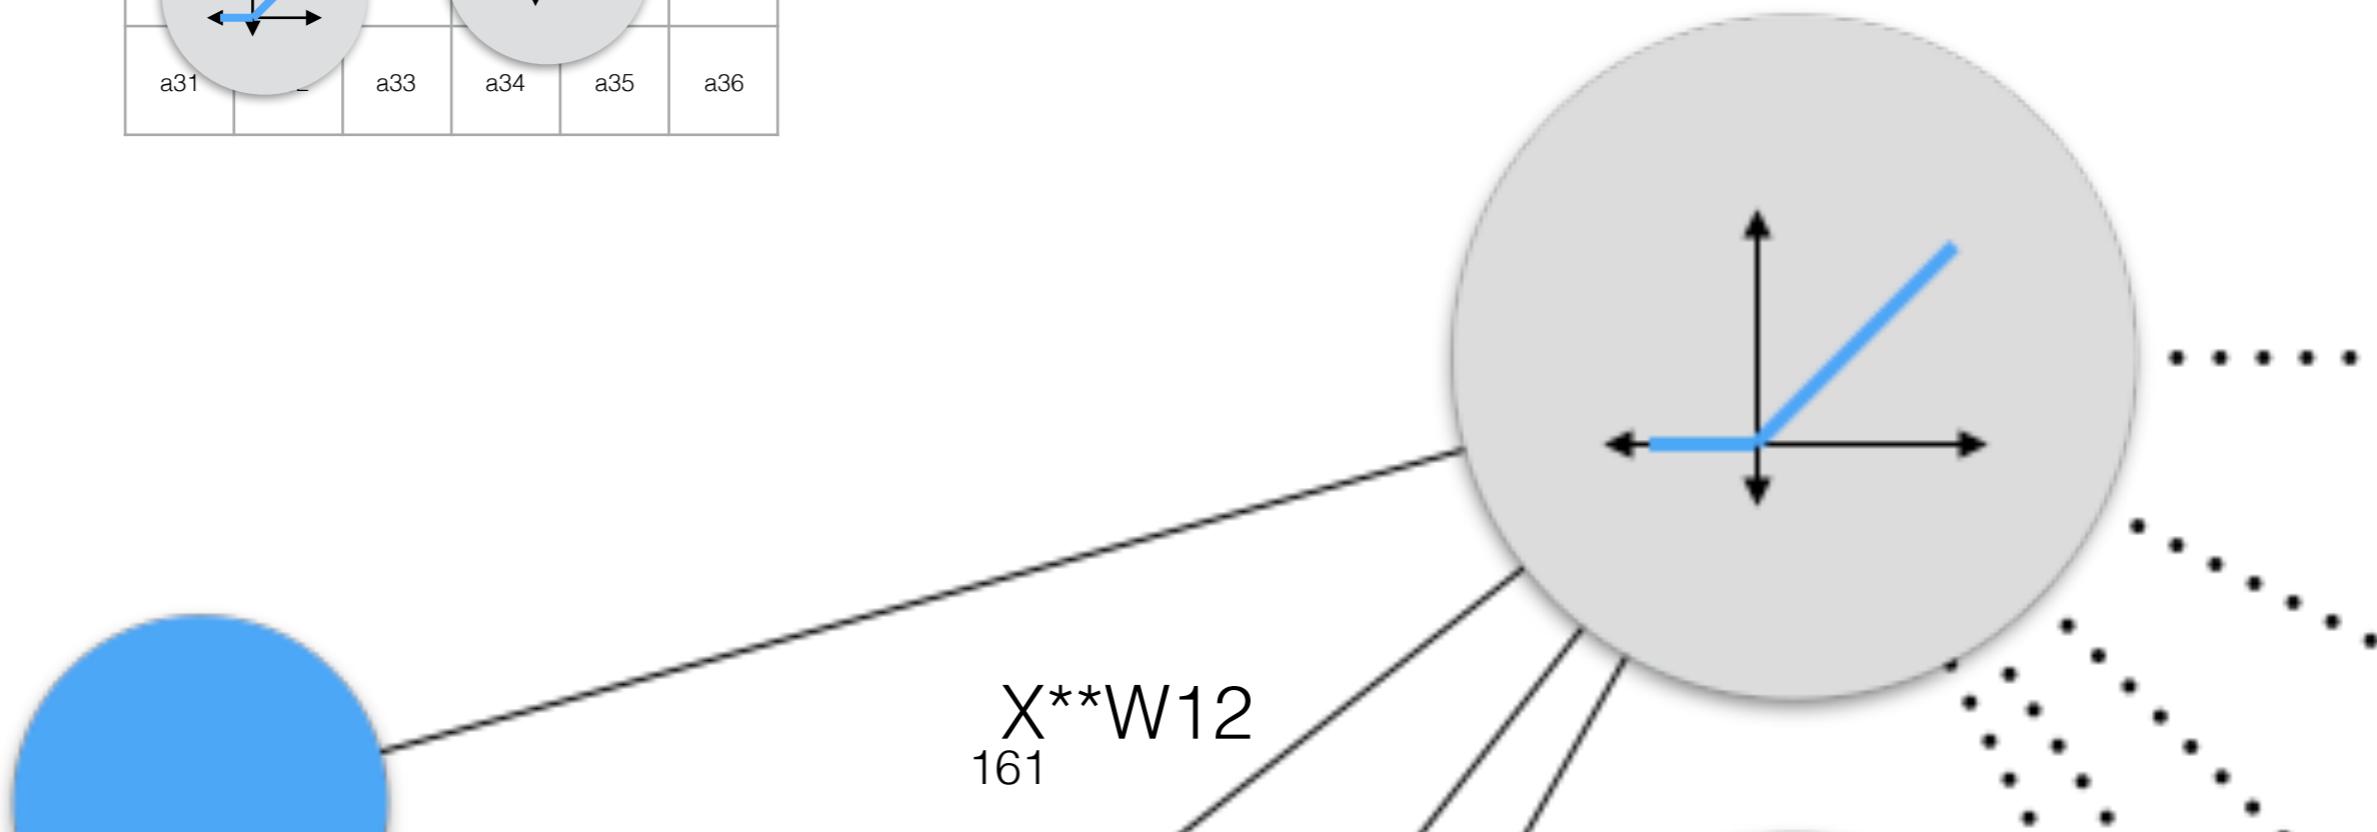
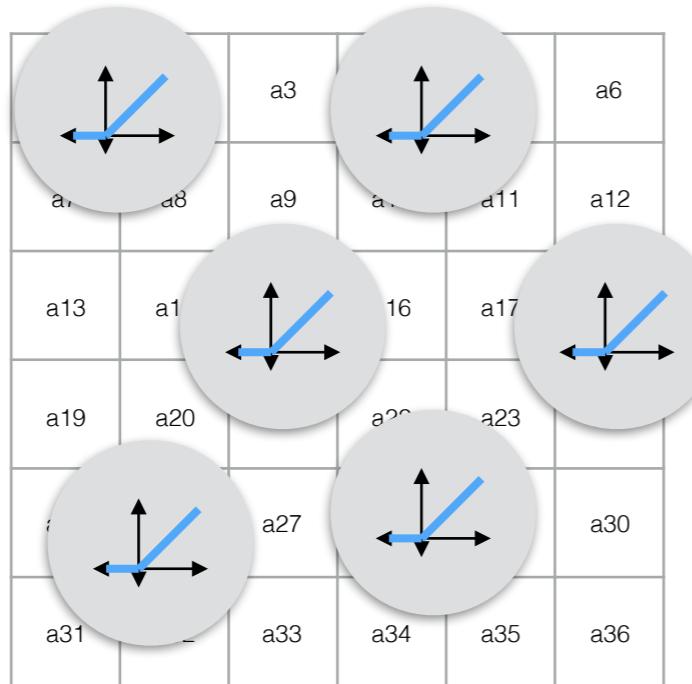
$X^{**}W11 =$

a1	a2	a3	a4	a5	a6
a7	a8	a9	a10	a11	a12
a13	a14	a15	a16	a17	a18
a19	a20	a21	a22	a23	a24
a25	a26	a27	a28	a29	a30
a31	a32	a33	a34	a35	a36



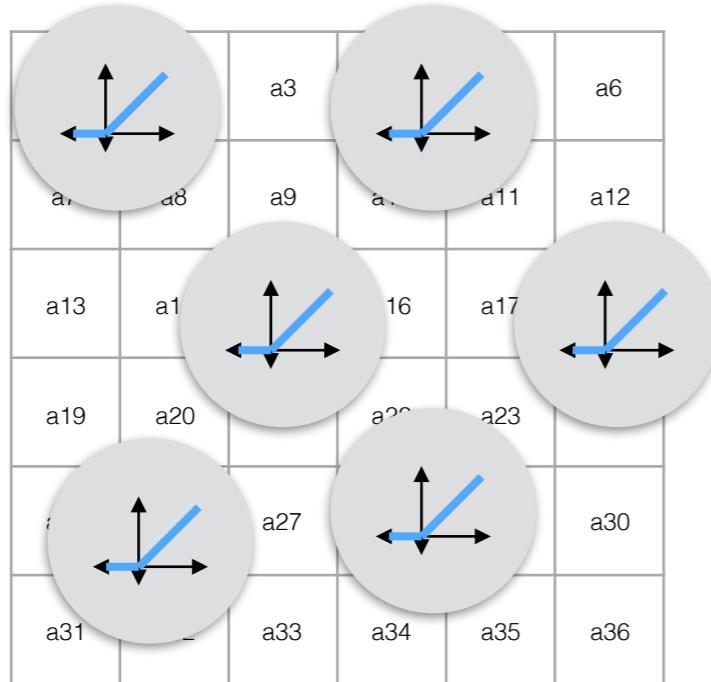
Redes Neurais Convolucionais

$X^{**}W11 =$



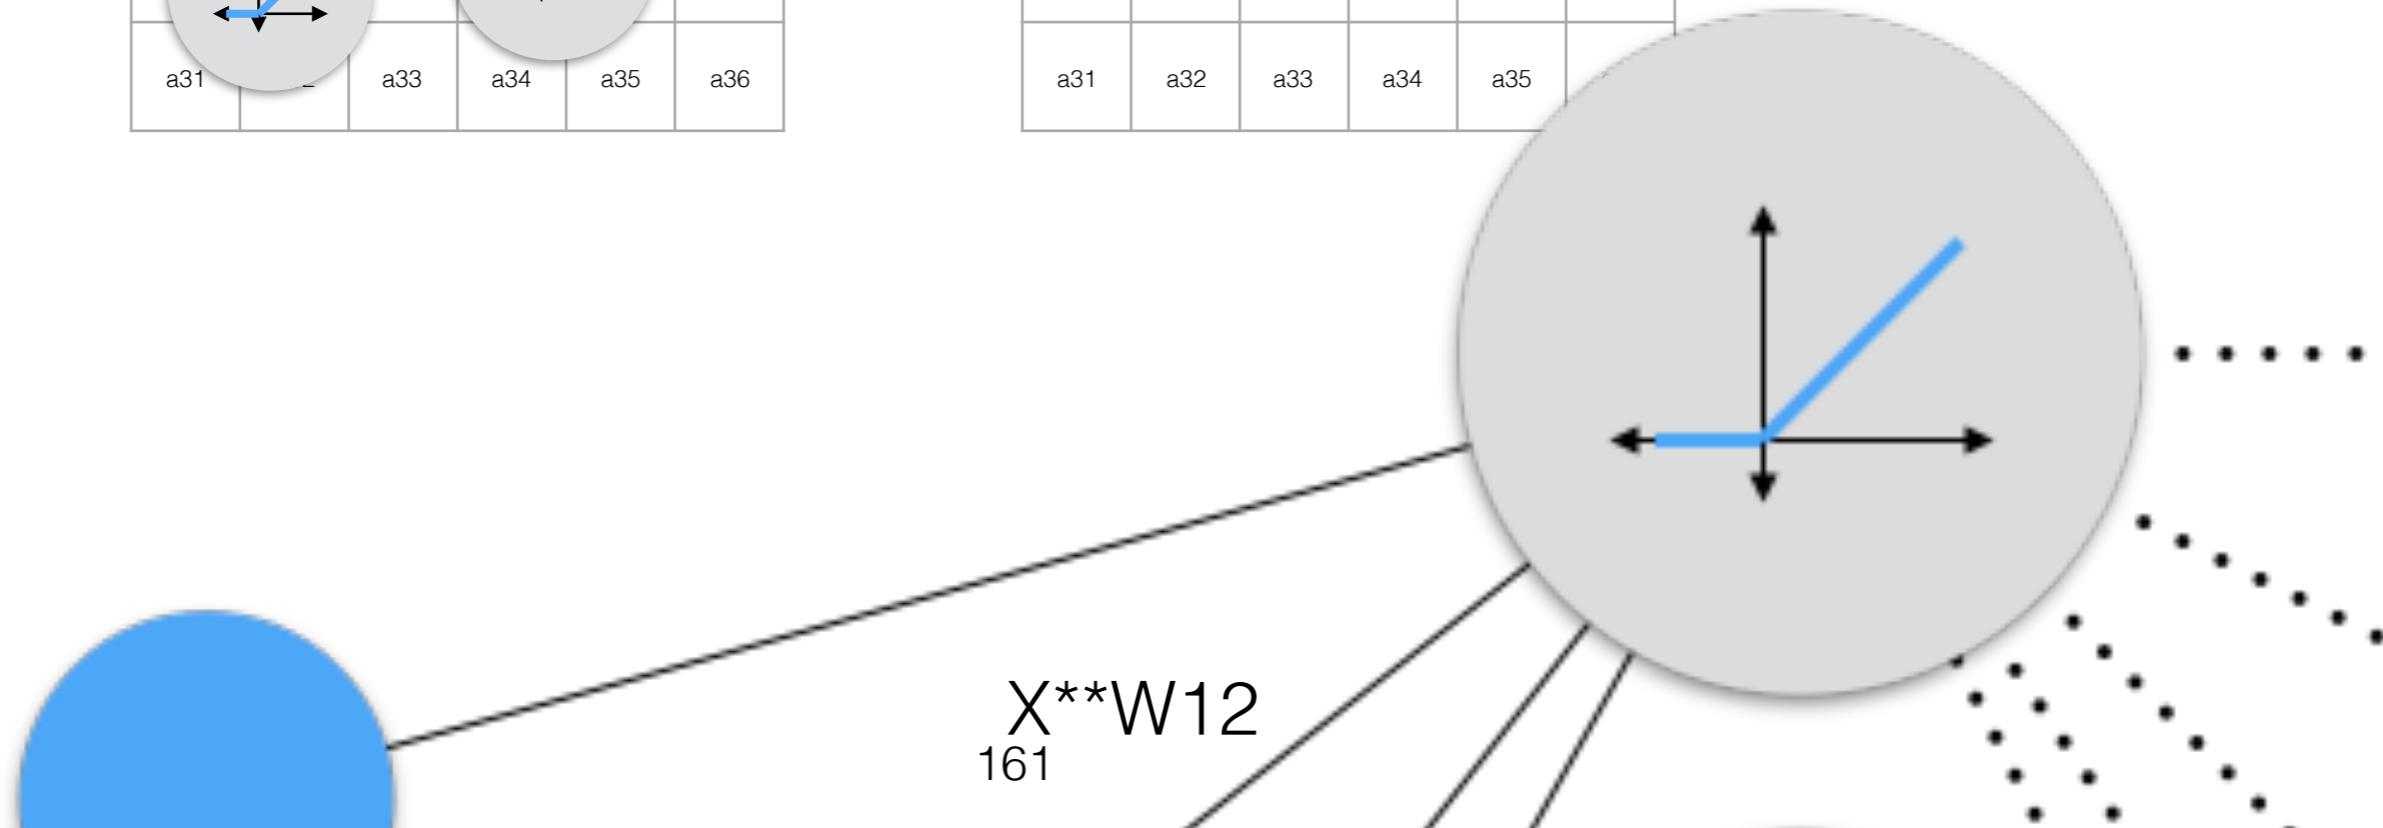
Redes Neurais Convolucionais

$X^{**}W11 =$

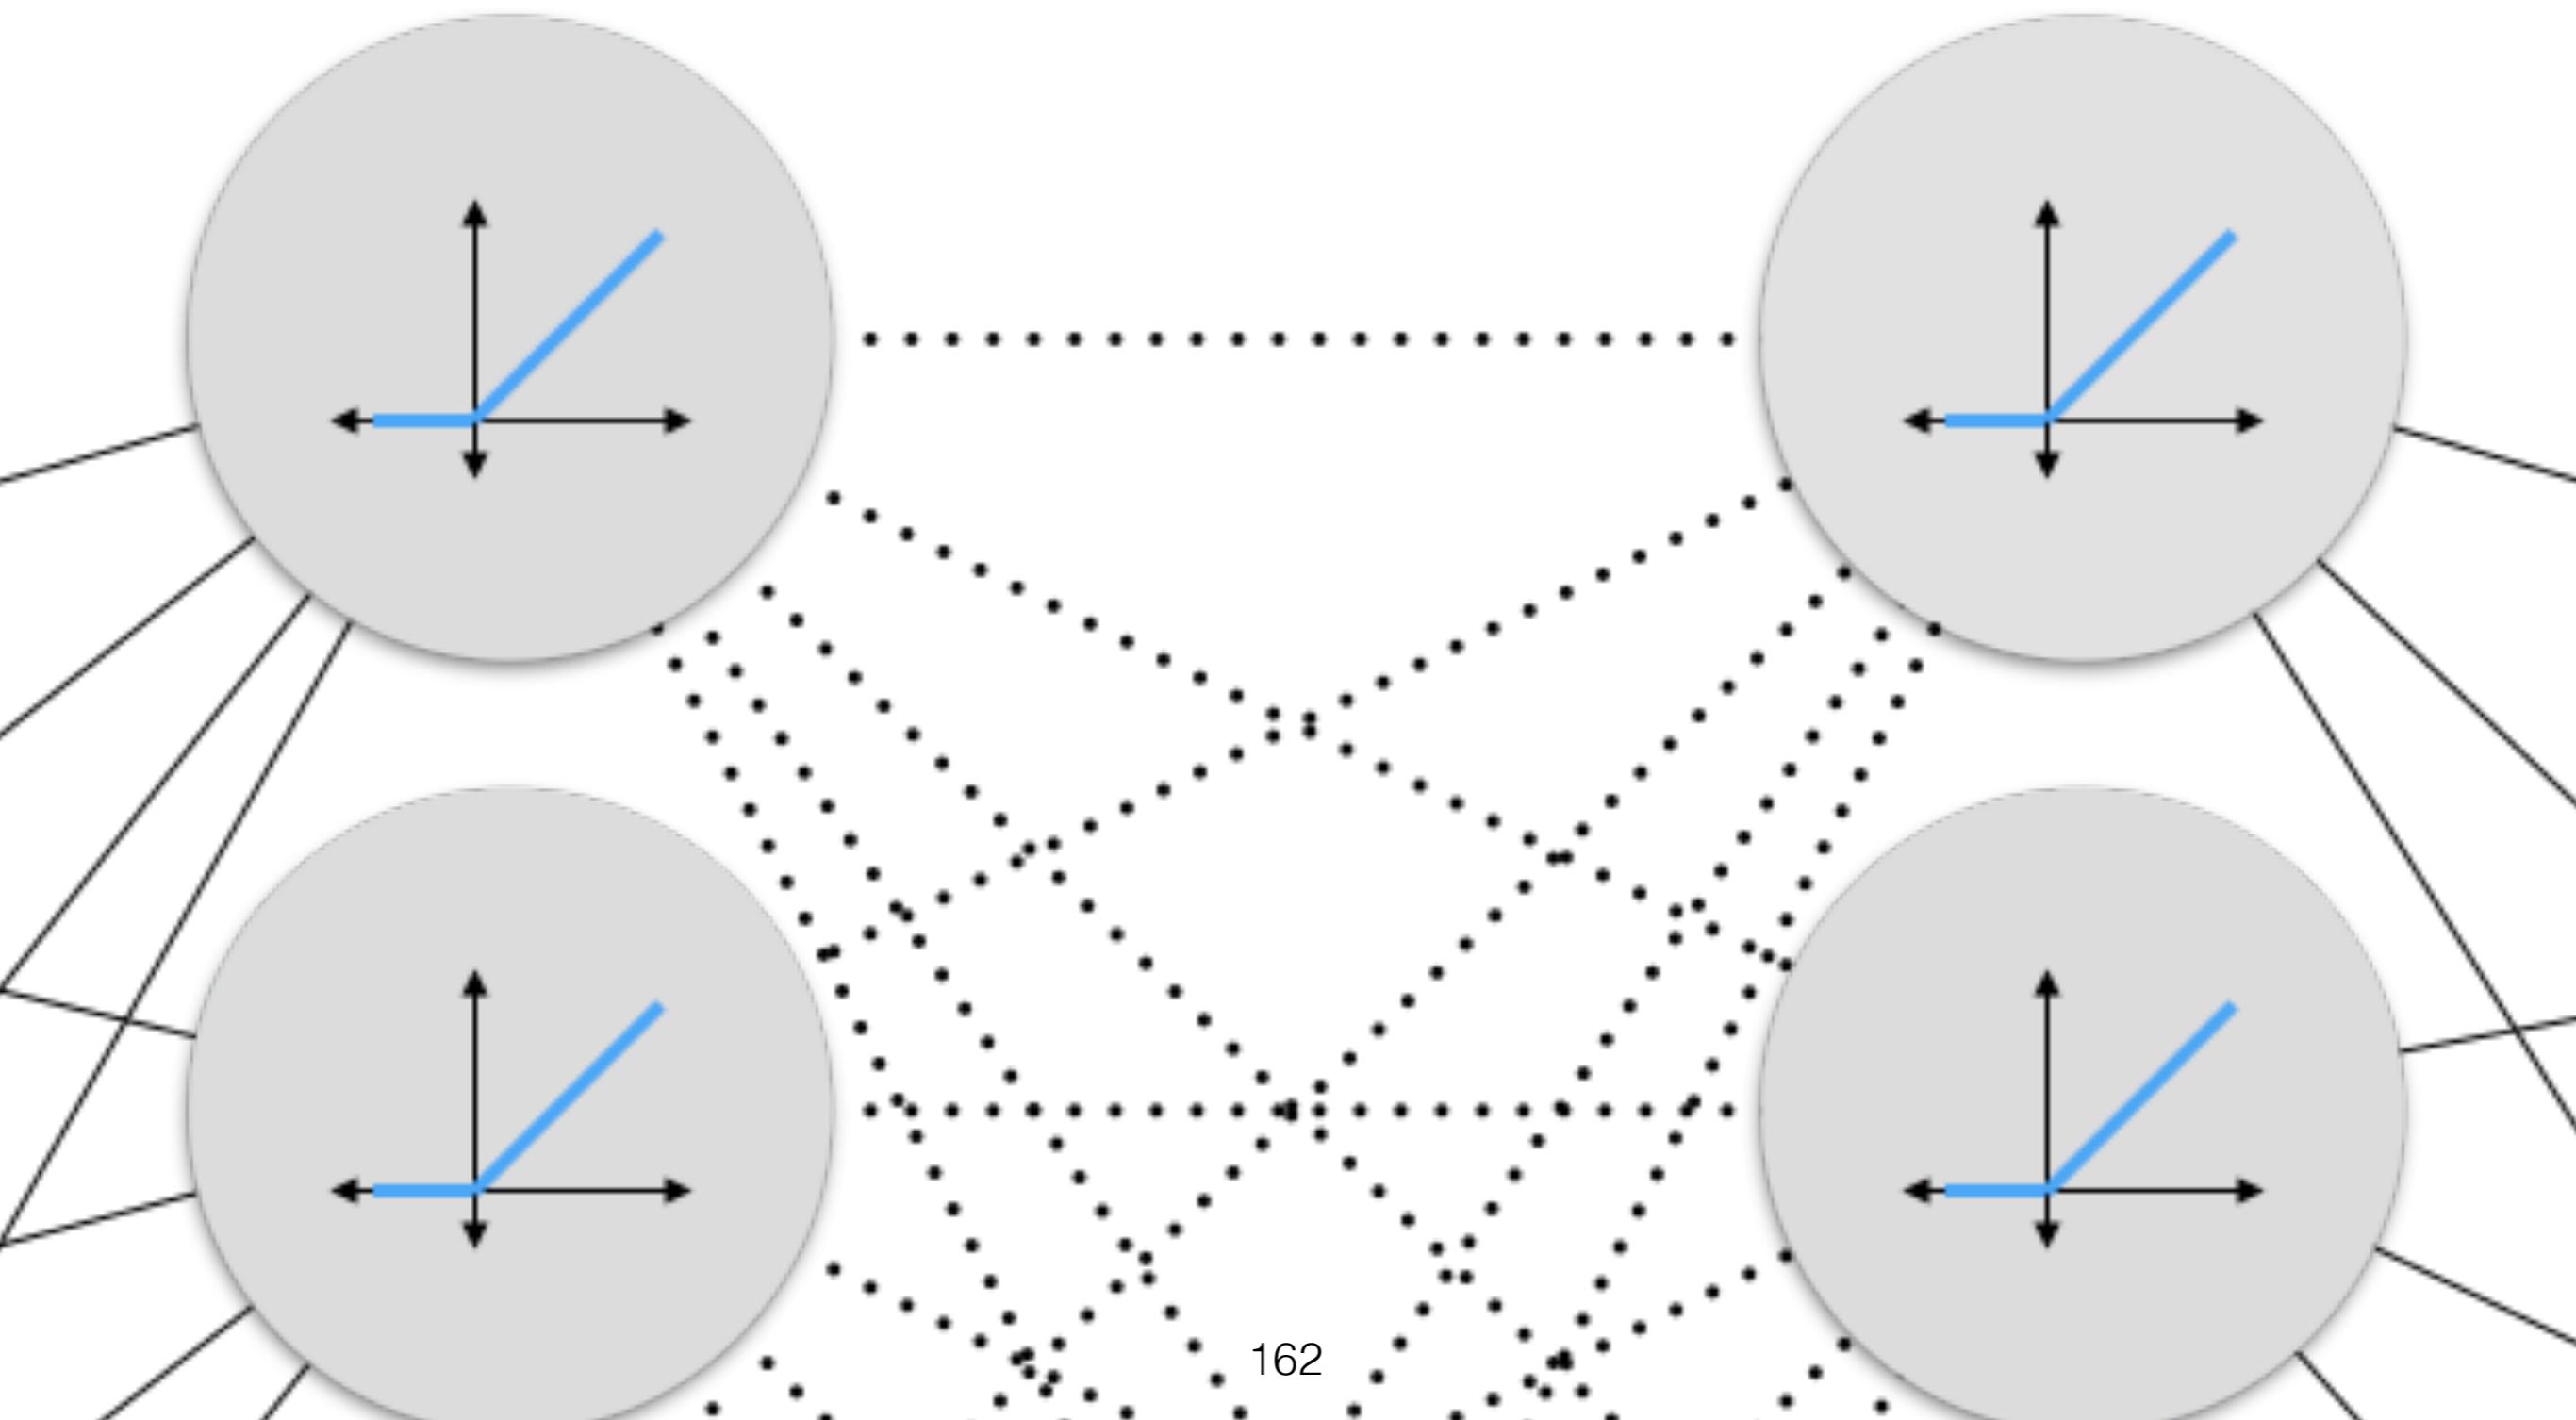


=

a1	a2	a3	a4	a5	a6
a7	a8	a9	a10	a11	a12
a13	a14	a15	a16	a17	a18
a19	a20	a21	a22	a23	a24
a25	a26	a27	a28	a29	a30
a31	a32	a33	a34	a35	a36

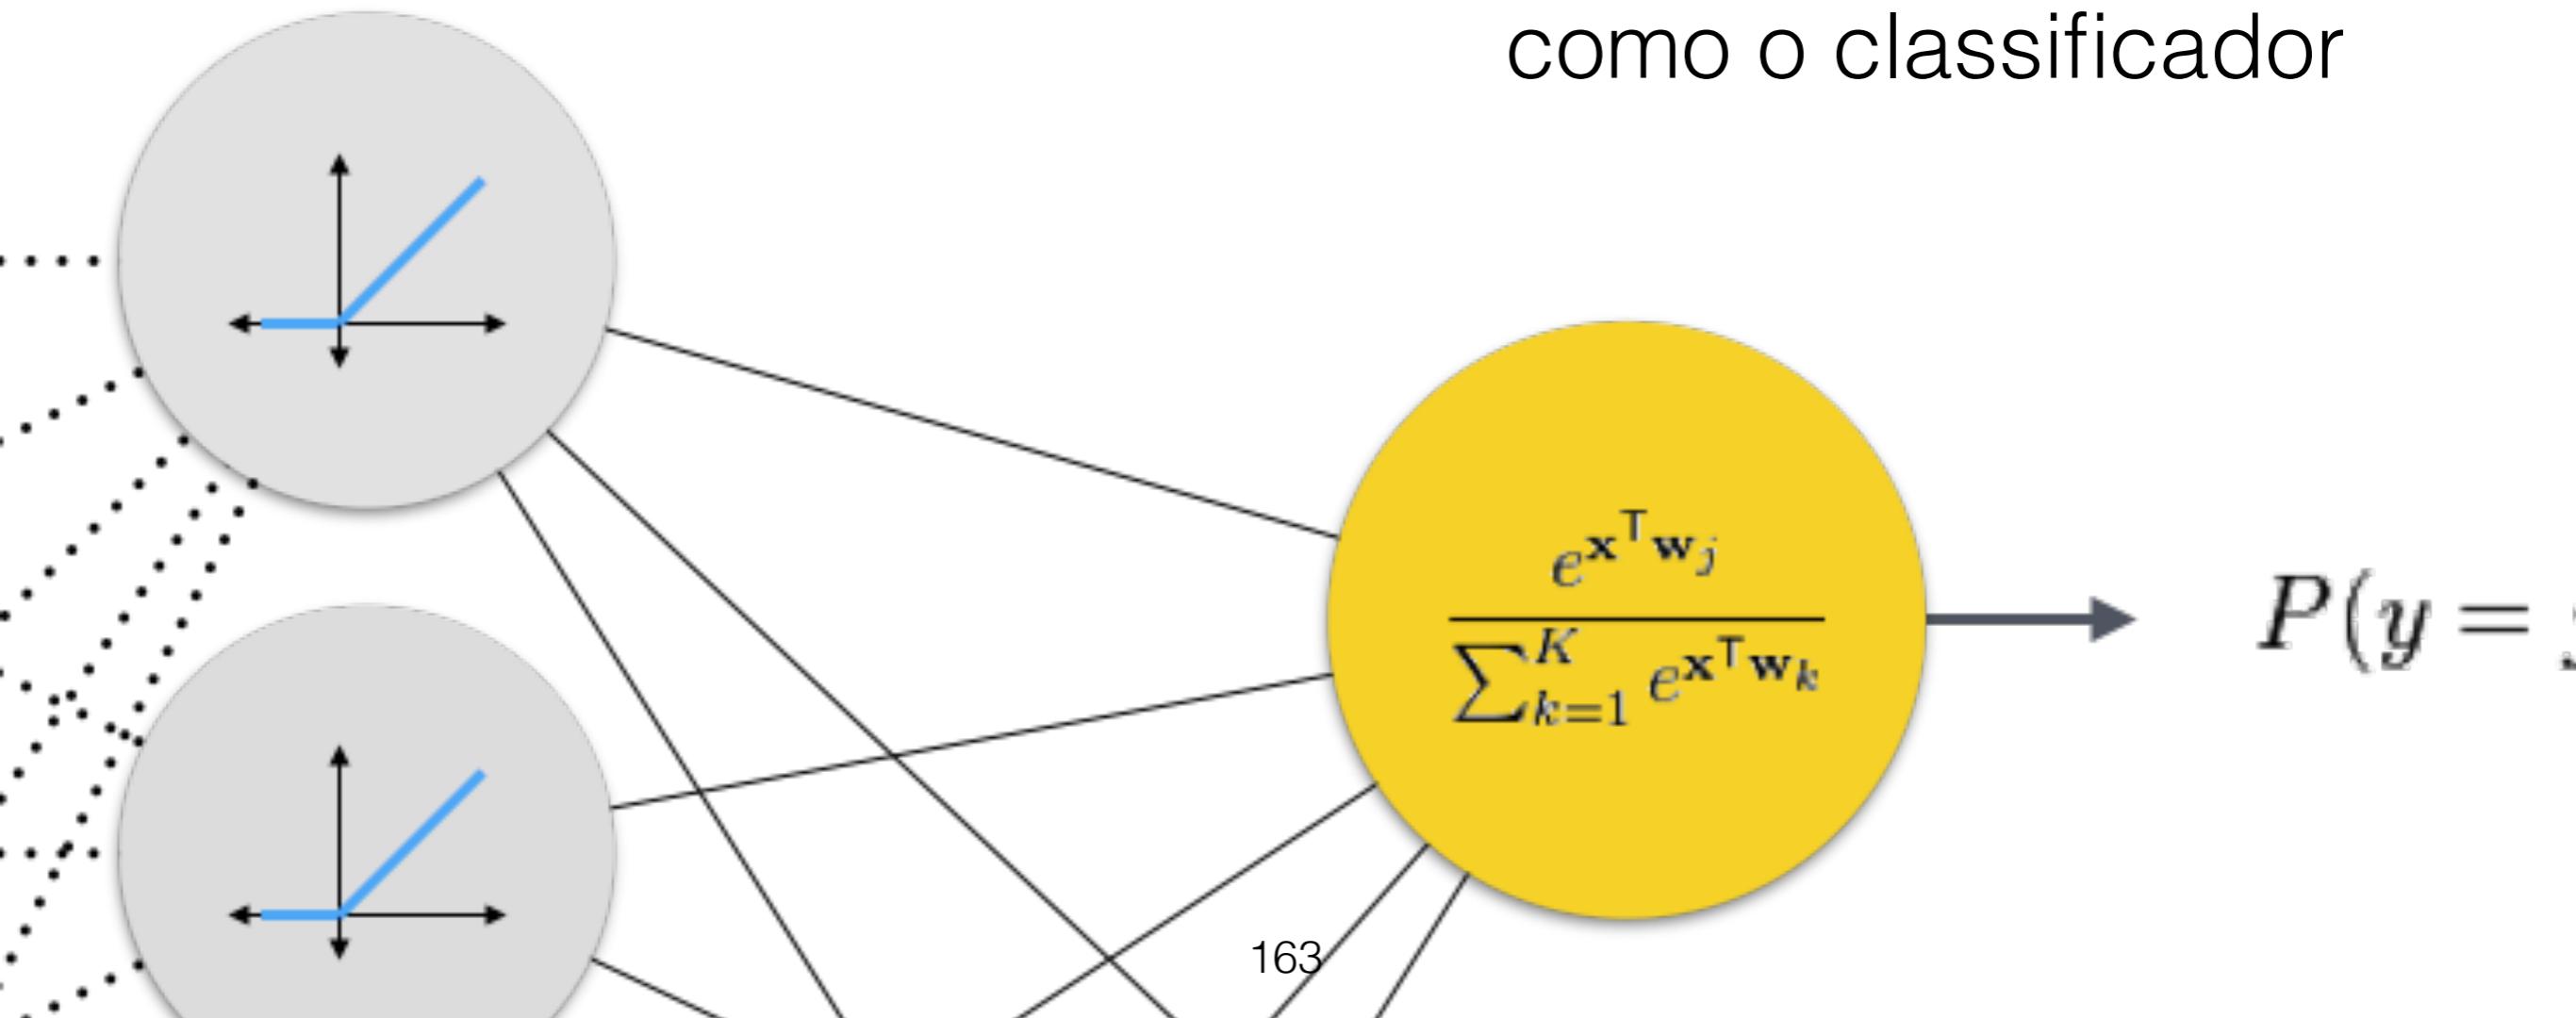


Redes Neurais Convolucionais



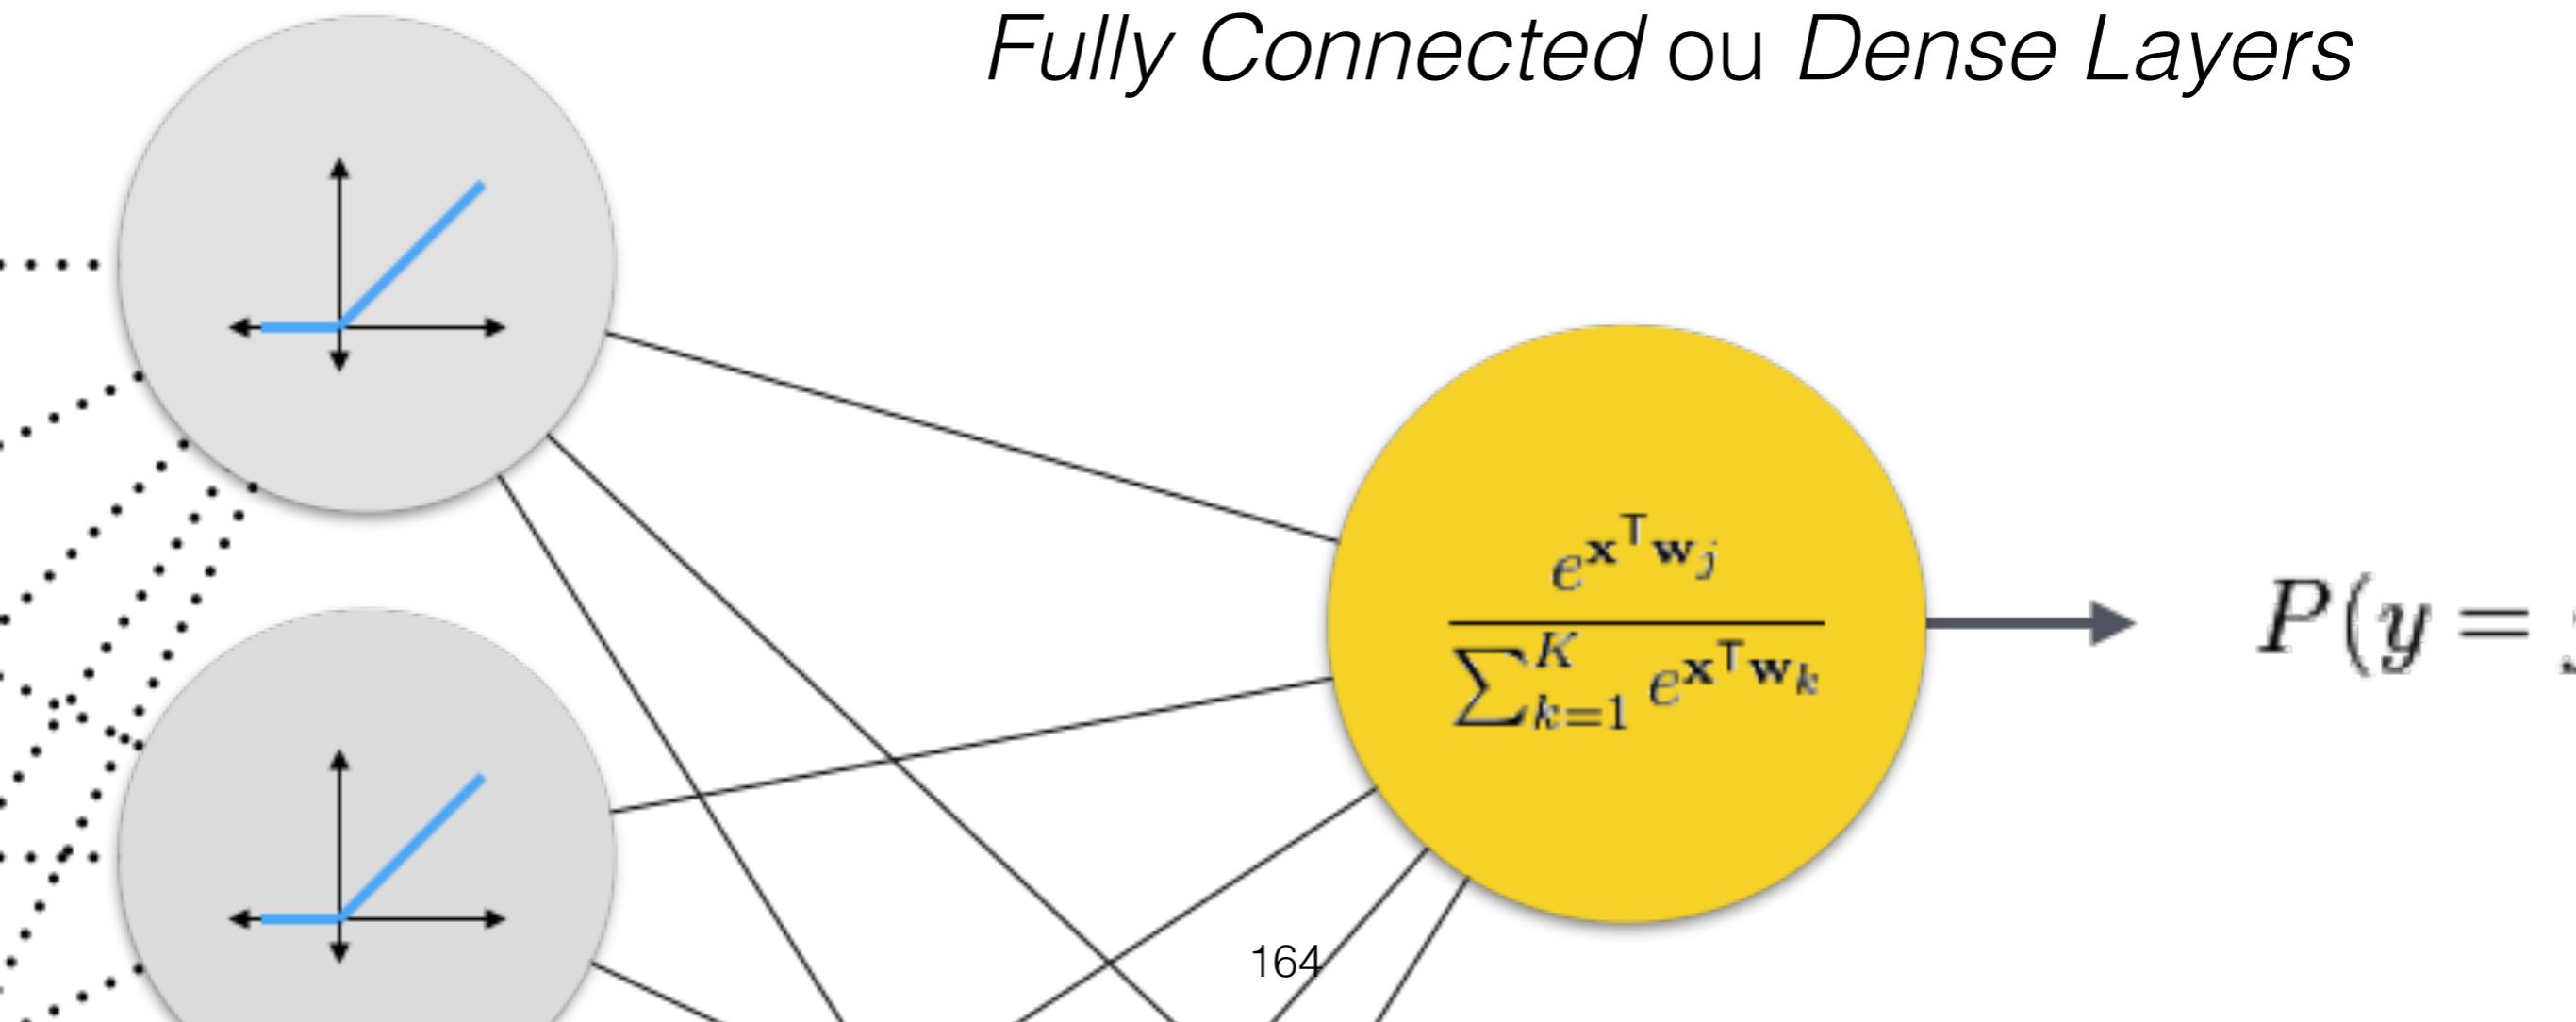
Redes Neurais Convolucionais

normalmente mantem-se uma rede neural comum na(s) últimas camadas agindo como o classificador

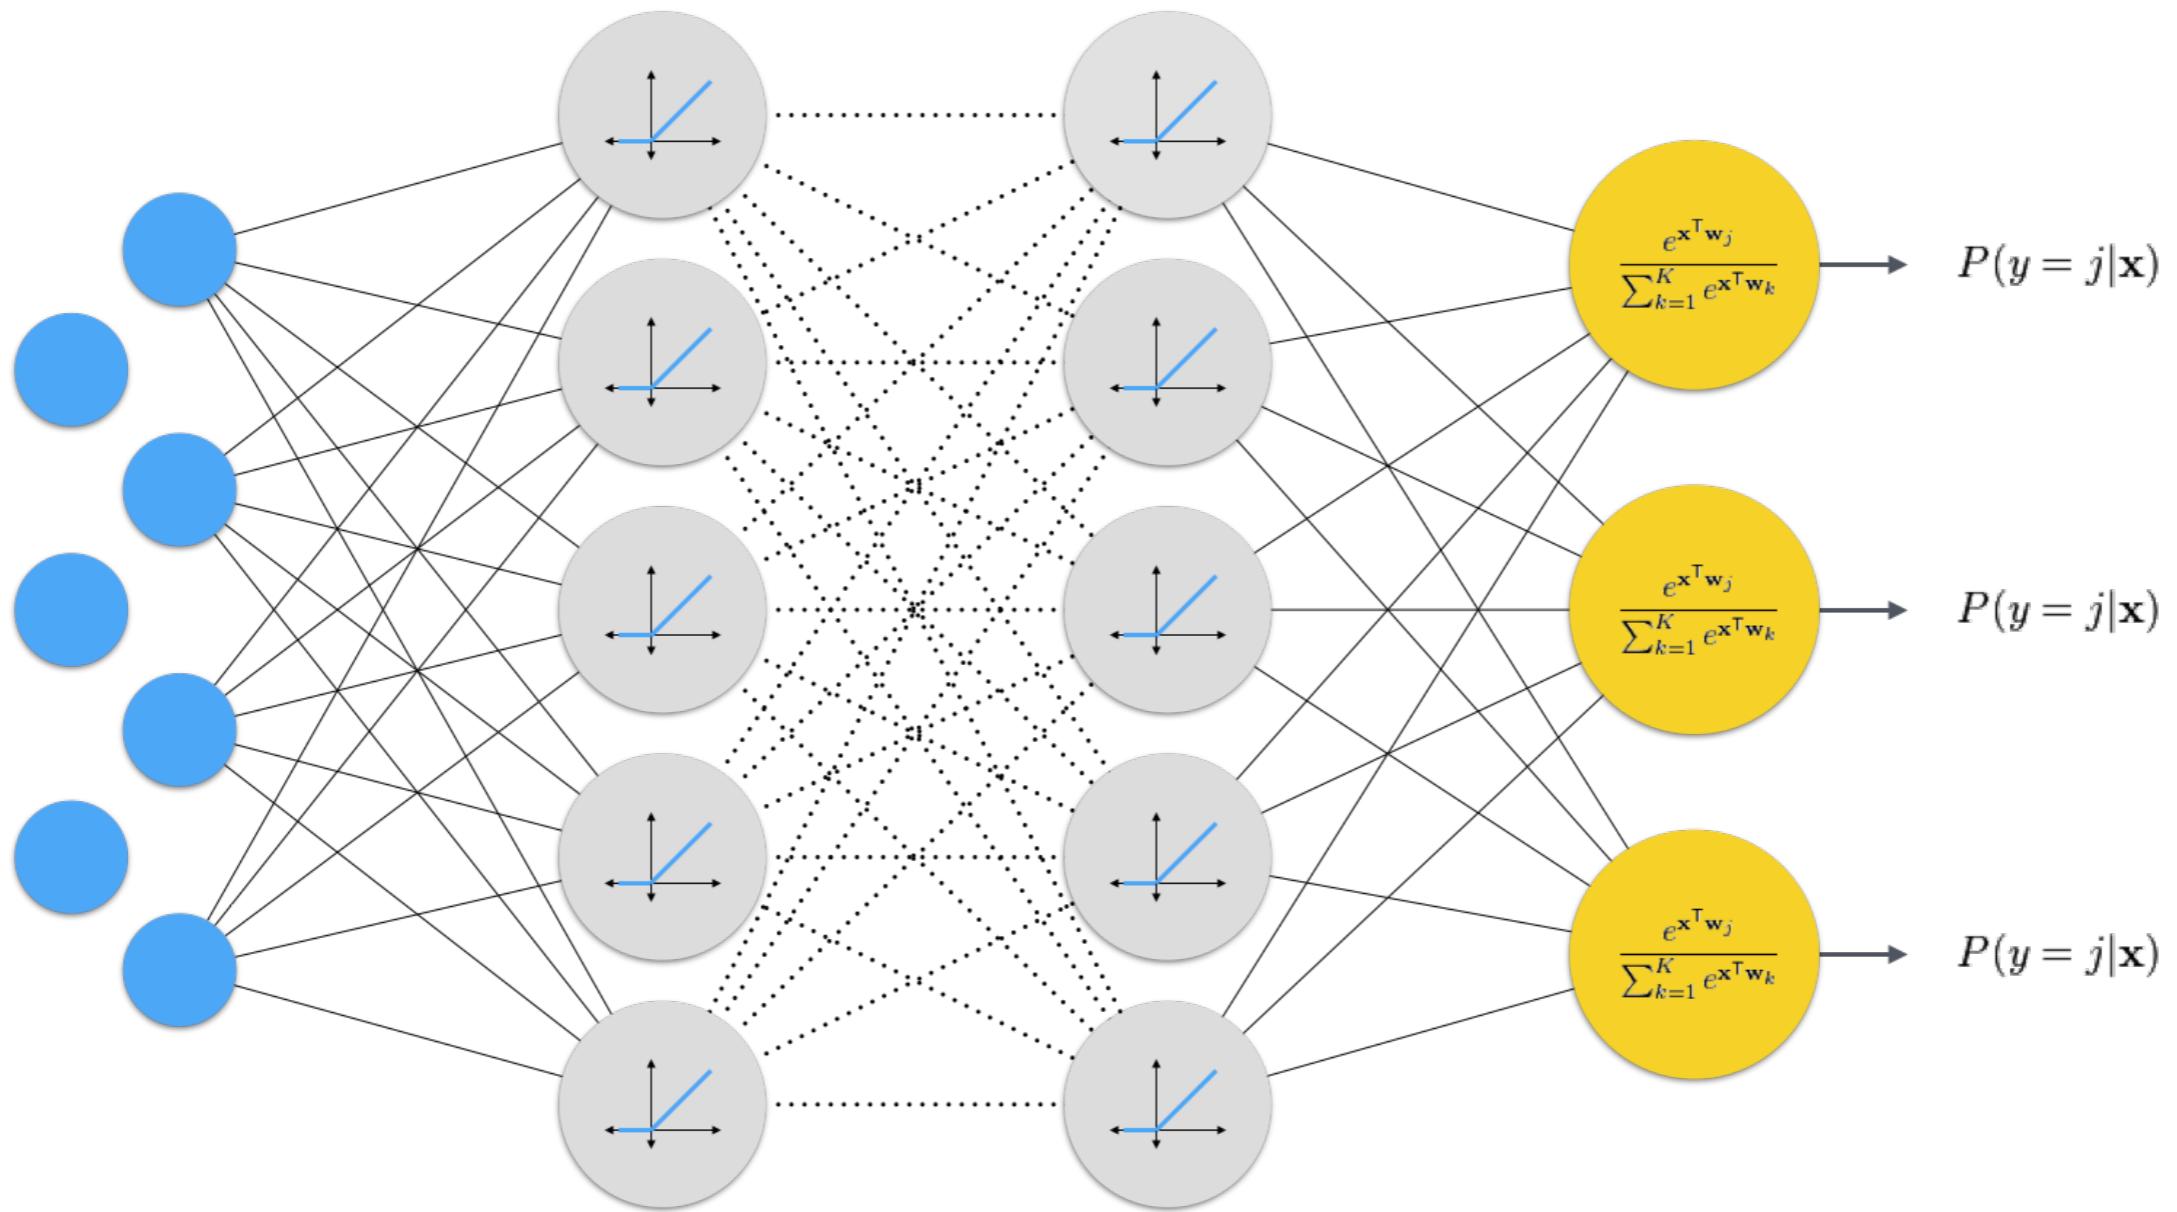


Redes Neurais Convolucionais

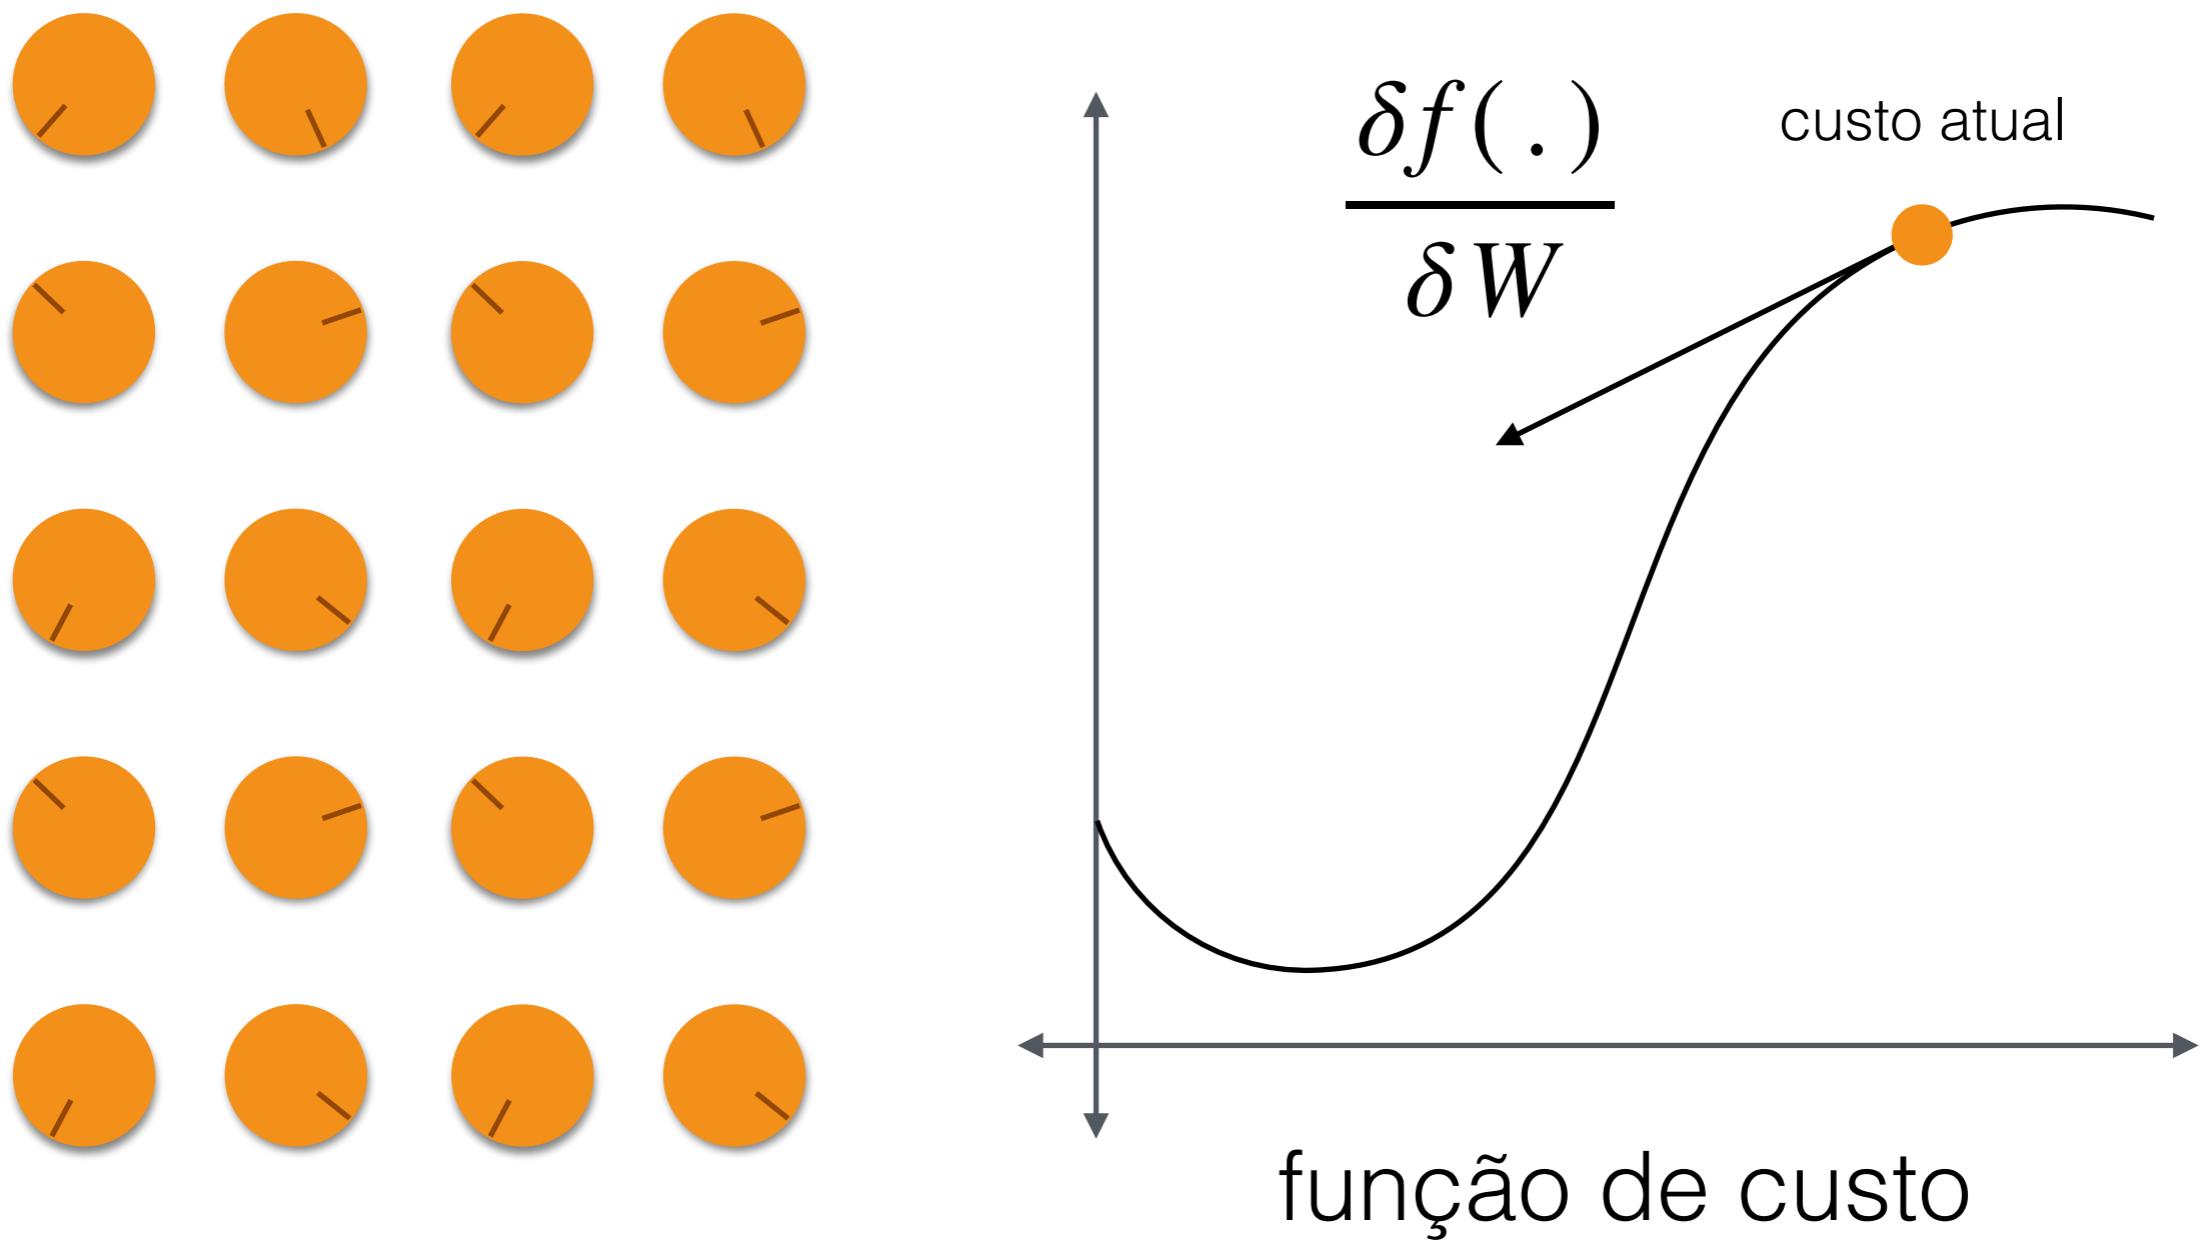
estas camadas finais são chamadas de
Fully Connected ou *Dense Layers*



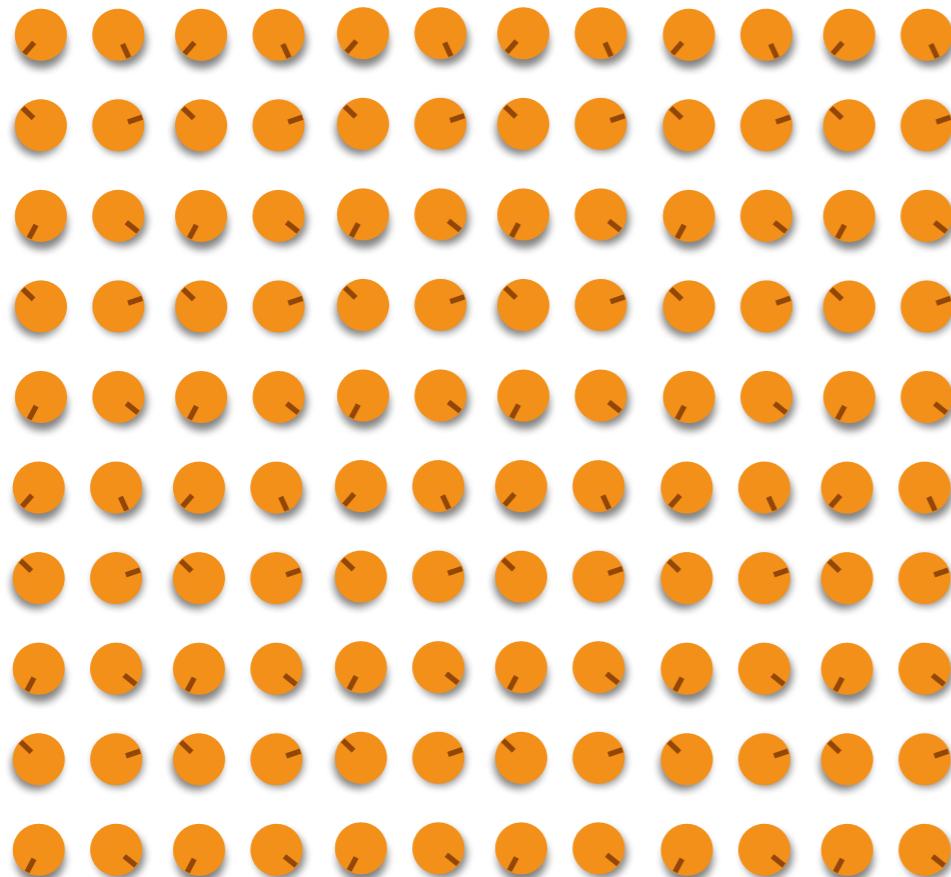
Redes Neurais Convolucionais



Redes Neurais Convolucionais



Redes Neurais Convolucionais



MUITOS pesos

Gradiente Descendente
realizado a cada exemplo
se torna **inviável**

A solução é aproximar:
Stochastic Gradient
Descent

Redes Neurais Convolucionais

acabou?

Redes Neurais Convolucionais

a1	a2	a3	a4	a5	a6
a7	a8	a9	a10	a11	a12
a13	a14	a15	a16	a17	a18
a19	a20	a21	a22	a23	a24
a25	a26	a27	a28	a29	a30
a31	a32	a33	a34	a35	a36

Redes Neurais Convolucionais

a1	a2	a3	a4	a5	a6
a7	a8	a9	a10	a11	a12
a13	a14	a15	a16	a17	a18
	a19	a20	a21	a22	a23
	a25	a26	a27	a28	a29
	a31	a32	a33	a34	a35
					a36

Pooling

a1	a2	a3	a4	a5	a6
a7	a8	a9	a10	a11	a12
a13	a14	a15	a16	a17	a18
a19	a20	a21	a22	a23	a24
a25	a26	a27	a28	a29	a30
a31	a32	a33	a34	a35	a36

Pooling

a1	a2	a3	a4	a5	a6
a7	a8	a9	a10	a11	a12
a13	a14	a15	a16	a17	a18
a19	a20	a21	a22	a23	a24
a25	a26	a27	a28	a29	a30
a31	a32	a33	a34	a35	a36

a1	a2	a3	a4	a5	a6
a7	a8	a9	a10	a11	a12
a13	a14	a15	a16	a17	a18
a19	a20	a21	a22	a23	a24
a25	a26	a27	a28	a29	a30
a31	a32	a33	a34	a35	a36

Pooling

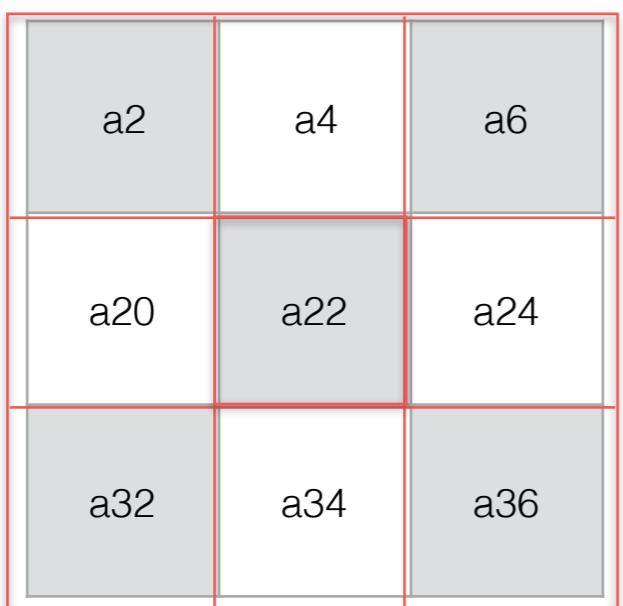
a1	a2	a3	a4	a5	a6
a7	a8	a9	a10	a11	a12
a13	a14	a15	a16	a17	a18
a19	a20	a21	a22	a23	a24
a25	a26	a27	a28	a29	a30
a31	a32	a33	a34	a35	a36

a2	a4	a6
a20	a22	a24
a32	a34	a36

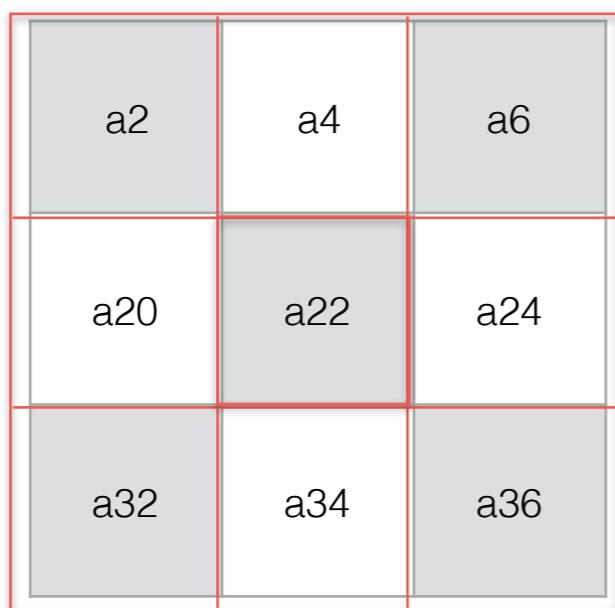
Pooling

a2	a4	a6
a20	a22	a24
a32	a34	a36

Pooling

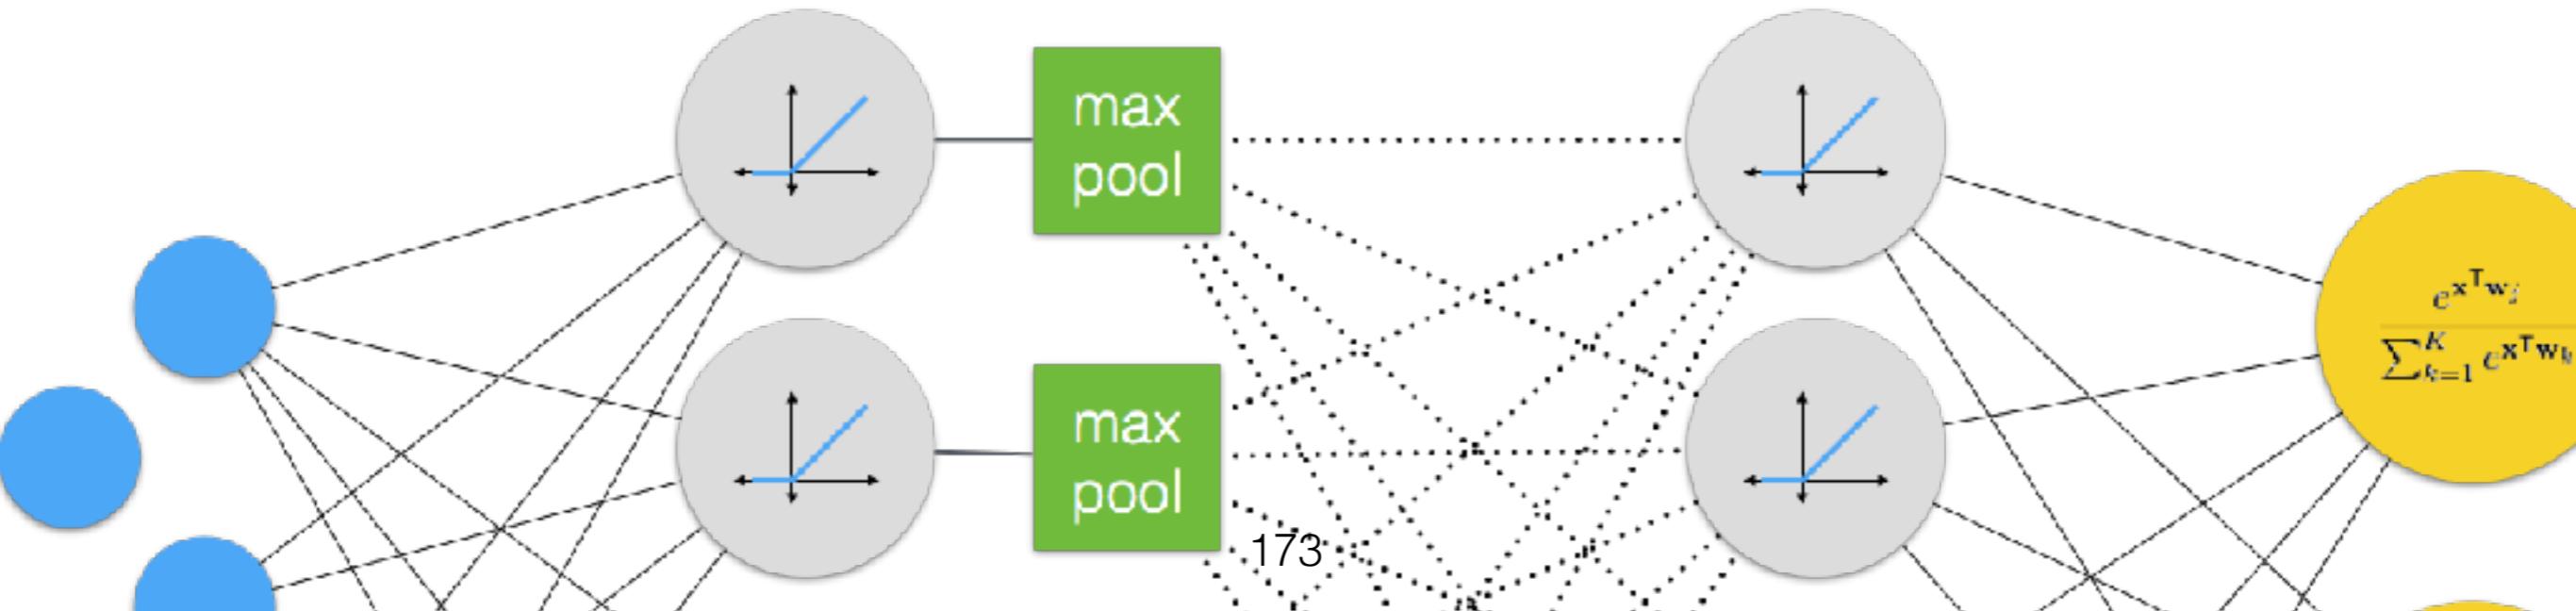


Pooling



características menos locais
mais globais

Arquiteturas



ImageNet / Large Scale Visual Recognition Challenge

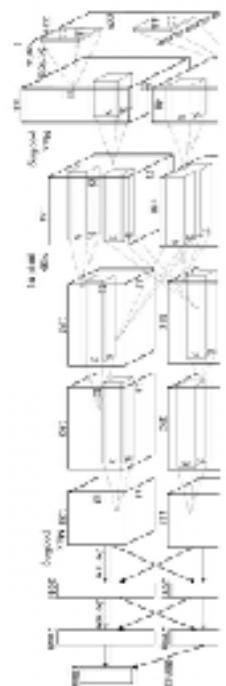
Dataset:
22K Categorias
14mi Imagens

Desafio:
1000 Categorias
1,4mi Imagens

The screenshot shows the ImageNet website interface. At the top, there is a logo composed of many small images forming the letters 'IM-GENET'. Below the logo, there are three tabs: 'Treemap Visualization' (highlighted in yellow), 'Images of the Synset', and 'Downloads'. Underneath these tabs, a breadcrumb navigation path is visible: 'ImageNet 2011 Fall Release > 1 > 1 > Woody plant, lignocuous plant > Tree'. The main content area displays a grid of 16 rows and 10 columns of images, each labeled with a tree name. The names include Calabash, Arbolera, Breakax, Gulta-percha, Spanish, Msasa, Indian, Lanseh, Bonduc, Nitta, Manila, Obeche, Dhawa, Cocobolo, Guinea, Chaulmoogra, Souari, Camwood, Granadilla, Maribewood, Satinwood, Montezuma, Quandong, Millettia, Gutta-percha, Jamaica, Keurboem, Fever, Puka, Kelembilla, Kino, Ice-cream, Treelet, Dagarne, Kingwood, Quandong, Scarlet, Silver, Buton, Bloodwood, Garib, Tipu, Christmas, Aallii, Princewood, Maria, Totu, Pepper, and Shaving-brush. To the left of the grid, there is a hierarchical tree structure for the 'ImageNet 2011 Fall Release (32326)' category, listing various plant types and their sub-categories with synset counts in parentheses.

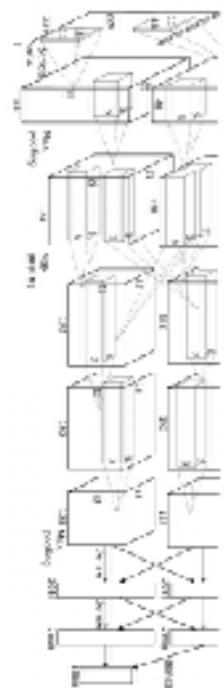
Arquiteturas e o Número de Camadas

Arquiteturas e o Número de Camadas

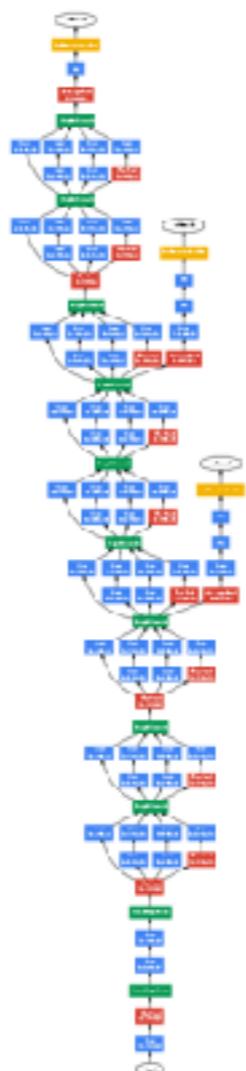


AlexNet (9)

Arquiteturas e o Número de Camadas

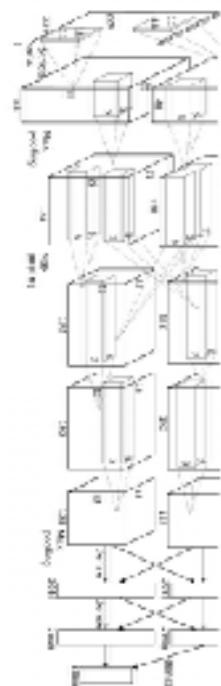


AlexNet (9)

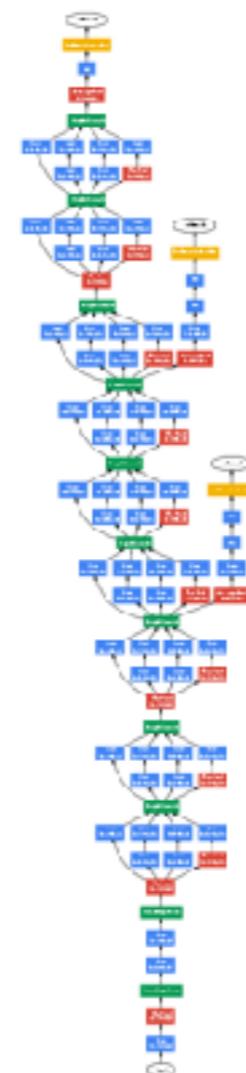


GoogLeNet (22)

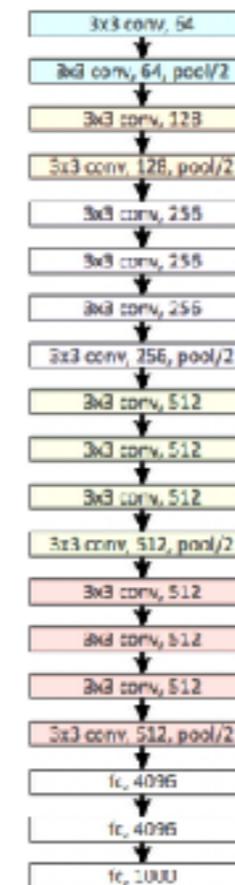
Arquiteturas e o Número de Camadas



AlexNet (9)

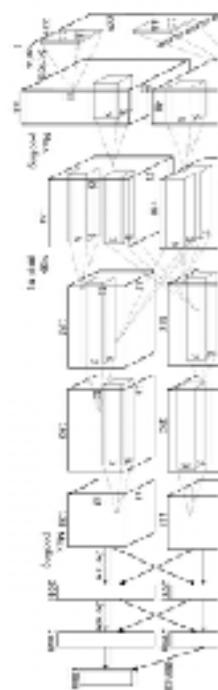


GoogLeNet (22)



VGG (16/19)

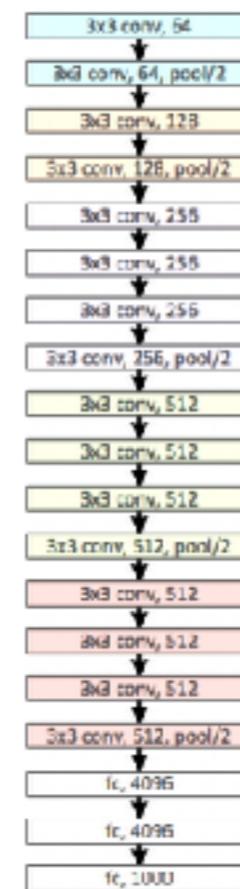
Arquiteturas e o Número de Camadas



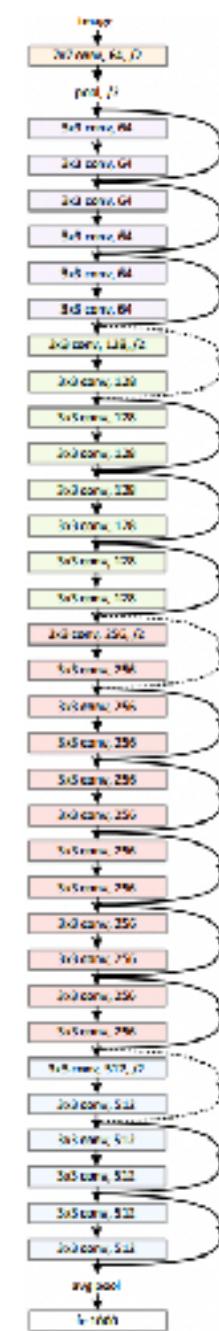
AlexNet (9)



GoogLeNet (22)



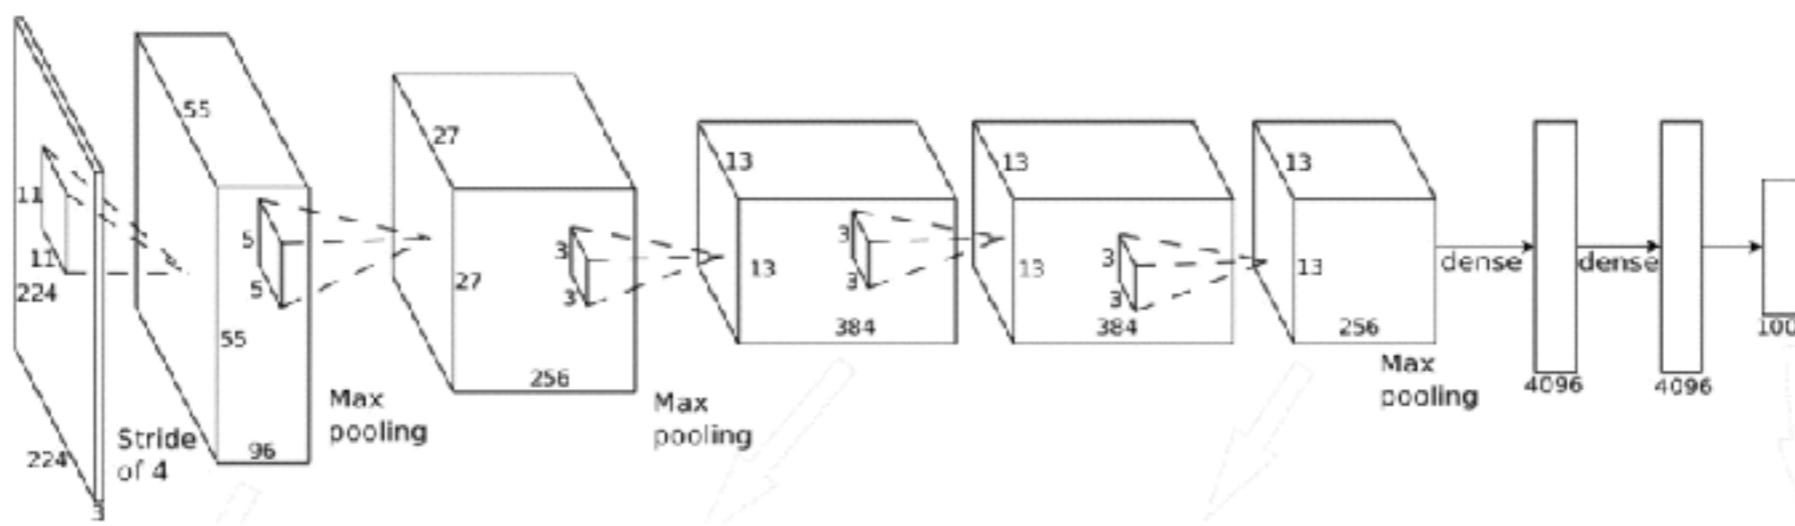
VGG (16/19)



ResNet (34+)

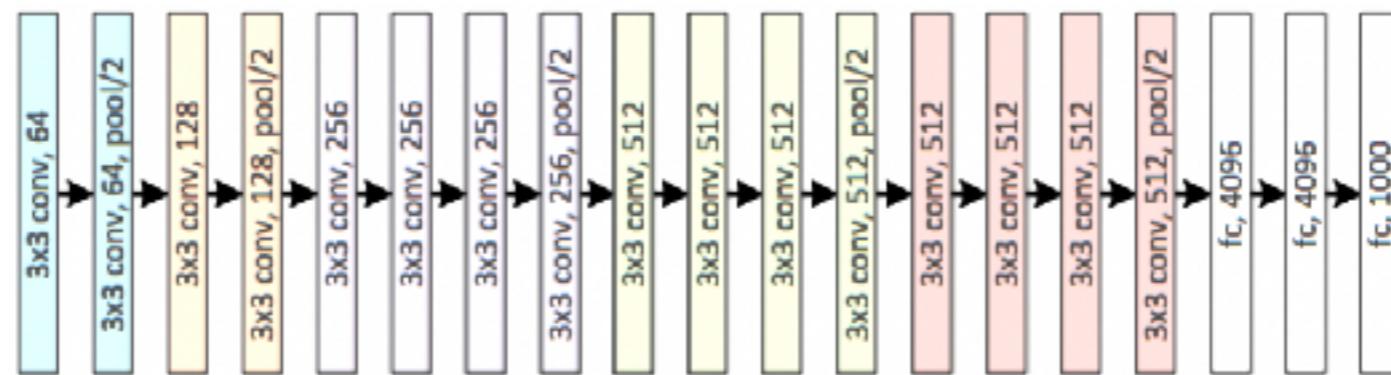
AlexNet (Krizhevsky, 2012)

- 60 million parameters.
- input 224×224
- conv1: $K = 96$ filters with $11 \times 11 \times 3$, stride 4, conv2: $K = 256$ filters with $5 \times 5 \times 48$,
- conv3: $K = 384$ filters with $3 \times 3 \times 256$,
- conv4: $K = 384$ filters with $3 \times 3 \times 192$,
- conv5: $K = 256$ filters with $3 \times 3 \times 192$,
- fc1, fc2: $K = 4096$.



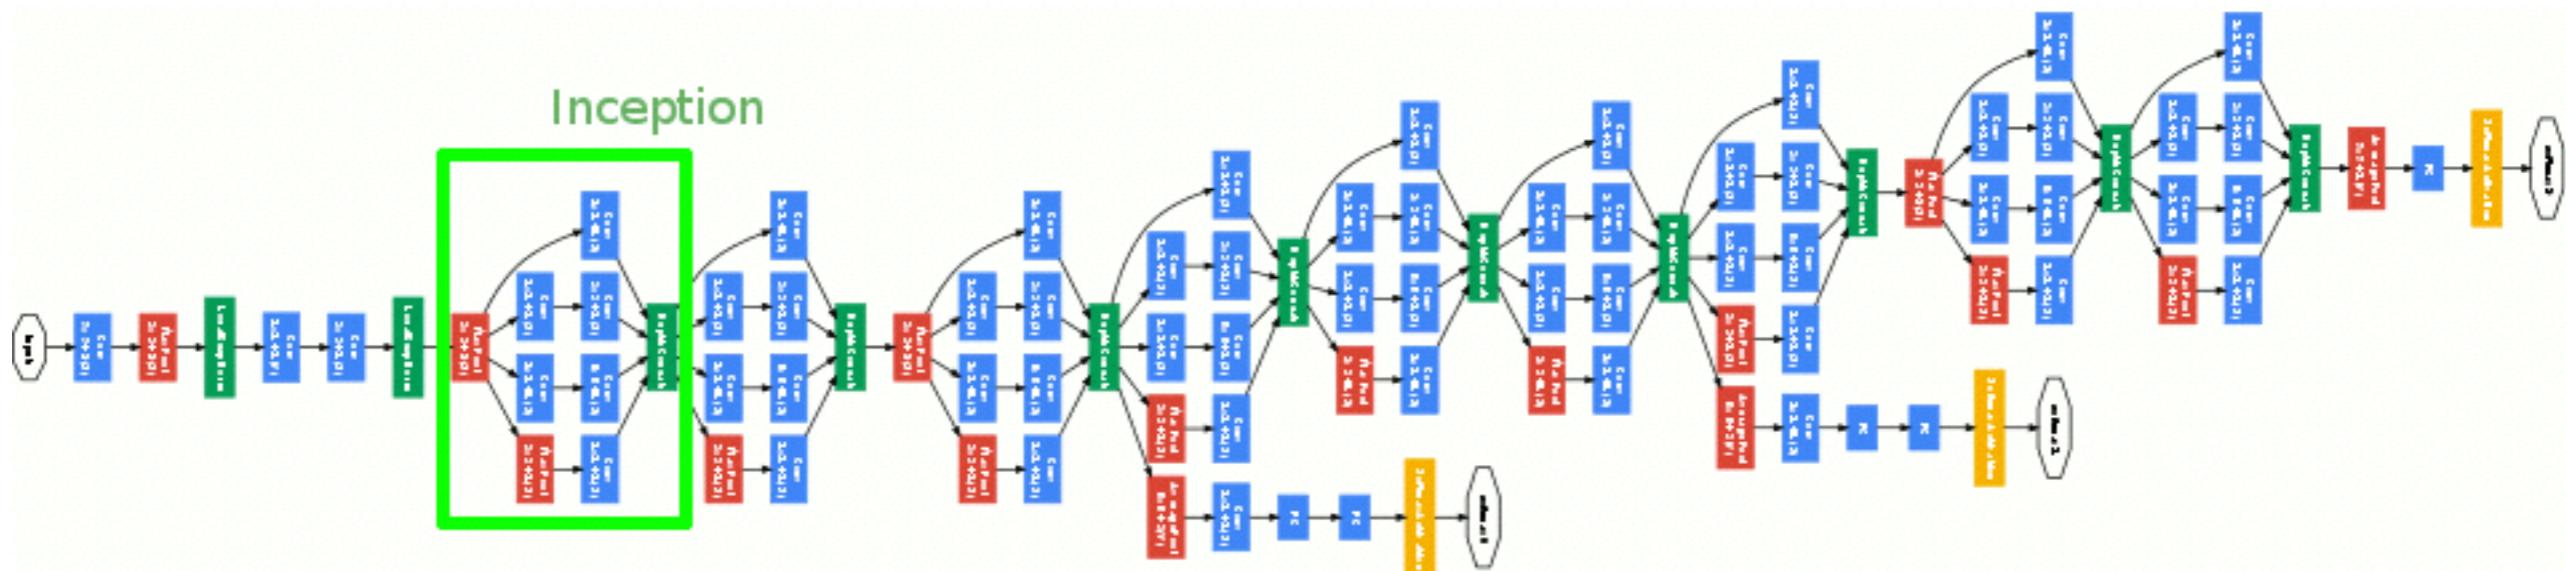
VGG 19 (Simonyan, 2014)

- +layers, –filter size = less parameters
 - conv 5-6-7-8: K = 256 + maxpool
- input 224×224 ,
 - conv 9-10-11-12: K = 512 + maxpool
- filters: all 3×3 ,
 - conv 13-14-15-16: K = 512 + maxpool
- conv 1-2: K = 64 + maxpool
 - fc1, fc2: K = 4096
- conv 3-4: K = 128 + maxpool

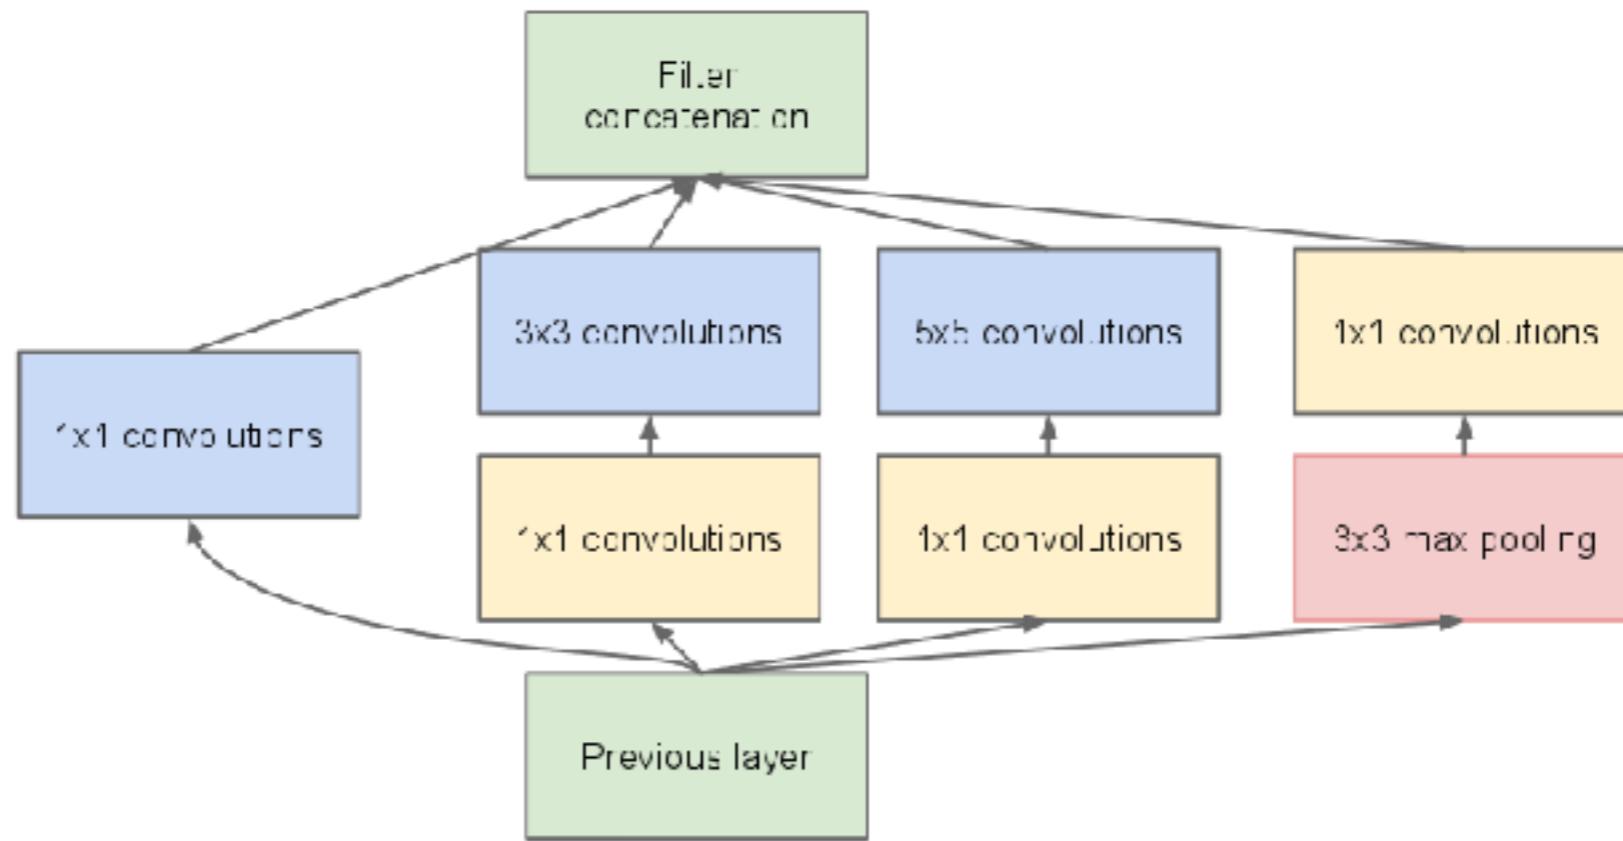


GoogLeNet (Szegedy, 2014)

- 22 layers
- Starts with two convolutional layers
- Inception layer (“filter bank”):
 - filters 1×1 , 3×3 , 5×5 + max pooling 3×3 ;
 - reduce dimensionality using 1×1 filters.
 - 3 classifiers in different parts
- Blue = convolution,
- Red = pooling,
- Yellow = Softmax loss fully connected layers
- Green = normalization or concatenation

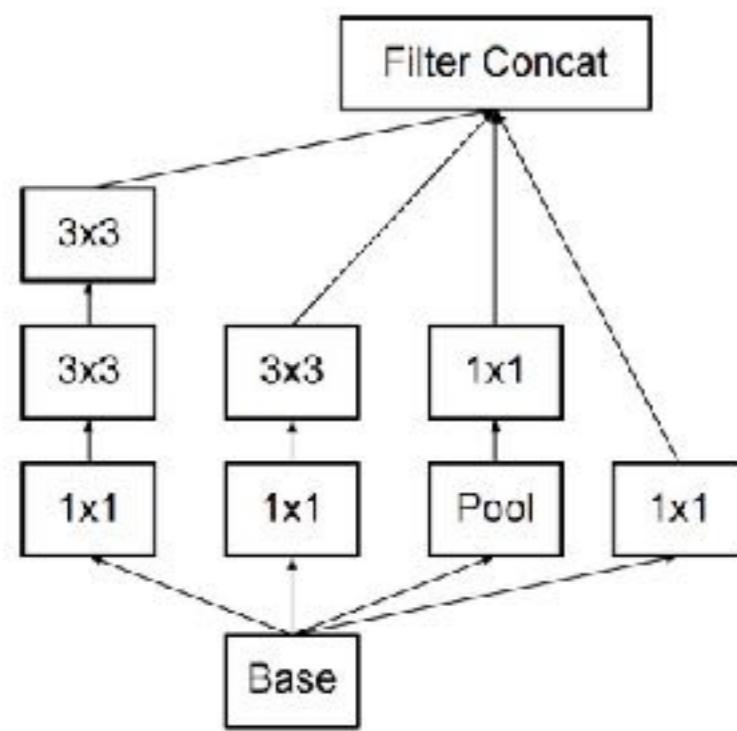


GoogLeNet (Szegedy, 2014)

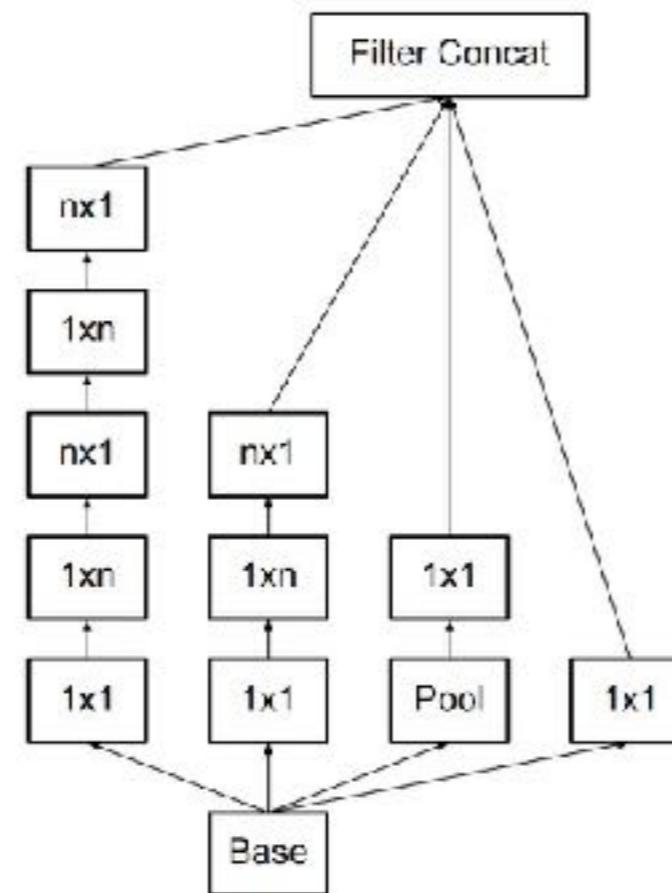


- 1×1 convolution reduces the depth of previous layers by half
- this is needed to reduce complexity (e.g. from 256 to 128 d)
- concatenates 3 filters plus an extra max pooling filter (because).

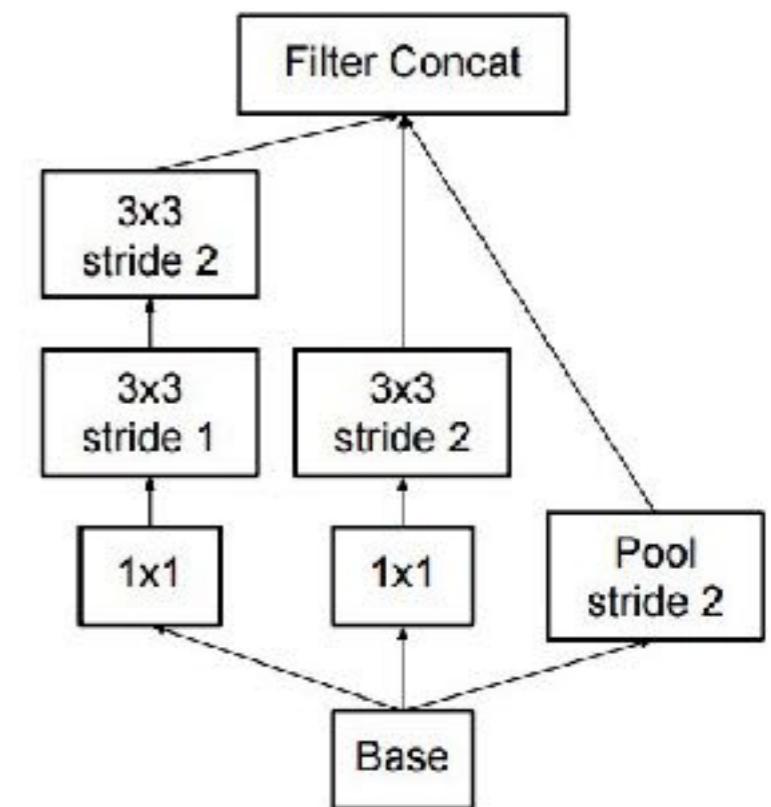
Inception Modules (V2 and V3)



Múltiplas conv. 3×3



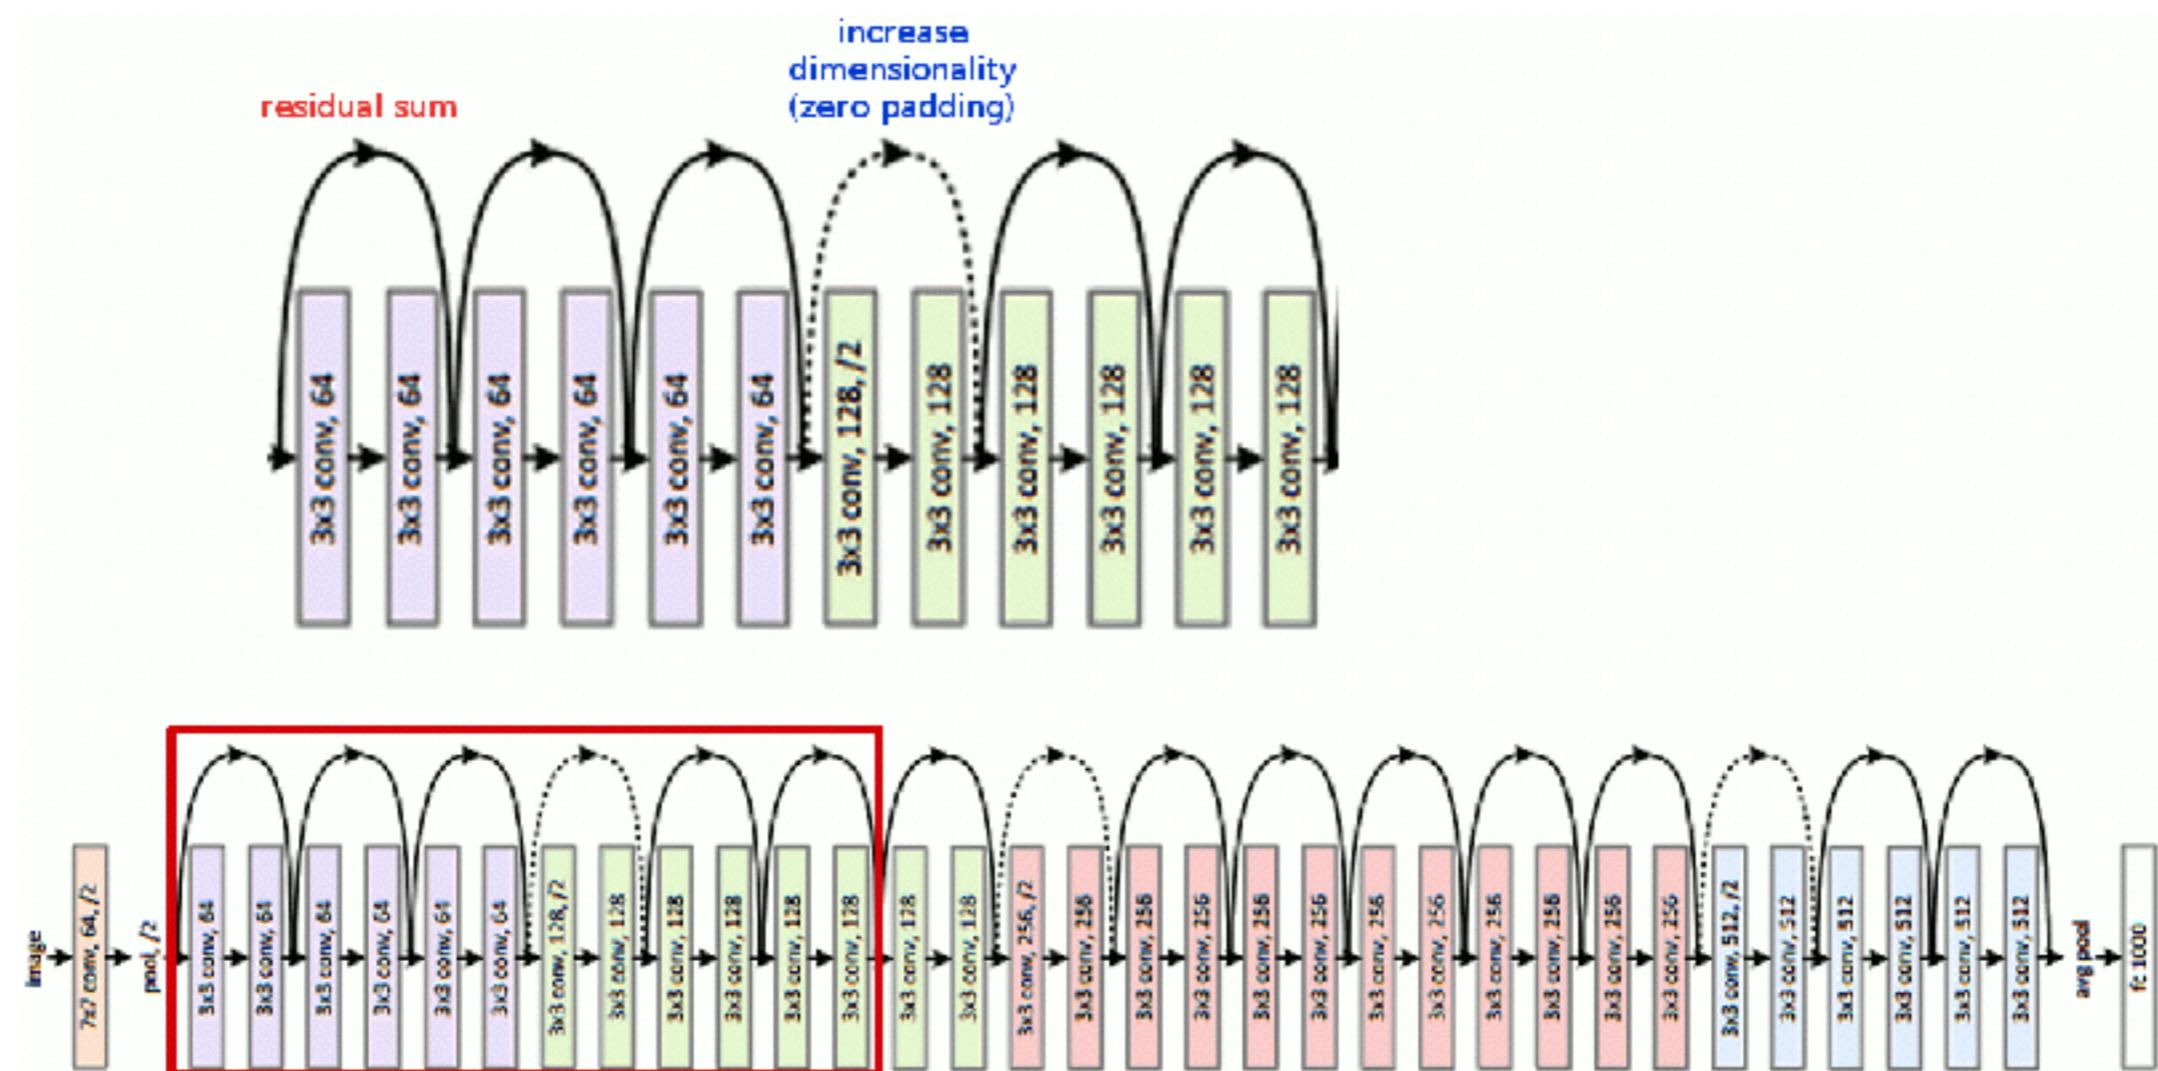
Flat Conv.



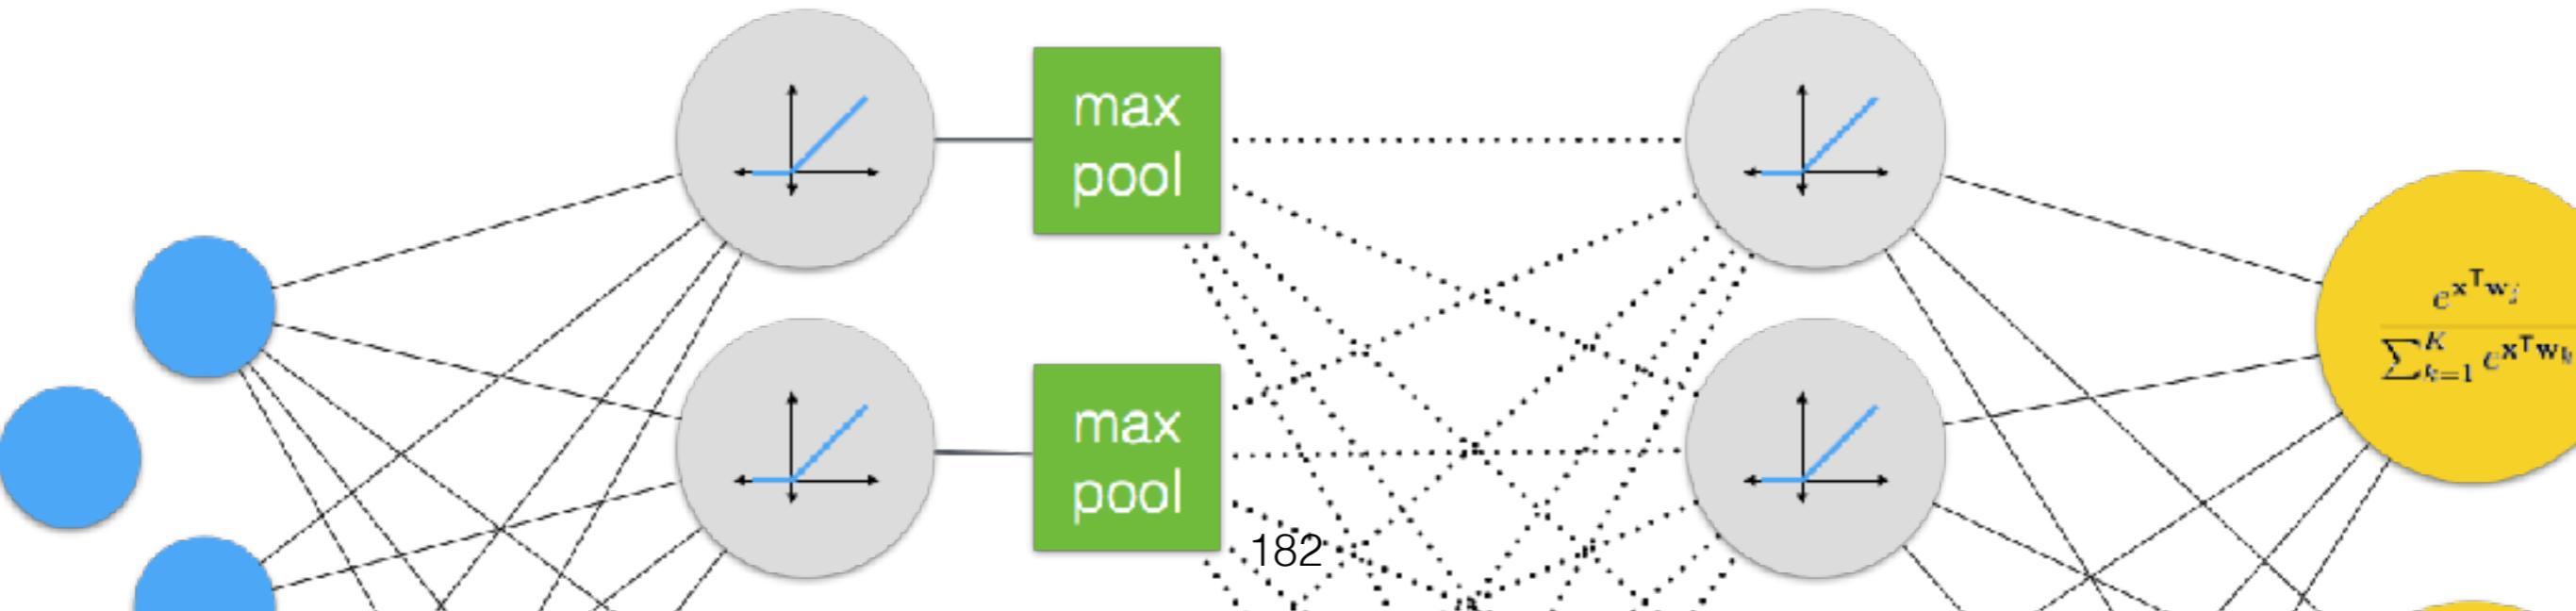
Diminuição de Tamanho

ResNet (He et al, 2015)

Reduz número de filtros, aumenta número de camadas (34-1000). Em uma arquitetura Residual, a entrada de camadas anteriores é repetida nas posteriores



Dicas para Treinamento



Dicas para Treinamento

Dicas para Treinamento

Tamanho de Batch

Dicas para Treinamento

Tamanho de Batch

Batch Normalization

Dicas para Treinamento

Tamanho de Batch

Batch Normalization

Learning Rate

Dicas para Treinamento

Tamanho de Batch

Batch Normalization

Learning Rate

Data Augmentation

Dicas para Treinamento

Tamanho de Batch

Batch Normalization

Learning Rate

Data Augmentation

Dropout

Dicas para Treinamento

Tamanho de Batch

Batch Normalization

Learning Rate

Data Augmentation

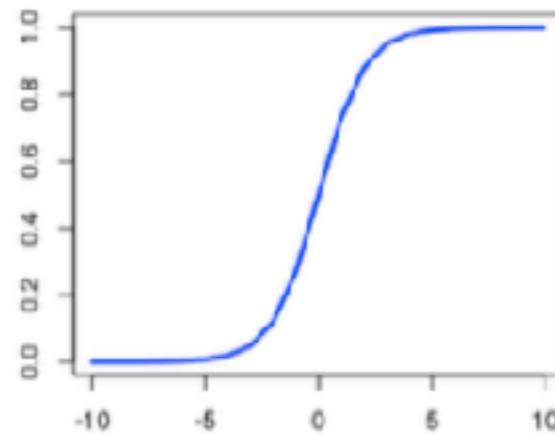
Dropout

**Divisão dos Dados em
Treino, Validação e
Teste**

Funções de Ativação

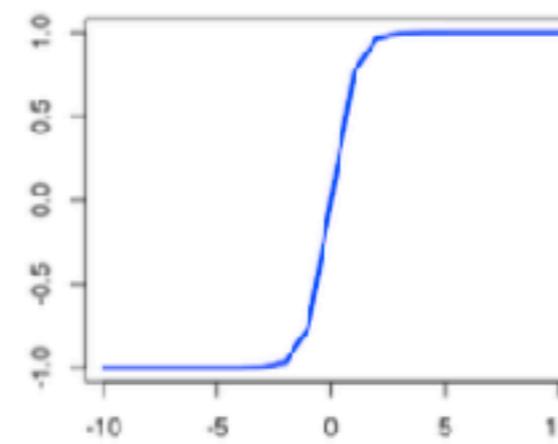
Sigmoid

$$f(x) = \frac{1}{1+e^{-x}}$$



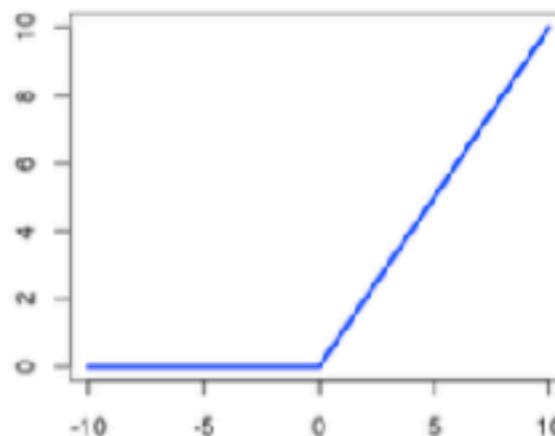
Hiperbolic Tangent

$$f(x) = \tanh(x)$$



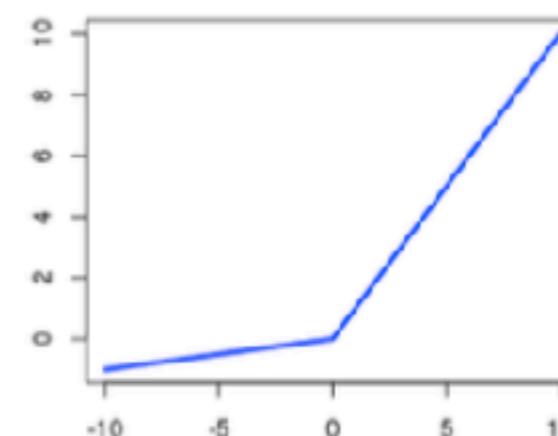
ReLU

$$f(x) = \max(0, x)$$

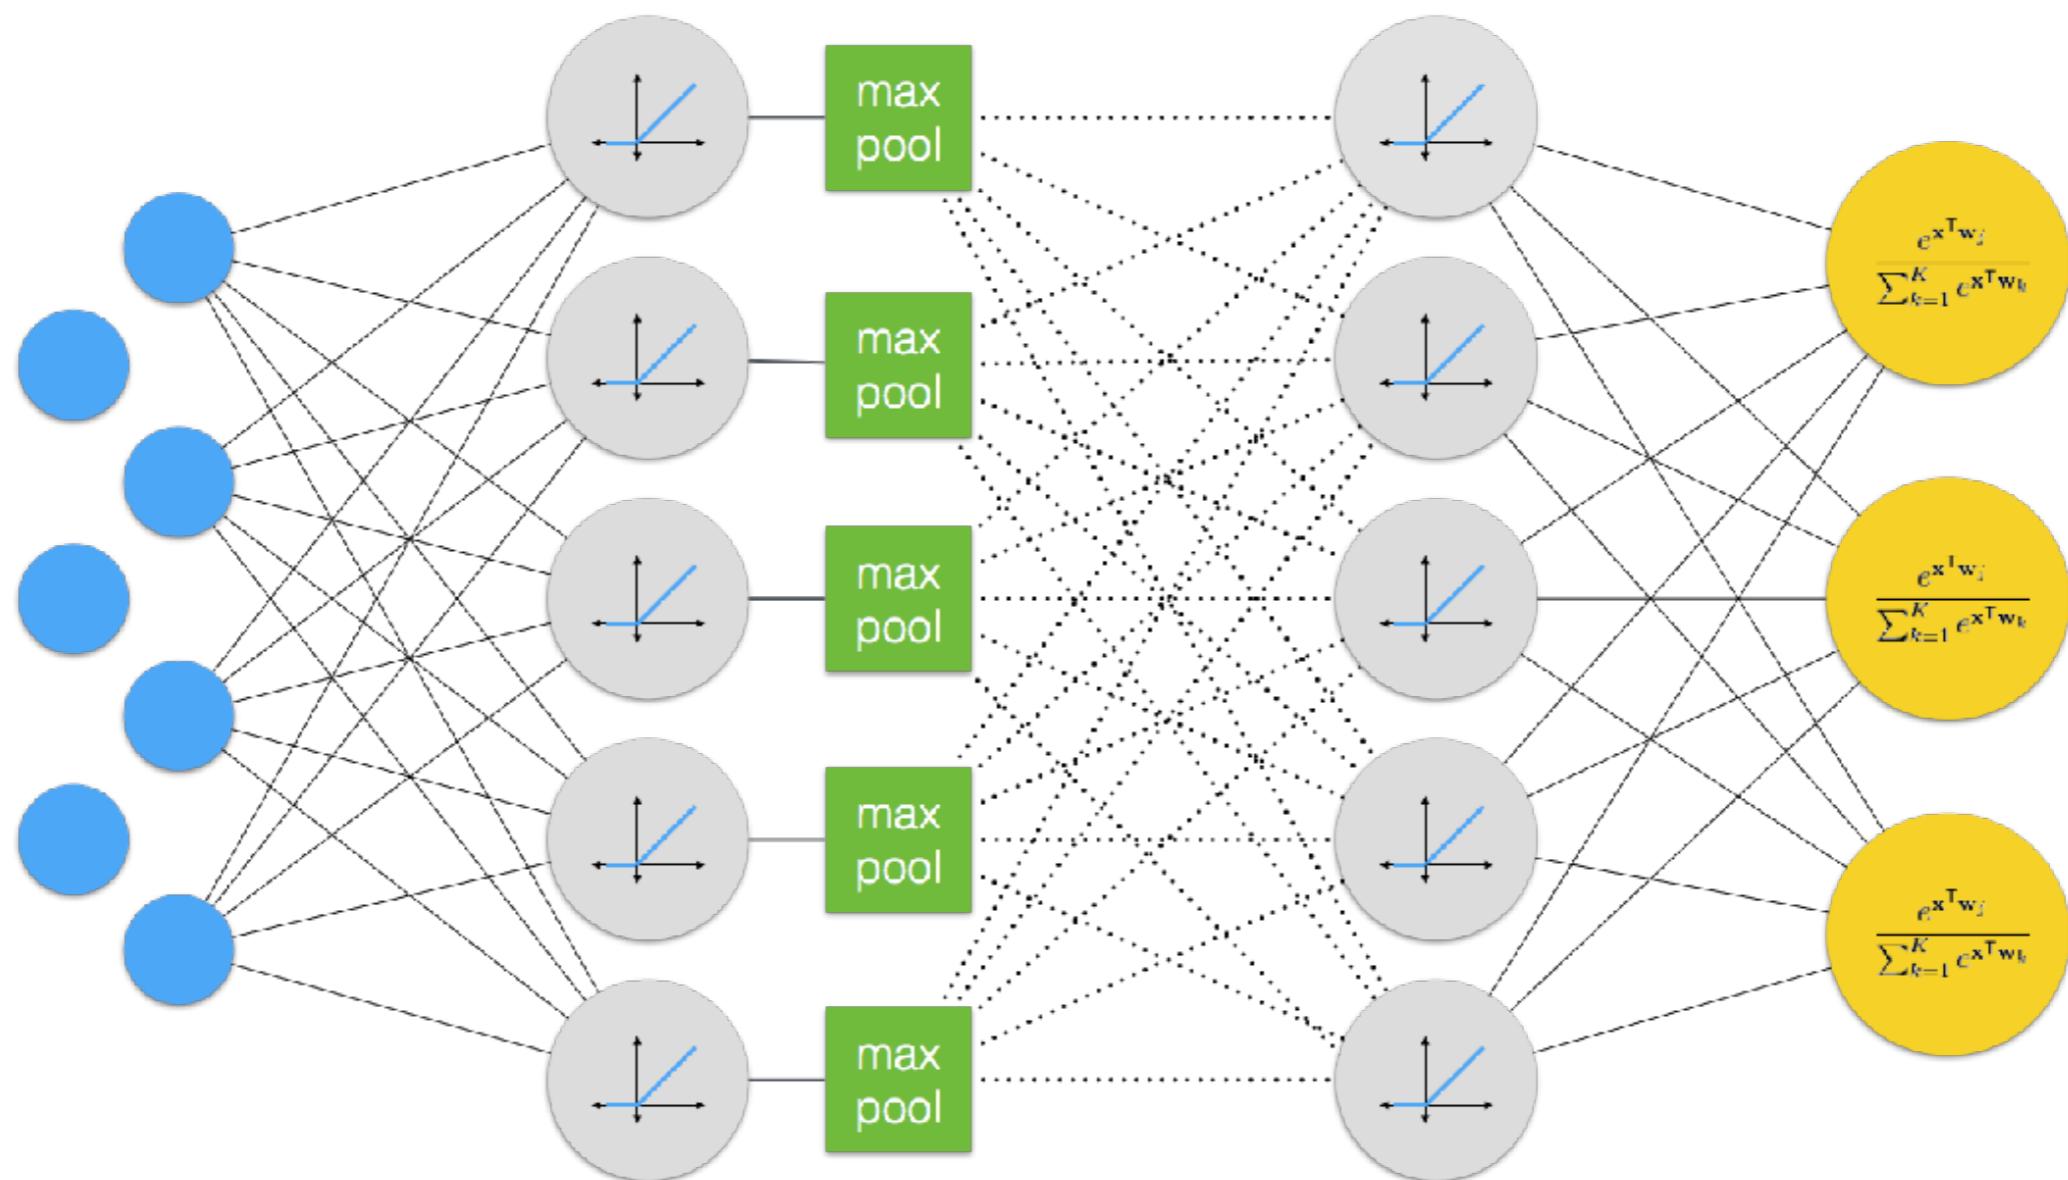


Leaky ReLU

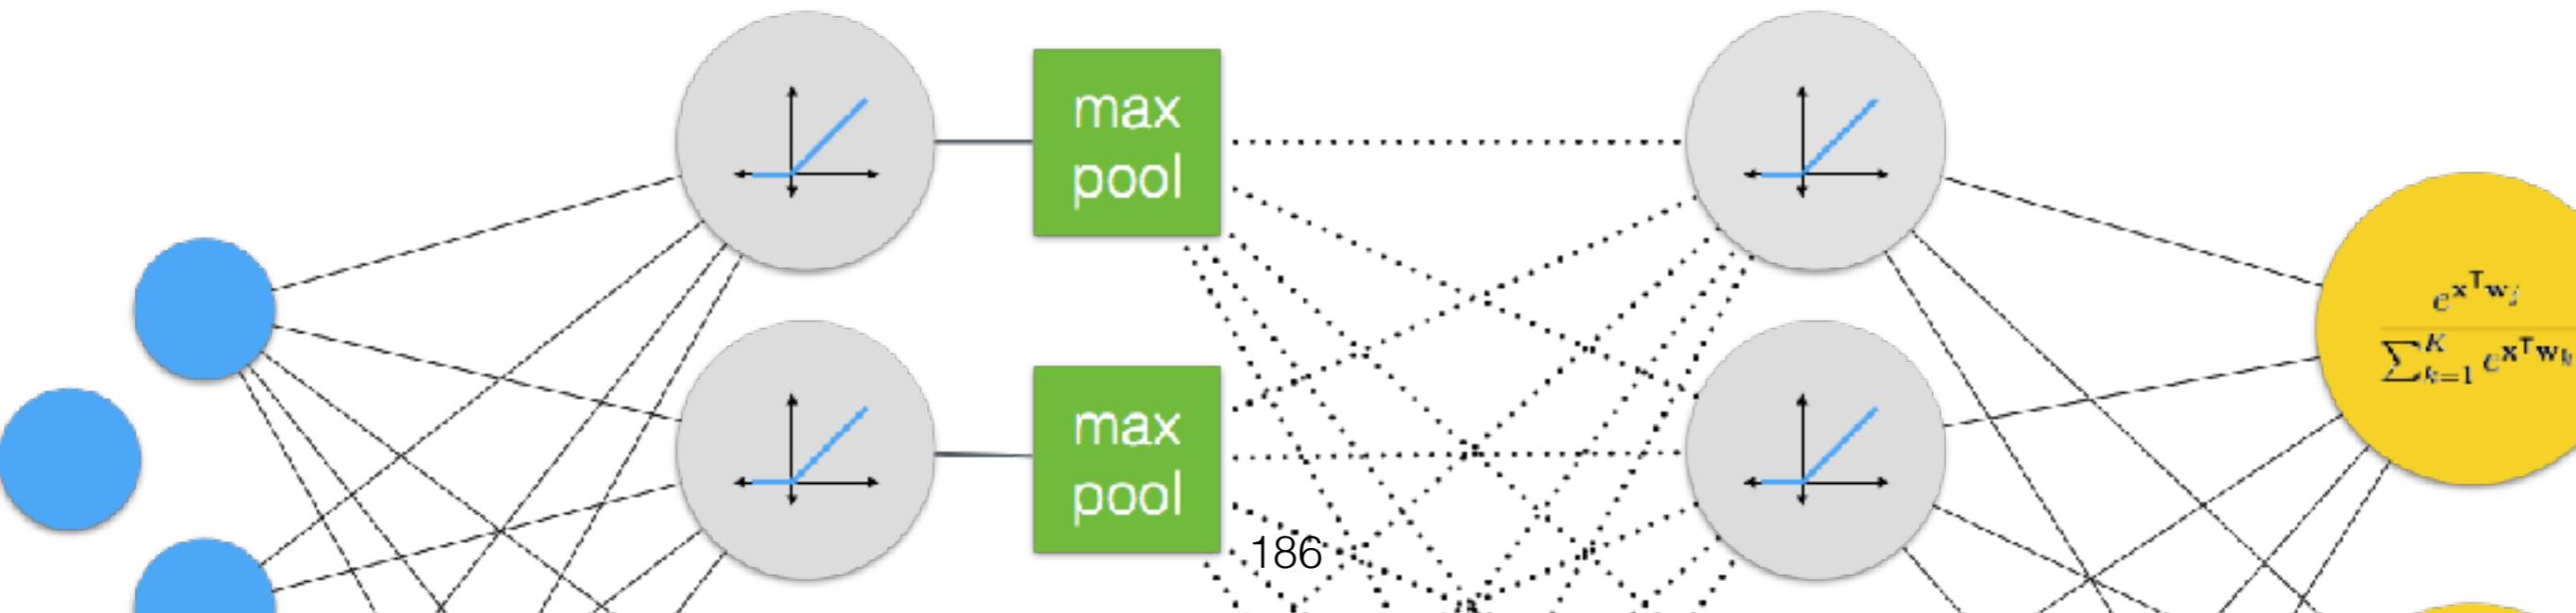
$$f(x) = \max(0.1x, x)$$



Redes Neurais Convolucionais



Deep Learning



DEMO #3

Deep Learning

Cronograma da Apresentação



Cronograma da Apresentação



Aprendizagem de
Máquina

Aprendizagem de
Representação

Deep Learning

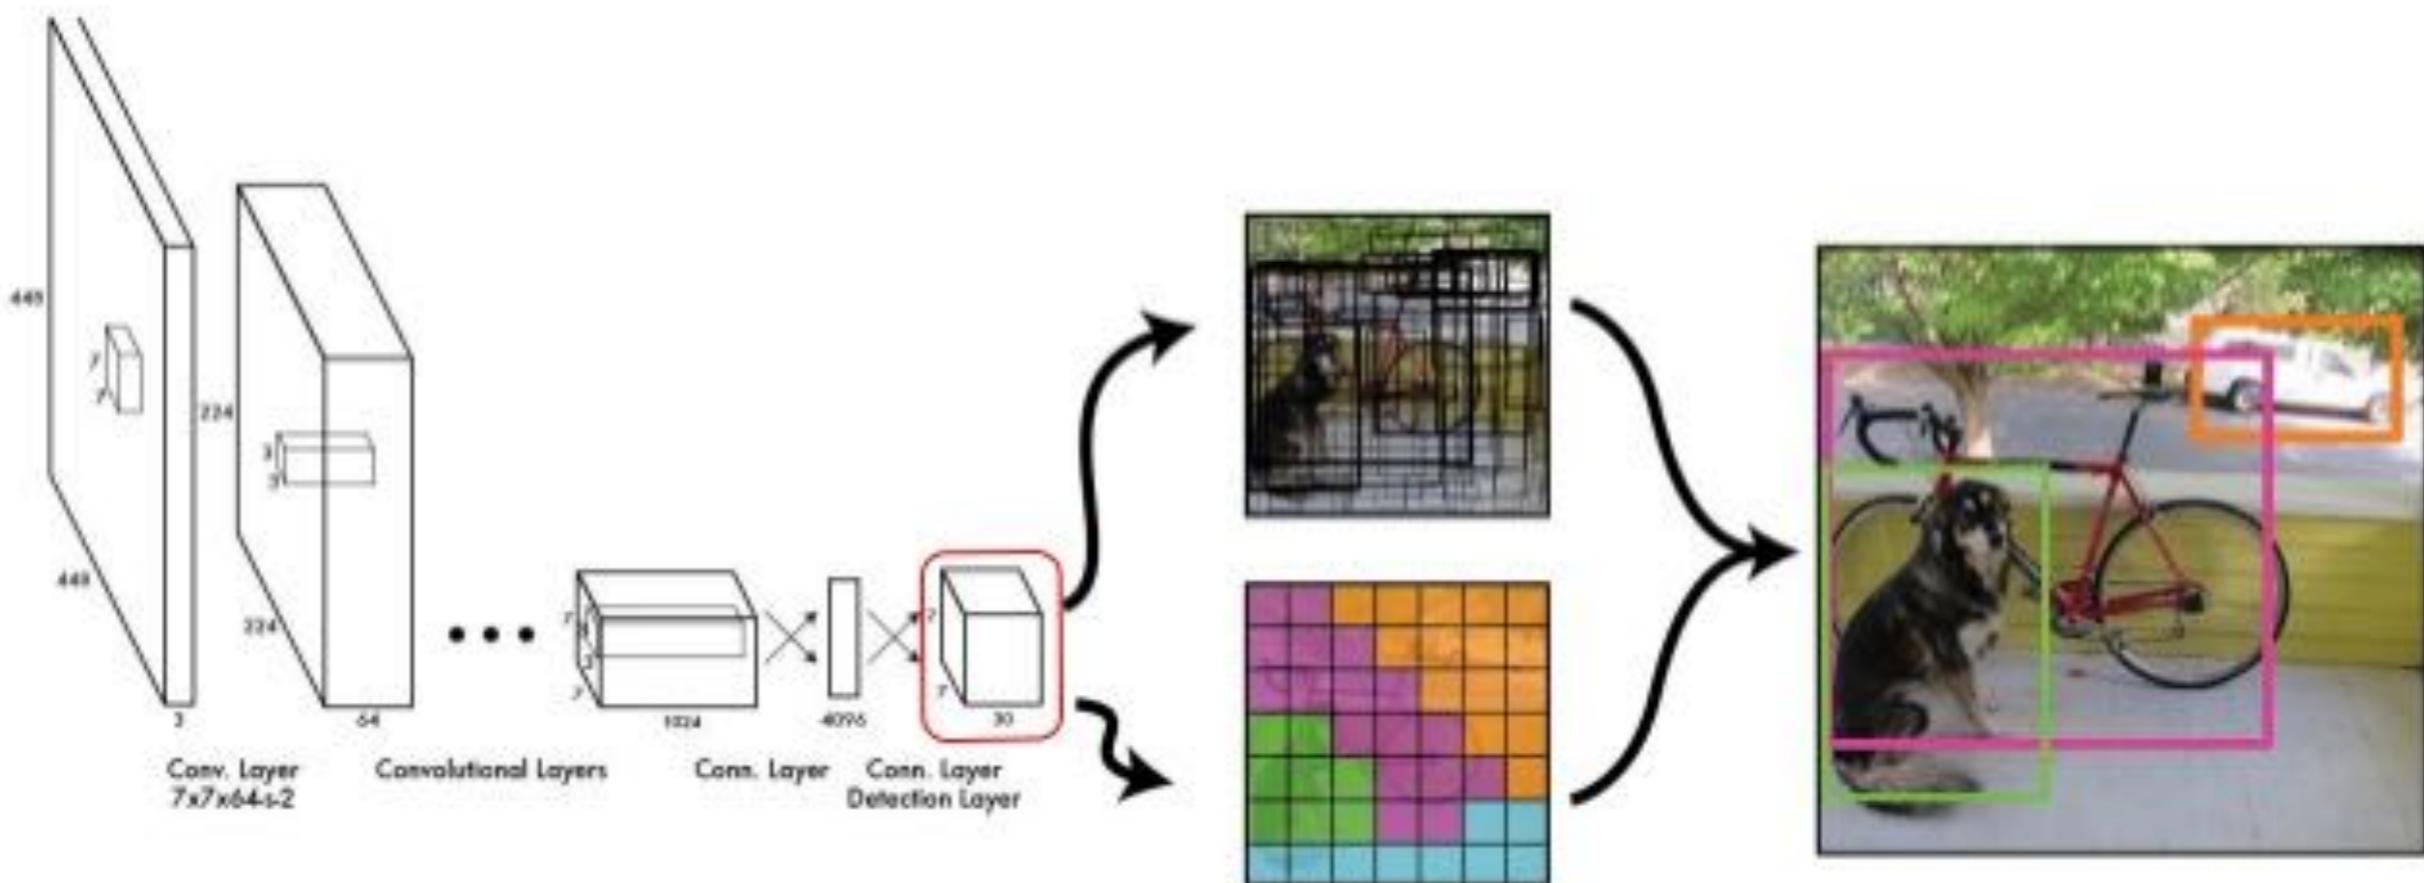
Aplicações e Diferentes Formulações

Aplicações e Diferentes Formulações

Localização e Detecção de
Objetos

YOLO: You Only Look Once

Aplicações



Redmon et al. [You Only Look Once: Unified, Real-Time Object Detection](#), CVPR 2016

30

<https://pjreddie.com/darknet/yolo/>

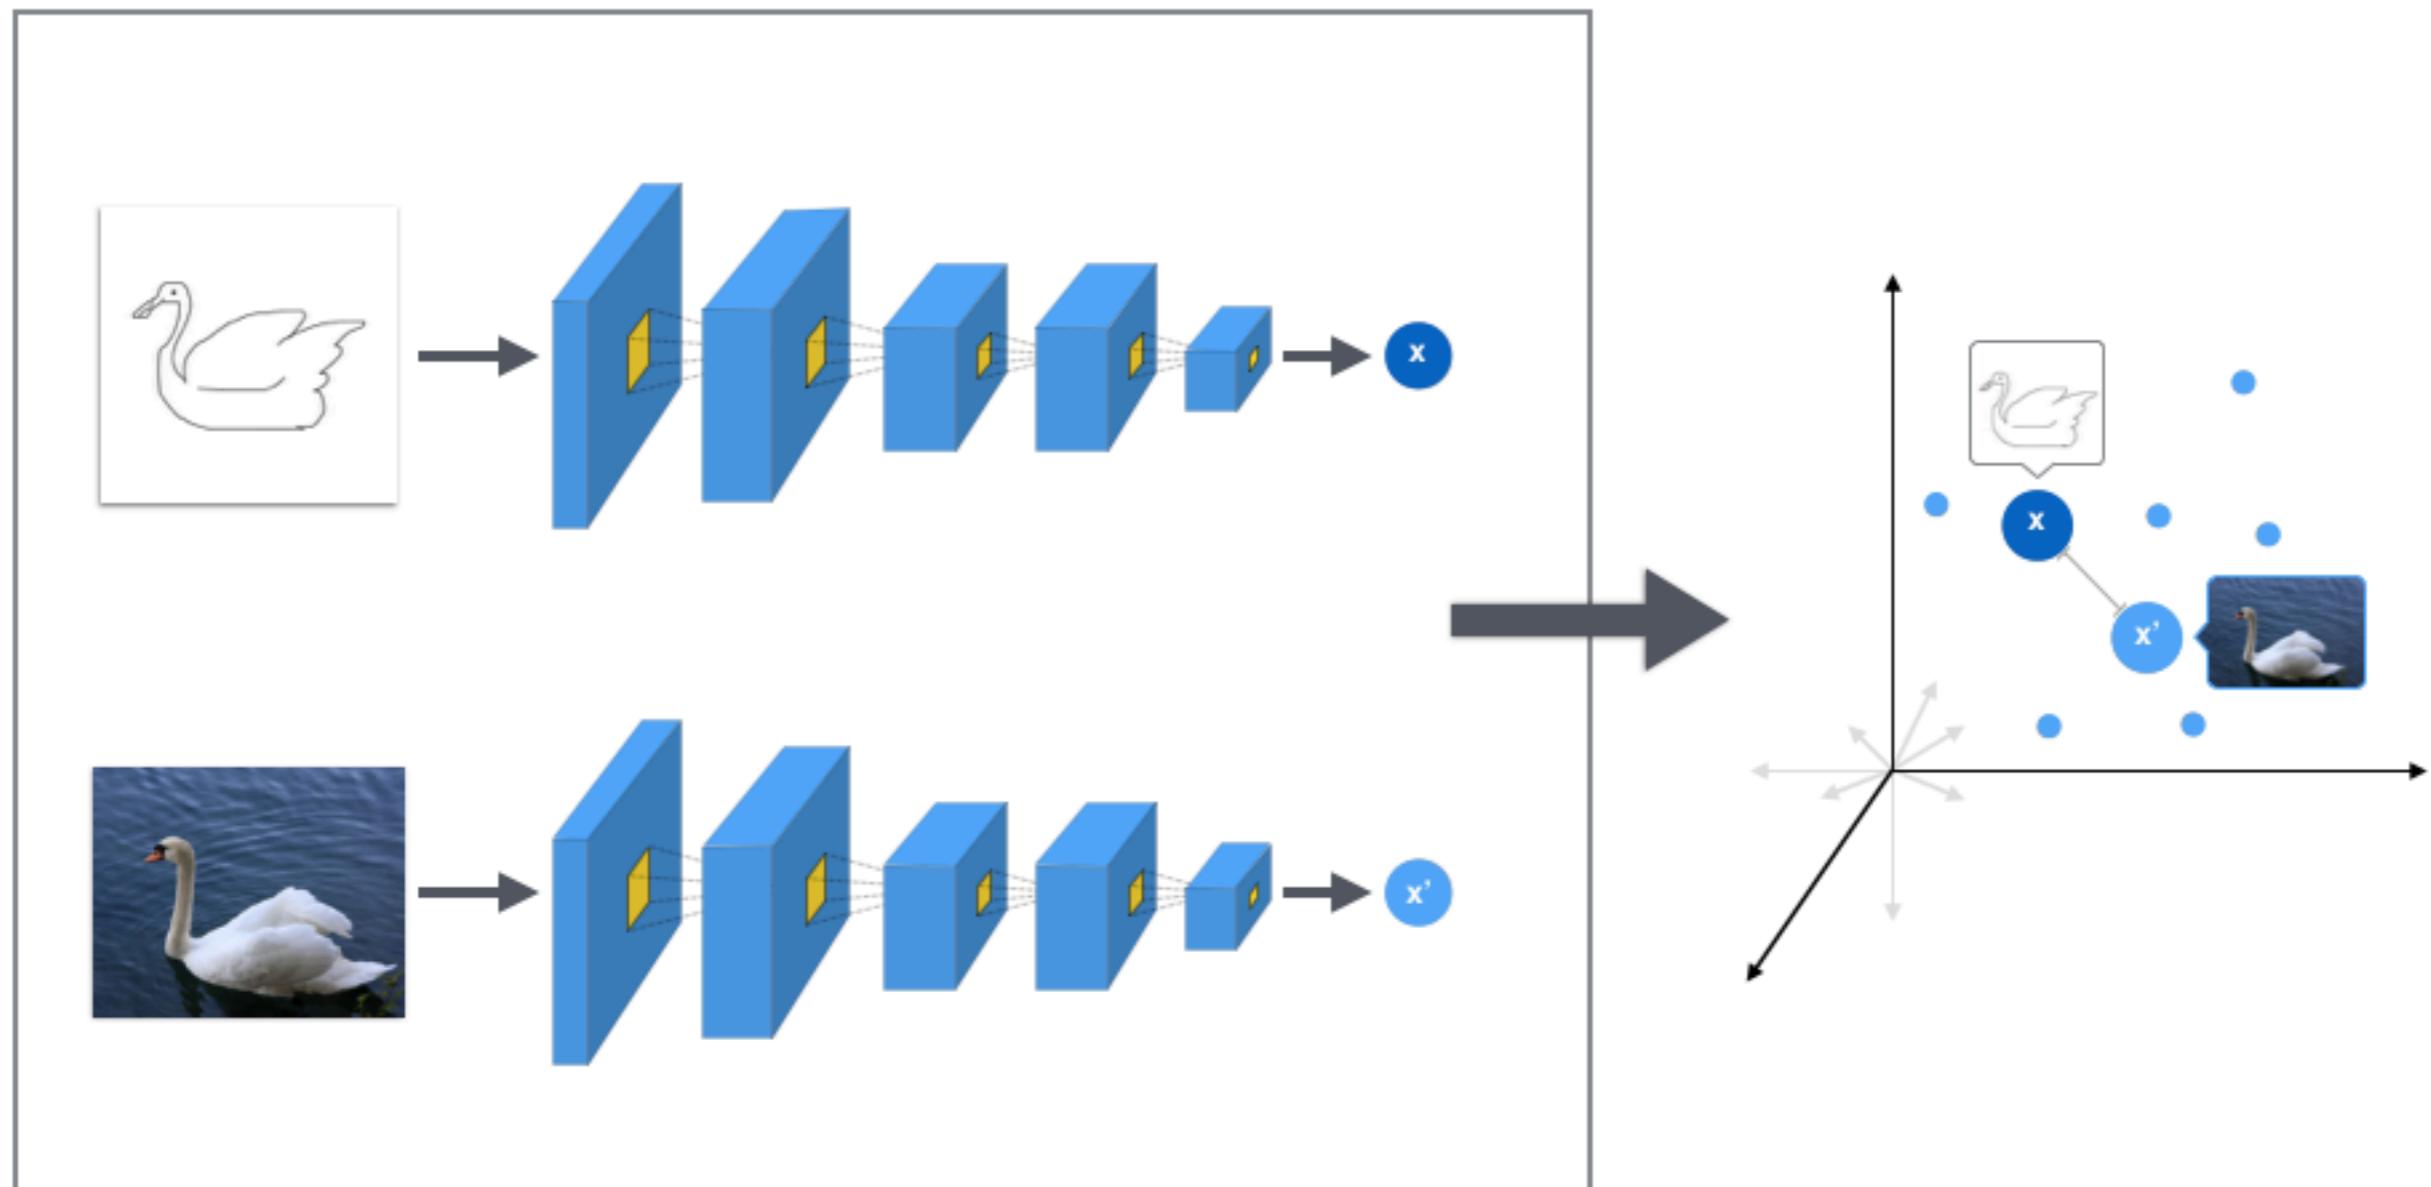
192

Aplicações e Diferentes Formulações

**Multi-stream Nets: Siamesas
de Trigêmeas**

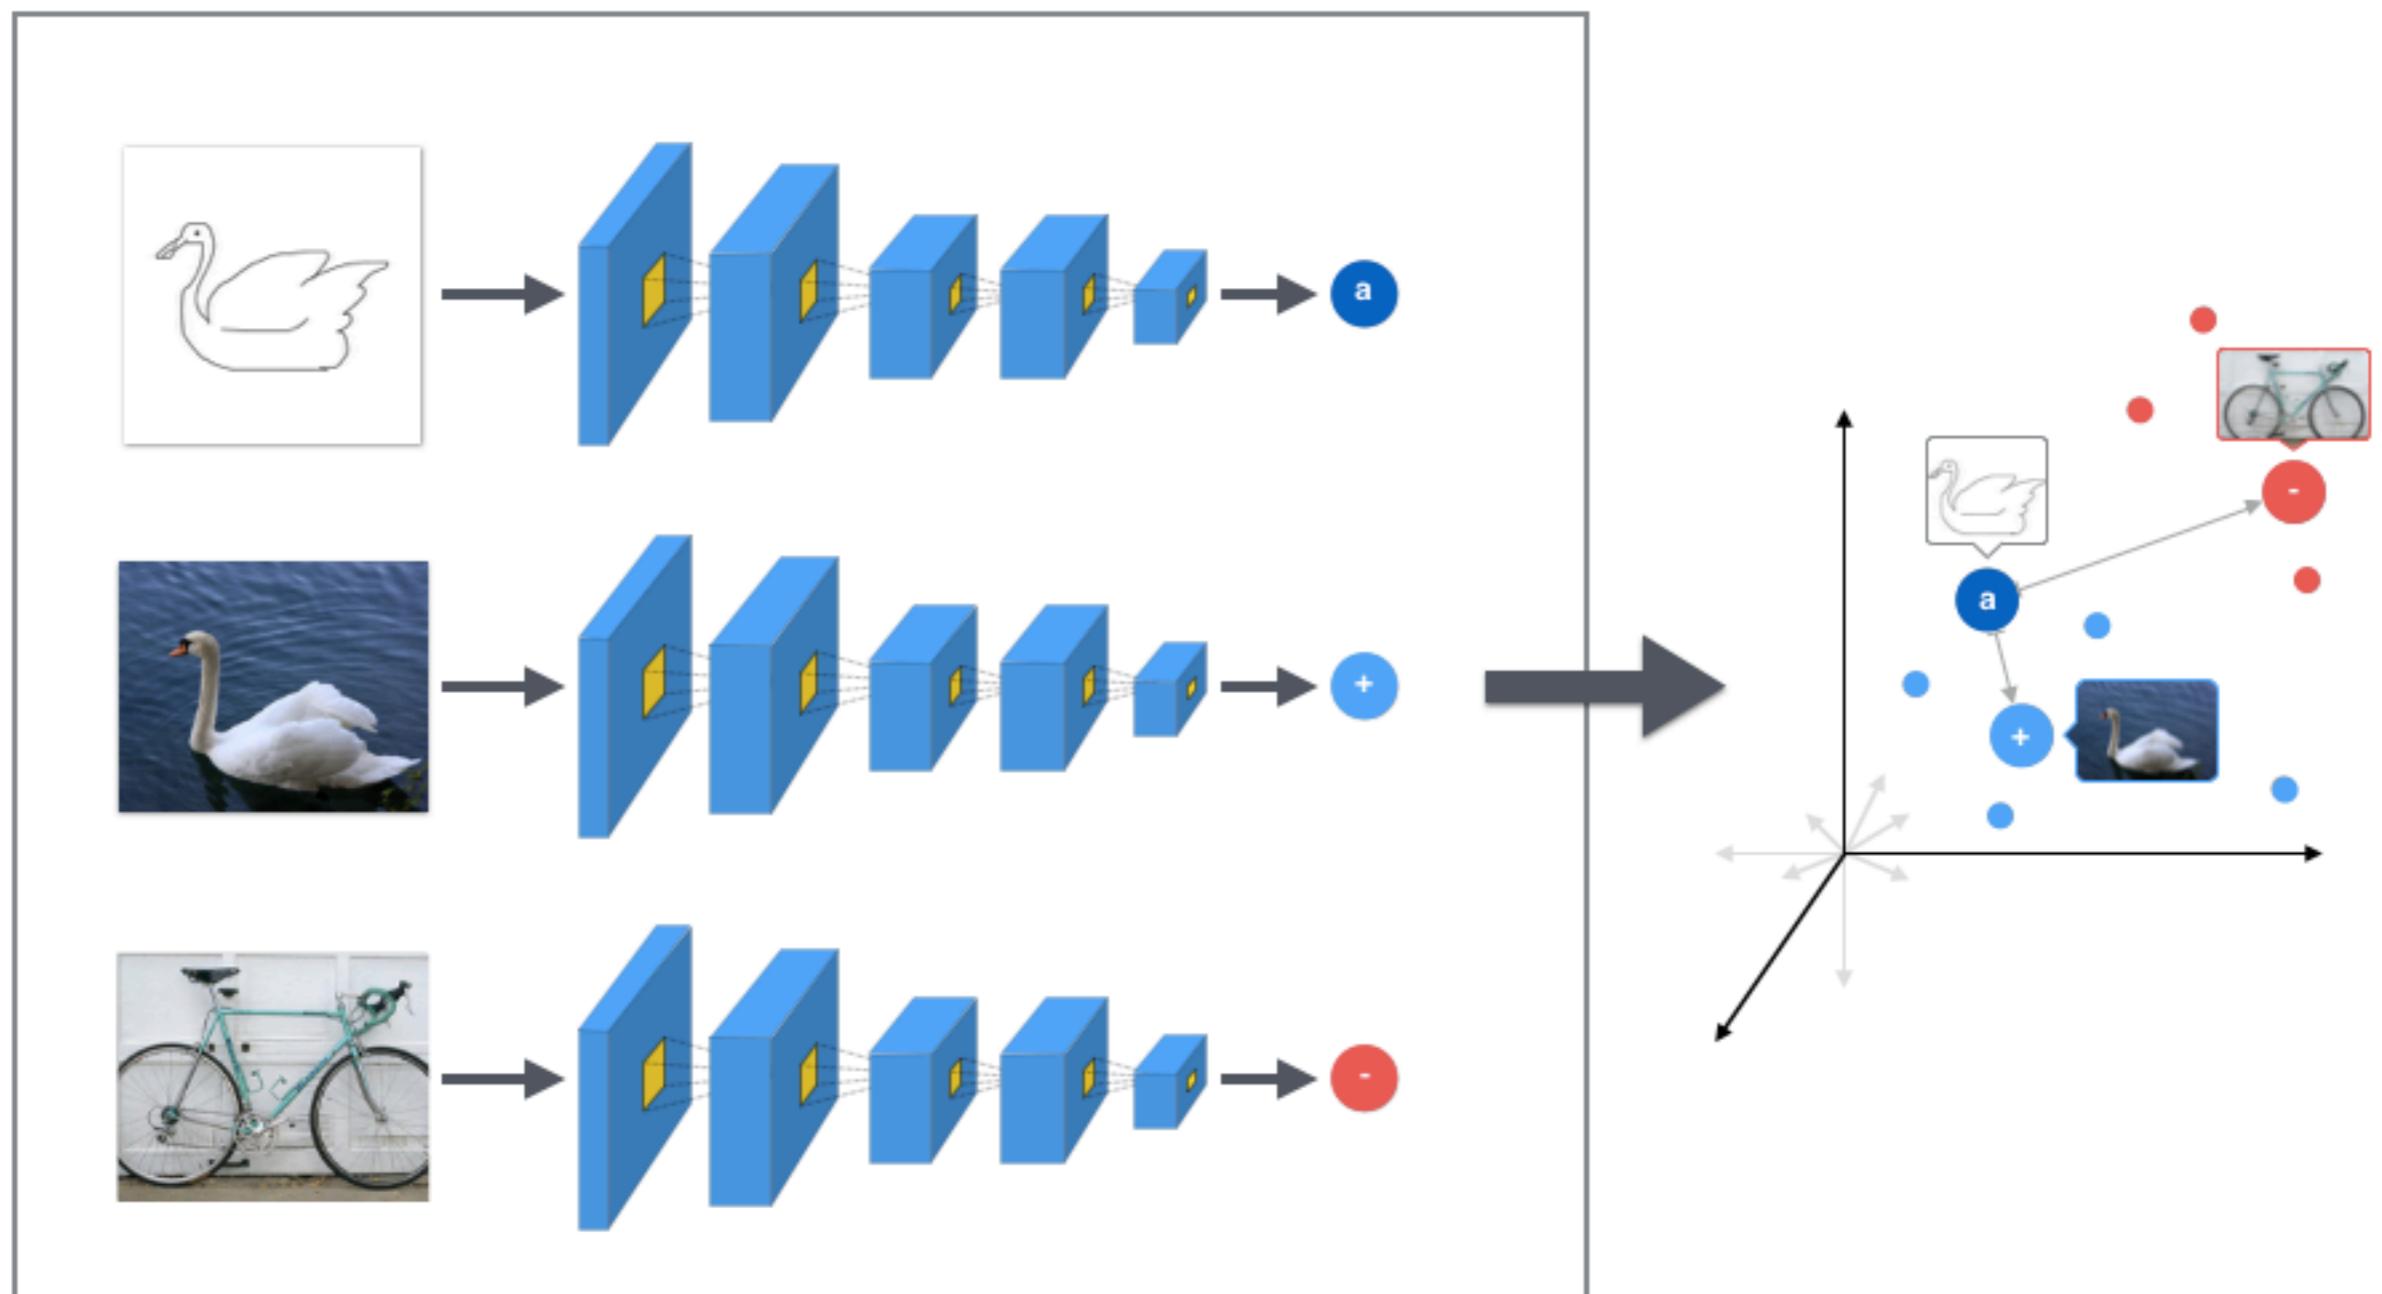
Redes Siamesas

Aplicações

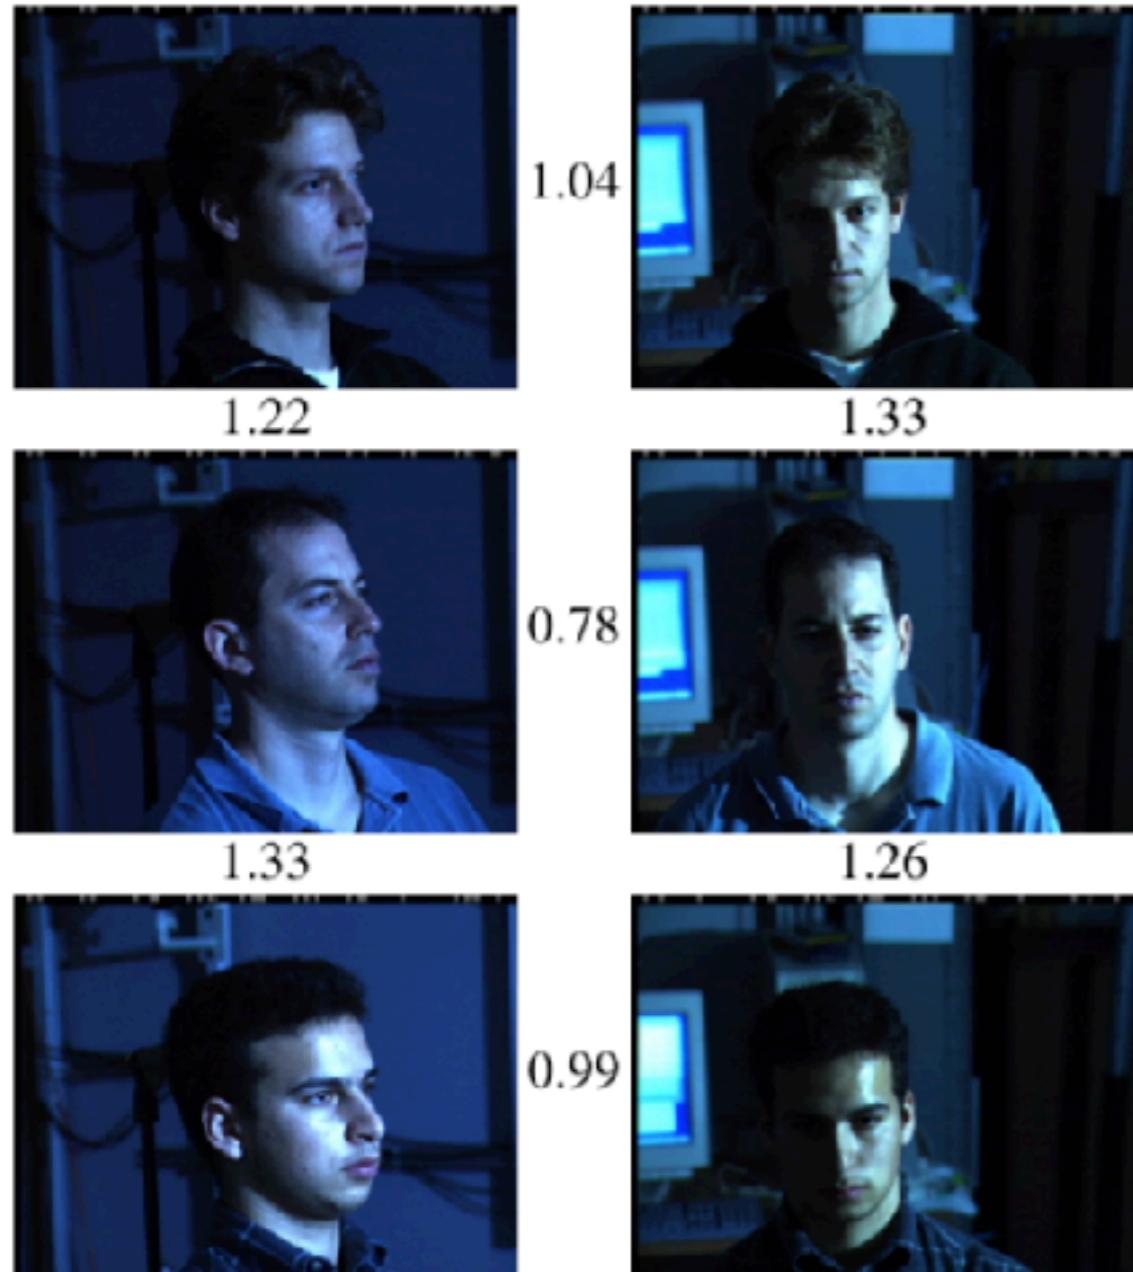


Redes Triplets

Aplicações



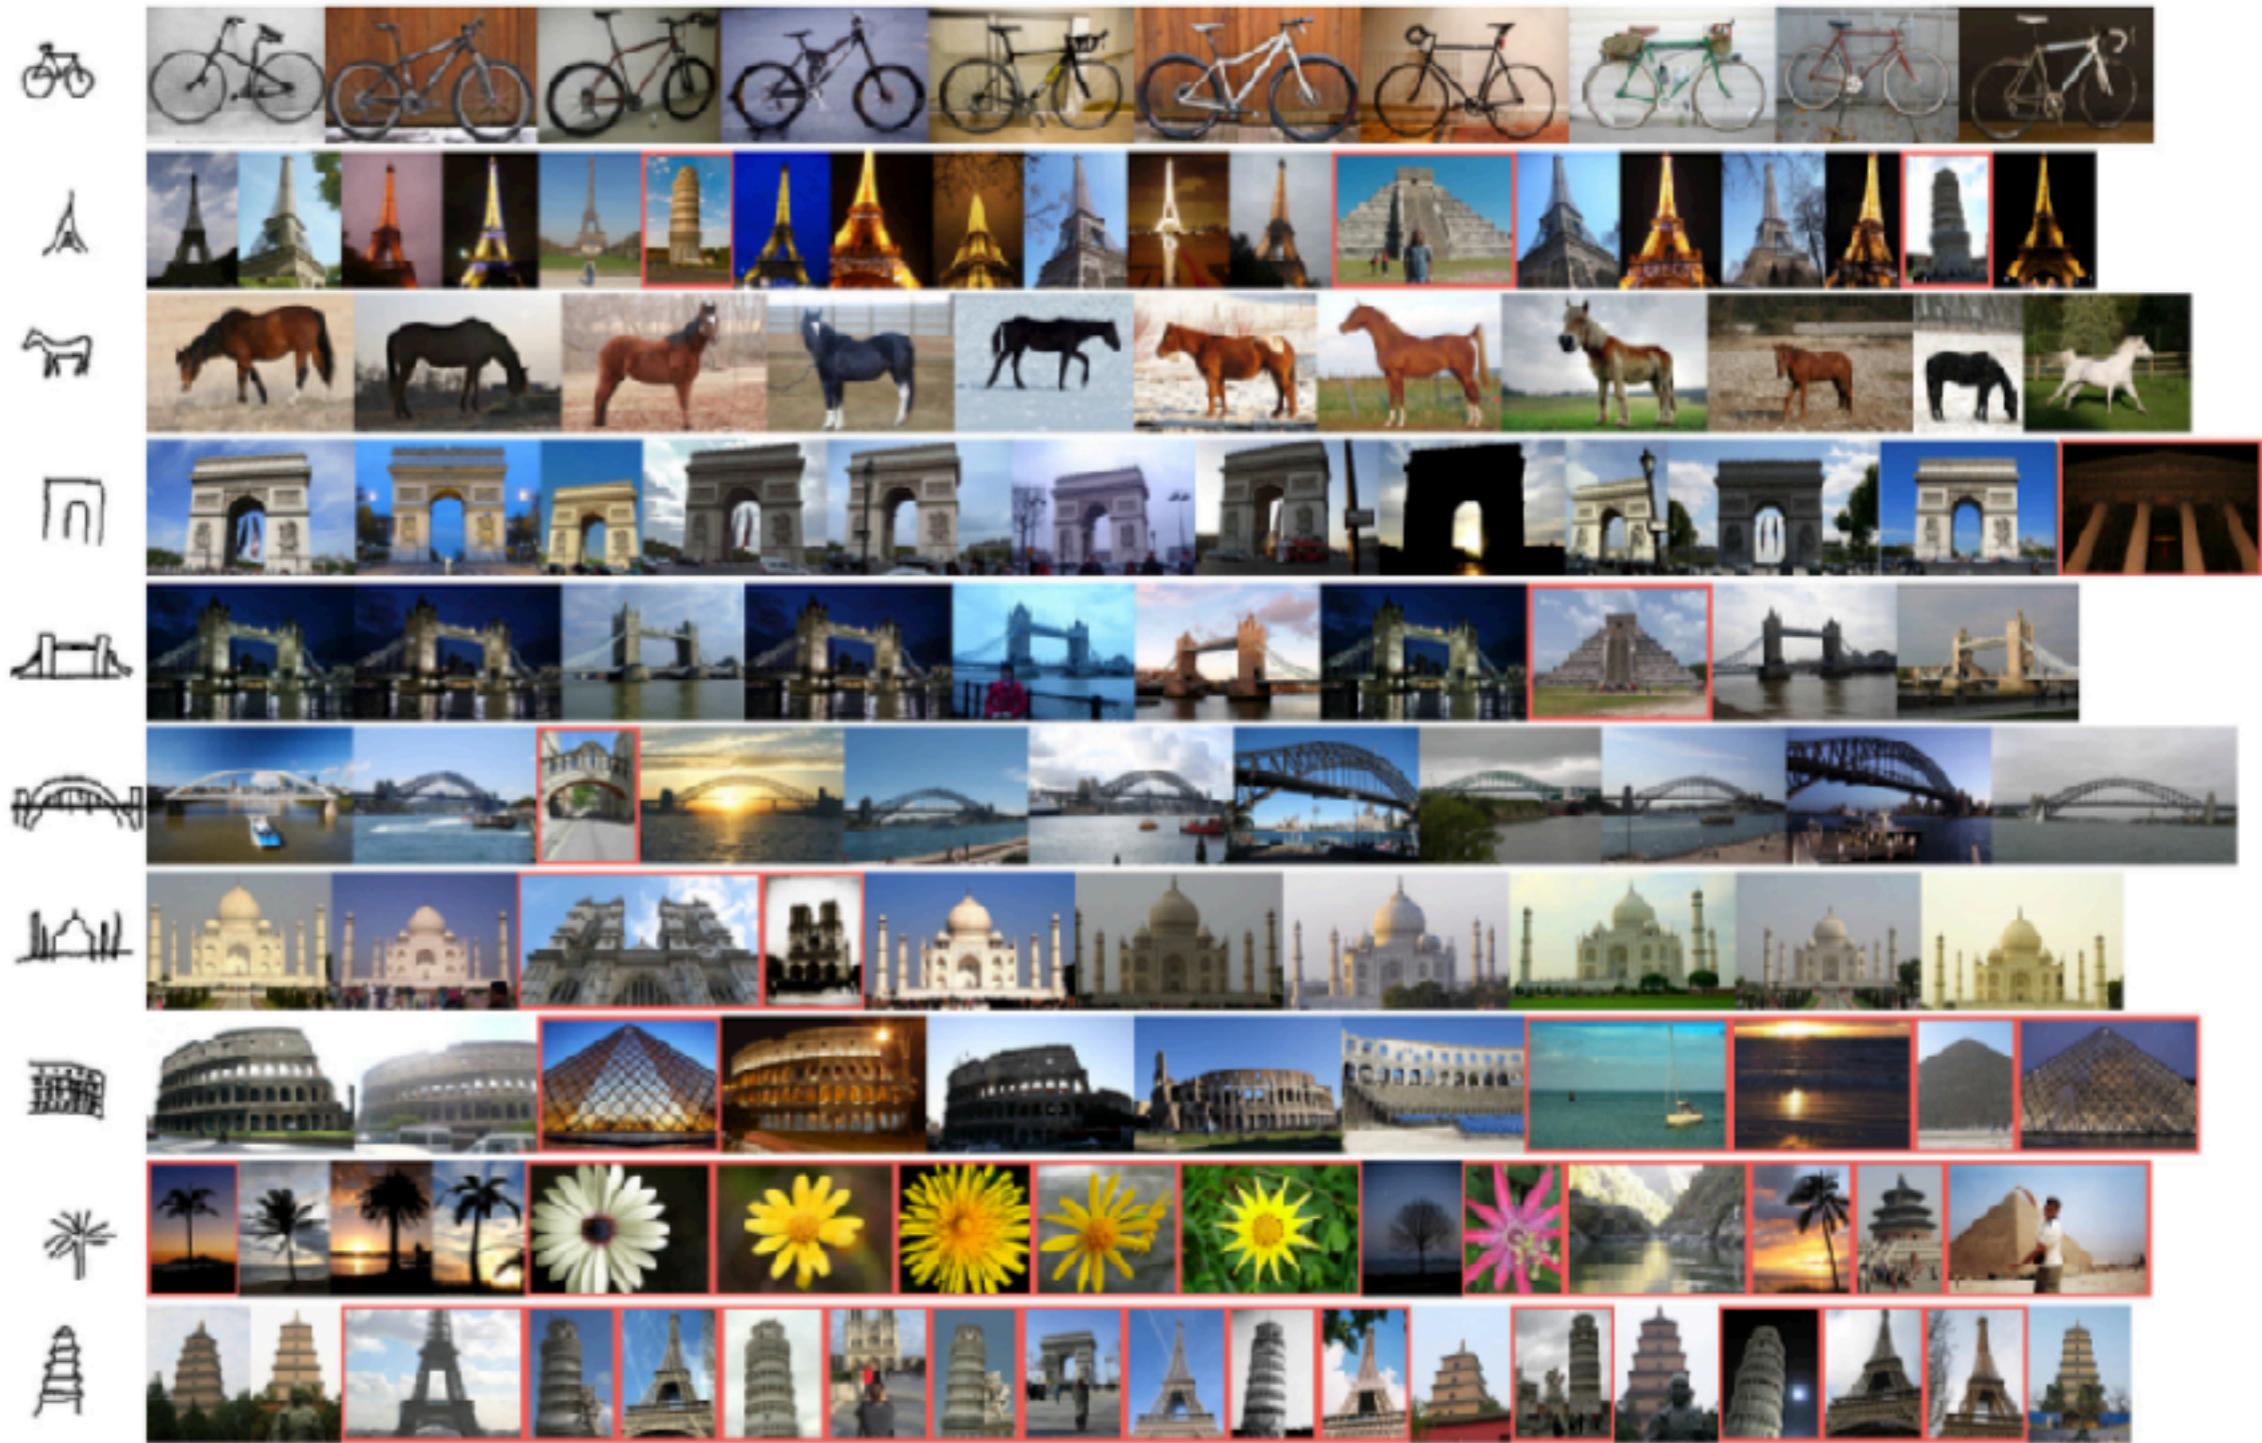
FaceNet, com Triplet Networks



Schroff et al, FaceNet: A Unified Embedding for Face Recognition and Clustering, 2017

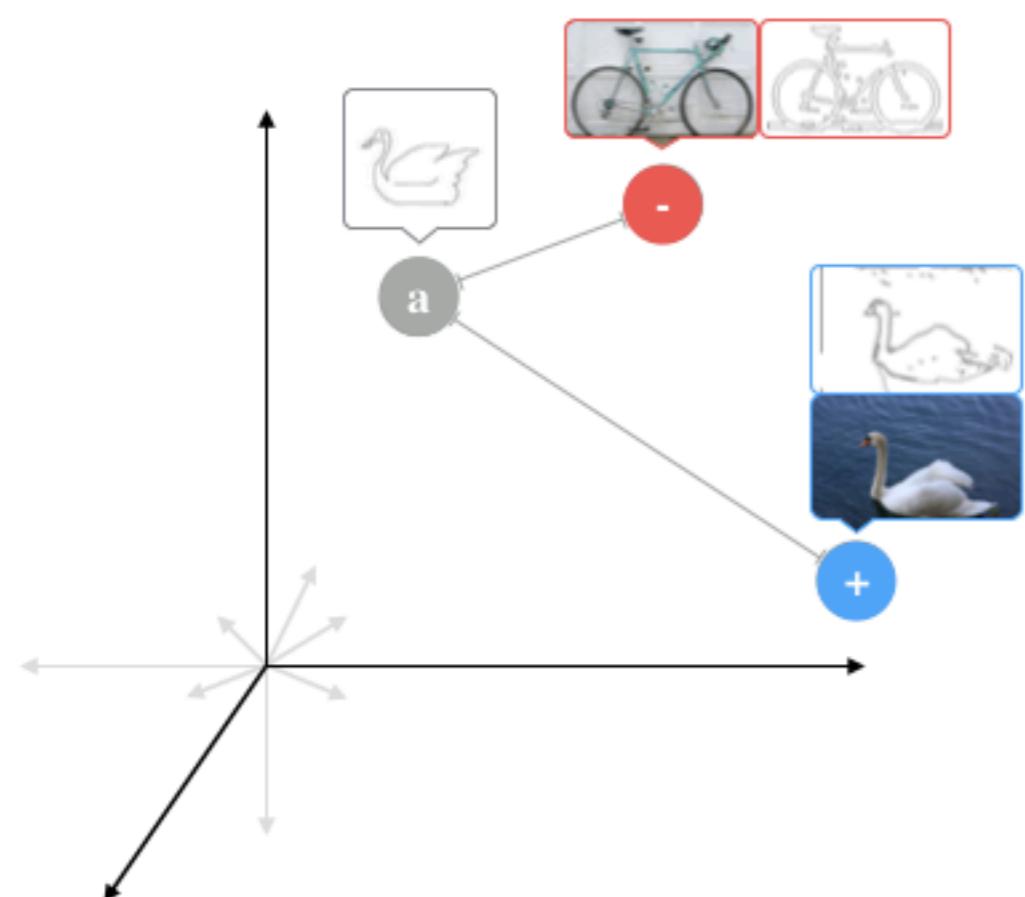
Sketch-based Image Retrieval

Aplicações

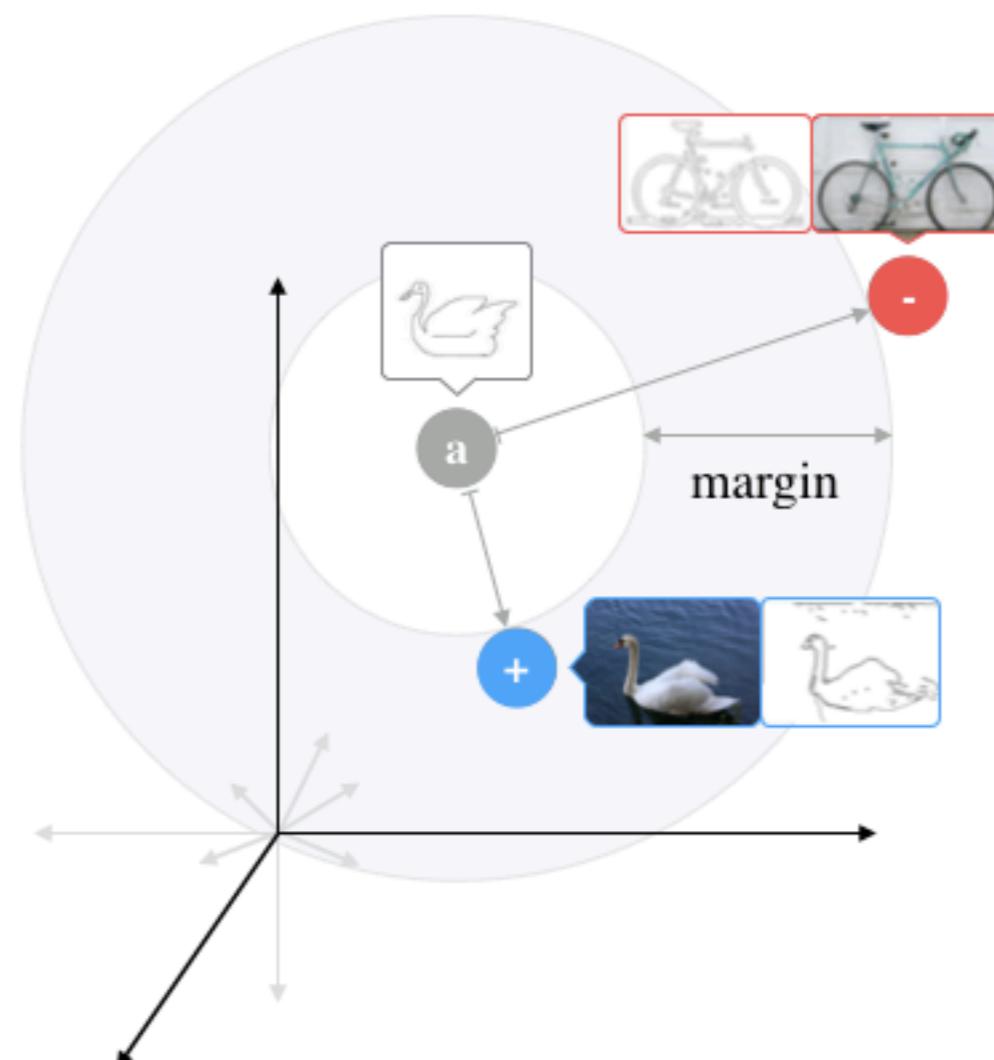


Triplet em Sketch-based Image Retr.

Aplicações



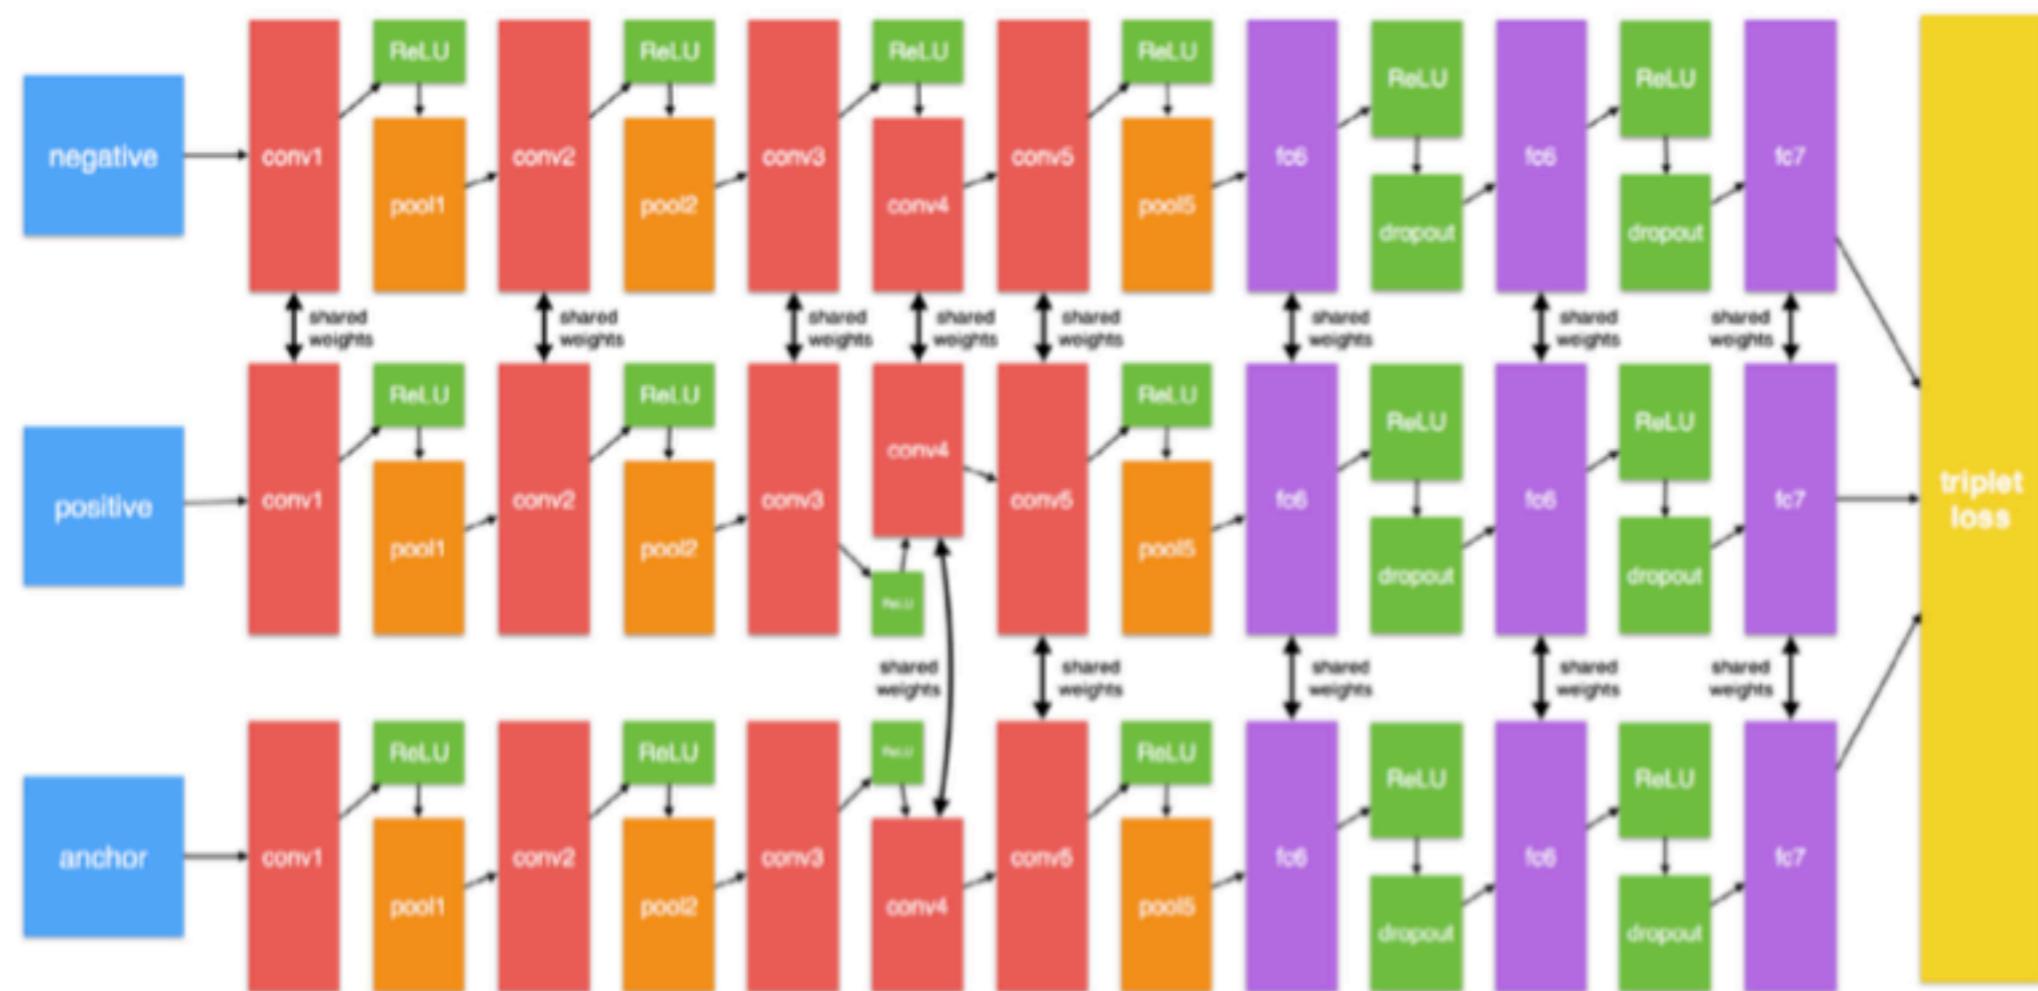
Antes do Treinamento



Depois do Treinamento

Sketch-based Image Retrieval

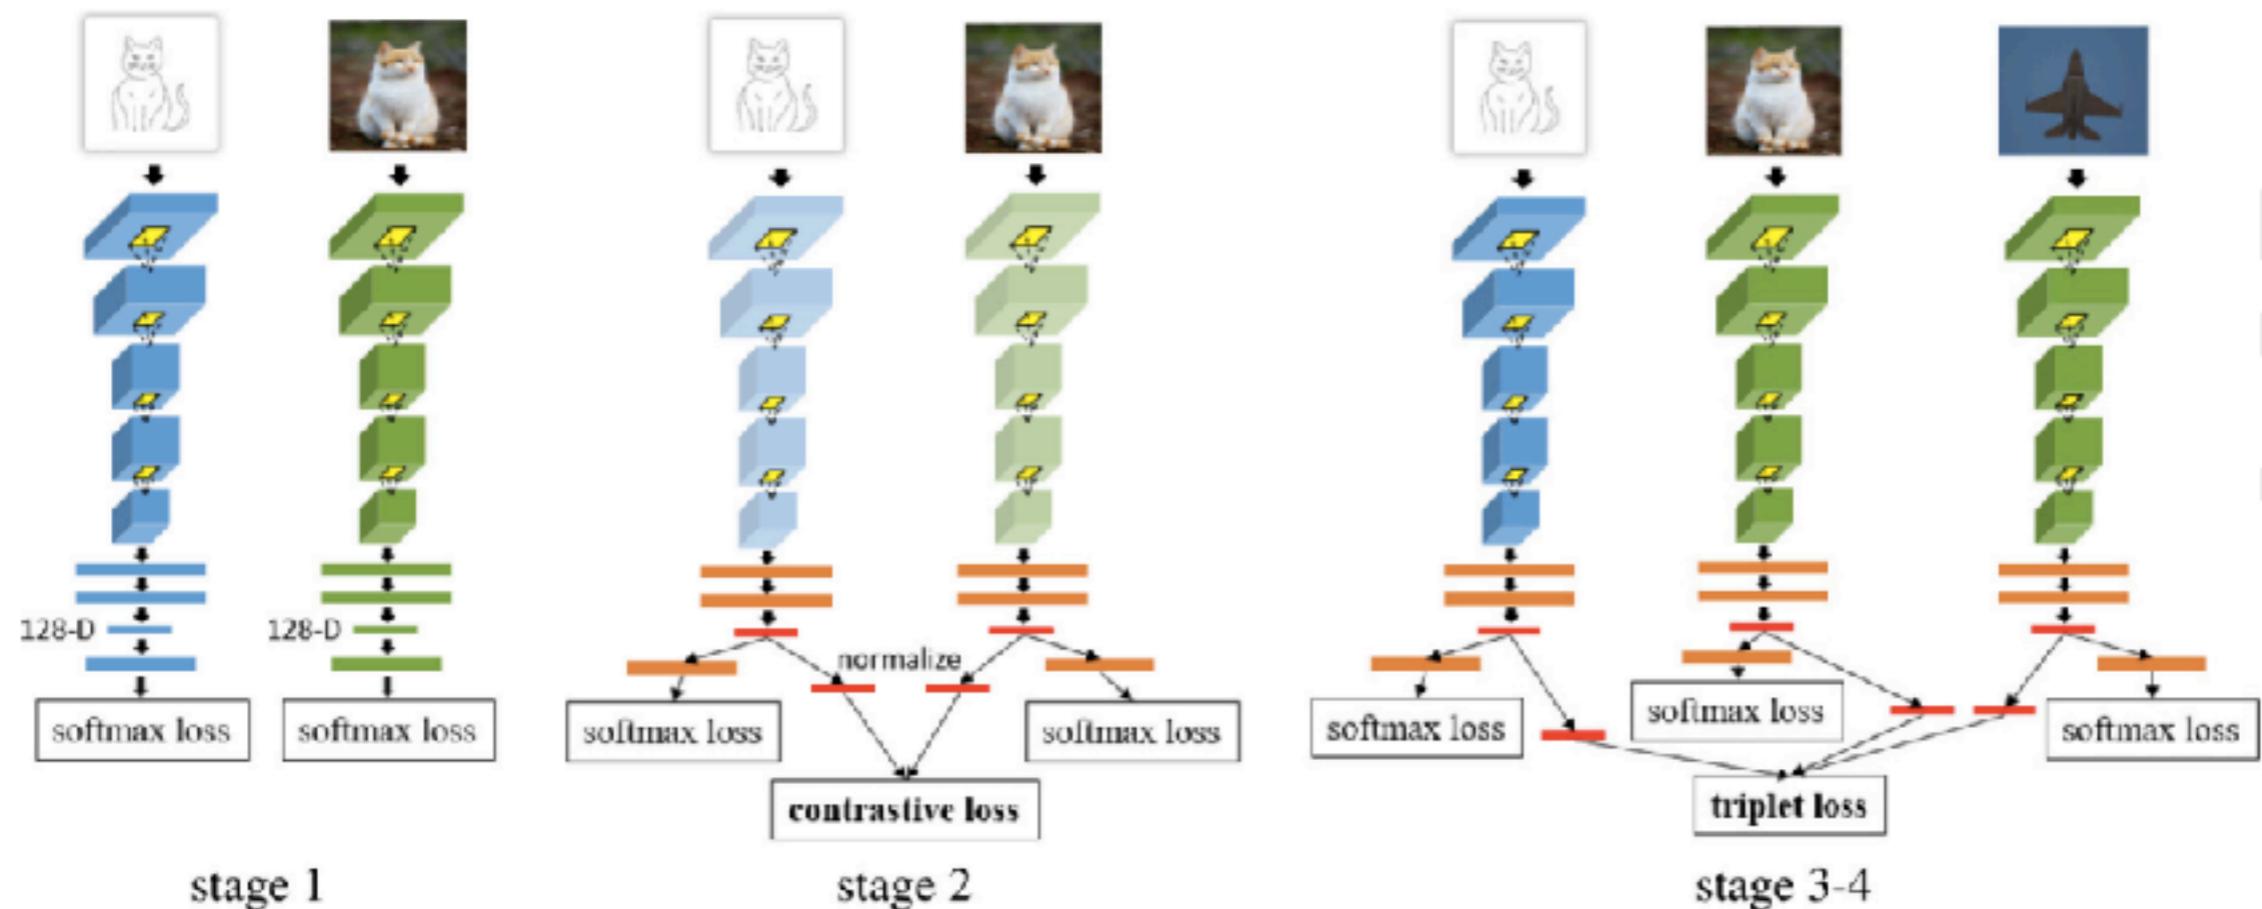
Aplicações



Bui et al, Compact descriptors for sketch-based image retrieval using a triplet loss convolutional neural network, CVIU 2017

Sketch-based Image Retrieval

Aplicações



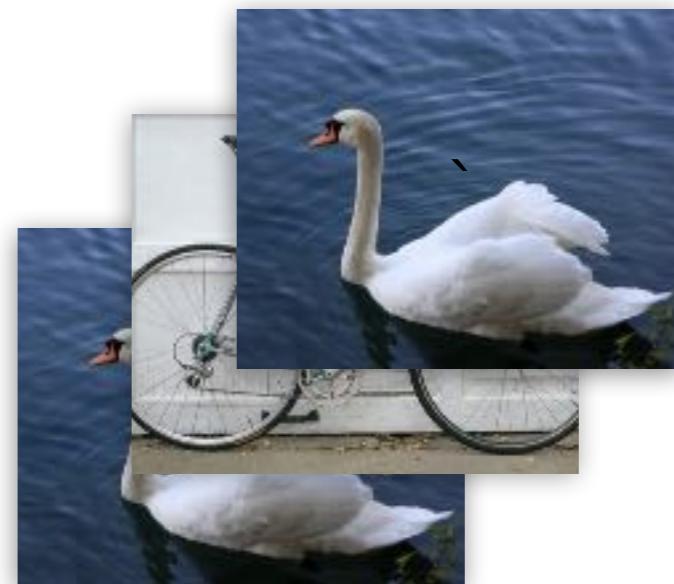
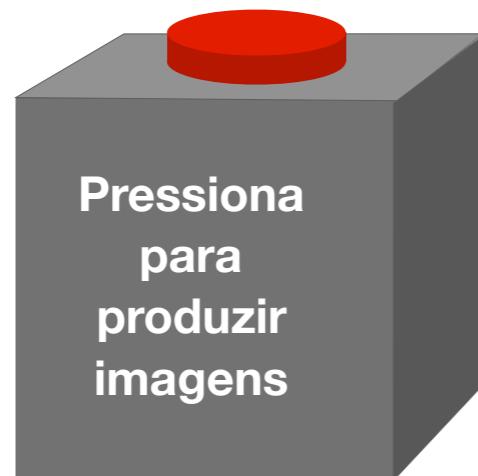
Bui et al, Sketching out the details: Sketch-based image retrieval using convolutional neural networks with multi-stage regression, Computers&Graphics 2018

Aplicações e Diferentes Formulações

**GANs: Generative
Adversarial Networks**

Generative Adversarial Networks

Aplicações



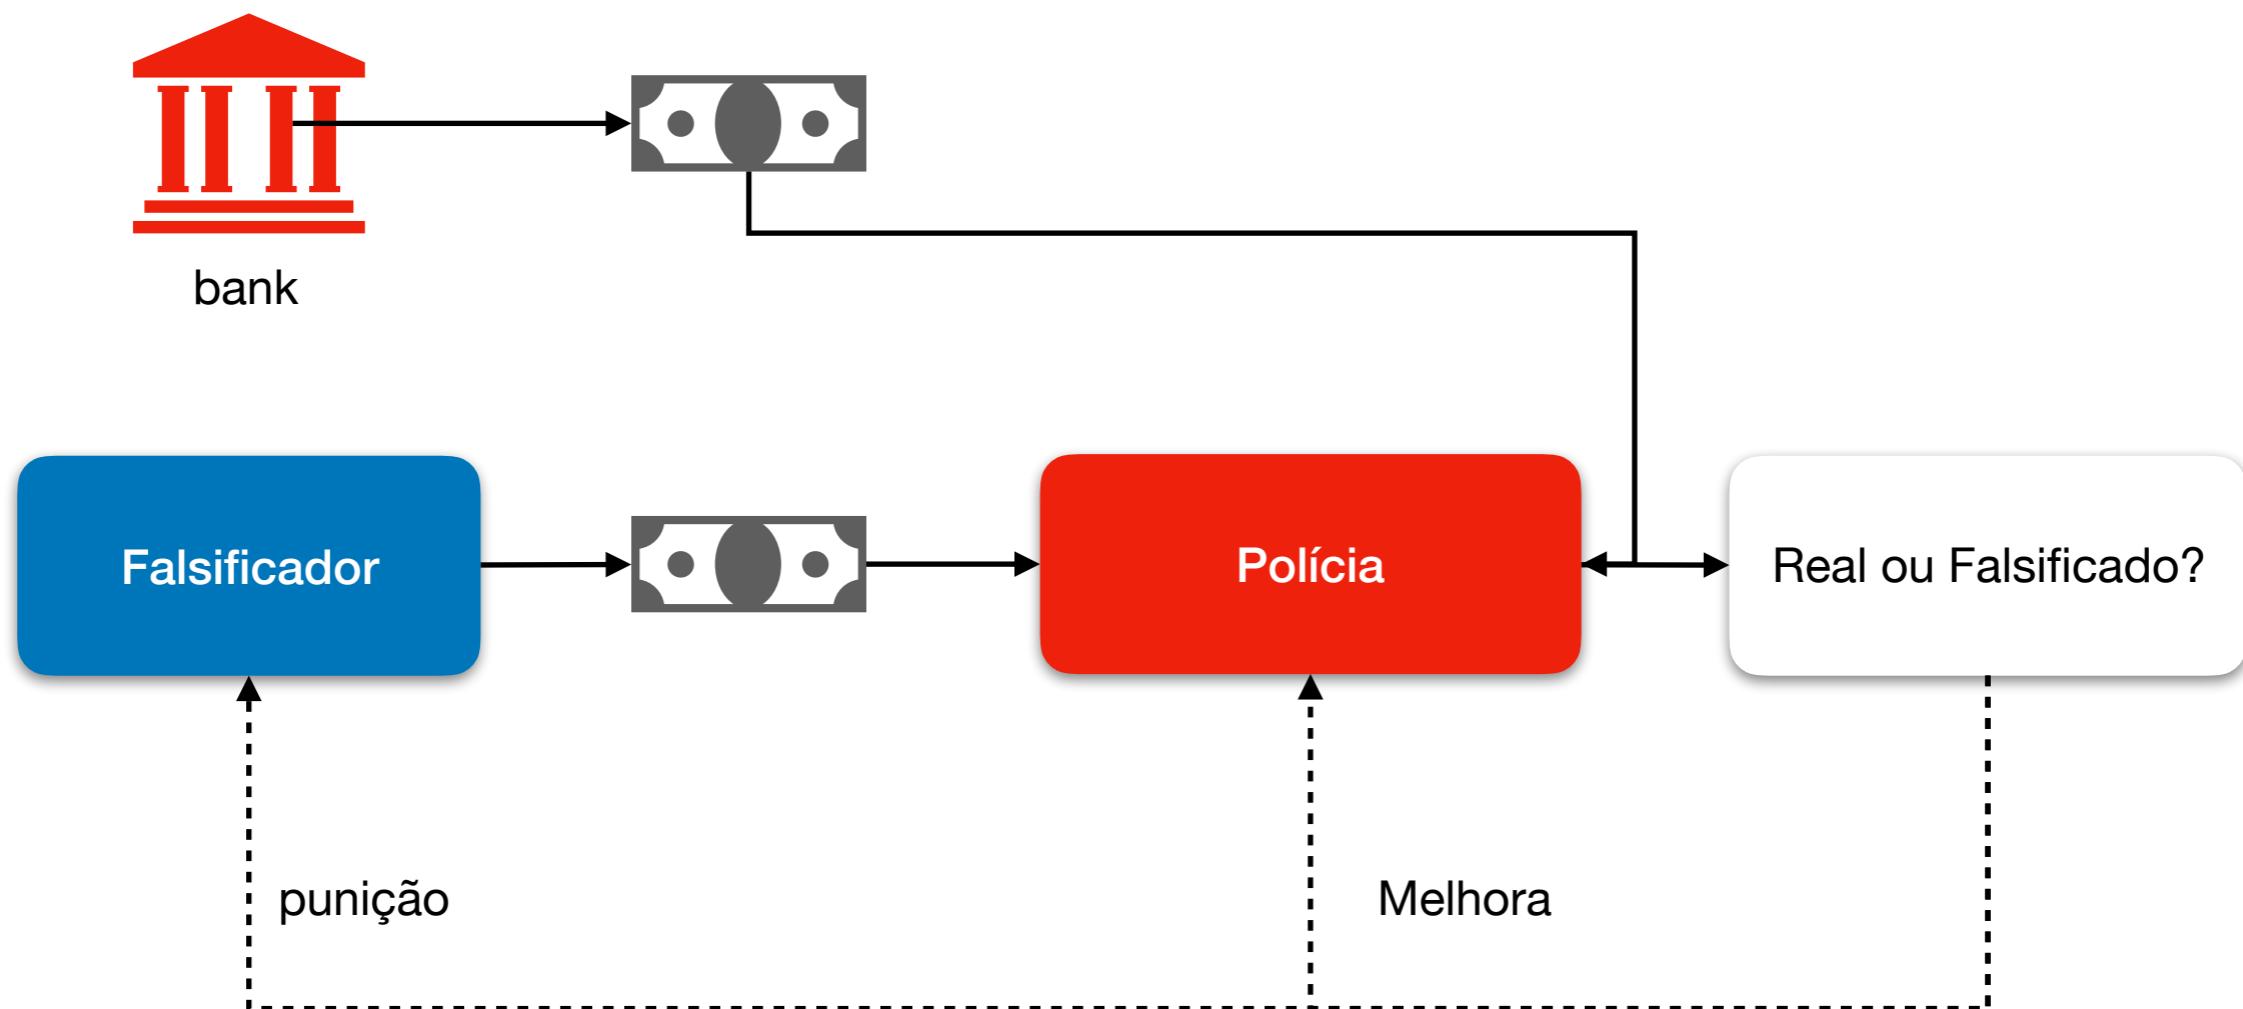
Black Box

Exemplos

GANs são modelos geradores, capazes de gerar imagens a partir de uma entrada qualquer

Generative Adversarial Networks

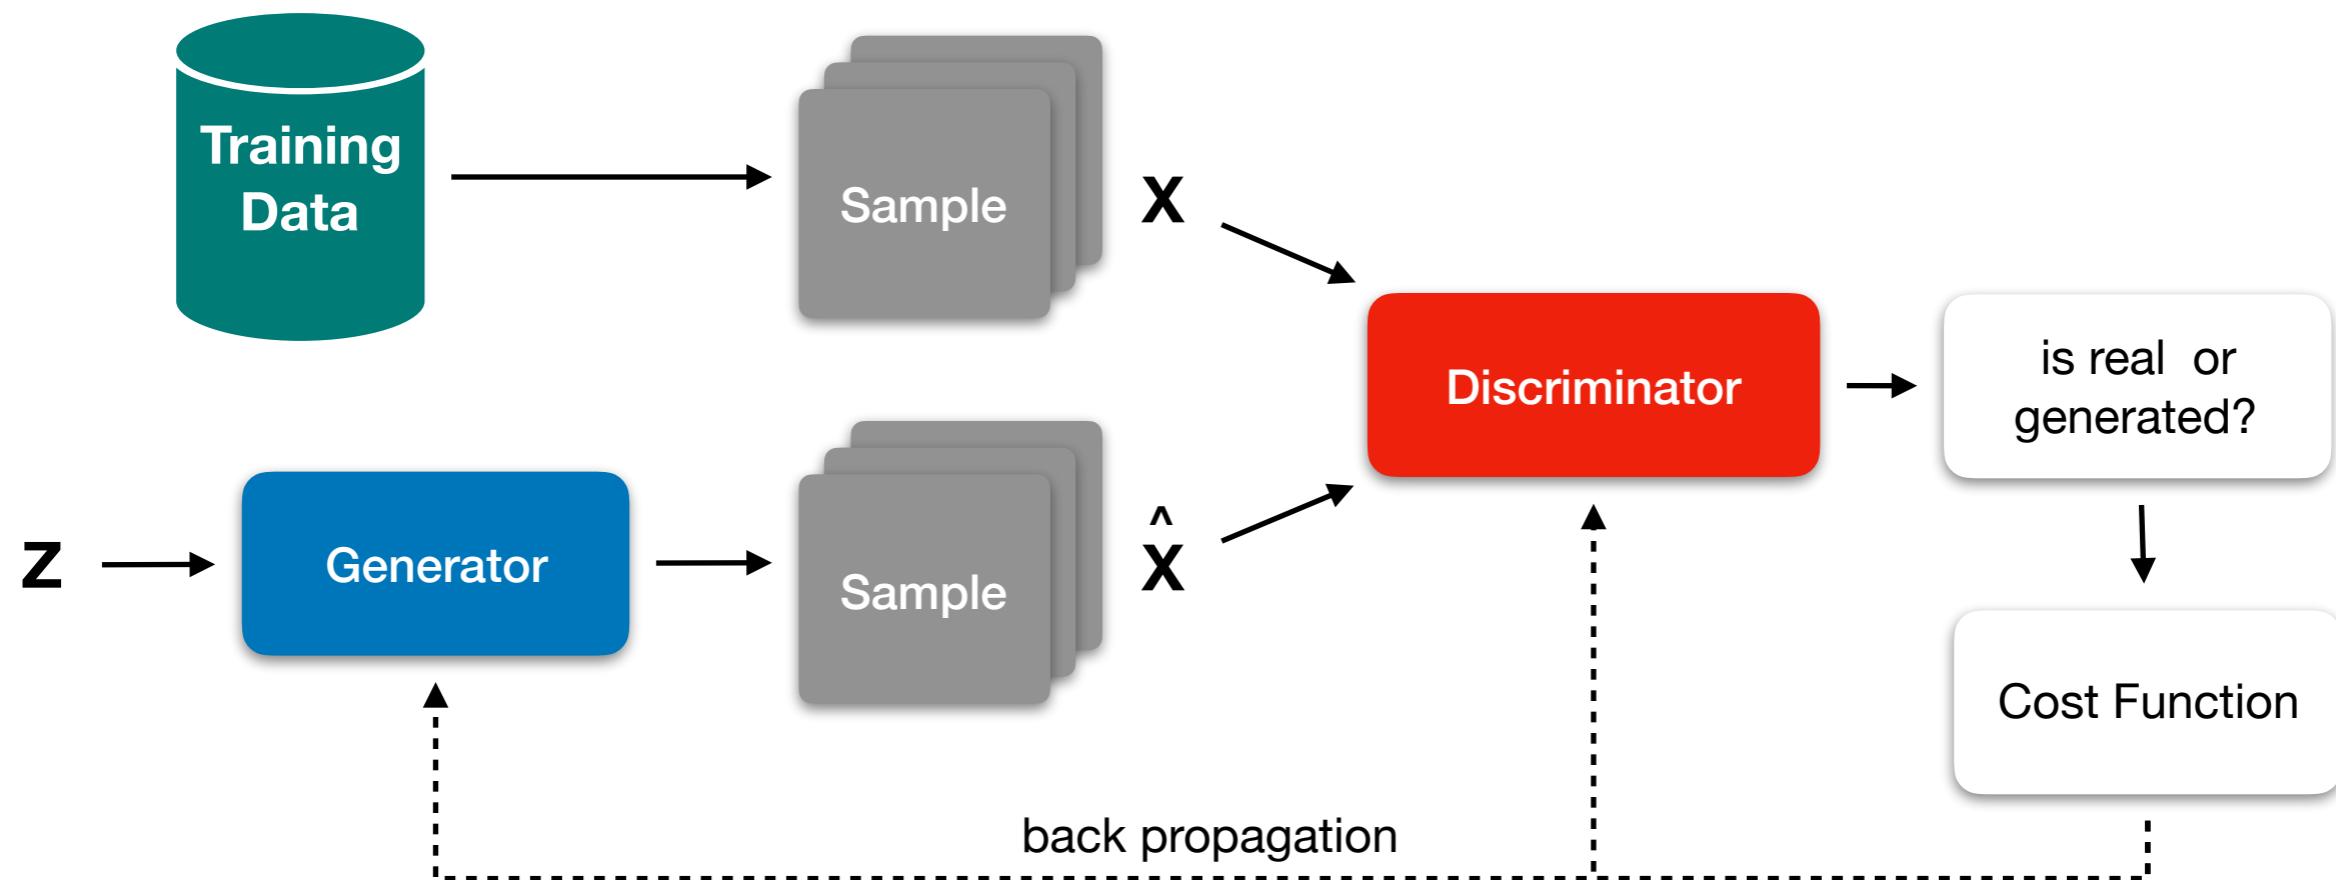
Aplicações



A polícia está sempre melhorando sua técnica de detecção de falsificação ao mesmo tempo em que os falsificadores melhoram sua habilidade em falsificar

Generative Adversarial Networks

Aplicações

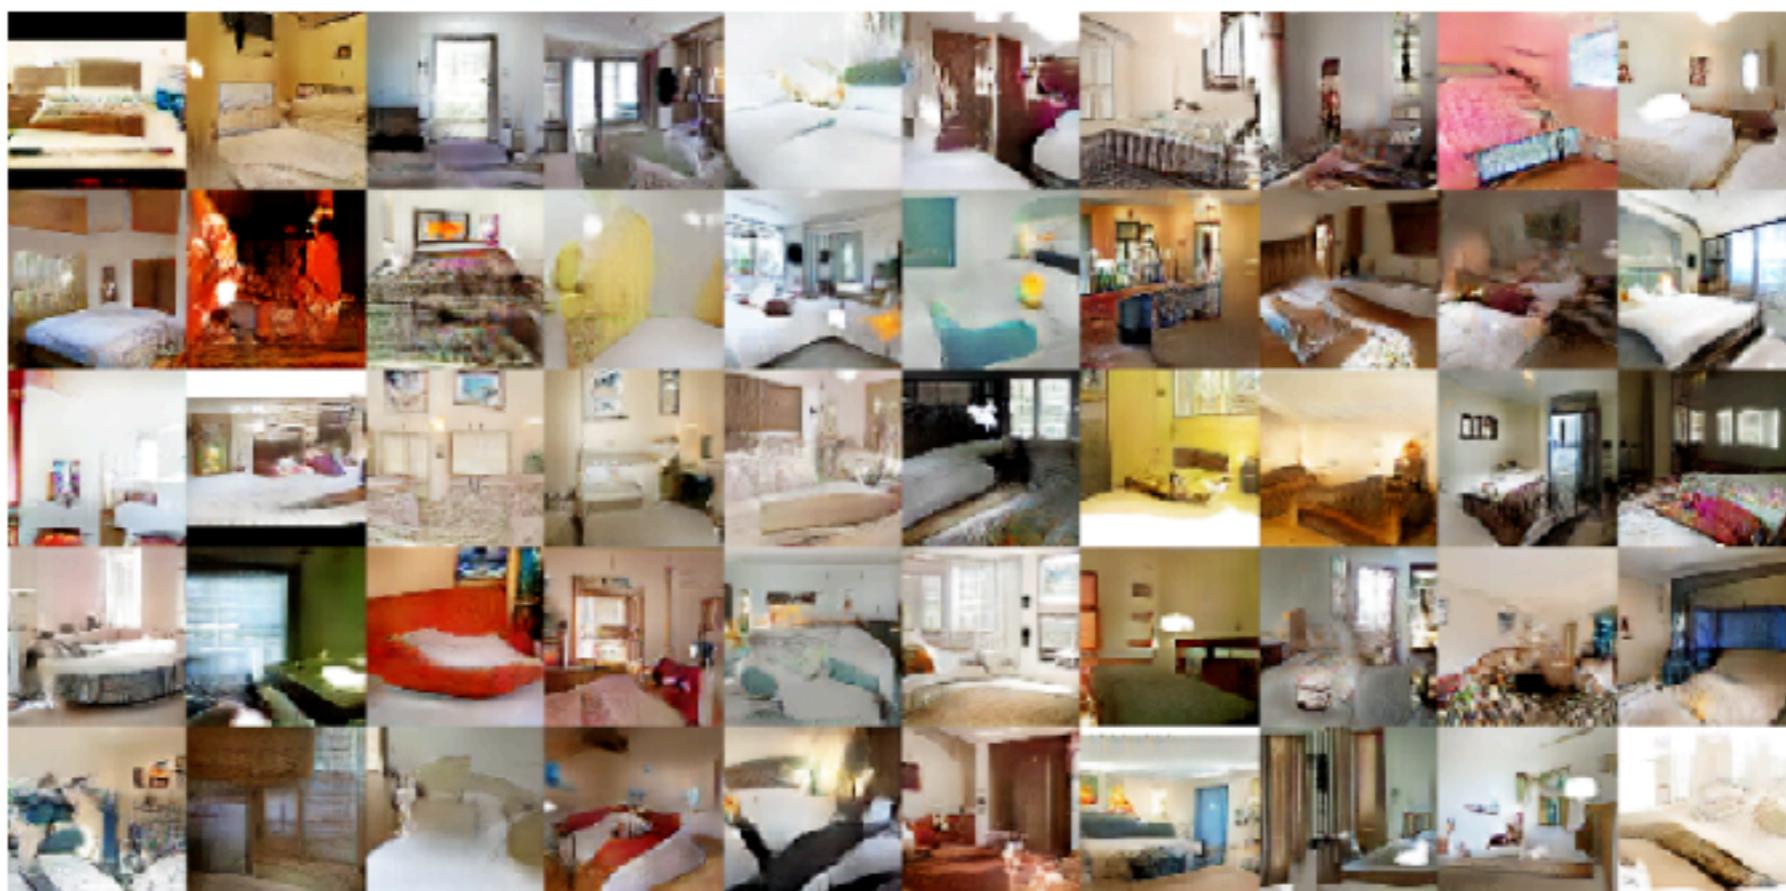


A cada batch, exemplos são retirados da base de dados e do conjunto de variáveis aleatórias z e após uma passagem pelas redes, G e D são otimizados baseados em seus respectivos objetivos no jogo

DCGAN for Image Generation

Aplicações

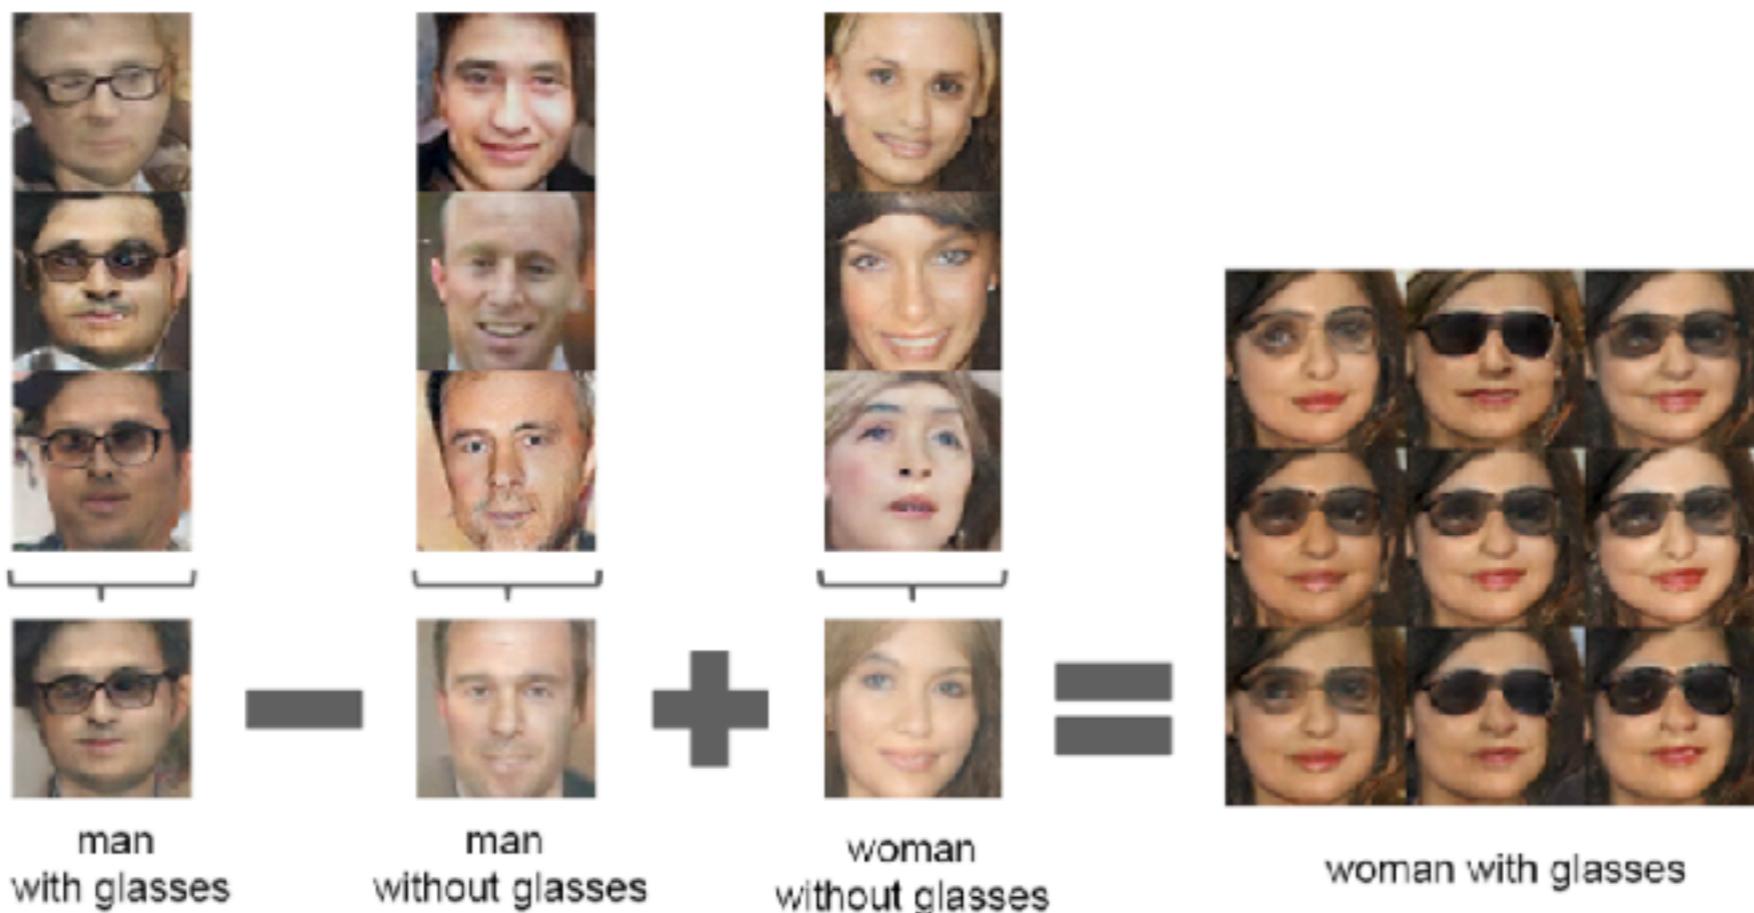
DCGAN trained for 5 epochs on LSUN Bedrooms



Alec Radford, Luke Metz and Soumith Chintala, “Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks”

Vector Space Arithmetic

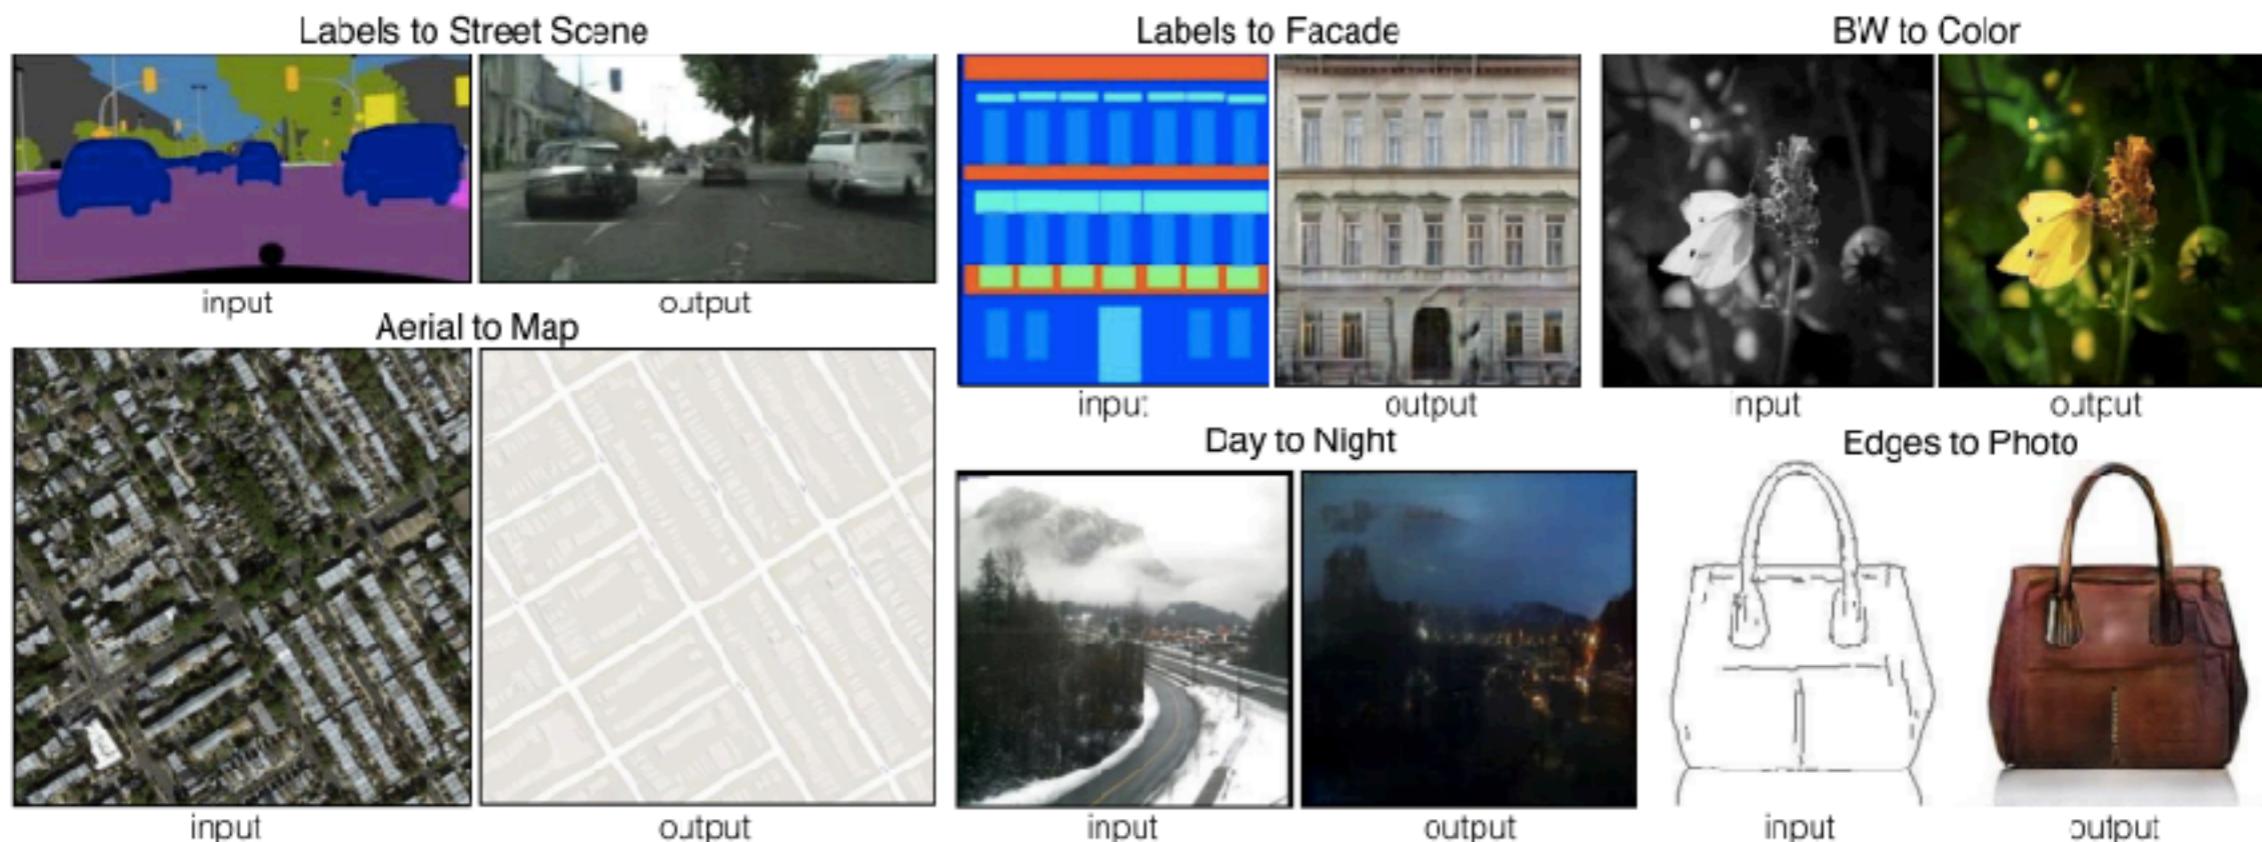
Aplicações



Alec Radford, Luke Metz and Soumith Chintala, “Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks”

Image to Image Translation

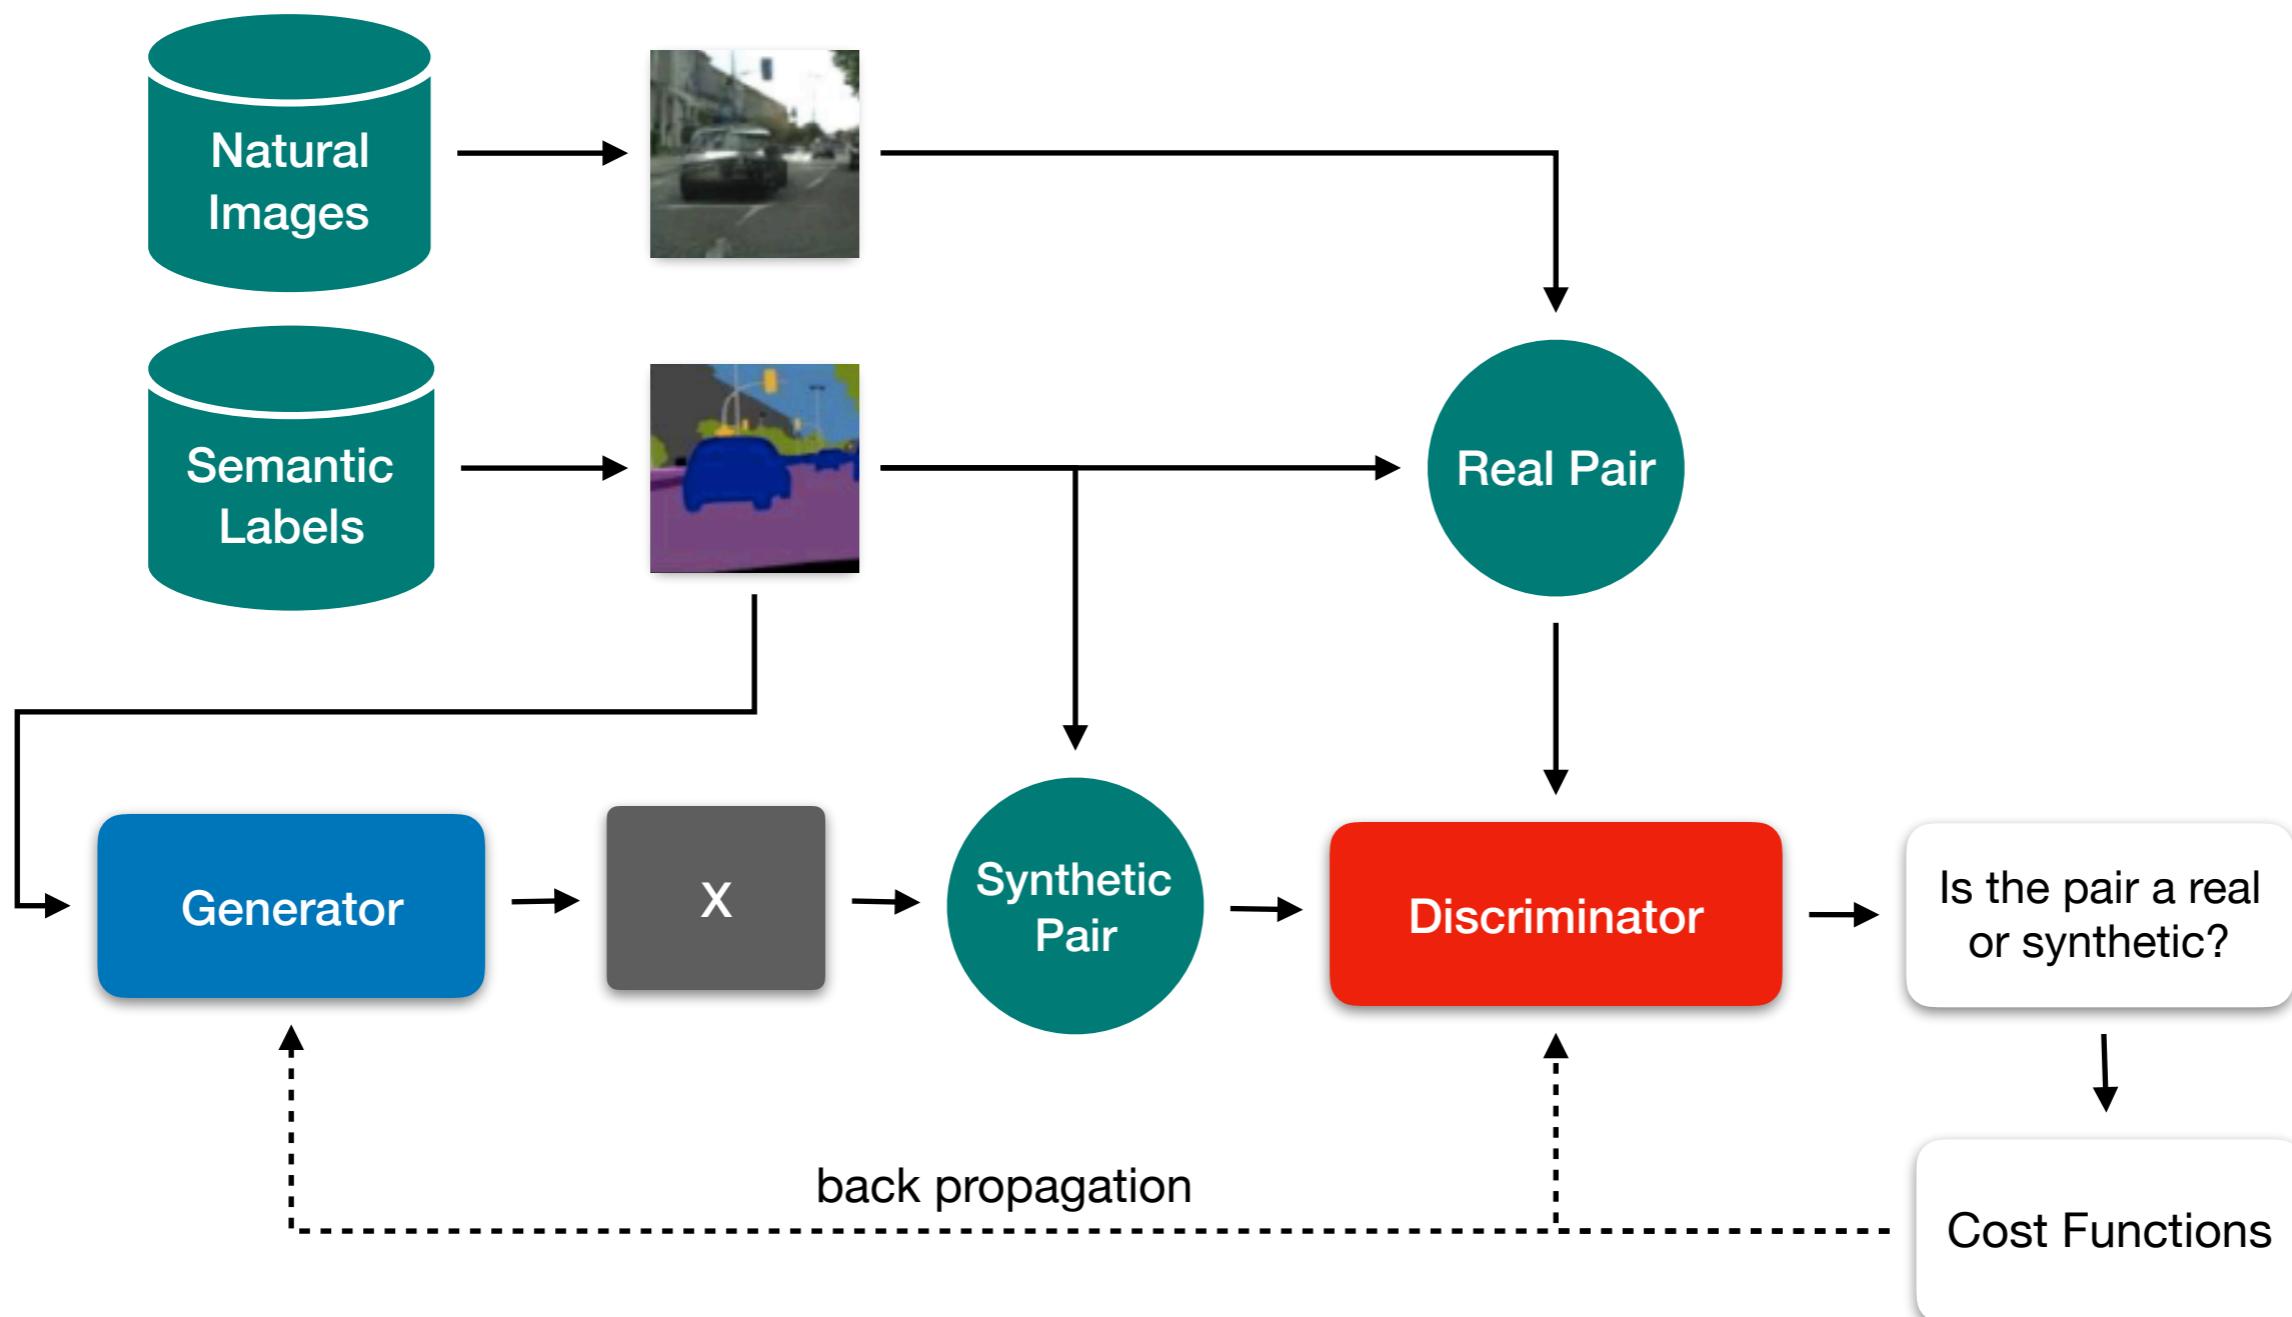
Aplicações



Phillip Isola, Jun-Yan Zhu, Tinghui Zhou and Alexei A. Efros, “Image-to-Image Translation with Conditional Adversarial Networks”

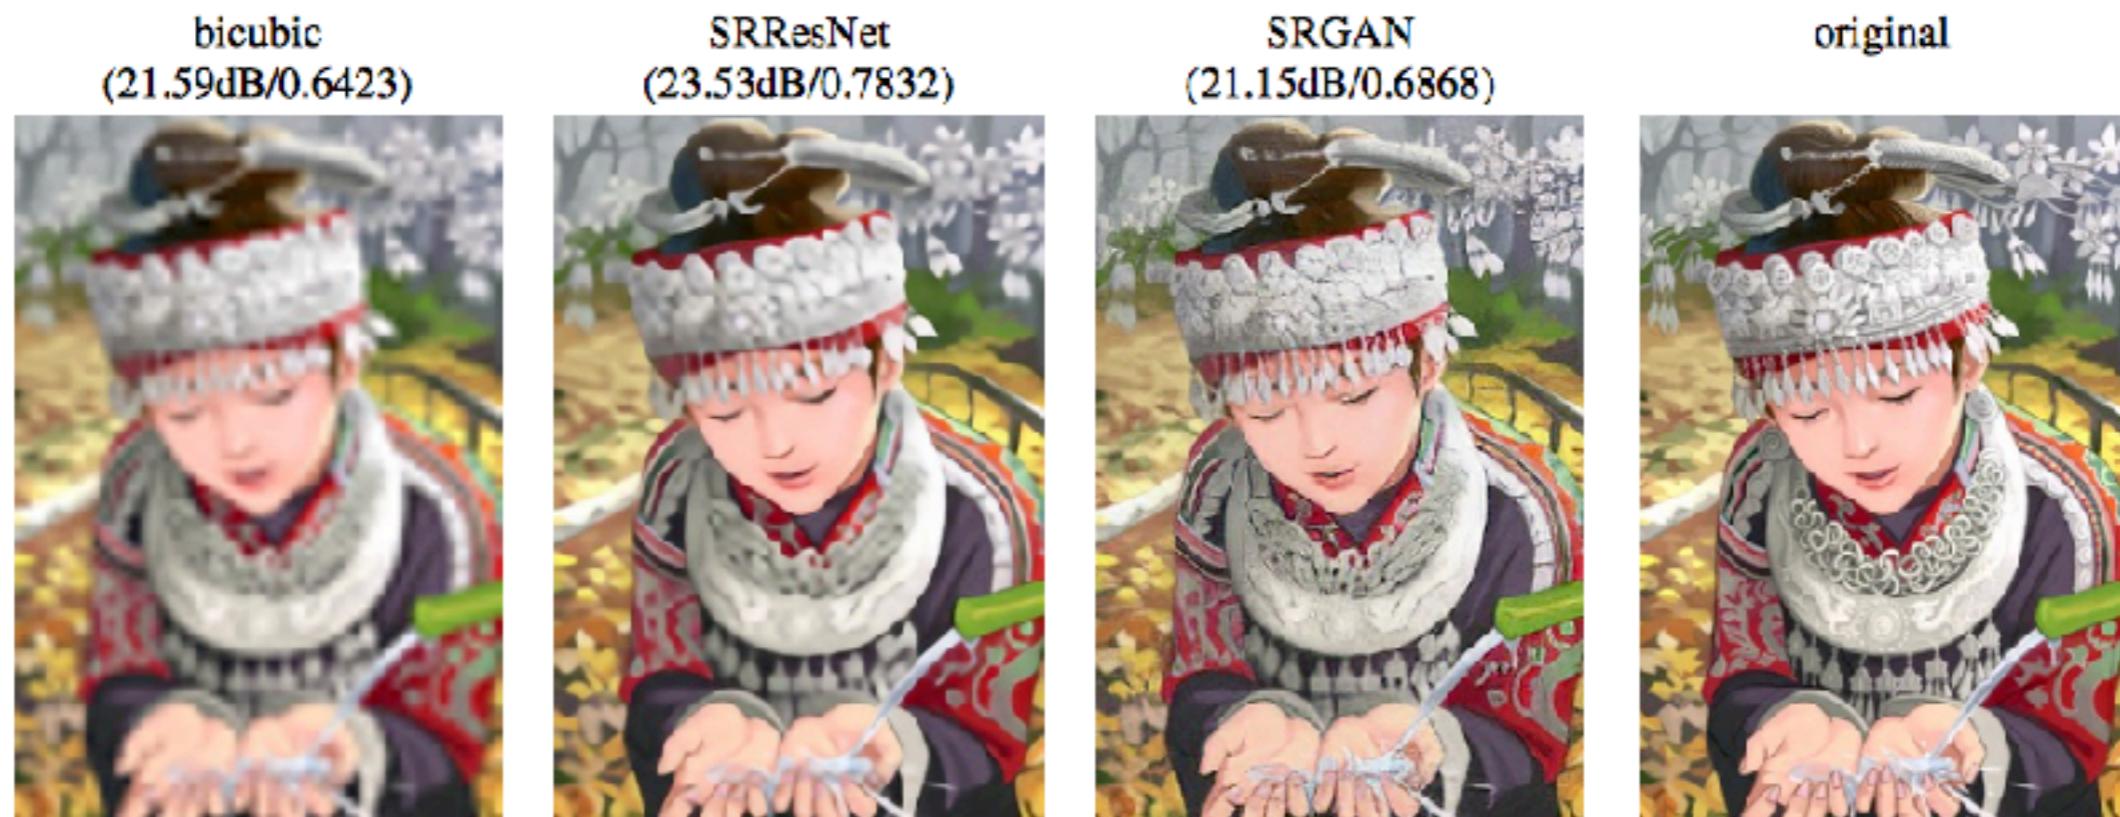
Image to Image Translation

Aplicações



Single Image Super-Resolution

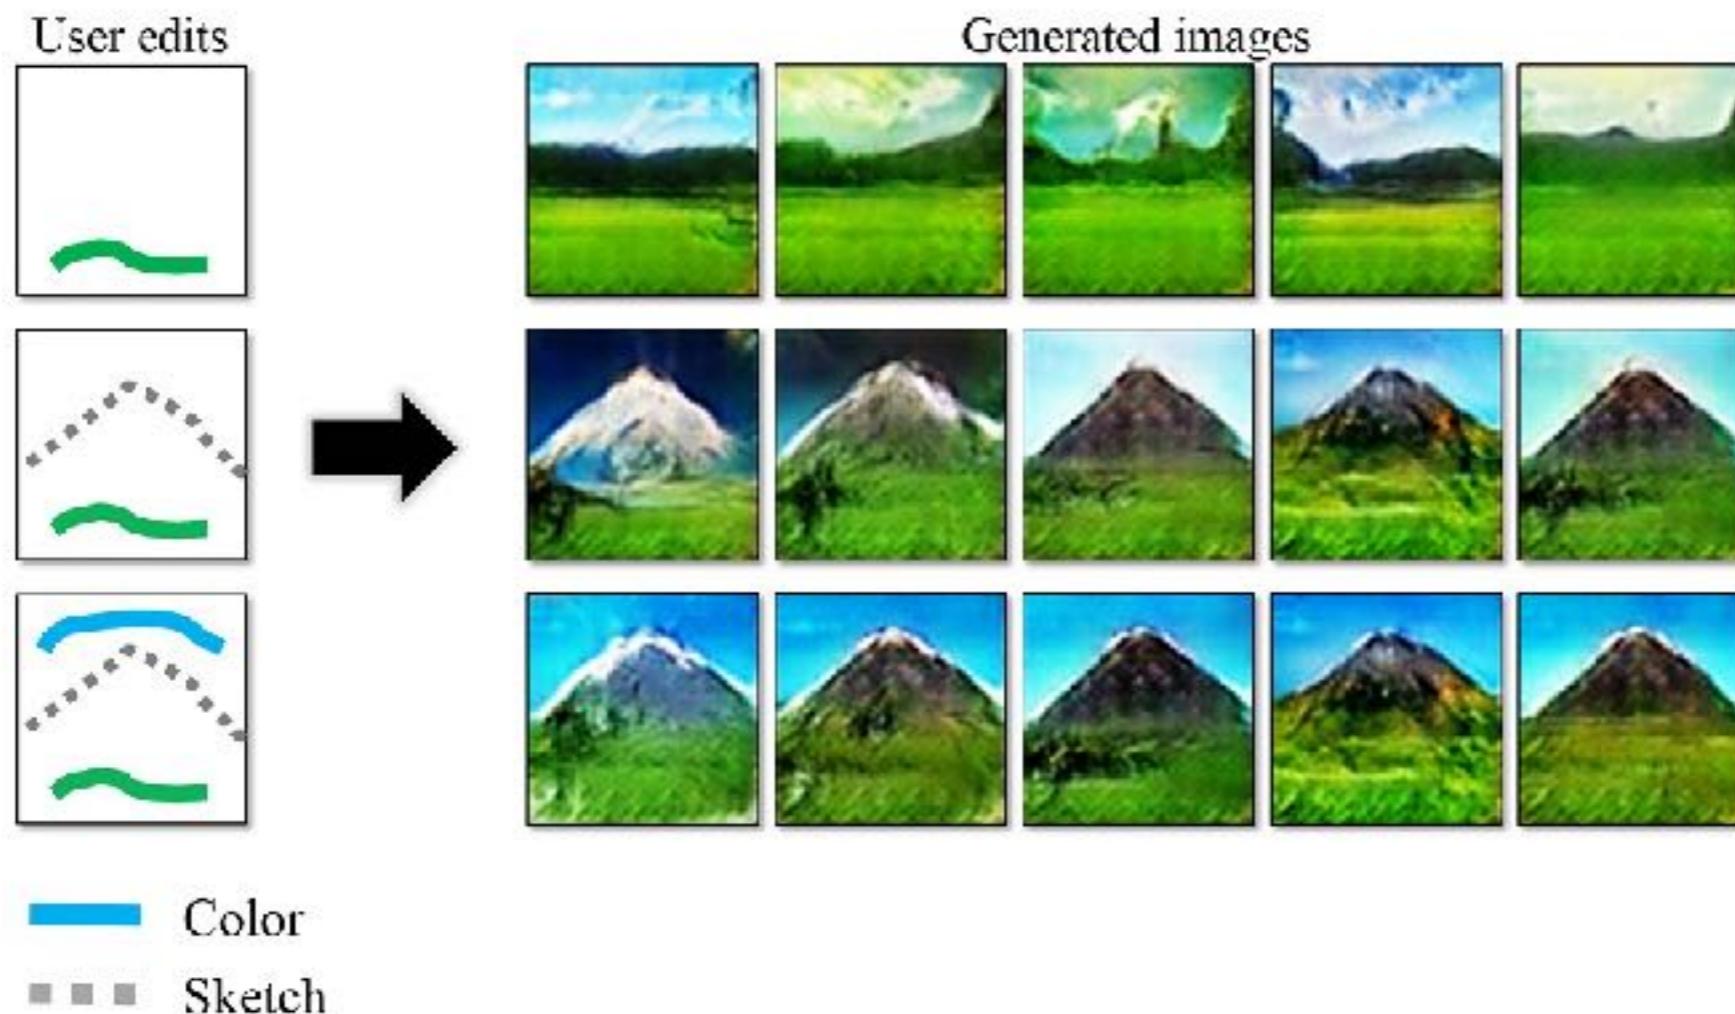
Aplicações



Christian Ledig, Lucas Theis, Ferenc Huszar, Jose Caballero, Andrew Cunningham, Alejandro Acosta, Andrew Aitken, Alykhan Tejani, Johannes Totz, Zehan Wang and Wenzhe Shi, “Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network”

Visual Manipulation

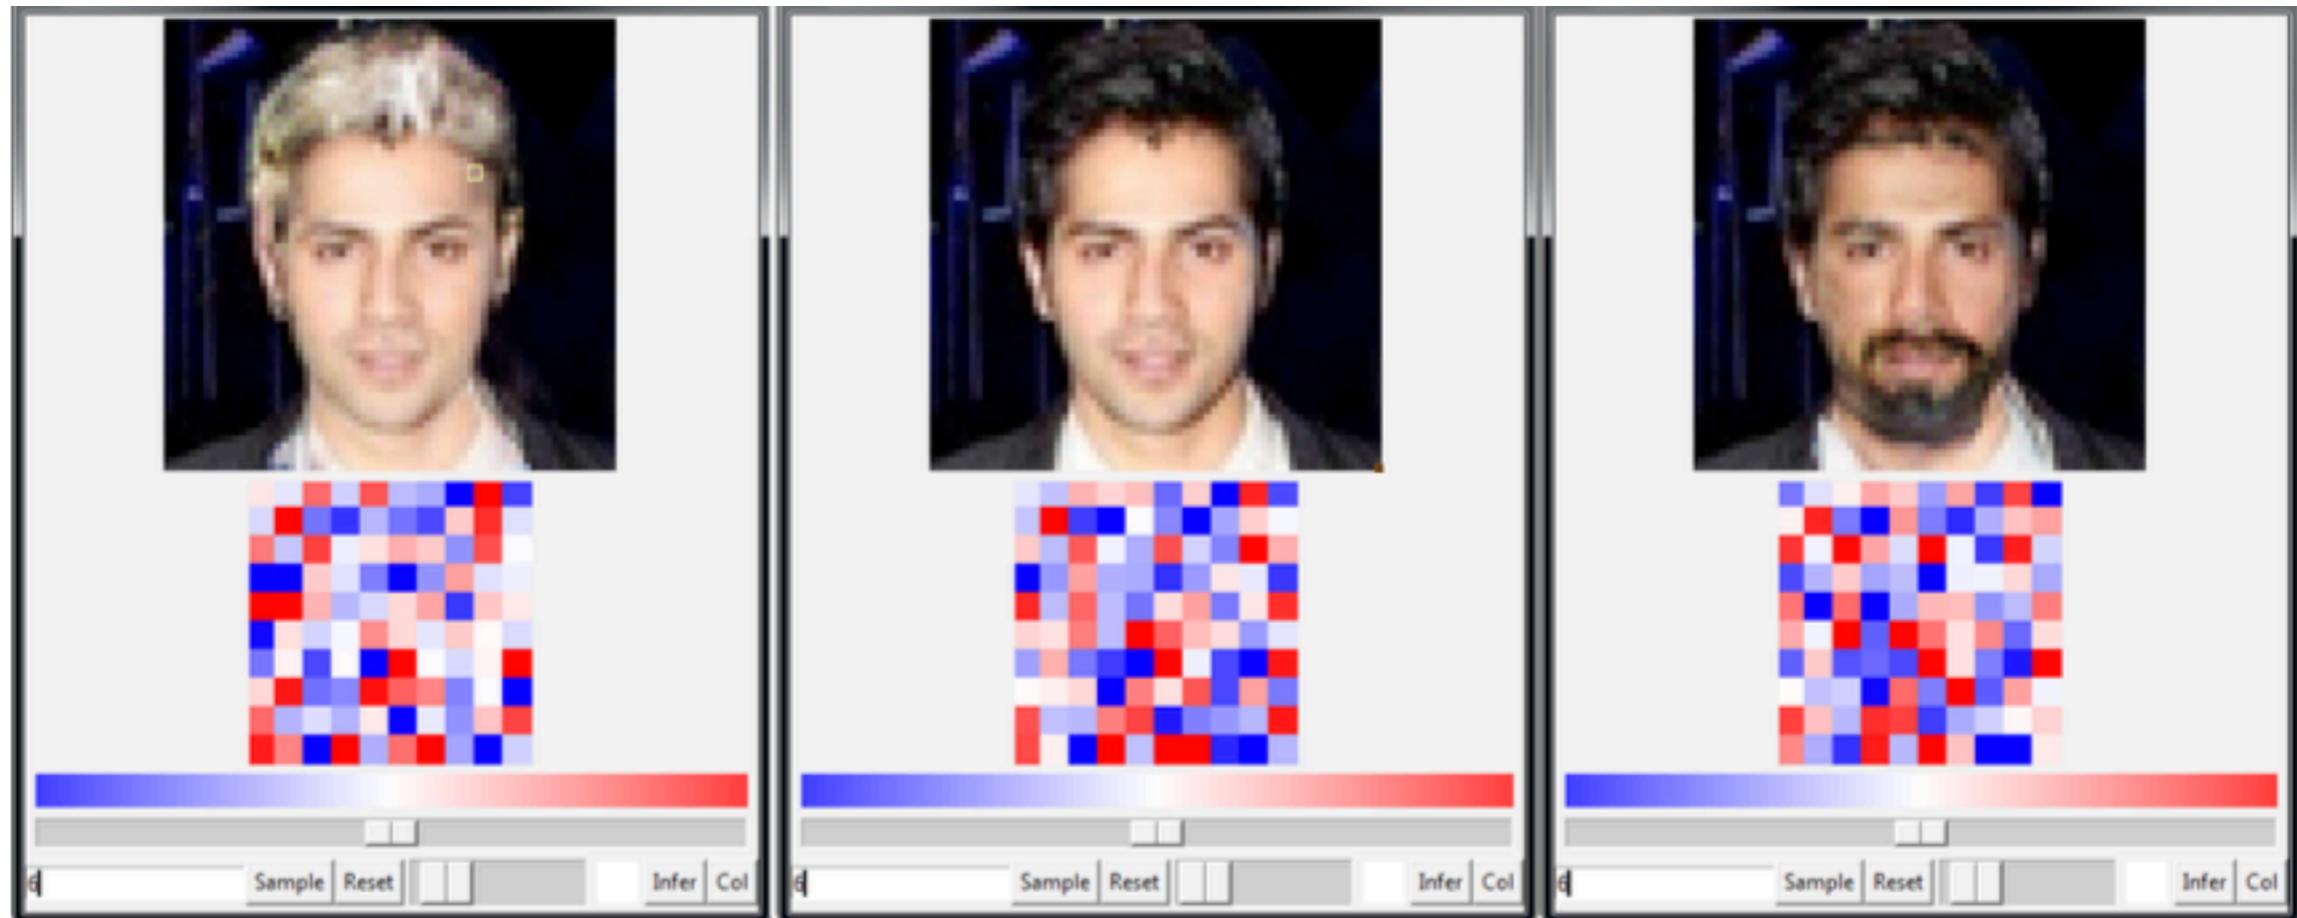
Aplicações



Jun-Yan Zhu, Philipp Krähenbühl, Eli Shechtman and Alexei A. Efros,
“Generative Visual Manipulation on the Natural Image Manifold”

Visual Manipulation

Aplicações



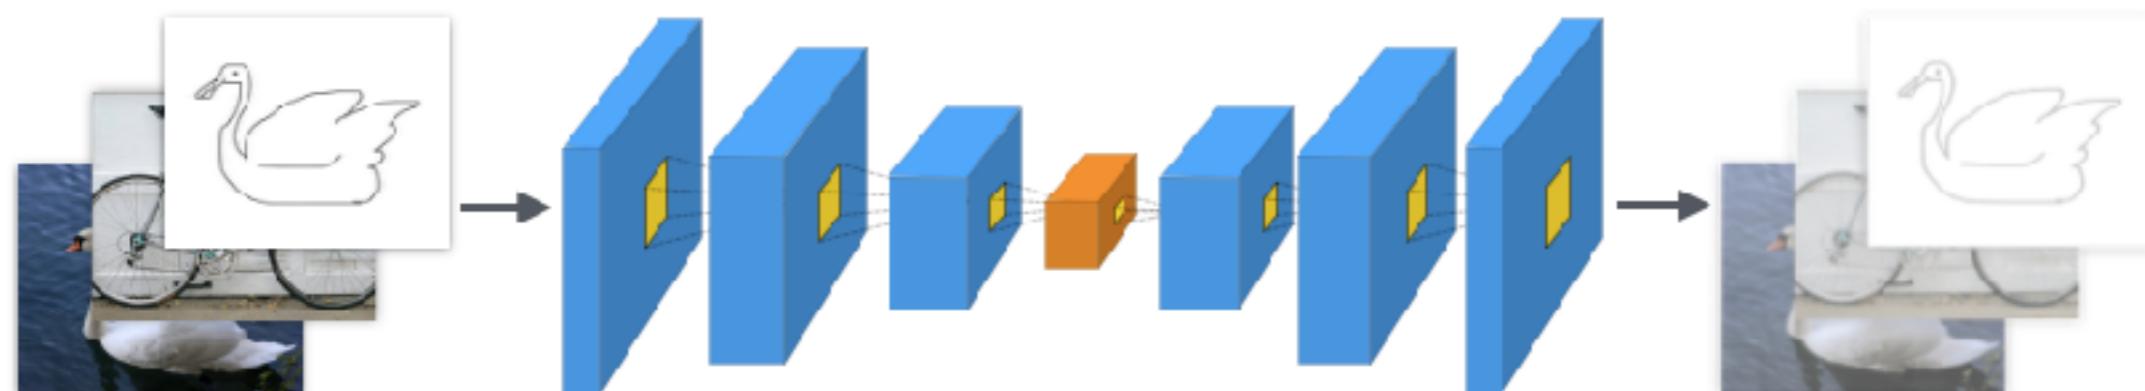
Andrew Brock, Theodore Lim, J.M. Ritchie and Nick Weston, “Neural Photo Editing with Introspective Adversarial Networks”

Aplicações e Diferentes Formulações

Autoencoders

Diagrama de um Autoencoder

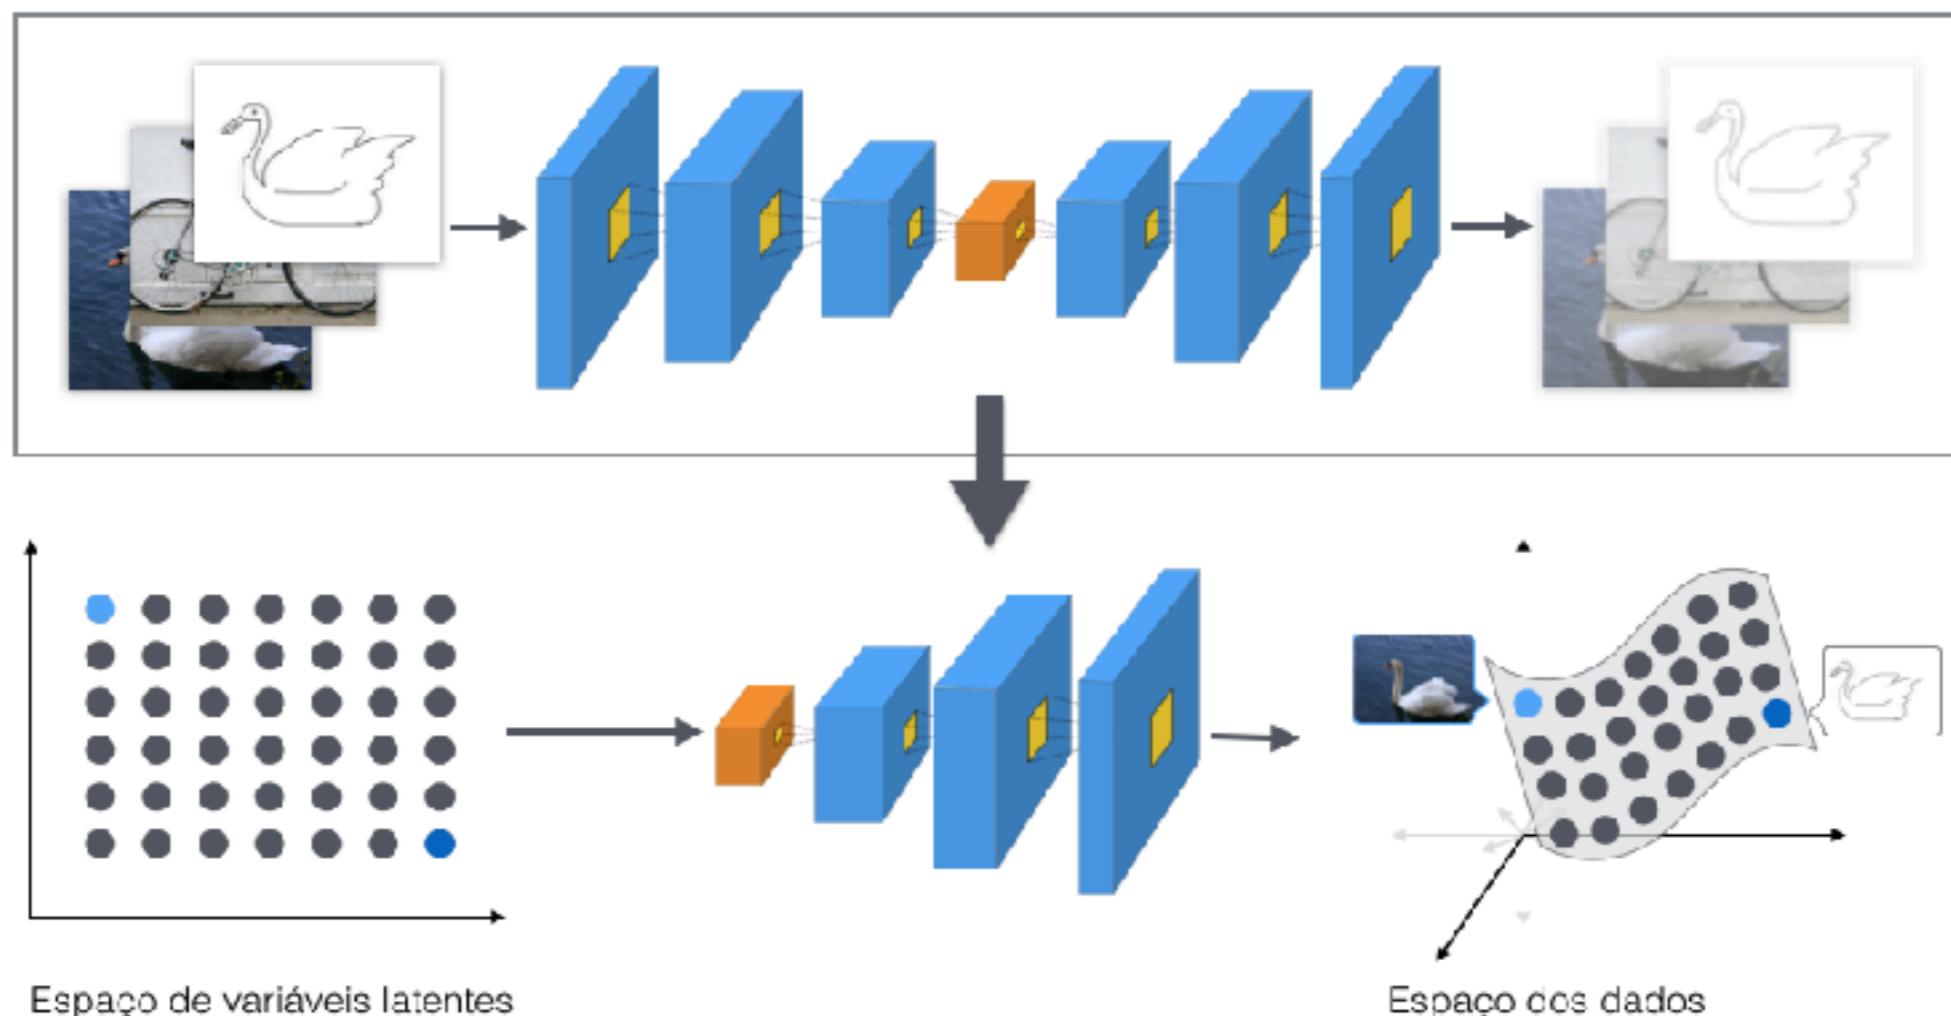
Aplicações



A ideia por trás de um autoencoder é descobrir padrões nos dados de forma **não-supervisionada**

Diagrama de um Autoencoder

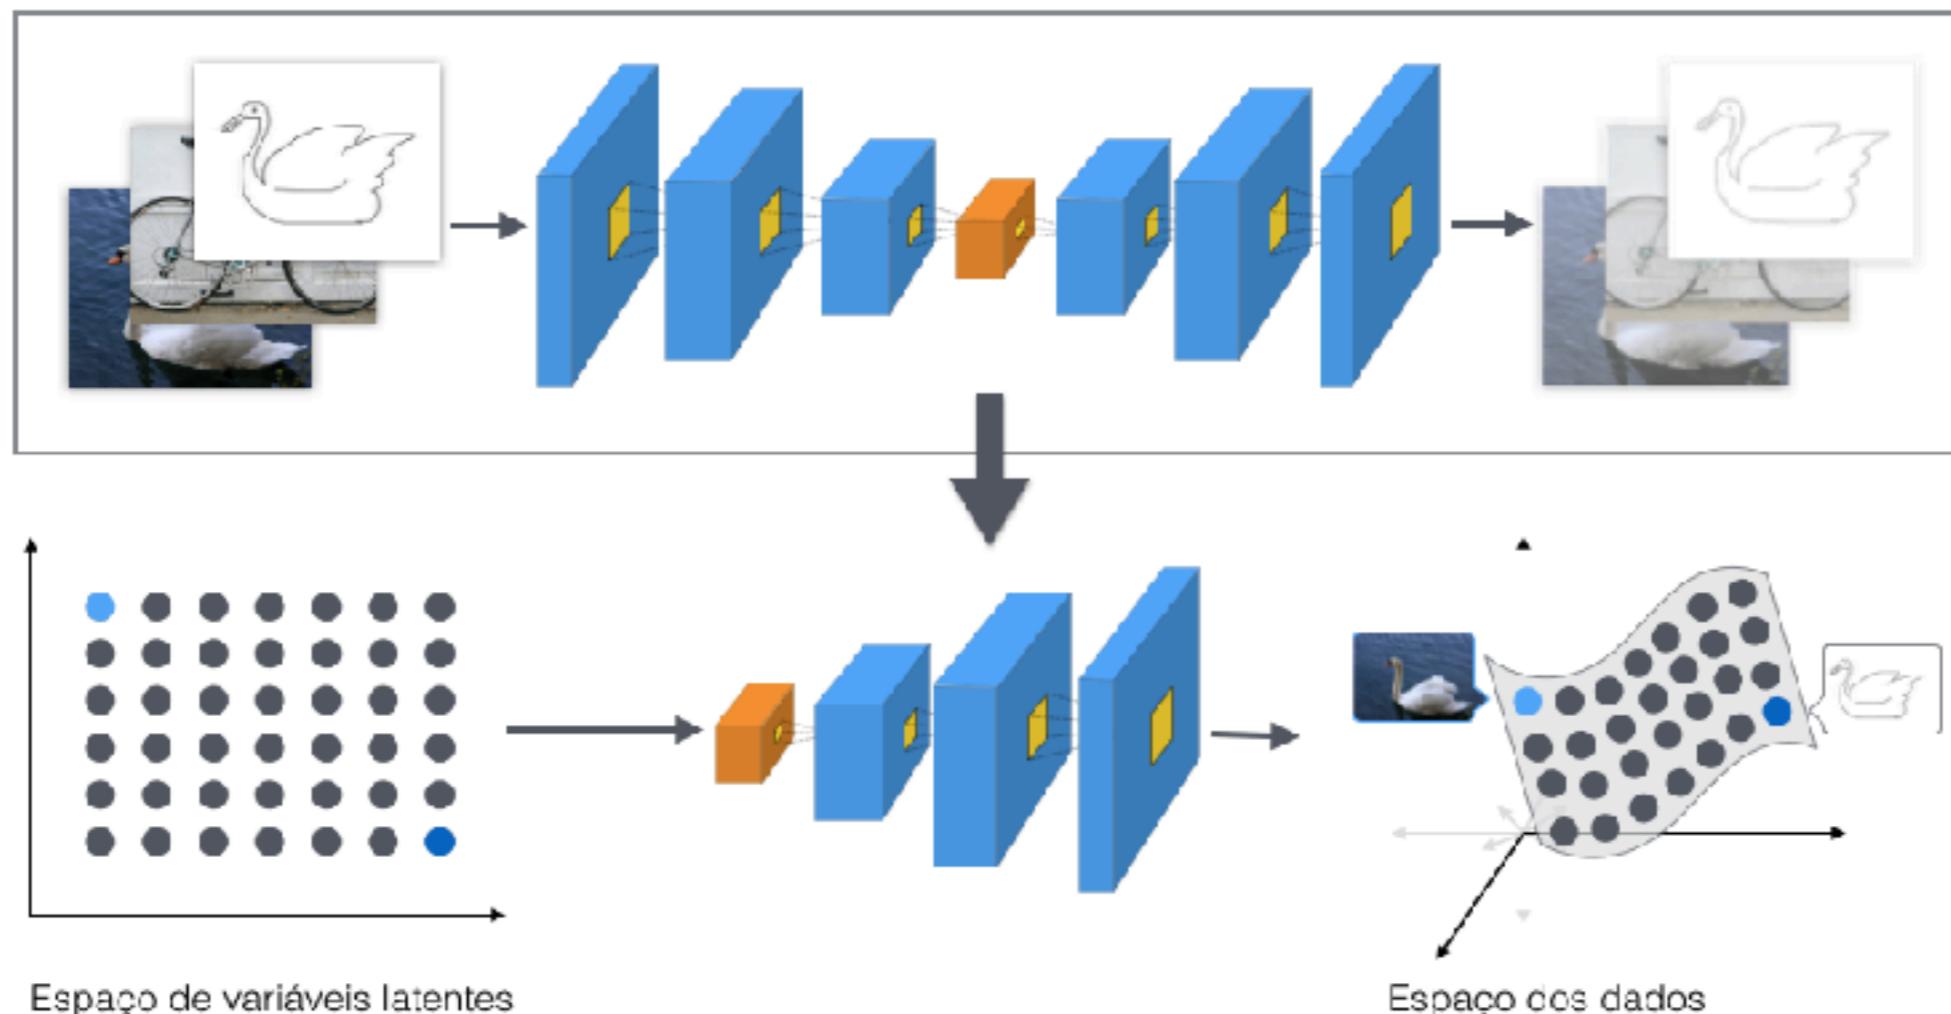
Aplicações



A ideia por trás de um autoencoder é descobrir padrões nos dados de forma **não-supervisionada**

Diagrama de um Autoencoder

Aplicações



A ideia por trás de um autoencoder é descobrir padrões nos dados de forma **não-supervisionada**

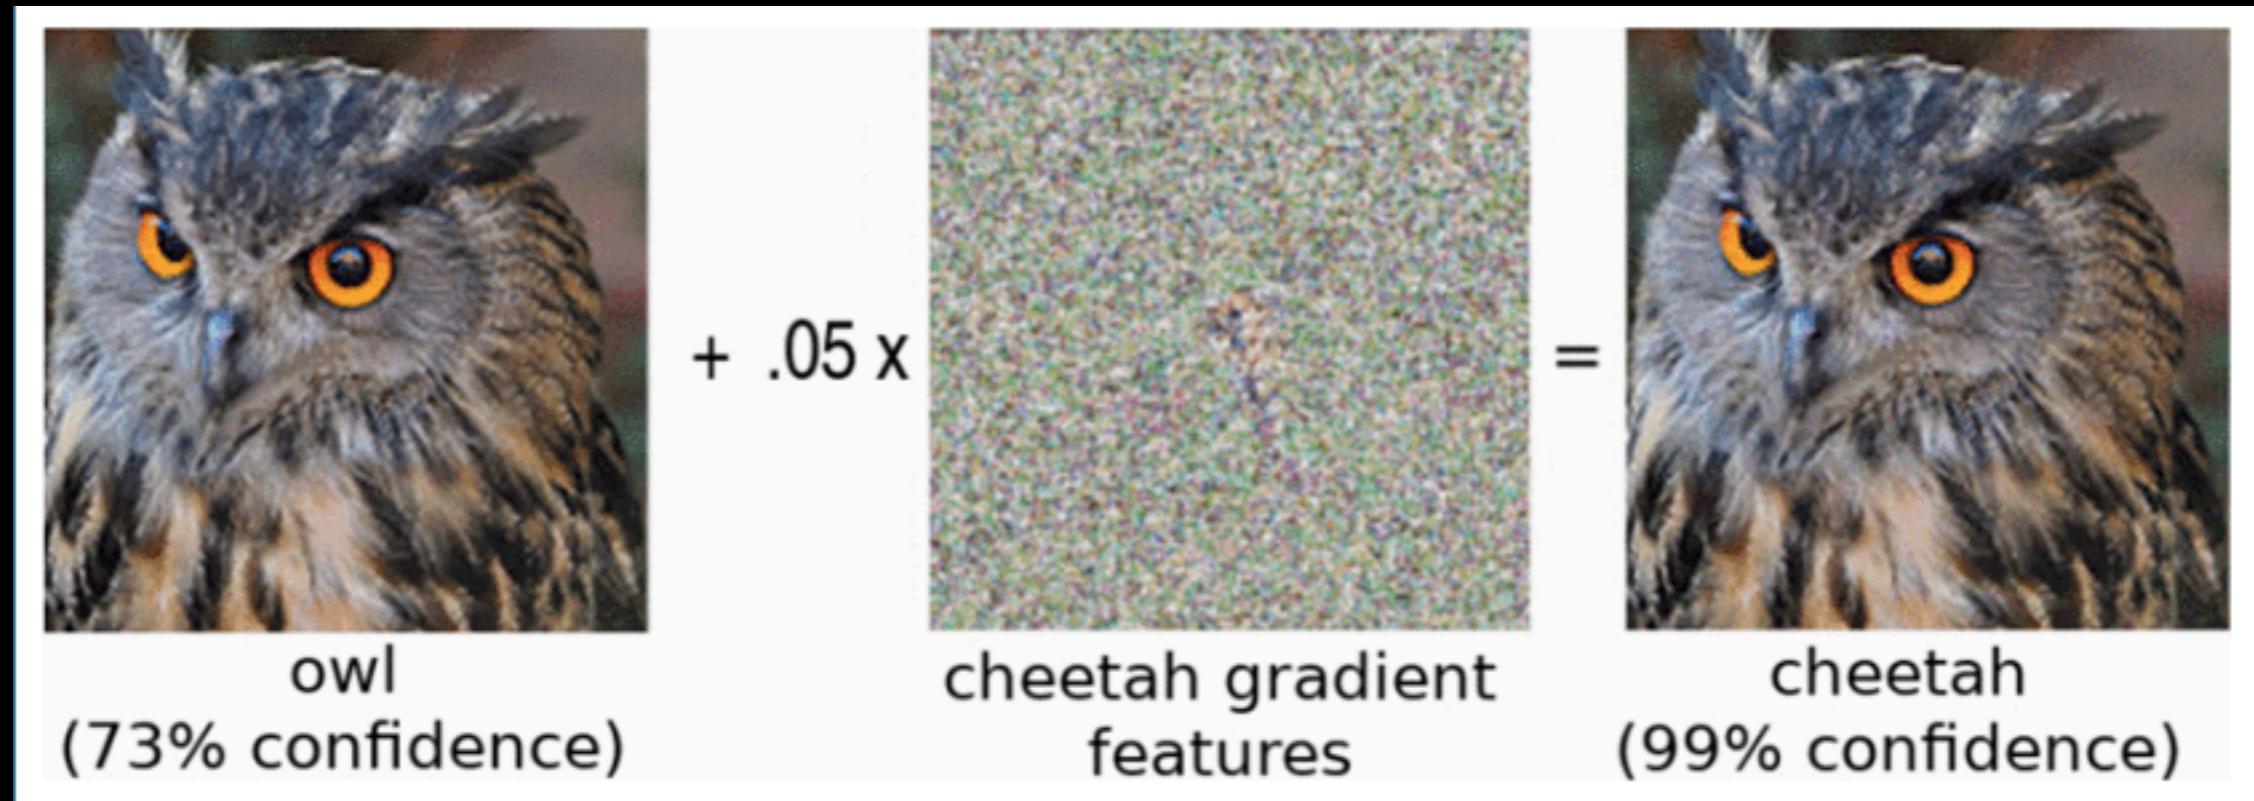
DEMO #4

DEMO #4

O que vocês querem fazer?

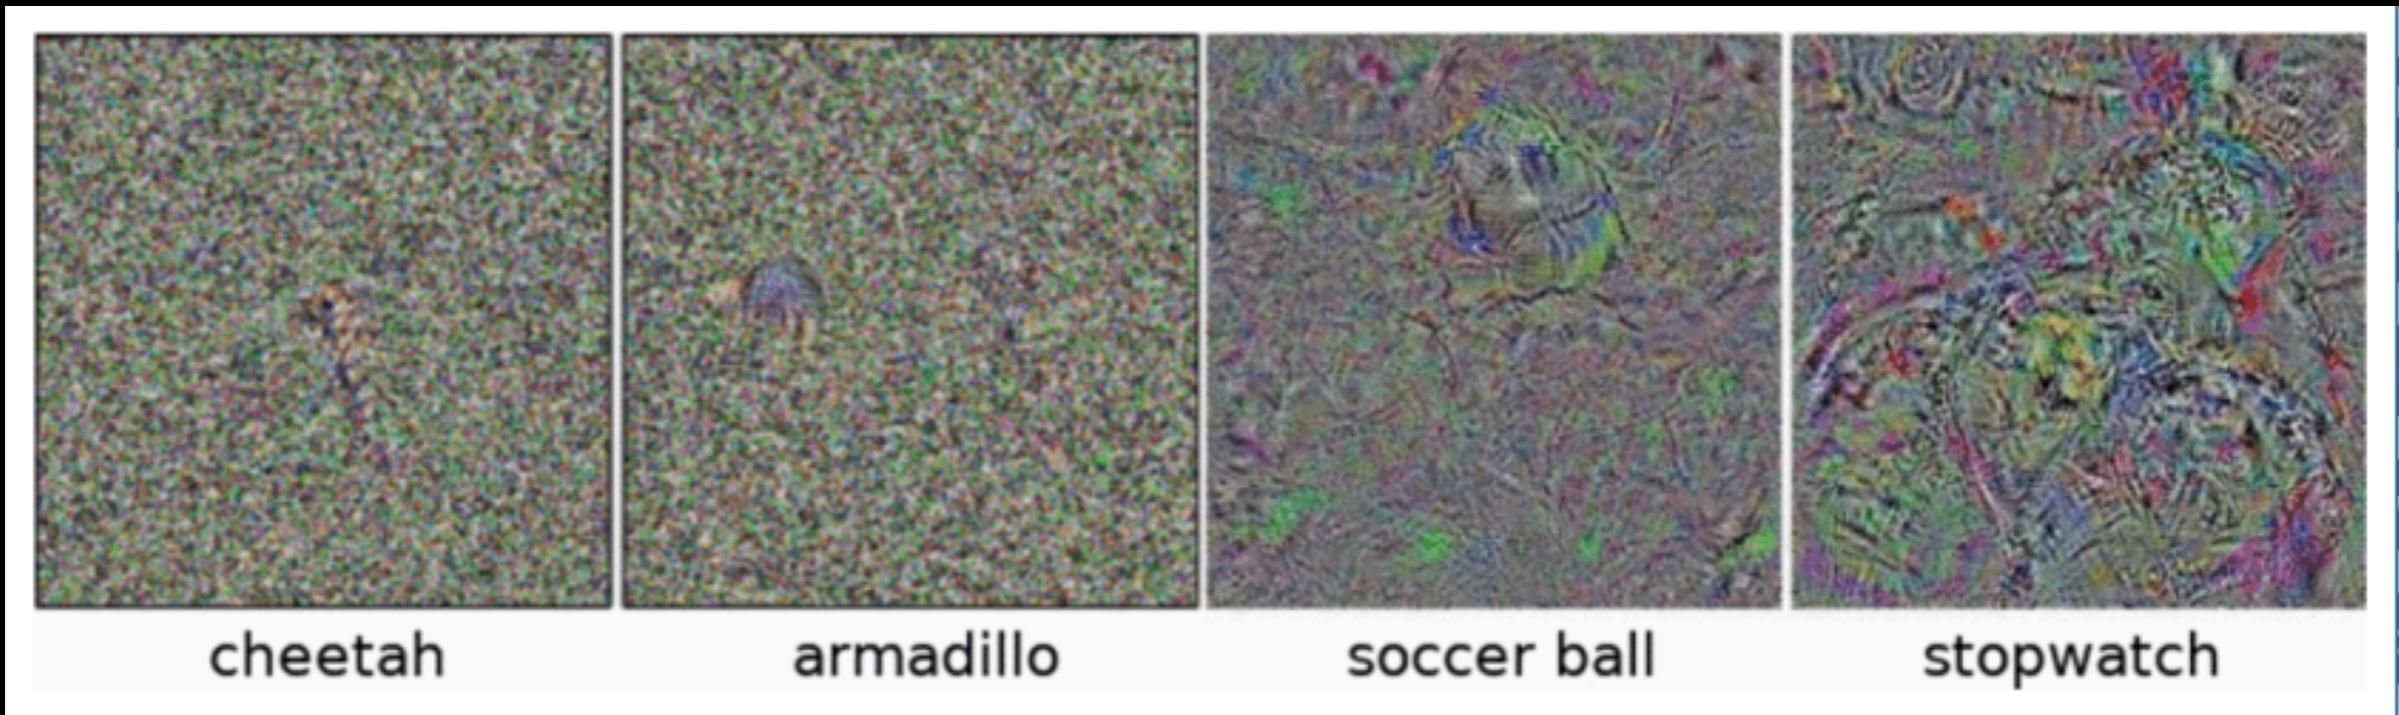
Limitações de Deep Learning e Perigos de Machine Learning

Limitações de Deep Learning e Perigos de Machine Learning



A. Nguyen, J. Yosinski, J. Clune, "Deep neural networks are easily fooled: High confidence predictions for unrecognizable images", IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 427-436, 2015.

Limitações de Deep Learning e Perigos de Machine Learning



A. Nguyen, J. Yosinski, J. Clune, "Deep neural networks are easily fooled: High confidence predictions for unrecognizable images", IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 427-436, 2015.

Limitações de Deep Learning e Perigos de Machine Learning

Model	Random Label	train accuracy	test accuracy
Inception-small	No	100%	85.75%
	Yes	100%	9.78%
Alexnet	No	100%	76.07%
	Yes	99.82%	9.86%
MLP 3x512	No	100%	52.39%
	Yes	100%	10.48%
MLP 1x512	No	100%	50.51%
	Yes	99.34%	10.61%
Inception V3	No	100%	80.38% (84.49%)
	Yes	99.14%	0.56%
Alexnet (2012)	No	-	83.60%

Zhang et al, Understanding Deep Learning Requires Rethinking Generalization

Limitações de Deep Learning e Perigos de Machine Learning

The screenshot shows a news article from The Verge. At the top left, there are three categories: 'WEB' in red, 'APPS' in blue, and 'TECH' in red. The main title of the article is 'FaceApp's creator apologizes for the app's skin-lightening 'hot' filter'. Below the title, it says 'By Lizzie Plaugic | Apr 25, 2017, 9:49am EDT'.

FaceApp's creator apologizes for the app's skin-lightening 'hot' filter

By Lizzie Plaugic | Apr 25, 2017, 9:49am EDT

[https://www.theverge.com/2017/4/25/15419522/
faceapp-hot-filter-racist-apology](https://www.theverge.com/2017/4/25/15419522/faceapp-hot-filter-racist-apology)

Limitações de Deep Learning e Perigos de Machine Learning



<https://www.wired.com/2017/04/courts-using-ai-sentence-criminals-must-stop-now/>

Fim

Perguntas?

Fim

Veja nosso survey paper!

**Everything you wanted to know about Deep Learning for Computer Vision but
were afraid to ask**

<http://conteudo.icmc.usp.br/pessoas/moacir/p17sibgrapi-tutorial/>
<https://goo.gl/CFGMVk>

Perguntas?

Fim

Veja nosso survey paper!

**Everything you wanted to know about Deep Learning for Computer Vision but
were afraid to ask**

<http://conteudo.icmc.usp.br/pessoas/moacir/p17sibgrapi-tutorial/>
<https://goo.gl/CFGMVk>

Agradecimentos:

**Moacir A. Ponti, Tiago S. Nazare, Tu Bui, John Collomosse, Rodrigo Mello
por contribuições para o material e aulas que levaram a sua concepção**

Organizadores do ERI, pela realização do evento e pelo convite

Perguntas?

Muito Obrigado